



ESTADÍSTICA I

Tercero del Grado en Matemáticas

Hugo Marquerie

Profesor: Amparo Baillo Moreno
Facultad de Ciencias - Universidad Autónoma de Madrid
Primer cuatrimestre 2024 - 2025

9 de Septiembre, 2024



Índice

1	Estadística descriptiva	1
1.1	Introducción	1
1.2	Estadísticos de tendencia central	1
1.3	Medidas de dispersión	1
1.4	Representación gráfica de datos	3
1.4.1	Diagrama de caja	3
1.4.2	Histograma	3
1.4.3	Estimadores núcleo o <i>kernel</i>	5
1.5	Estadísticos de asimetría	7
1.6	Análisis exploratorio de datos bivariantes	8
1.6.1	Recta de regresión	8
1.6.2	Coefficiente de correlación lineal	9
2	Muestreo aleatorio	11
2.1	Diferencia probabilidad e inferencia estadística	11
2.2	Conceptos probabilísticos básicos	12
2.2.1	Desigualdades de Markov y Chebyshev	13
2.2.2	Convergencias estocásticas	13
2.3	Población y muestra	15
2.3.1	La función de distribución empírica	17
2.4	Estadísticos de orden	19
3	Estimación puntual paramétrica	23
3.1	Modelos paramétricos e inferencia paramétrica	23
3.2	Estimadores	24
3.2.1	Propiedades interesantes de los estimadores	24
3.3	Estimador de máxima verosimilitud	27
3.3.1	El método de máxima verosimilitud	27
3.3.2	Cálculo efectivo del EMV	28
3.3.3	Motivación del método de máxima verosimilitud	28
3.3.4	Consistencia de los estimadores de máxima verosimilitud	29
3.4	Información de Fisher y cota de Frechet-Cramér-Rao	29

3.5	Comportamiento asintótico de los e.m.v.	32
3.6	El método de los momentos	34
3.7	Estimadores bayesianos	35
3.7.1	La distribución a priori	35
3.7.2	La distribución a posteriori	36
3.7.3	Familias conjugadas	37
4	Tema 4	39
5	Contraste de hipótesis	41
5.1	Planteamiento del problema. Conceptos básicos	41
5.2	Contrastes para la media de una distribución	43
6	Ejercicios	47
6.1	Hoja 1: Estadística descriptiva	47
6.2	Hoja 2: Muestreo aleatorio	60
6.3	Hoja 3: Estimación Puntual	67
6.4	Intervalos de confianza	74

1. Estadística descriptiva

1.1 Introducción

A partir de una población o variable aleatoria X con distribución de probabilidad P_X desconocida (y otra información), analizamos una muestra aleatoria $x_1, x_2, \dots, x_n$ de X con el objetivo de estimar P_X .

Ejemplo 1.1.1. Sea $X =$ proporción de grasa en una hamburguesa del macas, y P_X la distribución de X . Tenemos 10 individuos y medimos la proporción de grasa en cada uno de ellos. La muestra es $x_1, x_2, \dots, x_{10}$.

Un primer objetivo natural es resumir la información proporcionada por estos datos.

1.2 Estadísticos de tendencia central

Definición 1.2.1 (Media). Sea $x_1, x_2, \dots, x_n$ una muestra aleatoria de X , $\bar{x}$ es la media muestral $\iff \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$

Definición 1.2.2 (Mediana). Sea $x_1, x_2, \dots, x_n$ una muestra aleatoria de X , m es la mediana muestral $\iff m = \begin{cases} x_{(n+1)/2} & \text{si } n \text{ es impar} \\ x \in (x_{n/2}, x_{n/2+1}) & \text{si } n \text{ es par} \end{cases}$

Observación 1.2.1. • La media es sensible a valores extremos o *outliers* (no robusta).

- La mediana no es tan sensible a valores extremos (robusta).
- Si la muestra es simétrica, la media y la mediana coinciden.
- Si la muestra es asimétrica hacia la derecha, la media es mayor que la mediana.

1.3 Medidas de dispersión

Nuestra muestra $x_1, x_2, \dots, x_n$ puede estar más o menos concentrada alrededor de la media. Si está muy concentrada, la medida de posición (media, mediana) resume muy bien la información de la muestra. Si la muestra tiene alta variabilidad, la medida de posición no es muy buen descriptor. Por ello, necesitamos medidas de dispersión respecto a la media.

Observación 1.3.1. Sea una muestra $x_1, x_2, \dots, x_n$ de la v.a. X , la media muestral, $\bar{x}$, en el fondo es la esperanza de una v.a. discreta que da probabilidad $1/n$ a cada observación de la muestra. Es una **medida empírica** de la esperanza de X .

De la misma manera que la media muestral es una medida empírica de la esperanza de X , la varianza muestral es una medida empírica de la varianza de X .

Definición 1.3.1 (Varianza muestral). Sea $x_1, x_2, \dots, x_n$ una muestra aleatoria de X , s_n^2 es la varianza muestral de la distribución empírica

$$\begin{aligned} \iff s_n^2 &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \text{ (sesgada)} \quad \vee \quad s_n^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \text{ (insesgada)} \\ \implies \boxed{s_n^2} &= \frac{1}{n} \sum_{i=1}^n \left(x_i - \frac{1}{n} \sum_{j=1}^n x_j \right)^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 \end{aligned}$$

La varianza se mide en unidades al cuadrado de la variable. A veces conviene trabajar con la desviación típica (s_n), que es la raíz cuadrada de la varianza y se mide en las mismas unidades que la variable.

Teorema 1.3.1 (Desigualdad de Chebyshev). Sea X una v.a. con media μ y varianza σ^2

$$\implies \forall k > 0 : P(|X - \mu| > k\sigma) \leq \frac{1}{k^2}$$

Es decir, al aplicarlo a la Estadística, la proporción de observaciones de la muestra que distan de $\bar{x}$ en más de ks_n debería ser a lo sumo $1/k^2$.

Por ejemplo, $k = 4 \implies ks_n = 2s_n$ y un 75% de las observaciones de la muestra deberían estar en el intervalo $[\bar{x} - 2s_n, \bar{x} + 2s_n]$.

Definición 1.3.2 (Cuartiles y cuantiles). Sea $x_1, x_2, \dots, x_n$ una muestra aleatoria de X , Q_1 es el primer **cuartil** de la muestra y deja el 25% de las observaciones a la izquierda y el 75% a la derecha. Q_2 es la mediana y Q_3 es el tercer cuartil que deja el 75% de las observaciones a la izquierda y el 25% a la derecha.

En general, $\forall p \in (0, 1) :$ el **cuantil** p de la muestra es el valor $x_{(j)}$ que deja una proporción p de las observaciones a la izquierda y $1 - p$ a la derecha.

Hay varios métodos para calcular los cuantiles muestrales. Todos hacen una media ponderada de dos observaciones consecutivas $x_{(j)}$ y $x_{(j+1)}$ de la muestra ordenada que aproximadamente dejan una proporción p de los datos “a la izquierda”.

Para tamaños muestrales grandes, los resultados de todos los métodos son parecidos.  es el programa que ofrece un mayor número (9) de maneras de calcular los cuantiles: el método por defecto es `type = 7`, en el que:

$$\forall p \in (0, 1) : q_p = (1 - m)x_{(j)} + mx_{(j+1)} \quad \text{donde } m = \text{frac}(p(n - 1)) \wedge j = \lfloor p(n - 1) \rfloor + 1$$

1.4 Representación gráfica de datos

1.4.1 Diagrama de caja


Definición 1.4.1 (Rango intercuartílico). Sea $x_1, x_2, \dots, x_n$ una muestra aleatoria de X , el rango intercuartílico es la diferencia entre el primer y el tercer cuartil $RI = Q_3 - Q_1$.

Si separamos los datos ordenados en cuatro grupos con el mismo número de observaciones, el RI mide la distancia entre los dos grupos más extremos. Es una medida de dispersión robusta respecto a la mediana.

Para visualizar estas medidas de dispersión respecto a la mediana se utiliza el diagrama de caja (*box plot*). Para construir el diagrama de caja de la muestra, calculamos Q_1, Q_2, Q_3, RI y los límites inferior y superior del diagrama.

$$\begin{cases} LI = \text{La menor observación de la muestra en } [Q_1 - 1.5 \cdot RI, Q_3 + 1.5 \cdot RI] \\ LS = \text{La mayor observación de la muestra en el mismo intervalo} \end{cases}$$

En , se puede construir un diagrama de caja con el comando `boxplot`. Si le asignamos a una variable `B = boxplot(x)` podemos acceder a los valores de los cuantiles con `B$stats`.



1.4.2 Histograma

El diagrama de caja se utiliza para variables cuantitativas continuas (toman valores en un intervalo). No se usan para variables discretas. El histograma también se utiliza para variables

cuantitativas continuas, pero no se basa en cuartiles, sino en la frecuencia de los datos.

Sea X una v.a. continua con función de densidad f_X ($f \geq 0 \wedge \int_{\mathbb{R}} f(x) dx = 1$).

Esta f es habitualmente desconocida en la práctica y se estima a partir de una muestra aleatoria de X .

Sea $x_1, x_2, \dots, x_n$ una muestra aleatoria de X y $\dots < a_i^{(n)} < a_{i+1}^{(n)} < \dots$ una sucesión con $h_n = a_{i+1}^{(n)} - a_i^{(n)}$. La idea es dividir el espacio muestral de X en intervalos de tamaño h . Tenemos que $\forall A \subset \mathbb{R} : \mathbb{P}\{X \in A\} = \int_A f(x) dx$.


$$\begin{aligned} \implies \forall x \in \mathbb{R} : \mathbb{P}\left\{X \in \left(x - \frac{h}{2}, x + \frac{h}{2}\right)\right\} &= \int_{x-h/2}^{x+h/2} f(x) dx \approx f(x)h \\ \implies \forall x \in \mathbb{R} : f(x) &\approx \frac{1}{h} \mathbb{P}\left\{X \in \left(x - \frac{h}{2}, x + \frac{h}{2}\right)\right\} \end{aligned}$$

La idea del histograma y otros indicadores de la densidad es:

$$f(x) \approx \frac{1}{nh} \left| \left\{ i : x_i \in \left(x - \frac{h}{2}, x + \frac{h}{2}\right) \right\} \right| = \frac{1}{nh} \sum_{i=1}^n \mathbb{1}_{(x-\frac{h}{2}, x+\frac{h}{2})}(x_i)$$

Si el histograma es una aproximación de la densidad, debería integrar 1 y por supuesto ser no negativo. Para que  lo haga automáticamente, se puede usar el comando `hist`. Sin embargo, en el eje de las ordenadas no se representan las densidades, sino las frecuencias relativas. Para que se representen las densidades, se puede usar el argumento `freq = FALSE`.

La elección del tamaño de los intervalos es importante. Si son muy grandes, perdemos información. Si son muy pequeños, el histograma pierde robustez. Por norma general, $h = \frac{1}{\sqrt{n}}$ es una buena elección.



1.4.3 Estimadores núcleo o *kernel*

Existen otras formas de visualizar la distribución de datos:

$$\hat{f}_n(t) = \frac{1}{n2h_n} \sum_{i=1}^n \mathbb{1}_{(t-h_n, t+h_n)}(x_i) = \frac{1}{nh_n} \sum_{i=1}^n \underbrace{\frac{1}{2} \mathbb{1}_{(-1,1)}}_{\text{Núcleo uniforme}} \left(\frac{t-x_i}{h_n} \right)$$

Se puede generalizar este procedimiento (método de ventana móvil o *moving window method*) reemplazando la densidad uniforme $\mathbb{1}_{(-1,1)}/2$ por otra función de densidad K (llamada *kernel* o núcleo). Un ejemplo típico es $K(t) = \frac{1}{\sqrt{2\pi}} e^{-t^2/2}$ (núcleo gaussiano). Obtenemos entonces el estimador *kernel*:

$$\hat{f}_n(t) = \frac{1}{nh_n} \sum_{i=1}^n K\left(\frac{t-x_i}{h_n}\right) = \frac{1}{nh_n} \sum_{i=1}^n \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{t-x_i}{h_n}\right)^2}$$

que es una versión “suavizada” del histograma y $\hat{f}_n(t)$ es una función de densidad.

En , se puede obtener con el comando `density`.

Definición 1.4.2 (Convolución). Sean $f, g : \mathbb{R} \rightarrow \mathbb{R}$, la convolución de f y g es

$$f * g(x) := \int_{\mathbb{R}} f(x-t)g(t) dt$$

La convolución hereda propiedades de “suavidad” de f y g .

Recordamos que en Probabilidad I estudiamos la convolución de dos funciones de densidad de v.a. independientes para calcular la función de densidad de la suma de las v.a.

- Si V y W son v.a. continuas independientes con funciones de densidad f_V y f_W , entonces la función de densidad de $V + W$ es $f_V * f_W$.
- Si V y W son v.a. discretas independientes con funciones de masa p_V y p_W , entonces la función de masa de $V + W$ es $p_V * p_W$.

En este sentido se puede ver el estimador núcleo como una convolución de la función de densidad de la v.a. con un núcleo. Estimador núcleo:

$$\hat{f}_n(t) = \frac{1}{n} \sum_{i=1}^n K_h(t-x_i) = \sum_{i=1}^n K_h(t-x_i) \frac{1}{n} = \sum_{i=1}^n K_h(t-x_i) \mathbb{F}_n(x_i) = K_h * \mathbb{F}_n(t)$$

donde $\mathbb{F}_n$ es la **función de distribución empírica** de la muestra (función de masa de una v.a. discreta que da peso $1/n$ a cada elemento de la muestra $x_1, \dots, x_n$).

Además $K_h(x) = \frac{1}{h} K\left(\frac{x}{h}\right)$ es el **núcleo reescalado** y h es el **parámetro de suavizado**.

Es decir, el estimador núcleo es la función de densidad de la v.a. $Z_h + X^*$, donde Z_h es

una v.a. continua con función de densidad K_h y X^* es una v.a. discreta con distribución empírica.


Para generar una observación de la densidad $\hat{f}_n$, generamos una observación de F_n, X^* y generamos una observación de K_h, Z_h y sumamos esas observaciones ($X^* + Z_h$).

En concreto, si K es la densidad de $N(0, 1)$, entonces K_h es la densidad de $N(0, h)$.

$$\forall t \in \mathbb{R} : K(t) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}t^2} \implies K_h(t) = \frac{1}{\sqrt{2\pi h}} e^{-\frac{1}{2}\left(\frac{t}{h}\right)^2}$$

Una observación de $\hat{f}_n$ sigue la distribución de $X^* + hZ$, donde $Z \sim N(0, 1)$ y X^* es la variable aleatoria discreta que da peso $1/n$ a cada observación de la muestra.

De esta manera, al graficar el estimador núcleo, se obtiene una función de densidad suavizada que se ajusta a la distribución de los datos, una versión más suave del histograma.




Observamos un máximo en $x \approx 25$ que se denomina la **moda** de la distribución. La moda es el valor de la variable que más se repite en la muestra o el máximo de la función de densidad y se considera una medida de posición.

1.4.3.1 Elección de los parámetros

La elección del núcleo no afecta a las propiedades (como el aspecto general) del estimador núcleo, aunque sí a su diferenciabilidad, por ejemplo.

Lo que sí afecta al grado de aproximación del estimador núcleo a la densidad poblacional es el tamaño de la ventana h . Si h es muy pequeño, el estimador núcleo es muy variable y pierde robustez. Si h es muy grande, el estimador núcleo pierde precisión y no se ajusta a la distribución de los datos.



1.5 Estadísticos de asimetría

El tercer momento respecto de la media: $\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3$ da una medida natural de la asimetría de los datos en torno a su media. Para obtener una medida adimensional podemos dividir por la desviación típica al cubo.

Definición 1.5.1 (Coeficiente de asimetría). Sea $x_1, x_2, \dots, x_n$ una muestra aleatoria de X , el coeficiente de asimetría de la distribución empírica es

$$\frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{s_n^3} = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s_n} \right)^3$$

Si la distribución es simétrica, el coeficiente de asimetría es 0. Si la distribución es asimétrica hacia la derecha, el coeficiente de asimetría es positivo.

- Si el coeficiente de asimetría $\in [-0.5, 0.5]$, la distribución es aproximadamente simétrica.
- Si el coeficiente de asimetría en valor absoluto $\in (0.5, 1]$, la distribución es moderadamente asimétrica.
- Si el coeficiente de asimetría en valor absoluto > 1 , la distribución es marcadamente asimétrica.

Hasta ahora hemos hecho estadística descriptiva de una variable univariante, es decir, $x_1, \dots, x_n$ observaciones de una v.a. X con dimensión 1.

El siguiente paso natural es considerar una muestra $x_1, \dots, x_n$ de un vector aleatorio $\mathbb{X} = (X_1, \dots, X_p)$ formado por p v.a.'s cuantitativas. En este contexto hay varios problemas de interés. Por ejemplo, estudiar el tipo de dependencia (si existe) entre las componentes del vector $\mathbb{X}$ o también puede haber una componente que queremos describir en términos

de las restantes. (Cuando la variable respuesta y las explicativas son cuantitativas, se llama regresión lineal de la respuesta sobre las explicativas). A esta respuesta Y se le llama variable dependiente y a las explicativas $X_1, \dots, X_p$ se les llama variables independientes o regresores.

1.6 Análisis exploratorio de datos bivariantes

En este caso nos interesa un vector bivalente (X, Y) donde X es la variable independiente e Y la respuesta. Quiero describir Y en función de X es decir, encontrar g tal que $Y \approx g(X)$.

La función de regresión m es la función g que minimiza el error cuadrático

$$E[(Y - g(X))^2 | X = x]$$

Se puede demostrar que la función de regresión de Y sobre $X = x$ es $m(x) = E[Y | X = x]$. El problema es que no conocemos la distribución de probabilidad de (X, Y) pero se tiene una muestra aleatoria de ese vector $(x_1, y_1), \dots, (x_n, y_n)$.

1.6.1 Recta de regresión

Para simplificar suponemos g lineal, es decir, $g(x) = a + bx$. Entonces buscamos la recta que minimiza el error cuadrático medio, pero como tampoco sabemos cuál es la esperanza condicionada, debemos usar una aproximación.

$$E[(Y - (a + bX))^2 | X = x] \approx \frac{1}{n} \sum_{i=1}^n (y_i - (a + bx_i))^2$$

La recta de regresión de y sobre x basada en los datos $(x_1, y_1), \dots, (x_n, y_n)$ coincide con la recta de ajuste por mínimos cuadrados con ecuación $y = a + bx$. Los valores a y b se obtienen minimizando la suma de cuadrados de distancias verticales de los puntos a la recta.

$$\Rightarrow \hat{b} = \frac{s_{X,Y}}{s_X^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad \wedge \quad \hat{a} = \bar{y} - \hat{b}\bar{x}$$

donde $s_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \left(\sum_{i=1}^n x_i^2 \right) - \bar{x}^2$ es la varianza muestral de X y

$s_{x,y} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{n} \left(\sum_{i=1}^n x_i y_i \right) - \bar{x}\bar{y}$ es la covarianza muestral entre X e Y .

La recta de regresión pasa por el punto $(\bar{x}, \bar{y})$ y, por tanto, es poco robusta.

$\hat{b}$ es el **coeficiente de regresión lineal** de y sobre x o el parámetro de la regresión.

La recta de ecuación $\hat{y} = \hat{a} + \hat{b}x$ se denomina recta de regresión de y sobre x . El valor

pronosticado o previsto de y dado $x = x_i$ es $\hat{y}_i = \hat{a} + \hat{b}x_i$. Los valores $e_i = y_i - \hat{y}_i$ se denominan residuos. Obsérvese que $\hat{a}$ y $\hat{b}$ han sido seleccionados para minimizar la suma de cuadrados residuales $\sum_{i=1}^n e_i^2$. Nótese también que $\bar{e} = \frac{1}{n} \sum_{i=1}^n e_i = 0$. Una manera de medir el “error cuadrático” cometido en la aproximación dada por la recta de regresión es mediante la llamada **varianza residual**:

$$s_R^2 = \frac{1}{n-2} \sum_{i=1}^n e_i^2.$$

1.6.2 Coeficiente de correlación lineal

Definición 1.6.1. El coeficiente de correlación lineal (de Pearson) evaluado a partir de los datos (x_i, y_i) es $r = \frac{s_{x,y}}{s_x s_y}$.

Observamos que:

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n e_i^2 &= \frac{1}{n} \sum_{i=1}^n (y_i - \hat{a} - \hat{b}x_i)^2 = \frac{1}{n} \sum_{i=1}^n \left(y_i - \bar{y} + \hat{b}(\bar{x} - x_i) \right)^2 \\ &= \underbrace{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2}_{s_y^2} + \hat{b}^2 \underbrace{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}_{s_x^2} - 2\hat{b} \underbrace{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}_{s_{x,y}} \\ &= s_y^2(1 - r^2) \geq 0 \end{aligned}$$

Como el error cuadrático medio debe ser menor que s_y^2 (el error cometido al aproximar los y_i con la media muestral), se cumple que

$$0 \leq r^2 \leq 1 \iff \boxed{-1 \leq r \leq 1}$$

Obsérvese que $r = \hat{b} \frac{s_x}{s_y}$. En particular, r y $\hat{b}$ tienen el mismo signo.

Observación 1.6.1.

- Una correlación r cercana a 1 indica un alto grado de ajuste lineal de y en términos de x . Se dice que hay una “alta correlación positiva” o “relación lineal directa” entre ambas variables.
- Un r cercano a -1 indica también un alto grado de ajuste lineal de y en términos de x pero en este caso hay una “correlación negativa” o “relación lineal inversa” entre ambas variables. Un r cercano a 0 se interpreta como una débil asociación lineal entre x e y .

2. Muestreo aleatorio

2.1 Diferencia probabilidad e inferencia estadística

En Probabilidad I resolvimos problemas como este:

Ejemplo 2.1.1. En un ensayo clínico, se administra un medicamento a 200 pacientes. Se sabe que el medicamento es efectivo con probabilidad 0.75. ¿Cuál es la probabilidad de que mejoren más de 155 pacientes?

La información previa para responder a la pregunta es “el medicamento es efectivo con probabilidad 0.75”. En la práctica no es realista pensar que se pueda disponer de tal información. Ese dato sólo se conocería tras administrar el medicamento a todos los individuos enfermos de una población y comprobar que se ha producido una mejoría en el 75% de los casos. Estamos suponiendo totalmente conocida la distribución de la v.a. Y = “número de pacientes entre los 200 para los que el medicamento es efectivo”.

Saber que el medicamento es efectivo en el 75% de los casos equivale a afirmar que la distribución de Y es una binomial $B(n = 200, p = 0.75)$.

En este caso, podríamos calcular la probabilidad de que mejoren más de 155 pacientes de los 200 a los que se ha administrado el medicamento. La respuesta del problema se puede obtener de la forma siguiente usando el comando `pbinom` de  (que calcula los valores de la función de la distribución binomial):

```
1 - pbinom(155, 200, 0.75)
[1] 0.1852385
```

La situación inversa es más realista. Normalmente nos interesa conocer el porcentaje p de casos en los que un medicamento es efectivo a partir de la información obtenida al administrarlo a un subconjunto de la población de enfermos (la muestra).

Este es el tipo de problemas que nos plantearemos en Estadística I: En un ensayo clínico, se administra un medicamento a 200 pacientes y se observa que mejoran 150 pacientes. ¿Hay evidencia estadística para afirmar que el medicamento es efectivo en un porcentaje de casos superior al 75%?

Puesto en términos matemáticos, si $X_i = \begin{cases} 1 & \text{si el medicamento es efectivo en el paciente } i \\ 0 & \text{si no lo es} \end{cases}$

tenemos un conjunto de 200 v.a. $X_1, \dots, X_{200}$ independientes e idénticamente distribuidas (si la población es grande) con distribución $B(1, p)$.

Se suelen usar letras mayúsculas para denotar las v.a. y letras minúsculas para las 200 observaciones o realizaciones obtenidas tras realizar el experimento (ceros o unos) $x_1, \dots, x_{200}$.

Sabiendo que $\sum_{i=1}^{200} x_i = 150$, ¿qué podemos decir sobre p ? ¿Podemos afirmar que $p > 0.75$? Si hacemos una afirmación como esa, ¿cuál es el riesgo de equivocarnos?

En este caso, a partir de la información sobre 200 casos particulares, tenemos que obtener información general sobre p , un parámetro que afecta a toda la población.

Esta asignatura se dedica a estudiar estos y otros problemas similares. Tendréis que utilizar toda la información que habéis adquirido en probabilidad, para recorrer de nuevo el camino en la dirección contraria.

2.2 Conceptos probabilísticos básicos

Definición 2.2.1. Un espacio de probabilidad es un triplete $(\Omega, \mathcal{A}, P)$ donde:

1. Ω es el espacio muestral, que es el conjunto de todos los resultados posibles de un experimento aleatorio (un conjunto no vacío).

2. $\mathcal{A}$ es una σ -álgebra en Ω .

$$\iff \Omega \in \mathcal{A} \quad \wedge \quad \forall A \in \mathcal{A} : A^c \in \mathcal{A} \quad \wedge \quad \{A_n\}_{n \in \mathbb{N}} \subset \mathcal{A} \Rightarrow \bigcup_{n \in \mathbb{N}} A_n \in \mathcal{A}$$

3. $\mathbb{P} : \mathcal{A} \rightarrow [0, 1]$ es una medida de probabilidad en $\mathcal{A}$.

$$A \mapsto \mathbb{P}(A) \iff \mathbb{P}(\Omega) = 1 \quad \wedge \quad \mathbb{P}\left(\bigsqcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mathbb{P}(A_n).$$

La σ -álgebra más habitual en $\mathbb{R}$ es la de Borel $\mathcal{B}$, que se puede generar con los intervalos.

Una **variable aleatoria** es una aplicación medible $X : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathbb{R}, \mathcal{B})$.

Es decir, $\forall B \in \mathcal{B} : X^{-1}(B) = \{\omega \in \Omega : X(\omega) \in B\} \in \mathcal{A}$. $\omega \mapsto X(\omega)$

Entonces, $\mathbb{P}$ y X inducen una medida de probabilidad P_X en $(\mathbb{R}, \mathcal{B})$ llamada **distribución de probabilidad** de X : $\forall B \in \mathcal{B} : P_X(B) = \mathbb{P}(X^{-1}(B)) = \mathbb{P}(\{\omega \in \Omega : X(\omega) \in B\})$.

La **función de distribución** de X es $F_X : \mathbb{R} \rightarrow [0, 1]$

no decreciente y cont. por la derecha. $x \mapsto F_X(x) = \mathbb{P}(X \leq x) = P_X((-\infty, x])$

La **función generatriz de momentos** de la v.a. X es $\mu_X(t) = \mathbb{E}(e^{tX}) = \int_{-\infty}^{\infty} e^{tx} dP_X(x)$.

La **función característica** de la v.a. X es $\varphi_X(t) = \mathbb{E}(e^{itX}) = \int_{-\infty}^{\infty} e^{itx} dP_X(x)$.

Una v.a. X es **discreta** $\iff \exists S = \{a_n\}_{n \in \mathbb{N}} \subset \mathbb{R} : 1 = P_X(S) = \sum_{n \in \mathbb{N}} \mathbb{P}\{X = a_n\}$.

La función de distribución de X es (absolutamente) **continua**

$$\iff \exists \text{ una función de densidad } f : \forall B \in \mathcal{B} : P_X(B) = \int_B f(x) dx.$$

La **media poblacional** o **esperanza** de X es $\mu = \mathbb{E}(X) = \int_{\Omega} X(\omega) d\mathbb{P}(\omega) = \int_{-\infty}^{\infty} x dP_X(x)$.

$$\text{a) } X \text{ discreta} \implies \mu = \sum_{n \in \mathbb{N}} a_n \mathbb{P}\{X = a_n\}. \quad \text{b) } X \text{ continua} \implies \mu = \int_{-\infty}^{\infty} x f(x) dx.$$

Teorema 2.2.1 (de cambio de espacio de integración).

Sea g una función real medible tal que $\mathbb{E}(g(X))$ existe $\implies \mathbb{E}(g(X)) = \int_{-\infty}^{\infty} g(x) dP_X(x)$.

En particular $\sigma^2 = \mathbb{V}(X) = \int_{-\infty}^{\infty} (x - \mu)^2 dP_X(x)$.

El **momento de orden k** de la v.a. X respecto al origen es $\mathbb{E}(X^k)$.

El momento de orden k de X respecto a la media es $\mathbb{E}((X - \mu)^k)$.

2.2.1 Desigualdades de Markov y Chebyshev

Teorema 2.2.2 (Desigualdad de Markov). Sea X una v.a. no negativa con media finita.

$$\implies \forall \varepsilon > 0 : \mathbb{P}(X \geq \varepsilon) \leq \frac{\mathbb{E}(X)}{\varepsilon}$$

Teorema 2.2.3 (Desigualdad de Chebyshev). Sea X una v.a. con media y varianzas finitas.

$$\implies \forall \varepsilon > 0 : \mathbb{P}(|X - \mu| \geq \varepsilon) = \mathbb{P}(|X - \mu|^2 \geq \varepsilon^2) \underset{\text{Markov}}{\leq} \frac{\mathbb{E}((X - \mu)^2)}{\varepsilon^2} = \frac{\sigma^2}{\varepsilon^2}$$

2.2.2 Convergencias estocásticas

Sean $\forall n \in \mathbb{N} : X_n : (\Omega, \mathcal{A}, \mathbb{P}) \longrightarrow (\mathbb{R}, \mathcal{B})$ y X v.a. ¿Qué significa $X_n \xrightarrow{n \rightarrow \infty} X$?

1. **Convergencia en probabilidad:**

$$X_n \xrightarrow[n \rightarrow \infty]{P} X \iff \forall \varepsilon > 0 : \lim_{n \rightarrow \infty} \mathbb{P}(|X_n - X| < \varepsilon) = 1.$$

2. **Convergencia casi segura:**

$$X_n \xrightarrow[n \rightarrow \infty]{\text{c.s.}} X \iff \forall \varepsilon > 0 : \mathbb{P}\left(\lim_{n \rightarrow \infty} |X_n - X| < \varepsilon\right) = 1.$$

$$\text{Tenemos que } X_n \xrightarrow[n \rightarrow \infty]{\text{c.s.}} X \implies X_n \xrightarrow[n \rightarrow \infty]{P} X.$$

Ejemplo 2.2.1 (de convergencia en probabilidad pero no casi segura).

Consideramos una sucesión de v.a. X_n construidas de la siguiente forma.

- (a) Definimos una v.a. U uniforme en $[0, 1]$.
- (b) Le aplicamos ciertas funciones indicatrices $\forall n \geq 1 : \forall i \in \mathbb{N}_n : A_n^i = \left[\frac{i-1}{n}, \frac{i}{n}\right]$.

$$(\Omega, \mathcal{A}, \mathbb{P}) \xrightarrow{U} (\mathbb{R}, \mathcal{B}) \xrightarrow{\mathbb{1}_{A_n^i}} (\mathbb{R}, \mathcal{B})$$

Para un $\omega \in \Omega$ fijo, $U(\omega)$ es un número real en $[0, 1]$.

$$\begin{array}{lll} X_1^1 = \mathbb{1}_{A_1^1}(U) & X_2^1 = \mathbb{1}_{A_2^1}(U) & X_2^2 = \mathbb{1}_{A_2^2}(U) \\ X_1^2 = \mathbb{1}_{A_1^2}(U) & X_2^1 = \mathbb{1}_{A_2^1}(U) & X_2^2 = \mathbb{1}_{A_2^2}(U) \end{array}$$

$X_n^i \xrightarrow[n \rightarrow \infty]{P} 0$ porque $\forall \varepsilon > 0 : \mathbb{P}(X_n^i > \varepsilon) = \frac{1}{n} \xrightarrow{n \rightarrow \infty} 0$ pero $\nexists \omega \in \Omega : X_n^i \xrightarrow{n \rightarrow \infty} 0$.

3. Convergencia débil o en distribución: Sean F_n y F las funciones de distribución de X_n y X respectivamente. $X_n \xrightarrow[n \rightarrow \infty]{d} X \iff \forall x \in \mathbb{R} : \lim_{n \rightarrow \infty} F_n(x) = F(x)$.

Sean ϕ y ϕ_n las funciones características de X y X_n respectivamente. Se cumple que

$$X_n \xrightarrow[n \rightarrow \infty]{d} X \iff \forall t \in \mathbb{R} : \phi_n(t) \xrightarrow{n \rightarrow \infty} \phi(t).$$

También se cumple que $\forall g: \mathbb{R} \rightarrow \mathbb{R}$ continua y acotada:

$$X_n \xrightarrow[n \rightarrow \infty]{d} X \iff \mathbb{E}(g(X_n)) \xrightarrow{n \rightarrow \infty} \mathbb{E}(g(X))$$

Proposición 2.2.4. Sean X_n y X v.a. se satisfacen las siguientes propiedades:

$$\begin{array}{l} X_n \xrightarrow[n \rightarrow \infty]{c.s.} X \implies X_n \xrightarrow[n \rightarrow \infty]{P} X \implies X_n \xrightarrow[n \rightarrow \infty]{d} X \\ X_n \xrightarrow[n \rightarrow \infty]{P} cte \iff X_n \xrightarrow[n \rightarrow \infty]{d} cte \end{array}$$

Teorema 2.2.5 (de Slutsky).

Sean $\forall n \in \mathbb{N} : X_n, Y_n$ v.a. y X v.a. tal que $X_n \xrightarrow[n \rightarrow \infty]{d} X$ y $Y_n \xrightarrow[n \rightarrow \infty]{P} c \in \mathbb{R}$, entonces

$$X_n + Y_n \xrightarrow[n \rightarrow \infty]{d} X + c \quad \wedge \quad X_n Y_n \xrightarrow[n \rightarrow \infty]{d} cX$$

Teorema 2.2.6 (de la aplicación continua). Sean X_n, X v.a. y $g: \mathbb{R} \rightarrow \mathbb{R}$ una función continua en un conjunto $C \subset \mathbb{R}$ tal que $\mathbb{P}\{X \in C\} = 1$, entonces

$$\begin{array}{l} X_n \xrightarrow[n \rightarrow \infty]{d} X \implies g(X_n) \xrightarrow[n \rightarrow \infty]{d} g(X) \\ X_n \xrightarrow[n \rightarrow \infty]{P} X \implies g(X_n) \xrightarrow[n \rightarrow \infty]{P} g(X) \\ X_n \xrightarrow[n \rightarrow \infty]{c.s.} X \implies g(X_n) \xrightarrow[n \rightarrow \infty]{c.s.} g(X) \end{array}$$

2.3 Población y muestra

Definición 2.3.1. Sea $X: (\Omega, \mathcal{A}, \mathbb{P}) \longrightarrow (\mathbb{R}, \mathcal{B})$ una v.a. con función de probabilidad P_X , X constituye la **población** de la que se extraen las muestras.

Definición 2.3.2. Sean $X_1, \dots, X_n$ v.a. independientes e idénticamente distribuidas (i.i.d.) con distribución P_X donde X es la v.a. de referencia.

$\Longleftrightarrow X_1, \dots, X_n$ es una **muestra aleatoria** simple de tamaño n de la población X .

Definición 2.3.3. Sean $x_1, \dots, x_n$ observaciones (numéricas) de $X_1, \dots, X_n$.

$\Longleftrightarrow x_1, \dots, x_n$ es una **muestra observada** o **realizada** de $X_1, \dots, X_n$.

Para aproximar elementos poblacionales de interés (μ, σ^2, F_X , etc.) a partir de la muestra, construiremos estimadores de ellos que son funciones de la muestra aleatoria.

Definición 2.3.4 (Estadístico). Sea $X_1, \dots, X_n$ una muestra aleatoria simple de tamaño n de la población X y sea $T: (\mathbb{R}^n, \mathcal{B}_{\mathbb{R}^n}) \longrightarrow (\mathbb{R}, \mathcal{B}_{\mathbb{R}})$ una función.

$\Longleftrightarrow T = T(X_1, \dots, X_n)$ es un **estadístico** de $X_1, \dots, X_n$.

Nota: No hay que perder de vista que T es una v.a.

A veces se puede calcular analíticamente la distribución en el muestreo de un estadístico. Una herramienta útil para ello es la **función característica**.

Si no podemos determinar la distribución en el muestreo de un estadístico, tal vez podamos **aproximarla asintóticamente** (cuando $n \rightarrow \infty$) utilizando algún resultado de convergencia de sucesiones de v.a.'s.

Si esto tampoco es posible, entonces podemos aproximar la distribución en el muestreo de T mediante el **método de Montecarlo** (simulaciones intensivas de los valores de T).

Ejemplo 2.3.1. Supongamos, por ejemplo, que la distribución del tiempo de espera en la caja de un supermercado es exponencial de parámetro λ . ¿Cuál es la la distribución del promedio de los tiempos de espera de n clientes? Se supone que los clientes se han seleccionado en días diferentes de manera que sus tiempo de espera se pueden suponer independientes.

$$X \sim \exp(\lambda) \implies \forall t < \lambda : M_X(t) = \mathbb{E}(e^{tX}) = \left(1 - \frac{t}{\lambda}\right)^{-1}$$

Por tanto, la función generatriz de momentos (FGM) del promedio es

$$\bar{X} = \sum_{i=1}^n \frac{X_i}{n} \implies M_{\bar{X}}(t) = \mathbb{E} \left(e^{t\bar{X}} \right) = \mathbb{E} \left(e^{t \frac{1}{n} \sum_{i=1}^n X_i} \right) = \prod_{i=1}^n \mathbb{E} \left(e^{t \frac{X_i}{n}} \right) = \left(1 - \frac{t}{n\lambda} \right)^{-n}$$

Por tanto, tenemos que $\forall n \in \mathbb{N} : X \sim \exp(\lambda) \implies \bar{X} \sim \text{Gamma}(n, n\lambda)$.

Las características de la v.a. X que genera los datos (por ejemplo, los momentos, los cuantiles, la distribución, etc.) se denominan momentos, cuantiles, etc. **poblacionales**.

En general, uno de los objetivos principales de la inferencia estadística es **estimar** las características poblacionales a partir de la información proporcionada por la muestra.

Otras técnicas estadísticas no van orientadas directamente a aproximar el valor de una característica de interés (como por ejemplo la media), sino más bien a decidir entre dos posibles opciones acerca de ella (por ejemplo, si es mayor o menor que 1).

La correspondiente metodología se denomina **contraste de hipótesis**.

Definición 2.3.5 (Error estándar). Sea $X_1, \dots, X_n$ una muestra aleatoria simple de tamaño n de la población X y sea $T: (\mathbb{R}^n, \mathcal{B}_{\mathbb{R}^n}) \longrightarrow (\mathbb{R}, \mathcal{B}_{\mathbb{R}})$ un estadístico de $X_1, \dots, X_n$. El **error estándar** o **error típico** de T es la desviación típica de su distribución en el muestreo.

$$\sqrt{\mathbb{V}(T(X_1, \dots, X_n))}$$

Definición 2.3.6 (Sesgo). Sea T un estadístico de una muestra aleatoria $X_1, \dots, X_n$.

El **sesgo** de T es la diferencia entre la esperanza de T y el valor del parámetro estimando.

$$\mathbb{E}(T(X_1, \dots, X_n)) - \theta(X)$$

T se dice **consistente** si su sesgo tiende a cero cuando $n \rightarrow \infty$.

Teorema 2.3.1 (Ley fuerte de los grandes números de Kolmogorov).

Sea $\{X_k\}$ una sucesión de v.a.i.i.d. con media μ finita $\implies \bar{X} := \frac{\sum_{i=1}^n X_i}{n} \xrightarrow[n \rightarrow \infty]{c.s.} \mu$.

Teorema 2.3.2 (Teorema central del límite).

Sea $\{X_k\}$ una sucesión de v.a.i.i.d. con media μ y varianza σ^2 finitas.

$$\implies \sqrt{n} (\bar{X} - \mu) \xrightarrow[n \rightarrow \infty]{d} N(0, \sigma^2) \iff \frac{1}{\sigma} \sqrt{n} (\bar{X} - \mu) \xrightarrow[n \rightarrow \infty]{d} N(0, 1)$$

Es decir, $\forall t \in \mathbb{R} : \lim_{n \rightarrow \infty} P \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq t \right) = \Phi(t)$ con Φ la función de distribución de $N(0, 1)$.


2.3.1 La función de distribución empírica

Proposición 2.3.3. Se tiene que $\forall X$ v.a. : $\forall A \in \mathcal{B} : \mathbb{P}(X \in A) = \mathbb{E}(\mathbb{1}_A(X))$.

Demostración. $P_X(A) = \sum_{x \in A} P_X(x) = \sum_{x \in A} \mathbb{1}_A(x) P_X(x) = \mathbb{E}(\mathbb{1}_A(X))$ ■

Definición 2.3.7. Sea $\{X_i\}_{i=1}^n$ una muestra aleatoria de X , $\mathbb{F}_n$ es la **función de distribución empírica** $\iff \forall t \in \mathbb{R} : \mathbb{F}_n(t) = \mathbb{E}(\mathbb{1}_{\{X \leq t\}}) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{(-\infty, t]}(X_i)$.

Esta es la función de distribución que corresponde a una medida de probabilidad discreta que asigna masa $1/n$ a cada uno de los valores $X_1, \dots, X_n$.



Sea X una v.a. con fn de distribución de probabilidad P_X , i.e. $\forall A \in \mathcal{B}_{\mathbb{R}} : P_X(A) = \mathbb{P}(X \in A)$. P_X está caracterizada por la función de distribución F_X de X , porque

$$\forall x \in \mathbb{R} : F_X(x) = P_X((-\infty, x]) = \mathbb{P}(X \leq x).$$

$$\forall A \in \mathcal{B}_{\mathbb{R}} : \mathbb{P}(X \in A) = \mathbb{E}(\mathbb{1}_A(X)) \implies F(x) = \mathbb{E}(\mathbb{1}_{(-\infty, x]}(X)) = \mathbb{E}(\mathbb{1}_{\{X \leq x\}})$$

Observación 2.3.1. La v.a. $\mathbb{1}_{(-\infty, x]}(X) \sim \text{Bernoulli}$ de parámetro $p = \mathbb{P}(X \leq x) = F(x)$.

Por la ley fuerte de los grandes números, $\forall x \in \mathbb{R} : \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i \xrightarrow[n \rightarrow \infty]{c.s.} \mathbb{E}(Y) = \mu < \infty$.

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{Y_i \leq x\}} \xrightarrow[n \rightarrow \infty]{c.s.} \mathbb{E}(\mathbb{1}_{\{Y \leq x\}}) = \mathbb{P}(Y \leq x) = F_Y(x)$$

Teorema 2.3.4 (de Glivenko-Cantelli). Sea X una v.a. con función de distribución F . Sea $\{X_i\}_{i=1}^n$ una muestra aleatoria simple de X .

$$\implies \|\mathbb{F}_n - F\|_{\infty} := \sup_{x \in \mathbb{R}} |\mathbb{F}_n(x) - F(x)| \xrightarrow[n \rightarrow \infty]{c.s.} 0$$

Demostración. Dividimos la demostración en tres pasos:

1. Por la LFGN, para cada $t \in \mathbb{R}$ fijo, se cumple que

$$\mathbb{F}_n(t) \xrightarrow[n \rightarrow \infty]{c.s.} F(t) \quad \wedge \quad \mathbb{F}_n(t^-) \xrightarrow[n \rightarrow \infty]{c.s.} F(t^-)$$

donde $F(t^-) = \lim_{s \rightarrow t^-} F(s)$.

$$\implies \|\mathbb{F}_n(t^-) - F(t^-)\| \leq \|\mathbb{F}_n(t^-) - \mathbb{F}_n(s)\| + \|\mathbb{F}_n(s) - F(s)\| + \|F(s) - F(t^-)\|$$

Por la definición de límite por la izquierda, $\exists s > t$ suficientemente próximo a t tal que

$$|\mathbb{F}_n(t^-) - \mathbb{F}_n(s)| < \frac{\varepsilon}{3} \quad \wedge \quad |F(s) - F(t^-)| < \frac{\varepsilon}{3}$$

con probabilidad 1, la diferencia $|\mathbb{F}_n(t^-) - F(t^-)|$ puede ser tan pequeña como se quiera porque con probabilidad 1 $\exists n = n(\omega)$ tal que $|\mathbb{F}_n(s) - F(s)| < \frac{\varepsilon}{3} \implies \mathbb{F}_n(t^-) \xrightarrow[n \rightarrow \infty]{c.s.} F(t^-)$.

2. Dado un $\varepsilon > 0$ fijo, $\exists$ una partición finita de $\mathbb{R}$, $-\infty = t_0 < t_1 < \dots < t_k = \infty$ tal que $\forall i = 1, \dots, k : F(t_i) - F(t_{i-1}) < \varepsilon$.

F puede dar una cantidad finita de saltos mayores que ε . Dichos puntos donde F salta tienen que formar parte de la partición.

3. Para cualquier $i = 1, \dots, k$ $\wedge t = t_{i-1}, \dots, t_i$ fijos,

$$\begin{array}{c} \mathbb{F}_n \text{ es fn distrib} \\ \downarrow \\ \mathbb{F}_n(t) - F(t) \leq \mathbb{F}_n(t_i^-) - F(t_i^-) + \varepsilon \implies F(t) \geq F(t_i^-) - \varepsilon \end{array}$$

Además, $\mathbb{F}_n(t) - F(t) \geq \mathbb{F}_n(t_{i-1}^-) - F(t_{i-1}^-) - \varepsilon$

$$\implies |\mathbb{F}_n(t) - F(t)| \leq \max \left\{ |\mathbb{F}_n(t_i^-) - F(t_i^-)|, |\mathbb{F}_n(t_{i-1}^-) - F(t_{i-1}^-)| \right\} + \varepsilon$$

$$\implies \|\mathbb{F}_n - F\|_\infty \leq \max_{1 \leq i \leq k} \max \left\{ |\mathbb{F}_n(t_i^-) - F(t_i^-)|, |\mathbb{F}_n(t_{i-1}^-) - F(t_{i-1}^-)| \right\} + \varepsilon$$

Por tanto, $\forall \omega \in \Omega$: salvo un conjunto de probabilidad 0, $\exists n = n(\omega)$ a partir del cual $\|\mathbb{F}_n - F\|_\infty$ es tan pequeño como se quiera.

■

La estimación de la función de distribución F de una v.a. X mediante la función de distribución empírica $\mathbb{F}_n$ da lugar a un método de estimación muy general llamado **estimación *plug-in***. Es decir, si un objeto (parámetro, por ejemplo) que deseamos estimar se puede expresar en términos de la función de probabilidad de X , P_X , entonces el estimador *plug-in* es el que se obtiene al sustituir P_X por $\mathbb{F}_n$ en la expresión del objeto a estimar.

Ejemplo 2.3.2 (Estimación de la media).

$$\mu = \int_{\mathbb{R}} x \, dF(x) = \int_{\mathbb{R}} x \, dP_X(x) \xrightarrow[\text{plug-in}]{\text{estimador}} \bar{\mu} = \int_{\mathbb{R}} x \, d\mathbb{F}_n(x) = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$$

Sea $X_1, \dots, X_n$ una muestra aleatoria simple de X , entonces

$$\begin{aligned} S_n^2 &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n [(X_i - \mu) - (\bar{X} - \mu)]^2 \\ &= \frac{1}{n} \sum_{i=1}^n [(X_i - \mu)^2 - 2(X_i - \mu)(\bar{X} - \mu) + (\bar{X} - \mu)^2] \\ \implies \mathbb{E}(S_n^2) &= \frac{1}{n} \mathbb{E} \left[\sum_{i=1}^n (X_i - \mu)^2 - 2 \sum_{i=1}^n (X_i - \mu)(\bar{X} - \mu) + \sum_{i=1}^n (\bar{X} - \mu)^2 \right] \\ &= \frac{1}{n} \sum_{i=1}^n \mathbb{E}[(X_i - \mu)^2] - 2 \sum_{i=1}^n \mathbb{E}[(X_i - \mu)(\bar{X} - \mu)] + \frac{1}{n} \sum_{i=1}^n \mathbb{E}[(\bar{X} - \mu)^2] \\ &= \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2 \right] - \mathbb{E}[(\bar{X} - \mu)^2] = \mathbb{E}[(X - \mu)^2] - \mathbb{V}(\bar{X}) \end{aligned}$$

Si llamamos $Y = (X - \mu)^2$, $Y_i = (X_i - \mu)^2$, tenemos $\mathbb{E}(Y) = \mathbb{E}((X - \mu)^2) = \mathbb{V}(X) = \sigma^2$.

$$\mathbb{E}(S_n^2) = \mathbb{E}(\bar{Y}) - \mathbb{E}[(\bar{X} - \mu)^2] = \sigma^2 - \mathbb{V}(\bar{X}) = \sigma^2 - \frac{\sigma^2}{n} = \frac{n-1}{n} \sigma^2 < \sigma^2$$

Como S_n^2 es estrictamente menor que σ^2 , se dice que S_n^2 es un estimador **sesgado** porque **infraestima** σ^2 con sesgo $-\frac{1}{n}\sigma^2 \xrightarrow{n \rightarrow \infty} 0$ y es **asintóticamente insesgado**.

Ahora, por la LFGN, tenemos que $\bar{X} \xrightarrow[n \rightarrow \infty]{\text{c.s.}} \mu_X \wedge \bar{Y} \xrightarrow[n \rightarrow \infty]{\text{c.s.}} \mathbb{E}(Y) = \sigma^2$. Por tanto, aplicando el teorema de la aplicación continua (en este caso $g(x) = x^2$) tenemos que

$$(\bar{X} - \mu)^2 \xrightarrow[n \rightarrow \infty]{\text{c.s.}} 0 \implies S_n^2 = \bar{Y} - (\bar{X} - \mu)^2 \xrightarrow[n \rightarrow \infty]{\text{c.s.}} \sigma^2$$

2.4 Estadísticos de orden

Sea X una variable aleatoria, podemos hacer observaciones en paquetes de n , primero $\{x_1^{(1)}, \dots, x_n^{(1)}\}$, luego $\{x_1^{(2)}, \dots, x_n^{(2)}\}$, ..., $\{x_1^{(m)}, \dots, x_n^{(m)}\}$.

Sean $X_1, \dots, X_n$ n variables aleatorias i.i.d., podemos definir $\forall i \in \mathbb{N} : X_{(i)}$ como la variable aleatoria que toma el i -ésimo valor más pequeño de $\{X_i\}$, es decir,

$$X_{(1)} = \min_{1 \leq i \leq n} \{X_i\} \quad \wedge \quad X_{(n)} = \max_{1 \leq i \leq n} \{X_i\}$$

En este nuevo vector aleatorio $(X_{(1)}, \dots, X_{(n)})$ las variables aleatorias no son independientes,

pero sí son idénticamente distribuidas.

- X continua $\implies$ distrib. de $(X_{(1)}, \dots, X_{(n)})$ es continua con densidad $g(X_{(1)}, \dots, X_{(n)})$.
 - X discreta $\implies$ distrib. de $(X_{(1)}, \dots, X_{(n)})$ es discreta con fn. de masa $g(X_{(1)}, \dots, X_{(n)})$.
- $\implies \mathbb{P}\{X_{(1)} = x_1 \wedge \dots \wedge X_{(n)} = x_n\} = n!f(x_1) \cdots f(x_n)$ con f fn de densidad/masa de X

Determinemos la distribución marginal de $X_{(i)}$. Para ello, dado $x \in \mathbb{R}$, definimos la v.a. $\Xi :=$ “número de X_i ’s menores o iguales que x ” $\sim B(n, F(x))$. Entonces

$$F_{X_{(i)}}(x) = \mathbb{P}\{X_{(i)} \leq x\} = \mathbb{P}\{\Xi \geq i\} = \sum_{k=i}^n \binom{n}{k} F(x)^k (1 - F(x))^{n-k}$$

En caso de que F tenga densidad f , derivando y simplificando obtenemos

$$f_{X_{(i)}}(x) = \frac{n!}{(i-1)!(n-i)!} f(x) F(x)^{i-1} (1 - F(x))^{n-i}$$


Definición 2.4.1 (Función cuantílica). La función cuantílica es una manera rigurosa y unívoca de definir el concepto de cuantil poblacional y muestral en Estadística Matemática.

Sea X una v.a. con función de distribución F , la función cuantílica se define como

$$\forall p \in [0, 1] : F^{-1}(p) = \inf\{x \in \mathbb{R} : F(x) \geq p\}$$

Análogamente se define el **cuantil muestral** a partir de la función de distribución empírica $\mathbb{F}_n$.

$$\forall p \in [0, 1] : \mathbb{F}_n^{-1}(p) = \inf\{x \in \mathbb{R} : \mathbb{F}_n(x) \geq p\}$$



Ahora ya tenemos 2 medidas resumen de la posición o localización de la distribución de probabilidad de X : $\mathbb{E}(X) = \int_{\mathbb{R}} x dF(x)$ que es poco “robusta” y la mediana poblacional $F^{-1}(1/2)$, que separa la población en 2 subpoblaciones equiprobables y es robusta.

Estimamos $\mathbb{E}(X)$ mediante $\bar{X} = \int_{\mathbb{R}} x d\mathbb{F}_n(x)$ (por el principio *plug-in*).

Estimamos la mediana poblacional $F^{-1}(1/2)$ mediante $\mathbb{F}_n^{-1}(1/2)$.

Proposición 2.4.1. *Propiedades de $\bar{X}$ como estimador de $E(X)$:*

1. *Consistencia por la LFGN:* $\bar{X} \xrightarrow[n \rightarrow \infty]{c.s.} E(X) = \mu.$

2. *Normalidad asintótica por el TCL:* $\sqrt{n} (\bar{X} - \mu) \xrightarrow[n \rightarrow \infty]{d} N(0, \sigma^2).$

Ahora, para el cuantil muestral $\mathbb{F}_n^{-1}(1/2)$, tenemos que

1. Consistencia del cuantil p muestral:

$$\forall \varepsilon > 0 : F(F^{-1}(p) + \varepsilon) > p \implies \mathbb{F}_n^{-1}(p) \xrightarrow[n \rightarrow \infty]{c.s.} F^{-1}(p)$$

2. Normalidad asintótica del cuantil p muestral:

3. Estimación puntual paramétrica

3.1 Modelos paramétricos e inferencia paramétrica

Formular un **modelo estadístico** para una v.a. X consiste en especificar cuál es la familia de posibles distribuciones de probabilidad de X .

Un modelo es **paramétrico** si cada distribución F_θ de la familia es totalmente conocida salvo por el valor de un parámetro $\theta \in \mathbb{R}^k$, es decir, la familia de posibles distribuciones es $\mathcal{F} = \{F_\theta : \theta \in \Theta \subseteq \mathbb{R}^k\}$ donde Θ es el conjunto de posibles valores del parámetro θ y se denomina **espacio paramétrico**.

X	$f(\cdot; \theta)$
absolutamente continua	función de densidad
discreta	función de masa o de probabilidad

Sup. que $\mathcal{F}$ cumple la **condición de identificabilidad** $\iff \theta \neq \theta' \implies F_\theta \neq F_{\theta'}$.

El objetivo general de la **inferencia estadística paramétrica** consiste en, supuesto que X sigue un modelo paramétrico F_θ , **inferir** o **extraer información** sobre el parámetro θ a partir de una muestra de observaciones de X . Se divide en tres partes:

- Estimación puntual del parámetro. (Tema 3)
- Estimación por intervalos de confianza para θ . (Tema 4)
- Contraste de hipótesis sobre θ . (Tema 5)

En particular, el objetivo de la **estimación paramétrica puntual** es estimar (o aproximar) el valor desconocido de θ . Esto se hace mediante un **estimador**.

Cuestiones de interés en el Tema 3:

- determinar qué se entiende por una “buena” estimación;
- estudiar las **propiedades** de estos estimadores;
- ofrecer algún **procedimiento general** para **construir** estimadores;
- mostrar algunos **ejemplos** de especial relevancia.

3.2 Estimadores

Un estimador es una sucesión de funciones $T = (T_n)_{n \in \mathbb{N}}$ tales que $\forall n \in \mathbb{N} : T_n : \Omega \longrightarrow \Theta \subset \mathbb{R}^k$ donde Ω es el espacio muestral de las variables aleatorias $\forall n \in \mathbb{N} : X_n : \Omega \longrightarrow \mathbb{R}$ que siguen una distribución paramétrica $X_n \sim f(\cdot; \theta)$ con θ fijo. Es decir, para cada $n \in \mathbb{N}$, $T_n = (T_n^i)_{i=1}^k$ es un vector aleatorio, osea $\forall i \in \mathbb{N}_k : T_n^i : \Omega \longrightarrow \mathbb{R}$ es una v.a. en el mismo espacio de probabilidad que cada X_n , $(\Omega, \mathcal{A}, \mathbb{P})$.

Por tanto, los estimadores son sucesiones de vectores aleatorios y para un $n \in \mathbb{N}$ fijo, tiene sentido hablar de la media, varianza y distribución de T_n . La realización del estimador, $T_n(\omega) = t(X_1(\omega), \dots, X_n(\omega))$ (donde $t : \mathbb{R}^n \longrightarrow \mathbb{R}^k$) en una muestra concreta observada $(X_i(\omega))_{i \in \mathbb{N}_n} = (x_i)_{i \in \mathbb{N}_n}$ se denomina **estimación** y es un valor numérico (no aleatorio).

La calidad de un estimador se puede evaluar mediante su **error cuadrático medio**:

$$\text{ECM}(T_n) = \mathbb{E} [(T_n - \theta)^2]$$

Si suponemos que X sigue un modelo paramétrico de distribución de probabilidad, el ECM puede depender de θ , por lo que a veces se denota $\text{ECM}_\theta(T_n) = \mathbb{E}_\theta [(T_n - \theta)^2]$.

Sumando y restando $\mathbb{E}(T_n)$ es inmediato ver que

$$\text{ECM}(T_n) = \mathbb{E} [(T_n - \mathbb{E}(T_n))^2] + (\mathbb{E}(T_n) - \theta)^2 = \text{Varianza de } T_n + (\text{Sesgo de } T_n)^2$$

El ECM es un caso particular de una **función de riesgo** $R(\theta, T_n) = \mathbb{E}_\theta(\ell(\theta, T_n))$, siendo $\ell(\theta, a) = (\theta - a)^2$ la función de **pérdida cuadrática**.

3.2.1 Propiedades interesantes de los estimadores

Definición 3.2.1. Un estimador $T = (T_n)_{n \in \mathbb{N}}$ es **insesgado**

$$\iff \forall \theta \in \Theta : \forall n \in \mathbb{N} : X_n \sim f(\cdot; \theta) \implies \mathbb{E}_\theta(T_n) = \theta$$

Ejemplo 3.2.1. 1. $\bar{X}$ es un estimador insesgado de $\mu = \mathbb{E}(X)$.

2. $S_{n-1}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ es estimador insesgado de $\sigma^2 = V(X)$. En cambio,

3. $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ es estimador sesgado.

Definición 3.2.2. Un estimador $T = (T_n)_{n \in \mathbb{N}}$ es **consistente** en probabilidad

$$\iff \forall \theta \in \Theta : \left[(\forall n \in \mathbb{N} : X_n \sim f(\cdot; \theta)) \implies T_n \xrightarrow[n \rightarrow \infty]{P} \theta \right]$$

Si $\xrightarrow[n \rightarrow \infty]{P}$ se reemplaza por $\xrightarrow[n \rightarrow \infty]{\text{c.s.}}$, se obtiene la consistencia fuerte (o casi segura).

¿Cómo demostrar fácilmente la consistencia?

- Mediante la **ley de los grandes números**:

$g : \mathbb{R} \rightarrow \mathbb{R}$ continua $\implies T_n = g(\bar{X})$ es estimador consistente c.s. de $\theta = g(\mu)$.

- La consistencia en probabilidad se puede probar usando la **desigualdad de Markov**:

$$\mathbb{P}\{|T_n - \theta| > \varepsilon\} \leq \frac{\mathbb{E}|T_n - \theta|}{\varepsilon} \quad \mathbb{P}\{|T_n - \theta| > \varepsilon\} \leq \frac{\mathbb{E}[(T_n - \theta)^2]}{\varepsilon^2}$$

$$\mathbb{E}|T_n - \theta| \xrightarrow[n \rightarrow \infty]{n \rightarrow \infty} 0 \implies T_n \xrightarrow[n \rightarrow \infty]{P} \theta \quad \mathbb{E}[(T_n - \theta)^2] \xrightarrow[n \rightarrow \infty]{n \rightarrow \infty} 0 \implies T_n \xrightarrow[n \rightarrow \infty]{P} \theta$$

- Respecto a la consistencia casi segura recordemos que $T_n \xrightarrow[n \rightarrow \infty]{\text{c.s.}} \theta$

$$\iff \mathbb{P}\left\{\omega \in \Omega : \lim_{n \rightarrow \infty} T_n(X_1(\omega), \dots, X_n(\omega)) = \theta\right\} = 1.$$

Esta condición es, en general, difícil de comprobar directamente. Por ello, es habitual utilizar condiciones suficientes. Por ejemplo, la **condición de Borel-Cantelli**

$$T_n \xrightarrow[n \rightarrow \infty]{\text{c.s.}} \theta \iff \forall \varepsilon > 0 : \sum_{n=1}^{\infty} \mathbb{P}\{|T_n - \theta| > \varepsilon\} < \infty.$$

Por la desigualdad de Markov, la condición anterior puede establecerse a su vez usando alguna de las condiciones suficientes

$$\sum_{n=1}^{\infty} \mathbb{E}|T_n - \theta| < \infty \quad \vee \quad \sum_{n=1}^{\infty} \mathbb{E}[(T_n - \theta)^2] < \infty.$$

Ejercicio 3.2.1. Sean $X_1, \dots, X_n$ v.a.i.i.d. con distribución uniforme en el intervalo $[0, \theta]$, $\theta > 0$. Estudiar la consistencia de los siguientes estimadores de θ :

a) $T_n = 2\bar{X}$ b) $T_n^* = X_{(n)} = \max\{X_1, \dots, X_n\}$

¿Cuál es el ECM de ambos estimadores? ¿Cuál de los dos estimadores preferiríamos?

Solución. Tenemos que $\Theta = (0, \infty)$ y $f(x; \theta) = \mathbb{1}_{[0, \theta]}(x) \cdot 1/\theta$. Por tanto, la función de

distribución es $F(x; \theta) = \int_{-\infty}^x f(t; \theta) dt = \begin{cases} 0 & \text{si } x < 0 \\ x/\theta & \text{si } 0 \leq x \leq \theta. \\ 1 & \text{si } x > \theta \end{cases}$. Calculamos los sesgos:

a) $\mathbb{E}(T_n) = 2\mathbb{E}(\bar{X}) = 2\mu = 2\theta/2 = \theta \implies T_n$ es insesgado.

$\text{ECM}(T_n) = \mathbb{V}(T_n) = \mathbb{V}(2\bar{X}) = 4\mathbb{V}(\bar{X}) = 4 \cdot \mathbb{V}(X)/n = 4 \cdot \theta^2/12n = \theta^2/3n.$

$$\begin{aligned} \text{b) } F_{x_{(n)}}(x) &= \mathbb{P}\{x_{(n)} \leq x\} = \mathbb{P}\{x_1 \leq x \wedge \dots \wedge x_n \leq x\} \stackrel{\text{indep}}{=} \prod_{i=1}^n \mathbb{P}\{x_i \leq x\} \stackrel{\text{idd}}{=} (F(x))^n \\ \implies f_{x_{(n)}}(x) &= F'_{x_{(n)}}(x) = n(F(x))^{n-1} f(x) \stackrel{X \sim \text{UNIF}[0, \theta]}{=} \mathbb{1}_{[0, \theta]}(x) \cdot \frac{n}{\theta} \cdot \left(\frac{x}{\theta}\right)^{n-1} \end{aligned}$$

$$\text{Por tanto, } \mathbb{E}(T_n^*) = \int_{\mathbb{R}} x \cdot f_{x_{(n)}}(x) dx = \frac{n}{n+1} \theta < \theta \implies T_n^* \text{ tiene sesgo } -\frac{\theta}{n+1} < 0.$$

Otra manera de hacer el mismo cálculo es teniendo en cuenta que: si Y es una variable aleatoria con $\mathbb{E}(Y) < \infty$, entonces $\mathbb{E}(Y) = \int_0^\infty \mathbb{P}(Y > y) dy$.

$$\text{Por tanto, } \mathbb{E}(T_n^*) = \int_0^\infty (1 - F(t)) dt = \int_0^\theta \left[1 - \left(\frac{1}{\theta}\right)^n\right] dt = \frac{n}{n+1} \theta.$$

Entonces $\mathbb{V}(T_n^*) = \mathbb{E}(T_n^{*2}) - (\mathbb{E}(T_n^*))^2 = \frac{n\theta^2}{(n+2)(n+1)^2}$ y como se tiene que

$$\mathbb{E}(T_n^{*2}) = \int_0^\theta t^2 \cdot \frac{n}{\theta} \left(\frac{t}{\theta}\right)^{n-1} dt = \frac{n}{n+2} \theta^2, \text{ el error cuadrático medio es}$$

$$\text{ECM} = \mathbb{V}(T_n^*) + \text{sesgo}^2 = \frac{2\theta^2}{(n+2)(n+1)}$$

Entonces, a pesar de que T_n es insesgado y T_n^* no, el error cuadrático medio de T_n^* converge más rápido a 0 que el de T_n . Por tanto, en este caso, preferiríamos T_n^* .

Comparemos los tipos de consistencia de ambos estimadores:

1. Por la ley de los grandes números, $\forall \theta > 0 : T_n \xrightarrow[n \rightarrow \infty]{\text{c.s.}} 2\mathbb{E}(X) = 2\theta/2 = \theta$.

2. Como $\mathbb{E}|T_n^* - \theta| = \frac{\theta}{n+1} \xrightarrow[n \rightarrow \infty]{} 0$, se tiene que $T_n^* \xrightarrow[n \rightarrow \infty]{P} \theta$.

Como además $\sum_{n \in \mathbb{N}} \text{ECM}(T_n^*) < \infty$, se tiene que $T_n^* \xrightarrow[n \rightarrow \infty]{\text{c.s.}} \theta$.

Definición 3.2.3. Un estimador $T = (T_n)_{n \in \mathbb{N}}$ del parámetro θ es **asintóticamente normal** con tasa $\sqrt{n} \iff \sqrt{n}(T_n - \theta) \xrightarrow[n \rightarrow \infty]{d} N(0, \sigma(\theta))$, donde $\sigma(\theta)$ es una función del parámetro θ denominada **varianza asintótica del estimador**.

Esta propiedad es muy útil para obtener una idea más precisa del error cometido en la estimación, ya que permite hacer cálculos aproximados del tipo

$$\forall c > 0 : \mathbb{P}\{|T_n - \theta| < c\} = \mathbb{P}\{\sqrt{n}|T_n - \theta| < \sqrt{nc}\} \approx \Phi\left(\frac{c}{\sigma(\theta)/\sqrt{n}}\right) - \Phi\left(-\frac{c}{\sigma(\theta)/\sqrt{n}}\right)$$

donde Φ es la función de distribución de la normal estandar $N(0, 1)$.

¿Cómo podemos probar en la práctica la normalidad asintótica?

Teorema 3.2.1 (Método delta). Sea X una variable aleatoria con $\mathbb{E}(X) = \mu$ y $\mathbb{V}(X) = \sigma^2$ y sea $g: \mathbb{R} \rightarrow \mathbb{R}$ una función derivable en $\mathbb{E}(X)$ con derivada continua.

$$\implies \sqrt{n} (g(\bar{X}) - g(\mu)) \xrightarrow[n \rightarrow \infty]{d} N(0, |g'(\mu)| \sigma)$$

Demostración. Definimos el estimador $T_n = g(\bar{X})$ del parámetro $\theta = g(\mathbb{E}(X))$, entonces

$$\sqrt{n} (T_n - \theta) = \sqrt{n} (g(\bar{X}) - g(\mathbb{E}(X))) = \sqrt{n} g'(\zeta_n) \text{ con } \zeta_n \in (\bar{X}, \mathbb{E}(X)) \text{ por el TVM.}$$

Por la ley de los grandes números, $\bar{X} - \mathbb{E}(X) \xrightarrow[n \rightarrow \infty]{\text{c.s.}} 0$, luego $\zeta_n - \mathbb{E}(X) \xrightarrow[n \rightarrow \infty]{\text{c.s.}} 0$.

Por tanto, $g'(\zeta_n) \xrightarrow[n \rightarrow \infty]{\text{c.s.}} g'(\mathbb{E}(X))$ y, por el teorema central del límite,

$$\sqrt{n} (T_n - \theta) \xrightarrow[n \rightarrow \infty]{d} N\left(0, |g'(\mathbb{E}(X))| \sqrt{\mathbb{V}(E)}\right). \quad \blacksquare$$

Observación 3.2.1. En general, también se habla de normalidad asintótica (con tasa $\{a_n\}$) cuando se verifica un resultado del tipo $a_n (T_n - \theta) \xrightarrow[n \rightarrow \infty]{d} N(0, \sigma(\theta))$, donde $0 < a_n \nearrow \infty$ es una sucesión de constantes.

Tiene especial importancia el caso $a_n = \sqrt{n}$ porque es el que aparece en el **teorema central del límite**. Sin embargo, en muy diversos problemas estadísticos se obtiene normalidad asintótica con sucesiones a_n diferentes.

3.3 Estimador de máxima verosimilitud

Supongamos que la muestra $X_1, \dots, X_n$ está formada por v.a.i.i.d. cuya distribución tiene una función de densidad o de masa $f(\cdot; \theta_0)$ perteneciente a una familia $\{f(\cdot; \theta) : \theta \in \Theta\}$. El verdadero valor del parámetro se denota por θ_0 y la letra θ designa un valor genérico de este parámetro. Habitualmente θ_0 es desconocido. El primer objetivo de la inferencia paramétrica es definir un método general para estimarlo.

Nota: En este tema la expresión “función de densidad” deberá entenderse en sentido genérico para referirse también a las funciones de masa de las variables discretas.

Supondremos que se cumple la **condición de identificabilidad**, es decir, que las distribuciones correspondientes a $f(\cdot; \theta)$ son distintas para diferentes valores de θ . (MV0)

3.3.1 El método de máxima verosimilitud

La idea es que la propia densidad $f(\cdot; \theta)$ mide lo verosímil que es el valor de θ en base a la muestra observada.

Definición 3.3.1. Dada una muestra fija $x_1, \dots, x_n$, llamamos **función de verosimilitud** (*likelihood function*) a $L_n(\theta; x_1, \dots, x_n) = L_n(\theta) = \prod_{i=1}^n f(x_i; \theta)$.

El **estimador de máxima verosimilitud** de θ es $\hat{\theta}_n := \hat{\theta}_n(x_1, \dots, x_n) = \arg \max_{\theta \in \Theta} L_n(\theta)$ cuando este máximo esté bien definido.

Nota: También se puede utilizar $\hat{\theta}_n = \arg \max_{\theta \in \Theta} \log L_n(\theta)$.

3.3.2 Cálculo efectivo del EMV

Típicamente $\hat{\theta}_n$ se obtiene como solución de la **ecuación de verosimilitud** siguiente:

$$\frac{\partial}{\partial \theta} \log L_n(\theta) = \frac{\partial}{\partial \theta} \sum_{i=1}^n \log f(x_i; \theta) = 0$$

Ejemplo 3.3.1 (de cálculo del estimador de máxima verosimilitud).

1. Para la distribución de Poisson de parámetro λ , $\hat{\lambda}_n = \bar{x}$ porque

$$L_n(\lambda) = \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{x_i}}{x_i!} = \frac{e^{-n\lambda} \lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!} \implies \frac{d}{d\lambda} \log L_n(\lambda) = -n + \sum_{i=1}^n x_i \frac{1}{\lambda}$$

Imponiendo $\frac{d}{d\lambda} \log L_n(\lambda) = 0$ se obtiene $\hat{\lambda}_n = \bar{x}$.

2. Para la exponencial de parámetro θ , $\hat{\theta}_n = \bar{x}$, si $f(x; \theta) = \frac{1}{\theta} e^{-x/\theta}$, $x > 0$.

3. Para la normal $N(\mu, \sigma)$, $\hat{\mu}_n = \bar{x}$, $\hat{\sigma}_n^2 = \sum_{i=1}^n (x_i - \bar{x})^2 / n$.

4. Para otras distribuciones, como la gamma o la Weibull, los e.m.v. de los parámetros existen pero no hay expresiones “cerradas” para ellos (aparecen como soluciones únicas de ciertas ecuaciones).

5. Para la multinomial

Proposición 3.3.1. Si g es una función biyectiva, entonces el EMV de $g(\theta)$ es $g(\hat{\theta}_n)$.

3.3.3 Motivación del método de máxima verosimilitud

Por la ley de los grandes números,

$$\frac{1}{n} \log L_n(\theta) \xrightarrow[n \rightarrow \infty]{c.s.} \Psi(\theta) := \mathbb{E}_{\theta_0} [\log f(X; \theta)] = \int (\log f(x; \theta)) f(x; \theta_0) dx.$$

Teorema 3.3.2. Sea $X \sim f(\cdot; \theta_0)$. Supongamos que

(MV0) Se verifica la condición de “buena parametrización”.

(MV1) Las distribuciones $f(\cdot; \theta)$ tienen un soporte común.

(MV2) $\forall \theta \in \Theta : \Psi(\theta) < \infty$.

Entonces, θ_0 es el único máximo de la función $\theta \mapsto \Psi(\theta)$ y además

$$\forall \theta \neq \theta_0 : \mathbb{P}_{\theta_0} \{L_n(\theta_0; X_1, \dots, X_n) > L_n(\theta; X_1, \dots, X_n)\} \xrightarrow{n \rightarrow \infty} 1.$$

Demostración. ■

3.3.4 Consistencia de los estimadores de máxima verosimilitud

Teorema 3.3.3. Con las mismas hipótesis del teorema anterior, suponemos que el espacio paramétrico Θ es un intervalo abierto (no necesariamente finito) y, para casi todo x , $f(x; \theta)$ es derivable respecto a θ con derivada continua. (MV3)

Entonces con probabilidad tendiendo a 1, la ecuación $\frac{\partial}{\partial \theta} \log L_n(\theta; X_1, \dots, X_n) = 0$ tiene una raíz $\hat{\theta}_n = \hat{\theta}_n(X_1, \dots, X_n)$ tal que $\hat{\theta}_n \xrightarrow[n \rightarrow \infty]{P} \theta_0$.

Si además suponemos que la raíz es única, se tiene que $\hat{\theta}_n$ maximiza la verosimilitud L_n y, por tanto, es el estimador de máxima verosimilitud de θ_0 .

3.4 Información de Fisher y cota de Frechet-Cramér-Rao

Una comparación entre estimadores de un mismo parámetro θ en base a su ECM puede no dar un único óptimo porque la clase de todos los posibles estimadores es muy amplia. Una manera de buscar el “mejor estimador” es restringir la búsqueda en la clase de los estimadores insesgados.

Definición 3.4.1. Diremos que un estimador T_n^* de θ es el estimador **insesgado uniformemente de mínima varianza** (ECUMV)

$$\iff \forall \theta \in \Theta : \mathbb{E}(T_n^*) = \theta \wedge \forall T_n \text{ insesgado de } \theta : \mathbb{V}_\theta(T_n^*) \leq \mathbb{V}_\theta(T_n).$$

Encontrar el ECUMV no es fácil. Una posibilidad es buscar una cota inferior para la varianza $\mathbb{V}_\theta(T_n)$ de cualquier estimador insesgado T_n de θ y después encontrar un estimador insesgado T_n^* cuya varianza alcance esa cota. Entonces habremos encontrado el ECUMV.

En la discusión que sigue suponemos que, para $k = 1$ y 2 ,

$$\frac{\partial^k}{\partial \theta^k} \int f(x; \theta) dx = \int \frac{\partial^k}{\partial \theta^k} f(x; \theta) dx.$$

Teorema 3.4.1 (cuándo permutar la derivada con la integral). *Sea una función $g = g(x; \theta)$, donde $x \in \mathbb{R}$ y $\theta \in \Theta$, un intervalo abierto de $\mathbb{R}$. Supongamos que:*

a) $\forall \theta \in \Theta$, g es integrable como función de x
(esto se cumple cuando g es una función de densidad de probabilidad).

b) Para casi todo x y para todo θ , existe $\frac{\partial}{\partial \theta} g(x; \theta)$.

c) Existe una función integrable $G : \mathbb{R} \rightarrow \mathbb{R}$, tal que, para todo θ , $\left| \frac{\partial}{\partial \theta} g(x; \theta) \right| \leq G(x)$.

$$\implies \forall \theta \in \Theta : \frac{\partial}{\partial \theta} \int g(x; \theta) dx = \int \frac{\partial}{\partial \theta} g(x; \theta) dx.$$

Demostración. xd ■

Entonces, para cada $\theta \in \Theta$ fijo, $\int f(x; \theta) dx = 1 \implies \int \frac{\partial}{\partial \theta} f(x; \theta) dx = 0$.

Por tanto, $\int \frac{\partial}{\partial \theta} (\log f(x; \theta)) f(x; \theta) dx = \mathbb{E}_\theta \left[\frac{\partial}{\partial \theta} \log f(X; \theta) \right] = 0$

y también (comprobarlo) $\mathbb{E}_\theta \left[-\frac{\partial^2}{\partial \theta^2} \log f(X; \theta) \right] = \mathbb{E}_\theta \left[\left(\frac{\partial}{\partial \theta} \log f(X; \theta) \right)^2 \right]$.

Si esta última cantidad es finita se denota por $I(\theta)$ y se denomina **información de Fisher**. Representa intuitivamente la “cantidad de información” acerca del valor del parámetro θ contenida en una observación de la v.a. X .

$$I(\theta) = E_\theta \left[-\frac{\partial^2}{\partial \theta^2} \log f(X; \theta) \right] = E_\theta \left[\left(\frac{\partial}{\partial \theta} \log f(X; \theta) \right)^2 \right] = E_\theta \left[\left(\frac{\frac{\partial}{\partial \theta} f(X; \theta)}{f(X; \theta)} \right)^2 \right].$$

Ejemplo 3.4.1. Sea X sin $N(\mu, \sigma)$ con μ desconocida y $\sigma > 0$ conocida. Calculemos la información de Fisher de μ . Tenemos que $f(x; \mu) = \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-\mu)^2/2\sigma^2}$, luego

$$\begin{aligned} \frac{\partial}{\partial \mu} \log f(x; \mu) &= \frac{\partial}{\partial \mu} \left[\log \left(\frac{1}{\sqrt{2\pi}\sigma} \right) - \frac{(x-\mu)^2}{2\sigma^2} \right] = \frac{x-\mu}{\sigma^2} \\ \implies I(\mu) &= \mathbb{E}_\mu \left[\left(\frac{x-\mu}{\sigma^2} \right)^2 \right] = \frac{1}{\sigma^4} \mathbb{E}_\mu [(x-\mu)^2] = \frac{1}{\sigma^2}. \end{aligned}$$

Por tanto, cuánto más pequeña sea la varianza de la distribución, más información se tiene sobre el parámetro μ .

Ejemplo 3.4.2 (de cálculo del emv cuando el soporte depende del parámetro).

Sea $X \sim U[0, \theta]$ con $\theta > 0$ desconocido $\implies \hat{\theta}_n = \text{emv}(\theta) = \arg \max_{\theta \geq 0} L_n(\theta, x_1, \dots, x_n)$.

Tenemos que $f(x; \theta) = \frac{1}{\theta} \mathbb{1}_{[0, \theta]}(x)$, luego la función de verosimilitud es

$$L_n(\theta) = \prod_{i=1}^n f(x_i; \theta) = \begin{cases} (1/\theta)^n & \text{si } 0 \leq x_1, \dots, x_n \leq \theta \\ 0 & \text{en otro caso} \end{cases} = \begin{cases} 1/\theta^n & \text{si } \theta \geq \max\{x_1, \dots, x_n\} \\ 0 & \text{en otro caso} \end{cases}$$

Teorema 3.4.2. *Suponiendo que las integrales que aparecen en la demostración son finitas, que existen las derivadas utilizadas en los cálculos y que se dan las condiciones que permiten intercambiar las derivadas y las integrales, se verifica que para cualquier estimador insesgado de θ , T_n , $V_\theta(T_n) \geq 1/nI(\theta)$.*

Demostración. Definimos la v.a. $Z = \frac{\partial}{\partial \theta} \log L_n = \sum_{i=1}^n \frac{\partial}{\partial \theta} \log f(X_i; \theta)$ que satisface que $\mathbb{E}_\theta(Z) = 0$ y $V_\theta(Z) = nI(\theta)$. Sea ahora $T_n = T_n(X_1, \dots, X_n)$ un estimador insesgado de θ . Comprobemos que $\text{Cov}_\theta(Z, T_n) = 1$. En efecto,

$$E_\theta(ZT_n) = \int \cdots \int T_n(x_1, \dots, x_n) \left[\sum_{i=1}^n \frac{\frac{\partial}{\partial \theta} f(x_i; \theta)}{f(x_i; \theta)} \right] \prod_{j=1}^n f(x_j; \theta) dx_1 \cdots dx_n.$$

Pero

$$\left[\sum_{i=1}^n \frac{\frac{\partial}{\partial \theta} f(x_i; \theta)}{f(x_i; \theta)} \right] \prod_{j=1}^n f(x_j; \theta) = \frac{\partial}{\partial \theta} \prod_{j=1}^n f(x_j; \theta).$$

Por tanto,

$$\begin{aligned} \text{Cov}_\theta(Z, T_n) &= \int \cdots \int T_n(x_1, \dots, x_n) \frac{\partial}{\partial \theta} \prod_{j=1}^n f(x_j; \theta) dx_1 \cdots dx_n \\ &= \frac{\partial}{\partial \theta} \int \cdots \int T_n(x_1, \dots, x_n) \prod_{j=1}^n f(x_j; \theta) dx_1 \cdots dx_n \\ &= \frac{\partial}{\partial \theta} E_\theta(T_n) = \frac{\partial}{\partial \theta} \theta = 1. \end{aligned}$$

Por otra parte, la desigualdad de Cauchy-Schwartz establece que

$$\text{Cov}_\theta^2(Z, T_n) \leq V_\theta(Z) V_\theta(T_n),$$

es decir,

$$V_\theta(T_n) \geq \frac{1}{nI(\theta)}.$$

■

Definición 3.4.2. El término $1/nI(\theta)$ se denomina **cota de Fréchet-Cramér-Rao**.

Los estimadores (insesgados) cuya varianza coincide con el valor de esta cota se denominan **eficientes**.

Proposición 3.4.3. En general, si T_n no es insesgado se tiene que

$$V_{\theta}(T_n) \geq \frac{\left(\frac{\partial}{\partial \theta} E_{\theta}(T_n)\right)^2}{nI(\theta)}.$$

3.5 Comportamiento asintótico de los e.m.v.

Evaluar las propiedades asintóticas de un estimador, T_n , de θ es una manera de estudiar su optimalidad mucho menos restrictiva que la teoría de “pequeñas muestras” (insesgadez, eficiencia, ...).

Los estimadores de interés típicamente son consistentes y asintóticamente normales cuando $n \rightarrow \infty$. La varianza asintótica, $\sigma^2(\theta)$, proporciona una posible medida de la precisión del estimador. Si el estimador T_n es consistente y asintóticamente normal con

$$\sigma^2(\theta) = \frac{1}{I(\theta)},$$

entonces decimos que T_n es *asintóticamente eficiente*.

Un estimador asintóticamente eficiente minimiza la varianza asintótica uniformemente en θ dentro de la clase de los estimadores asintóticamente insesgados.

Teorema 3. Supongamos que se cumplen las condiciones (MV0)-(MV8):

(MV0) Θ es abierto.

(MV1) Las distribuciones $f(\cdot; \theta)$ tienen un soporte común.

(MV2) Para cada x la densidad $f(x; \theta)$ es tres veces diferenciable respecto a θ , con la tercera derivada continua en θ .

(MV3) $0 < I(\theta_0) < \infty$.

(MV4) $\Psi(\theta) := E_{\theta_0}(\log f(X; \theta)) < \infty$ para todo $\theta \in \Theta$.

(MV5) Se puede permutar dos veces la integral $\int f(x; \theta) dx$ con la derivada respecto a θ .

(MV6) Para cada $\theta_0 \in \Theta$ existen un número $c > 0$ y una función $M(x)$ (que pueden depender

de θ_0) tales que $E_{\theta_0}[M(X)] < \infty$ y

$$\left| \frac{\partial^3}{\partial \theta^3} \log f(x; \theta) \right| \leq M(x), \quad \forall x, \theta \in (\theta_0 - c, \theta_0 + c).$$

(MV7) $\hat{\theta}_n \xrightarrow{P} \theta$ cuando $n \rightarrow \infty$.

Entonces

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} N\left(0, \frac{1}{I(\theta_0)}\right).$$

Demostración del Teorema 3. Denotemos

$$\log L_n(\theta; X_1, \dots, X_n) = \tilde{\Psi}_n(\theta) := \sum_{i=1}^n \log f(X_i; \theta),$$

$$\tilde{\Psi}'_n = \frac{\partial}{\partial \theta} \tilde{\Psi}_n, \quad f' = \frac{\partial}{\partial \theta} f.$$

Recordemos que $\tilde{\Psi}_n(\theta)$ depende de la muestra. Para cada muestra fija se tiene

$$0 = \tilde{\Psi}'_n(\hat{\theta}_n) = \tilde{\Psi}'_n(\theta_0) + (\hat{\theta}_n - \theta_0)\tilde{\Psi}''_n(\theta_0) + \frac{1}{2}(\hat{\theta}_n - \theta_0)^2\tilde{\Psi}'''_n(\theta_n^*),$$

para algún θ_n^* entre $\hat{\theta}_n$ y θ_0 . Como el primer miembro es 0, resulta

$$\sqrt{n}(\hat{\theta}_n - \theta_0) = \frac{\frac{1}{\sqrt{n}}\tilde{\Psi}'_n(\theta_0)}{-\frac{1}{n}\tilde{\Psi}''_n(\theta_0) - \frac{1}{2n}(\hat{\theta}_n - \theta_0)\tilde{\Psi}'''_n(\theta_n^*)}.$$

La idea clave de la demostración es:

1. Probar que el numerador tiende en distribución a una $N(0, \sqrt{I(\theta_0)})$.
2. Probar que el primer término del denominador tiende en probabilidad a $I(\theta_0)$.
3. Probar que el segundo término del denominador tiende en probabilidad a 0.
4. Usar el Teorema de Slutsky para concluir.

Demostración del Teorema 3 (cont.):

Paso 1:

$$\frac{1}{\sqrt{n}}\tilde{\Psi}'_n(\theta_0) = \sqrt{n} \left[\frac{1}{n} \sum_{i=1}^n \frac{\partial}{\partial \theta} \log f(X_i; \theta_0) - E_{\theta_0} \left(\frac{\partial}{\partial \theta} \log f(X; \theta_0) \right) \right].$$

Como $E_{\theta_0} \left(\frac{\partial}{\partial \theta} \log f(X; \theta_0) \right) = 0$, la aplicación del TCL y la definición de $I(\theta_0)$ proporcionan directamente:

$$\frac{1}{\sqrt{n}}\tilde{\Psi}'_n(\theta_0) \xrightarrow{d} N(0, \sqrt{I(\theta_0)}).$$

Paso 2:

$$-\frac{1}{n}\tilde{\Psi}_n''(\theta_0) = \frac{1}{n} \sum_{i=1}^n \frac{f'(X_i; \theta_0)^2 - f(X_i; \theta_0)f''(X_i; \theta_0)}{f(X_i; \theta_0)^2}.$$

Por la Ley de los Grandes Números, esto tiende en probabilidad a:

$$I(\theta_0) - E_{\theta_0} \left(\frac{f''(X; \theta_0)}{f(X; \theta_0)} \right) = I(\theta_0).$$

Paso 3: Finalmente,

$$\frac{1}{n}\tilde{\Psi}_n'''(\theta) = \frac{1}{n} \sum_{i=1}^n \frac{\partial^3}{\partial \theta^3} \log f(X_i; \theta),$$

de modo que:

$$\left| \frac{1}{n}\tilde{\Psi}_n'''(\theta_n^*) \right| \leq \frac{1}{n} \sum_{i=1}^n M(X_i).$$

Con probabilidad tendiendo a 1, esto está acotado ya que el segundo miembro tiende a $E_{\theta_0}[M(X)]$. En definitiva, como $\hat{\theta}_n \xrightarrow{P} \theta_0$, deducimos:

$$\frac{1}{2n}(\hat{\theta}_n - \theta_0)\tilde{\Psi}_n'''(\theta_n^*) \xrightarrow{P} 0.$$

Esto concluye la prueba del Teorema 3.

Para n suficientemente grande, el resultado anterior concluye que:

$$\hat{\theta}_n \sim N \left(\theta, \frac{1}{nI(\theta)} \right).$$

Es decir, para tamaños muestrales grandes esperamos que el EMV sea aproximadamente insesgado y casi alcance la cota de F-C-R. Observemos que la variabilidad asintótica del EMV es inversamente proporcional a la información de Fisher.

3.6 El método de los momentos

Sea $X \sim f(\cdot; \theta)$, donde $\theta = (\theta_1, \dots, \theta_p)$ es un parámetro p -dimensional ($p \geq 1$). Si los momentos $\alpha_k(\theta) := E_{\theta}(X^k)$, $k = 1, \dots, p$, son funciones sencillas de los θ_i , un procedimiento natural para obtener un estimador de θ es resolver en $\theta_1, \dots, \theta_p$ el sistema de ecuaciones:

$$m_1 = \alpha_1(\theta), \dots, m_p = \alpha_p(\theta),$$

donde m_k es el momento muestral de orden k , $m_k = \frac{\sum_{i=1}^n X_i^k}{n}$.

La idea es estimar el parámetro como aquel valor de θ que hace que los momentos pobla-

cionales (tantos como componentes tenga θ) coincidan con los correspondientes momentos muestrales. En general, si θ_0 es el verdadero valor del parámetro, no sucederá que $m_k = \alpha_k(\theta_0)$ (de hecho, m_k es aleatorio), pero, por la Ley de los Grandes Números, $m_k \rightarrow \alpha_k(\theta_0)$ cuando $n \rightarrow \infty$.

Ejemplo del método de los momentos:

Sea $f(x; \theta) = \frac{1+\theta x}{2} \mathbf{1}_{[-1,1]}(x)$, $\theta \in [-1, 1]$. No es sencillo calcular el EMV, pero sí obtener el estimador por el método de los momentos:

$$E_\theta(X) = \int_{-1}^1 x f(x; \theta) dx = \frac{\theta}{3}.$$

Por tanto, la solución de $\bar{X} = E_\theta(X)$ es $\tilde{\theta}_n = 3\bar{X}$, cuya varianza es:

$$V_\theta(\tilde{\theta}_n) = V_\theta(3\bar{X}) = \frac{9\sigma^2}{n} = \frac{3 - \theta^2}{n}.$$

Este estimador es consistente ya que, por la LGN, $3\bar{X} \xrightarrow{c.s.} 3E_\theta(X) = \theta$.

3.7 Estimadores bayesianos

3.7.1 La distribución a priori

En muchos casos se tiene cierta información a priori (es decir, antes de extraer la muestra) sobre la probabilidad (entendida como “grado de creencia subjetiva”) de los diferentes valores del parámetro θ . En estos casos se sabe, o se supone, que ciertos intervalos de valores de θ son “más probables que otros” y se concreta esta información en una distribución a priori sobre θ cuya función de densidad se denota por $\pi(\theta)$.

Formalmente, este planteamiento equivale a considerar el parámetro θ como una v.a. con distribución conocida. En consecuencia, la densidad $f(x; \theta)$ con la que se generan los datos puede considerarse como la densidad condicionada de X dado θ . Por este motivo, se suele emplear la notación $f(x | \theta)$ en lugar de $f(x; \theta)$.

Del mismo modo, la función de densidad de la muestra $f(x_1, \dots, x_n; \theta)$ puede interpretarse (como función de $x_1, \dots, x_n$ para cada θ fijo) como la densidad del vector aleatorio $(X_1, \dots, X_n)$, condicionada al valor θ del parámetro. Por este motivo, suele denotarse (con cierto abuso de notación),

$$f(x_1, \dots, x_n | \theta) := \prod_{i=1}^n f(x_i | \theta).$$

3.7.2 La distribución a posteriori

La idea de la metodología bayesiana consiste en combinar la información a priori (recogida en $\pi(\theta)$) con la información muestral y la del modelo (recogidas en $f(x_1, \dots, x_n | \theta)$). Esto se consigue aplicando la fórmula de Bayes para obtener la “distribución a posteriori”, definida por la siguiente función de densidad en Θ :

$$\pi(\theta | x_1, \dots, x_n) = \frac{f(x_1, \dots, x_n | \theta)\pi(\theta)}{\int_{\Theta} f(x_1, \dots, x_n | \theta)\pi(\theta)d\theta}. \quad (3.1)$$

La densidad a posteriori recoge toda la información disponible sobre θ y es la base de todos los procedimientos de inferencia en la metodología bayesiana.

El cálculo de $\pi(\theta | x_1, \dots, x_n)$ puede ser complicado, pero en muchos casos se simplifica recordando que debe integrar 1. Esto significa que la integral que aparece en el denominador de 3.1 puede ser considerada como una constante (en el sentido de que no depende de θ) y esta es justamente la constante necesaria para que la integral en θ de $\pi(\theta | x_1, \dots, x_n)$ sea 1. Por tanto, en algunos ejemplos importantes, no es necesario calcular esa integral, siempre que, a partir del numerador de 3.1, se pueda identificar el tipo de distribución al que corresponde la densidad a posteriori.

Por ejemplo, si el numerador de la fórmula de Bayes es, salvo constantes multiplicativas, de la forma $\theta^{p-1}e^{-a\theta}$, entonces no es necesario calcular la integral del denominador porque ya podemos asegurar que $\pi(\theta | x_1, \dots, x_n)$ es una densidad gamma de parámetros a y p .

Ejemplo 3.7.1. Sea θ la proporción de votantes de un partido P . Asumimos que $X \sim \text{Bernoulli}(\theta)$. Con una priori $\text{Beta}(4, 10)$, la posteriori es:

$$\pi(\theta | x_1, \dots, x_n) \sim \text{Beta}(4 + \sum x_i, 10 + n - \sum x_i).$$

El estimador de Bayes es:

$$T_n = E[\theta | x_1, \dots, x_n] = \frac{4 + \sum x_i}{14 + n}.$$

En este caso, el estimador Bayes es una media ponderada entre la media muestral y el valor esperado de la distribución a priori. Si, por ejemplo, $\sum x_i = 125$ y $n = 1000$, entonces:

$$T_n = \frac{4 + 125}{14 + 1000} = 0.12722, \quad \hat{\theta}_n = \frac{125}{1000} = 0.125.$$

3.7.3 Familias conjugadas

En modelos bayesianos, una familia Π de distribuciones a priori es *conjugada* para una clase de densidades F si, al combinar una priori $\pi(\theta) \in \Pi$ con una función de verosimilitud $f(x \mid \theta) \in F$, la posteriori $\pi(\theta \mid x)$ pertenece también a Π .

Por ejemplo, para $X \sim \text{Bernoulli}(\theta)$, la familia $\text{Beta}(a, b)$ es conjugada, ya que la posteriori $\pi(\theta \mid x_1, \dots, x_n)$ será también una distribución Beta.

Más recientemente, se han desarrollado métodos numéricos, como el *Gibbs sampling* y, más en general, los métodos MCMC (*Markov chain Monte Carlo*), que permiten extender el uso de los métodos bayesianos a modelos muy complejos.

4. Tema 4

5. Contraste de hipótesis

5.1 Planteamiento del problema. Conceptos básicos

El onjetivo de la teoría de contraste de hjiipótesis es elegir entre dos posibilidades mulutualmente excluyentes, llamadas hipótesis nula y alternativa. Ambas relativas al valor de un parámetro poblacional, a partir de la información proporcionada por la muestra.

Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria de una v.a. X con función de distribución F_θ donde $\theta \in \Theta$.

Objetivo: Dada un partición del espacio paramétrico $\Theta = \Theta_0 \cup \Theta_1$, queremos contrastar las hipótesis H_0 y H_1 donde

$$H_0 : \theta \in \Theta_0 \quad (\text{hipótesis nula}), \quad H_1 : \theta \in \Theta_1 \quad (\text{hipótesis alternativa}),$$

Un test consiste en proporcionar una regla de decisión que, a cada observación de la muestra $(x_1, \dots, x_n)$, asigne una decisión: aceptar o rechazar H_0 .

Los contrastes habituales (no aleatorizados) se definen mediante una **región crítica** o **región de rechazo** $R \subset \mathbb{R}^n$ tal que cuando $(x_1, \dots, x_n) \in R$ se rechaza H_0 .

Es importante destacar que la metodología de contraste de hipótesis no “demuestra” la validez de la hipótesis que se acepta en cada caso (en el sentido en el que se demuestra algo mediante un método deductivo, por ejemplo). La manera correcta de interpretar los resultados es decir que los datos disponibles proporcionan (o no) evidencia estadística suficiente en contra de la hipótesis nula. En todo caso, la conclusión depende de información incompleta y aleatoria, procedente de una o varias muestras, y siempre existe la posibilidad de cometer un error aceptando una hipótesis equivocada.

Los procedimientos que se utilizan se suelen denominar **contrastos** o **tests de hipótesis**.

Posibles errores de un test:

- **Error de tipo I:** Rechazar H_0 cuando H_0 es cierta.
- **Error de tipo II:** Aceptar H_0 cuando H_0 es falsa.

Definición 5.1.1. La **función de potencia** de un test con región de rechazo R para contrastar $H_0 : \theta \in \Theta_0$ frente a $H_1 : \theta \in \Theta_1$ es $\theta_n : \Theta \rightarrow [0, 1]$

$$\theta \mapsto \beta_n(\theta) = \mathbb{P}_0 \{(X_1, \dots, X_n) \in R\}$$

Lo que en realidad se suele hacer es la **teoría de Neyman-Pearson**:

1. Acotar la probabilidad máxima de error de tipo I:

- Se fija un *nivel de significación* $\alpha \in (0, 1)$. Típicamente $\alpha = 0.05$.
- Se define el *tamaño* de un test como la máxima probabilidad de error de tipo I:

$$\max_{\theta \in \Theta_0} \mathbb{P}_\theta(R) = \max_{\theta \in \Theta_0} \beta_n(\theta).$$

- Se busca una región de rechazo R tal que $\max_{\theta \in \Theta_0} \mathbb{P}_\theta(R) \leq \alpha$.

2. Minimizar la probabilidad de error de tipo II: Se intenta buscar una región de rechazo R que maximice la función de potencia cuando $\theta \in \Theta_1$.

Las hipótesis H_0 y H_1 no son simétricas.

Como vemos, los test de hipótesis están diseñados para controlar la probabilidad máxima de rechazar H_0 cuando es cierta. En consecuencia, suelen ser “conservadores” con la hipótesis nula: hace falta mucha evidencia muestral para rechazar H_0 .

Observemos que es posible que, con los mismos datos, H_0 se rechace para un nivel de significación $\alpha = 0.05$ y se acepte para $\alpha = 0.01$.

En una primera aproximación, los problemas de contraste de hipótesis pueden clasificarse en **problemas de una muestra** (cuando hay una sola población de interés) y **problemas de dos muestras** (cuando se quiere comparar dos poblaciones y se dispone de una muestra de cada una de ellas). Presentaremos las ideas básicas en el caso de los problemas de una muestra pero pueden extenderse de modo análogo a los de dos muestras.

Ejemplo 5.1.1 (de contraste de 2 muestras). Sean $X_1, \dots, X_n$ e $Y_1, \dots, Y_m$ dos muestras aleatorias independientes de $N(\mu_1, \sigma_1)$ y $N(\mu_2, \sigma_2)$ respectivamente. Queremos contrastar $H_0 : \mu_1 = \mu_2$ frente a $H_1 : \mu_1 \neq \mu_2$. Consideramos $H =$ conjunto de posibles valores de $\mu_1 - \mu_2$, entonces $H_0 : \mu_1 - \mu_2 = 0$ y $H_1 : \mu_1 - \mu_2 \neq 0$ y se reduce a un contraste de una muestra.

Ejemplo 5.1.2. Sea $X =$ volumen de una botella de aceite $\sim N(\mu, \sigma^2)$ con μ y σ^2 desconocidos. De una muestra $x_1, \dots, x_{n=5}$, obtenemos que $\bar{x} = 95$ y $s = 1.1$.

$$X \sim N(\mu, \sigma^2) \implies \bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right) \implies \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1) \implies \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}$$

Queremos contrastar $H_0 : \mu = 100$ frente a $H_1 : \mu \neq 100$. Tenemos $\{|t| > t_{n-1, \alpha/2}\}$ como

región de rechazo donde $t = \frac{\bar{X} - 100}{\frac{S}{\sqrt{n}}} = -10.66$.

$$\alpha = 0.05 \implies t_{4,0.025} = 2.77... \implies \text{rechazamos } H_0.$$

$$\alpha = 0.01 \implies t_{4,0.005} = 4.60... \implies \text{rechazamos } H_0.$$

Si α sigue disminuyendo, la región de rechazo se hace más pequeña y llega α a un valor “frontera” α^* a partir del cual no se rechaza H_0 .

En este ejemplo hemos contrastado una hipótesis nula **simple** ya que H_0 indicaba que μ es exactamente 100. En  la hipótesis H_1 se llama **alternative** y puede ser **two.sided**, es decir, **greater** y **less**.

Supongamos ahora que queremos contrastar $H_0 : \mu \geq 100$ frente a $H_1 : \mu < 100$. En este caso, se llaman hipótesis **unilaterales** y la región de rechazo sería $R = \{t < -t_{n-1,\alpha}\}$, es decir, rechazaremos H_0 cuando $\bar{x}$ sea significativamente menor que μ_0 . Comprobemos si $\max_{H_0} \mathbb{P}(R) \leq \alpha$. Supongamos que $H_0 : \mu \geq \mu_0$ es cierta, queremos ver que $\mathbb{P}(R) \leq \alpha$.

$$\begin{aligned} \mathbb{P}_\mu(R) &= \mathbb{P}_\mu \{t < -t_{n-1,\alpha}\} = \mathbb{P}_\mu \left\{ \frac{\bar{X} - \mu}{S/\sqrt{n}} < -t_{n-1,\alpha} \right\} = \mathbb{P}_\mu \left\{ \frac{\bar{X} - \mu}{S/\sqrt{n}} + \frac{\mu - \mu_0}{S/\sqrt{n}} < -t_{n-1,\alpha} \right\} \\ &= \mathbb{P}_\mu \left\{ \frac{\bar{X} - \mu}{S/\sqrt{n}} < -t_{n-1,\alpha} - \frac{\mu - \mu_0}{S/\sqrt{n}} \right\} \leq \alpha \end{aligned}$$

Supongamos que hubieramos obtenido $\bar{x} = 98$. Entonces $\frac{\bar{x} - 100}{S/\sqrt{5}} = -4.2640$.

Como $-t_{4,0.01} = -3.747$, la hipótesis nula se rechaza y con un nivel de significación $\alpha = 0.05$ también ya que $-t_{4,0.01} = -2.1318$.

5.2 Contrastes para la media de una distribución

En cada caso se rechaza H_0 cuando $(x_1, \dots, x_n) \in R$.

- **Distribución normal con varianza conocida:** Sea $X \sim N(\mu, \sigma)$ con σ conocida.

$$H_0 : \mu = \mu_0 \quad R = \left\{ (x_1, \dots, x_n) : \left| \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} \right| \geq z_{\alpha/2} \right\} = \left\{ (x_1, \dots, x_n) : |z| \geq z_{\alpha/2} \right\}$$

$$H_0 : \mu \leq \mu_0 \quad R = \{(x_1, \dots, x_n) : z \geq z_\alpha\}$$

$$H_0 : \mu \geq \mu_0 \quad R = \{(x_1, \dots, x_n) : z \leq z_{1-\alpha}\}$$

donde $z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$ y $\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1)$ es el estadístico de contraste.

- **Distribución normal con varianza desconocida:** Sea $X \sim N(\mu, \sigma)$ con σ desconocida.

$$H_0 : \mu = \mu_0 \quad R = \{(x_1, \dots, x_n) : |t| \geq t_{n-1, \alpha/2}\}$$

$$H_0 : \mu \leq \mu_0 \quad R = \{(x_1, \dots, x_n) : t \geq t_{n-1, \alpha}\}$$

$$H_0 : \mu \geq \mu_0 \quad R = \{(x_1, \dots, x_n) : t \leq t_{n-1, 1-\alpha}\}$$

siendo $t = \frac{\bar{x} - \mu_0}{S/\sqrt{n}} \sim t_{n-1}$ el estadístico de contraste.

Cómo hacer un contraste de la t con :

```
help(t.test)
t.test(x, y = NULL, alternative = c("two.sided", "less", "greater"),
       mu = 0, paired = FALSE, var.equal = FALSE, conf.level = 0.95,...)
```

Ejercicio 5.2.1. Se certifica que un material estándar de referencia de un suelo contiene 94.6 ppm de un contaminante orgánico. Un análisis repetido arrojó los siguientes resultados: 98.6, 98.4, 97.2, 94.6 y 96.2 ppm. A un nivel de significación $\alpha = 0.05$ ¿hay suficiente evidencia estadística para concluir que los resultados difieren del valor esperado?. Si se disminuye α a 0.01, ¿se rechazaría H_0 ?

Solución. Suponemos que $X \sim N(\mu, \sigma)$ con μ y σ desconocidos. Como $n = 5$ y por tanto no podemos emplear la distribución asintótica de un estadístico del contraste, nuestra única distribución para resolver el contraste es $N(\mu, \sigma)$.

$$H_0 : \mu = 94.6 \wedge H_1 : \mu \neq 94.6 \quad R = \{|t| > t_{4, \alpha}\} \quad \text{donde } t = \frac{\bar{x} - 94.6}{s/\sqrt{5}} = 3.2421$$

```
X = c(98.6, 98.4, 97.2, 94.6, 96.2)
t.test(X, alternative="two.sided", mu=94.6)
```

Obtenemos como resultado:

```
One Sample t-test
data: X
t = 3.2421, df = 4, p-value = 0.03161
alternative hypothesis: true mean is not equal to 94.6
95 percent confidence interval:
 94.94468 99.05532
sample estimates:
mean of x
97
```


El intervalo de confianza es $IC_{95\%} = (94.94468, 99.05532)$ a nivel $\alpha = 0.05$.

El programa nos devuelve el p -valor del contraste que es 0.03161 y se define como $\inf \{ \alpha : \text{se rechaza } H_0 \}$. Como $0.03161 < 0.05$, se rechaza H_0 a nivel $\alpha = 0.05$.

6. Ejercicios

6.1 Hoja 1: Estadística descriptiva

1. Descarga el fichero de datos `data_banknote_authentication.txt` del repositorio de aprendizaje automático de la UC Irvine. Se han obtenido de imágenes digitalizadas de billetes de banco auténticos y falsificados, pero la información del repositorio no incluye cuál de las etiquetas (0 ó 1) corresponde a los auténticos. De cada imagen se obtuvieron cuatro variables continuas:


1. Varianza de la transformada por ondículas de la imagen.
2. Asimetría de la transformada por ondículas de la imagen.
3. Curtosis de la transformada por ondículas de la imagen.
4. Entropía de la imagen.

Realiza un análisis exploratorio de los datos y compara los dos grupos. Calcula estadísticos de posición y dispersión y realiza representaciones gráficas. Extrae conclusiones.

Solución. Con el siguiente código, podemos cargar los datos y realizar el análisis:

```
1  # Cargamos los datos
2  data = read.table("data_banknote_authentication.txt", sep=",")
3
4  data0 = data[data$V5 == 0,] # Seleccionamos los datos de la clase 0
5  data1 = data[data$V5 == 1,] # Seleccionamos los datos de la clase 1
6
7  # Estadísticos de posición
8  summary(data0) # Estadísticos de posición de la clase 0
9  summary(data1) # Estadísticos de posición de la clase 1
10
11 # Estadísticos generales
12 library(GGally) # Cargamos la librería GGally
13                # (muy potente para visualización de datos)
14 data$V5 <- as.factor(data$V5) # Convertimos la variable V5 a factor
15 ggpairs(data, aes(colour = data$V5)) # Dibujamos la matriz de gráficos
16                                     # de dispersión
```

Como resultado, obtenemos los estadísticos de posición de cada clase y la matriz de gráficos de dispersión. De esta forma, podemos comparar visualmente las distribuciones de las variables en cada clase.



Vemos que, en general, los individuos de la clase 0 corresponden a mediciones mayores de las variables 1 y 2. Además, hay mayor correlación entre las variables en la clase 0. Por tanto, concluimos que la clase 1 es la de los billetes auténticos.

2. Demuestra que $\sum_{i=1}^n (x_i - \bar{x})^2 = \min_{a \in \mathbb{R}} \sum_{i=1}^n (x_i - a)^2$

¿Qué significa esto en relación con la interpretación intuitiva de la media muestral?

Solución. Podemos hacerlo de dos formas:

(a) Podemos derivar la función a minimizar e igualar a 0:

$$\frac{d}{dx} \left(\sum_{i=1}^n (x_i - x)^2 \right) = \sum_{i=1}^n -2(x_i - x) = 0 \iff \sum_{i=1}^n x_i = \sum_{i=1}^n x \iff x = \bar{x}$$

(b) O podemos sumar y restar $\bar{x}$ para luego desarrollar el cuadrado:

$$\begin{aligned} \sum_{i=1}^n (x_i - a)^2 &= \sum_{i=1}^n (x_i - \bar{x} + \bar{x} - a)^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + 2(x_i - \bar{x})(\bar{x} - a) + \sum_{i=1}^n (\bar{x} - a)^2 \\ &\leq \sum_{i=1}^n (x_i - \bar{x})^2 \text{ y la igualdad se cumple } \iff a = \bar{x} \end{aligned}$$

3. Utilizando el fichero de datos **worldbank**, disponible en el paquete de  llamado **ks**, analiza los datos de emisiones de CO2 y de Producto Interior Bruto per cápita (GDP.capita) que se incluyen en el fichero para diferentes países del mundo. ¿Hay mucha diferencia entre las medias y las medianas? ¿Dirías que estos datos han sido extraídos de variables aleatorias con distribución normal?

Nota: Observa que hay bastantes “missing values” en el fichero (denotados con NA). El comando `na.omit` permite descartarlos sin necesidad de suprimirlos manualmente.

Solución. Podemos realizar el análisis con el siguiente código:


```
1 library(ks) # Cargamos la librería ks
2 data(worldbank) # Cargamos los datos de la librería worldbank
3 names(worldbank) # Mostramos los nombres de las variables disponibles
4
5 # Extraemos las variables de interés
6 C02 <- worldbank$C02
7 gdp_per_capita <- worldbank$GDP.capita
8
9 # Resumen de las variables
10 summary(C02)
11 summary(gdp_per_capita)
12
13 library(GGally) # Cargamos la librería GGally
14 # Dibujamos la matriz de gráficos de dispersión
15 ggpairs(data.frame(C02, gdp_per_capita))
```

Como resultado obtenemos la siguiente tabla de medias y medianas:

	CO2	PIB per cápita
Media	4.9	16618.3
Mediana	2.6	5728.1

En ella vemos que efectivamente la media es mucho mayor que la mediana para ambas variables, lo que indica que las distribuciones están sesgadas a la derecha.

Además, el código también nos muestra la matriz de gráficos de dispersión siguiente:



Como vemos, no parece que los datos sigan una distribución normal.

Podemos concluir que hay muy pocos países que emitan mucho CO2 o que tengan un PIB per cápita alto, aunque ambas cosas no parecen estar tan relacionadas pues el coeficiente de correlación es relativamente bajo.

4. Consideramos los pingüinos de la especie **Gentoo** que aparecen en el conjunto de datos **penguins** de la librería **palmerpenguins** de **R**. Para información detallada de estos datos escribir **help(penguins)** en la consola de **R**.


- Realizar un análisis descriptivo univariante de la longitud del pico: calcular los estadísticos de tendencia central, las medidas de dispersión y representar un diagrama de cajas y un estimador núcleo de la función de densidad. ¿Qué se observa en relación con las modas? Estudia la presencia de datos atípicos en la muestra.
- Dibuja el diagrama de dispersión de la longitud del pico y de la aleta. Selecciona una de las dos como variable respuesta y la otra como explicativa. Calcula la recta de regresión y el coeficiente de correlación. Interpreta los resultados.

Solución.


(a) El código para realizar el análisis univariante de la longitud del pico es el siguiente:

```
1 library(palmerpenguins) # Cargamos la librería palmerpenguins
2 # Seleccionamos los datos de la especie Gentoo
3 data = penguins[penguins$species == "Gentoo",]
4 picos = data$bill_length_mm # Extraemos la longitud del pico
5 summary(picos) # Resumen de la longitud del pico
6
7 par(mfrow = c(1, 2)) # Dividimos la ventana gráfica en 2 columnas
8 # Diagrama de caja
9 boxplot(picos, main = "Diagrama de Caja",
10         xlab = "Longitud del Pico", horizontal = TRUE)
11 # Estimador de densidad de núcleo
12 plot(density(picos, na.rm = TRUE), main = "Estimador Núcleo",
13       xlab = "Longitud del Pico", ylab = "Densidad")
```

Que nos da como resultado:



Sin embargo, observamos un dato atípico en el diagrama de caja. Podemos quitarlo de la muestra con `picos = sort(picos)[-123]` y volver a realizar el análisis.




Vemos que hay claramente dos modas probablemente correspondientes a pingüinos macho y hembra. Aparte de eso, la distribución parece bastante simétrica y centrada en torno a la media.

(b) Para resolver este apartado, necesitaremos el siguiente código adicional:

```
aletas = data$flipper_length_mm # Extraemos la longitud de las aletas
# Diagrama de dispersión de aletas y picos
plot(aletas, picos, main = "Diagrama de Dispersión",
      xlab = "Longitud de las Aletas", ylab = "Longitud del Pico")
# Recta de regresión
line = lm(picos ~ aletas)
abline(line, col = "red") # Añadimos la recta a la gráfica
```

Que nos dibuja la gráfica siguiente:



Vemos que las variables guardan una relación lineal positiva.

Sin embargo, hay bastante variabilidad en la muestra y por tanto la nube de datos no se ajusta perfectamente a la recta y el coeficiente de correlación no es muy elevado

```
cor(picos, aletas) = 0.6611621.
```

5. El paquete **gapminder** contiene un fichero de datos de población, esperanza de vida y renta per cápita de los países del mundo entre 1952 y 2007. Instala el paquete y lleva a cabo los siguientes gráficos:

- Un histograma de la esperanza de vida en 2007 de los países de Europa.
- Diagramas de cajas con las esperanzas de vida de cada continente en el año 1952.

- c) Un diagrama de dispersión de la renta per cápita y la esperanza de vida de cada país en el año 2007.
- d) Mejora el gráfico anterior representando cada punto de un color diferente en función del continente al que pertenece cada país y representando la renta per cápita en una escala logarítmica.

6. Determina razonadamente si las siguientes afirmaciones son verdaderas o falsas:

- a) Si añadimos 7 a todos los datos de un conjunto, el primer cuartil aumenta en 7 unidades y el rango intercuartílico no cambia.
- b) Si todos los datos de un conjunto se multiplican por -2 , la desviación típica se dobla.
- c) Si todos los datos de un conjunto se multiplican por 2, la varianza se dobla.
- d) Si cambiamos el signo de todos los datos de un conjunto, el coeficiente de asimetría también cambia de signo.
- e) Al multiplicar por tres todos los datos de un conjunto, el coeficiente de asimetría no varía.
- f) Si el coeficiente de correlación entre dos variables vale -0.8 , los valores por debajo del promedio de una variable están asociados con valores por debajo del promedio de la otra.
- g) Si para todo i , se cumple $y_i < x_i$, el coeficiente de correlación entre x e y es negativo.
- h) Al restar una unidad a cada dato de un conjunto, la desviación típica siempre disminuye.
- i) Si a un conjunto de datos con media $\bar{x}$ se le añade un nuevo dato que coincide con $\bar{x}$, la media no cambia y la desviación típica disminuye.

Solución.

- a) Es **verdadero** porque el primer cuartil es el valor que deja por debajo al 25% de los datos, y al sumar 7 a todos los datos, el 25% de los datos que antes eran menores que el primer cuartil, ahora son menores que el primer cuartil más 7. Por otro lado, el rango intercuartílico no cambia porque es la diferencia entre el tercer y el primer cuartil, y al sumar 7 a todos los datos, ambos cuartiles aumentan en 7.
- b) Es **verdadero** porque $\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$, y al multiplicar por -2 todos los datos, la media se multiplica por -2 y la desviación típica se multiplica por $|-2| = 2$.

- c) Es **falso** por el argumento anterior, al multiplicar todos los datos por 2, la varianza se multiplica por $2^2 = 4$.
- d) Es **verdadero** porque el coeficiente de asimetría es igual a $\frac{\sum_{i=1}^n (x_i - \bar{x})^3}{n\sigma^3}$, y al cambiar el signo de todos los datos, el numerador cambia de signo, pero el denominador no, por lo que el coeficiente de asimetría también cambia de signo.
- e) Es **verdadero** porque, similar a como ocurre en el apartado anterior, el numerador se multiplica por $3^3 = 27$ al igual que el denominador, por lo que el coeficiente de asimetría no varía.
- f) Es **falso** porque al ser el coeficiente de correlación negativo, cuando una variable aumenta, la otra disminuye y por tanto, los valores por debajo de la media de una variable están asociados con valores por encima de la media de la otra.
- g) Es **falso** porque el coeficiente de correlación no depende de la escala de las variables, sino de la relación lineal entre ellas.
- h) Es **falso** porque la desviación típica mide la dispersión de los datos respecto a la media, y al restar una unidad a cada dato, la dispersión no cambia, solo la posición de los datos.
- i) Es **verdadero** porque la media no cambia al añadir un dato igual a la media, y la desviación típica disminuye porque la dispersión de los datos respecto a la media disminuye.

7. Explica brevemente, línea a línea, qué hace el siguiente código de R :

```

1 X <- rnorm(30,-1,2) # Genera 30 datos aleatorios de una normal(-1, 2)
2 summary(X) # Resumen de los datos
3 quantile(X,0.9) # Devuelve el percentil 90
4 var(X) # Calcula la varianza de X
5 library(moments) # Carga la librería moments
6 skewness(X) # Calcula el coeficiente de asimetría
7 X0 <- sort(X) # Ordena los datos de X
8 X0[1] # Devuelve el menor dato
9 length(X) # Devuelve la longitud de X
10 f <- density(X) # Calcula el estimador de densidad de núcleo de X

```

De manera razonada, haz corresponder cada uno de los resultados que se ven debajo con el comando del código anterior que lo generó:

<code>length(X): [1] 30</code>	<code>quantile(X,0.9):</code> 90% 1.210152
<code>skewness(X) [1] 0.2894119</code>	<code>X0[1]: [1] -4.293553</code>
<code>summary(X):</code> Min. 1st Qu. Median Mean 3rd Qu. Max. -4.2936 -2.2853 -1.1732 -1.1023 0.15714765	<code>var(X): [1] 3.47647</code>

8. Ejecuta el siguiente código en *R*:

```
n <- 50
x <- rnorm(n)
y <- exp(x) + rnorm(n, sd = 0.5)
plot(x, y, type = "p")
```


- ¿Existe relación entre las variables? ¿Es lineal?
- ¿Es linealizable? Si es así, ajusta la recta de regresión a los datos linealizados.
- ¿Hay algún dato atípico?
- De los tres valores siguientes: 0.01, 0.80 y -0.73 , ¿cuál crees que podría corresponder al coeficiente de correlación entre x e y ?

Solución.

- Sí existe relación entre las variables, puesto que la y se calcula a partir de x . Sin embargo, no es lineal, sino exponencial.

Definición 6.1.1. Sean X e Y dos variables aleatorias. Se dice que la relación entre X e Y es linealizable $\iff \exists g, h : \mathbb{R} \rightarrow \mathbb{R}$ tales que $h(Y) \approx g(X)$.

- Como la relación es exponencial, podemos linealizarla con el logaritmo: $\ln(y) \approx x$.



- (c) Sí, las x que se alejan de la recta de regresión, son los datos atípicos de una distribución normal estándar.
- (d) El coeficiente de correlación entre x e y es 0.80 porque la relación es exponencial y como vemos en el gráfico, tras linealizarla, la nube de puntos se ajusta bastante bien a una recta con pendiente positiva.


9. El fichero olive contiene el porcentaje de ácido palmítico (palmitic) y palmitoleico (palmitoleic) en la fracción lipídica de 323 aceitunas procedentes de varias zonas del sur de Italia. Se han realizado con  los siguientes análisis sobre estos datos:

```
mean(olive$palmitoleic)
1.548019
var(olive$palmitic)
2.338908
var(olive$palmitoleic)
0.2572892
lm(palmitic ~ palmitoleic, data = olive)
```

Coefficients:

```
(Intercept) palmitoleic
9.437      2.510
```

A continuación se representa la función de distribución empírica correspondiente al porcentaje de ácido palmítico y el diagrama de cajas correspondiente al ácido palmitoleico:



A partir de los resultados anteriores contesta razonadamente a las siguientes preguntas:

- a) Determina si las siguientes afirmaciones son verdaderas o falsas:
- El rango intercuartílico de los porcentajes de ácido palmítico está entre 12 y 15.
 - Más del 25% de los datos presentan un porcentaje de ácido palmitoleico < 1 .
 - El percentil 75 de los porcentajes de ácido palmítico es mayor que el percentil 75 de los porcentajes de ácido palmitoleico.
- b) Aproxima el valor del porcentaje de ácido palmítico para una aceituna cuyo porcentaje de ácido palmitoleico es del 1%.
- c) Calcula el coeficiente de correlación entre ambas variables e interpreta el resultado.
- d) Si la función de distribución de una v.a. X es la distribución empírica correspondiente al porcentaje de ácido palmítico, ¿cuáles son la esperanza y la varianza de X ?

Solución.

- a) i. Es **falso** porque el rango intercuartílico es la diferencia entre el tercer y el primer cuartil, y en la gráfica vemos que $Q_1 > 12 \wedge Q_3 < 15 \implies$ el rango intercuartílico es menor que 3.
- ii. Es **falso** porque en la gráfica vemos que $Q_1 > 1$.
- iii. Es **verdadero** porque se ve en la gráfica.
- b) Por la regresión lineal, el porcentaje de ácido palmítico $\approx 9.437 + 2.510 \cdot 1 = 11.947$.
- c) Se tiene que $r = \hat{b}_{\frac{s_x}{s_y}} = 2.510 \cdot \frac{\sqrt{0.2572892}}{\sqrt{2.338908}} \approx 0.8325$ lo que indica una correlación fuerte.
- d) La esperanza sería la media muestral y la varianza sería la varianza muestral (0.2572892). Podemos calcular la media muestral con la regresión lineal:

$$\bar{y} = 9.437 + 2.510 \cdot \bar{x} = 9.437 + 2.510 \cdot 1.548019 \approx 13.32.$$

10. Disponemos de un conjunto de observaciones $x_1, \dots, x_{100}$, ya ordenadas de menor a mayor, cuya media muestral es $\bar{x}$. Creamos una nueva muestra añadiendo a la anterior los valores x_1 y x_{100} . ¿Qué condición se debe cumplir para que la media muestral de la nueva muestra coincida con $\bar{x}$, la media muestral de la muestra original?

Solución. Igualamos y despejamos:

$$\bar{x} = \frac{1}{100} \sum_{i=1}^{100} x_i = \frac{1}{102} \left(x_1 + x_{100} + \sum_{i=1}^{100} x_i \right) = \frac{1}{102} (x_1 + x_{100} + 100\bar{x}) \iff \bar{x} = \frac{x_1 + x_{100}}{2}$$

Es decir, la media de la nueva muestra debe ser la media de los dos valores extremos.

11. Sea $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ una muestra de datos bivariantes, con media muestral $(\bar{x}, \bar{y})$. Añadimos a la muestra el punto $(\bar{x}, \bar{y})$. Determina si la covarianza de la nueva muestra es mayor, menor o igual que la de la muestra original.

Solución. Sea $s_{X,Y}$ la covarianza de la muestra y $s'_{X,Y}$ la covarianza de la nueva muestra.

$$\Rightarrow s'_{X,Y} = \frac{1}{n} \left(\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) + (\bar{x} - \bar{x})(\bar{y} - \bar{y}) \right) = s_{X,Y} + 0 = s_{X,Y}$$

12. Tenemos una muestra $x_1, \dots, x_n$ cuya media es $\bar{x}$ y cuya varianza muestral es s_n^2 . Duplicamos ahora el tamaño muestral añadiendo los valores de signo opuesto a los originales:

$$x_1, \dots, x_n, -x_1, \dots, -x_n$$

Llamamos $\tilde{s}_n^2$ a la varianza muestral de esta segunda muestra. ¿Cuál es mayor, s_n^2 o $\tilde{s}_n^2$?

Solución. Calculemos primero la nueva media: $\tilde{\bar{x}} = \frac{1}{2n} \left(\sum_{i=1}^n x_i + \sum_{i=1}^n -x_i \right) = 0$.

$$\Rightarrow \tilde{s}_n^2 = \frac{1}{2n} \left(\sum_{i=1}^n (x_i - 0)^2 + \sum_{i=1}^n (-x_i - 0)^2 \right) = \frac{1}{2n} \left(\sum_{i=1}^n x_i^2 + \sum_{i=1}^n x_i^2 \right) = s_n^2 + \bar{x}^2$$

Por tanto, $\tilde{s}_n^2 \geq s_n^2$ con igualdad $\iff \bar{x} = 0$.

13. El fichero star.txt contiene la temperatura y la intensidad de la luz en un conjunto de estrellas. Calcula y representa la recta de mínimos cuadrados para explicar la temperatura en función de la intensidad de la luz. Comenta el resultado.

14. Sea $\hat{f}_n$ un estimador núcleo, con parámetro de suavizado h_n , construido a partir de una muestra $x_1, \dots, x_n$. Definimos una nueva variable X^0 como $X^0 = X^* + h_n Z$, donde X^* es la variable que toma los valores $x_1, \dots, x_n$ con probabilidad $1/n$ cada uno de ellos, y Z es una variable con distribución $N(0, 1)$. Demuestra que X^0 es una v.a. con distribución absolutamente continua (es decir, tiene una función de densidad) y que la correspondiente densidad es $\hat{f}_n$, con núcleo K normal estándar ($N(0, 1)$).

Indicación: Calcula las distribuciones condicionadas de $X^0 \mid X^* = x_i$ y utiliza la fórmula de las probabilidades totales.

Solución.

$$\hat{f}_n(x) = \frac{1}{nh_n} \sum_{i=1}^n K \left(\frac{x - x_i}{h_n} \right)$$

$X^0 = X^* + h_n Z$ con $Z \sim N(0, 1)$ y X^* uniforme en $\{x_1, \dots, x_n\}$.

$$\begin{aligned} \implies F_{X^0}(x) &= \mathbb{P}(X^0 \leq x) = \mathbb{P}(X^* + h_n Z \leq x) = \mathbb{E}(\mathbb{1}_{\{X^* + h_n Z \leq x\}}) \\ &= \mathbb{E}_{X^*}(\mathbb{E}(\mathbb{1}_{\{X^* + h_n Z \leq x\}} \mid X^*)) \text{ por la ley de las esperanzas condicionadas.} \end{aligned}$$

$$\begin{aligned} \mathbb{E}(\mathbb{1}_{X^* + h_n Z \leq x} \mid X^*) &= \mathbb{P}\{X^* + h_n Z \leq x \mid X^*\} = \mathbb{P}\left\{Z \leq \frac{x - X^*}{h_n} \mid X^*\right\} = \Phi\left(\frac{x - X^*}{h_n}\right) \\ \implies F_{X^0}(x) &= \mathbb{E}_{X^*}\left(\Phi\left(\frac{x - X^*}{h_n}\right)\right) = \sum_{i=1}^n \Phi\left(\frac{x - x_i}{h_n}\right) \mathbb{P}(X^* = x_i) = \frac{1}{n} \sum_{i=1}^n \Phi\left(\frac{x - x_i}{h_n}\right) \end{aligned}$$

Ahora calculamos la densidad $f_{X^0}(x)$ derivando $F_{X^0}(x)$:

$$f_{X^0}(t) = F'_{X^0}(t) = \frac{1}{nh_n} \sum_{i=1}^n K\left(\frac{x - x_i}{h_n}\right) = \hat{f}_n(x)$$

donde K es el núcleo de una normal estándar y h_n es el parámetro de suavizado. ■

Conclusión: Para generar una observación de $\hat{f}_n$, genero una X^* aleatoriamente de $\{x_1, \dots, x_n\}$ y luego le sumo una pequeña “perturbación” $h_n Z \sim N(0, h_n)$.

6.2 Hoja 2: Muestreo aleatorio

En esta hoja todos los estadísticos están basados en una muestra $X_1, \dots, X_n$ de v.a.i.i.d. con $\mathbb{E}(X_i) = \mu$ y $\mathbb{V}(X_i) = \sigma^2$ (estas dos cantidades se supondrán finitas cuando aparezcan en los enunciados). La función de distribución de las X_i se denota por F y la de densidad por f . $\mathbb{F}_n$ denota la función de distribución empírica. El símbolo $\longrightarrow$ denota $\xrightarrow{n \rightarrow \infty}$.

[1.] Se desea estimar el momento de orden 3, $\alpha_3 = \mathbb{E}(X^3)$, en una v.a. X con distribución exponencial de parámetro λ , es decir, la función de distribución de X es $F(t) = \mathbb{P}(X \leq t) = 1 - e^{-\lambda t}$, para $t \geq 0$. Definir un estimador natural para α_3 y calcular su error cuadrático medio. **Indicación:** Si $X \sim \exp(\lambda)$, entonces $\mathbb{E}(X^n) = \frac{n!}{\lambda^n}$ para todo entero positivo n .

Solución. Tenemos que $\alpha_3 = \mathbb{E}(X^3) = \int_{\mathbb{R}} x^3 dF(x) = \int_0^\infty x^3 f(x) dx$. Como $X \sim \exp(\lambda)$, tenemos que $F(x) = 1 - e^{-\lambda x}$ y $f(x) = \lambda e^{-\lambda x} \implies \forall n \in \mathbb{N} : \mathbb{E}(X^n) = \frac{n!}{\lambda^n}$.

Un estimador natural de α_3 es el *plug-in* que se obtiene de sustituir la distribución de probabilidad dada por F por la distribución empírica $\mathbb{F}_n$ asociada a la muestra.

$$\implies \hat{\alpha}_3 = \int_{\mathbb{R}} x^3 d\mathbb{F}_n(x) = \frac{1}{n} \sum_{i=1}^n X_i^3$$

Si definimos $Y_i = X_i^3$, entonces $\hat{\alpha}_3 = \bar{Y}$, donde $\bar{Y}$ es la media muestral de $Y_1, \dots, Y_n$.

Definición 6.2.1. Sea X una v.a. y $X_1, \dots, X_n$ una muestra aleatoria de X . Sea θ un “parámetro” de la población y sea $\hat{\theta}$ un estimador de θ . El error cuadrático medio (ECM) de $\hat{\theta}$ es

$$\begin{aligned} \text{ECM}(\hat{\theta}) &= \mathbb{E} \left[(\hat{\theta} - \theta)^2 \right] = \mathbb{E} \left[(\hat{\theta} - \mathbb{E}(\hat{\theta}) + \mathbb{E}(\hat{\theta}) - \theta)^2 \right] \\ &= \mathbb{E} \left[(\hat{\theta} - \mathbb{E}(\hat{\theta}))^2 \right] + \mathbb{E} \left[(\mathbb{E}(\hat{\theta}) - \theta)^2 \right] + 2\mathbb{E} \left[(\hat{\theta} - \mathbb{E}(\hat{\theta})) (\mathbb{E}(\hat{\theta}) - \theta) \right] \\ &= \mathbb{E} \left[(\hat{\theta} - \mathbb{E}(\hat{\theta}))^2 \right] + (\mathbb{E}(\hat{\theta}) - \theta)^2 + 2(\mathbb{E}(\hat{\theta}) - \theta) \underbrace{\mathbb{E}(\hat{\theta} - \mathbb{E}(\hat{\theta}))}_0 \\ &= \mathbb{E} \left[(\hat{\theta} - \mathbb{E}(\hat{\theta}))^2 \right] + \text{Sesgo}^2(\hat{\theta}) = \mathbb{V}(\hat{\theta}) + \text{Sesgo}^2(\hat{\theta}) \end{aligned}$$

Por tanto, $\text{ECM}(\hat{\alpha}_3) = \mathbb{V}(\hat{\alpha}_3) + \text{Sesgo}^2(\hat{\alpha}_3)$. Calculamos cada uno de los términos:

$$\begin{aligned} \text{Sesgo}(\hat{\alpha}_3) &= \mathbb{E}(\hat{\alpha}_3) - \alpha_3 = \mathbb{E}(\bar{Y}) - \mathbb{E}(Y) = 0 \text{ por ser } \bar{Y} \text{ insesgado} \\ \mathbb{V}(\hat{\alpha}_3) &= \mathbb{V}(\bar{Y}) = \frac{\mathbb{V}(Y)}{n} = \frac{\mathbb{E}(X^6) - \mathbb{E}^2(X^3)}{n} \\ \implies \text{ECM}(\hat{\alpha}_3) &= \frac{\mathbb{E}(X^6) - \mathbb{E}^2(X^3)}{n} = \frac{1}{n} \left(\frac{6!}{\lambda^6} - \frac{3!}{\lambda^3} \right) \xrightarrow{n \rightarrow \infty} 0 \end{aligned}$$

[2.] Supongamos que la muestra tiene tamaño $n = 50$ y que la distribución de las X_i es una $N(4, 1)$ (i.e., normal con media $\mu = 4$ y desviación típica $\sigma = 1$).

- (a) Obtener, utilizando la desigualdad de Chebichev, una cota superior para la probabilidad $\mathbb{P}\{|\bar{X} - 4| > 0.3\}$. Al utilizar la desigualdad de Chebichev no estamos usando el hecho de que la distribución de las observaciones es normal: es una desigualdad universal y proporciona una cota (no necesariamente muy ajustada) para $\mathbb{P}\{|\bar{X} - 4| > 0.3\}$, que solo depende de n y de σ .
- (b) Calcula exactamente la probabilidad $\mathbb{P}\{|\bar{X} - 4| > 0.3\}$ utilizando el hecho de que las X_i tienen distribución $N(4, 1)$. Comparar el resultado con la cota obtenida en (a).

Solución.


- (a) La desigualdad de Chebychev nos dice que si X es una v.a. con $\mathbb{E}(X) = \mu$ y $\mathbb{V}(X) = \sigma^2$ finitas, entonces $\mathbb{P}(|X - \mu| \geq k) \leq \frac{\sigma^2}{k^2}$. En este caso, como $\forall i : X_i \sim N(4, 1)$, tenemos que $\bar{X} \sim N(4, 1/\sqrt{50})$. Por tanto,

$$\mathbb{P}(|\bar{X} - 4| > 0.3) \leq \frac{1}{0.3^2 \cdot 50} = \frac{2}{9} \approx 0.22$$

- (b) Calculamos la probabilidad exacta:

$$\begin{aligned} \mathbb{P}(|\bar{X} - 4| > 0.3) &= \mathbb{P}(\bar{X} - 4 > 0.3) + \mathbb{P}(\bar{X} - 4 < -0.3) = 2\mathbb{P}(\bar{X} - 4 > 0.3) \\ &= 2\mathbb{P}\left(\frac{\bar{X} - 4}{1/\sqrt{50}} > \frac{0.3}{1/\sqrt{50}}\right) = 2\mathbb{P}(Z > 2.12) = 2(1 - \mathbb{P}(Z \leq 2.12)) \\ &= 2(1 - \Phi(2.12)) \approx 2(1 - 0.9830) = 0.034 \end{aligned}$$

3. Sea $X_1, \dots, X_n$ una muestra de una v.a. X con distribución de probabilidad Bernoulli($p = 0.4$). Acotamos la probabilidad de que la media muestral sea mayor que $1.1p$ mediante la desigualdad de Markov y mediante la desigualdad de Chebychev. Dibujamos las cotas obtenidas en función de n (el eje de ordenadas aparece en escala logarítmica). Razonar cuál de los dos gráficos corresponde a cada una de las desigualdades.



Solución. La desigualdad de Markov indica que $X \geq 0 \implies \mathbb{P}(X \geq a) \leq \frac{\mathbb{E}(X)}{a}$.

En este caso, $X_i \sim \text{Bernoulli}(p) \implies \bar{X}$ toma valores en $\{0/n, \dots, n/n\}$ con distribución:

$$\forall i \in \{0, \dots, n\} : \mathbb{P}(\bar{X} = i/n) = \binom{n}{i} p^i (1-p)^{n-i} \implies \mathbb{E}(\bar{X}) = p \wedge \mathbb{V}(\bar{X}) = \frac{p(1-p)}{n}$$

(a) Desigualdad de Markov: $\mathbb{P}(\bar{X} > 1.1p) \leq \frac{p}{1.1p} = \frac{10}{11} \approx 0.91$.

(b) Desigualdad de Chebychev:

$$\begin{aligned} \mathbb{P}(\bar{X} > 1.1p) &= \mathbb{P}(|\bar{X} - p| > 0.1p) - \mathbb{P}(\bar{X} - p < -0.1p) \\ &\leq \mathbb{P}(|\bar{X} - p| > 0.1p) \leq \frac{\mathbb{V}(\bar{X})}{(0.1p)^2} = \frac{p(1-p)}{n0.01p^2} = 100 \frac{1-p}{np} \end{aligned}$$

Por tanto, el gráfico que se curva hacia abajo corresponde a la desigualdad de Chebychev y el que es constante a la de Markov.

4. Dada una muestra de v.a.i.i.d. de tamaño 100 de una distribución normal de media

μ y desviación típica 1.5, determina aproximadamente la probabilidad de que la mediana muestral difiera de μ en menos que 0.1. ¿De qué tamaño habría que elegir la muestra para poder afirmar que con probabilidad 0.9, la mediana muestral difiere de μ en menos que 0.01? Resuelve el problema sustituyendo la mediana por la media y compara los resultados obtenidos.

Solución.

- (a) Sean $X_1, \dots, X_{100}$ muestra de $X \sim N(\mu, 1.5^2)$. La mediana muestral es $\mathbb{F}_{100}^{-1}(1/2)$ donde $\mathbb{F}$ es la función cuantílica.

$$\mathbb{P}\{|\mathbb{F}_{100}^{-1}(1/2) - \mu| < 0.1\} = \mathbb{P}\left\{-1 < \sqrt{100}(\mathbb{F}_{100}^{-1}(1/2) - F^{-1}(1/2)) < 1\right\}$$

Ahora aplicamos la distribución asintótica de la función cuantílica empírica:

$$\sqrt{n}(\mathbb{F}_n^{-1}(1/2) - F^{-1}(1/2)) \xrightarrow[n \rightarrow \infty]{d} N\left(0, \frac{1}{2f(\mu)}\right)$$

En este caso, consideramos que $n = 100$ es suficientemente grande para que la aproximación por la normal sea válida. Por tanto,

$$\begin{aligned} 2f(\mu)\sqrt{100}(\mathbb{F}_{100}^{-1}(1/2) - F^{-1}(1/2)) &\stackrel{\text{approx}}{\sim} N(0, 1) \sim Z \\ \implies \mathbb{P}\{-2f(\mu) < Z < 2f(\mu)\} &\approx 1 - \mathbb{P}\{Z > 0.53\} = 0.4052 \end{aligned}$$

- (b) Ahora la pregunta es cuánto vale n para que $\mathbb{P}\{|\mathbb{F}_n^{-1}(1/2) - F^{-1}(1/2)| < 0.01\} = 0.9$.

$$\begin{aligned} 0.9 &= \mathbb{P}\{-2f(\mu)\sqrt{n}0.01 < \sqrt{n}(\mathbb{F}_n^{-1}(1/2) - F^{-1}(1/2)) < 2f(\mu)\sqrt{n}0.01\} \\ &\approx \mathbb{P}\{-0.0053\sqrt{n} < Z < 0.0053\sqrt{n}\} = 1 - 2\mathbb{P}\{Z > 0.0053\sqrt{n}\} \\ \implies \mathbb{P}\{Z > 0.0053\sqrt{n}\} &= 0.05 \implies \boxed{n \approx 96335} \end{aligned}$$

Ahora la media:

- (a) Vamos a utilizar que $\bar{X} \sim N(\mu, \sigma/\sqrt{n}) \implies Z = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim N(0, 1)$.
- $$\implies \mathbb{P}\{|\bar{X} - \mu| < 0.1\} = \mathbb{P}\left\{-\frac{0.1\sqrt{n}}{1.5} < Z < \frac{0.1\sqrt{n}}{1.5}\right\} = 1 - 2\mathbb{P}\{Z \geq 0.67\} = 0.4972$$

- (b) Sale $n \geq 60282$.

[5.] (a) Sea $C_n = \int_{\mathbb{R}} (\mathbb{F}_n(t) - F(t))^2 dF(t)$ la discrepancia de Cramer-Von Mises entre $\mathbb{F}_n$ y F . ¿Se verifica que $C_n \xrightarrow{\text{c.s.}} 0$?

- (b) Calcular la distribución asintótica de la sucesión $D_n = \sqrt{n}(\mathbb{F}_n(t) - F(t))$, para un valor fijo $t \in \mathbb{R}$.

Solución.

(a) Sabemos que $\|\mathbb{F}_n - F\|_\infty = \max_{x \in \mathbb{R}} |\mathbb{F}_n(x) - F(x)| \xrightarrow[n \rightarrow \infty]{\text{c.s.}} 0$.

$$\begin{aligned} \Rightarrow \int_{\mathbb{R}} (\mathbb{F}_n(t) - F(t))^2 dF(t) &\leq \int_{\mathbb{R}} \left(\max_{x \in \mathbb{R}} |\mathbb{F}_n(x) - F(x)| \right)^2 dF(t) \\ &\leq \left(\max_{x \in \mathbb{R}} |\mathbb{F}_n(x) - F(x)| \right)^2 \int_{\mathbb{R}} f(t) dt \xrightarrow[n \rightarrow \infty]{\text{c.s.}} 0 \end{aligned}$$

(b) Sabemos que $\forall t \in \mathbb{R} : \mathbb{E}(\mathbb{F}_n(t)) = F(t)$. Entonces, por el teorema central del límite, $\sqrt{n}(\mathbb{F}_n(t) - F(t)) \xrightarrow[n \rightarrow \infty]{d} N(0, \mathbb{V}(\mathbb{F}_n(t)))$. Calculemos $\mathbb{V}(\mathbb{F}_n(t))$:

$$\begin{aligned} \mathbb{V}(\mathbb{F}_n(t)) &= \mathbb{E}(\mathbb{F}_n(t)^2) - \mathbb{E}^2(\mathbb{F}_n(t)) = \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n \mathbb{1}_{X_i \leq t}\right)^2 - F(t)^2 \\ &= \frac{1}{n} \sum_{i=1}^n \mathbb{P}(X \leq t) - F(t)^2 = \frac{1}{n} n F(t) - F(t)^2 = F(t) - F(t)^2 \end{aligned}$$

La distribución asintótica de D_n es $\int_{-\infty}^x \frac{1}{\sqrt{F(t) - F(t)^2} \sqrt{2\pi}} e^{\frac{-s^2}{2(F(t) - F(t)^2)}} ds$.

[6.] Sea X una v.a. con distribución de Cauchy $(\theta, a = 1)$, cuya función de densidad

$$f(x; \theta) = \frac{1}{\pi} \frac{1}{1 + (x - \theta)^2}, \quad x \in \mathbb{R}$$

depende del parámetro desconocido $\theta \in \mathbb{R}$. Comprobar que θ coincide con la mediana y la moda de X pero que la media $\mathbb{E}(X)$ no está definida.

Diseñar un experimento de simulación en , tomando algún valor concreto de θ , orientado a comprobar cómo se comportan la mediana muestral y la media muestral como estimadores de θ : mientras la mediana muestral se acerca al verdadero valor de θ al aumentar n , la media muestral oscila fuertemente y no se acerca a θ aunque se aumente el tamaño muestral n .

[7.] Se extrae una muestra aleatoria de tamaño $n = 600$ de una v.a. cuya desviación típica es $\sigma = 3$. Calcular aproximadamente la probabilidad $\mathbb{P}\{|\bar{X} - \mu| < 0.1\}$. ¿De qué tamaño habría que tomar la muestra para afirmar que, con probabilidad 0.9, la media muestral difiere de μ en menos de 0.1?

Solución.

(a) Suponemos que $n = 600$ es suficientemente grande para que la aproximación por la normal sea válida. Sabemos que $\mathbb{E}(\bar{X}) = \mathbb{E}(X)$ y $\mathbb{V}(\bar{X}) = \frac{\mathbb{V}(X)}{n}$. Por el teorema

central del límite $\sqrt{n}(\bar{X} - \mathbb{E}(X)) \xrightarrow[n \rightarrow \infty]{d} N\left(0, \frac{\mathbb{V}(X)}{n}\right)$.

$$\begin{aligned} \implies \mathbb{P}\{|\bar{X} - \mu| < 0.1\} &\approx 1 - 2\mathbb{P}\left(\frac{\bar{X} - \mu}{3/\sqrt{600}} \geq \frac{0.1}{3/\sqrt{600}}\right) \\ &= 1 - 2\Phi(0.8164) \approx 1 - 2 \cdot 0.2090 = 0.582 \end{aligned}$$

(b) Tenemos que $\mathbb{P}(|\bar{X} - \mu| < 0.1) = 0.9$.

$$\begin{aligned} 0.9 &\approx 1 - 2\mathbb{P}\left(\frac{\bar{X} - \mu}{3/\sqrt{n}} < \frac{0.1}{3/\sqrt{n}}\right) = 1 - 2\Phi\left(\frac{\sqrt{n}}{30}\right) \\ \iff \Phi\left(\frac{\sqrt{n}}{30}\right) &\approx 0.05 \iff \frac{\sqrt{n}}{30} \approx 1.65 \iff n \approx 2450 \end{aligned}$$

[8.] Sea $\hat{f}_n$ un estimador kernel de la densidad basado en un núcleo K que es una función de densidad con media finita. Comprobar que, en general, $\hat{f}_n(t)$ es un estimador sesgado de $f(t)$ en el sentido de que NO se tiene $\mathbb{E}(\hat{f}_n(t)) = f(t)$, para todo t y para toda densidad f .

Solución. Tenemos que $\int_{\mathbb{R}} K(t) dt = 1 \wedge \int_{\mathbb{R}} tK(t) dt < \infty$. Calculamos $\mathbb{E}(\hat{f}_n(t))$:

$$\begin{aligned} \mathbb{E}(\hat{f}_n(t)) &= \mathbb{E}\left(\frac{1}{nh_n} \sum_{i=1}^n K\left(\frac{t - X_i}{h_n}\right)\right) = \frac{1}{nh_n} \sum_{i=1}^n \mathbb{E}\left(K\left(\frac{t - X_i}{h_n}\right)\right) \\ &= \frac{1}{h_n} \mathbb{E}_X\left(K\left(\frac{t - X}{h_n}\right)\right) = \frac{1}{h_n} \int_{\mathbb{R}} K\left(\frac{t - x}{h_n}\right) f(x) dx \end{aligned}$$

Mediante el cambio de variables $u = \frac{t-x}{h_n} \implies x = t - h_n u$ y $dx = -h_n du$, obtenemos:

$$\mathbb{E}(\hat{f}_n(t)) = \int_{\mathbb{R}} K(u) f(t - h_n u) du$$

Ahora, calculamos el sesgo: $\text{Sesgo}(\hat{f}_n(t)) = \int_{\mathbb{R}} K(u) f(t - h_n u) du - \int_{\mathbb{R}} K(u) f(t) du$.

Suponemos que f es derivable tantas veces como necesitemos:

$$f(t - h_n u) - f(t) = f'(t)(-h_n u) + \frac{1}{2}f''(t)(-h_n u)^2 + \frac{1}{6}f'''(t)(-h_n u)^3 + \dots$$

Ahora suponemos que K es par:

$$\implies \text{Sesgo}(\hat{f}_n(t)) = -h_n f'(t) \int_{\mathbb{R}} u K(u) du + \frac{1}{2} h_n^2 f''(t) \int_{\mathbb{R}} u^2 K(u) du + \dots \approx \frac{1}{2} h_n^2 f''(t)$$

[9.] Sea $\mathbb{F}_n$ la función de distribución empírica correspondiente a la muestra X_1, X_2, X_3, X_4 .

(a) Si se observa $x_1 = 1, x_2 = 3, x_3 = 5$ y $x_4 = 7$, determina el valor de $\mathbb{F}_4^{-1}(1/2)$.

(b) Si se observa $x_1 = 1, x_2 = 3, x_3 = 5$ y $x_4 = 7$ y X^* es una variable aleatoria con

distribución $\mathbb{F}_4$, calcula el valor esperado de X^* (condicionado a la muestra).

- (c) Si X_1, X_2, X_3 y X_4 son i.i.d con distribución uniforme en el conjunto $\{1, 2, 3, \dots, 10\}$, ¿cuál es la distribución de la variable aleatoria $4\mathbb{F}_4(5)$?

Solución.

(a) $\mathbb{F}_4^{-1}(1/2) = \inf_{x \in \mathbb{R}} \{x : \mathbb{F}_4(x) \geq 1/2\} = 3.$

(b) $\mathbb{E}(X^* | X_i = x_i) = \frac{1}{4} \sum_{i=1}^4 x_i = \frac{1+3+5+7}{4} = 4.$

(c) $\mathbb{F}_4(5) = \frac{1}{4} \sum_{i=1}^4 \mathbb{1}_{\{X_i \leq 5\}}.$ Tenemos que $\forall i \in \mathbb{N}_4 : \mathbb{1}_{\{X_i \leq 5\}} \sim \text{Bernoulli}(p = F(5) = 1/2).$

$$\implies 4\mathbb{F}_4(5) = \frac{1}{4} \sum_{i=1}^4 \mathbb{1}_{\{X_i \leq 5\}} = \sum_{i=1}^4 \mathbb{1}_{\{X_i \leq 5\}} \sim \text{Binomial}(n = 4, p = 1/2)$$

6.3 Hoja 3: Estimación Puntual

En los ejercicios que siguen (a menos que se indique lo contrario) los estimadores están basados en una muestra $X_1, \dots, X_n$ de v.a.i.i.d. con las distribuciones indicadas. La abreviatura e.m.v. indicará “estimador de máxima verosimilitud”.

1. Sea X una variable aleatoria con distribución de Pareto dada por la función de densidad:

$$f(x; \theta) = \theta x_0^\theta x^{-\theta-1}, \quad x \geq x_0, \quad \theta > 1,$$

donde x_0 se supone que es un valor conocido. Sea $X_1, \dots, X_n$ una muestra de X .

- (a) Calcula la cantidad de información de Fisher.
- (b) Calcula el estimador de θ por el método de los momentos.
- (c) Determina el estimador de máxima verosimilitud de θ , estudia su consistencia y determina completamente su distribución asintótica.

Solución.

- (a) La información de Fisher viene dada por la fórmula:

$$\begin{aligned} I(\theta) &= \mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \log f(X; \theta) \right)^2 \right] = \mathbb{E} \left[-\frac{\partial^2}{\partial \theta^2} \log f(X; \theta) \right] = \\ \frac{\partial}{\partial \theta} \log f(X; \theta) &= \frac{\partial}{\partial \theta} (\log \theta + \theta \log x_0 - (\theta + 1) \log x) = \frac{1}{\theta} + \log x_0 - \log x. \\ \implies \frac{\partial^2}{\partial \theta^2} \log f(X; \theta) &= -\frac{1}{\theta^2} \implies \overline{I(\theta)} = \mathbb{E} \left[\frac{1}{\theta^2} \right] = \frac{1}{\theta^2}. \end{aligned}$$

- (b) Dado que el parámetro θ es unidimensional basta resolver la ecuación $m_1 = \alpha_1(\theta)$ para θ donde $m_1 = \bar{X}$ es el primer momento muestral y $\alpha_1(\theta) = \mathbb{E}(X)$.

$$\begin{aligned} \mathbb{E}(X) &= \int_{\mathbb{R}} x \cdot f(x; \theta) dx = \int_{x_0}^{\infty} x \cdot \theta x_0^\theta x^{-\theta-1} dx = \theta x_0^\theta \int_{x_0}^{\infty} x^{-\theta} dx \\ &= \theta x_0^\theta \left[\frac{x^{-\theta+1}}{-\theta+1} \right]_{x_0}^{\infty} = \theta x_0^\theta \left[0 + \frac{x_0^{-\theta+1}}{\theta-1} \right] = \frac{\theta x_0}{\theta-1} \implies \theta = \frac{\bar{X}}{\bar{X} - x_0}. \end{aligned}$$

- (c) La función de verosimilitud es $L_n(\theta) = \prod_{i=1}^n f(x_i; \theta) = \theta^n x_0^{n\theta} \prod_{i=1}^n x_i^{-\theta-1}$.

$$\implies \log L_n(\theta) = n \log \theta + n\theta \log x_0 - (\theta + 1) \sum_{i=1}^n \log x_i \text{ es la log-verosimilitud.}$$

$$\implies \frac{\partial}{\partial \theta} \log L_n(\theta) = \frac{n}{\theta} + n \log x_0 - \sum_{i=1}^n \log x_i = 0 \iff \theta = \frac{n}{\sum_{i=1}^n (\log x_i - \log x_0)}.$$

Entonces, el e.m.v. de θ es $\hat{\theta}_n = \frac{n}{\sum_{i=1}^n (\log x_i - \log x_0)}$.

i. **Consistencia:** Definimos las variables aleatorias iid $\forall i \in \mathbb{N}_i : Y_i = \log X_i - \log x_0$, entonces $\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i = \frac{1}{n} \sum_{i=1}^n \log X_i - \log x_0$. Por la ley fuerte de los grandes números, $\bar{Y} \xrightarrow[n \rightarrow \infty]{\text{c.s.}} \mathbb{E}(Y) = \mathbb{E}(\log X - \log x_0) = \mathbb{E}(\log X) - \log x_0$.

$$\mathbb{E}(\log X) \int_{\mathbb{R}} \log(x) \cdot f(x; \theta) dx = \int_{x_0}^{\infty} \log(x) \cdot \theta x_0^{\theta} x^{-\theta-1} dx = \theta x_0^{\theta} \int_{x_0}^{\infty} \log(x) \cdot x^{-\theta} dx.$$

Integrando por partes, se tiene que

$$\begin{aligned} \mathbb{E}(\log X) &= \theta x_0^{\theta} \left(-\frac{x^{-\theta} \log x}{\theta} \Big|_{x=x_0}^{\infty} + \int_{x_0}^{\infty} \frac{x^{-\theta-1}}{\theta} dx \right) = x_0^{\theta} \left(\frac{\log x_0}{x_0^{\theta}} + \frac{x^{-\theta}}{-\theta} \Big|_{x_0}^{\infty} \right) \\ &= x_0^{\theta} \left(\frac{\log x_0}{x_0^{\theta}} + \frac{1}{\theta x_0^{\theta}} \right) = \log x_0 + \frac{1}{\theta} \implies \mathbb{E}(\bar{Y}) = \frac{1}{\theta} \end{aligned}$$

Ahora bien, como $\hat{\theta} = \frac{1}{\bar{Y}}$ y $\bar{Y} \xrightarrow[n \rightarrow \infty]{\text{c.s.}} \mathbb{E}(\bar{Y}) = \frac{1}{\theta}$, entonces por el teorema de la aplicación continua, $\hat{\theta} \xrightarrow[n \rightarrow \infty]{\text{c.s.}} \theta$.

ii. **Distribución asintótica:** Dado que tenemos una v.a. Y y $g: \mathbb{R} \rightarrow \mathbb{R}$ dada por $g(x) = 1/x$ continua y derivable con derivada continua en un entorno de $\mathbb{E}(Y)$, podemos aplicar el método delta y tenemos que

$$\sqrt{n} (g(\bar{Y}) - g(\mathbb{E}(Y))) \xrightarrow[n \rightarrow \infty]{d} N(0, |g'(\mathbb{E}(Y))| \cdot \sqrt{\mathbb{V}(Y)})$$

Como $\mathbb{V}(Y) = \mathbb{E}(Y^2) - \mathbb{E}(Y)^2 = 1/\theta^2$ y $g'(\mathbb{E}(Y)) = -\theta^2$, entonces

$$\sqrt{n} (\hat{\theta} - \theta) \xrightarrow[n \rightarrow \infty]{d} N(0, \theta).$$

[2.] Supongamos que el error X cometido en la medición de una magnitud es una v.a. con distribución normal de media 0 y varianza θ . La función de densidad de X es

$$f(x; \theta) = \frac{1}{\sqrt{\theta} \sqrt{2\pi}} \exp\left(-\frac{x^2}{2\theta}\right), \quad x \in \mathbb{R}.$$

Se desea estimar θ a partir de una muestra $X_1, \dots, X_n$ de X .

- (a) Calcula el estimador de máxima verosimilitud, T_n .
- (b) Prueba que T_n es insesgado y eficiente.
- (c) Estudia la distribución asintótica de T_n .

Indicacion: $E_\theta(X^4) = 3\theta^2$.

Solución.

$$\begin{aligned}
 \text{(a) Tenemos que } L_n(\theta) &= \prod_{i=1}^n \frac{1}{\sqrt{\theta}\sqrt{2\pi}} \exp\left(-\frac{x_i^2}{2\theta}\right) = \frac{1}{(\sqrt{\theta}\sqrt{2\pi})^n} \exp\left(-\frac{1}{2\theta} \sum_{i=1}^n x_i^2\right). \\
 \implies \log(L_n(\theta)) &= -\frac{n}{2} \log(\theta) - \frac{n}{2} \log(2\pi) - \frac{1}{2\theta} \sum_{i=1}^n x_i^2 \\
 \implies \frac{d}{d\theta} \log(L_n(\theta)) &= -\frac{n}{2\theta} + \frac{1}{2\theta^2} \sum_{i=1}^n x_i^2 = 0 \iff \theta = \frac{1}{n} \sum_{i=1}^n x_i^2.
 \end{aligned}$$

Es decir, el e.m.v. de θ es $\hat{\theta}_n = \frac{1}{n} \sum_{i=1}^n x_i^2$, el segundo momento muestral.

(b) El sesgo de $\hat{\theta}_n$ es $\mathbb{E}(\hat{\theta}_n) - \theta = \mathbb{E}(X^2) - \theta = \mathbb{V}(X) + \mathbb{E}(X)^2 - \theta = \theta + 0 - \theta = 0$.

Luego $\hat{\theta}_n$ es insesgado. Para ver si es eficiente, calculamos la información de Fisher:

$$\begin{aligned}
 \frac{\partial}{\partial \theta} \log f(x; \theta) &= \frac{\partial}{\partial \theta} \left(-\frac{x^2}{2\theta} - \frac{1}{2} \log(2\pi) - \frac{1}{2} \log(\theta) \right) = \frac{x^2}{2\theta^2} - \frac{1}{2\theta}. \\
 \implies \left(\frac{\partial}{\partial \theta} \log f(x; \theta) \right)^2 &= \frac{x^4}{4\theta^4} - \frac{x^2}{2\theta^3} + \frac{1}{4\theta^2} \implies I(\theta) = \mathbb{E} \left[\frac{X^4}{4\theta^4} - \frac{X^2}{2\theta^3} + \frac{1}{4\theta^2} \right] = \frac{1}{2\theta^2}.
 \end{aligned}$$

Basta ver que $\mathbb{V}(\hat{\theta}_n) = \frac{1}{nI(\theta)} = \frac{2\theta^2}{n}$ para ver que es eficiente.

$$\begin{aligned}
 \mathbb{V}(\hat{\theta}_n) &= \mathbb{V} \left(\frac{1}{n} \sum_{i=1}^n X_i^2 \right) = \frac{1}{n^2} \sum_{i=1}^n \mathbb{V}(X_i^2) = \frac{1}{n^2} n \mathbb{V}(X^2) \\
 &= \frac{1}{n} (\mathbb{E}(X^4) - \mathbb{E}(X^2)^2) = \frac{1}{n} (3\theta^2 - \theta^2) = \frac{2\theta^2}{n}.
 \end{aligned}$$

Por tanto, $\hat{\theta}_n$ es insesgado y eficiente. ■

(c) Definimos $Y_i = X_i^2$, por tanto, $\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i = \frac{1}{n} \sum_{i=1}^n X_i^2 = \hat{\theta}_n$. Por el teorema central del límite, $\sqrt{n} (\bar{Y} - \mathbb{E}(Y)) \xrightarrow[n \rightarrow \infty]{d} N(0, \sqrt{\mathbb{V}(Y)}) = N(0, \sqrt{2\theta})$

$$\implies \sqrt{n} (\hat{\theta}_n - \theta) \xrightarrow[n \rightarrow \infty]{d} N(0, \sqrt{2\theta}).$$

[3.] Se dispone de un gran lote de piezas producidas en una cadena de montaje. Denotemos por p la proporción de piezas defectuosas en ese lote. Supongamos que se seleccionan al azar sucesivamente (con reemplazamiento) piezas del lote hasta que se encuentra una defectuosa. Sea X la variable aleatoria que indica el número de la extracción en la que aparece la primera pieza defectuosa.

- (a) Calcula $P(X = k)$ para $k = 1, 2, \dots$. Obtén el estimador de p por el método de los momentos, a partir de una muestra $X_1, \dots, X_n$ de la v.a. X .
- (b) Calcula el estimador de p por el método de máxima verosimilitud. Calcula su distribución asintótica.

Solución.

- (a) Del enunciado se sigue que $X \sim \text{GEOM}(p) \implies \mathbb{P}\{X = x\} = p(1-p)^{x-1}$. Donde p es la probabilidad que una pieza sea defectuosa.

Puesto que p es unidimensional basta resolver $m_1 = \alpha_1(p)$ donde $m_1 = \bar{X}$ es el primer momento muestral y $\alpha_1(p) = \mathbb{E}(X^1) = 1/p$. Por tanto, $\hat{p}_n = 1/\bar{X}$.

- (b) Calculamos la función de verosimilitud:

$$L_n(p) = \prod_{i=1}^n p(1-p)^{x_i-1} = p^n (1-p)^{\sum_{i=1}^n x_i - n} = \left(\frac{p}{1-p}\right)^n (1-p)^{\sum_{i=1}^n x_i}.$$

$$\begin{aligned} \frac{d}{dp} \log L_n(p) &= \frac{d}{dp} \left(n \log p - n \log(1-p) + \log(1-p) \sum_{i=1}^n x_i \right) \\ &= \frac{n}{p} + \frac{n}{1-p} - \frac{\sum_{i=1}^n x_i}{1-p} = 0 \iff p = \frac{1}{\bar{X}}. \end{aligned}$$

Por tanto, el e.m.v. de p es $\boxed{\hat{p}_n = 1/\bar{X}}$.

4. Estudia si es eficiente el e.m.v. del parámetro λ en una distribución de Poisson.
5. Un modelo probabilístico para la v.a. “velocidad del viento” es la distribución de Rayleigh cuya función de densidad es

$$f(x; \theta) = \frac{x}{\theta^2} e^{-\frac{x^2}{2\theta^2}} I_{[0, \infty)}(x), \quad \theta > 0.$$

La media y la varianza de esta distribución son, respectivamente, $\mu = \theta\sqrt{\pi/2}$, $\sigma^2 = (4 - \pi)/2 \theta^2$.

- (a) Calcula el estimador de θ por el método de los momentos. Estudia si es asintóticamente normal y, en caso afirmativo, calcula su varianza asintótica.
- (b) Calcula el estimador de θ por el método de máxima verosimilitud. ¿Es consistente?
- (c) Estudia si el estimador de máxima verosimilitud es asintóticamente normal y, en caso afirmativo, calcula su varianza asintótica.

6. Sea el modelo definido por la densidad

$$f(x; \theta) = \frac{1}{2\theta} \exp\left(-\frac{|x|}{\theta}\right), \quad x \in \mathbb{R}, \theta > 0.$$

- (a) Calcula el estimador de máxima verosimilitud, $\hat{\theta}_n$, de θ , basado en una muestra de tamaño n .
- (b) ¿Es insesgado $\hat{\theta}_n$? Calcula su error cuadrático medio.
- (c) ¿Es consistente $\hat{\theta}_n$? ¿Es eficiente?
- (d) Obtener la distribución límite de $\sqrt{n}(\hat{\theta}_n - \theta)$.

7. Sea $X_1, \dots, X_n$ una muestra aleatoria de la densidad

$$f_{\theta}(x) = \frac{\theta}{x^2}, \quad \text{si } 0 < \theta \leq x.$$

- (a) Determinar $\hat{\theta}$, el estimador de máxima verosimilitud (e.m.v.) de θ .
- (b) Demostrar que $\hat{\theta}$ es consistente en probabilidad.

8. Se observa una muestra de una distribución de Poisson de parámetro θ [función de probabilidad $f(x|\theta) = e^{-\theta}\theta^x/x!$, $x = 0, 1, 2, \dots$] en la que el parámetro θ solo puede tomar alguno de los valores del espacio paramétrico $\Theta = \{1, 2, 3\}$. Antes de observar la muestra, la opinión de un experto sobre los distintos valores que puede tomar θ queda reflejada en la siguiente distribución de probabilidad a priori sobre Θ :

θ	1	2	3
$\pi(\theta)$	$\frac{1}{2}$	$\frac{1}{4}$	$\frac{1}{4}$

- (a) Si definimos el estimador bayesiano de θ como el valor del parámetro más probable a posteriori tras observar la muestra, y ésta consiste en dos observaciones independientes x_1, x_2 tales que $x_1 + x_2 = 2$, ¿cuánto vale el estimador bayesiano de θ ?
- (b) Para una muestra que cumple la condición del apartado anterior, ¿cuál es el estimador de máxima verosimilitud de θ ?

9. Sea $X_1, \dots, X_n$ una muestra de una v.a. con función de densidad

$$f(x; \theta) = \theta x^{\theta-1}, \quad 0 < x < 1, \theta > 0.$$

Sea $T_n(X_1, \dots, X_n) = -\frac{1}{n} \sum_{i=1}^n \log X_i$.

- (a) Prueba que $E_{\theta}(T_n) = \frac{1}{\theta}$, $\text{Var}_{\theta}(T_n) = \frac{1}{n\theta^2}$.
- (b) ¿Es eficiente T_n como estimador de $1/\theta$?

Solución.

$$(a) \mathbb{E}_\theta(T_n) = \mathbb{E}_\theta \left(-\frac{1}{n} \sum_{i=1}^n \log X_i \right) = -\frac{1}{n} \sum_{i=1}^n \mathbb{E}_\theta(\log X_i) = -\theta \int_0^1 (\log x) x^{\theta-1} dx = \frac{1}{\theta}.$$

[10.] El número de fallos que se producen anualmente en cierto mecanismo es una v.a. con distribución de Poisson de parámetro θ . El valor de θ no es conocido exactamente, pero se tiene cierta información a priori que permite considerarlo como una v.a. con distribución $\gamma(\alpha, \beta)$ (donde α y β son conocidos). Si $x_1, \dots, x_n$ son observaciones independientes de la variable aleatoria “número de fallos”, calcular la distribución a posteriori y obtener, a partir de ella, un estimador puntual para θ .

[11.] Al tirar una moneda trucada, la probabilidad desconocida de obtener cara es $\theta \in (0, 1)$. A priori, pensamos que $E(\theta) = 1/2$ y $\text{Var}(\theta) = 1/12$. Queremos estimar θ tirando una vez la moneda. ¿Cuál es el estimador Bayes en función de si ha resultado cara o cruz?

Solución. Tenemos que $X \sim \text{Bernoulli}(\theta)$, además

$$\mathbb{E}(\theta) = 1/2 \quad (1) \quad \wedge \quad \mathbb{V}(\theta) = \mathbb{E}(\theta^2) - \mathbb{E}^2(\theta) = 1/12 \implies \mathbb{E}(\theta^2) = 1/3 \quad (2).$$

La función de densidad de la muestra es $f(x | \theta) = \theta^x(1 - \theta)^{1-x}$ con $x \in \{0, 1\}$.

- Si ha salido cara, $x = 1$ entonces la distribución a posteriori es

$$\pi(\theta | 1) \propto f(1 | \theta)\pi(\theta) = \theta\pi(\theta) \xrightarrow{(1)} \pi(\theta | 1) = 2\theta\pi(\theta) \text{ para } \theta \in (0, 1)$$

Por tanto, el estimador Bayes es

$$T_n(1) = \mathbb{E}(\theta | 1) = 2 \int \theta^2 \pi(\theta) d\theta \stackrel{(2)}{=} 2 \cdot \frac{1}{3} = \frac{2}{3}$$

•

[12.] El tiempo (en minutos) que una persona espera el autobús cada mañana tiene distribución uniforme sobre el intervalo $(0, \theta)$, $\theta > 0$. La función de densidad a priori sobre $\Theta = (0, \infty)$ es $\pi(\theta) = 192/\theta^4$, si $\theta \geq 4$ y 0 si $\theta < 4$. En tres mañanas, los tiempos de espera observados han sido de 5, 3 y 8 minutos. Calcula el estimador Bayes de θ .

[13.] La distribución de Hardy-Weinberg de parámetro θ toma los valores 1, 2 y 3 con las probabilidades siguientes:

Valores	1	2	3
Probabilidades	θ^2	$2\theta(1 - \theta)$	$(1 - \theta)^2$

Se dispone de una muestra de tamaño 10 de v.a. independientes que siguen la distribución de Hardy-Weinberg. Entre los 10 datos, se ha observado dos veces el valor 1, cinco veces el valor 2, y tres veces el valor 3. Calcula el estimador de momentos y el estimador de máxima

verosimilitud de θ .

Indicacion: La distribución multinomial $M(n, p_1, \dots, p_k)$ surge al realizar n pruebas independientes, cada una de las cuales tiene k posibles resultados (mutuamente excluyentes). La función de masa es $P(o_1, \dots, o_k) = \frac{n!}{o_1! \dots o_k!} p_1^{o_1} \dots p_k^{o_k}$, siendo o_j la frecuencia observada del resultado j en las n pruebas y p_j la probabilidad de obtener el resultado j en una prueba, con $\sum_{j=1}^k p_j = 1$.

Solución.

(a) Vamos a calcular el estimador de θ por el método de los momentos.

$$\mathbb{E}_\theta(X) = \sum_{x=1,2,3} x \cdot P(X=x) = \theta^2 + 4\theta(1-\theta) + 3(1-\theta)^2 = -2\theta + 3$$

$$\text{Por tanto, } \bar{x} = \frac{2 \cdot 1 + 5 \cdot 2 + 3 \cdot 3}{10} = 2.1 = \mathbb{E}_\theta(X) = -2\tilde{\theta} + 3 \implies \tilde{\theta} = 0.45.$$

(b) $\text{EMV}(\theta) = \tilde{\theta}_{10}$.

(c)

[14.] Sean $X_1, \dots, X_n$ v.a.i.i.d. de una población uniforme en el intervalo $[0, \theta]$. Determina cuál es el límite en distribución de la sucesión $\sqrt{n} \log(2\bar{X}/\theta)$.

[15.] Sea X_n la media muestral calculada con las n primeras observaciones de una sucesión de v.a.i.i.d. procedentes de una población con esperanza μ y varianza σ^2 . Determina hacia dónde convergen en distribución las siguientes sucesiones:

(a) $\sqrt{n}(X_n^2 - \mu^2),$

(b) $n(X_n - \mu)^2,$

(c) $\sqrt{n}(X_n - \mu)^2.$

6.4 Intervalos de confianza

4.1

Consideramos la v.a. X = cantidad de contaminación por mercurio (en p.p.m.) en los peces capturados en los ríos norteamericanos Lumber y Wacamaw (archivo *Datos-mercurio.txt*).

1. Representa un estimador de la función de densidad de X . Compara esta densidad estimada con la densidad normal de igual media y desviación típica (representada en la misma gráfica). En vista de las dos funciones, ¿dirías que la función de densidad de X es aproximadamente normal?
2. Calcula un intervalo de confianza de nivel 0.95 para la media de X . ¿Se puede considerar fiable este intervalo a pesar de la posible no-normalidad de X ?
3. ¿Qué tamaño muestral habría que tomar para estimar la contaminación media con un margen de error máximo de 0.06?
4. Calcula ahora un intervalo de confianza de nivel 0.99 para la media de X . Compáralo con el intervalo obtenido en el apartado anterior.

4.2

En un estudio sobre el efecto del hábito de fumar en la agregación de plaquetas en la sangre (que puede dar lugar a la formación de coágulos), se extrajeron muestras de sangre de 11 individuos antes y después de fumar un cigarrillo, y se midió el máximo porcentaje de plaquetas agregadas. Los resultados fueron:

Individuo	1	2	3	4	5	6	7	8	9	10	11
Antes	25	25	27	44	30	67	53	53	52	60	28
Después	27	29	37	56	46	82	57	80	61	59	43

Bajo hipótesis de normalidad, calcula un intervalo de confianza de nivel 0.95 para la diferencia media μ del máximo porcentaje de plaquetas agregadas antes y después de fumar un cigarrillo. ¿Qué conclusión se obtiene del resultado obtenido?

Indicación: Se trata de datos emparejados. Un procedimiento habitual en este caso consiste en suponer que la variable D , la diferencia entre el máximo porcentaje de plaquetas agregadas antes y después de fumar un cigarrillo, sigue una distribución $N(\mu, \sigma)$, con σ desconocido.

4.3

1. Utilizando el fichero *Datos-lipidos.txt*, estima, mediante un intervalo de confianza de nivel 0.95, la proporción de pacientes que tienen una concentración de colesterol superior o igual a 220 mg/dl. ¿Qué tamaño muestral habría que usar para tener una probabilidad aproximada de 0.95 de no cometer un error mayor que 0.01 en la estimación de esta proporción?
2. Suponiendo que la distribución de la variable “concentración de colesterol” fuese aproximadamente normal, obtener un estimador puntual para la proporción indicada en (a).

4.4

Sea una v.a. con función de densidad $f(x; \theta) = \theta x^{-(\theta+1)} 1_{[1, \infty)}(x)$.

1. Obtener el estimador de máxima verosimilitud de θ .
2. Obtener su distribución asintótica.
3. Calcular una cantidad pivotal aproximada y, a partir de ella, un intervalo de confianza de nivel aproximado $1 - \alpha$ para θ .

4.5

Sea $X_1, \dots, X_n$ una muestra aleatoria simple de una distribución uniforme en el intervalo $(\theta, 1)$, donde $\theta < 1$.

1. Calcula el estimador de máxima verosimilitud de θ .
2. Modifica el estimador de (a) para obtener una cantidad pivotal y un intervalo de confianza de nivel $1 - \alpha$ para θ .

4.6

Construye tres intervalos de confianza asintóticos diferentes para el parámetro λ de una distribución de Poisson usando los tres métodos siguientes:

1. Utiliza el comportamiento asintótico de la media muestral $\sqrt{n}(\bar{X} - \lambda) \xrightarrow{d} N(0, \sqrt{\lambda})$, estima de forma consistente la varianza y aplica el teorema de Slutsky.

2. Igual que el anterior, pero sin estimar la varianza.
3. Aplica el método delta para “estabilizar la varianza”, es decir, buscando una función g tal que $\sqrt{n}(g(\bar{X}) - g(\lambda)) \xrightarrow{d} N(0, 1)$.

4.7

Sean $\theta > 0$ y X una variable aleatoria con función de densidad:

$$f(x) = \frac{2(\theta - x)}{\theta^2}, \quad \text{para } 0 \leq x \leq \theta.$$

1. Calcula la función de distribución de X/θ y comprueba que X/θ es una cantidad pivotal.
2. Utiliza esta cantidad pivotal para encontrar un intervalo de confianza de nivel $1 - \alpha$ para θ basado en la única observación X .
3. Determina un estimador insesgado de θ basado en la única observación X .

4.8

Se desea estudiar la influencia de la hipertensión en los padres sobre la presión sanguínea de los hijos. Para ello se seleccionan dos grupos de niños, unos con padres de presión sanguínea normal (grupo 1) y otros con uno de sus padres hipertenso (grupo 2), obteniéndose las siguientes presiones sistólicas:

Grupo 1	104	88	100	98	102	92	96	100	96	96
Grupo 2	100	102	96	106	110	110	120	112	112	90

Halla un intervalo de confianza para la diferencia de medias, suponiendo que la distribución de la presión sistólica es normal y que las varianzas en las dos poblaciones de niños son iguales.

4.9

Sea $X_1, \dots, X_n$ una muestra de una distribución normal de media μ y varianza θ . Estamos interesados en estimar θ . Sea $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ la varianza muestral insesgada.

Calcular $\text{Var}(S^2)$ y compararla con la cota de Fréchet-Cramér-Rao.

4.10

1. Sea X_n una v.a. con distribución χ_n^2 . Determina hacia dónde convergen en distribución las sucesiones:

$$\sqrt{n/2}(X_n/n - 1) \quad \text{y} \quad \sqrt{2X_n} - \sqrt{2n}.$$

2. Sea X una v.a. con distribución $\gamma(5, 10)$. Calcular $P(X \leq 3)$ usando las tablas de la distribución χ^2 .

Indicación: Si ξ es una v.a. $\gamma(a, p)$ con densidad:

$$g(t) = \frac{a^p}{\Gamma(p)} e^{-at} t^{p-1}, \quad t > 0,$$

y $c > 0$ es una constante, entonces $c\xi$ es una v.a. $\gamma(a/c, p)$.

3. Sea $Y \sim \chi_{100}^2$. Calcular aproximadamente $P(Y \leq 90)$ usando las tablas de la $N(0, 1)$.

Indicación: Expresar Y como suma de v.a.i.i.d.

4. Sea $\bar{X}_n$ la media muestral calculada con las n primeras observaciones de una sucesión de v.a.i.i.d. procedentes de una población con esperanza μ y varianza σ^2 . Determina hacia dónde converge en distribución la sucesión $n(\bar{X}_n - \mu)^2$.