
PROBABILIDAD II

Tercero del Grado en Matemáticas

Hugo Marquerie

Profesor: José Manuel Conde Alonso
Facultad de Ciencias - Universidad Autónoma de Madrid
Segundo cuatrimestre 2024-2025

28 de enero, 2025

Puedes encontrar mi colección completa de apuntes en <https://hmarquer.github.io>.

Índice

1	Espacios de probabilidad	1
1.1	Sucesos y probabilidades	1
1.2	Variables aleatorias	3
1.2.1	Medida inducida	3
1.2.2	Función de distribución y función de densidad	3
1.3	Probabilidad condicionada	8
1.4	Independencia	9
1.4.1	Definiciones y resultados básicos	9
1.4.2	Criterios de independencia	10
2	Esperanza matemática	13
2.1	Definiciones y propiedades básicas	13
2.1.1	Esperanza	13
2.1.2	Varianza	14
2.2	Desigualdades básicas	15
2.2.1	Desigualdades de Chebyshev y Markov	19
2.3	Comportamiento a largo plazo	20
2.3.1	Definición de $\limsup$ y $\liminf$	20
2.3.2	Lemas de Borel-Cantelli	22
2.3.3	σ -álgebra de cola y teoremas de Kolmogorov	24
3	Convergencia de sucesiones de variables aleatorias	29
3.1	Diferentes tipos de convergencia	29
3.1.1	Implicaciones entre los diferentes tipos de convergencia	30
3.2	Otros resultados de convergencia	32
4	Martingalas	35
4.1	Esperanza condicionada	35
4.2	Procesos estocásticos y martingalas	40
4.2.1	Definiciones, interpretación y ejemplos	40
4.2.2	Propiedades de martingalas	43
4.3	Tiempos de parada	45
4.4	Aplicaciones y juegos de azar	50

5	Comportamiento a largo plazo	53
5.1	Leyes de los grandes números	53
5.2	Teorema central del límite	56
H	Hojas de ejercicios	59
H.0	Repaso de teoría de la medida	59
H.1	Espacios de probabilidad	65
H.1.1	Ejercicios básicos	65
H.1.2	Problemas	70
H.1.3	Problema para ampliar	73
H.2	Esperanza matemática	75
H.2.1	Ejercicios básicos	75
H.2.2	Problemas	77
H.2.3	Problemas para ampliar	86
H.3	Convergencia de sucesiones de variables aleatorias	88
H.4	Martingalas	93
H.4.1	Ejercicios básicos	93
H.4.2	Problemas	95
H.4.3	Problemas para ampliar	101
H.5	Comportamiento a largo plazo de sucesiones	103
H.5.1	Ejercicios básicos	103
H.5.2	Problemas	105
A	Entrega	111
A.1	El <i>Quijote</i> finito	111
A.2	Un <i>Quijote</i> infinito	111
A.2.1	Un <i>Quijote</i> con infinitos capítulos finitos	112
A.2.2	Un <i>Quijote</i> infinito e indivisible	112
A.3	Conexión con la medida de Lebesgue en $[0, 1]$	113

1. Espacios de probabilidad

1.1 Sucesos y probabilidades

Definición 1.1.1 (Espacio de probabilidad). La tripleta $(\Omega, \Sigma, \mathbb{P})$ es un espacio de probabilidad $\iff (\Omega, \Sigma, \mathbb{P})$ es un espacio de medida con $\mathbb{P}(\Omega) = 1$.

Definición 1.1.2 (Suceso). $A \subset \Omega$ es un suceso $\iff A \in \Sigma$.

Ejemplos 1.1.1 (de espacios de probabilidad).

[1] $\Omega = \{1, 2, \dots, n\}$, $\Sigma = \mathcal{P}(\Omega)$ y $\mathbb{P}$ dada por $\forall j \in \mathbb{N}_n : \mathbb{P}(j) = \frac{1}{n}$.

Observación 1.1.3. No existe ninguna medida de probabilidad uniforme sobre $\mathbb{N}^1$.

[2] $\Omega = \mathbb{N}$, $\Sigma = \mathcal{P}(\Omega)$ y $\mathbb{P}$ dada por $\forall j \in \mathbb{N} : \mathbb{P}(j) = 2^{-j}$.

[3] $([0, 1], \mathcal{B}([0, 1]), m)$, donde m es la medida de Lebesgue.

[4] $([0, 1], \mathcal{L}([0, 1]), m)$, donde $\mathcal{L}([0, 1])$ es la completación de $\mathcal{B}([0, 1])$.

Ejercicio 1.1.2. Comprobar que γ dada por la función de densidad $d\gamma(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx$ es una medida de probabilidad.

Solución: Como $d\gamma$ es una función positiva, basta ver que $\gamma(\mathbb{R}) = 1$, es decir, que $\int_{\mathbb{R}} d\gamma = 1$ o equivalentemente que $\int_{\mathbb{R}} d\gamma(x) dx = 1$.

Definimos $I := \int_{\mathbb{R}} e^{-\frac{x^2}{2}} dx$, entonces $I^2 = \left(\int_{\mathbb{R}} e^{-\frac{x^2}{2}} dx \right) \left(\int_{\mathbb{R}} e^{-\frac{y^2}{2}} dy \right)$.

$$\begin{aligned} \implies I^2 &= \iint_{\mathbb{R}^2} e^{-\frac{x^2+y^2}{2}} dx dy = \int_0^{2\pi} \int_0^\infty e^{-\frac{r^2}{2}} r dr d\theta = \int_0^{2\pi} \left[-e^{-\frac{r^2}{2}} \right]_0^\infty d\theta \\ &= \int_0^{2\pi} (-0 + e^0) d\theta = \int_0^{2\pi} d\theta = 2\pi \implies I = \sqrt{2\pi} \end{aligned}$$

Como $I = \sqrt{2\pi}$, entonces $\gamma(\mathbb{R}) = \frac{I}{\sqrt{2\pi}} = 1$ y por tanto γ es una medida de probabilidad. ■

Ejercicio 1.1.3. Comprobar que $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \gamma_n)$ con $d\gamma_n(x) = c_n e^{-\frac{\|x\|^2}{2}} dx$ es un espacio de probabilidad y calcular c_n .

¹El apartado 21b del ejercicio de ampliación 21 de la Hoja 1 consiste en demostrar este hecho.

Solución: Tenemos que para $n = 1$, γ_1 es una medida de probabilidad con $c_1 = \frac{1}{\sqrt{2\pi}}$ por el Ejercicio 1.1.2 anterior. Supongamos por inducción que γ_n es una medida de probabilidad con $c_n = (2\pi)^{-n/2}$. Ahora consideramos el caso $n + 1$: Sea $x = (x_1, \dots, x_n, x_{n+1})$, se tiene que $d\gamma_{n+1}(x) = c_{n+1}e^{-\frac{1}{2}\sum_{i=1}^{n+1}x_i^2} dx_1 \dots dx_{n+1}$ y por tanto

$$\begin{aligned}\gamma_{n+1}(\mathbb{R}^{n+1}) &= \int \dots \int_{\mathbb{R}^{n+1}} c_{n+1}e^{-\frac{1}{2}\sum_{i=1}^{n+1}x_i^2} dx_1 \dots dx_{n+1} \\ &= c_{n+1} \left(\int_{\mathbb{R}} e^{-\frac{x_{n+1}^2}{2}} dx_{n+1} \right) \left(\int \dots \int_{\mathbb{R}^n} e^{-\frac{1}{2}\sum_{i=1}^n x_i^2} dx_1 \dots dx_n \right).\end{aligned}$$

Como, por hipótesis de inducción, $\int \dots \int_{\mathbb{R}^n} e^{-\frac{1}{2}\sum_{i=1}^n x_i^2} dx_1 \dots dx_n = (2\pi)^{n/2}$, entonces

$$\gamma_{n+1}(\mathbb{R}^{n+1}) \stackrel{\text{H.I.}}{=} c_{n+1}(2\pi)^{n/2} \left(\int_{\mathbb{R}} e^{-\frac{x_{n+1}^2}{2}} dx_{n+1} \right) \stackrel{1.1.2}{=} c_{n+1}(2\pi)^{n/2} \sqrt{2\pi} = c_{n+1}(2\pi)^{n+1/2}.$$

Por tanto, $c_{n+1} = (2\pi)^{-n+1/2}$ y γ_{n+1} es una medida de probabilidad. Por inducción, $\forall n \in \mathbb{N} : \gamma_n$ es una medida de probabilidad con $c_n = (2\pi)^{-n/2}$. ■

Ejercicio 1.1.4. Comprobar que la medida α dada por la densidad $d\alpha(x) = c_0 \frac{1}{|x|} \mathbb{1}_{\{|x|>1\}}(x)$ no es una medida de probabilidad.

Solución: Como $d\alpha$ es una función positiva (para $c_0 > 0$), basta ver que su integral en $\mathbb{R}$ es infinita para cualquier valor de $c_0 > 0$.

$$\frac{1}{c_0} \alpha(\mathbb{R}) = \int_{\mathbb{R}} \frac{1}{|x|} \cdot \mathbb{1}_{\{|x|>1\}}(x) dx = - \int_{-\infty}^{-1} \frac{1}{x} dx + \int_1^{\infty} \frac{1}{x} dx = 2 \int_1^{\infty} \frac{1}{x} dx = 2 \log(x) \Big|_1^{\infty} = \infty.$$

Como $\forall c_0 > 0 : \alpha(\mathbb{R}) = \infty$, entonces α no es una medida de probabilidad. ■

Ejercicio 1.1.5 (de espacio de probabilidad “nuevo”). Sea $([0, 1], \mathcal{B}([0, 1]), \mu)$ donde $\mu = \mu_1 + \mu_2$ con $\mu_1 = \frac{1}{2}m|_{[0,1]}$ y $\mu_2(\{\frac{1}{n}\}) = 2^{-n-1}$, $\mu_2(A) = 0$ si $A \cap \{1, \frac{1}{2}, \frac{1}{3}, \dots\} = \emptyset$. Demuestra que μ es una medida de probabilidad.

Solución: Como μ_1 y μ_2 son medidas positivas, μ también lo es, por tanto, basta ver que $\mu([0, 1]) = 1$. Claramente $\mu_1([0, 1]) = \frac{1}{2}$, por lo que hay que probar que $\mu_2([0, 1]) = \frac{1}{2}$.

$$\mu_2([0, 1]) = \sum_{n \in \mathbb{N}} \mu_2\left(\left\{\frac{1}{n}\right\}\right) = \sum_{n \in \mathbb{N}} 2^{-n-1} = \frac{1}{2} \sum_{n \in \mathbb{N}} 2^{-n} = \frac{1}{2} \cdot 1 = \frac{1}{2}.$$

Por tanto, $\mu([0, 1]) = \mu_1([0, 1]) + \mu_2([0, 1]) = 1$ y μ es una medida de probabilidad. ■

1.2 Variables aleatorias

Definición 1.2.1 (Variable aleatoria). Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad, la aplicación $X: \Omega \longrightarrow \mathbb{R}$ es una variable aleatoria $\iff X$ es medible respecto a $\mathbb{P}$.

1.2.1 Medida inducida

Lema 1.2.1. Sea X una v.a. y definimos $\mu_X: \mathcal{B}(\mathbb{R}) \longrightarrow [0, 1]$ dada por $\mu_X(B) = \mathbb{P}(X \in B)$

$\implies \mu_X$ es una medida de probabilidad en el espacio medible $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$.

A esta medida μ_X se le llama **medida inducida** por X .

Demostración: Comprobemos las condiciones de la definición de medida:

i) $\mu_X(\emptyset) = \mathbb{P}(X \in \emptyset) = 0$.

ii) Sean $\{B_n\}_{n \in \mathbb{N}} \subset \mathcal{B}(\mathbb{R})$ disjuntos dos a dos, entonces

$$\begin{aligned} \mu_X\left(\bigsqcup_{n \in \mathbb{N}} B_n\right) &= \mathbb{P}\left(X \in \bigsqcup_{n \in \mathbb{N}} B_n\right) = \mathbb{P}\left(\left\{\omega \in \Omega : X(\omega) \in \bigsqcup_{n \in \mathbb{N}} B_n\right\}\right) \\ &\stackrel{\substack{\uparrow \\ \text{unión disjunta}}}{=} \mathbb{P}\left(\bigsqcup_{n \in \mathbb{N}} \{\omega \in \Omega : X(\omega) \in B_n\}\right) = \sum_{n \in \mathbb{N}} \mathbb{P}(\{\omega \in \Omega : X(\omega) \in B_n\}) \\ &= \sum_{n \in \mathbb{N}} \mathbb{P}(X \in B_n) = \sum_{n \in \mathbb{N}} \mu_X(B_n). \end{aligned}$$

Como μ_X es positiva (porque $\mathbb{P}$ lo es), basta ver que $\mu_X([0, 1]) = 1$.

$$\mu_X(\mathbb{R}) = \mathbb{P}(X \in \mathbb{R}) = \mathbb{P}(\{\omega \in \Omega : X(\omega) \in \mathbb{R}\}) = \mathbb{P}(\Omega) = 1.$$

Por tanto, μ_X es una medida de probabilidad. ■

1.2.2 Función de distribución y función de densidad

Definición 1.2.2 (Función de distribución). Sea X una v.a., $F_X: \mathbb{R} \longrightarrow [0, 1]$ es la función de distribución de $X \iff \forall t \in \mathbb{R} : F_X(t) = \mathbb{P}(X \leq t)$.

Proposición 1.2.2 (Propiedades de F_X). Sea F_X fn de distribución de X , entonces

$$\begin{aligned} (1) \quad \lim_{t \rightarrow \infty} F_X(t) &= 1 \wedge \lim_{t \rightarrow -\infty} F_X(t) = 0. & (3) \quad \forall t \in \mathbb{R} : \lim_{\substack{s \rightarrow t \\ s < t}} F_X(s) &= \mathbb{P}(X < t) \\ (2) \quad \forall t \in \mathbb{R} : \lim_{\substack{s \rightarrow t \\ s > t}} F_X(s) &= F_X(t). & (4) \quad \forall t \in \mathbb{R} : \mathbb{P}(X = t) &= F_X(t) - \lim_{\substack{s \rightarrow t \\ s < t}} F_X(s). \end{aligned}$$

Demostración: Recordamos la definición: $F_X(t) = \mathbb{P}(\{\omega \in \Omega : X(\omega) \leq t\})$

- (1) Sea $(t_n)_{n \in \mathbb{N}} \subset \mathbb{R}$ tal que $t_n \rightarrow \infty$, definimos $\forall n \in \mathbb{N} : A_n := \{\omega \in \Omega : X(\omega) \leq t_n\}$ y la sucesión de funciones medibles $(f_n)_{n \in \mathbb{N}}$ dada por $f_n := \mathbb{1}_{A_n}$. Entonces, como $\forall \omega \in \Omega : f_n(\omega) \leq 1$ y $\int_{\Omega} 1 d\mathbb{P} = \mathbb{P}(\Omega) = 1$ (luego $1 \in \mathcal{L}^1(\mathbb{P})$), podemos aplicar el teorema de la convergencia dominada a $(f_n)_{n \in \mathbb{N}}$ y obtenemos

$$\begin{aligned} \lim_{n \rightarrow \infty} F_X(t_n) &= \lim_{n \rightarrow \infty} \mathbb{P}(A_n) = \lim_{n \rightarrow \infty} \int_{\Omega} \mathbb{1}_{A_n} d\mathbb{P} = \lim_{n \rightarrow \infty} \int_{\Omega} f_n d\mathbb{P} \stackrel{\text{TCD}}{=} \int_{\Omega} \lim_{n \rightarrow \infty} f_n d\mathbb{P} \\ &= \int_{\Omega} \lim_{n \rightarrow \infty} \mathbb{1}_{A_n} d\mathbb{P} = \mathbb{P}\left(\lim_{n \rightarrow \infty} A_n\right) = \mathbb{P}(\Omega) = 1. \end{aligned}$$

Análogamente, si $(t_n)_{n \in \mathbb{N}} \subset \mathbb{R}$ cumple que $t_n \rightarrow -\infty$, podemos definir A_n y f_n como antes y aplicar el teorema de la convergencia dominada de igual manera:

$$\lim_{n \rightarrow \infty} F_X(t_n) = \lim_{n \rightarrow \infty} \int_{\Omega} f_n d\mathbb{P} \stackrel{\text{TCD}}{=} \int_{\Omega} \lim_{n \rightarrow \infty} f_n d\mathbb{P} = \mathbb{P}\left(\lim_{n \rightarrow \infty} A_n\right) = \mathbb{P}(\emptyset) = 0.$$

- (2) Sea $t \in \mathbb{R}$ y $(t_n)_{n \in \mathbb{N}}$ tal que $t_n \rightarrow t$ con $\forall n \in \mathbb{N} : t_n > t$. Definimos A_n y f_n como antes y aplicamos el teorema de la convergencia dominada de nuevo:

$$\begin{aligned} \lim_{n \rightarrow \infty} F_X(t_n) &= \lim_{n \rightarrow \infty} \int_{\Omega} f_n d\mathbb{P} \stackrel{\text{TCD}}{=} \int_{\Omega} \lim_{n \rightarrow \infty} f_n d\mathbb{P} = \mathbb{P}\left(\lim_{n \rightarrow \infty} A_n\right) \\ &= \mathbb{P}(\{\omega \in \Omega : X(\omega) \leq t\}) = \mathbb{P}(X \leq t) = F_X(t). \end{aligned}$$

■

Proposición 1.2.3. Sea $F: \mathbb{R} \rightarrow \mathbb{R}$ monótona no decreciente que cumple (1), (2) y (3)

$$\implies \exists (\Omega, \Sigma, \mathbb{P}) \text{ espacio de probabilidad} : \exists X \text{ v.a.} : \forall t \in \mathbb{R} : F_X(t) = F(t).$$

Demostración: Consideramos en el espacio de probabilidad $([0, 1], \mathcal{B}([0, 1]), m)$ la variable aleatoria $X: [0, 1] \rightarrow \mathbb{R}$ dada por $\forall \omega \in [0, 1] : X(\omega) = \sup \{t \in \mathbb{R} : F(t) < \omega\}$.

$$\begin{aligned} \implies \forall t \in \mathbb{R} : m(\{\omega \in \mathbb{R} : X(\omega) \leq t\}) &= m(\{\omega \in \mathbb{R} : \sup \{s \in \mathbb{R} : F(s) < \omega\} \leq t\}) \\ &= m(\{\omega \in \mathbb{R} : \omega \leq F(t)\}) = F(t). \end{aligned}$$

Por tanto, $\forall t \in \mathbb{R} : F_X(t) = m(\{\omega \in \mathbb{R} : X(\omega) \leq t\}) = F(t)^2$.

■

Definición 1.2.3 (Igualdad en distribución). Sean X e Y dos variables aleatorias en dos

²También se puede definiendo X como la identidad en el espacio de medida dado por la medida de Lebesgue-Stieltjes.

espacios de probabilidad, son iguales en distribución

$$\Longleftrightarrow \forall t \in \mathbb{R} : F_X(t) = F_Y(t) \Longleftrightarrow \mu_X = \mu_Y \Longleftrightarrow X \stackrel{d}{=} Y.$$

Ejemplo 1.2.1 (de variables aleatorias iguales en distribución).

Consideramos los espacios de probabilidad

$$(\Omega_1, \Sigma_1, \mathbb{P}_1) = (\{1, 2\}, \mathcal{P}(\{1, 2\}), |\cdot|) \text{ y } (\Omega_2, \Sigma_2, \mathbb{P}_2) = ([0, 1], \mathcal{B}([0, 1]), m)$$

y las variables aleatorias $X: \Omega_1 \longrightarrow \mathbb{R}$ dada por $X(1) = 0$ y $X(2) = 1$ e $Y: \Omega_2 \longrightarrow \mathbb{R}$ dada por $Y(\omega) = 0$ si $\omega \leq 1/2$ y $Y(\omega) = 1$ si $\omega > 1/2$.

Entonces, $X \stackrel{d}{=} Y$.

Definición 1.2.4 (Variable aleatoria discreta). Sea X una variable aleatoria en un espacio de probabilidad $(\Omega, \Sigma, \mathbb{P})$, X es discreta

$$\Longleftrightarrow \exists S \subset \mathbb{R} \text{ numerable} : \mathbb{P}(X \notin S) = 0.$$

Definición 1.2.5 (Variable aleatoria continua). Una variable aleatoria X es continua

$$\Longleftrightarrow F_X \text{ es continua.}$$

Definición 1.2.6 (Variable aleatoria absolutamente continua).

Una variable aleatoria X con medida inducida μ_X es absolutamente continua

$$\Longleftrightarrow \mu_X \text{ es absolutamente continua respecto a la medida de Lebesgue.}$$

Observación 1.2.7. Sea X absolutamente continua $\implies X$ es continua.

Sin embargo, el recíproco no es cierto.

Definición 1.2.8 (Función de densidad). Sea X una variable aleatoria absolutamente continua en $(\Omega, \Sigma, \mathbb{P})$, $f_X: \mathbb{R} \longrightarrow [0, 1] \in \mathcal{L}^1(m)$ es la función de densidad de X

$$\Longleftrightarrow \forall B \in \mathcal{B}(\mathbb{R}) : \mathbb{P}(X \in B) = \int_B f_X(x) dx.$$

Lema 1.2.4. Sea X una v.a. con función de distribución $F_X \in \mathcal{C}^1$

$$\implies X \text{ es absolutamente continua con función de densidad } f_X = F'_X.$$

Demostración: Sea μ_X la medida inducida por X , es decir, $\mu_X(B) = \mathbb{P}(X \in B)$ para todo $B \in \mathcal{B}(\mathbb{R})$. Sea $E \in \mathcal{B}(\mathbb{R})$ tal que $m(E) = 0$, entonces

$$\forall \varepsilon > 0 : \exists \{I_n = [a_n, b_n]\}_{n \in \mathbb{N}} \subset \mathcal{B}(\mathbb{R}) \text{ acotados} : E \subset \bigcup_{n \in \mathbb{N}} I_n : \sum_{n \in \mathbb{N}} m(I_n) < \varepsilon.$$

Podemos suponer sin pérdida de generalidad que E es acotado y entonces solo son necesarios una cantidad finita de intervalos I_n para cubrir E . Como $F_X \in \mathcal{C}^1$, por el teorema de valor medio,

$$\forall [a, b] \subset \mathbb{R} : \exists c \in (a, b) : F_X(b) - F_X(a) = F'_X(c)(b - a)$$

Como F'_X es continua en todo $\mathbb{R}$, $\exists M > 0$ tal que $\forall x \in \bigcup_{n=1}^k I_n : |F'_X(x)| \leq M$

$$\begin{aligned} \implies \mu_X(E) &\leq \mu_X\left(\bigcup_{n=1}^k I_n\right) \leq \sum_{n=1}^k \mu_X([a_n, b_n]) = \\ &\leq \sum_{n=1}^k (F_X(b_n) - F_X(a_n)) \leq \sum_{n=1}^k F'_X(c_n)(b_n - a_n) \leq M \cdot \varepsilon. \end{aligned}$$

Haciendo $\varepsilon \rightarrow 0$, tenemos que $\mu_X(E) = 0$. Por tanto, μ_X es absolutamente continua respecto a la medida de Lebesgue m .

Entonces, por el teorema de Radon-Nikodym, existe una función medible f_X tal que

$$\forall B \in \mathcal{B}(\mathbb{R}) : \mu_X(B) = \mathbb{P}(X \in B) = \int_B f_X(x) dx.$$

Por último, como F_X es de clase $\mathcal{C}^1$, por el teorema fundamental del cálculo, tenemos que

$$\forall t \in \mathbb{R} : F_X(t) = \int_{-\infty}^t F'_X(x) dx = \int_{-\infty}^t f_X(x) dx = \mu_X((-\infty, t]) = \mathbb{P}(X \leq t).$$

En consecuencia, $f_X = F'_X$ en c.t.p. (respecto a la medida de Lebesgue). ■

Lema 1.2.5. Sea X una v.a. absolutamente continua con función de densidad f_X tal que $\exists \alpha, \beta \in \mathbb{R} : \mathbb{P}(\alpha \leq X \leq \beta) = 1$ y sea $g : \mathbb{R} \rightarrow \mathbb{R} \in \mathcal{C}^1$ estrictamente creciente

$$\begin{aligned} \implies g(X) : \Omega \rightarrow \mathbb{R} \quad &\text{es una v.a. abs continua con función de densidad } f_{g(X)}(t) \\ \omega \mapsto &g(X(\omega)) \end{aligned}$$

$$\text{donde } \forall t \in \mathbb{R} : f_{g(X)}(t) = \begin{cases} \frac{f_X(g^{-1}(t))}{g'(g^{-1}(t))} & \text{si } g(\alpha) \leq t \leq g(\beta) \\ 0 & \text{en otro caso.} \end{cases}$$

Demostración: Basta ver que $\forall t \in \mathbb{R} : F_{g(X)}(t) = \int_{-\infty}^t f_{g(X)}(x) dx$, donde $F_{g(X)}$ es la función de distribución de $g(X)$. Como g es estrictamente creciente en todo $\mathbb{R}$, es inyectiva

y, en consecuencia, biyectiva sobre su imagen ($\exists g^{-1} : g(\mathbb{R}) \rightarrow \mathbb{R}$).

$$\implies F_{g(X)}(t) = \mathbb{P}(g(X) \leq t) = \mathbb{P}(X \leq g^{-1}(t)) = \int_{-\infty}^{g^{-1}(t)} f_X(x) dx$$

Podemos hacer el cambio de variable $y = g^{-1}(t)$ y obtenemos que

$$dy = \frac{1}{g'(g^{-1}(t))} dt \implies F_{g(X)}(t) = \int_{-\infty}^{g^{-1}(t)} f_X(x) dx = \int_{-\infty}^t \frac{f_X(g^{-1}(y))}{g'(g^{-1}(y))} \cdot \mathbb{1}_{(g(\alpha), g(\beta))}(y) dy.$$

Por tanto, $f_{g(X)}(t)$ es la función de densidad de $g(X)$. ■

Definición 1.2.9. Sea $X \neq \emptyset$ y $f : X \rightarrow \mathbb{R}$, $\sigma(f)$ es la σ -álgebra generada por f

$$\iff \sigma(f) = \{f^{-1}(E) : E \in \mathcal{B}(\mathbb{R})\} = \{\{x \in X : f(x) \in E\} : E \in \mathcal{B}(\mathbb{R})\}.$$

Es decir, $\sigma(f)$ es la σ -álgebra más pequeña que hace a f medible.

Definición 1.2.10 (Vector aleatorio). Sea $(X, \Omega, \mathbb{P})$ un espacio de probabilidad, la aplicación $X : \Omega \rightarrow \mathbb{R}^n$ es un vector aleatorio $\iff X$ es medible respecto $\mathcal{B}(\mathbb{R}^n)$.

Ejercicio 1.2.2. Sean $X_1, \dots, X_n : \Omega \rightarrow \mathbb{R}$ v.a. en un esp. de probabilidad $(\Omega, \Sigma, \mathbb{P})$.

(a) Demuestra que $X : \Omega \rightarrow \mathbb{R}^n$ es un vector aleatorio.

$$\omega \mapsto (X_1(\omega), \dots, X_n(\omega))$$

(b) Demuestra que $X_1 + \dots + X_n : \Omega \rightarrow \mathbb{R}$ es una variable aleatoria.

$$\omega \mapsto X_1(\omega) + \dots + X_n(\omega)$$

Solución:

(a) Queremos ver que $\forall E \in \mathcal{B}(\mathbb{R}^n) : X^{-1}(E) \in \Sigma$. Sabemos que la σ -álgebra $\mathcal{B}(\mathbb{R}^n)$ está generada por los conjuntos de la forma $E_1 \times \dots \times E_n$ con $E_i \in \mathcal{B}(\mathbb{R})$, por tanto, basta probarlo para estos conjuntos.

Sea $E = E_1 \times \dots \times E_n$ con $E_i \in \mathcal{B}(\mathbb{R})$, entonces

$$X^{-1}(E) = \{\omega \in \Omega : \forall i \in \mathbb{N}_n : X_i(\omega) \in E_i\} = \bigcap_{i=1}^n X_i^{-1}(E_i).$$

Como las X_i son variables aleatorias, entonces $X_i^{-1}(E_i) \in \Sigma \implies (X_i^{-1}(E_i))^c \in \Sigma$

$$\implies (X^{-1}(E))^c = \bigcup_{i=1}^n (X_i^{-1}(E_i))^c \in \Sigma \implies X^{-1}(E) \in \Sigma.$$

Por tanto, X es un vector aleatorio. ■

- (b) Definimos $g: \mathbb{R}^n \rightarrow \mathbb{R}$ dada por $g(x_1, \dots, x_n) = x_1 + \dots + x_n$. Como g es una función continua, es medible. Como la composición de funciones medibles es medible, entonces $Y: \Omega \rightarrow \mathbb{R}$ dada por $Y(\omega) = g(X_1(\omega), \dots, X_n(\omega)) = X_1(\omega) + \dots + X_n(\omega)$ es una variable aleatoria. ■

1.3 Probabilidad condicionada

Definición 1.3.1 (Probabilidad conticionada). Sean $A, B \in \Sigma$ dos sucesos con $\mathbb{P}(B) \neq 0$, $\mathbb{P}(A | B)$ es la probabilidad condicionada de A dado B

$$\iff \mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$$

Teorema 1.3.1 (Probabilidad total). Sea $(X, \Sigma, \mathbb{P})$ un espacio de probabilidad y $\{A_i\}_{i \in \mathbb{N}} \subset \Sigma$ una partición de Ω tal que $\forall i \in \mathbb{N} : \mathbb{P}(A_i) \neq 0$

$$\implies \forall B \in \Sigma : \mathbb{P}(B) = \sum_{i \in \mathbb{N}} \mathbb{P}(A_i) \cdot \mathbb{P}(B | A_i).$$

Demostración: Sea $B \in \Sigma$, entonces $B = \bigsqcup_{i \in \mathbb{N}} B \cap A_i$, y por la Definición 1.3.1:

$$\mathbb{P}(B) \stackrel{\text{aditividad}}{=} \sum_{i \in \mathbb{N}} \mathbb{P}(B \cap A_i) \stackrel{\text{def}}{=} \sum_{i \in \mathbb{N}} \mathbb{P}(A_i) \cdot \mathbb{P}(B | A_i).$$

Teorema 1.3.2 (de Bayes). Sea $(X, \Sigma, \mathbb{P})$ un espacio de probabilidad y $A, B \in \Sigma$

$$\implies \mathbb{P}(A | B) = \frac{\mathbb{P}(B | A) \cdot \mathbb{P}(A)}{\mathbb{P}(B)}.$$

Demostración: Por definición de probabilidad condicionada tenemos que

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \quad \wedge \quad \mathbb{P}(B | A) = \frac{\mathbb{P}(B \cap A)}{\mathbb{P}(A)}.$$

Luego despejando $\mathbb{P}(A \cap B) = \mathbb{P}(B | A) \cdot \mathbb{P}(A) = \mathbb{P}(A | B) \cdot \mathbb{P}(B)$

$$\implies \mathbb{P}(A | B) = \frac{\mathbb{P}(B | A) \cdot \mathbb{P}(A)}{\mathbb{P}(B)}.$$

1.4 Independencia

1.4.1 Definiciones y resultados básicos

1.4.1.1 Independencia de un par de sucesos, σ -álgebras o variables aleatorias

Definición 1.4.1 (Sucesos independientes). Sean $A, B \in \Sigma$ dos sucesos en $(X, \Sigma, \mathbb{P})$,

$$A \text{ y } B \text{ son independientes} \iff \mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B).$$

Definición 1.4.2 (Variables independientes). Sean X e Y dos variables aleatorias en un espacio de probabilidad $(\Omega, \Sigma, \mathbb{P})$, X e Y son independientes

$$\iff \forall E_1, E_2 \in \mathcal{B}(\mathbb{R}) : \{X \in E_1\} \text{ y } \{Y \in E_2\} \text{ son independientes.}$$

Definición 1.4.3 (σ -álgebras independientes). Sea $(X, \Sigma, \mathbb{P})$ un espacio de probabilidad y $\mathcal{A}, \mathcal{B} \subset \Sigma$ dos σ -álgebras, $\mathcal{A}$ y $\mathcal{B}$ son independientes

$$\iff \forall A \in \mathcal{A}, B \in \mathcal{B} : A \text{ y } B \text{ son independientes.}$$

Lema 1.4.1. Sean X e Y dos variables aleatorias independientes en $(\Omega, \Sigma, \mathbb{P})$

$$\iff \sigma(X) \text{ y } \sigma(Y) \text{ son } \sigma\text{-álgebras independientes.}$$

Demostración: Sean $A_1 \in \sigma(X) \iff \exists E_1 \in \mathcal{B}(\mathbb{R}) : A_1 = X^{-1}(E)$. Análogamente, sea $A_2 \in \sigma(Y) \iff \exists E_2 \in \mathcal{B}(\mathbb{R}) : A_2 = Y^{-1}(E)$. Tomamos dichos E_1 y E_2 , entonces

$$\mathbb{P}(A_1 \cap A_2) = \mathbb{P}(\{X \in E_1\} \cap \{Y \in E_2\}) = \mathbb{P}(X \in E_1) \cdot \mathbb{P}(Y \in E_2) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2)$$

$\uparrow$
indep

Como A_1 y A_2 eran arbitrarios, $\sigma(X)$ y $\sigma(Y)$ son independientes. ■

Lema 1.4.2. Sean $\mathcal{F}_1, \mathcal{F}_2 \subset \Sigma$ dos σ -álgebras independientes en $(\Omega, \Sigma, \mathbb{P})$ y $X_1: \mathcal{F}_1 \rightarrow \mathbb{R}$, $X_2: \mathcal{F}_2 \rightarrow \mathbb{R}$ dos variables aleatorias $\implies X_1$ y X_2 son independientes.

Demostración: Tenemos que $\forall i = 1, 2 : \forall E_i \in \mathcal{B}(\mathbb{R}) : \{X_i \in E_i\} \in \mathcal{F}_i$ y, como $\mathcal{F}_1$ y $\mathcal{F}_2$ son independientes, $\forall A_1 \in \mathcal{F}_1, A_2 \in \mathcal{F}_2 : \mathbb{P}(A_1 \cap A_2) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2)$.

$$\implies \mathbb{P}(A_1 \cap A_2) = \mathbb{P}(\{X \in E_1\} \cap \{X \in E_2\}) = \mathbb{P}(X \in E_1) \cdot \mathbb{P}(Y \in E_2) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2)$$

donde $A_i = \{X_i \in E_i\}$. Como A_1 y A_2 eran arbitrarios, X_1 y X_2 son independientes. ■

1.4.1.2 Independencia de una familia de objetos

Definición 1.4.4 (Sucesos independientes). Sean $A_1, \dots, A_n \in \Sigma$ sucesos en $(X, \Sigma, \mathbb{P})$,

$$A_1, \dots, A_n \text{ son independientes} \iff \forall J \subset \{1, \dots, n\} : \mathbb{P} \left(\bigcap_{j \in J} A_j \right) = \prod_{j \in J} \mathbb{P}(A_j).$$

Definición 1.4.5 (σ -álgebras independientes). Sea $(X, \Sigma, \mathbb{P})$ un espacio de probabilidad, las σ -álgebras $\Sigma_1, \dots, \Sigma_n \subset \Sigma$ son independientes

$$\begin{aligned} &\iff \forall A_1 \in \Sigma_1, \dots, A_n \in \Sigma_n : \mathbb{P} \left(\bigcap_{i=1}^n A_i \right) = \prod_{i=1}^n \mathbb{P}(A_i) \\ &\iff \forall A_1 \in \Sigma_1, \dots, A_n \in \Sigma_n : A_1, \dots, A_n \text{ son independientes.} \end{aligned}$$

Definición 1.4.6 (Variables independientes). Sean $X_1, \dots, X_n$ v.a. en $(\Omega, \Sigma, \mathbb{P})$,

$$X_1, \dots, X_n \text{ son independientes} \iff \sigma(X_1), \dots, \sigma(X_n) \text{ son independientes.}$$

Definición 1.4.7. Una familia de objetos (σ -álgebras, variables aleatorias, sucesos) es independiente $\iff$ cada subfamilia finita lo es.

Definición 1.4.8. Una familia de objetos (σ -álgebras, variables aleatorias, sucesos) es independiente 2 a 2 $\iff$ cada subfamilia de 2 elementos lo es.

Observación 1.4.9. La independencia implica la independencia 2 a 2, pero el recíproco no es cierto en general.

1.4.2 Criterios de independencia

Definición 1.4.10 (π -sistema). Sea $P \subset \mathcal{P}(\Omega)$, es un π -sistema de $X \neq \emptyset \iff$

- (i) $P \neq \emptyset$.
- (ii) Cerrado bajo intersección: $\forall A, B \in P : A \cap B \in P$.

Definición 1.4.11 (π -sistemas independientes). Sea $(\Omega, \Sigma, \mathbb{P})$ un esp de probabilidad, los π -sistemas $S_1, \dots, S_n \subset \Sigma$ son independientes

$$\iff \forall A_1 \in S_1, \dots, A_n \in S_n : \forall J \subset \mathbb{N}_n : \{A_j\}_{j \in J} \text{ son independientes.}$$

Definición 1.4.12 (λ -sistema). Sea $L \subset \mathcal{P}(\Omega)$, es un λ -sistema $\iff$

- (i) $\Omega \in L$.
- (ii) Cerrado bajo diferencia de conjuntos anidados: $A, B \in L \wedge A \subset B \implies B \setminus A \in L$.
- (iii) $\forall \{A_j\}_{j=1}^{\infty} \subset L$ creciente: $\bigcup_{j=1}^{\infty} A_j \in L$.

Teorema 1.4.3 (π - λ). Sean P π -sistema y L λ -sistema de Ω con $P \subset L \implies \sigma(P) \subset L$.

Demostración: En Durrett, 2019 apéndice 1. ■

Proposición 1.4.4. Sean $S_1, \dots, S_n$ π -sistemas independientes en $(X, \Sigma, \mathbb{P})$
 $\implies \sigma(S_1), \dots, \sigma(S_n)$ son independientes.

Demostración: Fijamos $A_2 \in S_2, \dots, A_n \in S_n$ y definimos

$$F := \bigcap_{j=2}^n A_j \quad \wedge \quad L_F := \{A \in \Sigma : \mathbb{P}(A \cap F) = \mathbb{P}(A) \cdot \mathbb{P}(F)\}.$$

Veamos que (a) $S_1 \subset L_F$ y (b) L_F es un λ -sistema:

(a) Sea $A_1 \in S_1$, entonces

$$\mathbb{P}(A_1 \cap F) = \mathbb{P}\left(\bigcap_{j=1}^n A_j\right) \stackrel{\text{indep}}{=} \prod_{j \in \mathbb{N}_n} \mathbb{P}(A_j) \stackrel{\text{indep}}{=} \mathbb{P}(A_1) \cdot \mathbb{P}\left(\bigcap_{j=2}^n A_j\right) = \mathbb{P}(A_1) \cdot \mathbb{P}(F).$$

Luego $A_1 \in L$ y, por tanto, $S_1 \subset L$.

(b) Comprobamos las propiedades de la definición de λ -sistema:

(i) $\mathbb{P}(\Omega \cap F) = \mathbb{P}(F) = 1 \cdot \mathbb{P}(F) = \mathbb{P}(\Omega) \cdot \mathbb{P}(F) \implies \Omega \in L$.

(ii) Sean $A, B \in L_F$ tales que $A \subset B$, entonces

$$\begin{aligned} \mathbb{P}([B \setminus A] \cap F) &= \mathbb{P}([B \cap F] \setminus [A \cap F]) \stackrel{A \subset B}{=} \mathbb{P}(B \cap F) - \mathbb{P}(A \cap F) \\ &\stackrel{A, B \in L}{=} \mathbb{P}(B) \cdot \mathbb{P}(F) - \mathbb{P}(A) \cdot \mathbb{P}(F) = \mathbb{P}(B \setminus A) \cdot \mathbb{P}(F) \implies B \setminus A \in L. \end{aligned}$$

(iii) Sea $\{A_j\}_{j=1}^{\infty} \subset L_F$ tal que $A_1 \subset A_2 \subset \dots$, entonces

$$\begin{aligned} \mathbb{P} \left(\left[\bigcup_{j \in \mathbb{N}} A_j \right] \cap F \right) &= \mathbb{P} \left(\bigcup_{j \in \mathbb{N}} (A_j \cap F) \right) \stackrel{\text{TCM}}{\underset{\downarrow}{=}} \lim_{j \rightarrow \infty} \mathbb{P}(A_j \cap F) = \lim_{j \rightarrow \infty} \mathbb{P}(A_j) \cdot \mathbb{P}(F) \\ &= \mathbb{P} \left(\bigcup_{j \in \mathbb{N}} A_j \right) \cdot \mathbb{P}(F) \implies \bigcup_{j \in \mathbb{N}} A_j \in L. \end{aligned}$$

Entonces, por el teorema π - λ , $\sigma(S_1) \subset L_F$. Es decir, $\forall E_1 \in S_1 : \mathbb{P}(E_1 \cap F) = \mathbb{P}(E_1) \cdot \mathbb{P}(F)$.

Por simetría del argumento, podemos repetir este razonamiento para $S_2, \dots, S_n$ y así sucesivamente n veces en total, obteniendo que

$$\forall E_1 \in S_1, \dots, E_n \in S_n : \mathbb{P} \left(\bigcap_{i=1}^n E_i \right) = \mathbb{P}(E_1) \cdot \dots \cdot \mathbb{P}(E_n).$$

Por tanto, $\sigma(S_1), \dots, \sigma(S_n)$ son independientes. ■

Corolario 1.4.5. Sean $X_1, \dots, X_n$ variables aleatorias, son independientes

$$\iff \forall t_1, \dots, t_n \in \mathbb{R} : \mathbb{P}(\{X_1 \leq t_1\} \cap \dots \cap \{X_n \leq t_n\}) = \prod_{i=1}^n \mathbb{P}(X_i \leq t_i)$$

Demostración: La implicación $\Rightarrow$ es trivial por definición. Veamos la otra dirección:

$\Leftarrow$ Definimos $S_j = \{\{X_j \in (-\infty, t]\} : t \in \mathbb{R}\}$, entonces

$$\forall j \in \mathbb{N}_n : S_j \text{ es un } \pi\text{-sistema} \quad \wedge \quad S_1, \dots, S_n \text{ son independientes.}$$

Por la Proposición 1.4.4, $\sigma(S_1), \dots, \sigma(S_n)$ son independientes. Por otro lado, $\forall j \in \mathbb{N}_n : \sigma(S_j) = \sigma(X_j)$. Esto, por definición, implica que $X_1, \dots, X_n$ son independientes. ■

2. Esperanza matemática

2.1 Definiciones y propiedades básicas

2.1.1 Esperanza

Definición 2.1.1 (Esperanza). Sea $X \in \mathcal{L}^1(\mathbb{P})$ una variable aleatoria,

$$\mathbb{E}[X] \text{ es la esperanza de } X \iff \mathbb{E}[X] = \int_{\Omega} X(\omega) \, d\mathbb{P}(\omega).$$

Proposición 2.1.1. Sea $g: \mathbb{R} \rightarrow \mathbb{R} \in \mathcal{L}^1(\mu_X)$ y $X: \Omega \rightarrow \mathbb{R}$ una variable aleatoria

$$\implies \mathbb{E}[g(X)] = \int_{\mathbb{R}} g(t) \, d\mu_X(t).$$

Demostración: Dividiremos la demostración en pasos:

(1) Consideramos primero $g = \mathbb{1}_A$, con $A \in \mathcal{B}(\mathbb{R})$, entonces $g(X) = \mathbb{1}_A(X)$

$$\begin{aligned} \implies \mathbb{E}[g(X)] &= \int_{\Omega} \mathbb{1}_A(X(\omega)) \, d\mathbb{P}(\omega) = \int_{\Omega} \mathbb{1}_{\{X(\omega) \in A\}} \, d\mathbb{P}(\omega) \\ &= \mathbb{P}(X \in A) = \mu_X(A) = \int_{\mathbb{R}} \mathbb{1}_A(t) \, d\mu_X(t) = \int_{\mathbb{R}} g(t) \, d\mu_X(t). \end{aligned}$$

(2) Por tanto, si $g = \sum_j \alpha_j \mathbb{1}_{E_j}$ es simple, entonces por linealidad de la integral:

$$\begin{aligned} \mathbb{E}[g(X)] &= \int_{\Omega} g(X(\omega)) \, d\mathbb{P}(\omega) = \int_{\Omega} \left(\sum_{j=1}^n \alpha_j \mathbb{1}_{E_j}(X(\omega)) \right) \, d\mathbb{P}(\omega) = \sum_{j=1}^n \alpha_j \int_{\Omega} \mathbb{1}_{E_j}(X(\omega)) \, d\mathbb{P}(\omega) \\ &\stackrel{(1)}{=} \sum_{j=1}^n \alpha_j \int_{\mathbb{R}} \mathbb{1}_{E_j}(t) \, d\mu_X(t) = \int_{\mathbb{R}} \left(\sum_{j=1}^n \alpha_j \mathbb{1}_{E_j}(t) \right) \, d\mu_X(t) = \int_{\mathbb{R}} g(t) \, d\mu_X(t). \end{aligned}$$

(3) Entonces, si g es medible no negativa, por un lema técnico, $\exists (s_n)_{n \in \mathbb{N}}$ una sucesión no decreciente de funciones simples tales que $\forall t \in \mathbb{R} : \lim s_n(t) = g(t)$, entonces por convergencia monótona:

$$\begin{aligned} \mathbb{E}[g(X)] &= \int_{\Omega} g(X(\omega)) \, d\mathbb{P}(\omega) = \int_{\Omega} \lim_{n \rightarrow \infty} s_n(X(\omega)) \, d\mathbb{P}(\omega) \\ &\stackrel{\text{TCM}}{=} \lim_{n \rightarrow \infty} \int_{\Omega} s_n(X(\omega)) \, d\mathbb{P}(\omega) \stackrel{(2)}{=} \lim_{n \rightarrow \infty} \int_{\mathbb{R}} s_n(t) \, d\mu_X(t) \stackrel{\text{TCM}}{=} \int_{\mathbb{R}} g(t) \, d\mu_X(t). \end{aligned}$$

(4) Finalmente, si g es medible arbitraria, entonces $g = g^+ - g^-$, con g^+, g^- medibles no

negativas, y por linealidad de la integral:

$$\int_{\mathbb{R}} g(t) d\mu_X(t) = \int_{\mathbb{R}} g^+(t) d\mu_X(t) - \int_{\mathbb{R}} g^-(t) d\mu_X(t) \stackrel{(3)}{=} \mathbb{E}[g^+(X)] - \mathbb{E}[g^-(X)] = \mathbb{E}[g(X)].$$

■

Observación 2.1.2. De la Proposición 2.1.1 se deduce que la esperanza es lineal, ya que hereda esta propiedad de la integral (??).

Corolario 2.1.2. Sea $X \in \mathcal{L}^1(\mathbb{P})$ una variable aleatoria $\implies \mathbb{E}[X] = \int_{\mathbb{R}} t d\mu_X(t)$.

Demostración: Tomamos $g(t) = t$ en la Proposición 2.1.1.

■

Proposición 2.1.3. Sean $X, Y \in \mathcal{L}^1(\mathbb{P})$ independientes $\implies \mathbb{E}[X \cdot Y] = \mathbb{E}[X] \cdot \mathbb{E}[Y]$.

Demostración: Se deja como ejercicio.

■

2.1.2 Varianza

Definición 2.1.3 (Varianza). Sea $X: \Omega \longrightarrow \mathbb{R}$ una variable aleatoria con $X \in \mathcal{L}^1(\mathbb{P})$,

$$\mathbb{V}(X) \text{ es la varianza de } X \iff \mathbb{V}(X) = \mathbb{E}[|X - \mathbb{E}[X]|^2].$$

Observación 2.1.4. La varianza es siempre no negativa. **(Motivo de excomuni3n)**

Proposici3n 2.1.4 (F3rmula de la varianza). Sea $X: \Omega \longrightarrow \mathbb{R} \in \mathcal{L}^1(\mathbb{P})$ v.a.

$$\implies \mathbb{V}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2.$$

Demostraci3n: Sea $X \in \mathcal{L}^1(\mathbb{P})$ una variable aleatoria, entonces

$$\begin{aligned} \mathbb{V}(X) &= \mathbb{E}[|X - \mathbb{E}[X]|^2] = \mathbb{E}[X^2 - 2X\mathbb{E}[X] + (\mathbb{E}[X])^2] \\ &\stackrel{\text{lineal}}{=} \mathbb{E}[X^2] - 2(\mathbb{E}[X])^2 + (\mathbb{E}[X])^2 = \mathbb{E}[X^2] - (\mathbb{E}[X])^2. \end{aligned}$$

■

Definici3n 2.1.5 (Momento). Sea $X: \Omega \longrightarrow \mathbb{R}$ v.a., $\mathbb{E}[|X|^p]$ es su momento de orden p .

Proposici3n 2.1.5. Sean $(X_j)_{j=1}^n \subset \mathcal{L}^2(\mathbb{P})$ variables aleatorias independientes

$$\implies \mathbb{V}\left(\sum_{j=1}^n X_j\right) = \sum_{j=1}^n \mathbb{V}(X_j).$$

Demostración: Usamos la fórmula para la varianza:

$$\mathbb{V} \left(\sum_{j=1}^n X_j \right) = \mathbb{E} \left[\left(\sum_{j=1}^n X_j \right)^2 \right] - \mathbb{E} \left[\sum_{j=1}^n X_j \right]^2 \stackrel{\uparrow \text{lineal}}{=} \mathbb{E} \left[\sum_{i,j=1}^n X_i \cdot X_j \right] - \left(\sum_{j=1}^n \mathbb{E} [X_j] \right)^2$$

Ahora bien, como $\forall i \neq j : X_i$ y X_j son independientes, por la Proposición 2.1.3, tenemos que $\mathbb{E} [X_i \cdot X_j] = \mathbb{E} [X_i] \cdot \mathbb{E} [X_j]$. Luego para el primer término tenemos:

$$\mathbb{E} \left[\sum_{i,j=1}^n X_i \cdot X_j \right] \stackrel{\downarrow \text{lineal}}{=} \sum_{j=1}^n \mathbb{E} [X_j^2] - \sum_{\substack{i,j=1 \\ i \neq j}}^n \mathbb{E} [X_i \cdot X_j] = \sum_{j=1}^n \mathbb{E} [X_j^2] - \sum_{\substack{i,j=1 \\ i \neq j}}^n \mathbb{E} [X_i] \cdot \mathbb{E} [X_j].$$

Por otro lado, para el segundo término, tenemos que

$$\left(\sum_{j=1}^n \mathbb{E} [X_j] \right)^2 = \sum_{i,j=1}^n \mathbb{E} [X_i] \cdot \mathbb{E} [X_j].$$

Por tanto, al restar el segundo término al primero, obtenemos:

$$\mathbb{V} \left(\sum_{j=1}^n X_j \right) = \sum_{j=1}^n \mathbb{E} [X_j^2] - \sum_{j=1}^n \mathbb{E} [X_j]^2 = \sum_{j=1}^n \mathbb{E} [X_j^2] - \mathbb{E} [X_j]^2.$$

Usando de nuevo la fórmula para la varianza, concluimos que $\mathbb{V} \left(\sum_j X_j \right) = \sum_j \mathbb{V} (X_j)$. ■

2.2 Desigualdades básicas

Definición 2.2.1 (Norma p -ésima). Sea $X : \Omega \longrightarrow \mathbb{R}$ una variable aleatoria y $p \in [1, \infty)$,

$$\|X\|_p \text{ es la norma } p\text{-ésima de } X \iff \|X\|_p = (\mathbb{E} [|X|^p])^{1/p}.$$

Definición 2.2.2 (Espacio $\mathcal{L}^p$). Sea (X, Σ, μ) un espacio de medida y $p \in [1, \infty]$, definimos

$$\mathcal{L}^p(\mu) := \left\{ f : X \longrightarrow \mathbb{R} : f \text{ es medible } \wedge \|f\|_p < \infty \right\}.$$

Definición 2.2.3 (Función convexa). Sea $\varphi : \mathbb{R} \longrightarrow \mathbb{R}$ una función, ϕ es convexa

$$\iff \forall a, b \in \mathbb{R}, \lambda \in [0, 1] : \varphi((1 - \lambda)a + \lambda b) \leq (1 - \lambda)\varphi(a) + \lambda\varphi(b).$$

Proposición 2.2.1. Sea $\varphi : \mathbb{R} \longrightarrow \mathbb{R}$ una función, entonces

$$(1) \quad \varphi \in \mathcal{C}^1(\mathbb{R}) \implies \varphi \text{ es convexa} \iff \varphi' \text{ es creciente}.$$

(2) $\varphi \in \mathcal{C}^2(\mathbb{R}) \implies \varphi \text{ es convexa} \iff \varphi'' \geq 0$.

Proposición 2.2.2 (Desigualdad de Jensen). Sea $\varphi: \mathbb{R} \longrightarrow \mathbb{R}$ una función convexa y X v.a. tales que $X, \varphi(X) \in \mathcal{L}^1(\mathbb{P}) \implies \varphi(\mathbb{E}[X]) \leq \mathbb{E}[\varphi(X)]$.

Demostración: Vamos a asumir que $\varphi \in \mathcal{C}^1$. Sea A la recta tangente a φ en $t_0 = \mathbb{E}[X]$. Como φ es convexa, $\forall t \in \mathbb{R} : A(t) \leq \varphi(t)$. Entonces,

$$\begin{aligned} \mathbb{E}[\varphi(X)] &= \int_{\Omega} \varphi(X(\omega)) \, d\mathbb{P}(\omega) \geq \int_{\Omega} A(X(\omega)) \, d\mathbb{P}(\omega) = \mathbb{E}[A(X)] \\ &= \mathbb{E}[aX + b] = a \mathbb{E}[X] + b = A(\mathbb{E}[X]) = A(t_0) = \varphi(t_0) = \varphi(\mathbb{E}[X]). \end{aligned}$$

Luego $\mathbb{E}[\varphi(X)] \geq \varphi(\mathbb{E}[X])$. ■

Corolario 2.2.3. Sean $q, p \in [1, \infty)$ con $p \leq q$ y $X \in \mathcal{L}^p(\mathbb{P})$

$$\implies X \in \mathcal{L}^q(\mathbb{P}) \wedge \|X\|_p \leq \|X\|_q.$$

Demostración: El caso $p = q$ es trivial. Supongamos $p < q$ y definimos

$$\varphi(t) := \begin{cases} t^{q/p} & \text{si } t \geq 0 \\ 0 & \text{si } t < 0 \end{cases} \xrightarrow{q > p} \varphi \text{ es } \mathcal{C}^1 \text{ y convexa.}$$

Entonces, por la desigualdad de Jensen, tenemos que

$$\varphi(\mathbb{E}[|X|^p]) \leq \mathbb{E}[\varphi(|X|^p)] = \mathbb{E}[|X|^q] = \|X\|_q^q$$

Ahora bien, como $\varphi(\mathbb{E}[|X|^p]) = (\mathbb{E}[|X|^p])^{q/p} = \|X\|_p^q$, se tiene que $\|X\|_p \leq \|X\|_q$. ■

Definición 2.2.4 (Exponente conjugado). Sea $p \in (1, \infty)$, $p' \in \mathbb{R}$ es el exponente conjugado de $p \iff 1/p + 1/p' = 1$.

Se dice que $p = 1$ y $p' = \infty$ son conjugados el uno del otro.

Teorema 2.2.4 (Desigualdad de Young). Sean $a, b > 0$ y $p \in (1, \infty) \implies ab \leq \frac{a^p}{p} + \frac{b^{p'}}{p'}$ donde p' es el exponente conjugado de p .

Demostración: Es una consecuencia directa de la concavidad del logaritmo. ■

Teorema 2.2.5 (Desigualdad de Hölder). Sea $p \in (1, \infty)$ y $X \in \mathcal{L}^p(\mathbb{P}), Y \in \mathcal{L}^{p'}(\mathbb{P})$

$$\implies \mathbb{E}[|X \cdot Y|] \leq \|X\|_p \cdot \|Y\|_{p'}$$

donde p' es el exponente conjugado de p .

Demostración: Suponemos que $\|Y\|_{p'} \neq 0$ (si no, la desigualdad es trivial).

Definimos una función $h: \Omega \rightarrow \mathbb{R}$ y una medida ν en Ω dadas por

$$h(\omega) := \frac{|X(\omega)|}{|Y(\omega)|^{p'-1}} \mathbb{1}_{\{Y \neq 0\}}(\omega) \quad \wedge \quad d\nu = \frac{|Y(\omega)|^{p'}}{\|Y\|_{p'}^{p'}} \mathbb{1}_{\{Y \neq 0\}}(\omega) d\mathbb{P}(\omega)$$

donde ν es una medida porque $\frac{|Y(\omega)|^{p'}}{\|Y\|_{p'}^{p'}} \in \mathcal{L}^1(\mathbb{P})$ por hipótesis.

Además $\nu(\Omega) = \int_{\Omega} \frac{|Y(\omega)|^{p'}}{\|Y\|_{p'}^{p'}} d\mathbb{P} = \frac{\|Y\|_{p'}^{p'}}{\|Y\|_{p'}^{p'}} = 1$, luego ν es de probabilidad.

$$\begin{aligned} \Rightarrow \mathbb{E}[|X \cdot Y|] &= \int_{\Omega} |X(\omega) \cdot Y(\omega)| d\mathbb{P}(\omega) \\ &= \|Y\|_{p'}^{p'} \int_{\Omega} \frac{|X(\omega)|}{|Y(\omega)|^{p'-1}} \frac{|Y(\omega)|^{p'}}{\|Y\|_{p'}^{p'}} d\mathbb{P}(\omega) = \|Y\|_{p'}^{p'} \left[\int_{\Omega} h(\omega) d\nu(\omega) \right]^{p/p}. \end{aligned}$$

Como $p > 1$, $\varphi(t) = |t|^p$ es convexa y por la desigualdad de Jensen se tiene que

$$\begin{aligned} \mathbb{E}[|X \cdot Y|] &= \|Y\|_{p'}^{p'} \left[\varphi \left(\int_{\Omega} h(\omega) d\nu(\omega) \right) \right]^{1/p} \underset{\substack{\uparrow \\ \text{j Jensen}}}{\leq} \|Y\|_{p'}^{p'} \left[\int_{\Omega} h(\omega)^p d\nu(\omega) \right]^{1/p} = \\ &\leq \|Y\|_{p'}^{p'} \left[\int_{\Omega} \frac{|X(\omega)|^p}{|Y(\omega)|^{p(p'-1)}} \cdot \frac{|Y(\omega)|^{p'}}{\|Y\|_{p'}^{p'}} d\mathbb{P}(\omega) \right]^{1/p} = \|X\|_p \|Y\|_{p'}. \end{aligned}$$

■

Demostración (Alternativa): Si $\|X\|_p = 0$ o $\|Y\|_{p'} = 0$, la desigualdad es trivial, por tanto, suponemos que $\|X\|_p \neq 0$ y $\|Y\|_{p'} \neq 0$ y definimos $\hat{X} := X/\|X\|_p$ y $\hat{Y} := Y/\|Y\|_{p'}$.

$$\Rightarrow \mathbb{E}[|X \cdot Y|] = \int_{\Omega} |X(\omega) \cdot Y(\omega)| d\mathbb{P}(\omega) = \|X\|_p \cdot \|Y\|_{p'} \int_{\Omega} |\hat{X}(\omega) \cdot \hat{Y}(\omega)| d\mathbb{P}(\omega).$$

Por la desigualdad de Young, $\forall \omega \in \Omega : \left| \hat{X}(\omega) \cdot \hat{Y}(\omega) \right| \leq \frac{|\hat{X}(\omega)|^p}{p} + \frac{|\hat{Y}(\omega)|^{p'}}{p'}$.

$$\begin{aligned} \Rightarrow \mathbb{E}[|X \cdot Y|] &\leq \|X\|_p \cdot \|Y\|_{p'} \left(\frac{1}{p} \int_{\Omega} |\hat{X}(\omega)|^p d\mathbb{P}(\omega) + \frac{1}{p'} \int_{\Omega} |\hat{Y}(\omega)|^{p'} d\mathbb{P}(\omega) \right) = \\ &\leq \|X\|_p \cdot \|Y\|_{p'} \left(\frac{1}{p} + \frac{1}{p'} \right) = \|X\|_p \cdot \|Y\|_{p'}. \end{aligned}$$

■

Definición 2.2.5 (Norma $\mathcal{L}^p$). Sea (X, Σ, μ) un espacio de medida, $p \in [1, \infty]$ y $f: X \rightarrow$

$\mathbb{R}$ medible, $\|f\|_p$ es la norma $\mathcal{L}^p$ de f

$$\Longleftrightarrow \begin{cases} \|f\|_p = \left(\int_X |f|^p d\mu \right)^{1/p} & \text{si } p \in [1, \infty) \\ \|f\|_\infty = \text{ess sup } |f| = \inf_{\substack{A \in \Sigma \\ \mu(A)=0}} \left\{ \sup_{x \in A^c} |f(x)| \right\} & \text{si } p = \infty. \end{cases}$$

Proposición 2.2.6 (Desigualdad de Minkowski). Sea $1 \leq p \leq \infty$ y $X, Y \in \mathcal{L}^p(\mathbb{P})$

$$\implies \|X + Y\|_p \leq \|X\|_p + \|Y\|_p.$$

Demostración: Dividimos la demostración en tres casos excluyentes:

I. Si $p = 1$, entonces podemos aplicar directamente la desigualdad triangular de $|\cdot|$:

$$\begin{aligned} \|X + Y\|_1 &= \int_{\Omega} |X(\omega) + Y(\omega)| d\mathbb{P}(\omega) \stackrel{\Delta}{\leq} \int_{\Omega} [|X| + |Y|] d\mathbb{P}(\omega) \\ &\stackrel{\text{lineal}}{=} \int_{\Omega} |X| d\mathbb{P}(\omega) + \int_{\Omega} |Y| d\mathbb{P}(\omega) = \|X\|_1 + \|Y\|_1. \end{aligned}$$

II. Si $1 < p < \infty$, entonces

$$\begin{aligned} |X(\omega) + Y(\omega)|^p &= |X(\omega) + Y(\omega)| |X(\omega) + Y(\omega)|^{p-1} \\ &= |X(\omega)| |X(\omega) + Y(\omega)|^{p-1} + |Y(\omega)| |X(\omega) + Y(\omega)|^{p-1}. \end{aligned} \tag{2.1}$$

Integrando el primer sumando del lado derecho, obtenemos

$$\begin{aligned} \int_{\Omega} |X(\omega)| |X(\omega) + Y(\omega)|^{p-1} d\mathbb{P}(\omega) &\stackrel{\text{Hölder}}{\leq} \|X\|_p \| |X + Y|^{p-1} \|_{p'} = \\ &\leq \|X\|_p \left[\int_{\Omega} |X + Y|^{(p-1)p'} dP \right]^{1/p'} = \\ &\leq \|X\|_p \left[\int_{\Omega} |X + Y|^p dP \right]^{\frac{1}{p} \cdot \frac{p}{p'}} = \|X\|_p \left(\|X + Y\|_p \right)^{p/p'}. \end{aligned} \tag{2.2}$$

Entonces, como consecuencia de (2.1) y (2.2), deducimos que

$$\begin{aligned} \|X + Y\|_p^p &\stackrel{(2.1)}{\leq} \int_{\Omega} |X(\omega)| |X(\omega) + Y(\omega)|^{p-1} d\mathbb{P}(\omega) + \int_{\Omega} |Y(\omega)| |X(\omega) + Y(\omega)|^{p-1} d\mathbb{P}(\omega) \\ &\stackrel{(2.2)}{\leq} \|X\|_p \|X + Y\|_p^{p/p'} + \|Y\|_p \|X + Y\|_p^{p/p'} = \|X + Y\|_p^{p/p'} \left[\|X\|_p + \|Y\|_p \right]. \\ \Longleftrightarrow \|X + Y\|_p^{p-p/p'} &= \|X + Y\|_p \leq \|X\|_p + \|Y\|_p. \end{aligned}$$

III. Si $p = \infty$, entonces tomamos

$$A_1 \subset \Omega : \|X\|_\infty = \sup_{\omega \in A_1^c} |X(\omega)| \quad \text{y} \quad A_2 \subset \Omega : \|Y\|_\infty = \sup_{\omega \in A_2^c} |Y(\omega)|.$$

Definimos $A := A_1 \cup A_2$, entonces

$$\begin{aligned} \|X\|_\infty + \|Y\|_\infty &= \sup_{\omega \in A_1^c} |X(\omega)| + \sup_{\omega \in A_2^c} |Y(\omega)| \geq \sup_{\omega \in A^c} |X(\omega)| + \sup_{\omega \in A^c} |Y(\omega)| \\ &\geq \sup_{\omega \in A^c} [|X(\omega)| + |Y(\omega)|] \geq \sup_{\omega \in A^c} |X(\omega) + Y(\omega)| \\ &\geq \inf_{\substack{B \in \Sigma \\ \mathbb{P}(B)=0}} \sup_{\omega \in B^c} |X(\omega) + Y(\omega)| = \|X + Y\|_\infty. \end{aligned}$$

Como se ha demostrado en los tres casos, se tiene que $\|X + Y\|_p \leq \|X\|_p + \|Y\|_p$. ■

Proposición 2.2.7 (Desigualdad de Hölder generalizada). Sea $p \in [1, \infty]$ y $X \in \mathcal{L}^p(\mathbb{P})$, $Y \in \mathcal{L}^{p'}(\mathbb{P}) \implies \mathbb{E}[|X \cdot Y|] \leq \|X\|_p \cdot \|Y\|_{p'}$ con p' el exponente conjugado de p .

Demostración: Se deja como ejercicio. ■

Observación 2.2.6. Sea $X \in \mathcal{L}^\infty$ y $1 \leq p \leq \infty$, entonces

$$\begin{aligned} \|X\|_p^p &= \int_{\Omega} |X(\omega)|^p d\mathbb{P}(\omega) = \int_{\{\omega: |X(\omega)| > \|X\|_\infty\}} |X(\omega)|^p d\mathbb{P}(\omega) + \int_{\{\omega: |X(\omega)| \leq \|X\|_\infty\}} |X(\omega)|^p d\mathbb{P}(\omega) \\ &\leq \|X\|_\infty^p \int_{\{\omega: |X(\omega)| \leq \|X\|_\infty\}} d\mathbb{P}(\omega) \leq \|X\|_\infty^p \mathbb{P}(\Omega) = \|X\|_\infty^p \implies \|X\|_p \leq \|X\|_\infty. \end{aligned}$$

2.2.1 Desigualdades de Chebyshev y Markov

Proposición 2.2.8 (Desigualdad de Chebyshev). Sea X una v.a. y $\varphi: \mathbb{R} \rightarrow \mathbb{R}$ medible y no negativa, definimos $\forall A \in \mathcal{B}(\mathbb{R}) : i_A := \inf_{t \in A} \varphi(t)$

$$\implies i_A \cdot \mathbb{P}(X \in A) \leq \mathbb{E}[\mathbb{1}_{\{X \in A\}} \cdot \varphi(X)].$$

Demostración: Sea $A \in \mathcal{B}(\mathbb{R})$, entonces $\forall \omega \in \Omega : X(\omega) \in A : i_A \leq \varphi(X(\omega))$

$$\implies i_A \cdot \mathbb{1}_{\{X \in A\}}(\omega) \leq \mathbb{1}_{\{X \in A\}}(\omega) \cdot \varphi(X(\omega))$$

Integrando, obtenemos que $i_A \cdot \mathbb{P}(X \in A) \leq \mathbb{E}[i_A \cdot \mathbb{1}_{\{X \in A\}}] \leq \mathbb{E}[\mathbb{1}_{\{X \in A\}} \cdot \varphi(X)]$. ■

Corolario 2.2.9 (Desigualdad de Markov). Sea $X \in \mathcal{L}^1(\mathbb{P})$ una v.a. y $1 \leq p < \infty$

$$\implies \forall t > 0 : \mathbb{P}(|X| \geq t) \leq \frac{\|X\|_p^p}{t^p}.$$

Demostración: Tomamos $\varphi(t) = |t|^p$ y $A = \{|X| \geq t\}$, por la desigualdad de Chebyshev:

$$t^p \cdot \mathbb{P}(|X| \geq t) \leq \mathbb{E} [\mathbb{1}_{\{|X| \geq t\}} \cdot |X|^p] \leq \mathbb{E} [|X|^p] = \|X\|_p^p.$$

■

Corolario 2.2.10. Sea $X \in \mathcal{L}^2(\mathbb{P})$ una variable aleatoria

$$\implies \forall \varepsilon > 0 : \mathbb{P}(|X - \mathbb{E}[X]| > \varepsilon) \leq \frac{\mathbb{V}(X)}{\varepsilon^2}.$$

Demostración: Se deja como ejercicio.

■

2.3 Comportamiento a largo plazo

2.3.1 Definición de $\limsup$ y $\liminf$

Sea $(A_n) \subset \Sigma$ una sucesión de subconjuntos de Ω . En general, $\lim_{n \rightarrow \infty} A_n$ no se puede definir salvo en ciertos casos particulares, por ejemplo:

- I. Si $\forall n \in \mathbb{N} : A_n \subset A_{n+1}$, podemos definir $\lim_{n \rightarrow \infty} A_n := \bigcup_{n=1}^{\infty} A_n$.
- II. Si $\forall n \in \mathbb{N} : A_{n+1} \subset A_n$, podemos definir $\lim_{n \rightarrow \infty} A_n := \bigcap_{n=1}^{\infty} A_n$.

Sin embargo, estos casos son muy limitados, queremos ser capaces de tomar límites de más tipos de sucesiones de conjuntos. Además, son muy dependientes de cada conjunto en la sucesión, cosa que no ocurre con las sucesiones de números reales.

Por ello, vamos a buscar una definición a partir de $\limsup$ y $\liminf$.

Ejemplo 2.3.1. Sea la sucesión (A_n) dada por

$$A_n = \begin{cases} \{1, 2\} & \text{si } n \text{ es par} \\ \{2, 3\} & \text{si } n \text{ es impar,} \end{cases}$$

Entonces, (nos gustaría que) $\liminf_{n \rightarrow \infty} A_n = \{2\}$ porque 2 está en todos los conjuntos y $\limsup_{n \rightarrow \infty} A_n = \{1, 2, 3\}$ porque 1 y 3 están en infinitos conjuntos.

Esto motiva las siguientes definiciones:

Definición 2.3.1 (Límite superior). Sea $(A_n) \subset \mathcal{P}(\Omega)$ una sucesión de conjuntos, $\limsup A_n$

es el límite superior de (A_n)

$$\Longleftrightarrow \limsup_{n \rightarrow \infty} A_n = \bigcap_{n=1}^{\infty} \left(\bigcup_{k=n}^{\infty} A_k \right).$$

Es decir, $\limsup A_n$ es el conjunto cuyos elementos pertenecen a infinitos de los A_n .

Definición 2.3.2 (Límite inferior). Sea $(A_n) \subset \mathcal{P}(\Omega)$ una sucesión de conjuntos, $\liminf A_n$ es el límite inferior de (A_n)

$$\Longleftrightarrow \liminf_{n \rightarrow \infty} A_n = \bigcup_{n=1}^{\infty} \left(\bigcap_{k=n}^{\infty} A_k \right).$$

Es decir, $\limsup A_n$ es el conjunto cuyos elementos pertenecen a todos los A_n a partir de un cierto índice n .

2.3.1.1 Propiedades de $\limsup$ y $\liminf$

Ejercicio 2.3.2. Sea $(A_n)_{n \in \mathbb{N}}$ una sucesión de conjuntos, demuestra que

- | | |
|---|---|
| (a) $\liminf_{n \rightarrow \infty} A_n \subset \limsup_{n \rightarrow \infty} A_n.$ | (c) $\mathbb{1}_{\limsup A_n} = \limsup_{n \rightarrow \infty} \mathbb{1}_{A_n}.$ |
| (b) $\left(\liminf_{n \rightarrow \infty} A_n \right)^c = \limsup_{n \rightarrow \infty} A_n^c.$ | (d) $\mathbb{1}_{\liminf A_n} = \liminf_{n \rightarrow \infty} \mathbb{1}_{A_n}.$ |

Solución:

(a) Sea $\omega \in \liminf A_n$, entonces $\exists N \in \mathbb{N} : \forall n \geq N : \omega \in A_n$. Por tanto, $\omega \in A_n$ para infinitos n , es decir, $\omega \in \limsup A_n$. ■

(b) Sea $\omega \in (\liminf A_n)^c$, entonces $\forall n \in \mathbb{N} : \exists N \geq n : \omega \notin A_N$. Por tanto, $\omega \in A_n^c$ para infinitos n , es decir, $\omega \in \limsup A_n^c$. ■

(c) Sea $\omega \in \Omega$ fijo, entonces

$$\limsup_{n \rightarrow \infty} \mathbb{1}_{A_n}(\omega) = \limsup_{n \rightarrow \infty} a_n \quad \text{donde} \quad \forall n \in \mathbb{N} : a_n = \begin{cases} 1 & \text{si } \omega \in A_n \\ 0 & \text{si } \omega \notin A_n \end{cases}.$$

Luego $\limsup a_n = 1 \Longleftrightarrow \exists$ infinitos $n \in \mathbb{N} : a_n = 1 \left(\Longleftrightarrow \omega \in A_n \right).$

Por tanto, $\omega \in \limsup A_n \Longleftrightarrow \mathbb{1}_{\limsup A_n}(\omega) = 1$. ■

(d) Por el apartado (b), tenemos que $\mathbb{1}_{\liminf A_n} = \mathbb{1}_{(\limsup A_n^c)^c} = 1 - \mathbb{1}_{\limsup A_n^c}$. Ahora, por

el apartado (c), tenemos que $\mathbb{1}_{\limsup A_n^c} = \limsup_{n \rightarrow \infty} \mathbb{1}_{A_n^c}$, luego

$$\begin{aligned} \mathbb{1}_{\liminf A_n} &= 1 - \limsup_{n \rightarrow \infty} \mathbb{1}_{A_n^c} = 1 - \limsup_{n \rightarrow \infty} (1 - \mathbb{1}_{A_n}) \\ &= 1 + \liminf_{n \rightarrow \infty} \mathbb{1}_{A_n} - 1 = \liminf_{n \rightarrow \infty} \mathbb{1}_{A_n}. \end{aligned}$$

■

Lema 2.3.1 (de Fatou para probabilidades). Sean $(A_n)_{n \in \mathbb{N}} \subset \Sigma$ en $(\Omega, \Sigma, \mathbb{P})$

$$\implies (1) \mathbb{P} \left(\liminf_{n \rightarrow \infty} A_n \right) \leq \liminf_{n \rightarrow \infty} \mathbb{P}(A_n) \quad \wedge \quad (2) \mathbb{P} \left(\limsup_{n \rightarrow \infty} A_n \right) \geq \limsup_{n \rightarrow \infty} \mathbb{P}(A_n).$$

Demostración: Veamos ambas desigualdades por separado:

(1) Aplicamos el Lema de Fatou a $(\mathbb{1}_{A_n})_{n \in \mathbb{N}}$, que es una sucesión de funciones no negativas:

$$\begin{aligned} \mathbb{P} \left(\liminf_{n \rightarrow \infty} A_n \right) &= \int_{\Omega} \mathbb{1}_{\liminf_{n \rightarrow \infty} A_n} d\mathbb{P} \stackrel{2.3.2:(d)}{=} \int_{\Omega} \liminf_{n \rightarrow \infty} \mathbb{1}_{A_n} d\mathbb{P} \\ &\stackrel{\text{Fatou}}{\leq} \liminf_{n \rightarrow \infty} \int_{\Omega} \mathbb{1}_{A_n} d\mathbb{P} = \liminf_{n \rightarrow \infty} \mathbb{P}(A_n). \end{aligned}$$

(2) Primero, observamos que podemos escribir

$$\mathbb{P} \left(\limsup_{n \rightarrow \infty} A_n \right) \stackrel{2.3.2:(b)}{=} \mathbb{P} \left(\left(\liminf_{n \rightarrow \infty} A_n^c \right)^c \right) = 1 - \mathbb{P} \left(\liminf_{n \rightarrow \infty} A_n^c \right)$$

Ahora, por el apartado (1), $\mathbb{P} \left(\liminf_{n \rightarrow \infty} A_n^c \right) \leq \liminf_{n \rightarrow \infty} \mathbb{P}(A_n^c) = \liminf_{n \rightarrow \infty} (1 - \mathbb{P}(A_n))$.

$$\begin{aligned} \implies \mathbb{P} \left(\limsup_{n \rightarrow \infty} A_n \right) &= 1 - \mathbb{P} \left(\liminf_{n \rightarrow \infty} A_n^c \right) \geq 1 - \liminf_{n \rightarrow \infty} (1 - \mathbb{P}(A_n)) = \\ &\geq 1 + \limsup_{n \rightarrow \infty} (\mathbb{P}(A_n) - 1) = \limsup_{n \rightarrow \infty} \mathbb{P}(A_n). \end{aligned}$$

■

2.3.2 Lemas de Borel-Cantelli

Lema 2.3.2 (de Borel-Cantelli I). Sea $(A_n)_{n \in \mathbb{N}} \subset \Sigma$ en $(\Omega, \Sigma, \mathbb{P})$ tal que $\sum_n \mathbb{P}(A_n) < \infty$

$$\implies \mathbb{P} \left(\limsup_{n \rightarrow \infty} A_n \right) = 0.$$

Demostración: Definimos $N: \Omega \rightarrow \mathbb{R} \cup \{\infty\}$ dada por $N(\omega) = \sum_{n \in \mathbb{N}} \mathbb{1}_{A_n}(\omega)$, entonces

$$\limsup_{n \rightarrow \infty} A_n = \{\omega \in \Omega : N(\omega) = \infty\}.$$

Por tanto, $\mathbb{E}[N] \stackrel{\text{TCM}}{=} \sum_{n \in \mathbb{N}} \mathbb{E}[\mathbb{1}_{A_n}] = \sum_{n \in \mathbb{N}} \mathbb{P}(A_n) < \infty$.

$$\implies N \in \mathcal{L}^1(\mathbb{P}) \implies \mathbb{P}(\{\omega \in \Omega : N(\omega) = \infty\}) = 0.$$

Concluimos por tanto que $\mathbb{P}(\limsup A_n) = 0$. ■

Ejemplo 2.3.3 (de falsedad del recíproco del Lema de Borel-Cantelli I).

Sea $(A_n) \subset \mathcal{B}(\mathbb{R})$ una sucesión de conjuntos dada por $A_n = [0, 1/n]$, entonces

$$\limsup_{n \rightarrow \infty} A_n = \{0\} \implies \mathbb{P}\left(\limsup_{n \rightarrow \infty} A_n\right) = 0.$$

Sin embargo, $\sum_{n \in \mathbb{N}} \mathbb{P}(A_n) = \sum_{n \in \mathbb{N}} 1/n = \infty$.

Lema 2.3.3 (de Borel-Cantelli II). Sean $(A_n)_{n \in \mathbb{N}} \subset \Sigma$ independientes en $(\Omega, \Sigma, \mathbb{P})$

$$\sum_{n \in \mathbb{N}} \mathbb{P}(A_n) = \infty \implies \mathbb{P}\left(\limsup_{n \rightarrow \infty} A_n\right) = 1.$$

Demostración: Sean $M < N < \infty$, entonces

$$\begin{aligned} \mathbb{P}\left(\bigcap_{n=M}^N A_n^c\right) &= \prod_{n=M}^N \mathbb{P}(A_n^c) = \prod_{n=M}^N (1 - \mathbb{P}(A_n)) \leq \prod_{n=M}^N e^{-\mathbb{P}(A_n)} \text{ porque } 1 - x \leq e^{-x} \\ &\leq e^{-\sum_{n=M}^N \mathbb{P}(A_n)} \xrightarrow{N \rightarrow \infty} 0, \quad \forall M < \infty. \end{aligned}$$

$$\begin{aligned} \text{Como } \Omega &= \bigcup_{n=M}^{\infty} A_n \sqcup \bigcap_{n=M}^{\infty} A_n^c, \text{ hemos visto que } \mathbb{P}\left(\bigcap_{n=M}^{\infty} A_n^c\right) = \lim_{N \rightarrow \infty} \mathbb{P}\left(\bigcap_{n=M}^N A_n^c\right) = 0. \\ &\implies \forall M < \infty : \mathbb{P}\left(\bigcup_{n=M}^{\infty} A_n\right) = 1 \implies \mathbb{P}\left(\bigcap_{M=1}^{\infty} \bigcup_{n=M}^{\infty} A_n\right) = 1. \end{aligned}$$

Entonces, concluimos que $\mathbb{P}\left(\limsup_{n \rightarrow \infty} A_n\right) = 1$. ■

Observación 2.3.3. Este Lema de Borel-Cantelli II nos proporciona el recíproco del Lema de Borel-Cantelli I en el caso de sucesos independientes.

Es decir, si $(A_n)_{n \in \mathbb{N}} \subset \Sigma$ son independientes, entonces

$$\mathbb{P}\left(\limsup_{n \rightarrow \infty} A_n\right) = 0 \iff \sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty.$$

Observación 2.3.4. Los Lemas de Borel-Cantelli (I y II) también nos aseguran que si $(A_n)_n$

son sucesos independientes, entonces $\mathbb{P}(\limsup A_n) \in \{0, 1\}$.

2.3.3 σ -álgebra de cola y teoremas de Kolmogorov

Observación 2.3.5. Sea X una variable aleatoria en $(\Omega, \Sigma, \mathbb{P})$, la σ -álgebra generada por X ,

$$\sigma(X) := \{X^{-1}(E) \mid E \in \mathcal{B}(\mathbb{R})\},$$

induce una partición de Ω en conjuntos disjuntos dada por la relación de equivalencia

$$\forall \omega_1, \omega_2 \in \Omega : \omega_1 \sim \omega_2 \iff X(\omega_1) = X(\omega_2).$$

Es decir, intuitivamente, la σ -álgebra generada por X representa toda la información disponible al observar X . Por ejemplo, si sabemos que $X(\omega) = x$, entonces sabemos que $\omega \in X^{-1}(\{x\})$, pero no podemos distinguir entre los distintos ω que cumplen esto.

Definición 2.3.6 (σ -álgebra de Cola). Sean $(X_n)_{n \in \mathbb{N}}$ variables aleatorias en $(\Omega, \Sigma, \mathbb{P})$, $T \subset \mathcal{P}(\Omega)$ es la σ -álgebra de cola de $(X_n)_{n \in \mathbb{N}}$

$$\iff T := \bigcap_{n \in \mathbb{N}} \sigma(X_n, X_{n+1}, \dots).$$

donde $\sigma(X_n, X_{n+1}, \dots)$ es la mínima σ -álgebra que hace medibles a $X_n, X_{n+1}, \dots$

Observación 2.3.7. Por la Observación 2.3.5, sabemos que $\sigma(X_n, X_{n+1}, \dots)$ representa toda la información que se puede tener de ω al conocer los valores de $X_n(\omega), X_{n+1}(\omega), \dots$

Por tanto, intuitivamente, la σ -álgebra de cola T representa toda la información que se puede tener de ω al conocer los valores de $X_n(\omega)$ para infinitos n . Es decir, un suceso estará en la σ -álgebra de cola si depende de infinitas de las X_n .

De esta manera, definimos una estructura que captura la información que se preserva “en el infinito” de la sucesión $(X_n)_{n \in \mathbb{N}}$. Son eventos que dependen del comportamiento asintótico de la secuencia y no de un número finito de términos iniciales.

Ejemplos 2.3.4 (de elementos que (no) están en la σ -álgebra de cola).

[1] $A = \{X_2 \geq 0\} \notin T$ en general.

[2] $\forall (B_n)_{n \in \mathbb{N}} \subset \mathcal{B}(\mathbb{R}) : \limsup_{n \rightarrow \infty} \{X_n \in B_n\} \in T$.

[3] Si $S_n := \sum_{j=1}^n X_j$ entonces $\left\{ \omega \in \Omega : \exists \lim_{n \rightarrow \infty} S_n(\omega) \right\} \in T$.

[4] $\left\{ \omega \in \Omega : \limsup_{n \rightarrow \infty} S_n(\omega) > 0 \right\} \notin T$.

Teorema 2.3.4 (Ley 0-1 de Kolmogorov). Sea $(X_n)_{n \in \mathbb{N}}$ una sucesión de v.a.i. y $A \in T$
 $\implies \mathbb{P}(A) \in \{0, 1\}$.

Demostración: Sea $A \in T$, veamos que A es independiente de sí mismo:

1. Veamos que $E \in \sigma(X_1, \dots, X_k)$ y $F \in \sigma(X_{k+1}, X_{k+2}, \dots) \implies E, F$ son indep.

a. Si $F \in \sigma(X_{k+1}, \dots, X_{k+l})$ por el teorema Π - λ E y F son independientes.

b. Si no, consideramos los π -sistemas siguientes:

$$\Pi_1 = \sigma(X_1, \dots, X_k) \quad \wedge \quad \Pi_2 = \bigcup_{j \geq 1} \sigma(X_{k+1}, \dots, X_{k+l}).$$

Entonces por el caso 1a, Π_1, Π_2 son independientes, luego por el teorema Π - λ $\sigma(\Pi_1), \sigma(\Pi_2)$ son independientes. Como $\sigma(X_{k+1}, \dots) \subset \sigma(\Pi_2)$, se tiene que E y F son indep.

2. Veamos que $E \in \sigma(\{X_n\}_{n \in \mathbb{N}})$ y $F \in T \implies E, F$ son independientes.

a. Si $E \in \sigma(X_1, \dots, X_k)$, tomamos $F \in \sigma(X_{k+1}, \dots)$ (en particular), por el paso 1 E, F son independientes.

b. Si no, consideramos los π -sistemas siguientes:

$$\Pi'_1 = \bigcup_{k \geq 1} \sigma(X_1, \dots, X_k) \quad \wedge \quad \Pi'_2 = T.$$

Entonces Π'_1, Π'_2 son independientes, luego por el teorema Π - λ $\sigma(\Pi'_1), \sigma(\Pi'_2)$ son independientes. Como $\sigma(\{X_n\}_{n \in \mathbb{N}}) \subset \sigma(\Pi'_1)$, se tiene que E y F son indep.

3. En conclusión, $T \subset \sigma(\{X_n\}_{n \in \mathbb{N}})$ y por tanto $A \in T \implies A \in \sigma(\{X_n\}_{n \in \mathbb{N}})$. Como T es independiente de $\sigma(\{X_n\}_{n \in \mathbb{N}})$, se tiene que A es independiente de A .

Por tanto $\mathbb{P}(A) = \mathbb{P}(A \cap A) = \mathbb{P}(A) \cdot \mathbb{P}(A) \implies \mathbb{P}(A) \in \{0, 1\}$. ■

Observación 2.3.8. Si definimos $T'_m := \bigcap_{n=m}^{\infty} \sigma(X_n, X_{n+1}, \dots)$, entonces $\forall m \in \mathbb{N} : T'_m = T$.

Demostración: Definimos $\forall m \in \mathbb{N} : \Sigma_m := \sigma(X_m, X_{m+1}, \dots)$, entonces $\Sigma_m \subset \Sigma_{m-1}$.

$$\implies T = \bigcap_{n \in \mathbb{N}} \Sigma_n \quad \wedge \quad T \subset T'_m = \bigcap_{n=m}^{\infty} \Sigma_n.$$

Por tanto, $T'_m = \bigcap_{n=m}^{\infty} \Sigma_n = \bigcap_{n=0}^{\infty} \Sigma_n = T$. ■

Ejemplo 2.3.5 (mono escritor). Tomamos $(X_j)_{j \in \mathbb{N}}$ v.a.i.i.d. dadas por $\forall j \in \mathbb{N} : X_j \sim \text{Unif}(\{1, \dots, 40\})$. Definimos

$$A_n = \{\text{que se escriba el Quijote con las variables } (n-1)L+1 \text{ hasta } nL\}$$

donde L es la longitud del Quijote en caracteres. Entonces

$$\mathbb{P}(A_n) = \mathbb{P}\left(\bigcap_{j=(n-1)L+1}^{nL} \{X_j = Q_j\}\right) \stackrel{\text{indep}}{=} \prod_{j=(n-1)L+1}^{nL} \mathbb{P}(X_j = Q_j) = (1/40)^L.$$

Además, los A_n son independientes y $\sum_{n \in \mathbb{N}} \mathbb{P}(A_n) = \infty$. Por tanto, por el Lema 2.3.3,

$$\mathbb{P}\left(\limsup_{n \rightarrow \infty} A_n\right) = 1.$$

Es decir, el mono escribirá el Quijote infinitas veces.

Ejercicio 2.3.6. ¿Qué pasaría si el Quijote fuese de longitud infinita?

Solución: Podemos encontrar una respuesta en la sección A.2 del apéndice A. Es una entrega que suma hasta 1 punto en la nota final.

Ejemplo 2.3.7 (un juego justo en el que se gana siempre).

$$X_n = \begin{cases} 1 & \text{con probabilidad } 2^n/2^{n+1} \\ -2^n & \text{con probabilidad } 1/2^{n+1} \end{cases}$$

Este es un juego equilibrado, es decir, $\mathbb{E}[X_n] = \frac{2^n}{2^{n+1}} - \frac{2^n}{2^{n+1}} = 0$. Sin embargo, veamos que, si jugamos infinitas veces, ganaremos siempre. Definimos A como el suceso de perder infinitas veces. Entonces $A = \limsup_{n \rightarrow \infty} A_n$ donde A_n es perder en la n -ésima partida.

$$\sum_{n \in \mathbb{N}} \mathbb{P}(A_n) = \sum_{n \in \mathbb{N}} \mathbb{P}(X_n = -2^n) = \sum_{n \in \mathbb{N}} \frac{1}{2^{n+1}} < 1.$$

Por tanto, por el Lema 2.3.2 $\mathbb{P}(A) = 0$ y ganaremos siempre.

Teorema 2.3.5 (desigualdad maximal de Kolmogorov). Sean $\{X_j\}_{j \in \mathbb{N}_n}$ variables aleatorias independientes y centradas (i.e. $\forall j \in \mathbb{N} : \mathbb{E}[X_j] = 0$) y $\forall j \in \mathbb{N}_n : X_j \in \mathcal{L}^2(\mathbb{P})$

$$\implies \forall t \in \mathbb{R} : \mathbb{P}\left(\max_{1 \leq k \leq n} |S_k| > t\right) \leq \frac{\mathbb{V}(S_n)}{t^2} \quad \text{donde} \quad S_k = \sum_{j=1}^k X_j.$$

Demostración: Definimos $\forall k \in \mathbb{N}_n, t \in \mathbb{R}_+$:

$$A_k(t) = \{\omega \in \Omega : |S_k(\omega)| > t \wedge \forall j < k : |S_j(\omega)| \leq t\}.$$

Entonces, $\left\{ \omega \in \Omega : \max_{1 \leq k \leq n} |S_k(\omega)| > t \right\} = \bigsqcup_{k=1}^n A_k(t)$ y, por tanto,

$$\begin{aligned} \mathbb{V}(S_n) &= \mathbb{E}[S_n^2] = \int_{\Omega} S_n^2(\omega) d\mathbb{P}(\omega) \geq \int_{\{\max_{1 \leq k \leq n} |S_n| > t\}} S_n^2(\omega) d\mathbb{P}(\omega) = \sum_{k=1}^n \int_{A_k(t)} S_n^2(\omega) d\mathbb{P}(\omega) = \\ &\geq \sum_{k=1}^n \int_{A_k(t)} (S_n - S_k + S_k)^2 d\mathbb{P} = \sum_{k=1}^n \int_{A_k(t)} S_k^2 + 2S_k(S_n - S_k) + (S_n - S_k)^2 d\mathbb{P} \\ &\geq \sum_{k=1}^n \int_{A_k(t)} S_k^2 d\mathbb{P} + \sum_{k=1}^n 2 \int_{\Omega} \mathbb{1}_{A_k(t)} \cdot S_k (S_n - S_k) d\mathbb{P} \\ &\geq \sum_{k=1}^n t^2 \cdot \mathbb{P}(A_k(t)) = t^2 \cdot \mathbb{P}\left(\max_{1 \leq k \leq n} S_k\right) \end{aligned}$$

(*) Tenemos que $\mathbb{1}_{A_k(t)} \cdot S_k$ es $\sigma(X_1, \dots, X_k)$ -medible y, además, $S_n - S_k = \sum_{j=k+1}^n X_j$ es $\sigma(X_{k+1}, \dots, X_n)$ -medible. Por el teorema Π - λ , $\mathbb{1}_{A_k} S_k$ y $S_n - S_k$ son independientes

$$\implies \mathbb{E}[\mathbb{1}_{A_k(t)} S_k \cdot (S_n - S_k)] = \mathbb{E}[\mathbb{1}_{A_k(t)} S_k] \cdot \mathbb{E}[S_n - S_k] = 0.$$

■

3. Convergencia de sucesiones de variables aleatorias

3.1 Diferentes tipos de convergencia

Definición 3.1.1 (Convergencia en probabilidad). Sea $(X_n)_{n \in \mathbb{N}}$ una sucesión de variables aleatorias, X_n converge en probabilidad a X

$$\iff \forall \varepsilon > 0 : \lim_{n \rightarrow \infty} \mathbb{P}(|X_n - X| > \varepsilon) = 0 \iff X_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} X.$$

Definición 3.1.2 (Convergencia casi segura). Sea $(X_n)_{n \in \mathbb{N}}$ una sucesión de variables aleatorias, X_n converge casi seguro a X

$$\iff \exists A \in \Sigma : \mathbb{P}(A) = 0 \wedge \forall \omega \in A^c : \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega) \iff X_n \xrightarrow[n \rightarrow \infty]{\text{c.s.}} X.$$

Es decir, $X_n \xrightarrow[n \rightarrow \infty]{\text{c.s.}} X \iff X_n$ converge puntualmente a X en casi todo $\omega \in \Omega$.

Observación 3.1.3. Veamos varias caracterizaciones útiles de la convergencia casi segura:

$$\begin{aligned} X_n \xrightarrow[n \rightarrow \infty]{\text{c.s.}} X &\stackrel{\text{defn}}{\iff} \exists A \in \Sigma : \mathbb{P}(A) = 0 \wedge \forall \omega \in A^c : \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega) \\ &\stackrel{\text{defn de límite en } \mathbb{R}}{\iff} \exists A \in \Sigma : \mathbb{P}(A) = 0 \\ &\quad \wedge \forall \omega \in A^c : \forall \varepsilon > 0 : \exists N \in \mathbb{N} : \forall n \geq N : |X_n(\omega) - X(\omega)| < \varepsilon \\ &\stackrel{2.3.2}{\iff} \exists A \in \Sigma : \mathbb{P}(A) = 0 \wedge \forall \varepsilon > 0 : A^c \subset \liminf_{n \rightarrow \infty} \{|X_n - X| < \varepsilon\} \\ &\iff \forall \varepsilon > 0 : \mathbb{P}\left(\liminf_{n \rightarrow \infty} \{|X_n - X| < \varepsilon\}\right) = 1 \\ &\stackrel{2.3.2:(b)}{\iff} \forall \varepsilon > 0 : \mathbb{P}\left(\limsup_{n \rightarrow \infty} \{|X_n - X| > \varepsilon\}\right) = 0 \\ &\stackrel{\text{Fatou}}{\iff} \forall \varepsilon > 0 : \limsup_{n \rightarrow \infty} \mathbb{P}(|X_n - X| > \varepsilon) = 0. \end{aligned}$$

Definición 3.1.4 (Convergencia en $\mathcal{L}^p$). Sea (X, Σ, μ) un esp medida y $(f_n)_{n \in \mathbb{N}} \subset \mathcal{L}^p(\mu)$ una sucesión de funciones medibles, f_n converge en $\mathcal{L}^p(\mu)$ a f


$$\iff \lim_{n \rightarrow \infty} \|f_n - f\|_p = 0 \iff f_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}^p} f.$$

Definición 3.1.5 (convergencia en distribución). Sea $(X_n)_{n \in \mathbb{N}}$ una sucesión de variables aleatorias, X_n converge en distribución a X

$$\iff \forall t \in \mathbb{R} \text{ punto de continuidad de } F_X : \lim_{n \rightarrow \infty} F_{X_n}(t) = F_X(t) \iff X_n \xrightarrow[n \rightarrow \infty]{d} X.$$

3.1.1 Implicaciones entre los diferentes tipos de convergencia

Vamos a probar el siguiente diagrama de implicaciones entre los diferentes tipos de convergencia de sucesiones de variables aleatorias:



Las flechas que no están es porque no se dan en general (veremos contraejemplos).

Proposición 3.1.1. Sea $(X_n)_{n \in \mathbb{N}}$ tal que $X_n \xrightarrow{c.s.} X \implies X_n \xrightarrow{\mathbb{P}} X$.

Demostración: Sea $\varepsilon > 0$, tenemos que $\exists A \in \Sigma : \mathbb{P}(A) = 0 : \forall \omega \in A^c : X_n(\omega) \rightarrow X(\omega)$.

Para $\omega \in A^c$, $\limsup_{n \rightarrow \infty} |X_n(\omega) - X(\omega)| = 0$

$$\implies \mathbb{P} \left(\left\{ \omega \in \Omega : \limsup_{n \rightarrow \infty} |X_n(\omega) - X(\omega)| > \varepsilon \right\} \right) = 0.$$

Por otro lado, por el Lema de Fatou para probabilidades, tenemos que

$$\begin{aligned}
 \mathbb{P} \left(\left\{ \omega \in \Omega : \limsup_{n \rightarrow \infty} |X_n(\omega) - X(\omega)| > \varepsilon \right\} \right) &\geq \limsup_{n \rightarrow \infty} \mathbb{P}(\{\omega \in \Omega : |X_n(\omega) - X(\omega)| > \varepsilon\}) \\
 &\geq \lim_{n \rightarrow \infty} \mathbb{P}(|X_n - X| > \varepsilon) \geq 0.
 \end{aligned}$$

■

Proposición 3.1.2. Sea $1 \leq p \leq \infty$ y $(X_n)_{n \in \mathbb{N}}$ tal que $X_n \xrightarrow{\mathcal{L}^p} X \implies X_n \xrightarrow{\mathbb{P}} X$.

Demostración: Sea $\varepsilon > 0$, queremos ver que $\mathbb{P}(|X_n - X| > \varepsilon) \rightarrow 0$.

1. Si $p < \infty$, entonces, por la desigualdad de Chebyshev

$$0 \leq \mathbb{P}(|X_n - X| > \varepsilon) \leq \frac{\|X_n - X\|_p^p}{\varepsilon^p} \xrightarrow{n \rightarrow \infty} 0.$$

2. Si $p = \infty$, veamos dos pruebas distintas:

– Por un lado, como tenemos que $\|X_n - X\|_2 \leq \|X_n - X\|_\infty$ (ejercicio), entonces

$$0 \leq \mathbb{P}(|X_n - X| > \varepsilon) \leq \frac{\|X_n - X\|_2^2}{\varepsilon^2} \leq \frac{\|X_n - X\|_\infty^2}{\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0.$$

- Por otro lado, si $X_n \xrightarrow{\mathcal{L}^\infty} X$, entonces $X_n \xrightarrow{\text{c.s.}} X$ uniformemente (ejercicio). Entonces, por la proposición anterior, $X_n \xrightarrow{\mathbb{P}} X$.

En cualquier caso hemos probado que $X_n \xrightarrow{\mathbb{P}} X$. ■

Proposición 3.1.3. Sea $(X_n)_{n \in \mathbb{N}}$ tal que $X_n \xrightarrow{\mathbb{P}} X \implies X_n \xrightarrow{d} X$.

Demostración: Sea $t \in \mathbb{R}$ punto de continuidad de F_X y $\varepsilon > 0$, veamos que

$$F_{X_n}(t) \leq F_X(t + \varepsilon) + \mathbb{P}(|X_n - X| > \varepsilon) \quad (3.1)$$

$$F_{X_n}(t) \geq F_X(t - \varepsilon) - \mathbb{P}(|X_n - X| > \varepsilon). \quad (3.2)$$

Si aceptamos (3.1) y (3.2), entonces

$$F_X(t - \varepsilon) - \mathbb{P}(|X_n - X| > \varepsilon) \leq F_{X_n}(t) \leq F_X(t + \varepsilon) + \mathbb{P}(|X_n - X| > \varepsilon).$$

Como $X_n \xrightarrow{\mathbb{P}} X$, entonces $\mathbb{P}(|X_n - X| > \varepsilon) \xrightarrow{n \rightarrow \infty} 0$

$$\implies F_X(t - \varepsilon) \leq \lim_{n \rightarrow \infty} F_{X_n}(t) \leq F_X(t + \varepsilon).$$

Tomando límites en ε , $\lim_{\varepsilon \rightarrow 0} F_X(t - \varepsilon) \leq \lim_{n \rightarrow \infty} F_{X_n}(t) \leq \lim_{\varepsilon \rightarrow 0} F_X(t + \varepsilon)$, como F_X es continua en t , entonces concluimos que $\lim_{n \rightarrow \infty} F_{X_n}(t) = F_X(t)$, luego $X_n \xrightarrow{d} X$.

Veamos que se cumplen las desigualdades

(3.1) Basta ver que $\{X_n \leq t\} \subset \{X \leq t + \varepsilon\} \cup \{|X_n - X| > \varepsilon\}$, operamos

$$\begin{aligned} \{X_n \leq t\} &= \left[\{X_n \leq t\} \cap \{|X_n - X| \leq \varepsilon\} \right] \cup \left[\{X_n \leq t\} \cap \{|X_n - X| > \varepsilon\} \right] \\ &\subset \{X \leq t + \varepsilon\} \cup \{|X_n - X| > \varepsilon\}. \end{aligned}$$

(3.2) Se hace de forma análoga. ■

Proposición 3.1.4. Sea $(X_n)_{n \in \mathbb{N}}$ tal que $X_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} X \implies \exists (X_{n_k})_{k \in \mathbb{N}} : X_{n_k} \xrightarrow[k \rightarrow \infty]{\text{c.s.}} X$.

Demostración: Definimos $\forall k \in \mathbb{N} : n_k = \min \{n \in \mathbb{N} : \mathbb{P}(|X_n - X| > 2^{-k}) \leq 2^{-k}\}$ y llamaremos $A_k := \{|X_{n_k} - X| > 2^{-k}\}$. Como $\mathbb{P}(|X_n - X| > \varepsilon) \xrightarrow{n \rightarrow \infty} 0$, $\forall k \in \mathbb{N} : \exists n_k \in \mathbb{N}$

$$\implies \sum_{k=1}^{\infty} \mathbb{P}(A_k) \leq \sum_{k=1}^{\infty} 2^{-k} = 1 < \infty.$$

Entonces, por el Lema de Borel-Cantelli I, $\mathbb{P}\left(\limsup_{k \rightarrow \infty} A_k\right) = 0$.

Por otro lado, afirmamos que $\left\{ \omega \in \Omega : \limsup_{n \rightarrow \infty} |X_{n_k}(\omega) - X(\omega)| \neq 0 \right\} \subset \limsup_{k \rightarrow \infty} A_k$.

En efecto, si $\omega \in \Omega$ es tal que $\limsup_{k \rightarrow \infty} |X_{n_k}(\omega) - X(\omega)| \neq 0$, entonces $\exists$ infinitos índices k tales que $\omega \in A_k$. Por tanto, $\omega \in \limsup_{k \rightarrow \infty} A_k$. ■

3.2 Otros resultados de convergencia

Proposición 3.2.1 (de Borel-Cantelli III). Sea $(A_n)_{n \in \mathbb{N}}$ una sucesión de sucesos independientes dos a dos tal que $\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty$

$$\implies \frac{\sum_{j=1}^n \mathbb{1}_{A_j}}{\sum_{j=1}^n \mathbb{P}(A_j)} \xrightarrow[n \rightarrow \infty]{c.s.} 1.$$

Demostración: Denotamos $S_N := \sum_{j=1}^N \mathbb{1}_{A_j}$, entonces por la independencia dos a dos

$$\mathbb{V}(S_n) = \sum_{j=1}^n \mathbb{V}(\mathbb{1}_{A_j}) \leq \sum_{j=1}^n \mathbb{P}(A_j). \quad (3.3)$$

Por otro lado, $\mathbb{V}(\mathbb{1}_{A_j}) = \mathbb{E}[\mathbb{1}_{A_j}^2] - \mathbb{E}^2[\mathbb{1}_{A_j}] \leq \mathbb{E}[\mathbb{1}_{A_j}^2] = \mathbb{E}[\mathbb{1}_{A_j}]$. Sea $\varepsilon > 0$, por la

$$\begin{aligned} \mathbb{P}\left(\left|\frac{\sum_{j=1}^n \mathbb{1}_{A_j}}{\sum_{j=1}^n \mathbb{P}(A_j)} - 1\right| > \varepsilon\right) &= \mathbb{P}\left(\left|\sum_{j=1}^n \mathbb{1}_{A_j} - \sum_{j=1}^n \mathbb{P}(A_j)\right| > \varepsilon \sum_{j=1}^n \mathbb{P}(A_j)\right) \\ &\stackrel{\text{Chebyshev}}{\leq} \frac{1}{\varepsilon^2 \left(\sum_{j=1}^n \mathbb{P}(A_j)\right)^2} \mathbb{V}(S_n) \stackrel{3.3}{\leq} \frac{1}{\varepsilon^2 \sum_{j=1}^n \mathbb{P}(A_j)} \xrightarrow[n \rightarrow \infty]{} 0. \end{aligned}$$

Por tanto, $\frac{\sum_{j=1}^{\infty} \mathbb{1}_{A_j}}{\sum_{j=1}^{\infty} \mathbb{P}(A_j)} \xrightarrow[n \rightarrow \infty]{\mathbb{P}} 1$.

Definimos $\forall k \in \mathbb{N} : n_k := \min \{n : \mathbb{E}[S_n] \geq k^2\}$ y $T_k := S_{n_k}$, entonces, $k^2 \leq \mathbb{E}[T_k] \leq k^2 + 1$.

$$\implies \mathbb{P}\left(\underbrace{\{|T_k \cdot \mathbb{E}[T_k]| > \varepsilon \mathbb{E}[T_k]\}}_{A_k^\varepsilon}\right) \leq \frac{1}{\varepsilon^2 k^2}.$$

$$\implies \sum_{k=1}^{\infty} \mathbb{P}(A_k^\varepsilon) \leq \frac{1}{\varepsilon^2} \sum_{k=1}^{\infty} \frac{1}{k^2} < \infty \stackrel{\text{B-C I}}{\implies} \mathbb{P}\left(\limsup_{k \rightarrow \infty} A_k^\varepsilon\right) = 0.$$

Por el argumento de la demostración de la Proposición 3.1.4, $\frac{T_k}{\mathbb{E}[T_k]} \xrightarrow[k \rightarrow \infty]{c.s.} 1$. Sea n tal que $n_k \leq n \leq n_{k+1}$, entonces

$$\frac{T_k}{\mathbb{E}[T_{k+1}]} \leq \frac{S_n}{\mathbb{E}[S_n]} \leq \frac{T_{k+1}}{\mathbb{E}[T_k]}$$

y basta probar que (a) $\frac{T_k}{\mathbb{E}[T_{k+1}]} \xrightarrow[k \rightarrow \infty]{c.s.} 1$ y (b) $\frac{T_{k+1}}{\mathbb{E}[T_k]} \xrightarrow[k \rightarrow \infty]{c.s.} 1$.

(a) Sea $\omega \in \Omega$ tal que $\frac{T_k(\omega)}{\mathbb{E}[T_k]} \xrightarrow{k \rightarrow \infty} 1 \implies \frac{T_k(\omega)}{\mathbb{E}[T_{k+1}]} = \frac{T_k(\omega)}{\mathbb{E}[T_k]} \cdot \frac{\mathbb{E}[T_k]}{\mathbb{E}[T_{k+1}]}$ y además

$$\frac{k^2}{(k+1)^2 + 1} \leq \frac{\mathbb{E}[T_k]}{\mathbb{E}[T_{k+1}]} \leq \frac{k^2 + 1}{(k+1)^2}$$

con cada uno de estos términos tendiendo a 1. Por tanto, $\frac{T_k}{\mathbb{E}[T_{k+1}]} \xrightarrow[k \rightarrow \infty]{c.s.} 1$.

(b) Se hace de forma análoga.

Como $\frac{T_k}{\mathbb{E}[T_{k+1}]} \leq \frac{S_n}{\mathbb{E}[S_n]} \leq \frac{T_{k+1}}{\mathbb{E}[T_k]}$, entonces $\frac{S_n}{\mathbb{E}[S_n]} \xrightarrow[n \rightarrow \infty]{c.s.} 1$. ■

Observación 3.2.1. Esta es una forma más fuerte del Lema de Borel-Cantelli II porque la independencia implica la independencia dos a dos (pero no al revés).

$$\text{Además } \limsup_{n \rightarrow \infty} A_n = \left\{ \omega \in \Omega : \sum_{n=1}^{\infty} \mathbb{1}_{A_n}(\omega) = \infty \right\}.$$

Proposición 3.2.2. Sean $(X_n)_{n \in \mathbb{N}}$ v.a.i. y centradas tal que $\sum_{n=1}^{\infty} \mathbb{V}(X_n) < \infty$.

$$\implies \exists X \text{ variable aleatoria} : \sum_{j=1}^n X_j \xrightarrow[n \rightarrow \infty]{c.s.} X.$$

Demostración: Definimos $S_n := \sum_{j=1}^n X_j$ y fijamos $M < N$

$$\mathbb{P} \left(\max_{M \leq n \leq N} |S_n - S_M| > \varepsilon \right) \stackrel{\text{máx Kolmogorov}}{\leq} \frac{1}{\varepsilon^2} \mathbb{V}(S_N - S_M) \stackrel{\text{indep}}{\leq} \frac{1}{\varepsilon^2} \sum_{j=M}^N \mathbb{V}(X_j) \leq \frac{1}{\varepsilon^2} \sum_{j=M}^{\infty} \mathbb{V}(X_j) \xrightarrow{M \rightarrow \infty} 0.$$

$$\implies \lim_{M \rightarrow \infty} \mathbb{P} \left(\sup_{n \geq M} |S_n - S_M| > \varepsilon \right) = 0.$$

Definimos $W_M = \sup_{n, k \geq M} |S_n - S_k|$, entonces veamos que $W_M \xrightarrow[\mathbb{P}]{M \rightarrow \infty} 0$:

$$\begin{aligned} \mathbb{P}(W_M > \varepsilon) &= \mathbb{P} \left(\sup_{n, k \geq M} |S_n - S_l| > \varepsilon \right) \\ &\leq \mathbb{P} \left(\sup_{n \geq M} |S_n - S_M| > \frac{\varepsilon}{2} \right) + \mathbb{P} \left(\sup_{k \geq M} |S_k - S_M| > \frac{\varepsilon}{2} \right) \end{aligned}$$

ya que, por desigualdad triangular y subaditividad de la medida,

$$\begin{aligned}\mathbb{P}\left(\sup_{n,k \geq M} |S_n - S_k| > \varepsilon\right) &= \mathbb{P}\left(\sup_{n,k \geq M} |S_n - S_M + S_M - S_k| > \varepsilon\right) \\ &\leq \mathbb{P}\left(\sup_{n \geq M} |S_n - S_M| + \sup_{k \geq M} |S_k - S_M| > \varepsilon\right) \\ &\leq \mathbb{P}\left(\sup_{n \geq M} |S_n - S_M| > \frac{\varepsilon}{2}\right) + \mathbb{P}\left(\sup_{k \geq M} |S_k - S_M| > \frac{\varepsilon}{2}\right).\end{aligned}$$

Por tanto, $\mathbb{P}(W_M > \varepsilon) \leq 2\mathbb{P}\left(\sup_{n \geq M} |S_n - S_M| > \frac{\varepsilon}{2}\right) \xrightarrow{M \rightarrow \infty} 0$. Como $\forall \omega \in \Omega : (W_M(\omega))_{M \in \mathbb{N}}$ es decreciente, entonces $W_M \xrightarrow[\text{c.s.}]{M \rightarrow \infty} 0$.

Entonces, para todo ω en un conjunto de probabilidad 1, $W_M(\omega) \xrightarrow{M \rightarrow \infty} 0 \implies S_n(\omega)$ es de Cauchy (en $\mathbb{R}$ espacio completo) y por tanto, $S_n \xrightarrow[n \rightarrow \infty]{\text{c.s.}} X$. ■

4. Martingalas

4.1 Esperanza condicionada

Sea $(\Omega, \Sigma, \mathbb{P})$ un espacio de probabilidad y $\mathcal{F} \subset \Sigma$ una σ -álgebra. Podemos interpretar intuitivamente $\mathcal{F}$ como una representación parcial de la información en Σ del experimento aleatorio.

Por ejemplo, sea $\mathcal{A} = \{A_i\}_{i \in I} \subset \Sigma$ una partición de Ω y $\mathcal{F} = \sigma(\mathcal{A})$ la σ -álgebra generada por $\mathcal{A}$. Entonces, cómo mucho, podemos conocer a qué A_i pertenece el ω del experimento aleatorio, pero no podemos distinguir entre los distintos ω en A_i , la σ -álgebra $\mathcal{F}$ no nos permite medir conjuntos más pequeños para “afinar más”.

Otro ejemplo es el caso de $\mathcal{F} = \sigma(X)$ donde X es una variable aleatoria y $\sigma(X)$ es la σ -álgebra generada por X . En este caso, si conocemos $X(\omega) = x$, sabemos que $\omega \in X^{-1}(\{x\})$, pero no podemos distinguir entre los distintos ω que cumplen $X(\omega) = x$. Además, el valor de X puede determinarse completamente a partir de cuáles eventos de $\mathcal{F}$ ocurren, sin especificar más, por tanto, X solo utiliza la información disponible en $\mathcal{F}$.

Entonces, cabe preguntarse cómo podemos calcular la esperanza de una variable aleatoria X si nos restringimos a la información disponible en $\mathcal{F}$:

Proposición 4.1.1 (Esperanza condicionada). *Sea $X \in \mathcal{L}^1(\mathbb{P})$ en $(\Omega, \Sigma, \mathbb{P})$ espacio de probabilidad y $\mathcal{F} \subset \Sigma$ una σ -álgebra*

$$\implies \exists! Y \in \mathcal{L}^1(\mathbb{P}) : Y \text{ es } \mathcal{F}\text{-medible} \wedge \mathbb{E}[YZ] = \mathbb{E}[XZ]$$

donde $Z \in \mathcal{L}^\infty(\mathbb{P})$ es $\mathcal{F}$ -medible.

*Esta Y se denomina **esperanza condicionada** de X dada $\mathcal{F}$ y se denota por $\mathbb{E}[X | \mathcal{F}]$.*

Demostración: Definimos $\nu: \mathcal{F} \rightarrow \mathbb{R}$ dada por $\nu(A) := \int_A X(\omega) d\mathbb{P}(\omega)$, entonces es una medida con signo (ejercicio). Además, $\nu \ll \mathbb{P}$ en $\mathcal{F}$ porque si $A \in \mathcal{F}$ es tal que $\mathbb{P}(A) = 0$, entonces $\nu(A) = \int_A X d\mathbb{P} = 0$.

Por tanto, por el teorema de Radon-Nikodym,

$$\exists! Y \in \mathcal{L}^1(\mathbb{P}) : Y \text{ es } \mathcal{F}\text{-medible} \wedge \forall A \in \mathcal{F} : \nu(A) = \int_A Y d\mathbb{P}.$$

Veamos ahora que $\forall Z \in \mathcal{L}^\infty(\mathbb{P}) : \mathbb{E}[YZ] = \mathbb{E}[XZ]$:

1. Si Z es una función indicatriz, $Z = \mathbb{1}_A$ con $A \in \mathcal{F}$, entonces

$$\mathbb{E}[Y \mathbb{1}_A] = \int_A Y \, d\mathbb{P} = \nu(A) = \int_A X \, d\mathbb{P} = \mathbb{E}[X \mathbb{1}_A].$$

2. Si Z es una función simple, se tiene por linealidad de la integral (ejercicio).
 3. Si $Z \in \mathcal{L}^\infty(\mathbb{P})$ se tiene por el teorema de la convergencia dominada.

■

Observación 4.1.1. $\forall Z \in \mathcal{L}^\infty(\mathbb{P})$ $\mathcal{F}$ -medible : $\mathbb{E}[XZ] = \mathbb{E}[\mathbb{E}[X | \mathcal{F}] Z]$.

Lema 4.1.2 (Propiedades de la esperanza condicionada). Sean $X, Y, Z \in \mathcal{L}^1(\mathbb{P})$ tres variables aleatorias en $(\Omega, \Sigma, \mathbb{P})$ y $\mathbb{E}[X | \mathcal{F}]$ la esperanza condicionada de X dada $\mathcal{F} \subset \Sigma$ σ -álgebra, entonces

- (1) $X \geq 0$ c.s. $\implies \mathbb{E}[X | \mathcal{F}] \geq 0$ c.s.
- (2) $\mathbb{E}[\mathbb{E}[X | \mathcal{F}]] = \mathbb{E}[X]$.
- (3) $\mathbb{E}[X | \Sigma] = X$.
- (4) $\mathbb{E}[X | \{\emptyset, \Omega\}] \equiv \mathbb{E}[X]$.
- (5) $\mathbb{E}[cX + dY | \mathcal{F}] = c \cdot \mathbb{E}[X | \mathcal{F}] + d \cdot \mathbb{E}[Y | \mathcal{F}]$.
- (6) $Z \in \mathcal{L}^\infty(\mathbb{P})$ es $\mathcal{F}$ -medible $\implies \mathbb{E}[ZX | \mathcal{F}] = Z \cdot \mathbb{E}[X | \mathcal{F}]$.

Demostración:

- (1) Sea $B \in \mathcal{F}$ tal que $\forall \omega \in B : \mathbb{E}[X | \mathcal{F}](\omega) < 0$, supongamos por contradicción que $\mathbb{P}(B) > 0$. Entonces, tenemos que

$$0 \leq \mathbb{E}[X \mathbb{1}_B] = \mathbb{E}[\mathbb{E}[X | \mathcal{F}] \mathbb{1}_B] = \int_B \mathbb{E}[X | \mathcal{F}] \, d\mathbb{P} < 0 \implies 0 < 0. \longrightarrow \leftarrow$$

Luego debe ser que $\mathbb{P}(B) = 0$ y por tanto $\mathbb{E}[X | \mathcal{F}] \geq 0$ c.s.

- (2) Si tomamos $Z = \mathbb{1}_\Omega$ y aplicamos la definición de esperanza condicionada, tenemos que

$$\mathbb{E}[X] = \mathbb{E}[X \cdot Z] = \mathbb{E}[\mathbb{E}[X | \mathcal{F}] \cdot Z] = \mathbb{E}[\mathbb{E}[X | \mathcal{F}]].$$

- (3) Vamos a usar que Y es la esperanza condicionada de X dada $\mathcal{F}$

$$\iff Y \text{ es } \mathcal{F}\text{-medible} \wedge \forall A \in \mathcal{F} : \int_A Y \, d\mathbb{P} = \int_A X \, d\mathbb{P}.$$

En este caso, $\mathcal{F} = \Sigma$ y trivialmente $\forall A \in \Sigma : \int_A X \, d\mathbb{P} = \int_A X \, d\mathbb{P}$. Como la esperanza condicionada es única (salvo un conjunto de probabilidad 0), $Y = \mathbb{E}[X \mid \Sigma] = X$ c.s.

(4) En este caso, $\mathcal{F} = \{\emptyset, \Omega\}$ luego Y es la esperanza condicionada de X dada $\mathcal{F}$

$$\iff Y \text{ es } \{\emptyset, \Omega\}\text{-medible} \wedge \int_{\emptyset} Y \, d\mathbb{P} = \int_{\emptyset} X \, d\mathbb{P} = 0 \wedge \int_{\Omega} Y \, d\mathbb{P} = \int_{\Omega} X \, d\mathbb{P} = \mathbb{E}[X].$$

Como Y es $\{\emptyset, \Omega\}$ -medible $\implies Y$ es constante c.s. y $Y = \mathbb{E}[X]$ satisface las dos igualdades, $\mathbb{E}[X \mid \Sigma] = \mathbb{E}[X]$ c.s.

(5) Por un lado, $c \cdot \mathbb{E}[X \mid \mathcal{F}] + d \cdot \mathbb{E}[Y \mid \mathcal{F}]$ es $\mathcal{F}$ -medible porque $\mathbb{E}[X \mid \mathcal{F}]$ y $\mathbb{E}[Y \mid \mathcal{F}]$ lo son, y la combinación lineal de funciones medibles es medible.

Por otro lado, para todo $A \in \mathcal{F}$:

$$\begin{aligned} \int_A (c \cdot \mathbb{E}[X \mid \mathcal{F}] + d \cdot \mathbb{E}[Y \mid \mathcal{F}]) \, d\mathbb{P} &\stackrel{\text{lineal}}{=} c \int_A \mathbb{E}[X \mid \mathcal{F}] \, d\mathbb{P} + d \int_A \mathbb{E}[Y \mid \mathcal{F}] \, d\mathbb{P} \\ &= c \int_A X \, d\mathbb{P} + d \int_A Y \, d\mathbb{P} = \int_A (cX + dY) \, d\mathbb{P}. \end{aligned}$$

Concluimos por la unicidad de la esperanza condicionada.

(6) Sea Y la esperanza condicionada de $X \cdot Z$ dada $\mathcal{F}$. Para probar que $Y = Z \cdot \mathbb{E}[X \mid \mathcal{F}]$, tenemos que ver que

$$Z \cdot \mathbb{E}[X \mid \mathcal{F}] \text{ es } \mathcal{F}\text{-medible} \wedge \forall A \in \mathcal{F} : \int_A Z \cdot \mathbb{E}[X \mid \mathcal{F}] \, d\mathbb{P} = \int_A X \cdot Z \, d\mathbb{P}.$$

I. Si $Z = \mathbb{1}_A$ donde $A \in \mathcal{F}$, entonces

$$\forall B \in \mathcal{F} : \int_B Z \cdot \mathbb{E}[X \mid \mathcal{F}] \, d\mathbb{P} = \int_{B \cap A} \mathbb{E}[X \mid \mathcal{F}] \, d\mathbb{P} = \int_{B \cap A} X \, d\mathbb{P} = \int_B X \cdot Z \, d\mathbb{P}.$$

II. Si Z es simple, entonces $Z = \sum_{i=1}^n a_i \mathbb{1}_{A_i}$ donde $A_i \in \mathcal{F}$ y $a_i \in \mathbb{R}$. Por linealidad de la integral, tenemos que

$$\begin{aligned} \forall B \in \mathcal{F} : \int_B Z \cdot \mathbb{E}[X \mid \mathcal{F}] \, d\mathbb{P} &= \sum_{i=1}^n a_i \int_B \mathbb{1}_{A_i} \cdot \mathbb{E}[X \mid \mathcal{F}] \, d\mathbb{P} \\ &\stackrel{\text{I}}{=} \sum_{i=1}^n a_i \int_B \mathbb{1}_{A_i} X \, d\mathbb{P} = \int_B Z \cdot X \, d\mathbb{P}. \end{aligned}$$

III. Si $Z \geq 0$ es $\mathcal{F}$ -medible, entonces $\exists (s_n)_{n \in \mathbb{N}}$ simples y $\mathcal{F}$ -medibles tales que $s_n \nearrow Z$ c.s.

$$\begin{aligned} \implies \forall B \in \mathcal{F} : \int_B Z \cdot \mathbb{E}[X \mid \mathcal{F}] \, d\mathbb{P} &\stackrel{\text{TCM}}{=} \lim_{n \rightarrow \infty} \int_B s_n \cdot \mathbb{E}[X \mid \mathcal{F}] \, d\mathbb{P} \\ &\stackrel{\text{II}}{=} \lim_{n \rightarrow \infty} \int_B s_n \cdot X \, d\mathbb{P} \stackrel{\text{TCM}}{=} \int_B Z \cdot X \, d\mathbb{P}. \end{aligned}$$

IV. Por último, si Z es $\mathcal{F}$ -medible arbitraria, entonces $Z = Z^+ - Z^-$ y, por linealidad de la integral, tenemos que

$$\begin{aligned} \forall B \in \mathcal{F} : \int_B Z \cdot \mathbb{E}[X | \mathcal{F}] d\mathbb{P} &= \int_B Z^+ \cdot \mathbb{E}[X | \mathcal{F}] d\mathbb{P} - \int_B Z^- \cdot \mathbb{E}[X | \mathcal{F}] d\mathbb{P} \\ &\stackrel{\text{III}}{=} \int_B Z^+ \cdot X d\mathbb{P} - \int_B Z^- \cdot X d\mathbb{P} = \int_B Z \cdot X d\mathbb{P}. \quad \blacksquare \end{aligned}$$

Lema 4.1.3. Sea $X \in \mathcal{L}^1(\mathbb{P})$ en $(\Omega, \Sigma, \mathbb{P})$ y $\mathcal{F} \subset \Sigma$ una σ -álgebra

$$\implies \forall Z \text{ } \mathcal{F}\text{-medible} : \mathbb{E}[|X - Z|^2] \geq \mathbb{E}[|X - \mathbb{E}[X | \mathcal{F}]|^2] \geq 0.$$

Demostración: Sumamos y restamos $\mathbb{E}[X | \mathcal{F}]$ dentro de $|X - Z|^2$:

$$\begin{aligned} \mathbb{E}[|X - Z|^2] &= \mathbb{E}[|X - \mathbb{E}[X | \mathcal{F}] + \mathbb{E}[X | \mathcal{F}] - Z|^2] \\ &= \mathbb{E}[|X - \mathbb{E}[X | \mathcal{F}]|^2] + \mathbb{E}[|Z - \mathbb{E}[X | \mathcal{F}]|^2] \\ &\quad + 2\mathbb{E}[(X - \mathbb{E}[X | \mathcal{F}])(\mathbb{E}[X | \mathcal{F}] - Z)] \end{aligned}$$

Veamos que $\mathbb{E}[(X - \mathbb{E}[X | \mathcal{F}])(\mathbb{E}[X | \mathcal{F}] - Z)] = 0$. Tenemos que

$$\begin{aligned} \mathbb{E}[(X - \mathbb{E}[X | \mathcal{F}])(\mathbb{E}[X | \mathcal{F}] - Z)] &= \\ &= \mathbb{E}[X \cdot Z] - \mathbb{E}[\mathbb{E}[X | \mathcal{F}] \cdot Z] + \mathbb{E}[(\mathbb{E}[X | \mathcal{F}])^2] - \mathbb{E}[X \cdot \mathbb{E}[X | \mathcal{F}]] \end{aligned} \tag{4.1}$$

Por definición de esperanza condicionada, $\mathbb{E}[Z \cdot \mathbb{E}[X | \mathcal{F}]] = \mathbb{E}[X \cdot Z]$ y queda 0 porque

$$\mathbb{E}\left[X \cdot \underbrace{\mathbb{E}[X | \mathcal{F}]}_{\mathcal{F}\text{-medible}}\right] = \mathbb{E}[\mathbb{E}[X | \mathcal{F}] \cdot \mathbb{E}[X | \mathcal{F}]] = \mathbb{E}[(\mathbb{E}[X | \mathcal{F}])^2].$$

Luego los dos primeros términos y los dos últimos de (4.1) se cancelan entre sí. \blacksquare

Observación 4.1.2. Este resultado nos dice que la esperanza condicionada es la **mejor aproximación cuadrática** de X por una variable aleatoria $\mathcal{F}$ -medible.

Proposición 4.1.4. Sea $X \in \mathcal{L}^1(\mathbb{P})$ y $\mathcal{F}$ una σ -álgebra independiente de $\sigma(X)$

$$\implies \mathbb{E}[X | \mathcal{F}] \equiv \mathbb{E}[X] \text{ c.s.}$$

Demostración: Sea $Z \in \mathcal{L}^\infty(\mathbb{P})$ $\mathcal{F}$ -medible, entonces $\mathbb{E}[Z \cdot \mathbb{E}[X | \mathcal{F}]] = \mathbb{E}[X \cdot Z]$. Como $\sigma(X)$ es independiente de $\mathcal{F}$, Z y X son independientes, por lo que

$$\mathbb{E}[Z \cdot \mathbb{E}[X | \mathcal{F}]] = \mathbb{E}[Z \cdot X] \stackrel{2.1.3}{=} \mathbb{E}[Z] \cdot \mathbb{E}[X] \underset{\text{lineal}}{=} \mathbb{E}[\mathbb{E}[X] \cdot Z]$$

Entonces, la función $Y := \mathbb{E}[X] \mathbb{1}_\Omega$ es $\mathcal{F}$ -medible y cumple $\mathbb{E}[Z \cdot Y] = \mathbb{E}[X \cdot Z]$ para todo Z $\mathcal{F}$ -medible. Por la unicidad de la esperanza condicionada, $Y = \mathbb{E}[X | \mathcal{F}]$ c.s. ■

Proposición 4.1.5. Sea $X \in \mathcal{L}^1(\mathbb{P})$ y $\mathcal{F}_1, \mathcal{F}_2$ σ -álgebras tales que $\mathcal{F}_1 \subset \mathcal{F}_2 \subset \Sigma$

$$\implies \mathbb{E}[\mathbb{E}[X | \mathcal{F}_1] | \mathcal{F}_2] = \mathbb{E}[\mathbb{E}[X | \mathcal{F}_2] | \mathcal{F}_1] = \mathbb{E}[X | \mathcal{F}_1] \text{ c.s.}$$

Demostración: Como $\mathcal{F}_1 \subset \mathcal{F}_2$, entonces $\mathbb{E}[X | \mathcal{F}_1]$ es $\mathcal{F}_2$ -medible. Por lo tanto, por la propiedad (3) del Lema 4.1.2, tenemos que

$$\mathbb{E}[\mathbb{E}[X | \mathcal{F}_1] | \mathcal{F}_2] = \mathbb{E}[X | \mathcal{F}_1] \text{ c.s.}$$

Para la otra igualdad, sea Z $\mathcal{F}_1$ -medible, entonces también es $\mathcal{F}_2$ -medible.

$$\implies \mathbb{E}[Z \cdot \mathbb{E}[X | \mathcal{F}_1]] \stackrel{Z \text{ es } \mathcal{F}_1\text{-medible}}{=} \mathbb{E}[X \cdot Z] \stackrel{Z \text{ es } \mathcal{F}_2\text{-medible}}{=} \mathbb{E}[Z \cdot \overbrace{\mathbb{E}[X | \mathcal{F}_2]}^{\mathcal{F}_2\text{-medible}}] \stackrel{Z \text{ es } \mathcal{F}_1\text{-medible}}{=} \mathbb{E}[Z \cdot \mathbb{E}[\mathbb{E}[X | \mathcal{F}_2] | \mathcal{F}_1]]$$

Por tanto, por unicidad de la esperanza condicionada, queda demostrado. ■

Ejercicio 4.1.1 (de Jacobo). Sea X una variable aleatoria incorrelada con todas las Z $\mathcal{F}$ -medibles. Demuestra que $\sigma(X)$ es independiente de $\mathcal{F}$.

Ejercicio 4.1.2. Si $\mathcal{F} = \sigma(A_1, \dots, A_n)$ y $\Omega = \bigsqcup_{j=1}^n A_j$, demuestra que

$$\forall \omega \in \Omega : \mathbb{E}[X | \mathcal{F}](\omega) = \sum_{j=1}^n \mathbb{E}[X \cdot \mathbb{1}_{A_j}] \frac{\mathbb{1}_{A_j}(\omega)}{\mathbb{P}(A_j)}$$

(a) Extiende el resultado a particiones numerables de $\Omega = \bigsqcup_{j=1}^\infty A_j$.

(b) Prueba todas las propiedades ya vistas de $\mathbb{E}[X | \mathcal{F}]$ en este caso.

Solución: Denotamos $Y := \sum_{j=1}^n \mathbb{E}[X \cdot \mathbb{1}_{A_j}] \cdot \frac{\mathbb{1}_{A_j}}{\mathbb{P}(A_j)}$. Entonces, queremos demostrar que $\forall Z \in \mathcal{L}^\infty(\mathbb{P})$ $\mathcal{F}$ -medible, se cumple que $\mathbb{E}[Y \cdot Z] = \mathbb{E}[X \cdot Z]$.

Ahora bien, como $\mathcal{F} = \sigma(A_1, \dots, A_n)$, basta demostrar la propiedad para $Z = \mathbb{1}_{A_k}$:

$$\mathbb{E}[Y \cdot Z] = \sum_{j=1}^n \frac{\mathbb{E}[X \cdot \mathbb{1}_{A_j}]}{\mathbb{P}(A_j)} \cdot \mathbb{E}[\mathbb{1}_{A_j} \cdot \mathbb{1}_{A_k}] = \sum_{j=1}^n \frac{\mathbb{E}[X \cdot \mathbb{1}_{A_j}]}{\mathbb{P}(A_j)} \cdot \mathbb{P}(A_j \cap A_k)$$

Como los $\forall j \neq k : A_j \cap A_k = \emptyset$, la expresión anterior se reduce a:

$$\mathbb{E}[Y \cdot Z] = \frac{\mathbb{E}[X \cdot \mathbb{1}_{A_k}]}{\mathbb{P}(A_k)} \cdot \mathbb{P}(A_k) = \mathbb{E}[X \cdot \mathbb{1}_{A_k}] = \mathbb{E}[X \cdot Z].$$

Podríamos probarlo para cualquier Z $\mathcal{F}$ -medible mediante aproximación por funciones

simples, teorema de la convergencia monótona y linealidad de la esperanza.

Entonces, por la unicidad de la esperanza condicionada, tenemos que $Y = \mathbb{E}[X \mid \mathcal{F}]$.

4.2 Procesos estocásticos y martingalas

4.2.1 Definiciones, interpretación y ejemplos

Definición 4.2.1 (Proceso estocástico). Un proceso estocástico es una familia indexada de variables aleatorias $\{X_\alpha : \alpha \in I\}$ en $(\Omega, \Sigma, \mathbb{P})$.

Observación 4.2.2. Normalmente, los procesos estocásticos se usan para modelizar fenómenos aleatorios que evolucionan en el tiempo (de ahí que se llamen *procesos*). En tal caso, la colección de índices I representa diferentes momentos en el *tiempo* y X_α el valor del fenómeno en el *instante* $\alpha \in I$.

Definición 4.2.3 (Filtración). Sea $(\Omega, \Sigma, \mathbb{P})$ un espacio de probabilidad, F es una filtración

$$\iff F = (\mathcal{F}_n)_{n \in \mathbb{N}} : \forall n \in \mathbb{N} : \mathcal{F}_n \text{ es una } \sigma\text{-álgebra } \wedge \mathcal{F}_n \subset \mathcal{F}_{n+1} \subset \Sigma.$$

Observación 4.2.4. Dado que cada σ -álgebra $\mathcal{F}_n$ representa una cantidad de información parcial acerca del espacio de probabilidad y que $\mathcal{F}_n \subset \mathcal{F}_{n+1}$, podemos interpretar $\mathcal{F}_n$ como *toda* la información disponible hasta el instante n .

Es decir, hay un refinamiento progresivo de la información a medida que n aumenta, por eso se dice que F es una *filtración*, porque filtra la información disponible para el observador.

Definición 4.2.5 (Proceso adaptado). Sea $(X_n)_{n \in \mathbb{N}}$ un proceso estocástico y F una filtración en $(\Omega, \Sigma, \mathbb{P})$, $(X_n)_{n \in \mathbb{N}}$ es un proceso adaptado a $F \iff \forall n \in \mathbb{N} : X_n$ es $\mathcal{F}_n$ -medible.

Observación 4.2.6. Sea $(X_n)_{n \in \mathbb{N}}$ un proceso estocástico, entonces está adaptado a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$ dada por $\forall n \in \mathbb{N} : \mathcal{F}_n = \sigma(X_1, \dots, X_n)$.

Definición 4.2.7 (Submartingala). Sea $(X_n)_{n \in \mathbb{N}}$ un proceso estocástico adaptado a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$, $(X_n)_{n \in \mathbb{N}}$ es una submartingala

$$\iff \forall n \in \mathbb{N} : \mathbb{E}[X_{n+1} \mid \mathcal{F}_n] \geq X_n.$$

Definición 4.2.8 (Supermartingala). Sea $(X_n)_{n \in \mathbb{N}}$ un proceso estocástico adaptado a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$, $(X_n)_{n \in \mathbb{N}}$ es una supermartingala

$$\iff (-X_n)_{n \in \mathbb{N}} \text{ es una submartingala} \iff \forall n \in \mathbb{N} : \mathbb{E}[X_{n+1} \mid \mathcal{F}_n] \leq X_n.$$

Definición 4.2.9 (Martingala). Sea $(X_n)_{n \in \mathbb{N}}$ un proceso estocástico adaptado a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$, $(X_n)_{n \in \mathbb{N}}$ es una martingala

$$\begin{aligned} &\iff (X_n)_{n \in \mathbb{N}} \text{ es una submartingala} \wedge (X_n)_{n \in \mathbb{N}} \text{ es una supermartingala} \\ &\iff \forall n \in \mathbb{N} : \mathbb{E}[X_{n+1} \mid \mathcal{F}_n] = X_n. \end{aligned}$$

Observación 4.2.10. En vista de las observaciones 4.2.2 y 4.2.4, podemos interpretar una martingala como un fenómeno aleatorio que evoluciona en el tiempo de manera tal que la mejor predicción del valor futuro, dado todo lo que se conoce hasta el momento, es igual al valor actual del fenómeno.

En otras palabras, no hay tendencia al alza ni a la baja en el valor esperado del fenómeno a lo largo del tiempo, lo que implica que el proceso es “justo”, “neutral” o “imparcial”.

Ejemplos 4.2.1 (de martingalas).

[1] Sean $(X_j)_{j \in \mathbb{N}}$ variables aleatorias independientes y centradas. Entonces, si definimos

$$\forall C_0 \in \mathbb{R} : S_n^{C_0} := C_0 + \sum_{j=1}^n X_j,$$

$(S_n^{C_0})_{n \in \mathbb{N}}$ es una martingala respecto a la filtración dada por $\mathcal{F}_n = \sigma(X_1, \dots, X_n)$:

$$\mathbb{E}[S_{n+1}^{C_0} \mid \mathcal{F}_n] = \mathbb{E}\left[X_{n+1} + C_0 + \sum_{j=1}^n X_j \mid \mathcal{F}_n\right] \stackrel{\text{lineal}}{=} \mathbb{E}[X_{n+1} \mid \mathcal{F}_n] + C_0 + \sum_{j=1}^n \mathbb{E}[X_j \mid \mathcal{F}_n].$$

Como las X_j son independientes, $\sigma(X_{n+1})$ es independiente de $\mathcal{F}_n = \sigma(X_1, \dots, X_n)$, por tanto, por la Proposición 4.1.4, $\mathbb{E}[X_{n+1} \mid \mathcal{F}_n] = \mathbb{E}[X_{n+1}] = 0$. Además, como las $\{X_j\}_{j=1}^n$ son $\mathcal{F}_n$ -medibles, por la propiedad (3) del Lema 4.1.2 $\mathbb{E}[X_j \mid \mathcal{F}_n] = X_j$ para todo $j \leq n$.

$$\implies \mathbb{E}[S_{n+1}^{C_0} \mid \mathcal{F}_n] = 0 + C_0 + \sum_{j=1}^n X_j = S_n^{C_0}.$$

[2] Sean $(X_j)_{j \in \mathbb{N}}$ como en el ejemplo anterior y las mismas $\mathcal{F}_n$. Si $(A_n)_{n \in \mathbb{N}}$ es un proceso

adaptado a $(\mathcal{F}_n)$ acotado y previsible (i.e. A_n es $\mathcal{F}_{n-1}$ -medible), entonces si definimos

$$\forall C_0 \in \mathbb{R} : S_n^{C_0, A} := C_0 + \sum_{j=1}^n A_j X_j,$$

$(S_n^{C_0, A})_{n \in \mathbb{N}}$ es una martingala respecto a $(\mathcal{F}_n)_{n \in \mathbb{N}}$:

$$\begin{aligned} \mathbb{E} [S_{n+1}^{C_0, A} \mid \mathcal{F}_n] &= \mathbb{E} \left[A_{n+1} X_{n+1} + C_0 + \sum_{j=1}^n A_j X_j \mid \mathcal{F}_n \right] \\ &\stackrel{\text{lineal}}{=} \mathbb{E} [A_{n+1} X_{n+1} \mid \mathcal{F}_n] + C_0 + \sum_{j=1}^n \mathbb{E} [A_j X_j \mid \mathcal{F}_n] \end{aligned}$$

Como A_{n+1} es $\mathcal{F}_n$ -medible, por la propiedad (6) del Lema 4.1.2, podemos sacar A_{n+1} de la esperanza:

$$\begin{aligned} \mathbb{E} [A_{n+1} X_{n+1} \mid \mathcal{F}_n] &= A_{n+1} \cdot \mathbb{E} [X_{n+1} \mid \mathcal{F}_n] \stackrel{\text{indep}}{=} A_{n+1} \cdot \mathbb{E} [X_{n+1}] = A_{n+1} \cdot 0 = 0. \\ \implies \mathbb{E} [S_{n+1}^{C_0, A} \mid \mathcal{F}_n] &= 0 + C_0 + \sum_{j=1}^n \mathbb{E} [A_j X_j \mid \mathcal{F}_n] \stackrel{(3)}{=} C_0 + \sum_{j=1}^n A_j X_j = S_n^{C_0, A}. \end{aligned}$$

Veamos que $\forall n \in \mathbb{N} : \mathbb{E} [S_n^{C_0, A}] = C_0$. Se puede demostrar por inducción:

- Para $n = 1$, tenemos que $\mathbb{E} [S_1^{C_0, A}] = C_0 + \mathbb{E} [A_1 X_1]$. Como A_1 es $\mathcal{F}_0 = \{\emptyset, \Omega\}$ -medible, X_1 es independiente de A_1 , luego por la Proposición 2.1.3, tenemos que

$$\mathbb{E} [S_n^{C_0, A}] = C_0 + \mathbb{E} [A_1] \cdot \mathbb{E} [X_1] = C_0 + 0 = C_0.$$

- Supongamos que $\mathbb{E} [S_n^{C_0, A}] = C_0$ y veamos que se cumple para $n + 1$:

$$\begin{aligned} \mathbb{E} [S_{n+1}^{C_0, A}] &= \mathbb{E} [A_{n+1} \cdot X_{n+1} + S_n^{C_0, A}] \stackrel{\text{lineal}}{=} \mathbb{E} [A_{n+1} \cdot X_{n+1}] + \mathbb{E} [S_n^{C_0, A}] \\ &\stackrel{\text{indep}}{=} \mathbb{E} [A_{n+1}] \cdot \mathbb{E} [X_{n+1}] + \mathbb{E} [S_n^{C_0, A}] \stackrel{\text{HI}}{=} \mathbb{E} [A_{n+1}] \cdot 0 + C_0 = C_0. \end{aligned}$$

Luego por el principio de inducción, se cumple que $\mathbb{E} [S_n^{C_0, A}] = C_0$ para todo $n \in \mathbb{N}$.

Este resultado significa que la mejor estimación de tu fortuna en el tiempo n es la que tienes al principio, C_0 . Es decir, no hay una estrategia ganadora a largo plazo porque la información disponible no genera ninguna ventaja.

[3] Sea $X \in \mathcal{L}^1(\mathbb{P})$, $(\mathcal{F}_n)_n$ una filtración y $X_n = \mathbb{E}[X \mid \mathcal{F}_n]$ para todo $n \in \mathbb{N}$. Entonces, $(X_n)_{n \in \mathbb{N}}$ es una martingala respecto a $(\mathcal{F}_n)_n$ (la Martingala de Doob):

$$\mathbb{E} [X_{n+1} \mid \mathcal{F}_n] = \mathbb{E} [\mathbb{E} [X \mid \mathcal{F}_{n+1}] \mid \mathcal{F}_n] \stackrel{\mathcal{F}_n \subset \mathcal{F}_{n+1}}{=} \mathbb{E} [X \mid \mathcal{F}_n] = X_n.$$

Observación 4.2.11. Este último ejemplo anterior es casi el único. Es decir, bajo ciertas condiciones adecuadas, una martingala puede expresarse como la esperanza condicionada de una variable aleatoria respecto a una filtración apropiada. Este resultado se conoce como el Teorema de representación de Doob para martingalas.

4.2.2 Propiedades de martingalas

Lema 4.2.1 (Desigualdad de Jensen condicional).

Sea $X \in \mathcal{L}^1(\mathbb{P})$ en $(\Omega, \Sigma, \mathbb{P})$, $\mathcal{F} \subset \Sigma$ una σ -álgebra y $\varphi: \mathbb{R} \rightarrow \mathbb{R}$ una función convexa

$$\implies \varphi(\mathbb{E}[X | \mathcal{F}]) \leq \mathbb{E}[\varphi(X) | \mathcal{F}] \text{ c.s.}$$

Corolario 4.2.2. Sea $(X_n)_{n \in \mathbb{N}}$ una martingala y $\varphi: \mathbb{R} \rightarrow \mathbb{R}$ convexa

$$\implies (\varphi(X_n))_{n \in \mathbb{N}} \text{ es una submartingala.}$$

Demostración: Por la desigualdad de Jensen condicionada, tenemos que

$$\begin{array}{c} \varphi(X_n) = \varphi(\mathbb{E}[X_{n+1} | \mathcal{F}_n]) \leq \mathbb{E}[\varphi(X_{n+1}) | \mathcal{F}_n] \text{ c.s.} \\ \uparrow \\ (X_n)_n \text{ martingala} \end{array}$$

Por tanto, $\varphi(X)$ es una submartingala respecto a la filtración $\mathcal{F} = (\mathcal{F}_n)_{n \in \mathbb{N}}$. ■

Ejercicio 4.2.2. Sea $(X_n)_{n \in \mathbb{N}}$ una martingala, prueba que $(e^{X_n})_n$, $(|X_n|)_n$ y $(X_n^+)_n$ donde $X^+ = \max\{X, 0\}$ son submartingalas.

Solución: En todos los casos tenemos $(\varphi(X_n))_{n \in \mathbb{N}}$ con φ una función convexa. Por tanto, por el Corolario 4.2.2, $(\varphi(X_n))_{n \in \mathbb{N}}$ es una submartingala. ■

Proposición 4.2.3 (Desigualdad de Hölder condicional). Sea $p \in (1, \infty)$, $X \in \mathcal{L}^p(\mathbb{P})$, $Y \in \mathcal{L}^{p'}(\mathbb{P})$ y $\mathcal{F} \subset \Sigma$ una σ -álgebra

$$\implies \mathbb{E}[|X \cdot Y| | \mathcal{F}] \leq \left(\mathbb{E}[|X|^p | \mathcal{F}]\right)^{1/p} \cdot \left(\mathbb{E}[|Y|^{p'} | \mathcal{F}]\right)^{1/p'} \text{ c.s.}$$

donde p' es el exponente conjugado de p .

Teorema 4.2.4 (Descomposición de Doob). Sea $(Y_n)_{n \in \mathbb{N}}$ una submartingala respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$ en el espacio de probabilidad $(\Omega, \Sigma, \mathbb{P})$, entonces

(1) $\exists (X_n)_{n \in \mathbb{N}}$ martingala respecto a $(\mathcal{F}_n)_{n \in \mathbb{N}}$,

(2) $\exists (A_n)_{n \in \mathbb{N}} \subset \mathcal{L}^1(\mathbb{P}) : \forall n \in \mathbb{N} : A_n \geq 0 \wedge A_n \leq A_{n+1} \wedge A_n$ es $\mathcal{F}_{n-1}$ -medible

tales que $\forall n \in \mathbb{N} : Y_n = X_n + A_n$.

Demostración: Definimos $A_0 \equiv 0$ y $\forall n \in \mathbb{N} : A_n := A_{n-1} + \mathbb{E}[Y_n - Y_{n-1} | \mathcal{F}_{n-1}]$. Entonces, definimos $X_n := Y_n - A_n$. Comprobemos primero las propiedades de A_n :

(i) Veamos que A_n es $\mathcal{F}_{n-1}$ -medible. Como A_0 es constante, es $\mathcal{F}_0 = \{\emptyset, \Omega\}$ -medible. Por tanto, $A_1 = A_0 + \mathbb{E}[Y_1 - Y_0 | \mathcal{F}_0]$ es $\mathcal{F}_0$ -medible. Ahora, supongamos que A_n es $\mathcal{F}_{n-1}$ -medible, entonces $A_{n+1} = A_n + \mathbb{E}[Y_{n+1} - Y_n | \mathcal{F}_n]$ es $\mathcal{F}_n$ -medible por construcción. Por el principio de inducción, A_n es $\mathcal{F}_{n-1}$ -medible para todo $n \in \mathbb{N}$.

(ii) Veamos que $A_n \leq A_{n+1}$, para ello, basta ver que $A_{n+1} - A_n \geq 0$:

$$\begin{aligned} A_{n+1} - A_n &= \cancel{A_n} + \mathbb{E}[Y_{n+1} - Y_n | \mathcal{F}_n] - \cancel{A_n} \stackrel{\text{lineal}}{\downarrow} \mathbb{E}[Y_{n+1} | \mathcal{F}_n] - \mathbb{E}[Y_n | \mathcal{F}_n] \\ &\stackrel{(3)}{\downarrow} \mathbb{E}[Y_{n+1} | \mathcal{F}_n] - Y_n \stackrel{(Y_n)_n \text{ submartingala}}{\downarrow} Y_n - Y_n = 0. \end{aligned}$$

(iii) Como $A_0 = 0 \geq 0$ y $\forall n \in \mathbb{N} : A_n \geq A_{n-1}$, tenemos que $A_n \geq 0$ para todo $n \in \mathbb{N}$.

Veamos ahora que $(X_n)_{n \in \mathbb{N}}$ es una martingala respecto a $(\mathcal{F}_n)_{n \in \mathbb{N}}$:

$$\begin{aligned} \mathbb{E}[X_{n+1} | \mathcal{F}_n] &= \mathbb{E}[Y_{n+1} - A_{n+1} | \mathcal{F}_n] \stackrel{\text{lineal}}{\downarrow} \mathbb{E}[Y_{n+1} | \mathcal{F}_n] - \mathbb{E}[A_{n+1} | \mathcal{F}_n] \\ &\stackrel{(3)}{\downarrow} \mathbb{E}[Y_{n+1} | \mathcal{F}_n] - A_{n+1} = \mathbb{E}[Y_{n+1} | \mathcal{F}_n] - (A_n + \mathbb{E}[Y_{n+1} - Y_n | \mathcal{F}_n]) \\ &\stackrel{\text{lineal}}{\downarrow} \mathbb{E}[Y_{n+1} | \mathcal{F}_n] - A_n - \mathbb{E}[Y_{n+1} | \mathcal{F}_n] + \mathbb{E}[Y_n | \mathcal{F}_n] \stackrel{(3)}{\downarrow} Y_n - A_n = X_n. \end{aligned}$$

Luego, $(X_n)_{n \in \mathbb{N}}$ es una martingala respecto a $(\mathcal{F}_n)_{n \in \mathbb{N}}$ y se tiene $Y_n = X_n + A_n$. ■

Observación 4.2.12. El teorema de descomposición de Doob nos dice que cualquier submartingala puede entenderse como la suma de una martingala y una *perturbación* no decreciente y no negativa.

Esta perturbación puede interpretarse como una especie de “ganancia” que se acumula a lo largo del tiempo, mientras que la martingala representa el componente “justo” del proceso.

4.3 Tiempos de parada

Definición 4.3.1 (Tiempo de parada). Sea $T: \Omega \longrightarrow \mathbb{N}$ una variable aleatoria en $(\Omega, \Sigma, \mathbb{P})$, es un tiempo de parada respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$

$$\iff \forall n \in \mathbb{N} : T^{-1}(\{n\}) = \{\omega \in \Omega : T(\omega) = n\} \in \mathcal{F}_n.$$

Observación 4.3.2. Intuitivamente, un tiempo de parada es una variable aleatoria discreta que indica el momento en el que se detiene un proceso estocástico. Como la decisión solo se puede tomar en función de la información disponible hasta ese momento, se pide que $T^{-1}(\{n\}) \in \mathcal{F}_n$. En otras palabras, no nos podemos anticipar a eventos futuros.

Ejemplos 4.3.1 (de tiempos de parada).

[1] T dado por $\forall \omega \in \Omega : T(\omega) = t_0$ es un tiempo de parada respecto a cualquier filtración.

[2] Sea X es un proceso adaptado, $E \in \mathcal{B}(\mathbb{R})$, entonces T_E dada por

$$\implies \forall \omega \in \Omega : T_E(\omega) = \inf \{n \in \mathbb{N} : X_n(\omega) \in E\} \text{ es un tiempo de parada respecto a } \mathcal{F}.$$

Lema 4.3.1. Sea $T: \Omega \longrightarrow \mathbb{N}$ una variable aleatoria, es un tiempo de parada

$$\iff \forall k \in \mathbb{N} : \{\omega \in \Omega : T(\omega) \leq k\} \in \mathcal{F}_k$$

Demostración: Veamos ambas implicaciones:

[$\Rightarrow$] Sea T un tiempo de parada respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$, entonces $\forall n \in \mathbb{N} : T^{-1}(\{n\}) \in \mathcal{F}_n$ por definición. Por tanto,

$$\forall k \in \mathbb{N} : T^{-1}(\{n \in \mathbb{N} : n \leq k\}) = \bigcup_{n=1}^k T^{-1}(\{n\}) \in \mathcal{F}_k$$

ya que las $\mathcal{F}_n$ están anidadas y son cerradas bajo uniones numerables.

[$\Leftarrow$] Sea T una variable aleatoria tal que $\forall k \in \mathbb{N} : T^{-1}(\{n \in \mathbb{N} : n \leq k\}) \in \mathcal{F}_k$. Entonces, como las $\mathcal{F}_n$ son σ -álgebras anidadas, tenemos que

$$\begin{aligned} \forall n \in \mathbb{N} : T^{-1}(\{n\}) &= T^{-1}(\{k \leq n\}) \setminus T^{-1}(\{k \leq n-1\}) \\ &= T^{-1}(\{k \leq n\}) \cap (T^{-1}(\{k \leq n-1\}))^c \in \mathcal{F}_n. \end{aligned}$$

■

Proposición 4.3.2. Sea $T: \Omega \longrightarrow \mathbb{N}$ un tiempo de parada respecto a la filtración $(\mathcal{F}_k)_{k \in \mathbb{N}}$

en $(\Omega, \Sigma, \mathbb{P})$ tal que $T < \infty$ c.s. donde $\Sigma = \sigma\left(\bigcup_{k \in \mathbb{N}} \mathcal{F}_k\right)$

$\implies \mathcal{F}_T := \{A \in \Sigma : \forall k \in \mathbb{N} : A \cap \{T \leq k\} \in \mathcal{F}_k\}$ es una σ -álgebra.

$\mathcal{F}_T$ se denomina la σ -álgebra **inducida** por T o la **σ -álgebra de parada**.

Demostración: Comprobemos las propiedades de la definición:

- (i) $\Omega \in \mathcal{F}_T$ porque $\Omega \in \Sigma$ y $\Omega \cap \{T \leq k\} = \{T \leq k\} \in \mathcal{F}_k$ por el Lema 4.3.1.
- (ii) Sea $A \in \mathcal{F}_T$, entonces $\forall k \in \mathbb{N} : A \cap \{T \leq k\} \in \mathcal{F}_k$. Por tanto, para $A^c \in \Sigma$, tenemos

$$\begin{aligned} \forall k \in \mathbb{N} : A^c \cap \{T \leq k\} &= (\Omega \setminus A) \cap \{T \leq k\} \\ &= (\Omega \cap \{T \leq k\}) \setminus (A \cap \{T \leq k\}) \in \mathcal{F}_k. \end{aligned}$$

- (iii) Sean $\{A_j\}_{j \in \mathbb{N}} \subset \mathcal{F}_T$, entonces $\forall k, j \in \mathbb{N} : A_j \cap \{T \leq k\} \in \mathcal{F}_k$. Por tanto, tenemos que

$$\left(\bigcup_{j=1}^{\infty} A_j\right) \cap \{T \leq k\} = \bigcup_{j=1}^{\infty} (A_j \cap \{T \leq k\}) \in \mathcal{F}_k.$$

Como se cumplen las tres propiedades, $\mathcal{F}_T$ es una σ -álgebra. ■

Observación 4.3.3. La σ -álgebra de parada $\mathcal{F}_T$ representa la información que se tiene en el momento en el que se decide parar el proceso estocástico.

La condición clave $A_n \cap \{T \leq k\} \in \mathcal{F}_k$ significa: “Si nos preguntamos si ocurrió A y además el tiempo de parada fue menor o igual a k , podemos responder usando solo la información hasta el momento k ”.

Lema 4.3.3. Sea T un tiempo de parada respecto a la filtración $(\mathcal{F}_n)_n$, entonces

- (1) Sea $S \leq T$ un tiempo de parada respecto a la filtración $(\mathcal{F}_n)_n \implies \mathcal{F}_S \subset \mathcal{F}_T$.
- (2) $\forall Y \in \mathcal{L}^1(\Omega, \Sigma, \mathbb{P}) : \forall n \in \mathbb{N} : \mathbb{E}[Y \mid \mathcal{F}_T] \mathbb{1}_{\{T=n\}} = \mathbb{E}[Y \mid \mathcal{F}_n] \mathbb{1}_{\{T=n\}}$ c.s.
- (3) Sea $(X_n)_n$ un proceso estocástico adaptado a $(\mathcal{F}_n)_n$, definimos X_T dada por

$$\forall \omega \in \Omega : X_T(\omega) = X_{T(\omega)}(\omega) \implies X_T \text{ es } \mathcal{F}_T\text{-medible.}$$

Demostración:

- (1) Sea $A \in \mathcal{F}_S$, entonces $\forall k \in \mathbb{N} : A \cap \{S \leq k\} \in \mathcal{F}_k$. Podemos escribir

$$A \cap \{T \leq k\} = (A \cap \{S \leq k\} \cap \{T \leq k\}) \cup (A \cap \{S > k\} \cap \{T \leq k\}),$$

pero como $S \leq T$, si $S > k$, entonces $T \geq S > k$, por tanto $\{T \leq k\} \cap \{S > k\} = \emptyset$.

$$\implies A \cap \{T \leq k\} = A \cap \{S \leq k\} \cap \{T \leq k\} = A \cap \{S \leq k\} \in \mathcal{F}_k.$$

$\uparrow$
 $S \leq T$

Por tanto, $A \in \mathcal{F}_T$ y, en consecuencia, $\mathcal{F}_S \subset \mathcal{F}_T$.

- (2) Sea $Y \in \mathcal{L}^1(\mathbb{P})$ y $n \in \mathbb{N}$. Queremos ver que $\mathbb{E}[Y \mid \mathcal{F}_T] \mathbb{1}_{\{T=n\}} = \mathbb{E}[Y \mid \mathcal{F}_n] \mathbb{1}_{\{T=n\}}$ c.s.
Sea $A \in \mathcal{F}_T$, entonces $\forall k \in \mathbb{N} : A \cap \{T \leq k\} \in \mathcal{F}_k$

$$\implies A \cap \{T = n\} = A \cap \{T \leq n\} \cap \{T \leq n-1\}^c \in \mathcal{F}_n.$$

Entonces, por la propiedad de la esperanza condicionada, tenemos que

$$\mathbb{E}[Y \cdot \mathbb{1}_{\{T=n\}} \cdot \mathbb{1}_A] = \mathbb{E}[\mathbb{E}[Y \cdot \mathbb{1}_{\{T=n\}} \mid \mathcal{F}_T] \cdot \mathbb{1}_A].$$

Ahora bien, como $\{T = n\} \in \mathcal{F}_T$, podemos aplicar el Lema 4.1.2:(6).

$$\implies \mathbb{E}[Y \cdot \mathbb{1}_{\{T=n\} \cap A}] = \mathbb{E}[\mathbb{E}[Y \mid \mathcal{F}_T] \cdot \mathbb{1}_{\{T=n\}} \cdot \mathbb{1}_A].$$

Por otro lado, como $A \cap \{T = n\} \in \mathcal{F}_n$, al condicionar por $\mathcal{F}_n$, tenemos

$$\mathbb{E}[Y \cdot \mathbb{1}_{\{T=n\} \cap A}] = \mathbb{E}[\mathbb{E}[Y \mid \mathcal{F}_n] \cdot \mathbb{1}_{\{T=n\} \cap A}] = \mathbb{E}[\mathbb{E}[Y \mid \mathcal{F}_n] \cdot \mathbb{1}_{\{T=n\}} \cdot \mathbb{1}_A].$$

Luego $\int_A \mathbb{E}[Y \mid \mathcal{F}_T] \cdot \mathbb{1}_{\{T=n\}} d\mathbb{P} = \int_A \mathbb{E}[Y \mid \mathcal{F}_n] \cdot \mathbb{1}_{\{T=n\}} d\mathbb{P}$. Como A era arbitrario,

$$\mathbb{E}[Y \mid \mathcal{F}_T] \cdot \mathbb{1}_{\{T=n\}} = \mathbb{E}[Y \mid \mathcal{F}_n] \cdot \mathbb{1}_{\{T=n\}} \text{ c.s.}$$

- (3) Sea $E \in \mathcal{B}(\mathbb{R})$ y $k \in \mathbb{N}$, queremos ver que $X_T^{-1}(E) \cap \{T \leq k\} \in \mathcal{F}_T$.

$$X_T^{-1}(E) = \{\omega \in \Omega : X_{T(\omega)}(\omega) \in E\} = \bigcup_{n \in \mathbb{N}} \{X_n \in E\} \cap \{T = n\}.$$

$$\implies X_T^{-1}(E) \cap \{T \leq k\} = \bigcup_{n=1}^k \underbrace{\{X_n \in E\}}_{\in \mathcal{F}_n} \cap \underbrace{\{T = n\}}_{\in \mathcal{F}_n}.$$

Como $\mathcal{F}_n \subset \mathcal{F}_{n+1}$, tenemos que $X_T^{-1}(E) \cap \{T \leq k\} \in \mathcal{F}_k$ y, por tanto, $X_T^{-1}(E) \in \mathcal{F}_T$.
Luego, como E era arbitrario, X_T es $\mathcal{F}_T$ -medible. ■

Teorema 4.3.4 (de parada opcional). Sea $(X_n)_n$ un proceso estocástico y $S \leq T$ tiempos de parada respecto a la filtración $(\mathcal{F}_n)_n$ tales que $T < \infty$ c.s., entonces

- (1) Si $(X_n)_n$ es una martingala respecto a $(\mathcal{F}_n)_n \implies \mathbb{E}[X_T \mid \mathcal{F}_S] = X_S$ c.s.
- (2) Si $(X_n)_n$ es una submartingala respecto a $(\mathcal{F}_n)_n \implies \mathbb{E}[X_T \mid \mathcal{F}_S] \geq X_S$ c.s.
- (3) Si $(X_n)_n$ es una supermartingala respecto a $(\mathcal{F}_n)_n \implies \mathbb{E}[X_T \mid \mathcal{F}_S] \leq X_S$ c.s.

donde X_S está dada por $\forall \omega \in \Omega : X_S(\omega) = X_{S(\omega)}(\omega)$.

Demostración: Consultar Durrett, 2019. ■

Teorema 4.3.5 (Desigualdad maximal de Doob). Sea $(X_n)_n$ una submartingala respecto a la filtración $(\mathcal{F}_n)_n$ y sean $\lambda > 0$ y $n \in \mathbb{N}$, entonces

$$(1) \quad \lambda \cdot \mathbb{P} \left(\left\{ \omega \in \Omega : \max_{1 \leq j \leq n} X_j(\omega) \geq \lambda \right\} \right) \leq \mathbb{E} \left[X_n \cdot \mathbb{1}_{\{\omega \in \Omega : \max_{1 \leq j \leq n} X_j(\omega) \geq \lambda\}} \right].$$

$$(2) \quad \lambda \cdot \mathbb{P} \left(\left\{ \omega \in \Omega : \min_{1 \leq j \leq n} X_j(\omega) \leq -\lambda \right\} \right) \leq \mathbb{E} [X_n^+] - \mathbb{E} [X_1].$$

Demostración: No se va a demostrar. ■

Corolario 4.3.6. Sea $(X_n)_n$ una submartingala

$$\implies \forall \lambda > 0, n \in \mathbb{N} : \mathbb{P} \left(\left\{ \omega \in \Omega : \max_{1 \leq j \leq n} |X_j(\omega)| \geq \lambda \right\} \right) \leq 2\mathbb{E} [|X_n|] - \mathbb{E} [X_1]$$

Demostración: Por la desigualdad maximal de Doob y usando que $\mathbb{E} [X_n^+] \leq \mathbb{E} [|X_n|]$ y que $\mathbb{E} [X_n \cdot \mathbb{1}_{\{\max_{1 \leq j \leq n} X_j \geq \lambda\}}] \leq \mathbb{E} [|X_n|]$. ■

Teorema 4.3.7 (de convergencia de martingalas). Sea $(X_n)_n$ una submartingala

$$\left(\sup_{n \in \mathbb{N}} \|X_n\|_1 < \infty \right) \vee \left(\forall n \in \mathbb{N} : X_n \leq 0 \right) \implies X_n \xrightarrow[n \rightarrow \infty]{c.s.} X_\infty \wedge |X_\infty| < \infty \text{ c.s.}$$

Demostración: Vamos a dividir la prueba en casos:

I. Consideramos $\forall n \in \mathbb{N} : X_n \geq 0$ y $\sup_{n \in \mathbb{N}} \|X_n\|_2 < \infty$.

(a) Tenemos que para todo $k, n \in \mathbb{N}$,

$$\begin{aligned} \|X_{n+k} - X_n\|_2^2 &= \mathbb{E} [X_{n+k}^2] + \mathbb{E} [X_n^2] - 2\mathbb{E} [X_{n+k}X_n] \\ &= \mathbb{E} [X_{n+k}^2] + \mathbb{E} [X_n^2] - 2\mathbb{E} [\mathbb{E} [X_{n+k}X_n \mid \mathcal{F}_n]] \\ &= \mathbb{E} [X_{n+k}^2] + \mathbb{E} [X_n^2] - 2\mathbb{E} [X_n \cdot \mathbb{E} [X_{n+k} \mid \mathcal{F}_n]] \end{aligned}$$

Ahora, $\mathbb{E} [X_{n+k} \mid \mathcal{F}_n] = \mathbb{E} [\mathbb{E} [X_{n+k} \mid \mathcal{F}_{n+k-1}] \mid \mathcal{F}_n] \geq \mathbb{E} [X_{n+k-1} \mid \mathcal{F}_n]$. Iterando k veces, tenemos que $\mathbb{E} [X_j \mid \mathcal{F}_k] \geq X_k$ para todo $j > k$. Por tanto,

$$\|X_{n+k} - X_n\|_2^2 \leq \mathbb{E} [X_{n+k}^2] + \mathbb{E} [X_n^2] - 2\mathbb{E} [X_n^2] = \mathbb{E} [X_{n+k}^2] - \mathbb{E} [X_n^2].$$

Entonces, deducimos que

i. La sucesión $(\|X_n\|_2)_{n \in \mathbb{N}}$ es creciente.

ii. $\|X_n\|_2 \nearrow \sup_{n \in \mathbb{N}} \|X_n\|_2$.

iii. $(X_n)_{n \in \mathbb{N}}$ es una sucesión de Cauchy en $\mathcal{L}^2(\mathbb{P})$. Como $\mathcal{L}^2(\mathbb{P})$ es completo,

$$\exists X_\infty \in \mathcal{L}^2(\mathbb{P}) : X_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}^2} X_\infty \text{ con } X_\infty < \infty \text{ c.s.}$$

(b) Sea $(n_k)_{k \in \mathbb{N}}$ tal que $\|X_{n_k} - X_\infty\|_2 \leq 2^{-k}$. Sea $\varepsilon > 0$, definimos $A_k^\varepsilon = \{|X_{n_k} - X_\infty| > \varepsilon\}$.

$$\begin{aligned} \Rightarrow \sum_{k=1}^{\infty} \mathbb{P}(A_k^\varepsilon) &\stackrel{\text{Chebyshev}}{\leq} \frac{1}{\varepsilon^2} \sum_{k=1}^{\infty} \mathbb{E}[|X_{n_k} - X_\infty|^2] = \\ &\leq \frac{1}{\varepsilon^2} \sum_{k=1}^{\infty} \|X_{n_k} - X_\infty\|_2^2 \leq \frac{1}{\varepsilon^2} \sum_{k=1}^{\infty} 4^{-k} = \frac{4}{3\varepsilon^2} < \infty. \end{aligned}$$

Entonces, por el lema de Borel-Cantelli I, $\mathbb{P}\left(\limsup_{k \rightarrow \infty} A_k^\varepsilon\right) = 0 \Rightarrow X_{n_k} \xrightarrow[k \rightarrow \infty]{\text{c.s.}} X_\infty$.

(c) Tenemos que

$$\begin{aligned} \|X_{n_{k+1}} - X_{n_k}\|_1 &\leq \|X_{n_{k+1}} - X_\infty\|_1 + \|X_\infty - X_{n_k}\|_1 \\ &\leq \|X_{n_{k+1}} - X_\infty\|_2 + \|X_\infty - X_{n_k}\|_2 \\ &\leq 2^{-k-1} + 2^{-k} = 3 \cdot 2^{-k-1} \end{aligned}$$

Para cada k fijo, definimos, para $j \geq 0$, $Y_j = X_{n_k+j} - X_{n_k}$ que es una submartingala con respecto a la filtración $(\mathcal{F}_{n_k+j})_{j \in \mathbb{N}}$. Entonces, por el corolario,

$$\mathbb{P}\left(\underbrace{\left\{\omega \in \Omega : \max_{n_k \leq j < n_{k+1}} |Y_j| > \varepsilon\right\}}_{B_k^\varepsilon}\right) \leq \frac{2}{\varepsilon} \cdot \mathbb{E}[|Y_{n_k+1}|].$$

Sumando en k , tenemos que

$$\begin{aligned} \sum_{k=1}^{\infty} \mathbb{P}(B_k^\varepsilon) &\leq \frac{2}{\varepsilon} \sum_{k=1}^{\infty} \mathbb{E}[|Y_{n_{k+1}-n_k}|] = \\ &\leq \frac{2}{\varepsilon} \sum_{k=1}^{\infty} \|X_{n_{k+1}} - X_{n_k}\|_1 \leq \frac{6}{\varepsilon} \sum_{k=1}^{\infty} 2^{-k-1} = \frac{3}{2\varepsilon} < \infty. \end{aligned}$$

De nuevo por el lema de Borel-Cantelli I, $\mathbb{P}(\limsup_{k \rightarrow \infty} B_k^\varepsilon) = 0$. Entonces, si definimos $Z_k = \max_{n_k \leq j < n_{k+1}} |Y_j|$, tenemos que $Z_k \xrightarrow[k \rightarrow \infty]{\text{c.s.}} 0$.

(d) Sea $\omega \in \Omega$ tal que $X_{n_k}(\omega) \xrightarrow[k \rightarrow \infty]{} X_\infty(\omega)$ y $Z_k(\omega) \xrightarrow[k \rightarrow \infty]{} 0$.

Para cada $j \in \mathbb{N}$, podemos elegir $n_k(j)$ tal que $n_k(j) \leq j < n_{k+1}$

$$\Rightarrow |X_j(\omega) - X_\infty(\omega)| \leq$$

Como $Z_k \xrightarrow[k \rightarrow \infty]{\text{c.s.}} 0$ y $X_{n_k} \xrightarrow[k \rightarrow \infty]{\text{c.s.}} X_\infty$, entonces

$$\mathbb{P}(\{\omega : Z_k\})$$

II. Consideramos $\forall n \in \mathbb{N} : X_n \leq 0$ c.s. Sea $Y_n = e^{X_n} \geq 0$.

$$\implies \|Y_n\|_\infty \leq 1 \implies \|Y_n\|_2 \leq 1.$$

■

4.4 Aplicaciones y juegos de azar

Ejemplos 4.4.1. Sean $(X_j)_{j \in \mathbb{N}}$ una sucesión de v.a.i.i.d., definimos $S_n = \sum_{j=1}^n X_j$, entonces

[1] $\forall j \in \mathbb{N} : X_j \in \mathcal{L}^1(\mathbb{P}) \implies (S_n - n\mathbb{E}[X_1])_{n \in \mathbb{N}}$ es una martingala respecto a la filtración dada por $\mathcal{F}_n = \sigma(X_1, \dots, X_n)$.

[2] $\forall j \in \mathbb{N} : X_j \in \mathcal{L}^2(\mathbb{P}) \wedge \mathbb{E}[X_1] = 0 \implies (S_n^2 - n\mathbb{V}(X_1))_{n \in \mathbb{N}}$ es una martingala respecto a la filtración dada por $\mathcal{F}_n = \sigma(X_1, \dots, X_n)$.

Teorema 4.4.1 (Identidad de Wald). Sea $(X_j)_{j \in \mathbb{N}} \subset \mathcal{L}^1(\mathbb{P})$ una sucesión de v.a.i.i.d., $\forall n \in \mathbb{N} : S_n := \sum_{j=1}^n X_j$ y T un tiempo de parada

$$\implies \mathbb{E}[S_T] = \mathbb{E}[T] \cdot \mathbb{E}[X_1] \text{ c.s.}$$

Demostración: Definimos $Y_n = S_n - n\mathbb{E}[X_1]$. Sabemos que $(Y_n)_{n \in \mathbb{N}}$ es una martingala de media 0. Definimos

$$\forall n \in \mathbb{N} : Z_n := S_{\min\{T, n\}} - \min\{T, n\} \cdot \mathbb{E}[X_1].$$

Entonces, se tiene que $\forall n \in \mathbb{N} : T_n := \min\{T, n\}$ es un tiempo de parada (ejercicio)

Por tanto, el teorema de parada opcional garantiza que Z_n es una martingala de media 0 (ejercicio: hay que ver que $\mathbb{E}[Z_{T_{n+1}} | \mathcal{F}_{T_n}] = Z_{T_n}$).

$$\implies \mathbb{E}[Z_n] = 0 \implies \mathbb{E}[S_{\min\{T, n\}} - \min\{T, n\} \cdot \mathbb{E}[X_1]] = 0.$$

Entonces, $\forall n \in \mathbb{N} : \mathbb{E}[S_{\min\{T, n\}}] = \mathbb{E}[\min\{T, n\}] \cdot \mathbb{E}[X_1]$.

Para T acotada, hemos terminado. Si T no es acotada, entonces tenemos que $T_n \nearrow T$ y queremos probar que

$$\mathbb{E}[S_T] = \mathbb{E}\left[\lim_{n \rightarrow \infty} S_{\min\{T, n\}}\right] = \lim_{n \rightarrow \infty} \mathbb{E}[\min\{T, n\}] \mathbb{E}[X_1] \stackrel{\text{TCM}}{=} \mathbb{E}[T] \cdot \mathbb{E}[X_1].$$

Por el TCD, basta ver que $\forall n \in \mathbb{N} : \mathbb{E} [|S_{\min\{T,n\}}|] \leq \mathbb{E} [T] \cdot \mathbb{E} [|X_1|]$ c.s.

$$\begin{aligned}
S_{\min\{T,n\}} = \sum_{j=1}^{\min\{T,n\}} |X_j| &\implies \mathbb{E} [|S_{\min\{T,n\}}|] \leq \sum_{j=1}^n \mathbb{E} \left[\sum_{k=1}^j |X_k| \cdot \mathbb{1}_{T=j} \right] = \sum_{j=1}^n \mathbb{E} [|X_j| \cdot \mathbb{1}_{\{T \geq j\}}] = \\
&\leq \sum_{j=1}^n \mathbb{E} [\mathbb{1}_{\{T \geq j\}} \cdot \mathbb{E} [|X_j| \mid \mathcal{F}_{j-1}]] = \\
&\stackrel{\uparrow \text{ indep}}{\leq} \mathbb{E} [|X_1|] \sum_{j=1}^n \mathbb{P}(T \geq j) \leq \mathbb{E} [|X_1|] \cdot \mathbb{E} [T]
\end{aligned}$$

$$|S_{\min\{T,n\}}| \leq \sum_{j=1}^n \sum_{k=1}^j |X_k| \cdot \mathbb{1}_{T=j} = \sum_{j=1}^n |X_j| \cdot \mathbb{1}_{\{T \geq j\}} = \sum_{j=1}^n |X_j| \cdot \mathbb{1}_{\{T \geq j\}} \leq \sum_{j=1}^{\infty} |X_j| \cdot \mathbb{1}_{\{T \geq j\}}.$$

Como $\sum_{j=1}^{\infty} |X_j| \cdot \mathbb{1}_{\{T \geq j\}} \in \mathcal{L}^1(\mathbb{P})$, entonces al aplicar el TCD se completa la prueba. ■

Ejercicio 4.4.2 (Ruleta). Jugamos a un juego con probabilidad $p \in (0, 1)$ de ganar 1 euro o perderlo, el jugador empieza con J euros y la banca tiene B euros. Calcula la probabilidad de que el jugador se arruine.

Solución: Definimos $S_n = \sum_{j=1}^n X_j$ y consideramos el tiempo de parada

$$T := \inf \{j \in \mathbb{N} : S_j \leq -J \vee S_j \geq B\} \quad (\text{con } \inf \emptyset = \infty).$$

Dividimos el espacio muestral en tres partes disjuntas:

5. Comportamiento a largo plazo

5.1 Leyes de los grandes números

Teorema 5.1.1 (Ley débil de los grandes números). Sean $(X_j)_{j \in \mathbb{N}} \subset \mathcal{L}^1(\mathbb{P})$ v.a.i.i.d.

$$\implies \frac{S_n}{n} \xrightarrow[n \rightarrow \infty]{\mathcal{L}^1} \mathbb{E}[X_1] \quad \text{donde} \quad S_n = \sum_{j=1}^n X_j.$$

Demostración: Vamos a dividir la demostración en dos pasos:

1. Para $X \in \mathcal{L}^2(\mathbb{P})$, por el Corolario 2.2.3. se tiene que

$$\left\| \frac{S_n}{n} - \mathbb{E}[X_1] \right\|_1 \leq \left\| \frac{S_n}{n} - \mathbb{E}[X_1] \right\|_2 = \frac{1}{n} \sqrt{\mathbb{V}(S_n)}.$$

Ahora bien, como las X_j son independientes, por la Proposición 2.1.5, tenemos que $\mathbb{V}(S_n) = \sum_j \mathbb{V}(X_j) = n \cdot \mathbb{V}(X_1)$, por lo que

$$\left\| \frac{S_n}{n} - \mathbb{E}[X_1] \right\|_1 \leq \frac{1}{n} \sqrt{n \cdot \mathbb{V}(X_1)} = \frac{1}{\sqrt{n}} \sqrt{\mathbb{V}(X_1)} \xrightarrow[n \rightarrow \infty]{} 0.$$

2. Para $X \in \mathcal{L}^1(\mathbb{P})$, definimos $\forall N \in \mathbb{N} : X_{j,N} = X_j \cdot \mathbb{1}_{\{|X_j| \leq N\}} \wedge S_{n,N} = \sum_{j=1}^n X_{j,N}$.

Entonces, por la desigualdad de Minkowski, obtenemos que

$$\left\| \frac{S_n}{n} - \mathbb{E}[X_1] \right\|_1 \leq \underbrace{\left\| \frac{S_n}{n} - \frac{S_{n,N}}{n} \right\|_1}_{\text{(I)}} + \underbrace{\left\| \frac{S_{n,N}}{n} - \mathbb{E}[X_{1,N}] \right\|_1}_{\text{(II)}} + \underbrace{\left\| \mathbb{E}[X_{1,N}] - \mathbb{E}[X_1] \right\|_1}_{\text{(III)}}.$$

Ahora bien, como $\forall j, N \in \mathbb{N} : X_{j,N} \in \mathcal{L}^\infty(\mathbb{P})$, por el paso 1 se tiene que

$$\text{(II)} = \left\| \frac{S_{n,N}}{n} - \mathbb{E}[X_{1,N}] \right\|_1 \xrightarrow[n \rightarrow \infty]{} 0.$$

Por el teorema de convergencia dominada, $\text{(III)} = \left\| \mathbb{E}[X_{1,N}] - \mathbb{E}[X_1] \right\|_1 \xrightarrow[N \rightarrow \infty]{} 0$.

Por tanto, basta controlar el primer sumando de la desigualdad anterior:

$$\begin{aligned} \text{(I)} &= \left\| \frac{S_n}{n} - \frac{S_{n,N}}{n} \right\|_1 = \frac{1}{n} \int_{\Omega} \left| \sum_{j=1}^n X_j \mathbb{1}_{\{|X_j| > N\}} \right| d\mathbb{P} \leq \frac{1}{n} \sum_{j=1}^n \int_{\Omega} |X_j| \mathbb{1}_{\{|X_j| > N\}} d\mathbb{P} \\ &\leq \int_{\Omega} |X_1| \mathbb{1}_{\{|X_1| > N\}} d\mathbb{P} \xrightarrow[N \rightarrow \infty]{} 0 \quad \text{por el TCD.} \end{aligned}$$

■

Teorema 5.1.2 (Ley fuerte de los grandes números). Sean $(X_j)_{j \in \mathbb{N}} \subset \mathcal{L}^1(\mathbb{P})$ v.a.i.i.d.

$$\implies \frac{S_n}{n} \xrightarrow[n \rightarrow \infty]{c.s.} \mathbb{E}[X_1] \quad \text{donde} \quad S_n = \sum_{j=1}^n X_j.$$

Demostración: Vamos a dividir la demostración en varios pasos:

1. Primero truncamos las X_j : definimos $Y_k := X_k \cdot \mathbb{1}_{\{|X_k| \leq k\}} \wedge T_n := \sum_{k=1}^n Y_k$

$$\implies \sum_{k=1}^{\infty} \mathbb{P}(X_k \neq Y_k) = \sum_{k=1}^{\infty} \mathbb{P}(|X_k| > k) \leq \sum_{k=1}^{\infty} \mathbb{P}(|X_k| \geq k) \stackrel{\text{H2:10}}{\leq} \mathbb{E}[|X|] = \|X_1\|_1 < \infty.$$

Entonces, por el lema de Borel-Cantelli I, $\mathbb{P}\left(\limsup_{k \rightarrow \infty} \{X_k \neq Y_k\}\right) = 0$ y, por tanto, para casi todo $\omega \in \Omega$ se tiene que $X_k(\omega) \neq Y_k(\omega)$ en un número finito de ocasiones.

$$\implies \sum_{k=1}^n \frac{X_k(\omega) - Y_k(\omega)}{n} \xrightarrow[n \rightarrow \infty]{} 0 \implies \frac{S_n(\omega)}{n} - \frac{T_n(\omega)}{n} \xrightarrow[n \rightarrow \infty]{} 0 \quad \text{c.s.}$$

Por tanto, para probar el teorema, basta ver que $\frac{T_n}{n} \xrightarrow[n \rightarrow \infty]{c.s.} \mathbb{E}[X_1]$.

2. Se tiene que $\forall y \geq 0 : 2y \sum_{k \geq y} \frac{1}{k^2} \leq 4$ (ejercicio).

3. Veamos cómo controlar la suma de las varianzas. Primero acotamos $\mathbb{V}(Y_k)$:

$$\mathbb{V}(Y_k) \leq \mathbb{E}[|Y_k|^2] \stackrel{\text{H2:9}}{\leq} 2 \int_0^{\infty} t \cdot \mathbb{P}(|Y_k| > t) dt \leq \int_0^k 2t \cdot \mathbb{P}(|X_1| > t) dt. \quad (5.1)$$

Ahora podemos usar esta cota para controlar $\sum_k \mathbb{V}(Y_k)/k^2$:

$$\begin{aligned} \sum_{k=1}^{\infty} \frac{1}{k^2} \mathbb{V}(Y_k) &\stackrel{(5.1)}{\leq} \sum_{k=1}^{\infty} \frac{1}{k^2} \int_0^k 2t \cdot \mathbb{P}(|X_1| > t) dt \stackrel{\text{Fubini}}{\leq} \int_0^{\infty} \sum_{k \geq t} \frac{2t}{k^2} \cdot \mathbb{P}(|X_1| > t) dt = \\ &\leq \int_0^{\infty} \mathbb{P}(|X_1| > t) \left[2t \sum_{k \geq t} \frac{1}{k^2} \right] dt \stackrel{2}{\leq} 4 \int_0^{\infty} \mathbb{P}(|X_1| > t) dt \stackrel{\text{H2:9}}{\leq} 4 \cdot \mathbb{E}[|X_1|]. \end{aligned}$$

4. Basta demostrar el resultado suponiendo que $\forall k \in \mathbb{N} : Y_k \geq 0$ y luego aplicarlo a Y_k^+ y a Y_k^- por separado para probar el caso general (ejercicio).

5. Sea $\alpha > 1$, definimos $k(n) = \lfloor \alpha^n \rfloor$ y sea $\varepsilon > 0$.

$$\implies \sum_{n=1}^{\infty} \mathbb{P}(|T_{k(n)} - \mathbb{E}[T_{k(n)}]| > \varepsilon \cdot k(n)) \stackrel{\text{Chebyshev}}{\leq} \sum_{n=1}^{\infty} \frac{\mathbb{V}(T_{k(n)})}{\varepsilon^2 k(n)^2}.$$

Como las X_j son independientes, las Y_j también lo son y, por tanto,

$$\begin{aligned} \sum_{n=1}^{\infty} \mathbb{P}(|T_{k(n)} - \mathbb{E}[T_{k(n)}]| > \varepsilon \cdot k(n)) &\stackrel{2.1.5}{\leq} \sum_{n \in \mathbb{N}} \frac{1}{\varepsilon^2 k(n)^2} \sum_{j=1}^{k(n)} \mathbb{V}(Y_j) = \\ &\stackrel{\text{Fubini}}{\leq} \frac{1}{\varepsilon^2} \sum_{j=1}^{\infty} \mathbb{V}(Y_j) \sum_{n \cdot k(n) > j} \frac{1}{k(n)^2}. \end{aligned}$$

Ahora bien, como $k(n) = \lfloor \alpha^n \rfloor$, se tiene que $\sum_{n \cdot k(n) > j} \frac{1}{k(n)^2} \sim \sum_{n \cdot \alpha^n > j} \frac{1}{\alpha^{2n}} \sim j^{-2}$.

$$\Rightarrow \sum_{n=1}^{\infty} \mathbb{P}(|T_{k(n)} - \mathbb{E}[T_{k(n)}]| > \varepsilon \cdot k(n)) \sim \frac{1}{\varepsilon^2} \sum_{j=1}^{\infty} \frac{\mathbb{V}(Y_j)}{j^2} \stackrel{\uparrow 3}{\leq} \frac{4}{\varepsilon^2} \cdot \|X_1\|_1 < \infty.$$

Entonces, por Borel-Cantelli II, $\mathbb{P}\left(\limsup_{n \rightarrow \infty} \{|T_{k(n)} - \mathbb{E}[T_{k(n)}]| > \varepsilon \cdot k(n)\}\right) = 0$.

6. Por el teorema de la convergencia dominada, $\frac{\mathbb{E}[T_{k(n)}]}{k(n)} \xrightarrow{n \rightarrow \infty} \mathbb{E}[X_1]$ (ejercicio).

7. Por 6, $\frac{T_{k(n)}}{k(n)} \xrightarrow[n \rightarrow \infty]{\text{c.s.}} \mathbb{E}[X_1]$. Sea ahora $m \in \mathbb{N} : k(n) \leq m \leq k(n+1)$, entonces, como

$$\forall k \in \mathbb{N} : Y_k \geq 0, \text{ se tiene que } \frac{T_{k(n)}}{k(n+1)} \leq \frac{T_m}{m} \leq \frac{T_{k(n+1)}}{k(n)}.$$

$$\Rightarrow \lim_{n \rightarrow \infty} \frac{T_{k(n)}}{k(n+1)} = \lim_{n \rightarrow \infty} \frac{k(n)}{k(n+1)} \cdot \frac{T_{k(n)}}{k(n)} = \lim_{n \rightarrow \infty} \frac{k(n)}{k(n+1)} \cdot \lim_{n \rightarrow \infty} \frac{T_{k(n)}}{k(n)} \stackrel{6}{=} \frac{1}{\alpha} \cdot \mathbb{E}[X_1] \text{ c.s.}$$

De la misma forma, $\lim_{n \rightarrow \infty} \frac{T_{k(n+1)}}{k(n)} = \alpha \cdot \mathbb{E}[X_1]$ c.s. Por lo tanto,

$$\forall \alpha > 1 : \frac{\mathbb{E}[X_1]}{\alpha} \leq \lim_{m \rightarrow \infty} \frac{T_m}{m} \leq \alpha \cdot \mathbb{E}[X_1] \text{ c.s.}$$

Haciendo α tender a 1^+ , se tiene que $\lim_{m \rightarrow \infty} \frac{T_m}{m} = \mathbb{E}[X_1]$ c.s. y hemos terminado. ■

Observación 5.1.1. A pesar de los nombres, la ley fuerte de los grandes números no implica la ley débil de los grandes números ya que, como vimos en el Tema 3, la convergencia casi segura no implica la convergencia en $\mathcal{L}^p$ en general.

5.2 Teorema central del límite

Teorema 5.2.1 (central del límite). Sean $(X_j)_{j \in \mathbb{N}} \subset \mathcal{L}^2(\mathbb{P})$ v.a.i.i.d.

$$\implies \frac{S_n - n \cdot \mathbb{E}[X_1]}{\sqrt{n} \sqrt{\mathbb{V}(X_1)}} \xrightarrow[n \rightarrow \infty]{d} Z \quad \text{con} \quad \forall t \in \mathbb{R} : f_Z(t) = \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}.$$

Definición 5.2.1 (Función característica). Sea X una variable aleatoria,

$$\varphi_X \text{ es su función característica} \iff \forall t \in \mathbb{R} : \varphi_X(t) = \mathbb{E}[e^{itX}].$$

Por la Proposición 2.1.1, sabemos que $\varphi_X(t) = \int_{\mathbb{R}} e^{its} d\mu_X(s)$. Luego si X es absolutamente continua, $\varphi_X(t) = \int_{\mathbb{R}} e^{its} f_X(s) ds$.

Además, $\varphi_X(t)$ está bien definida para todo $t \in \mathbb{R}$ y para todo $X < \infty$ c.s.:

$$|\varphi_X(t)| = |\mathbb{E}[e^{itX}]| \leq \mathbb{E}[|e^{itX}|] = \mathbb{E}[1] = 1 \implies \forall t \in \mathbb{R} : e^{itX} \in \mathcal{L}^1(\mathbb{P}).$$

Observación 5.2.2. La ley de grandes números nos dice que el promedio de los resultados del mismo experimento se estabiliza en el valor esperado, mientras que el teorema central del límite, al dividir S_n entre su desviación típica, normaliza el promedio y nos permite hablar de una distribución.

Podemos apreciar esta diferencia si calculamos la varianza de la variable aleatoria de la que tomamos el límite en cada caso. Para la ley de grandes números, tenemos que

$$\mathbb{V}\left(\frac{1}{n} \sum_{j=1}^n X_j\right) = \frac{1}{n^2} \mathbb{V}\left(\sum_{j=1}^n X_j\right) \stackrel{\text{indep}}{=} \frac{1}{n^2} \cdot n \mathbb{V}(X_1) = \frac{\mathbb{V}(X_1)}{n} \xrightarrow[n \rightarrow \infty]{} 0.$$

Es decir, al dividir por n , la varianza tiende a 0, lo significa que estamos aplastando la distribución de la variable aleatoria hacia un punto, que es el valor esperado.

En cambio, para el teorema central del límite, tenemos que

$$\begin{aligned} \mathbb{V}\left(\frac{S_n - n \cdot \mathbb{E}[X_1]}{\sqrt{n} \sqrt{\mathbb{V}(X_1)}}\right) &= \mathbb{V}\left(\frac{1}{\sqrt{n} \sqrt{\mathbb{V}(X_1)}} \sum_{j=1}^n X_j\right) \\ &= \frac{1}{n \mathbb{V}(X_1)} \cdot \mathbb{V}\left(\sum_{j=1}^n X_j\right) \stackrel{\text{indep}}{=} \frac{1}{n \mathbb{V}(X_1)} \cdot n \mathbb{V}(X_1) = 1 \end{aligned}$$

Es decir, al dividir por $\sqrt{n}$, la varianza se mantiene constante y no tiende a 0, lo que significa que la distribución de la variable aleatoria no se aplasta hacia un punto, sino

converge a una distribución.

Teorema 5.2.2. Sea $u: \mathbb{R} \rightarrow \mathbb{C}$ dada por $u(t) = \int_X f(t, s) d\mu(s)$ donde $f: \mathbb{R} \times X \rightarrow \mathbb{C}$ es una función medible y μ es una medida en X . Supongamos que:

- (i) $\int_X |f(t, s)| d\mu(s) < \infty$ para todo $t \in \mathbb{R}$.
- (ii) $\forall s \in X : \exists \frac{\partial}{\partial t} f(t, s): \mathbb{R} \rightarrow \mathbb{R}$ continua en $t_0 \in \mathbb{R}$.
- (iii) $\exists \delta > 0 : \int_X \int_{-\delta}^{\delta} \left| \frac{\partial}{\partial t} f(t + \theta, s) \right| d\theta d\mu(s) < \infty$.

$$\implies u'(t_0) = \int_X \frac{\partial}{\partial t} \Big|_{t_0} f(t, s) d\mu(s).$$

Lema 5.2.3. Sea Z una variable aleatoria con distribución normal de media 0 y varianza 1

$$\implies \forall t \in \mathbb{R} : \varphi_Z(t) = e^{-\frac{t^2}{2}}.$$

Lema 5.2.4. Sea $X \in \mathcal{L}^2(\mathbb{P}) \implies \varphi_X(t) = 1 + i \mathbb{E}[X] t - \frac{1}{2} \mathbb{E}[X^2] t^2 + o(t^2)$.

Teorema 5.2.5 (de continuidad de Lévy). Sean $(X_n)_n$ variables aleatorias, entonces

$$X_n \xrightarrow[n \rightarrow \infty]{d} X \iff \forall t \in \mathbb{R} : \varphi_{X_n}(t) \xrightarrow[n \rightarrow \infty]{} \varphi_X(t).$$

H. Hojas de ejercicios

H.0 Repaso de teoría de la medida

1. Define con precisión los siguientes conceptos:

- | | |
|------------------------------------|---|
| (a) σ -álgebra. | (g) Función simple. |
| (b) σ -álgebra de Borel. | (h) Función integrable. |
| (c) σ -álgebra de Lebesgue. | (i) Integral de una función integrable. |
| (d) Medida. | (j) Espacio de medida producto. |
| (e) Espacio de medida. | (k) Medida absolutamente continua. |
| (f) Función medible. | (l) Medidas mutuamente singulares. |

Solución:

Definición H.0.1 (σ -álgebra). Sea $X \neq \emptyset$, $\Sigma \subset \mathcal{P}(X)$ es una σ -álgebra de $X \iff$

- (a) $X \in \Sigma$
- (b) $E \in \Sigma \implies E^c = X \setminus E \in \Sigma$
- (c) $\{E_n\}_{n=1}^{\infty} \subset \Sigma \implies \bigcup_{n=1}^{\infty} E_n \in \Sigma$

Definición H.0.2 (σ -álgebra de Borel). Sea $(X, \mathcal{T})$ un espacio topológico, $\mathcal{B}(X)$ es la σ -álgebra de Borel de X

$$\iff \mathcal{B}(X) \text{ es la } \sigma\text{-álgebra generada por } \mathcal{T} \iff \mathcal{B}(X) = \sigma(\mathcal{T}).$$

Definición H.0.3 (Medida exterior de Lebesgue). $m^*: \mathcal{P}(\mathbb{R}^d) \longrightarrow [0, \infty]$ es la medida exterior de Lebesgue en $\mathbb{R}^n$

$$\iff \forall E \subset \mathbb{R}^d : m^*(E) = \inf \left\{ \sum_{n=1}^{\infty} \text{vol}(Q_n) : Q_n \text{ cubo cerrado } \wedge E \subset \bigcup_{n=1}^{\infty} Q_n \right\}$$

Definición H.0.4 (Conjunto medible). Sea μ^* una medida exterior en $X \neq \emptyset$, $E \subset X$ es μ^* -medible $\iff \forall A \subset X : \mu^*(A) = \mu^*(A \cap E) + \mu^*(A \cap E^c)$.

La familia de conjuntos μ^* -medibles se denota por $\mathcal{A}^*$.

Definición H.0.5 (σ -álgebra de Lebesgue). Sea $m^*: \mathcal{P}(\mathbb{R}^d) \longrightarrow [0, \infty]$ la medida exterior de Lebesgue en $\mathbb{R}^d$, $\mathcal{L}$ es la σ -álgebra de Lebesgue en $\mathbb{R}^d$

$$\Longleftrightarrow \mathcal{L} = \{E \subset \mathbb{R}^d : E \text{ es } m^*\text{-medible}\}.$$

Definición H.0.6 (Medida). Sea $\Sigma \subset \mathcal{P}(X)$ una σ -álgebra de un conjunto $X \neq \emptyset$, una aplicación $\mu: \Sigma \longrightarrow [0, \infty]$ es una medida en $\Sigma \Longleftrightarrow$

(a) $\mu(\emptyset) = 0$.

(b) Aditividad: $\{E_k\}_{k \in \mathbb{N}} \subset \Sigma$ disjuntos dos a dos $\implies \mu\left(\bigsqcup_{n=1}^{\infty} E_n\right) = \sum_{n=1}^{\infty} \mu(E_n)$.

Definición H.0.7 (Espacio medible). Sean $X \neq \emptyset$, (X, Σ) es un espacio medible

$$\Longleftrightarrow \Sigma \text{ es una } \sigma\text{-álgebra de } X.$$

Definición H.0.8 (Espacio de medida). (X, Σ, μ) es un espacio de medida $\Longleftrightarrow$

(a) (X, Σ) es un espacio medible.

(b) $\mu: \Sigma \longrightarrow [0, \infty]$ es una medida.

Definición H.0.9 (Función medible). Sea (X, Σ) un espacio medible, $f: X \longrightarrow \mathbb{R}^n$ es una función medible $\Longleftrightarrow \forall B \in \mathcal{B}(\mathbb{R}^n) : f^{-1}(B) = \{x \in X : f(x) \in B\} \in \Sigma$.

Definición H.0.10 (Función simple). Sea (X, Σ, μ) un espacio de medida, $\varphi: X \longrightarrow \mathbb{R}$ es una función simple

$$\Longleftrightarrow \left(\exists \{a_i\}_{i=1}^n \subset \mathbb{R} \wedge \exists \{E_i\}_{i=1}^n \subset \Sigma \text{ medibles bajo } \mu \right) : f = \sum_{i=1}^n a_i \mathbb{1}_{E_i}$$

Definición H.0.11 (Función integrable). Sea $f: X \longrightarrow \mathbb{R}$ una función medible en un espacio de medida (X, Σ, μ) , f es integrable respecto de μ en $E \in \Sigma$

$$\Longleftrightarrow f \in \mathcal{L}^1(\mu, E) := \left\{ g: X \longrightarrow \mathbb{R} : g \text{ es medible } \wedge \int_E |g| d\mu < \infty \right\}$$

Definición H.0.12 (Integral de fn simple). Sea $\varphi: X \longrightarrow \mathbb{R}$ una fn simple en un es-

pacio de medida (X, Σ, μ) , $I \in \mathbb{R}$ es la integral de φ respecto de μ en $E \in \Sigma$

$$\Longleftrightarrow I = \int_E \varphi \, d\mu := \sum_{i=1}^n a_i \mu(E_i) \quad \text{donde} \quad \varphi = \sum_{i=1}^n a_i \mathbb{1}_{E_i}$$

Definición H.0.13 (Integral de fn no negativa). Sea $f: X \rightarrow \mathbb{R}$ una fn medible no negativa en un espacio de medida (X, Σ, μ) , $I \in \mathbb{R}$ es la integral de f respecto de μ en $E \in \Sigma$

$$\Longleftrightarrow I = \int_E f \, d\mu := \sup \left\{ \int_E \varphi \, d\mu : \varphi \text{ simple} \wedge 0 \leq \varphi \leq f \right\}$$

Definición H.0.14 (Integral). Sea $f: X \rightarrow \mathbb{R}$ una función medible en un espacio de medida (X, Σ, μ) , $I \in \mathbb{R}$ es la integral de f respecto de μ en $E \in \Sigma$

$$\Longleftrightarrow I = \int_E f \, d\mu := \int_E f^+ \, d\mu - \int_E f^- \, d\mu \quad \text{donde} \quad f^+ = \max\{f, 0\} \wedge f^- = \max\{-f, 0\}$$

Definición H.0.15 (Medida con signo). Sea Σ una σ -álgebra de $X \neq \emptyset$, $\nu: \Sigma \rightarrow \mathbb{R}$ es una medida con signo $\Longleftrightarrow$

(a) $\nu(\emptyset) = 0$.

(b) Aditividad: $\{E_k\}_{k \in \mathbb{N}} \subset \Sigma$ disjuntos dos a dos $\implies \nu \left(\bigsqcup_{n=1}^{\infty} E_n \right) = \sum_{n=1}^{\infty} \nu(E_n)$.

(c) $\forall E \in \Sigma : |\nu(E)| < \infty$.

Definición H.0.16 (Continuidad absoluta). Sean μ medida y ν medida con signo en un espacio medible (Ω, Σ) , ν es absolutamente continua respecto a μ

$$\Longleftrightarrow \forall E \in \Sigma : \mu(E) = 0 \implies \nu(E) = 0.$$

Definición H.0.17 (Medidas mutuamente singulares). Sea (X, Σ) un espacio medible, dos medidas con signo μ y ν en Σ son mutuamente singulares

$$\Longleftrightarrow \exists E, F \in \Sigma : E \sqcup F = X \wedge E \text{ es nulo para } \nu \wedge F \text{ es nulo para } \mu.$$

Para el resto de la hoja, sea $(\Omega, \mathcal{F}, \mu)$ un espacio de medida y $(\mathbb{R}, \mathcal{B}(\mathbb{R}), m)$ la recta real con la σ -álgebra de Borel y la medida de Lebesgue.

2. Enuncia los siguientes resultados:

- (a) Teorema de la convergencia monótona. (d) Teorema de Fubini.
 (b) Teorema de la convergencia dominada. (e) Teoremas de Carathéodory.
 (c) Lema de Fatou. (f) Teorema de Radon-Nikodym.

Solución:

Teorema H.0.1 (de convergencia monótona para conjuntos). Sea (X, Σ, μ) un espacio de medida y $(E_n)_{n \in \mathbb{N}} \subset \Sigma$ una sucesión creciente (i.e. $\forall n \in \mathbb{N} : E_n \subset E_{n+1}$)

$$\implies \mu \left(\bigcup_{n=1}^{\infty} E_n \right) = \lim_{n \rightarrow \infty} \mu \left(\bigcap_{i=1}^n E_i \right) = \lim_{n \rightarrow \infty} \mu(E_n)$$

Teorema H.0.2 (de convergencia monótona para funciones). Sea (X, Σ, μ) un espacio de medida y $(f_n)_{n \in \mathbb{N}}$ una sucesión creciente de funciones medibles no negativas

$$\implies \forall E \in \Sigma : \lim_{n \rightarrow \infty} \int_E f_n d\mu = \int_E \lim_{n \rightarrow \infty} f_n d\mu$$

Teorema H.0.3 (de la convergencia dominada). Sea $(f_n)_{n \in \mathbb{N}}$ una sucesión de fns medibles en (X, Σ, μ) tal que $\exists \lim f_n =: f \wedge \exists g$ integrable : $\forall n \in \mathbb{N} : |f_n| \leq g$ ¹

$$\implies \lim_{n \rightarrow \infty} \int |f_n - f| d\mu = 0, \quad \text{en particular,} \quad \int \lim_{n \rightarrow \infty} f_n d\mu = \lim_{n \rightarrow \infty} \int f_n d\mu.$$

Lema H.0.4 (de Fatou). Sea $(f_n)_{n \in \mathbb{N}}$ una sucesión de funciones medibles no negativas en un espacio de medida (X, Σ, μ)

$$\implies \int \liminf_{n \rightarrow \infty} f_n d\mu \leq \liminf_{n \rightarrow \infty} \int f_n d\mu$$

Teorema H.0.5 (de Caratheodory I). Sea μ^* una medida exterior en $X \neq \emptyset$, entonces

- (a) $\mathcal{A}^* := \{E \subset X : E \text{ es } \mu^* \text{-medible}\}$ es una σ -álgebra.
 (b) $\mu^*|_{\mathcal{A}^*}$ es una medida completa.

Teorema H.0.6 (de Caratheodory II). Sea $X \neq \emptyset$, $\mathcal{A} \subset \mathcal{P}(X)$ un álgebra y $\mu_0 : \mathcal{A} \rightarrow [0, \infty]$ una premedida, entonces

- (a) $\mathcal{A}^*$ es una σ -álgebra que contiene a $\mathcal{A}$.

¹Se dice que g “domina” a todas las f_n .

(b) $\mu^*|_{\mathcal{A}^*}$ es una medida que extiende a μ_0 .

Teorema H.0.7 (de Radon-Nikodym). Sea (X, Σ) un espacio medible, μ una medida σ -finita y ν una medida con signo, entonces

(1) $\exists! \lambda, s$ medidas con signo : $\nu = \lambda + s$ $\wedge$ $\lambda \ll \mu$ $\wedge$ $s \perp \mu$.

(2) $\exists! f \in L^1(\mu) : \forall E \in \Sigma : \lambda(E) = \int_E f d\mu$.

[3.] Demuestra que la intersección de una familia de σ -álgebras es una σ -álgebra.

Proposición H.0.8. Sean Σ_1, Σ_2 dos σ -álgebras en un conjunto $X \neq \emptyset$

$\implies \Sigma_1 \cap \Sigma_2$ es una σ -álgebra en X .

Demostración: Comprobamos las propiedades de la Definición H.0.1:

(i) Se tiene que $X \in \Sigma = \Sigma_1 \cap \Sigma_2$ porque $X \in \Sigma_1, \Sigma_2$.

(ii) $E \in \Sigma \implies E \in \Sigma_1, \Sigma_2 \implies E^c \in \Sigma_1, \Sigma_2 \implies E^c \in \Sigma$.

(iii) Sea $\{E_n\}_{n=1}^\infty \subset \Sigma \implies \{E_n\}_{n=1}^\infty \subset \Sigma_1, \Sigma_2 \implies \bigcup_{n=1}^\infty E_n \in \Sigma_1, \Sigma_2 \implies \bigcup_{n=1}^\infty E_n \in \Sigma$.

Concluimos que $\Sigma_1 \cap \Sigma_2$ es una σ -álgebra en X . ■

[4.] Decide si la unión de dos σ -álgebras es una σ -álgebra.

[5.] Demuestra que la familia de intervalos $\{(a, b] : a < b\}$ genera $\mathcal{B}(\mathbb{R})$.

[6.] Sean $f, g : \Omega \rightarrow \mathbb{R}$ funciones medibles. Demuestra:

(a) $\max\{f, g\}$ es medible.

(b) $f + g$ es medible.

(c) Si $h : \mathbb{R} \rightarrow \mathbb{R}$ es medible, entonces $h \circ f$ es medible.

[7.] Sean $f_n : \Omega \rightarrow \mathbb{R}, n \in \mathbb{N}$, funciones medibles. Demuestra:

(a) $\inf_n f_n$ es medible.

(b) $\liminf_n f_n$ es medible.

[8.] Sea f medible. Demostrar que existe un conjunto $A \subseteq \mathcal{F}$ tal que $f^{-1}(A) \subseteq \{0\}$ y $f^{-1}(A^c) \subseteq \{0\}$. Decide si A es necesariamente único.

[9.] Sea $\{A_n\}_{n \in \mathbb{N}} \subseteq \mathcal{F}$ una colección creciente, es decir, $A_n \subseteq A_{n+1}$ para todo n . Demuestra que

$$\lim_{n \rightarrow \infty} \mu(A_n) = \mu \left(\bigcup_{n \in \mathbb{N}} A_n \right).$$

[10.] Sea $\{B_n\}_{n \in \mathbb{N}} \subseteq \mathcal{F}$ una colección decreciente, es decir, $B_{n+1} \subseteq B_n$ para todo n .

(a) Si existe k tal que $\mu(B_k) < \infty$, demuestra que

$$\lim_{n \rightarrow \infty} \mu(B_n) = \mu \left(\bigcap_{n \in \mathbb{N}} B_n \right).$$

(b) Si no existe ese valor de k , demuestra que la fórmula de arriba puede ser falsa.

[11.] Demuestra que si $f \geq 0$ y además $\int f d\mu = 0$, entonces $f(x) = 0$ en casi todo punto.

[12.] Demuestra que si $f \geq 0$ es una función medible, la fórmula

$$\nu(A) = \int_A f d\mu, \quad A \in \mathcal{F},$$

define una medida sobre $\mathcal{F}$.

[13.] Demuestra el lema de Fatou usando el teorema de la convergencia monótona.

Ejercicio H.0.1. Demuestra que para Σ una σ -álgebra no finita $\implies \Sigma$ es no numerable.

H.1 Espacios de probabilidad

En todos los ejercicios, $(\Omega, \mathcal{F}, \mathbb{P})$ es un espacio de probabilidad.

H.1.1 Ejercicios básicos

1. (Principio de inclusión-exclusión) Sea $\{A_j\}_{j=1}^n \subset \mathcal{F}$. Demostrar

$$\begin{aligned} \mathbb{P}\left(\bigcup_{j=1}^n A_j\right) &= \sum_{j=1}^n \mathbb{P}(A_j) - \sum_{i < j} \mathbb{P}(A_i \cap A_j) + \sum_{i < j < k} \mathbb{P}(A_i \cap A_j \cap A_k) - \cdots + (-1)^{n-1} \mathbb{P}\left(\bigcap_{j=1}^n A_j\right) \\ &= \sum_{m=1}^n (-1)^{m-1} \sum_{\substack{I \subset \mathbb{N}_n \\ |I|=m}} \mathbb{P}\left(\bigcap_{j \in I} A_j\right). \end{aligned}$$

Solución: Observamos que para $n = 1$ se cumple trivialmente. Para $n = 2$ podemos expresar $A_1 \cup A_2$ como la unión de sus partes disjuntas: $A_1 \setminus A_2$, $A_1 \cap A_2$ y $A_2 \setminus A_1$

$$\begin{aligned} \implies \mathbb{P}(A_1 \cup A_2) + \mathbb{P}(A_1 \cap A_2) &= \mathbb{P}(A_1 \setminus A_2) + \mathbb{P}(A_2 \setminus A_1) + 2\mathbb{P}(A_1 \cap A_2) \\ &= \mathbb{P}(A_1 \setminus A_2 \sqcup A_1 \cap A_2) + \mathbb{P}(A_2 \setminus A_1 \sqcup A_1 \cap A_2) \\ &= \mathbb{P}(A_1) + \mathbb{P}(A_2). \end{aligned}$$

Luego despejando obtenemos $\mathbb{P}(A_1 \cup A_2) = \mathbb{P}(A_1) + \mathbb{P}(A_2) - \mathbb{P}(A_1 \cap A_2)$.

Supongamos por inducción que se cumple para $n \in \mathbb{N}$ arbitrario, entonces para $n + 1$:

$$\begin{aligned} \mathbb{P}\left(\bigcup_{j=1}^{n+1} A_j\right) &= \mathbb{P}\left(A_{n+1} \cup \bigcup_{j=1}^n A_j\right) \stackrel{\text{caso } n=2}{=} \mathbb{P}(A_{n+1}) + \mathbb{P}\left(\bigcup_{j=1}^n A_j\right) - \mathbb{P}\left(A_{n+1} \cap \bigcup_{j=1}^n A_j\right) \\ &\stackrel{\text{caso inductivo}}{=} \mathbb{P}(A_{n+1}) + \sum_{m=1}^n (-1)^{m-1} \sum_{\substack{I \subset \mathbb{N}_n \\ |I|=m}} \mathbb{P}\left(\bigcap_{j \in I} A_j\right) - \mathbb{P}\left(A_{n+1} \cap \bigcap_{j \in I} A_j\right) \\ &= \sum_{m=1}^{n+1} (-1)^{m-1} \sum_{\substack{I \subset \mathbb{N}_{n+1} \\ |I|=m}} \mathbb{P}\left(\bigcap_{j \in I} A_j\right). \end{aligned}$$

Por el principio de inducción, se cumple para todo $n \in \mathbb{N}$. ■

2. (Desigualdades de Bonferroni) Sea $\{A_j\}_{j=1}^n \subset \mathcal{F}$. Demostrar

$$(a) \quad \mathbb{P}\left(\bigcup_{j=1}^n A_j\right) \leq \sum_{j=1}^n \mathbb{P}(A_j).$$

$$(b) \quad \mathbb{P}\left(\bigcup_{j=1}^n A_j\right) \geq \sum_{j=1}^n \mathbb{P}(A_j) - \sum_{i < j} \mathbb{P}(A_i \cap A_j).$$

$$(c) \mathbb{P}\left(\bigcup_{j=1}^n A_j\right) \leq \sum_{j=1}^n \mathbb{P}(A_j) - \sum_{i < j} \mathbb{P}(A_i \cap A_j) + \sum_{i < j < k} \mathbb{P}(A_i \cap A_j \cap A_k).$$

(d) ...

Solución:

(a)

3. Sean X e Y v.a. Sea $A \in \mathcal{F}$. Definimos

$$Z(\omega) = \begin{cases} X(\omega), & \omega \in A, \\ Y(\omega), & \omega \in A^c. \end{cases}$$

Demostrar que Z es una v.a.

Solución: Basta ver que Z es una función medible, es decir que $\forall E \in \mathcal{B}(\mathbb{R}) : Z^{-1}(E) \in \mathcal{F}$.

Sea $E \in \mathcal{B}(\mathbb{R})$, entonces

$$\begin{aligned} Z^{-1}(E) &\stackrel{\text{def}}{=} \{\omega \in \Omega : Z(\omega) \in E\} = \{\omega \in A : X(\omega) \in E\} \cup \{\omega \in A^c : Y(\omega) \in E\} \\ &= A \cap X^{-1}(E) \cup A^c \cap Y^{-1}(E). \end{aligned}$$

Como $\mathcal{F}$ es σ -álgebra, $A^c \in \mathcal{F}$ y como X e Y son variables aleatorias, $X^{-1}(E), Y^{-1}(E) \in \mathcal{F}$.

Por lo tanto, $Z^{-1}(E) \in \mathcal{F}$. ■

4. Decide si la siguiente afirmación es cierta. $X : \Omega \rightarrow \mathbb{R}$ e $Y : \Omega \rightarrow \mathbb{R}$ son variables aleatorias si y solo si $X + Y$ lo es.

Solución: Es falsa, basta considerar $X = \mathbb{1}_{\mathcal{C}}$ en el esp de probabilidad $([0, 1], \mathcal{B}([0, 1]), m)$ donde $\mathcal{C}$ es el conjunto de Cantor e $Y = -X$. Entonces $X + Y = 0$ que sí es una variable aleatoria, pero ni X ni Y lo son porque $\mathcal{C}$ no es medible ($\mathcal{C} \notin \mathcal{B}([0, 1])$).

En la otra dirección la afirmación sí es cierta porque la suma de funciones medibles es medible (??).

5. Enunciar y demostrar:

(a) La fórmula de la probabilidad total.

(b) La regla de Bayes.

Solución:

(a) Se puede encontrar en Teorema 1.3.1.

(b) Se puede encontrar en Teorema 1.3.2.

6. Probar que si A y B son independientes, también lo son A y B^c , A^c y B , y A^c y B^c .

Solución:

- (a) $\mathbb{P}(A \cap B^c) = \mathbb{P}(A) - \mathbb{P}(A \cap B) \stackrel{\text{indep}}{=} \mathbb{P}(A) - \mathbb{P}(A) \cdot \mathbb{P}(B) = \mathbb{P}(A) (1 - \mathbb{P}(B)) = \mathbb{P}(A) \cdot \mathbb{P}(B^c).$
- (b) De forma completamente análoga al apartado anterior, $\mathbb{P}(A^c \cap B) = \mathbb{P}(A^c) \cdot \mathbb{P}(B).$
- (c) $\mathbb{P}(A^c \cap B^c) = \mathbb{P}(A^c) - \mathbb{P}(A^c \cap B) \stackrel{\uparrow}{=} \mathbb{P}(A^c) - \mathbb{P}(A^c) \cdot \mathbb{P}(B) = \mathbb{P}(A^c) \cdot \mathbb{P}(B^c).$
(b)

7. Sean $A, B \in \mathcal{F}$.

- (a) Probar que A y B son independientes si y solo si $\mathbb{1}_A$ y $\mathbb{1}_B$ son independientes.
- (b) Probar que si $\{A_j\}_{j=1}^n \subset \mathcal{F}$ son independientes, entonces $\{\mathbb{1}_{A_j}\}_{j=1}^n$ son independientes.

Solución:

- (a) Como $X = \mathbb{1}_A$ e $Y = \mathbb{1}_B$ solo toman valores en $\{0, 1\}$, se tiene que $\forall E_1, E_2 \in \mathcal{B}(\mathbb{R}) :$
 $\{\mathbb{1}_A \in E_1\}, \{\mathbb{1}_B \in E_2\} \in \{\emptyset, A, A^c, \Omega\}, \{\emptyset, B, B^c, \Omega\}$ respectivamente.

Como ya sabemos del ejercicio anterior que A y B son independientes $\iff A$ y B^c , A^c y B , A^c y B^c son independientes y $\emptyset$ y Ω son trivialmente independientes, se tiene que $\mathbb{1}_A$ y $\mathbb{1}_B$ son independientes $\iff A$ y B lo son. ■

8. Sean A, B, C, D, E sucesos independientes. Probar o refutar las afirmaciones siguientes:

- (a) Los sucesos $A \cap B$ y $C^c \cup (D \cap E^c)$ son independientes.
- (b) $A \cup B$ y $A \cap C$ son independientes.
- (c) $\mathbb{P}(A \cap B \mid C) = \mathbb{P}(A \mid C) \cdot \mathbb{P}(B \mid C)$ (se supone que $\mathbb{P}(C) > 0$).

Solución:

- (a) Sean los π -sistemas $\Pi_1 = \{A, B, A \cap B\}$ y $\Pi_2 = \{C, D, E, C \cap D, C \cap E, D \cap E\}$, son independientes por serlo A, B, C, D, E . Entonces, por la Proposición 1.4.4, $\sigma(\Pi_1)$ y $\sigma(\Pi_2)$ son independientes. Como $A \cap B \in \sigma(\Pi_1)$ y $C^c \cup (D \cap E^c) \in \sigma(\Pi_2)$, se tiene que son independientes. ■

- (b) Observamos que $(A \cup B) \cap (A \cap C) = (A \cap C) \cup (A \cap B \cap C) = A \cap C$ luego

$$\mathbb{P}((A \cup B) \cap (A \cap C)) = \mathbb{P}(A \cap C)$$

que es distinto de $\mathbb{P}(A \cup B) \cdot \mathbb{P}(A \cap C)$ para $\mathbb{P}(A \cup B) \neq 1$. Por ejemplo, consideramos $\Omega = \mathbb{N}_8$ con $\forall j \in \mathbb{N}_8 : \mathbb{P}(\{j\}) = 1/8$ y $A = \{1, 2, 3, 4\}$, $B = \{1, 2, 5, 6\}$, $C = \{1, 3, 5, 7\}$,

entonces A, B, C son independientes porque

$$\mathbb{P}(A \cap B \cap C) \mathbb{P}(\{1\}) = \frac{1}{8} = \left(\frac{1}{2}\right)^3 = \mathbb{P}(A) \cdot \mathbb{P}(B) \cdot \mathbb{P}(C).$$

Sin embargo, $\mathbb{P}((A \cup B) \cap (A \cap C)) = \mathbb{P}(A \cap C) = \mathbb{P}(\{1, 3\}) = 1/4$ y

$$\mathbb{P}(A \cup B) \cdot \mathbb{P}(A \cap C) = \mathbb{P}(\{1, 2, 3, 4, 5, 6\}) \cdot \mathbb{P}(A \cap C) = \frac{3}{4} \cdot \frac{1}{4} = \frac{3}{16} \neq \frac{1}{4}.$$

(c) Al condicionar por un suceso independiente no se altera la probabilidad:

$$\begin{aligned} \mathbb{P}(A \cap B \mid C) &= \frac{\mathbb{P}(A \cap B \cap C)}{\mathbb{P}(C)} = \frac{\mathbb{P}(A) \cdot \mathbb{P}(B) \cdot \mathbb{P}(C)}{\mathbb{P}(C)} = \mathbb{P}(A) \cdot \mathbb{P}(B) \\ &= \frac{\mathbb{P}(A) \cdot \mathbb{P}(C)}{\mathbb{P}(C)} \cdot \frac{\mathbb{P}(B) \cdot \mathbb{P}(C)}{\mathbb{P}(C)} = \frac{\mathbb{P}(A \cap C)}{\mathbb{P}(C)} \cdot \frac{\mathbb{P}(B \cap C)}{\mathbb{P}(C)} \\ &= \mathbb{P}(A \mid C) \cdot \mathbb{P}(B \mid C) \end{aligned}$$

luego la afirmación es cierta. ■

9. Resolver el ejercicio anterior suponiendo solamente que los cinco sucesos son independientes dos a dos.

Solución:

- (a) El argumento expuesto en el ejercicio anterior ya no funcionaría puesto que la independencia dos a dos no implica la independencia de los π -sistemas definidos.
- (b) La afirmación sigue siendo falsa y el mismo contraejemplo lo prueba ya que independencia $\implies$ independencia dos a dos.
- (c) Es falsa y basta considerar el ejemplo del ejercicio 18 donde A, B, C son independientes dos a dos pero no lo son los tres a la vez. Entonces,

$$\mathbb{P}(A \cap B \mid C) = \frac{\mathbb{P}(A \cap B \cap C)}{\mathbb{P}(C)} = \frac{\mathbb{P}(\{1\})}{\mathbb{P}(\{1, 4\})} = \frac{1/4}{1/2} = \frac{1}{2}$$

$$\mathbb{P}(A \mid C) \cdot \mathbb{P}(B \mid C) = \frac{\mathbb{P}(A \cap C)}{\mathbb{P}(C)} \cdot \frac{\mathbb{P}(B \cap C)}{\mathbb{P}(C)} = \frac{\mathbb{P}(\{1\})}{\mathbb{P}(\{1, 4\})} \cdot \frac{\mathbb{P}(\{1\})}{\mathbb{P}(\{1, 2\})} = \frac{1/4}{1/2} \cdot \frac{1/4}{1/2} = \frac{1}{4}$$

Luego $\mathbb{P}(A \cap B \mid C) \neq \mathbb{P}(A \mid C) \cdot \mathbb{P}(B \mid C)$.

10. Sean $X_1, \dots, X_n$ v.a. que toman valores en conjuntos numerables $S_1, \dots, S_n$ respectivamente. Demostrar que si para todos $x_j \in S_j$, $1 \leq j \leq n$,

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \prod_{j=1}^n \mathbb{P}(X_j = x_j), \quad (\text{H.1})$$

entonces las X_j son independientes.

Solución: Sea $\{t_j\}_{j \in \mathbb{N}_n} \subset \mathbb{R}$, entonces, por el Corolario 1.4.5, basta ver que

$$\mathbb{P} \left(\bigcap_{j=1}^n \{X_j \leq t_j\} \right) = \prod_{j=1}^n \mathbb{P}(X_j \leq t_j).$$

Ahora bien, como las X_j son discretas, $\{X_j \leq t_j\} = \bigsqcup_{\substack{x_j \in S_j \\ x_j \leq t_j}} \{X_j = x_j\}$, luego

$$\begin{aligned} \mathbb{P} \left(\bigcap_{j=1}^n \{X_j \leq t_j\} \right) &= \mathbb{P} \left(\bigcap_{j=1}^n \bigsqcup_{\substack{x_j \in S_j \\ x_j \leq t_j}} \{X_j = x_j\} \right) = \mathbb{P} \left(\bigsqcup_{\substack{x_j \in S_j \\ x_j \leq t_j \\ 1 \leq j \leq n}} \bigcap_{i=1}^n \{X_i = x_i\} \right) \\ &= \sum_{\substack{x_j \in S_j \\ x_j \leq t_j \\ 1 \leq j \leq n}} \mathbb{P} \left(\bigcap_{i=1}^n \{X_i = x_i\} \right) = \sum_{\substack{x_j \in S_j \\ x_j \leq t_j \\ 1 \leq j \leq n}} \prod_{j=1}^n \mathbb{P}(X_j = x_j) \\ &= \prod_{j=1}^n \sum_{\substack{x_j \in S_j \\ x_j \leq t_j}} \mathbb{P}(X_j = x_j) = \prod_{j=1}^n \mathbb{P} \left(\bigsqcup_{\substack{x_j \in S_j \\ x_j \leq t_j}} \{X_j = x_j\} \right) = \prod_{j=1}^n \mathbb{P}(X_j \leq t_j). \end{aligned}$$

Aplicando el Corolario 1.4.5 se concluye que las X_j son independientes. ■

11. Demostrar que una variable aleatoria no discreta puede no tener densidad.

Solución: Basta considerar una variable aleatoria que no sea ni discreta ni absolutamente continua. Consideramos en el espacio de probabilidad $(\Omega, \Sigma, \mathbb{P}) = ([0, 1], \mathcal{B}([0, 1]), m)$ la variable aleatoria $X(\omega) = \omega \cdot \mathbb{1}_{[1/2, 1]}(\omega)$.

(a) Para ver que X no es discreta, supongamos por reducción al absurdo que $\exists S \subset [0, 1]$ numerable tal que $\mathbb{P}(X \notin S) = 0$. Entonces

$$\begin{aligned} \mathbb{P}(X \in [1/2, 1] \setminus S) &= \mathbb{P}(X \in [1/2, 1]) - \sum_{x \in S \cap [1/2, 1]} \mathbb{P}(X = x) \\ &= \mathbb{P}(X \in [1/2, 1]) - \sum_{x \in S \cap [1/2, 1]} m(\{x\}) = \mathbb{P}(X \in [1/2, 1]) = 1/2 \neq 0. \end{aligned}$$

Luego X no es discreta.

(b) Veamos ahora que X no tiene densidad: Supongamos por contradicción que sí la tiene, entonces $\exists f: \mathbb{R} \rightarrow \mathbb{R}$ tal que $\forall E \in \mathcal{B}([0, 1]) : \mathbb{P}(X \in E) = \int_E f(x) dx$. Sin embargo, si consideramos $E = \{0\}$, se tiene que

$$\mathbb{P}(X = 0) = m([0, 1/2)) = 1/2 \neq 0 = m(\{0\}) \cdot f(0) = \int_{\{0\}} f(x) dx.$$

Luego X no tiene densidad.

Por tanto, X es una variable aleatoria no discreta que no tiene densidad. ■

H.1.2 Problemas

12. Sean X e Y variables aleatorias, sean $E, F \in \mathcal{F}$ disjuntos, y

$$Z(\omega) = \begin{cases} Y^2(\omega), & \omega \in E, \\ 1, & \omega \in F, \\ X(\omega), & \omega \in (E \cup F)^c. \end{cases}$$

- (a) Demostrar que Z es una variable aleatoria.
- (b) Describir $\sigma(Z)$ (en términos de X , Y , E y F).

Solución:

- (a) Basta ver que Z es una función medible, es decir que $\forall t \in \mathbb{R} : Z^{-1}((-\infty, t]) \in \mathcal{F}$.
- (b) Por definición, la σ -álgebra generada por Z es

$$\sigma(Z) = \{Z^{-1}(B) : B \in \mathcal{B}(\mathbb{R})\}$$

13. Construir una función $F : \mathbb{R}^2 \rightarrow [0, 1]$ tal que:

- (a) $F(x, y) = 1$ si $x > x_0$, $y > y_0$, $F(x, y) = 0$ si $x < x_1$, $y < y_1$,
- (b) $x_1 < x_2$ e $y_1 < y_2$ implica $F(x_1, y_1) \leq F(x_2, y_2)$,
- (c) F es continua por la derecha (en cada variable),

y tal que $\mu(\{(-\infty, a] \times (-\infty, b]\}) := F(a, b)$ no define una medida de probabilidad.

Solución: Para definir una medida sobre $\mathcal{B}(\mathbb{R}^2)$ en $\mathbb{R}^2$ basta con definirla para rectángulos. En este caso, suponiendo que F define una medida, la medida del rectángulo de (x_1, y_1) a (x_2, y_2) es $\mu((x_1, x_2] \times (y_1, y_2]) = F(x_2, y_2) - F(x_1, y_2) - F(x_2, y_1) + F(x_1, y_1)$.

Consideramos el siguiente ejemplo para F :

$$F(x, y) = \begin{cases} 1, & \text{si } x \geq 1 \wedge y \geq 1 \\ 2/3 & \text{si } (0 \leq x < 1 \wedge y \geq 1) \vee (0 \leq y < 1 \wedge x \geq 1) \\ 0 & \text{en otro caso} \end{cases}$$

que cumple las propiedades del enunciado.

Sin embargo, la medida del rectángulo $(1/2, 3/2] \times (1/2, 3/2]$ es $-1/3 \notin [0, 1]$, por lo que F no define una medida de probabilidad.

14. Demostrar que si a una F que cumpla (a), (b) y (c) se le suma la condición

$$F(y_1, y_2) - F(x_1, y_2) - F(y_1, x_2) + F(x_1, x_2) \geq 0 \quad \text{para todos } x_1, x_2, y_1, y_2,$$

entonces $\mu(\{(-\infty, a] \times (-\infty, b]\}) := F(a, b)$ define una medida de probabilidad en $\mathbb{R}^2$.

Solución: Para definir una medida sobre $\mathcal{B}(\mathbb{R}^2)$ en $\mathbb{R}^2$ basta con definirla para rectángulos. Igual que en el ejercicio anterior, se tiene que la medida del rectángulo de (x_1, y_1) a (x_2, y_2) es $\mu((x_1, x_2] \times (y_1, y_2]) = F(x_2, y_2) - F(x_1, y_2) - F(x_2, y_1) + F(x_1, y_1)$.

Como μ se define para cumplir las propiedades de la definición de medida, ya sabemos que es una medida y sabemos que es positiva porque lo es para rectángulos (por la propiedad del enunciado). Solo falta ver que $\mu(\mathbb{R}^2) = 1$:

Sea la sucesión creciente de conjuntos $(R_n := (-n, n] \times (-n, n])_{n \in \mathbb{N}}$, entonces $R_n \xrightarrow{n \rightarrow \infty} \mathbb{R}^2$ y, por el teorema de convergencia monótona, tenemos que

$$\mu(\mathbb{R}^2) = \lim_{n \rightarrow \infty} \mu(R_n) = \lim_{n \rightarrow \infty} F(n, n) - F(-n, n) - F(n, -n) + F(-n, -n) = 1.$$

Por tanto, μ es una medida de probabilidad en $\mathbb{R}^2$. ■

15. Sea X una v.a. Demostrar que si F_X es continua, entonces $Y = F_X(X)$ tiene distribución uniforme en $[0, 1]$. Demostrar que la condición de continuidad es necesaria en general.

Solución: Basta ver que $\mathbb{P}(Y \leq t) = t$ para $t \in (0, 1)$. Como $F_X(x)$ es continua, tenemos

$$\{Y \leq t\} = \{F_X(X) \leq t\} = \{X \leq a : F_X(a) = t\}$$

porque la continuidad de F_X implica la existencia de algún $a \in \mathbb{R}$ tal que $F_X(a) = t$ para cualquier $t \in (0, 1)$. Por lo tanto, $\mathbb{P}(Y \leq t) = \mathbb{P}(X \leq a) = F_X(a) = t$. ■

La condición de continuidad es necesaria porque tomado $X \equiv 1$ constante, $F_X(x) = \mathbb{1}_{[1, \infty)}(x)$ que no es continua. En este caso, $Y = F_X(X) = 1$ con probabilidad 1, que no tiene distribución uniforme en $[0, 1]$. ■

16. Sean X e Y v.a. Demostrar que Y es medible con respecto a $\sigma(X)$ si y solo si $Y = f(X)$ para alguna función $f : \mathbb{R} \rightarrow \mathbb{R}$ $\mathcal{B}(\mathbb{R})$ -medible.

Solución: Queremos ver que Y $\sigma(X)$ medible $\iff \exists f$ medible tal que $Y = f(X)$.

⇐ Sea $Y = f(X)$ con f Borel medible y $E \in \mathcal{B}(\mathbb{R})$, entonces

$$Y^{-1}(E) = \{\omega \in \Omega : f(X(\omega)) \in E\} = (f \circ X)^{-1}(E) = X^{-1}(f^{-1}(E)) \in \sigma(X).$$

⇒ Sea Y $\sigma(X)$ -medible, entonces $\forall E \in \mathcal{B}(\mathbb{R}) : Y^{-1}(E) \in \sigma(X)$. Dividimos en casos:

Caso 1: Sea $Y = \mathbb{1}_A$ con $A \in \sigma(X)$, entonces $\exists E \in \mathcal{B}(\mathbb{R})$ tal que $A = X^{-1}(E)$

$$\implies \forall \omega \in \Omega : Y(\omega) = \mathbb{1}_A(\omega) = \mathbb{1}_{X^{-1}(E)}(\omega) = \mathbb{1}_E(X(\omega)).$$

Luego hemos encontrado una función $f = \mathbb{1}_E$ medible tal que $Y = f(X)$.

Caso 2: Para $Y = \sum_{j=1}^n a_j \mathbb{1}_{A_j}$ simple, por linealidad, $Y = f(X)$ con $f = \sum_{j=1}^n a_j \mathbb{1}_{E_j}$.

Caso 3: Para Y función no negativa, $\exists (s_n)_{n \in \mathbb{N}}$ creciente de funciones simples tal que $s_n \xrightarrow{n \rightarrow \infty} Y$. Por lo tanto

$$Y(\omega) = \lim_{n \rightarrow \infty} s_n(X(\omega)) \implies Y = \lim_{n \rightarrow \infty} s_n(X).$$

Caso 4: Para Y función medible arbitraria, podemos escribir $Y = Y^+ - Y^-$ con $Y^+ = \max\{Y, 0\}$ y $Y^- = \max\{-Y, 0\}$ que son funciones no negativas. Por lo tanto, $\exists f_1, f_2$ medibles tales que $Y^+ = f_1(X)$ y $Y^- = f_2(X)$, luego

$$Y = Y^+ - Y^- = f_1(X) - f_2(X) = (f_1 - f_2)(X). \quad \blacksquare$$

17. Fijado C con $\mathbb{P}(C) > 0$, decimos que A y B son condicionalmente independientes con respecto a C si $\mathbb{P}(A \cap B | C) = \mathbb{P}(A | C) \cdot \mathbb{P}(B | C)$. Probar que si $\mathbb{P}(B \cap C) > 0$,

$$\mathbb{P}(A \cap B | C) = \mathbb{P}(A | C) \cdot \mathbb{P}(B | C) \iff \mathbb{P}(A | C) = \mathbb{P}(A | B \cap C).$$

Solución: Aplicando la Definición 1.3.1, tenemos

$$\begin{aligned} \mathbb{P}(A \cap B | C) &= \mathbb{P}(A | C) \cdot \mathbb{P}(B | C) \iff \frac{\mathbb{P}(A \cap B \cap C)}{\mathbb{P}(C)} = \mathbb{P}(A | C) \cdot \frac{\mathbb{P}(B \cap C)}{\mathbb{P}(C)} \\ &\iff \cancel{\mathbb{P}(C)} \cdot \frac{\mathbb{P}(A \cap B \cap C)}{\cancel{\mathbb{P}(C)}} = \mathbb{P}(A | C) \cdot \frac{\mathbb{P}(B \cap C)}{\cancel{\mathbb{P}(C)}} \cdot \cancel{\mathbb{P}(C)} \quad \text{porque } \mathbb{P}(C) > 0 \\ &\iff \frac{\mathbb{P}(A \cap B \cap C)}{\mathbb{P}(B \cap C)} = \mathbb{P}(A | C) \cdot \frac{\cancel{\mathbb{P}(B \cap C)}}{\cancel{\mathbb{P}(B \cap C)}} \quad \text{porque } \mathbb{P}(B \cap C) > 0 \\ &\iff \mathbb{P}(A | B \cap C) = \mathbb{P}(A | C) \quad \text{por definición de probabilidad condicionada.} \quad \blacksquare \end{aligned}$$

18. Dar un ejemplo de tres eventos A, B, C independientes dos a dos, que no sean independientes.

Solución: Basta considerar $\Omega = \{1, 2, 3, 4\}$ con $\mathbb{P}(\{j\}) = 1/4$ y $A = \{1, 2\}$, $B = \{1, 3\}$, $C = \{1, 4\}$. Se tiene que A, B, C son independientes dos a dos porque

$$\mathbb{P}(A \cap B) = \mathbb{P}(\{1\}) = 1/4 = \mathbb{P}(A) \cdot \mathbb{P}(B) = 1/2 \cdot 1/2$$

$$\mathbb{P}(A \cap C) = \mathbb{P}(\{1\}) = 1/4 = \mathbb{P}(A) \cdot \mathbb{P}(C) = 1/2 \cdot 1/2$$

$$\mathbb{P}(B \cap C) = \mathbb{P}(\{1\}) = 1/4 = \mathbb{P}(B) \cdot \mathbb{P}(C) = 1/2 \cdot 1/2.$$

Sin embargo, $\mathbb{P}(A \cap B \cap C) = \mathbb{P}(\{1\}) = 1/4 \neq 1/8 = \mathbb{P}(A) \cdot \mathbb{P}(B) \cdot \mathbb{P}(C)$.

[19.] Sea $\Omega = \{1, 2, 3, 4\}$, $\mathcal{F} = \mathcal{P}(\Omega)$, $\mathbb{P}(\{j\}) = \frac{1}{4}$. Encontrar $\mathcal{A}_1, \mathcal{A}_2 \subset \mathcal{F}$ que sean independientes² pero no generen σ -álgebras independientes.

Solución: Basta tomar $\mathcal{A}_1 = \{\{1, 2\}, \{1, 3\}\}$ y $\mathcal{A}_2 = \{\{1, 4\}\}$ que son independientes:

$$\mathbb{P}(\{1, 2\} \cap \{1, 4\}) = \mathbb{P}(\{1\}) = 1/4 = 1/2 \cdot 1/2 = \mathbb{P}(\{1, 2\}) \cdot \mathbb{P}(\{1, 4\})$$

$$\mathbb{P}(\{1, 3\} \cap \{1, 4\}) = \mathbb{P}(\{1\}) = 1/4 = 1/2 \cdot 1/2 = \mathbb{P}(\{1, 3\}) \cdot \mathbb{P}(\{1, 4\}).$$

Sin embargo, $\sigma(\mathcal{A}_1) = \mathcal{P}(\Omega)$ y $\sigma(\mathcal{A}_2) = \{\emptyset, \{1, 4\}, \{2, 3\}, \Omega\}$ que no son independientes porque tienen sucesos en común, por ejemplo $\{1, 4\}$: $\mathbb{P}(\{1, 4\}) = 1/2 \neq 1/4 = (\mathbb{P}(\{1, 4\}))^2$.

[20.] Sea $\Omega = \{\omega_1, \dots, \omega_p\}$, donde p es un número primo. Supongamos que los elementos de Ω son equiprobables. Demostrar que dos sucesos A y B no pueden ser independientes salvo que $\mathbb{P}(A), \mathbb{P}(B) \in \{0, 1\}$.

Solución: Sean $A, B \in \mathcal{P}(\Omega)$ sucesos independientes, entonces $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$. Como los elementos de Ω son equiprobables,

$$\mathbb{P}(A \cap B) = \frac{|A \cap B|}{p} = \frac{|A| \cdot |B|}{p^2} = \mathbb{P}(A) \cdot \mathbb{P}(B) \implies |A \cap B| = \frac{1}{p} |A| \cdot |B|.$$

Si suponemos que $\mathbb{P}(A), \mathbb{P}(B) \notin \{0, 1\}$ (es decir, $|A|, |B| \neq 0, p$), entonces como p es primo, $|A|, |B| \nmid p$ y $|A \cap B| \in \mathbb{Q} \setminus \mathbb{N}$ lo cual es absurdo.

Por tanto, A y B no pueden ser independientes salvo que $\mathbb{P}(A), \mathbb{P}(B) \in \{0, 1\}$. ■

H.1.3 Problema para ampliar

[21.] (Medida uniforme en $\mathbb{N}$) Sea $\Omega = \mathbb{N}$. Decimos que $A \subset \Omega$ tiene densidad asintótica $\mu(A)$ si

$$\lim_{n \rightarrow \infty} \frac{|A \cap \{1, 2, 3, \dots, n\}|}{n} = \mu(A).$$

(a) Decidir si μ define una medida de probabilidad en Ω .

²Se define la independencia para dos conjuntos de sucesos como: $\mathcal{A}_1, \mathcal{A}_2$ son independientes $\iff \forall A_1 \in \mathcal{A}_1, A_2 \in \mathcal{A}_2 : A_1, A_2$ son sucesos independientes.

- (b) Decidir si puede haber una medida de probabilidad $\mathbb{P}$ en $\mathbb{N}$ que sea uniforme, es decir, tal que $\mathbb{P}(\{n\}) = \mathbb{P}(\{m\})$ para todos $n, m \in \mathbb{N}$.

Solución:

- (a) Comprobamos las propiedades de la definición de medida:

- i. La primera se cumple: $\mu(\emptyset) = \lim_{n \rightarrow \infty} \frac{|\emptyset \cap \{1, 2, 3, \dots, n\}|}{n} = \lim_{n \rightarrow \infty} \frac{0}{n} = 0$.
- ii. Sin embargo, la aditividad no se cumple: Sean $\{A_j := \{j\}\}_{j \in \mathbb{N}}$, entonces los A_j son disjuntos dos a dos y $\bigsqcup_{j \in \mathbb{N}} A_j = \mathbb{N}$. Por tanto,

$$\mu\left(\bigsqcup_{j \in \mathbb{N}} A_j\right) = \mu(\mathbb{N}) = \lim_{n \rightarrow \infty} \frac{|\mathbb{N} \cap \{1, 2, 3, \dots, n\}|}{n} = \lim_{n \rightarrow \infty} \frac{n}{n} = 1.$$

$$\text{Ahora bien, } \forall j \in \mathbb{N} : \mu(A_j) = \lim_{n \rightarrow \infty} \frac{|A_j \cap \{1, 2, 3, \dots, n\}|}{n} = \lim_{n \rightarrow \infty} \frac{1}{n} = 0.$$

$$\text{Por tanto, } \mu\left(\bigsqcup_{j \in \mathbb{N}} A_j\right) = 1 \neq 0 = \sum_{j \in \mathbb{N}} \mu(A_j).$$

Luego μ no define una medida en Ω .

- (b) Suponemos por contradicción que existe $\mathbb{P}$ medida de probabilidad uniforme en $\mathbb{N}$, entonces $\forall n, m \in \mathbb{N} : \mathbb{P}(\{n\}) = \mathbb{P}(\{m\})$, en particular $\forall n \in \mathbb{N} : \mathbb{P}(\{n\}) = \mathbb{P}(\{1\})$.

Entonces, por aditividad, como $\mathbb{N} = \bigsqcup_{n \in \mathbb{N}} \{n\}$, se tiene que

$$\mathbb{P}(\mathbb{N}) = \mathbb{P}\left(\bigsqcup_{n \in \mathbb{N}} \{n\}\right) = \sum_{n \in \mathbb{N}} \mathbb{P}(\{n\}) = \sum_{n \in \mathbb{N}} \mathbb{P}(\{1\}).$$

Como $\mathbb{P}$ es medida de probabilidad, esta suma debe converger, pero al ser todos los sumandos iguales e infinitos de ellos, $\forall n \in \mathbb{N} : \mathbb{P}(\{n\}) = 0$. Entonces $\mathbb{P}(\mathbb{N}) = 0$ y $\mathbb{P}$ no es medida de probabilidad.

Por tanto, no puede haber una medida de probabilidad uniforme en $\mathbb{N}$.

H.2 Esperanza matemática

Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad.

H.2.1 Ejercicios básicos

[1.] Demostrar $\mathbb{1}_{\bigcup_{j=1}^n A_j} = \mathbb{1}_\Omega - \prod_{j=1}^n (\mathbb{1}_\Omega - \mathbb{1}_{A_j})$. Tomar esperanzas para demostrar:

(a) El principio de inclusión-exclusión.

(b) Las desigualdades de Bonferroni.

Solución:

[2.] Demostrar que dos variables aleatorias son incorreladas siempre que sean independientes.

Solución: Sean X, Y dos variables aleatorias independientes, entonces

$$\begin{aligned}\text{cov}(X, Y) &= \mathbb{E}[(X - \mathbb{E}[X]) \cdot (Y - \mathbb{E}[Y])] \\ &= \mathbb{E}[XY] - \mathbb{E}[X] \cdot \mathbb{E}[Y] = 0.\end{aligned}$$

Ahora bien, como X y Y son independientes, por la Proposición 2.1.3,

$$\mathbb{E}[X \cdot Y] = \mathbb{E}[X] \cdot \mathbb{E}[Y] - \mathbb{E}[X] \cdot \mathbb{E}[Y] = 0.$$

■

[3.] Demostrar que $\mathbb{V}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$.

Solución: Se puede encontrar en Proposición 2.1.4.

[4.] Demostrar que si $\{X_j\}_{j=1}^n$ son variables aleatorias independientes dos a dos, entonces

$$\mathbb{V}\left(\sum_{j=1}^n X_j\right) = \sum_{j=1}^n \mathbb{V}(X_j).$$

Solución: Sean $\{X_j\}_{j=1}^n$ variables aleatorias independientes dos a dos, entonces

$$\begin{aligned}\mathbb{V}\left[\sum_{j=1}^n X_j\right] &= \mathbb{E}\left[\left(\sum_{j=1}^n X_j - \mathbb{E}\left[\sum_{j=1}^n X_j\right]\right)^2\right] \\ &= \mathbb{E}\left[\left(\sum_{i=1}^n X_i - \mathbb{E}\left[\sum_{i=1}^n X_i\right]\right) \cdot \left(\sum_{j=1}^n X_j - \mathbb{E}\left[\sum_{j=1}^n X_j\right]\right)\right] \\ &= \sum_{i,j=1}^n \mathbb{E}[X_i X_j] - \mathbb{E}\left[\sum_{i=1}^n X_i\right]^2\end{aligned}$$

Como $\forall i \neq j : X_i$ y X_j son independientes, por la Proposición 2.1.3,

$$\begin{aligned}\mathbb{V}\left(\sum_{j=1}^n X_j\right) &= \sum_{j=1}^n \mathbb{E}[X_j^2] + \sum_{\substack{i,j=1 \\ i \neq j}}^n \mathbb{E}[X_i] \cdot \mathbb{E}[X_j] - \sum_{i,j=1}^n \mathbb{E}[X_i] \cdot \mathbb{E}[X_j] \\ &= \sum_{j=1}^n \mathbb{E}[X_j^2] - \sum_{j=1}^n \mathbb{E}[X_j]^2 = \sum_{j=1}^n (\mathbb{E}[X_j^2] - \mathbb{E}[X_j]^2) = \sum_{j=1}^n \mathbb{V}[X_j].\end{aligned}$$

■

[5.] Sean $X, Y \in \mathcal{L}^1(P)$ tales que para todo conjunto $A \in \mathcal{F}$,

$$\int_A X \, d\mathbb{P} = \int_A Y \, d\mathbb{P}.$$

Decidir razonadamente si $X = Y$ en casi todo punto.

Solución: Tenemos que $\forall A \in \mathcal{F} : \int_A (X - Y) \, d\mathbb{P} = 0$. Entonces, si tomamos

$$A_1 = \{\omega \in \Omega : X(\omega) > Y(\omega)\} \quad \wedge \quad A_2 = \{\omega \in \Omega : X(\omega) < Y(\omega)\},$$

ambos conjuntos están en $\mathcal{F}$ y se satisface que

$$\mathbb{P}(A_1) = \int_{A_1} (X - Y) \, d\mathbb{P} = 0 = \int_{A_2} (X - Y) \, d\mathbb{P} = \mathbb{P}(A_2).$$

Luego $X - Y = 0$ en casi todo punto, es decir, $X = Y$ c.s.

■

[6.] Decidir si la siguiente afirmación es cierta: sea $\{A_n\}_{n \in \mathbb{N}} \subset \mathcal{F}$. Si $\limsup A_n = \bigcup_{n=1}^{\infty} A_n$, entonces $\{A_n\}_{n \in \mathbb{N}}$ es una sucesión creciente.

Solución: La afirmación es falsa. Por ejemplo, sea $\Omega = \{1, 2, 3\}$ y $\mathcal{F} = \mathcal{P}(\Omega)$, tomamos

$$\forall n \in \mathbb{N} : A_n = \begin{cases} \{1, 2\} & \text{si } n \text{ es par} \\ \{1, 3\} & \text{si } n \text{ es impar.} \end{cases}$$

Entonces, $\limsup A_n = \{1, 2, 3\} = \bigcup_{n=1}^{\infty} A_n$, pero la sucesión no es creciente.

[7.] Sea $a \in \mathbb{R}$. Si X tiene varianza finita, demostrar que $a|X|^{3/2} \in \mathcal{L}^1(P)$.

Solución: Si $\mathbb{V}(X) = \mathbb{E}[X^2] - \mathbb{E}^2[X] < \infty$, entonces $X \in \mathcal{L}^2(\mathbb{P})$. Definimos

$$A_1 = \{\omega \in \Omega : X(\omega) < 1\} \quad \wedge \quad A_2 = \{\omega \in \Omega : X(\omega) \geq 1\}.$$

Entonces $\Omega = A_1 \sqcup A_2$ y, por tanto,

$$\begin{aligned} \int_{\Omega} |X|^{3/2} d\mathbb{P} &= \int_{A_1} |X|^{3/2} d\mathbb{P} + \int_{A_2} |X|^{3/2} d\mathbb{P} \\ &\leq \int_{A_1} |X| d\mathbb{P} + \int_{A_2} |X|^2 d\mathbb{P} < \infty \text{ porque } X \in \mathcal{L}^1(\mathbb{P}) \cap \mathcal{L}^2(\mathbb{P}). \end{aligned}$$

Por tanto, $X \in \mathcal{L}^{3/2}(\mathbb{P})$ y como $a \in \mathbb{R}$, entonces $a|X|^{3/2} \in \mathcal{L}^1(\mathbb{P})$. ■

[8.] Decide si existe una sucesión de variables aleatorias $(Y_n)_{n \in \mathbb{N}}$, independientes y no negativas, tales que $\sum_{n=1}^{\infty} Y_n < \infty$ en un conjunto de probabilidad $1/2$ y $\sum_{n=1}^{\infty} Y_n = \infty$ en un conjunto de probabilidad $1/2$.

Solución: Que una serie de variables aleatorias converja es un evento de la σ -álgebra de cola, luego, como las variables son independientes, por la ley 0-1 de Kolmogorov, la probabilidad de que converja es 0 o 1. Por tanto, no existe tal sucesión.

H.2.2 Problemas

[9.] Sea $X \geq 0$ c.s. una variable aleatoria, y $p > 0$. Demostrar

$$\mathbb{E}[X^p] = p \int_0^{\infty} t^{p-1} \cdot \mathbb{P}(X > t) dt.$$

Solución: Empecemos el desarrollo desde la parte derecha de la igualdad:

$$\begin{aligned} p \int_0^{\infty} t^{p-1} \cdot \mathbb{P}(X > t) dt &= p \int_0^{\infty} t^{p-1} \left(\int_{\Omega} \mathbb{1}_{\{X > t\}}(\omega) d\mathbb{P}(\omega) \right) dt \\ &\stackrel{\text{Fubini}}{=} p \int_{\Omega} \int_0^{\infty} t^{p-1} \cdot \mathbb{1}_{\{X > t\}}(\omega) dt d\mathbb{P}(\omega) = p \int_{\Omega} \int_0^{X(\omega)} t^{p-1} dt d\mathbb{P}(\omega) \\ &= p \int_{\Omega} \left[\frac{t^p}{p} \right]_0^{X(\omega)} d\mathbb{P}(\omega) = \int_{\Omega} X(\omega)^p d\mathbb{P}(\omega) = \mathbb{E}[X^p]. \end{aligned} \quad \blacksquare$$

[10.] Demostrar que si $X \geq 0$ c.s. es una variable aleatoria integrable,

$$\sum_{n=1}^{\infty} \mathbb{P}(X \geq n) \leq \mathbb{E}[X] \leq \sum_{n=0}^{\infty} \mathbb{P}(X \geq n).$$

Solución: Del ejercicio anterior, sabemos que $\mathbb{E}[X] = \int_0^\infty \mathbb{P}(X > t) dt$. Podemos dividir el intervalo $[0, \infty)$ en subintervalos $[0, 1), [1, 2), [2, 3), \dots$, de forma que

$$\mathbb{E}[X] = \int_0^\infty \mathbb{P}(X > t) dt = \sum_{n=0}^\infty \int_n^{n+1} \mathbb{P}(X > t) dt.$$

Para cada $t \in [n, n+1)$, tenemos que $\mathbb{P}(X \geq n+1) \leq \mathbb{P}(X > t) \leq \mathbb{P}(X \geq n)$.

$$\Rightarrow \sum_{n=0}^\infty \int_n^{n+1} \mathbb{P}(X \geq n+1) dt \leq \mathbb{E}[X] \leq \sum_{n=0}^\infty \int_n^{n+1} \mathbb{P}(X \geq n) dt.$$

Al evaluar las integrales (la medida del intervalo $[n, n+1)$ es 1), obtenemos:

$$\sum_{n=0}^\infty \mathbb{P}(X \geq n+1) \leq \mathbb{E}[X] \leq \sum_{n=0}^\infty \mathbb{P}(X \geq n).$$

Realizando un cambio de índice en la primera suma ($m = n+1$):

$$\sum_{m=1}^\infty \mathbb{P}(X \geq m) \leq \mathbb{E}[X] \leq \sum_{n=0}^\infty \mathbb{P}(X \geq n).$$

■

11. (a) Encontrar dos variables aleatorias incorreladas que no sean independientes.

(b) Decidir si existe un número natural $n \geq 2$ tal que si n variables aleatorias son incorreladas entonces dos de ellas son independientes.

(c) Decidir si en toda sucesión infinita de variables aleatorias incorreladas hay dos que son independientes.

Solución:

$$(a) \text{ Sea } X = \begin{cases} 1 & \text{con probabilidad } 1/3 \\ 0 & \text{con probabilidad } 1/3, \text{ entonces } E[X^2 X] = 0 \text{ y } \mathbb{E}[X] = 0 \\ -1 & \text{con probabilidad } 1/3 \end{cases}$$

$\Rightarrow X$ y X^2 son incorreladas pero no independientes.

(b) Si n es impar o par, tomamos las variables aleatorias $Y_j = X^j$ para $j = 1, 2, \dots, n$, donde X es la variable del apartado anterior. Veamos que todas estas variables son incorreladas entre sí pero ningún par es independiente:

Consideramos $Y_i = X^i$ y $Y_j = X^j$ con $i \neq j$, entonces

$$\mathbb{E}[Y_i \cdot Y_j] = \mathbb{E}[X^i \cdot X^j] = \mathbb{E}[X^{i+j}]$$

Ahora bien, para la variable X , tenemos que:

$$\forall k \in \mathbb{N} : \mathbb{E}[X^k] = \begin{cases} 0 & \text{si } k \text{ es impar} \\ 2/3 & \text{si } k \text{ es par} \end{cases}$$

Por tanto, como $\text{cov}(Y_i, Y_j) = \mathbb{E}[Y_i \cdot Y_j] - \mathbb{E}[Y_i] \cdot \mathbb{E}[Y_j]$, tenemos tres casos:

$$\text{cov}(Y_i, Y_j) = \begin{cases} 2/3 - 2/3 \cdot 2/3 = 0 & \text{si } i, j \text{ pares,} \\ 0 - 0 = 0 & \text{si } i, j \text{ impares,} \\ 0 - 0 = 0 & \text{si } i \text{ par y } j \text{ impar o viceversa.} \end{cases}$$

Lo que prueba que son incorreladas. Sin embargo, ningún par es independiente.

Luego no existe $n \geq 2$ tal que para n variables aleatorias incorreladas haya necesariamente dos que sean independientes.

12. Sea ϕ una función estrictamente convexa, es decir,

$$\phi(\lambda a + (1 - \lambda)b) < \lambda\phi(a) + (1 - \lambda)\phi(b), \quad \lambda \in (0, 1), \quad a, b \in \mathbb{R}.$$

Demostrar que $\mathbb{E}[\phi(X)] = \phi(\mathbb{E}[X])$ implica que $X = \mathbb{E}[X]$ casi seguro.

Solución: Sea A la recta tangente a ϕ en el punto $\mathbb{E}[X]$, entonces

$$\begin{aligned} \forall x \in \mathbb{R} : A(x) &\leq \phi(x) \quad \wedge \quad (A(x) = \phi(x) \iff x = \mathbb{E}[X]) . \\ \implies A(\mathbb{E}[X]) &\stackrel{\text{lineal}}{=} \mathbb{E}[A(X)] \leq \mathbb{E}[\phi(X)] = \phi(\mathbb{E}[X]) = A(\mathbb{E}[X]) \end{aligned}$$

Luego la desigualdad es una igualdad y $\mathbb{E}[A(X)] = \mathbb{E}[\phi(X)]$. Por la linealidad de la esperanza, esto implica que $\mathbb{E}[A(X) - \phi(X)] = 0$, pero como $A(X) - \phi(X) \geq 0$, tenemos que $A(X) = \phi(X)$ c.s.

Por tanto, $X = \mathbb{E}[X]$ c.s., ya que $\phi(x) = A(x)$ si y solo si $x = \mathbb{E}[X]$. ■

13. Sea $\varepsilon > 0$. Decidir si existe un $\delta > 0$ tal que para toda variable aleatoria $X \in \mathcal{L}^2(\mathbb{P})$ con $\mathbb{E}[X] = 0$, $\mathbb{V}(X) = 1$, se tiene

$$\mathbb{P}(|X| > \varepsilon) \geq \delta.$$

Solución: Para ver que la afirmación es falsa, basta ver que

$$\exists \varepsilon > 0 : \forall \delta > 0 : \exists X \in \mathcal{L}^2(\mathbb{P}) : \mathbb{E}[X] = 0 \wedge \mathbb{V}(X) = 1 \wedge \mathbb{P}(|X| > \varepsilon) < \delta.$$

Consideramos el espacio de probabilidad $([0, 1], \mathcal{B}([0, 1]), m)$ y X_j dada por

$$\forall \omega \in [0, 1] : X_j(\omega) = \begin{cases} -j & \text{si } \omega \in [0, p_j) \\ 0 & \text{si } \omega \in [p_j, 1 - p_j) \\ j & \text{si } \omega \in [1 - p_j, 1]. \end{cases}$$

Entonces, $\mathbb{E}[X] = 0 \wedge \mathbb{V}(X) = \mathbb{E}[X^2] = j^2 \cdot (2p_j) = 1 \implies p_j = \frac{1}{2j^2}$.

Ahora, si fijamos $\varepsilon = 1/2$ y tomamos $\delta > 0$, tenemos que

$$\mathbb{P}(|X_j| > 1/2) \leq \mathbb{P}(|X_j| > 0) = 2p_j = \frac{1}{j^2}.$$

Es decir, basta tomar j suficientemente grande para que $1/j^2 < \delta$.

14. Probar que si $\mathbb{E}[|X|] < \infty$, entonces

$$\lim_{x \rightarrow \infty} x \cdot \mathbb{P}(|X| \geq x) = 0.$$

Solución: Escribimos la expresión como una integral:

$$\forall t \in \mathbb{R} : t \cdot \mathbb{P}(|X| \geq t) = \int_{\{|X| \geq t\}} t \, d\mathbb{P}(\omega) \leq \int_{\{|X| \geq t\}} |X| \, d\mathbb{P} = \int_{\Omega} |X| \mathbb{1}_{\{|X| \geq t\}} \, d\mathbb{P}.$$

Como $|X| \mathbb{1}_{\{|X| \geq t\}} \leq |X|$ y $X \in \mathcal{L}^1(\mathbb{P})$ (porque $\mathbb{E}[|X|] < \infty$), por el teorema de convergencia dominada

$$\implies \lim_{t \rightarrow \infty} \int_{\Omega} |X| \mathbb{1}_{\{|X| \geq t\}} \, d\mathbb{P} = \int_{\Omega} |X| \lim_{t \rightarrow \infty} \mathbb{1}_{\{|X| \geq t\}} \, d\mathbb{P} = 0. \quad \blacksquare$$

15. Sean $(A_n)_{n \in \mathbb{N}}$ independientes y $\mathbb{P}(A_n) < 1$ para todo n . Demostrar que

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) = 1 \implies \sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty.$$

Solución: Como $\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) = 1$, entonces $\mathbb{P}\left(\bigcap_{n=1}^{\infty} A_n^c\right) = 0$ y por la independencia

$$0 = \prod_{n=1}^{\infty} \mathbb{P}(A_n^c) = \prod_{n=1}^{\infty} (1 - \mathbb{P}(A_n)).$$

Tenemos que $\mathbb{P}(A_n) \leq 1/2$ salvo en un número finito de n (o el problema es trivial).

$$0 = \prod_{n=1}^{\infty} (1 - \mathbb{P}(A_n)) = \prod_{n: \mathbb{P}(A_n) > 1/2} (1 - \mathbb{P}(A_n)) \prod_{n: \mathbb{P}(A_n) \leq 1/2} (1 - \mathbb{P}(A_n)).$$

Entonces, usando que $\forall x \in [-1/2, 0] : x \leq \frac{1}{2} \log(1+x)$, tenemos

$$\prod_{n: \mathbb{P}(A_n) < 1/2} e^{\frac{2}{2} \log(1-\mathbb{P}(A_n))} \geq e^{2(-\sum_{n \in \mathbb{N}} \mathbb{P}(A_n))} \geq 0 \implies \lim_{M \rightarrow \infty} \sum_{n=1}^M \mathbb{P}(A_n) = \infty.$$

■

16. Sea $\{A_n\}_{n \in \mathbb{N}}$ tal que $\mathbb{P}(A_n) \xrightarrow{n \rightarrow \infty} 0$ y $\sum_{n=1}^{\infty} \mathbb{P}(A_n^c \cap A_{n+1}) < \infty$.

- (a) Probar que $\mathbb{P}(\limsup A_n) = 0$.
- (b) Encontrar una sucesión que cumpla las hipótesis del apartado anterior pero a la que no se le pueda aplicar el lema de Borel-Cantelli.

Solución:

- (a) Definimos $\forall n \in \mathbb{N} : B_n = A_n^c \cap A_{n+1}$. Entonces, por la hipótesis, $\sum_{n=1}^{\infty} \mathbb{P}(B_n) < \infty$. Por tanto, por el Lema de Borel-Cantelli I, tenemos que

$$\mathbb{P}\left(\limsup_{n \rightarrow \infty} B_n\right) = 0.$$

$$\begin{aligned} \text{Ahora bien, } \omega \in \limsup_{n \rightarrow \infty} B_n &\iff \exists I \subset \mathbb{N} : |I| = |\mathbb{N}| : \forall i \in I : \omega \in B_i = A_i^c \cap A_{i+1} \\ &\iff \exists I \subset \mathbb{N} : |I| = |\mathbb{N}| : \forall i \in I : \omega \notin A_i \wedge \omega \in A_{i+1}. \end{aligned}$$

Es decir, $\limsup (A_n^c \cap A_{n+1}) = [(\liminf A_n)^c] \cap [\limsup A_n]$. Por tanto, tenemos que

$$\mathbb{P}\left(\left[\left(\liminf_{n \rightarrow \infty} A_n\right)^c\right] \cap \left[\limsup_{n \rightarrow \infty} A_n\right]\right) = 0$$

Ahora bien, podemos descomponer $\limsup A_n$ de la siguiente forma:

$$\begin{aligned} \limsup A_n &= (\limsup A_n \cap \liminf A_n) \sqcup (\limsup A_n \cap (\liminf A_n)^c) \\ &= \liminf A_n \sqcup (\limsup A_n \cap (\liminf A_n)^c) \\ \implies \mathbb{P}(\limsup A_n) &= \mathbb{P}(\liminf A_n) + \mathbb{P}(\limsup A_n \cap (\liminf A_n)^c). \end{aligned}$$

Luego basta ver que $\mathbb{P}(\liminf A_n) = 0$:

$$\begin{aligned} \mathbb{P}\left(\liminf_{n \rightarrow \infty} A_n\right) &= \int_{\Omega} \mathbb{1}_{\{\liminf A_n\}}(\omega) d\mathbb{P}(\omega) = \int_{\Omega} \liminf_{n \rightarrow \infty} \mathbb{1}_{A_n}(\omega) d\mathbb{P}(\omega) \\ &\stackrel{\text{Fatou}}{\leq} \liminf_{n \rightarrow \infty} \int_{\Omega} \mathbb{1}_{A_n}(\omega) d\mathbb{P}(\omega) = \liminf_{n \rightarrow \infty} \mathbb{P}(A_n) = 0. \end{aligned}$$

■

- (b) Consideremos el espacio de probabilidad $([0, 1], \mathcal{B}([0, 1]), m)$, donde m es la medida de Lebesgue. Sea la sucesión de eventos $A_n = [0, 1/n]$ para $n \in \mathbb{N}$. Entonces:

$$- \mathbb{P}(A_n) = m([0, 1/n]) = 1/n \implies \lim \mathbb{P}(A_n) = 0.$$

– $A_n^c = [1/n, 1) \wedge A_{n+1} = [0, 1/(n+1))$ y, como $1/(n+1) < 1/n$, tenemos que

$$A_n^c \cap A_{n+1} = [1/n, 1) \cap [0, 1/(n+1)) = \emptyset.$$

Entonces $\mathbb{P}(A_n^c \cap A_{n+1}) = 0$, así que $\sum_{n=1}^{\infty} \mathbb{P}(A_n^c \cap A_{n+1}) = \sum_{n=1}^{\infty} 0 = 0 < \infty$.

Por tanto, las hipótesis del apartado anterior se cumplen. Sin embargo, no se puede aplicar el Lema de Borel-Cantelli I porque

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \sum_{n=1}^{\infty} \mathbb{P}(A_n) = \sum_{n=1}^{\infty} 1/n = \infty.$$

17. Sean $\{A_n\}_{n=1}^{\infty} \subset \mathcal{F}$ y X una variable aleatoria.

(a) Si $0 \leq X \in \mathcal{L}^2(\mathbb{P})$, demuestra

$$\mathbb{P}(X > 0) \geq \frac{(\mathbb{E}[X])^2}{\mathbb{E}[X^2]}.$$

(b) Demuestra que

$$\mathbb{P}(\limsup A_n) = \lim_{n \rightarrow \infty} \lim_{N \rightarrow \infty} \mathbb{P}\left(\bigcup_{k=n}^N A_k\right).$$

(c) Supón que $\sum_j \mathbb{P}(A_j) = \infty$ y existe una constante $0 < \alpha$ tal que, para todo $m \in \mathbb{N}$,

$$\liminf_{n \rightarrow \infty} \left[\left(\sum_{j=m}^n \mathbb{P}(A_j) \right)^2 / \left(\sum_{m \leq i, j \leq n} \mathbb{P}(A_i \cap A_j) \right) \right] \geq \alpha.$$

Aplica (a) a $\sum_n \mathbb{1}_{A_n}$ y usa (b) para demostrar que $\mathbb{P}(\limsup A_n) \geq \alpha$.

(d) Decide si en las condiciones de (c) se puede concluir, usando algún resultado de clase, que de hecho $\mathbb{P}(\limsup A_n) = 1$.

Solución:

(a) Observamos que, como $X \geq 0$, podemos escribir:

$$\begin{aligned} \mathbb{E}[X] &= \int_{\Omega} X(\omega) d\mathbb{P}(\omega) = \int_{\Omega} X \cdot \mathbb{1}_{\{X>0\}} d\mathbb{P} + \int_{\Omega} X \cdot \mathbb{1}_{\{X \leq 0\}} d\mathbb{P} \\ &= \int_{\Omega} X \cdot \mathbb{1}_{\{X>0\}} d\mathbb{P} + \int_{\Omega} X \cdot \mathbb{1}_{\{X=0\}} d\mathbb{P} = \mathbb{E}[X \cdot \mathbb{1}_{\{X>0\}}]. \end{aligned}$$

Ahora aplicamos la desigualdad de Hölder con $p = 2$:

$$\mathbb{E}[X] = \mathbb{E}[X \cdot \mathbb{1}_{\{X>0\}}] = \mathbb{E}[X^2]^{1/2} \cdot \mathbb{E}[\mathbb{1}_{\{X>0\}}^2]^{1/2} = \mathbb{E}[X^2]^{1/2} \cdot \mathbb{P}(X > 0)^{1/2}.$$

Elevando al cuadrado y despejando, obtenemos

$$(\mathbb{E}[X])^2 \leq \mathbb{E}[X^2] \cdot \mathbb{P}(X > 0) \implies \mathbb{P}(X > 0) \geq \frac{(\mathbb{E}[X])^2}{\mathbb{E}[X^2]}.$$

- (b) Como $\forall n \in \mathbb{N} : \left(\bigcup_{k=n}^N A_k\right)_{N \in \mathbb{N}}$ es una sucesión creciente de sucesos, podemos aplicar el Teorema de convergencia monótona:

$$\lim_{n \rightarrow \infty} \lim_{N \rightarrow \infty} \mathbb{P} \left(\bigcup_{k=n}^N A_k \right) = \lim_{n \rightarrow \infty} \mathbb{P} \left(\bigcup_{k=n}^{\infty} A_k \right)$$

Ahora bien, como $(\bigcup_{k=n} A_k)_{n \in \mathbb{N}}$ es una sucesión decreciente de sucesos, podemos aplicar el teorema de convergencia monótona para sucesiones decrecientes:

$$\lim_{n \rightarrow \infty} \lim_{N \rightarrow \infty} \mathbb{P} \left(\bigcup_{k=n}^N A_k \right) = \lim_{n \rightarrow \infty} \mathbb{P} \left(\bigcup_{k=n}^{\infty} A_k \right) = \mathbb{P} \left(\bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k \right) = \mathbb{P} \left(\limsup_{n \rightarrow \infty} A_n \right).$$

- (c) Seguimos la indicación del enunciado. Primero calculamos la esperanza de la suma de las indicatrices y del cuadrado de la suma de las indicatrices:

$$\begin{aligned} \mathbb{E} \left[\sum_{j=m}^n \mathbb{1}_{A_j} \right] &= \sum_{j=m}^n \mathbb{E} [\mathbb{1}_{A_j}] = \sum_{j=m}^n \mathbb{P}(A_j). \\ \mathbb{E} \left[\left(\sum_{j=m}^n \mathbb{1}_{A_j} \right)^2 \right] &= \mathbb{E} \left[\sum_{m \leq i, j \leq n} \mathbb{1}_{A_i} \mathbb{1}_{A_j} \right] = \sum_{m \leq i, j \leq n} \mathbb{P}(A_i \cap A_j). \end{aligned}$$

Aplicamos el apartado (a):

$$\mathbb{P} \left(\sum_{j=m}^n \mathbb{1}_{A_j} > 0 \right) \geq \frac{\left(\sum_{j=m}^n \mathbb{P}(A_j) \right)^2}{\sum_{m \leq i, j \leq n} \mathbb{P}(A_i \cap A_j)}.$$

Ahora bien, $\mathbb{P} \left(\sum_{j=m}^n \mathbb{1}_{A_j} > 0 \right) = \mathbb{P} \left(\bigcup_{j=m}^n A_j \right)$ y tomando $\liminf_{n \rightarrow \infty}$ en ambos lados de la desigualdad, obtenemos que

$$\forall m \in \mathbb{N} : \liminf_{n \rightarrow \infty} \mathbb{P} \left(\bigcup_{j=m}^n A_j \right) \geq \liminf_{n \rightarrow \infty} \frac{\left(\sum_{j=m}^n \mathbb{P}(A_j) \right)^2}{\sum_{m \leq i, j \leq n} \mathbb{P}(A_i \cap A_j)} \stackrel{\text{hipótesis}}{\geq} \alpha.$$

Como $(\bigcup_{k=m}^n A_k)_{n \in \mathbb{N}}$ es una sucesión creciente de sucesos, $\left(\mathbb{P} \left(\bigcup_{j=m}^n A_j \right) \right)_{n \in \mathbb{N}}$ es una sucesión creciente de números reales. Como además está acotada por 1, converge a un límite:

$$\liminf_{n \rightarrow \infty} \mathbb{P} \left(\bigcup_{j=m}^n A_j \right) = \lim_{n \rightarrow \infty} \mathbb{P} \left(\bigcup_{j=m}^n A_j \right).$$

Si ahora tomamos el límite cuando $m \rightarrow \infty$, tenemos que

$$\lim_{m \rightarrow \infty} \lim_{n \rightarrow \infty} \mathbb{P} \left(\bigcup_{j=m}^n A_j \right) \stackrel{(b)}{=} \mathbb{P} \left(\limsup_{n \rightarrow \infty} A_n \right) \geq \alpha.$$

■

18. Sea $X \in \mathcal{L}^1(\mathbb{P})$.

(a) Demuestra que para todo $\alpha \in \mathbb{R}$,

$$\mathbb{E}[X] = \mathbb{E}[X \cdot \mathbb{1}_{\{X > \alpha\}}] + \mathbb{E}[X \mathbb{1}_{\{X \leq \alpha\}}].$$

(b) Explica si las fórmulas

$$\mathbb{V}(X) = \mathbb{V}(X \cdot \mathbb{1}_{\{X > \alpha\}}) + \mathbb{V}(X \cdot \mathbb{1}_{\{X \leq \alpha\}}) \quad \wedge \quad \mathbb{E}[X^2] = \mathbb{E}[X^2 \cdot \mathbb{1}_{\{X > \alpha\}}] + \mathbb{E}[X^2 \cdot \mathbb{1}_{\{X \leq \alpha\}}]$$

son ciertas para todo $\alpha \in \mathbb{R}$.

(c) Demuestra que existe una constante $c < 1$ tal que

$$\forall X \geq 0 : X \in \mathcal{L}^2(\mathbb{P}) : \mathbb{P}(X > \mathbb{E}[X/2]) \leq c \frac{(\mathbb{E}[X])^2}{\mathbb{E}[X^2]}.$$

Solución:

(a) Por la linealidad de la esperanza, como $\{X > \alpha\} \sqcup \{X \leq \alpha\} = \Omega$, tenemos que

$$\mathbb{E}[X] = \mathbb{E}[X \cdot \mathbb{1}_{\{X > \alpha\}} + X \cdot \mathbb{1}_{\{X \leq \alpha\}}] = \mathbb{E}[X \cdot \mathbb{1}_{\{X > \alpha\}}] + \mathbb{E}[X \cdot \mathbb{1}_{\{X \leq \alpha\}}].$$

(b) Igual que para el apartado anterior, la segunda igualdad es cierta por la linealidad de la esperanza (siempre que $X \in \mathcal{L}(\mathbb{P})$). Si $X \notin \mathcal{L}^2(\mathbb{P})$, ambos lados de la igualdad son ∞ , así que también se cumple.

La primera no es cierta en general, por ejemplo consideramos

$$X = \mathbb{1}_{[0, 1/2]} - \mathbb{1}_{(1/2, 1]}$$

en el espacio de probabilidad $([0, 1], \mathcal{B}([0, 1]), m)$. Entonces, tenemos que

$$\mathbb{V}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2 = 1.$$

Sin embargo, si tomamos $\alpha = 0$, tenemos que

$$\mathbb{V}(X \cdot \mathbb{1}_{\{X > 0\}}) = \mathbb{E}[X^2 \cdot \mathbb{1}_{\{X > 0\}}] - \mathbb{E}[X \cdot \mathbb{1}_{\{X > 0\}}]^2 = 0 \quad \wedge \quad \mathbb{V}(X \cdot \mathbb{1}_{\{X \leq 0\}}) = 0.$$

Luego $\mathbb{V}(X \cdot \mathbb{1}_{\{X > 0\}}) + \mathbb{V}(X \cdot \mathbb{1}_{\{X \leq 0\}}) = 0 + 0 = 0 \neq 1 = \mathbb{V}(X)$.

(c) Tomamos $\alpha = \mathbb{E} [X/2]$ y aplicamos el apartado (a):

$$\mathbb{E} [X] = \mathbb{E} \left[X \cdot \mathbb{1}_{\{X > \mathbb{E} [X/2]\}} \right] + \mathbb{E} \left[X \cdot \mathbb{1}_{\{X \leq \mathbb{E} [X/2]\}} \right].$$

Entonces, por la desigualdad de Hölder con $p = 2$ para el primer sumando, tenemos

$$\begin{aligned} \mathbb{E} \left[X \cdot \mathbb{1}_{\{X > \mathbb{E} [X/2]\}} \right] &\leq \mathbb{E} [X^2]^{1/2} \cdot \mathbb{E} \left[\mathbb{1}_{\{X > \mathbb{E} [X/2]\}} \right]^{1/2} = \\ &\leq \mathbb{E} [X^2]^{1/2} \cdot \mathbb{P} (X > \mathbb{E} [X/2])^{1/2}. \end{aligned}$$

El segundo sumando lo podemos acotar de la siguiente forma:

$$\begin{aligned} \mathbb{E} \left[X \cdot \mathbb{1}_{\{X \leq \mathbb{E} [X/2]\}} \right] &= \int_{\{X \leq \mathbb{E} [X/2]\}} X \, d\mathbb{P} \leq \int_{\{X \leq \mathbb{E} [X/2]\}} \mathbb{E} [X/2] \, d\mathbb{P} = \\ &\leq \mathbb{E} [X/2] \cdot \mathbb{P} (X \leq \mathbb{E} [X/2]) \leq \frac{\mathbb{E} [X]}{2}. \end{aligned}$$

Entonces, podemos acotar la esperanza de X de la siguiente forma:

$$\begin{aligned} \mathbb{E} [X] &\leq \mathbb{E} [X^2]^{1/2} \cdot \mathbb{P} (X > \mathbb{E} [X/2])^{1/2} + \frac{\mathbb{E} [X]}{2} \\ \iff \mathbb{E} [X] - \frac{\mathbb{E} [X]}{2} &\leq \mathbb{E} [X^2]^{1/2} \cdot \mathbb{P} (X > \mathbb{E} [X/2])^{1/2} \\ \iff \frac{\mathbb{E} [X]^2}{4} &\leq \mathbb{E} [X^2] \cdot \mathbb{P} (X > \mathbb{E} [X/2]) \end{aligned}$$

Luego, despejando, finalmente llegamos a la desigualdad que queríamos demostrar:

$$\mathbb{P} (X > \mathbb{E} [X/2]) \geq \frac{1}{4} \cdot \frac{\mathbb{E} [X]^2}{\mathbb{E} [X^2]}.$$

Es decir, $c = 1/4$. ■

Nota: De hecho, este mismo método se puede emplear para demostrar que

$$\forall p \in [1, \infty) : \mathbb{P} (X > \mathbb{E} [X/2]) \geq \frac{1}{2^p} \cdot \frac{\mathbb{E} [X]^p}{\mathbb{E} [X^p]}.$$

19. Sea $M(\omega) = \sup_{n \geq 1} X_n(\omega)$. Mostrar que:

(a) Si existe $x \in \mathbb{R}$ tal que

$$\sum_{n=1}^{\infty} \mathbb{P}(X_n > x) < \infty,$$

entonces $\mathbb{P}(M < \infty) = 1$.

(b) Si $X_1, X_2, \dots$ son independientes dos a dos y

$$\sum_{n=1}^{\infty} \mathbb{P}(X_n > x) = \infty \quad \text{para todo } x \in \mathbb{R},$$

entonces $\mathbb{P}(M = \infty) = 1$.

Solución:

- (a) Sea $A_n = \{X_n \leq x\}$. Entonces, como $\sum_{n=1}^{\infty} \mathbb{P}(A_n^c) < \infty$, por el Lema de Borel-Cantelli I, tenemos que

$$\mathbb{P}\left(\limsup_{n \rightarrow \infty} A_n^c\right) = 0 \implies \mathbb{P}\left(\liminf_{n \rightarrow \infty} A_n\right) = 1.$$

Entonces, para un $\omega \in \liminf_{n \rightarrow \infty} A_n$, tenemos que $\exists n_0(\omega) : \forall n \geq n_0(\omega) : X_n(\omega) \leq x$.

Por tanto, $M(\omega) = \sup_{n \geq 1} X_n(\omega) \leq \max_{i \in \mathbb{N}_{n_0(\omega)}} \{x, x_i\} < \infty$. Luego

$$\liminf_{n \rightarrow \infty} A_n \subset \{M < \infty\} \implies \mathbb{P}(\liminf_{n \rightarrow \infty} A_n) \leq \mathbb{P}(M < \infty).$$

Concluimos entonces que $\mathbb{P}(M < \infty) = 1$. ■

H.2.3 Problemas para ampliar

20. (Young implica Hölder)

- (a) Demostrar la desigualdad de Young: si a, b son positivos,

$$ab \leq \frac{a^p}{p} + \frac{b^{p'}}{p'},$$

donde $\frac{1}{p} + \frac{1}{p'} = 1$.

- (b) Usar la desigualdad de Young para dar una prueba de la desigualdad de Hölder que no utilice la desigualdad de Jensen.

Solución:

- (a) Se puede encontrar en Teorema 2.2.4.
(b) Se puede encontrar en Teorema 2.2.5.

21. (Hölder implica Jensen) Deducir la desigualdad de Jensen en el caso particular $\phi(t) = |t|^p$ de la desigualdad de Hölder.

22. Demostrar el siguiente (importante) corolario de la desigualdad de Hölder: si $f \in L^p$ para algún $1 \leq p \leq \infty$, entonces

$$\|f\|_p = \sup_{\{g: \|g\|_{p'}=1\}} \int fg.$$

23. Demostrar las desigualdades de Hölder y Minkowski en los casos $p = 1$ y $p = \infty$.

24. Decimos que una constante c es la mejor aproximación a X en $L^p(\mathbb{P})$ si

$$\mathbb{E}[|X - c|^p] = \inf_{s \in \mathbb{R}} \mathbb{E}[|X - s|^p].$$

Sea $(\Omega, \mathcal{F}, P) = ([0, 1], \mathcal{B}(\mathbb{R}), m)$.

- (a) Sea $X := 2\mathbb{1}[0, 1/3] - \mathbb{1}[2/3, 1]$. Hallar una constante c que mejor aproxime a X en $L^1(P)$. Hacer lo mismo con $L^2(P)$ y $L^\infty(P)$.
- (b) Repetir con $Y := 2\mathbb{1}[0, 1/2] - \mathbb{1}[1/2, 1]$. ¿Es c única?

H.3 Convergencia de sucesiones de variables aleatorias

Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad.

1. Encontrar una sucesión $(X_n)_n$ que converja en probabilidad pero que no converja en ningún punto.

Solución: Consideramos $(X_n)_{n \in \mathbb{N}}$ en $([0, 1], \mathcal{B}([0, 1]), m)$ dada por

$$\begin{aligned} X_1 &= \mathbb{1}_{[0,1]}, \\ X_2 &= \mathbb{1}_{[0,1/2]} \wedge X_3 = \mathbb{1}_{[1/2,1]}, \\ X_4 &= \mathbb{1}_{[0,1/3]} \wedge X_5 = \mathbb{1}_{[1/3,2/3]} \wedge X_6 = \mathbb{1}_{[2/3,1]}, \\ X_7 &= \mathbb{1}_{[0,1/4]} \wedge X_8 = \mathbb{1}_{[1/4,1/2]} \wedge X_9 = \mathbb{1}_{[1/2,3/4]} \wedge X_{10} = \mathbb{1}_{[3/4,1]}, \\ &\vdots \end{aligned}$$

Entonces, para $\varepsilon > 0$, tenemos que $\mathbb{P}(|X_n| > \varepsilon) = \mathbb{P}(X_n = 1) \xrightarrow{n \rightarrow \infty} 0$. Luego $(X_n)_n$ converge en probabilidad a 0.

Sin embargo, para $\omega \in [0, 1]$, tenemos que $X_n(\omega) = 1$ para infinitos n y $X_n(\omega) = 0$ para infinitos n , por lo que no converge en ningún punto.

2. Encontrar $(X_n)_n$ que converja en probabilidad pero que no converja en $\mathcal{L}^p(\mathbb{P})$.

Solución: Consideramos $(X_n)_{n \in \mathbb{N}}$ en $([0, 1], \mathcal{B}([0, 1]), m)$ dada por

$$\forall \omega \in [0, 1] : X_n(\omega) = \begin{cases} n & \text{si } \omega \in [0, 1/n] \\ 0 & \text{si } \omega \in (1/n, 1]. \end{cases}$$

Entonces, para $\varepsilon > 0$, tenemos que $\mathbb{P}(|X_n| > \varepsilon) = \mathbb{P}(X_n = n) = 1/n \xrightarrow{n \rightarrow \infty} 0$. Luego $(X_n)_n$ converge en probabilidad a 0.

Sin embargo, veamos que no converge en $\mathcal{L}^p(\mathbb{P})$ para ningún $p \geq 1$. Como si $1 \leq p < q$, entonces $\|x\|_p \leq \|x\|_q$ (Corolario 2.2.3); basta ver que $(X_n)_{n \in \mathbb{N}}$ no converge en $\mathcal{L}^1(\mathbb{P})$:

$$\|X_n - 0\|_1 = \int_0^1 |X_n(\omega)| d\omega = \mathbb{E}[|X_n|] = n \cdot \frac{1}{n} = 1 \not\xrightarrow{n \rightarrow \infty} 0.$$

Luego $(X_n)_n$ no converge en $\mathcal{L}^p(\mathbb{P})$ para ningún $p \geq 1$.

3. Encontrar una sucesión $(X_n)_n$ que converja en distribución pero que no converja en probabilidad. Pista: dos variables aleatorias con la misma distribución pueden ser muy diferentes punto a punto.

Solución: Consideramos $\{1, 2\}$ con $\mathbb{P}(1) = \mathbb{P}(2) = 1/2$ y la sucesión de variables aleatorias $(X_n)_{n \in \mathbb{N}}$ dada por $\forall n \in \mathbb{N} : X_{2n} = \mathbb{1}_{\{1\}}$ y $X_{2n+1} = \mathbb{1}_{\{2\}}$. Entonces, tenemos que

$$\forall n \in \mathbb{N} : X_n = \begin{cases} 0 & \text{con probabilidad } 1/2 \\ 1 & \text{con probabilidad } 1/2 \end{cases} \implies \forall t \in \mathbb{R} : F_{X_n}(t) = \begin{cases} 0 & \text{si } t < 0 \\ 1/2 & \text{si } 0 \leq t < 1 \\ 1 & \text{si } t \geq 1 \end{cases}$$

Luego la distribución es siempre la misma y $X_n \xrightarrow[n \rightarrow \infty]{d} X$.

Sin embargo, veamos que no converge en probabilidad. De hacerlo, lo haría a una variable con la misma distribución, es decir, a $X_1 = \mathbb{1}_{\{1\}}$ o a $X_2 = \mathbb{1}_{\{2\}}$. Para $\varepsilon > 0$, tenemos que

$$\mathbb{P}(|X_n - X_1| > \varepsilon) = \begin{cases} 0 & \text{si } n \text{ es par} \\ 1 & \text{si } n \text{ es impar} \end{cases} \quad \wedge \quad \mathbb{P}(|X_n - X_2| > \varepsilon) = \begin{cases} 1 & \text{si } n \text{ es par} \\ 0 & \text{si } n \text{ es impar.} \end{cases}$$

Como ninguna de estas sucesiones de probabilidades converge a 0, entonces $(X_n)_n$ no converge en probabilidad.

[4.] Demostrar que si una sucesión $(X_n)_n$ converge en distribución a una constante C , entonces converge en probabilidad.

Solución: Sea $C \in \mathbb{R}$ y $(X_n)_n$ una sucesión de variables aleatorias tales que $X_n \xrightarrow[n \rightarrow \infty]{d} X$ donde $X \equiv C$. Entonces, para todo punto de continuidad t de F_X , tenemos que

$$\lim_{n \rightarrow \infty} F_{X_n}(t) = F_X(t) = \begin{cases} 0 & \text{si } t < C \\ 1 & \text{si } t \geq C \end{cases} = \mathbb{1}_{[C, \infty)}(t).$$

Sea $\varepsilon > 0$, entonces $\{\omega \in \Omega : |X_n(\omega) - X| > \varepsilon\} = \{X_n - C > \varepsilon\} \sqcup \{X_n - C < -\varepsilon\}$.

$$\begin{aligned} \implies \mathbb{P}(|X_n - X| > \varepsilon) &= \mathbb{P}(X_n - C > \varepsilon) + \mathbb{P}(X_n - C < -\varepsilon) \\ &= 1 - \mathbb{P}(X_n \leq \varepsilon + C) + \mathbb{P}(X_n < C - \varepsilon) \end{aligned}$$

Ahora bien, como $\{X_n < C - \varepsilon\} \subset \{X_n \leq C - \varepsilon\}$, entonces

$$\begin{aligned} \mathbb{P}(|X_n - X| > \varepsilon) &\leq 1 - \mathbb{P}(X_n \leq \varepsilon + C) + \mathbb{P}(X_n \leq C - \varepsilon) = \\ &\leq 1 - F_{X_n}(\varepsilon + C) + F_{X_n}(C - \varepsilon). \end{aligned}$$

Como $\varepsilon > 0$, $C + \varepsilon$ y $C - \varepsilon$ son puntos de continuidad de F_X , por lo que

$$F_{X_n}(\varepsilon + C) \xrightarrow[n \rightarrow \infty]{} F_X(\varepsilon + C) = 1 \quad \wedge \quad F_{X_n}(C - \varepsilon) \xrightarrow[n \rightarrow \infty]{} F_X(C - \varepsilon) = 0.$$

Por tanto, $\mathbb{P}(|X_n - X| > \varepsilon) \xrightarrow[n \rightarrow \infty]{} 1 - 1 + 0 = 0$ y $(X_n)_n$ converge en probabilidad a C . ■

[5.] Demostrar que si una sucesión monótona $(X_n)_n$ converge en probabilidad entonces con-

verge casi seguro.

Solución: Sea $(X_n)_n$ una sucesión de variables aleatorias monótonas tal que $X_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} X$.

Como $(X_n)_n$ es monótona, $(X_n(\omega))_{n \in \mathbb{N}}$ también lo es. Por tanto, $\forall \omega \in \Omega : \exists \lim X_n(\omega)$ (aunque sea ∞ o $-\infty$). Pero como $\forall \varepsilon > 0 : \mathbb{P}(|X_n - X| > \varepsilon) \xrightarrow[n \rightarrow \infty]{} 0$, entonces

$$|X_n(\omega)| \xrightarrow[n \rightarrow \infty]{} \infty \text{ sólo en un conjunto de probabilidad } 0.$$

Esto es porque si existiese $B \in \Sigma$ tal que $\mathbb{P}(B) > 0$ y $\forall \omega \in B : |X_n(\omega)| \xrightarrow[n \rightarrow \infty]{} \infty$, entonces

$$\forall \omega \in B : \forall \varepsilon > 0 : \exists N_\varepsilon \in \mathbb{N} : \forall n \geq N_\varepsilon : |X_n(\omega) - X(\omega)| > \varepsilon$$

y se tendría que $\mathbb{P}(|X_n - X| > \varepsilon) \geq \mathbb{P}(B) > 0$, lo que contradice la convergencia en probabilidad. Por tanto,

$$\exists A \in \Sigma : \mathbb{P}(A) = 0 : \forall \omega \in A^c : X_n(\omega) \xrightarrow[n \rightarrow \infty]{} X(\omega).$$

Es decir, X_n converge casi seguro a X . ■

[6.] Demostrar que si $1 \leq p < q$ y $(X_n)_n$ converge en $\mathcal{L}^q(\mathbb{P})$, entonces converge en $\mathcal{L}^p(\mathbb{P})$.

Solución: Sea $(X_n)_{n \in \mathbb{N}}$ una sucesión de variables aleatorias tales que $X_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}^q} X$.

$$\implies \|X_n - X\|_p \stackrel{2.2.3}{\leq} \|X_n - X\|_q \xrightarrow[n \rightarrow \infty]{} 0.$$

Por tanto, $(X_n)_n$ converge en $\mathcal{L}^p(\mathbb{P})$. ■

[7.] Decide si la siguiente afirmación es cierta o falsa: sea $s > 0$. La sucesión $(X_n)_{n=1}^\infty$, donde

$$\mathbb{P}(X_n = n) = \frac{1}{n^s}, \quad \mathbb{P}(X_n = 0) = 1 - \frac{1}{n^s},$$

converge en $\mathcal{L}^2(\mathbb{P})$ si y solo si converge en probabilidad.

Solución: Observamos que X_n tiende en probabilidad a 0 para todo valor de $s > 0$:

$$\mathbb{P}(|X_n - 0| > \varepsilon) = \mathbb{P}(X_n = n) = \frac{1}{n^s} \xrightarrow[n \rightarrow \infty]{} 0.$$

Sin embargo, para que X_n converja en $\mathcal{L}^2(P)$, es necesario que $s > 2$:

$$\|X_n - 0\|_2 = [n^2 \cdot \mathbb{P}(X_n = n) + 0 \cdot \mathbb{P}(X_n = 0)]^{1/2} = \left(n^2 \cdot \frac{1}{n^s}\right)^{1/2} \xrightarrow[n \rightarrow \infty]{} 0 \iff s > 2.$$

Por lo tanto, la afirmación es falsa.

[8.] Asume que $X_n \in \mathcal{L}^2(\mathbb{P})$ para todo n . Sea $S_n = \sum_{j=1}^n X_j$, $A_n = \mathbb{E}[S_n]$ y $B_n = \mathbb{V}(S_n)$.

Demuestra que $\lim_{n \rightarrow \infty} B_n / \alpha_n^2 = 0$ implica $\frac{S_n - A_n}{\alpha_n} \xrightarrow[n \rightarrow \infty]{\mathbb{P}} 0$.

Solución: Veamos primero que $S_n \in \mathcal{L}^2(\mathbb{P})$ para todo n :

$$\|S_n\|_2^2 = \left\| \sum_{j=1}^n X_j \right\|_2^2 \stackrel{\text{Minkowski}}{\leq} \sum_{j \in \mathbb{N}_n} \|X_j\|_2^2 < \infty \quad \text{porque} \quad \forall j \in \mathbb{N} : X_j \in \mathcal{L}^2(\mathbb{P}).$$

Entonces, podemos aplicar el Corolario 2.2.10, y tenemos que

$$\forall \varepsilon > 0 : \mathbb{P} \left(\left| \frac{S_n - A_n}{\alpha_n} \right| > \varepsilon \right) = \mathbb{P}(|S_n - A_n| > \varepsilon \alpha_n) \leq \frac{1}{\varepsilon^2 \alpha_n^2} \mathbb{V}(S_n) = \frac{1}{\varepsilon^2} \cdot \frac{B_n}{\alpha_n^2} \xrightarrow{n \rightarrow \infty} 0.$$

Por tanto, $\frac{S_n - A_n}{\alpha_n} \xrightarrow[n \rightarrow \infty]{\mathbb{P}} 0$. ■

[9.] Si Ω es numerable y $\mathcal{F} = \mathcal{P}(\Omega)$, demostrar que la convergencia en probabilidad implica la convergencia casi seguro en $(\Omega, \mathcal{F}, \mathbb{P})$.

Solución: Sea X tal que $X_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} X$ (que existe por hipótesis). Supongamos por contradicción que $\exists A \in \Sigma : \mathbb{P}(A) > 0$ donde X_n no converge a X . Entonces, A es numerable (porque Ω lo es) y, como $\mathbb{P}(A) > 0$, existe un $\omega \in A : \mathbb{P}(\{\omega\}) > 0$ tal que $(X_n(\omega))_{n \in \mathbb{N}}$ no converge a $X(\omega)$. Tomamos dicho ω , entonces

$$\exists \varepsilon > 0 : \forall N \in \mathbb{N} : \exists n > N : |X_n(\omega) - X(\omega)| > \varepsilon.$$

Por tanto, $\omega \in \{|X_n - X| > \varepsilon\}$ para dicho $\varepsilon > 0$.

$$\implies \exists \varepsilon > 0 : \mathbb{P}(|X_n - X| > \varepsilon) \geq \mathbb{P}(\{\omega\}) > 0.$$

Como $\mathbb{P}(\{\omega\})$ es una constante positiva, entonces $\mathbb{P}(|X_n - X| > \varepsilon)$ no puede converger a 0 cuando $n \rightarrow \infty$ y X_n no converge a X en probabilidad. $\rightarrow \leftarrow$ ■

[10.] Si $(X_n)_n$ son independientes y $\mathbb{P}(X_n = 1) = p_n$, $\mathbb{P}(X_n = 0) = 1 - p_n$, demostrar que $X_n \rightarrow 0$ casi seguro si y solo si $\sum_n p_n < \infty$.

Solución: Vamos a hacer ambas implicaciones a la vez dado que, bajo independencia, el Lema de borel Cantelli I es un si y solo si (Observación 2.3.3).

Definimos $A_n = \{X_n = 1\}$, entonces, como las X_n son independientes, los A_n son independientes. Por el Lema de Borel-Cantelli, $\sum_n \mathbb{P}(A_n) = \sum_n p_n < \infty \iff \mathbb{P} \left(\limsup_{n \rightarrow \infty} A_n \right) = 0$.

Esto es equivalente a que $\mathbb{P}(\liminf_{n \rightarrow \infty} A_n^c) = 1$, es decir, para casi todo $\omega \in \Omega$, existe un $n_0 \in \mathbb{N}$ tal que $\forall n \geq n_0 : X_n(\omega) = 0$.

$$\iff \exists A \in \Sigma : \mathbb{P}(A) = 0 : \forall \omega \in A^c : \lim_{n \rightarrow \infty} X_n(\omega) = 0 \iff X_n \xrightarrow[n \rightarrow \infty]{\text{c.s.}} 0.$$

Por tanto, $(X_n)_n$ converge casi seguro a 0 si y solo si $\sum_n p_n < \infty$. ■

11. Asume que $X_n = Y_n$ en distribución para todo n . Demuestra que aunque $Y_n \rightarrow 0$ casi seguro, puede ser que X_n no converja en ningún punto.

Solución: Consideramos la sucesión $(X_n)_{n \in \mathbb{N}}$ de la solución del ejercicio 1 de esta hoja y la sucesión $(Y_n)_{n \in \mathbb{N}}$ dada por

$$\begin{aligned} Y_1 &= \mathbb{1}_{[0,1]}, \\ Y_2 &= \mathbb{1}_{[0,1/2]} = Y_3 \\ Y_4 &= \mathbb{1}_{[0,1/3]} = Y_5 = Y_6, & \implies \quad \forall n \in \mathbb{N} : X_n \stackrel{d}{=} Y_n. \\ Y_7 &= \mathbb{1}_{[0,1/4]} = Y_8 = Y_9 = Y_{10}, \\ &\vdots \end{aligned}$$

En la solución del ejercicio 1 ya vimos que X_n no converge en ningún punto.

Tenemos que $\forall \omega \in (0, 1] : \exists n_0 \in \mathbb{N} : \forall n \geq n_0 : Y_n(\omega) = 0$. Es decir, tenemos convergencia puntual excepto en el punto $\omega = 0$. Ahora bien, como $\mathbb{P}(\{0\}) = m(\{0\}) = 0$, $Y_n \xrightarrow[n \rightarrow \infty]{\text{c.s.}} 0$.

Es decir, $Y_n \rightarrow 0$ casi seguro, pero X_n no converge en ningún punto. ■

12. Si X_n es independiente de Y_n para todo n , $X_n \rightarrow X$ e $Y_n \rightarrow Y$ en distribución, y X e Y son independientes, demuestra que $X_n + Y_n \rightarrow X + Y$ en distribución.

H.4 Martingalas

Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad, $\mathcal{F} \subseteq \Sigma$ una σ -álgebra y $(\mathcal{F}_n)_{n=1}^{\infty}$ una filtración.

H.4.1 Ejercicios básicos

1. Sean $A, B \in \Sigma$. Calcular $\mathbb{E}[\mathbb{1}_A \mid \sigma(B)]$.

Solución: Tenemos que $\sigma(B) = \{\emptyset, B, B^c, \Omega\}$. Por tanto, Z es $\sigma(B)$ -medible si y solo si es constante en B y en B^c . Es decir, $Z = a \cdot \mathbb{1}_B + b \cdot \mathbb{1}_{B^c}$ para algunos $a, b \in \mathbb{R}$.

Entonces, $Y := \mathbb{E}[\mathbb{1}_A \mid \sigma(B)]$ es la única variable aleatoria $\sigma(B)$ -medible que cumple

$$\begin{aligned} & \forall Z \text{ } \sigma(B)\text{-medible} : \mathbb{E}[Z \cdot \mathbb{1}_A] = \mathbb{E}[Z \cdot Y] \\ \iff & \forall a, b \in \mathbb{R} : \mathbb{E}[(a \cdot \mathbb{1}_B + b \cdot \mathbb{1}_{B^c}) \cdot \mathbb{1}_A] = \mathbb{E}[(a \cdot \mathbb{1}_B + b \cdot \mathbb{1}_{B^c}) \cdot Y]. \end{aligned}$$

Ahora bien, $\mathbb{E}[Z \cdot \mathbb{1}_A] = a \cdot \mathbb{P}(A \cap B) + b \cdot \mathbb{P}(A \cap B^c)$ y como Y es $\sigma(B)$ -medible, también es de la forma $Y = a' \cdot \mathbb{1}_B + b' \cdot \mathbb{1}_{B^c}$ para algunos $a', b' \in \mathbb{R}$. Entonces,

$$\begin{aligned} \forall a, b \in \mathbb{R} : a \cdot \mathbb{P}(A \cap B) + b \cdot \mathbb{P}(A \cap B^c) &= \mathbb{E}[(a \mathbb{1}_B + b \mathbb{1}_{B^c}) \cdot (a' \mathbb{1}_B + b' \mathbb{1}_{B^c})] \\ &= a \cdot a' \cdot \mathbb{P}(B) + b \cdot b' \cdot \mathbb{P}(B^c). \end{aligned}$$

Como esto debe ser cierto para todo $a, b \in \mathbb{R}$, tomando $b = 0$ o $a = 0$, tenemos

$$a' = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \wedge b' = \frac{\mathbb{P}(A \cap B^c)}{\mathbb{P}(B^c)} \implies \mathbb{E}[\mathbb{1}_A \mid \sigma(B)] = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \cdot \mathbb{1}_B + \frac{\mathbb{P}(A \cap B^c)}{\mathbb{P}(B^c)} \cdot \mathbb{1}_{B^c}.$$

2. Demostrar las siguientes propiedades de la esperanza condicional:

- (a) Si $X \geq 0$ c.s., entonces $\mathbb{E}[X \mid \mathcal{F}] \geq 0$ c.s.
- (b) $\mathbb{E}[\mathbb{E}[X \mid \mathcal{F}]] = \mathbb{E}[X]$.
- (c) $\mathbb{E}[X \mid \Sigma] = X$ c.s.
- (d) $\mathbb{E}[X \mid \{\emptyset, \Omega\}] = \mathbb{E}[X]$ c.s.
- (e) La esperanza condicionada es lineal.
- (f) Si Z es $\mathcal{F}$ -medible y acotada, $\mathbb{E}[XZ \mid \mathcal{F}] = Z \cdot \mathbb{E}[X \mid \mathcal{F}]$ c.s.

Solución: Todas estas propiedades se enuncian y demuestran en el Lema 4.1.2.

3. Sean $X, Y \in \mathcal{L}^1(\mathbb{P})$. Demostrar que $\mathbb{E}[X \cdot \mathbb{E}[X \mid Y]] \geq 0$.

Solución: La esperanza de X condicionada a Y se define como $\mathbb{E}[X | Y] := \mathbb{E}[X | \sigma(Y)]$.

$$\begin{aligned} \implies \mathbb{E}[X \cdot \mathbb{E}[X | Y]] &= \mathbb{E}[\mathbb{E}[X | Y] \cdot \mathbb{E}[X | Y]] = \mathbb{E}[\mathbb{E}[X | Y]^2] \geq 0. \\ &\quad \uparrow \\ &\quad \mathbb{E}[X | Y] \text{ es } \sigma(Y)\text{-medible} \end{aligned}$$

■

4. (a) Sea $f \in \mathcal{L}^1(\mathbb{P})$. Demostrar que $X_n = \mathbb{E}[f | \mathcal{F}_n]$ es una martingala.

(b) Demostrar que la suma de variables aleatorias independientes de media 0 se puede ver como una martingala.

Solución: Ambas demostraciones se encuentran en los Ejemplos 4.2.1:

(a) Este es el ejemplo 3 de los Ejemplos 4.2.1 (la martingala de Doob).

(b) Este es el ejemplo 1 de los Ejemplos 4.2.1.

5. (a) Demostrar que la parte positiva de una martingala es una submartingala.

(b) Decidir si la parte negativa de una martingala es una submartingala, una supermartingala, o ninguna de las dos.

Solución: Sea $X = (X_n)_{n \in \mathbb{N}}$ una martingala.

(a) Definimos $(X_n^+)_{n \in \mathbb{N}} = (\max\{X_n, 0\})_{n \in \mathbb{N}}$, queremos probar que

$$\forall n \in \mathbb{N} : \mathbb{E}[\max\{X_n, 0\} | \mathcal{F}_n] \geq \max\{X_n, 0\} \quad \text{c.s.}$$

Como $(X_n)_{n \in \mathbb{N}}$ es una martingala, tenemos que $\max\{X_n, 0\} = \max\{\mathbb{E}[X_{n+1} | \mathcal{F}_n], 0\}$.

$$\implies X_n^+ = \max\{X_n, 0\} \geq \mathbb{E}[\max\{X_{n+1}, 0\} | \mathcal{F}_n] = \mathbb{E}[X_{n+1}^+ | \mathcal{F}_n].$$

Esto es porque $f, g \geq 0 \implies \int \max\{f, g\} d\mathbb{P} \geq \max\{\int f, \int g\}$.

■

Nota: Otra forma de demostrarlo es mediante la desigualdad de Jensen condicional aplicando el Corolario 4.2.2 ya que $f(x) = \max\{x, 0\}$ es convexa. Este es el método que se emplea en el Ejercicio 4.2.2.

6. Demostrar que $T : \Omega \rightarrow \{2, 4, 6, \dots\}$ es un tiempo de parada si y solo si $\{T > 2\ell + 1\} \in \mathcal{F}_{2\ell}$ para todo $\ell \in \mathbb{N} = \{1, 2, 3, \dots\}$.

Solución: Veamos ambas implicaciones por separado:

$\Rightarrow$ Suponemos que T es un tiempo de parada. Por el Lema 4.3.1,

$$\forall \ell \in \mathbb{N} : \{T \leq \ell\} \in \mathcal{F}_\ell \implies \forall \ell \in \mathbb{N} : \{T > 2\ell + 1\} = \{T \leq 2\ell\}^c \in \mathcal{F}_{2\ell}.$$

$\Leftarrow$ Suponemos que $\forall \ell \in \mathbb{N} : \{T > 2\ell + 1\} \in \mathcal{F}_{2\ell}$, queremos ver que $\forall k \in \mathbb{N} : \{T \leq k\} \in \mathcal{F}_k$.

$$* \ k = 2j \implies \{T \leq k\} = \{T \leq 2j\} = \{T > 2j + 1\}^c \in \mathcal{F}_{2j} = \mathcal{F}_k.$$

$$* \ k = 2j + 1 \implies \{T \leq k\} = \{T \leq 2j + 1\} \underset{\substack{\uparrow \\ T \neq 2j + 1}}{=} \{T \leq 2j\} = \{T > 2j + 1\}^c \in \mathcal{F}_{2j} \text{ y}$$

$$\text{como } \mathcal{F}_{2j} \subset \mathcal{F}_{2j+1} = \mathcal{F}_k, \{T \leq k\} \in \mathcal{F}_k. \quad \blacksquare$$

H.4.2 Problemas

7. Supongamos que $\mathcal{F} = \sigma(A_1, \dots, A_n)$.

(a) Demostrar la desigualdad de Jensen condicional para $(\Omega, \Sigma, \mathbb{P})$.

(b) Demostrar la desigualdad de Hölder condicional para $(\Omega, \Sigma, \mathbb{P})$.

Solución:

(a) Sea $\varphi: \mathbb{R} \rightarrow \mathbb{R}$ una función convexa y $X \in \mathcal{L}^1(\mathbb{P})$. Queremos probar que

$$\varphi(\mathbb{E}[X | \mathcal{F}]) \leq \mathbb{E}[\varphi(X) | \mathcal{F}] \quad \text{c.s.}$$

Aunque los A_j no formen una partición de Ω , siempre podemos construir una finita que genere la misma σ -álgebra. Por tanto, $\exists B_1, \dots, B_m \in \Sigma$ tal que $\mathcal{F} = \sigma(B_1, \dots, B_m)$.

Entonces, por el Ejercicio 4.1.2, sabemos que

$$\forall \omega \in \Omega : \mathbb{E}[X | \mathcal{F}](\omega) = \sum_{i=1}^m \frac{\mathbb{E}[X \mathbb{1}_{B_i}]}{\mathbb{P}(B_i)} \mathbb{1}_{B_i}(\omega).$$

Fijamos $j \in \mathbb{N}_m$ y tomamos $\omega \in B_j$, entonces

$$\mathbb{E}[X | \mathcal{F}](\omega) = \frac{\mathbb{E}[X \mathbb{1}_{B_j}]}{\mathbb{P}(B_j)} =: \mathbb{E}_{\tilde{\mathbb{P}}}[X] \quad \wedge \quad \mathbb{E}[\varphi(X) | \mathcal{F}](\omega) = \frac{\mathbb{E}[\varphi(X) \mathbb{1}_{B_j}]}{\mathbb{P}(B_j)} =: \mathbb{E}_{\tilde{\mathbb{P}}}[\varphi(X)]$$

donde $(\tilde{\Omega}, \tilde{\Sigma}, \tilde{\mathbb{P}}) = (B_j, \{A \cap B_j : A \in \Sigma\}, \frac{\mathbb{P}}{\mathbb{P}(B_j)})$ es un nuevo espacio de probabilidad.

Entonces, por la desigualdad de Jensen en $(\tilde{\Omega}, \tilde{\Sigma}, \tilde{\mathbb{P}})$, tenemos que

$$\varphi(\mathbb{E}_{\tilde{\mathbb{P}}}[X]) \leq \mathbb{E}_{\tilde{\mathbb{P}}}[\varphi(X)] \implies \forall \omega \in B_j : \varphi(\mathbb{E}[X | \mathcal{F}](\omega)) \leq \mathbb{E}[\varphi(X) | \mathcal{F}](\omega).$$

Como esto es cierto para todo $j \in \mathbb{N}_m$ y los B_j forman una partición de Ω ,

$$\forall \omega \in \Omega : \varphi(\mathbb{E}[X | \mathcal{F}](\omega)) \leq \mathbb{E}[\varphi(X) | \mathcal{F}](\omega) \implies \varphi(\mathbb{E}[X | \mathcal{F}]) \leq \mathbb{E}[\varphi(X) | \mathcal{F}]. \quad \blacksquare$$

(b) Sea $p \in [1, \infty]$, $X \in \mathcal{L}^p(\mathbb{P})$ y $Y \in \mathcal{L}^q(\mathbb{P})$ con $\frac{1}{p} + \frac{1}{q} = 1$. Queremos probar que

$$\mathbb{E}[|X \cdot Y| | \mathcal{F}] \leq \left(\mathbb{E}[|X|^p | \mathcal{F}] \right)^{1/p} \cdot \left(\mathbb{E}[|Y|^q | \mathcal{F}] \right)^{1/q} \text{ c.s.}$$

Igual que en el apartado anterior, podemos escribir una expresión explícita para la esperanza condicional y aplicar la desigualdad de Hölder en un nuevo espacio de probabilidad. En este caso,

$$\begin{aligned} \forall j \in \mathbb{N}_m : \forall \omega \in B_j : \mathbb{E}[|X \cdot Y| \mid \mathcal{F}](\omega) &= \frac{\mathbb{E}[|X \cdot Y| \mathbb{1}_{B_j}]}{\mathbb{P}(B_j)} = \mathbb{E}_{\tilde{\mathbb{P}}}[|X \cdot Y|]. \\ \implies \mathbb{E}_{\tilde{\mathbb{P}}}[|X \cdot Y|] &\stackrel{\text{Hölder}}{\leq} \mathbb{E}_{\tilde{\mathbb{P}}} [|X|^p]^{1/p} \cdot \mathbb{E}_{\tilde{\mathbb{P}}} [|Y|^q]^{1/q}. \end{aligned}$$

Igual que antes, como esto es cierto para todo $j \in \mathbb{N}_m$ y los B_j forman una partición de Ω , tenemos que (en todo Ω):

$$\mathbb{E}[|X \cdot Y| \mid \mathcal{F}] \leq \mathbb{E}[|X|^p \mid \mathcal{F}]^{1/p} \cdot \mathbb{E}[|Y|^q \mid \mathcal{F}]^{1/q}. \quad \blacksquare$$

8. Demostrar las siguientes propiedades de la esperanza condicional:

- (a) (Convergencia monótona) Si $X_n \geq 0$ c.s. para todo n y $\{X_n\}_n$ es una sucesión creciente, $\mathbb{E}[\lim_n X_n \mid \mathcal{F}] = \lim_n \mathbb{E}[X_n \mid \mathcal{F}]$ c.s.
- (b) (Fatou) Si $X_n \geq 0$ c.s. para todo n , $\mathbb{E}[\liminf_n X_n \mid \mathcal{F}] \leq \liminf_n \mathbb{E}[X_n \mid \mathcal{F}]$.
- (c) (Convergencia dominada) Si $\mathbb{E}[\sup_n |X_n|] < \infty$ y $\lim_n X_n$ existe c.s., $\mathbb{E}[\lim_n X_n \mid \mathcal{F}] = \lim_n \mathbb{E}[X_n \mid \mathcal{F}]$ c.s.

Solución:

- (a) Tenemos que $\forall n \in \mathbb{N} : X_n \leq X_{n+1}$, luego $X_{n+1} - X_n \geq 0$ c.s. Por tanto, por el Lema 4.1.2:(1), tenemos que $\mathbb{E}[X_{n+1} - X_n \mid \mathcal{F}] \geq 0$ luego, por linealidad, $\mathbb{E}[X_{n+1} \mid \mathcal{F}] \geq \mathbb{E}[X_n \mid \mathcal{F}]$. Entonces, $(\mathbb{E}[X_n \mid \mathcal{F}])_{n \in \mathbb{N}}$ es una sucesión creciente de variables aleatorias $\mathcal{F}$ -medibles.

Por tanto, $\exists \lim_n \mathbb{E}[X_n \mid \mathcal{F}]$ y es $\mathcal{F}$ -medible.

Sea $Z \in \mathcal{L}^\infty(\mathbb{P})$ $\mathcal{F}$ -medible, entonces por el teorema de convergencia monótona usual:

$$\mathbb{E} \left[\left(\lim_{n \rightarrow \infty} \mathbb{E}[X_n \mid \mathcal{F}] \right) \cdot Z \right] \stackrel{\text{TCM}}{=} \lim_{n \rightarrow \infty} \mathbb{E}[\mathbb{E}[X_n \mid \mathcal{F}] \cdot Z]$$

Por otro lado, $(X_n)_{n \in \mathbb{N}}$ también satisface las hipótesis del teorema de convergencia monótona usual, luego

$$\mathbb{E} \left[\lim_{n \rightarrow \infty} X_n \cdot Z \right] \stackrel{\text{TCM}}{=} \lim_{n \rightarrow \infty} \mathbb{E}[X_n \cdot Z] = \lim_{n \rightarrow \infty} \mathbb{E}[\mathbb{E}[X_n \mid \mathcal{F}] \cdot Z].$$

Entonces, concluimos que $\mathbb{E} \left[\left(\lim_{n \rightarrow \infty} \mathbb{E}[X_n \mid \mathcal{F}] \right) \cdot Z \right] = \mathbb{E} \left[\lim_{n \rightarrow \infty} X_n \cdot Z \right]$ para todo $Z \in$

$\mathcal{L}^\infty(\mathbb{P})$ $\mathcal{F}$ -medible. Por tanto, por unicidad de la esperanza condicionada:

$$\lim_{n \rightarrow \infty} \mathbb{E}[X_n | \mathcal{F}] = \mathbb{E}\left[\lim_{n \rightarrow \infty} X_n | \mathcal{F}\right] \text{ c.s.} \quad \blacksquare$$

(b) Definimos $Y_n = \inf_{k \geq n} X_k$. Entonces $\liminf_n X_n = \lim_n Y_n$ y $(Y_n)_n$ es una sucesión creciente de variables aleatorias. Es decir, cumple las hipótesis del apartado anterior.

$$\implies \mathbb{E}\left[\liminf_{n \rightarrow \infty} X_n | \mathcal{F}\right] = \mathbb{E}\left[\lim_{n \rightarrow \infty} Y_n | \mathcal{F}\right] \stackrel{(a)}{=} \liminf_{n \rightarrow \infty} \mathbb{E}[Y_n | \mathcal{F}].$$

Ahora bien, como $Y_n \leq X_n$ para todo $n \in \mathbb{N}$, $\mathbb{E}[Y_n | \mathcal{F}] \leq \mathbb{E}[X_n | \mathcal{F}]$ c.s.

$$\implies \mathbb{E}\left[\liminf_{n \rightarrow \infty} X_n | \mathcal{F}\right] = \liminf_{n \rightarrow \infty} \mathbb{E}[Y_n | \mathcal{F}] \leq \liminf_{n \rightarrow \infty} \mathbb{E}[X_n | \mathcal{F}] \text{ c.s.} \quad \blacksquare$$

[9.] Encontrar una sucesión de variables aleatorias $\{X_n\}_n$ con $\mathbb{E}[X_n] = 0$ para todo n tales que $S = \{S_n\}_n \in \mathbb{N}$ no sea una martingala con respecto a la filtración $\{\sigma(X_1, \dots, X_n)\}_n$.

Solución: Por el ejemplo 1 de los Ejemplos 4.2.1, sabemos que las variables aleatorias X_n no pueden ser independientes e idénticamente distribuidas, ya que en ese caso $(S_n)_n$ sería una martingala con respecto a la filtración $(\sigma(X_1, \dots, X_n))_n$.

Sean $\forall n \in \mathbb{N} : \mathcal{F}_n = \Sigma$ y $X_0 \not\equiv 0$ tal que $\mathbb{E}[X_0] = 0$. Tomamos $\forall n \in \mathbb{N} : X_n = X_0$

$$\implies \mathbb{E}[S_2 | \mathcal{F}_1] = \mathbb{E}[S_2 | \Sigma] = S_2 = 2X_0 \neq S_1.$$

Por tanto, S no es una martingala con respecto a la filtración $(\mathcal{F}_n)_n$.

[10.] Si X es una submartingala y φ es una función convexa creciente (no decreciente), demostrar que $\varphi(X)$ es una submartingala. Demostrar que el requisito de ser creciente es necesario en general.

Solución: Sea $(X_n)_{n \in \mathbb{N}}$ una submartingala y φ una función convexa no decreciente.

$$\implies \mathbb{E}[\varphi(X_{n+1}) | \mathcal{F}_n] \stackrel{\text{Jensen condicional}}{\geq} \varphi(\mathbb{E}[X_{n+1} | \mathcal{F}_n]).$$

Ahora, como X es una submartingala, $\mathbb{E}[X_{n+1} | \mathcal{F}_n] \geq X_n$ y, como φ es no decreciente, esta desigualdad se mantiene al aplicar φ a ambos lados:

$$\mathbb{E}[\varphi(X_{n+1}) | \mathcal{F}_n] \geq \varphi(\mathbb{E}[X_{n+1} | \mathcal{F}_n]) \geq \varphi(X_n).$$

Por tanto, $(\varphi(X_n))_{n \in \mathbb{N}}$ es una submartingala. \blacksquare

Veamos que el requisito de ser creciente es necesario en general. Consideremos una submartingala $(X_n)_{n \in \mathbb{N}}$ que no sea martingala y la función $\varphi(x) = -x$. Entonces, φ es convexa pero decreciente y $\varphi(X_n) = -X_n$ es una supermartingala que no es una martingala. Es

decir, $\varphi(X_n)$ no es una submartingala.

11. Decidir si el valor absoluto de una submartingala es una submartingala.

Solución: Por el ejercicio anterior 10, sospechamos que no es cierto en general, ya que la función $f(x) = |x|$ no es no decreciente.

Veamos que la afirmación es falsa ofreciendo un contraejemplo. Consideramos la submartingala dada por $X_1 = -2$ y $\forall n \geq 2 : X_n = 1$. Entonces, $X = (X_n)_{n \in \mathbb{N}}$ es una submartingala, pero $(|X_n|)_{n \in \mathbb{N}} = (2, 1, \dots)$ no es una submartingala ya que $\mathbb{E}[|X_2| \mid \mathcal{F}_1] = 1 < 2 = |X_1|$.

12. Si $(X_n)_n$ es una submartingala, demostrar que $(X_n)_n$ es una submartingala con respecto a la filtración $\{\sigma(X_1, \dots, X_n)\}_n$.

Solución: Sea $(X_n)_{n \in \mathbb{N}}$ una submartingala con respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$. Entonces, por definición, tenemos que $\forall n \in \mathbb{N} : X_n$ es $\mathcal{F}_n$ -medible, luego $\sigma(X_n) \subset \mathcal{F}_n$. Como además $\mathcal{F}_n \subset \mathcal{F}_{n+1}$, tenemos que $\forall k \leq n : \sigma(X_k) \subset \mathcal{F}_n$. Por tanto, $\sigma(X_1, \dots, X_n) \subset \mathcal{F}_n$.

Entonces, la Proposición 4.1.5, tenemos que

$$\mathbb{E}[X_{n+1} \mid \sigma(X_1, \dots, X_n)] = \mathbb{E}[\mathbb{E}[X_{n+1} \mid \mathcal{F}_n] \mid \sigma(X_1, \dots, X_n)].$$

Ahora, como $(X_n)_{n \in \mathbb{N}}$ es una submartingala $\mathbb{E}[X_{n+1} \mid \mathcal{F}_n] \geq X_n$ luego al aplicar la esperanza condicionada, la desigualdad se mantiene:

$$\mathbb{E}[X_{n+1} \mid \sigma(X_1, \dots, X_n)] = \mathbb{E}[\mathbb{E}[X_{n+1} \mid \mathcal{F}_n] \mid \sigma(X_1, \dots, X_n)] \geq \mathbb{E}[X_n \mid \sigma(X_1, \dots, X_n)].$$

Como X_n es $\sigma(X_1, \dots, X_n)$ -medible, aplicando el Lema 4.1.2:(3), tenemos

$$\mathbb{E}[X_{n+1} \mid \sigma(X_1, \dots, X_n)] \geq \mathbb{E}[X_n \mid \sigma(X_1, \dots, X_n)] = X_n.$$

Por tanto, $(X_n)_{n \in \mathbb{N}}$ es una submartingala con respecto a la filtración $(\sigma(X_1, \dots, X_n))_{n \in \mathbb{N}}$. ■

13. Sean $\{T_j\}_{j=1}^n$ tiempos de parada. Demostrar que los siguientes son tiempos de parada:

(a) $\sum_{j=1}^n T_j.$

(b) $\max_{1 \leq j \leq n} T_j.$

(c) $\min_{1 \leq j \leq n} T_j.$

Solución:

(a) Lo haremos por inducción. Para $n = 1$, tenemos que T_1 es un tiempo de parada por hipótesis. Supongamos que $\sum_{j=1}^n T_j$ es un tiempo de parada. Sea $k \in \mathbb{N}$, entonces

$$\left\{ \sum_{j=1}^{n+1} T_j = k \right\} = \bigcup_{\ell=1}^{k-n} \left(\left\{ \sum_{j=1}^n T_j = k - \ell \right\} \cap \{T_{n+1} = \ell\} \right).$$

Por hipótesis de inducción, $\left\{\sum_{j=1}^n T_j = k - \ell\right\} \in \mathcal{F}_{k-\ell} \subset \mathcal{F}_k$ y $\{T_{n+1} = \ell\} \in \mathcal{F}_\ell \subset \mathcal{F}_k$.
 Por tanto, $\left\{\sum_{j=1}^{n+1} T_j = k\right\} \in \mathcal{F}_k$ y $\sum_{j=1}^{n+1} T_j$ es un tiempo de parada.

Entonces, por inducción, $\sum_{j=1}^n T_j$ es un tiempo de parada para todo $n \in \mathbb{N}$. ■

(b) Sea $k \in \mathbb{N}$, entonces $\left\{\max_{1 \leq j \leq n} T_j \leq k\right\} = \bigcap_{j=1}^n \{T_j \leq k\}$. Por hipótesis,

$$\forall j \in \mathbb{N}_n : \{T_j \leq k\} \in \mathcal{F}_k \implies \left\{\max_{1 \leq j \leq n} T_j \leq k\right\} \in \mathcal{F}_k.$$

Por tanto, $\max_{1 \leq j \leq n} T_j$ es un tiempo de parada. ■

(c) Sea $k \in \mathbb{N}$, por hipótesis, tenemos que $\forall j \in \mathbb{N}_n : \{T_j \leq k\} \in \mathcal{F}_k$.

$$\implies \left\{\min_{1 \leq j \leq n} T_j \leq k\right\}^c = \left\{\min_{1 \leq j \leq n} T_j > k\right\} = \bigcap_{j=1}^n \{T_j > k\} = \bigcap_{j=1}^n \{T_j \leq k\}^c \in \mathcal{F}_k.$$

Luego $\{\min_{1 \leq j \leq n} T_j \leq k\} \in \mathcal{F}_k$ y, por tanto, $\min_{1 \leq j \leq n} T_j$ es un tiempo de parada. ■

14. Sea $(X_n)_n$ un proceso adaptado a $(\mathcal{F}_n)_n$ y $A \in \mathcal{B}(\mathbb{R})$. Demostrar que la función

$$S(\omega) = \sup\{n \in \mathbb{N} : X_n(\omega) \in A\}$$

no es un tiempo de parada en general.

Solución: Intuitivamente, si X_n fuese la fortuna acumulada de un jugador despues de n partidas, $S(\omega)$ sería la última partida en la que el jugador tuvo una fortuna en A . Pero, mientras se está jugando, no se puede saber si la fortuna del jugador va volver a estar en A o no, por lo que $S(\omega)$ no debería ser un tiempo de parada.

Consideramos $\mathcal{F}_1 = \{\Omega, \emptyset\}$, $X_1 \equiv 1$ y $\forall n \geq 2 : \mathcal{F}_n = \{\emptyset, B, B^c, \Omega\}$ con $\mathbb{P}(B) \in (0, 1)$, y

$$\forall n \geq 2 : \forall \omega \in \Omega : X_n(\omega) := \begin{cases} 1 & \text{si } \omega \in B \\ 0 & \text{si } \omega \in B^c \end{cases}$$

Tomamos $A = [1, \infty)$, entonces

$$\{S = 1\} = \{\omega \in \Omega : \sup\{n \in \mathbb{N} : X_n(\omega) \geq 1\} = 1\} = B^c \notin \mathcal{F}_1 = \{\emptyset, \Omega\}.$$

Por tanto, S no es un tiempo de parada. ■

15. Sea $(X_n)_n$ un proceso adaptado, $k \in \mathbb{N}$ y $A \in \mathcal{B}(\mathbb{R})$. Demostrar que la variable aleatoria cuyo valor es el tiempo en el que X entra en A por k -ésima vez es un tiempo de parada.

Solución: Definimos la variable aleatoria T_k dada por

$$\forall \omega \in \Omega : T_k(\omega) = \begin{cases} \min \left\{ n \in \mathbb{N} : \sum_{j=1}^n \mathbb{1}_A(X_j(\omega)) = k \right\} & \text{si el conjunto es no vacío,} \\ \infty & \text{si el conjunto es vacío.} \end{cases}$$

Esta es justo la variable aleatoria que queremos demostrar que es un tiempo de parada.

Sea $\ell \in \mathbb{N}$, entonces

$$\begin{aligned} \{T_k = \ell\} &= \left\{ \omega \in \Omega : \sum_{j=1}^{\ell} \mathbb{1}_A(X_j(\omega)) = k \wedge \sum_{j=1}^{\ell-1} \mathbb{1}_A(X_j(\omega)) < k \right\} \\ &= \left\{ \omega \in \Omega : \exists J \subset \mathbb{N}_{\ell} : |J| = k : \forall j \in \mathbb{N}_n : (X_j(\omega) \in A \iff j \in J) \right\} \\ &= \bigcup_{\substack{J \subset \mathbb{N}_{\ell} \\ |J|=k}} \left[\bigcap_{j \in J} \{X_j \in A\} \right] \cap \left[\bigcap_{j \in \mathbb{N}_n \setminus J} \{X_j \notin A\} \right]. \end{aligned}$$

Como $\forall j \in \mathbb{N} : X_j$ es $\mathcal{F}_j$ -medible, tenemos que $\{X_j \in A\}, \{X_j \notin A\} = \{X_j \in A\}^c \in \mathcal{F}_j$. Por tanto, como las $\mathcal{F}_n$ están anidadas, $\{X_j \in A\}, \{X_j \notin A\} \in \mathcal{F}_{\ell}$. Por último, como tanto las intersecciones como las uniones presentes en la expresión anterior son finitas, tenemos que $\{T_k = \ell\} \in \mathcal{F}_{\ell}$. Luego T_k es un tiempo de parada. ■

16. Sea T un tiempo de parada y $(X_n)_n$ una submartingala. Demostrar que si definimos

$$\forall n \in \mathbb{N} : Y_n = X_{\min\{T, n\}},$$

entonces $(Y_n)_n$ es una submartingala con respecto a la filtración $(\mathcal{F}_{\min\{T, n\}})_n$.

Solución: Sabemos que $\forall n \in \mathbb{N} : S_n := \min\{T, n\}$ es un tiempo de parada (ejercicio 13, apartado (c) tomando $T_1 = T$ y $T_2 = n$). Entonces

$$\mathcal{F}_{S_n} = \{A \in \Sigma : \forall k \in \mathbb{N} : A \cap \{\min\{T, n\} \leq k\} \in \mathcal{F}_k\}$$

define una filtración ya que $S_n \leq S_{n+1} \implies \mathcal{F}_{S_n} \subset \mathcal{F}_{S_{n+1}}$ (Lema 4.3.3:(1)).

Además, por el Lema 4.3.3:(3), $Y_n = X_{S_n}$ es $\mathcal{F}_{S_n}$ -medible. Luego $(Y_n)_{n \in \mathbb{N}}$ es un proceso adaptado a la filtración $(\mathcal{F}_{S_n})_{n \in \mathbb{N}}$.

Solo falta ver que $\mathbb{E}[Y_{n+1} | \mathcal{F}_{S_n}] \geq Y_n$ c.s. Como $S_n = \min\{T, n\} \leq \min\{T, n+1\} = S_{n+1}$ y $(X_n)_n$ es una submartingala, por el Teorema 4.3.4:(2), tenemos que

$$\mathbb{E}[Y_{n+1} | \mathcal{F}_{S_n}] = \mathbb{E}[X_{S_{n+1}} | \mathcal{F}_{S_n}] \geq X_{S_n} = Y_n.$$

Por tanto, $(Y_n)_{n \in \mathbb{N}}$ es una submartingala con respecto a la filtración $(\mathcal{F}_{S_n})_{n \in \mathbb{N}}$. ■

17. Sea $\{X_n\}_n$ una sucesión de variables aleatorias independientes, $\sup_n \|X_n\|_1 < \infty$, y

$\mathbb{E}[X_j] = \mathbb{E}[X_\ell]$ para todos j, ℓ . Sea $\mathcal{L}^1(\mathbb{P}) \ni N : \Omega \rightarrow \mathbb{N}$ una variable aleatoria independiente de la sucesión $(X_n)_n$. Demostrar

$$\mathbb{E}[S_N] = \mathbb{E}[N] \cdot \mathbb{E}[X_1].$$

Solución: Consideramos la partición de Ω dada por los conjuntos

$$\forall k \in \mathbb{N} : N^{-1}(k) = \{\omega \in \Omega : N(\omega) = k\}.$$

Podemos calcular la esperanza de S_N en cada uno de estos conjuntos:

$$\mathbb{E}[S_N] = \int_{\Omega} S_N(\omega) d\mathbb{P}(\omega) = \int_{\bigsqcup_k \{N=k\}} S_N d\mathbb{P} = \int_{\Omega} S_N \left(\sum_{k=1}^{\infty} \mathbb{1}_{\{N=k\}} \right) d\mathbb{P}$$

Veamos que las variables $(S_N \cdot \mathbb{1}_{\{N=k\}})_{k \in \mathbb{N}}$ están dominadas por una función en $\mathcal{L}^1$ para aplicar el TCD:

$$|S_N \cdot \mathbb{1}_{\{N=k\}}| \leq |S_N| = \left| \sum_{j=1}^N X_j \right| \leq \sum_{j=1}^N |X_j|.$$

Como las X_n están uniformemente en $\mathcal{L}^1(\mathbb{P})$ ($\sup_n \|X_n\|_1 < \infty$), la suma de un número finito de ellas también lo está y como $N \in \mathcal{L}^1$, $N < \infty$ c.s. y podemos aplicar el teorema de convergencia dominada a $(S_N \cdot \mathbb{1}_{\{N=k\}})_{k \in \mathbb{N}}$ c.s.:

$$\mathbb{E}[S_N] = \sum_{k=1}^{\infty} \int_{\{N=k\}} S_N d\mathbb{P} = \sum_{k=1}^{\infty} \mathbb{E}[S_N \cdot \mathbb{1}_{\{N=k\}}] = \sum_{k=1}^{\infty} \mathbb{E}[S_k \cdot \mathbb{1}_{\{N=k\}}].$$

Ahora, como N es independiente de $(X_n)_n$, y $f : \mathbb{R}^k \rightarrow \mathbb{R}$ dada por $f(x_1, \dots, x_k) = \sum_j x_j$ es una función medible, por el ??:??, N es independiente de $S_k = \sum_{j=1}^k X_j$. Por tanto, podemos aplicar la Proposición 2.1.3:

$$\mathbb{E}[S_N] = \sum_{k=1}^{\infty} \mathbb{E}[S_k \cdot \mathbb{1}_{\{N=k\}}] = \sum_{k=1}^{\infty} \mathbb{E}[S_k] \cdot \mathbb{E}[\mathbb{1}_{\{N=k\}}].$$

Como $\forall j \in \mathbb{N} : \mathbb{E}[X_j] = \mathbb{E}[X_1]$, por linealidad de la esperanza, $\mathbb{E}[S_k] = k \cdot \mathbb{E}[X_1]$

$$\implies \mathbb{E}[S_N] = \sum_{k=1}^{\infty} k \cdot \mathbb{E}[X_1] \cdot \mathbb{P}(N = k) = \mathbb{E}[X_1] \cdot \sum_{k=1}^{\infty} k \cdot \mathbb{P}(N = k) = \mathbb{E}[X_1] \cdot \mathbb{E}[N].$$

■

H.4.3 Problemas para ampliar

[18.] Demostrar la desigualdad de Jensen condicional.

Solución: Se trata del Lema 4.2.1.

[19.] Demostrar la desigualdad de Hölder condicional.

Solución: Se trata de la Proposición 4.2.3.

[20.] Sea X una submartingala tal que

$$\sup_n \|X_n\|_1 < \infty.$$

Demostrar que $X_n = Y_n - Z_n$, donde Y es una martingala y Z es una supermartingala no negativa. Además,

$$\sup_n \|Y_n\|_1 < \infty, \quad \sup_n \|Z_n\|_1 < \infty.$$

Si además $X_n \geq 0$ para todo n , entonces $Y_n \geq 0$ para todo n .

Indicación: Definir $Y_n = \lim_{k \rightarrow \infty} \mathbb{E}[X_k \mid \mathcal{F}_n]$.

[21.] Sea X una submartingala tal que

$$\sup_n \|X_n\|_1 < \infty.$$

Demostrar que X_n converge c.s.

H.5 Comportamiento a largo plazo de sucesiones

H.5.1 Ejercicios básicos

[1.] Sea $(X_n)_n$ una sucesión de v.a.i. tales que $\sup_n \mathbb{E}[|X_n|] < \infty$. Demostrar que existe una sucesión de números $(a_n)_{n \in \mathbb{N}}$ tal que $(S_n - a_n)/n \xrightarrow{n \rightarrow \infty} 0$ casi seguro y en $\mathcal{L}^1(\mathbb{P})$.

[2.] Sea $y \geq 0$. Demostrar $2y \sum_{k>y} \frac{1}{k^2} \leq 4$.

[3.] Sea X una variable aleatoria. Demostrar:

(a) $\varphi_X(0) = 1$.

(b) $\varphi_X(-t) = \overline{\varphi_X(t)}$.

(c) $|\varphi_X(t)| \leq 1$ para todo $t \in \mathbb{R}$.

(d) $\varphi_X(t)$ es uniformemente continua en $\mathbb{R}$.

(e) $\varphi_{aX+b}(t) = e^{itb} \varphi_X(at)$.

Solución: Recordamos que, por definición, $\varphi_X(t) = \mathbb{E}[e^{itX}]$. Entonces:

(a) $\varphi_X(0) = \mathbb{E}[e^{i0X}] = \mathbb{E}[1] = 1$.

(b) $\varphi_X(-t) = \mathbb{E}[e^{-itX}] = \mathbb{E}[\overline{e^{itX}}] = \overline{\mathbb{E}[e^{itX}]} = \overline{\varphi_X(t)}$.

(c) $|\varphi_X(t)| = |\mathbb{E}[e^{itX}]| \leq \mathbb{E}[|e^{itX}|] = \mathbb{E}[1] = 1$.

(d) Sea $\varepsilon > 0$, tomamos $\delta > 0$ y $t_1, t_2 \in \mathbb{R}$ tales que $|t_1 - t_2| < \delta$. Entonces,

$$\begin{aligned} |\varphi_X(t_1) - \varphi_X(t_2)| &= |\mathbb{E}[e^{it_1X}] - \mathbb{E}[e^{it_2X}]| = |\mathbb{E}[e^{it_1X} - e^{it_2X}]| \\ &= \left| \mathbb{E}\left[e^{it_1X} (1 - e^{i(t_2-t_1)X})\right] \right| \leq \mathbb{E}[|1 - e^{i(t_2-t_1)X}|] . \end{aligned}$$

(e) $\varphi_{aX+b}(t) = \mathbb{E}[e^{it(aX+b)}] = \mathbb{E}[e^{itb} e^{itaX}] = e^{itb} \mathbb{E}[e^{itaX}] = e^{itb} \varphi_X(at)$.

[4.] Si X e Y son independientes, demostrar

$$\varphi_{X+Y}(t) = \varphi_X(t) \cdot \varphi_Y(t).$$

Solución: Por definición, tenemos que $\varphi_{X+Y}(t) = \mathbb{E}[e^{it(X+Y)}] = \mathbb{E}[e^{itX} e^{itY}]$. Ahora bien, como X e Y son independientes, por el ??, e^{itX} y e^{itY} son independientes.

Por tanto, por la Proposición 2.1.3, tenemos que

$$\varphi_{X+Y}(t) = \mathbb{E} [e^{itX} \cdot e^{itY}] = \mathbb{E} [e^{itX}] \cdot \mathbb{E} [e^{itY}] = \varphi_X(t) \cdot \varphi_Y(t).$$

■

[5.] Decidir si la siguiente afirmación es cierta: si X es una normal de media μ y varianza 1, es decir, si

$$f_X(t) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(t-\mu)^2}{2}},$$

entonces $\mathbb{E}[X^3] = 0$.

Solución: Sea $Z = X - \mu$, entonces Z es una normal de media 0 y varianza 1. Por tanto,

$$\mathbb{E}[Z^3] = \int_{\Omega} Z^3 d\mathbb{P} \stackrel{2.1.1}{=} \int_{\mathbb{R}} t^3 \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt = 0$$

ya que el integrando es una función impar.

Por otro lado, podemos calcular $\mathbb{E}[Z^3]$ en función de $\mathbb{E}[X^3]$:

$$\mathbb{E}[Z^3] = \mathbb{E}[(X - \mu)^3] = \mathbb{E}[X^3] - 3\mu \mathbb{E}[X^2] + 3\mu^2 \mathbb{E}[X] - \mu^3.$$

Ahora bien, como $1 = \mathbb{V}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2 \implies \mathbb{E}[X^2] = 1 + \mu^2$. Luego

$$\mathbb{E}[Z^3] = \mathbb{E}[X^3] - 3\mu(1 + \mu^2) + 3\mu^3 - \mu^3 = \mathbb{E}[X^3] - 3\mu - \mu^3.$$

Como $\mathbb{E}[Z^3] = 0$, tenemos que $\mathbb{E}[X^3] = 3\mu + \mu^3$. Es decir, si $\mu \notin \{0, \pm\sqrt{3}\}$, entonces $\mathbb{E}[X^3] \neq 0$. Luego la afirmación es falsa en general.

[6.] Demuestra que si φ es la función característica de alguna variable aleatoria, $|\varphi|^2$ es la función característica de alguna variable aleatoria.

Solución: Sea X una variable aleatoria con función característica φ . Sabemos que $\exists Y: \mathbb{R} \rightarrow \mathbb{R}$ y una medida μ en $\mathbb{R}$ tal Y tiene la misma distribución en $(\mathbb{R}, \mu)$ que X . Entonces, $(\mathbb{R}^2, \mu \times \mu)$ es un espacio de probabilidad donde X_1 y X_2 , dadas por

$$\begin{aligned} X_1: \mathbb{R}^2 &\longrightarrow \mathbb{R} & X_2: \mathbb{R}^2 &\longrightarrow \mathbb{R} \\ (x, y) &\longmapsto Y(x) & (x, y) &\longmapsto Y(y), \end{aligned} \quad \wedge$$

son independientes y tienen la misma distribución que X .

Entonces, $\varphi_{X_1-X_2}(t) \underset{4}{=} \varphi_{X_1}(t) \cdot \varphi_{-X_2}(t) \underset{3:(e)}{=} \varphi_{X_1}(t) \cdot \varphi_{X_2}(-t) \underset{3:(b)}{=} \varphi_X(t) \cdot \overline{\varphi_X(t)} = |\varphi_X(t)|^2$. ■

H.5.2 Problemas

[7.] Sea $\{X_n\}$ una sucesión de v.a.i.i.d. uniformes en $[0, 1]$. Demostrar:

(a) Para todo $p > 0$,

$$\left(\frac{1}{n} \sum_{j=1}^n X_j^p\right)^{\frac{1}{p}} \xrightarrow{n \rightarrow \infty} \left(\frac{1}{p+1}\right)^{\frac{1}{p}}$$

en probabilidad.

(b) $(X_1 \cdots X_n)^{1/n} \rightarrow e^{-1}$ en probabilidad.

Solución:

(a) Como las X_j son i.i.d., $\forall p > 0$: las X_j^p son i.i.d. (??) y se tiene que

$$\forall j \in \mathbb{N} : \mathbb{E}[X_j^p] = \int_{\Omega} X_j^p d\mathbb{P} = \int_0^1 x^p dx = \left[\frac{x^{p+1}}{p+1}\right]_0^1 = \frac{1}{p+1}.$$

Entonces, por la ley fuerte de los grandes números, sabemos que

$$\frac{1}{n} \sum_{j=1}^n X_j^p \xrightarrow[n \rightarrow \infty]{\text{c.s.}} \mathbb{E}[X_1^p] = \frac{1}{p+1}.$$

Por lo tanto, $\left(\frac{1}{n} \sum_{j=1}^n X_j^p\right)^{\frac{1}{p}} \xrightarrow[n \rightarrow \infty]{\text{c.s.}} \left(\frac{1}{p+1}\right)^{\frac{1}{p}}$ y, como la convergencia casi segura implica la convergencia en probabilidad, hemos terminado. ■

(b) Definimos $\forall n \in \mathbb{N} : P_n = \left(\prod_{j=1}^n X_j\right)^{1/n}$, entonces $\log P_n = \frac{1}{n} \sum_{j=1}^n \log X_j$.

Entonces, igual que en el apartado anterior, como las X_j son i.i.d., las $\log X_j$ también lo son y, por la ley fuerte de los grandes números, tenemos que

$$\log P_n \xrightarrow[n \rightarrow \infty]{\text{c.s.}} \mathbb{E}[\log X_1] = \int_0^1 \log x dx = \left[x \log x - x\right]_0^1 = 0 - 0 - 1 = -1.$$

Por lo tanto, $P_n \xrightarrow[n \rightarrow \infty]{\text{c.s.}} e^{-1}$. Igual que en el apartado anterior, como la convergencia casi segura implica la convergencia en probabilidad, hemos terminado. ■

[8.] Sea X una variable con distribución normal de media 0 y varianza 1, es decir, que X tiene densidad $f_X(t) = \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}$. Demostrar que $\varphi_X(t) = e^{-\frac{t^2}{2}}$.

Solución: Sea $t \in \mathbb{R}$. Tenemos que, $\varphi_X(t) = \mathbb{E}[e^{itX}] = \int_{\mathbb{R}} e^{itx} f_X(x) dx$

$$\begin{aligned} \Rightarrow \varphi_X(t) &= \int_{\mathbb{R}} e^{itx} \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{-\frac{x^2}{2}} \cdot e^{itx} dx \\ &= \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} \exp\left(-\frac{x^2}{2} + itx - \frac{t^2}{2} + \frac{t^2}{2}\right) dx = e^{-\frac{t^2}{2}} \cdot \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{-\frac{1}{2}(x-it)^2} dx. \end{aligned}$$

Como la integral $\int_{\mathbb{R}} e^{-\frac{1}{2}(x-it)^2} dx$ es la integral de una función gaussiana, sabemos que vale $\sqrt{2\pi}$. Por tanto, nos queda

$$\varphi_X(t) = e^{-\frac{t^2}{2}} \cdot \frac{1}{\sqrt{2\pi}} \cdot \sqrt{2\pi} = e^{-\frac{t^2}{2}}.$$

■

[9.] Si X_n es independiente de Y_n para todo n , $X_n \rightarrow X$ e $Y_n \rightarrow Y$ en distribución, y X e Y son independientes, demuestra que $X_n + Y_n \rightarrow X + Y$ en distribución.

Solución: Por el Teorema de Lévy, basta ver que $\varphi_{X_n+Y_n}(t) \rightarrow \varphi_{X+Y}(t)$ para todo $t \in \mathbb{R}$.

Por el Teorema de Lévy, como $X_n \rightarrow X$ e $Y_n \rightarrow Y$ en distribución, sabemos que para todo $t \in \mathbb{R}$, $\varphi_{X_n}(t) \xrightarrow{n \rightarrow \infty} \varphi_X(t)$ y $\varphi_{Y_n}(t) \xrightarrow{n \rightarrow \infty} \varphi_Y(t)$. Por tanto, tenemos que

$$\varphi_{X_n+Y_n}(t) \stackrel{\text{indep}}{=} \varphi_{X_n}(t) \cdot \varphi_{Y_n}(t) \xrightarrow{n \rightarrow \infty} \varphi_X(t) \cdot \varphi_Y(t) \stackrel{\text{indep}}{=} \varphi_{X+Y}(t).$$

■

[10.] Sea X una variable aleatoria tal que $\int |s|^n d\mu_X(s) < \infty$.

Demostrar que $\varphi_X^{(n)}(t) = \int (is)^n e^{its} d\mu_X(s)$.

Solución: Sabemos que $\varphi_X(t) = \mathbb{E}[e^{itX}] = \int e^{its} d\mu_X(s)$. Entonces, para calcular $\varphi_X^{(n)}(t)$ queremos “meter” la derivada dentro de la integral.

Para ello, comprobemos que todas las derivadas de e^{its} , es decir, las f_n dadas por

$$f_n(t, s) := \frac{d^n}{dt^n} e^{its} = (is)^n e^{its},$$

satisfacen las propiedades del Teorema 5.2.2:

(i) $\int_{\mathbb{R}} |(is)^n e^{its}| d\mu_X(s) = \int_{\mathbb{R}} |s|^n d\mu_X(s) < \infty$ por hipótesis.

(ii) $\frac{\partial}{\partial t} (is)^n e^{its} = (is)^n i s e^{its} = (is)^{n+1} e^{its}$, que es continua en t para todo $s \in \mathbb{R}$.

(iii) Sea $\delta > 0$ un número real positivo cualquiera. Entonces,

$$\begin{aligned} \int_{\mathbb{R}} \int_{-\delta}^{\delta} \left| \frac{\partial}{\partial t} (is)^n e^{i(t+\theta)s} \right| d\theta d\mu_X(s) &= \int_{\mathbb{R}} \int_{-\delta}^{\delta} |(is)^{n+1} e^{i(t+\theta)s}| d\theta d\mu_X(s) \\ &= \int_{\mathbb{R}} |s|^{n+1} \int_{-\delta}^{\delta} d\theta d\mu_X(s) \\ &= \int_{\mathbb{R}} |s|^{n+1} \cdot 2\delta d\mu_X(s) = 2\delta \int_{\mathbb{R}} |s|^{n+1} d\mu_X(s) < \infty. \end{aligned}$$

Como se satisfacen las tres propiedades del Teorema 5.2.2, podemos intercambiar la integral y la derivada:

$$\varphi_X^{(n)}(t) = \frac{d^n}{dt^n} \int e^{its} d\mu_X(s) = \int \frac{d^n}{dt^n} e^{its} d\mu_X(s) = \int (is)^n e^{its} d\mu_X(s).$$

■

11. Demostrar que, para todo $t \in \mathbb{R}$,

$$\left| e^{it} - \sum_{m=0}^n \frac{(it)^m}{m!} \right| \leq \min \left\{ \frac{|t|^{n+1}}{(n+1)!}, \frac{2|t|^n}{n!} \right\}.$$

12. Sea $(\Omega, \Sigma, \mathbb{P})$ el intervalo $[0, 1]$ con la medida de Lebesgue. Escribimos $\omega \in (0, 1)$ usando la expansión decimal habitual. Definimos $S_n(\omega)$ como el número de setes que aparecen en las n primeras posiciones de la expansión decimal de ω ; por ejemplo, $S_3(0.777) = 3$, $S_3(0.12345) = 0$.

(a) Decidir razonadamente si $n^{-1}S_n$ converge casi seguro, y en caso de respuesta afirmativa, hallar el límite.

(b) Decidir razonadamente si $(S_n - 10^{-1}n)$ converge casi seguramente a una constante, y en caso de respuesta afirmativa, hallar el límite.

(c) Decidir razonadamente si

$$\frac{S_n - 10^{-1}n}{n^{1/2}}$$

converge casi seguramente a una constante, y en caso de respuesta afirmativa, hallar el límite.

(d) Decidir razonadamente si

$$\frac{S_n - 10^{-1}n}{n^{2/3}}$$

converge en distribución, y en caso de respuesta afirmativa, hallar el límite.

Solución: Si definimos la sucesión $(X_j)_{j \in \mathbb{N}}$ dada por

$$\forall j \in \mathbb{N} : \forall \omega \in (0, 1) : X_j(\omega) = \begin{cases} 1 & \text{si el } j\text{-ésimo dígito de } \omega \text{ es un siete} \\ 0 & \text{en otro caso,} \end{cases}$$

entonces $S_n = \sum_{j=1}^n X_j$ y, por lo visto en la sección A.3 de la entrega, las X_j son independientes y $\forall j \in \mathbb{N} : \mathbb{P}(X_j = 1) = 1/10$. Por tanto, $\mathbb{E}[X_j] = 1/10$.

(a) Como las X_j son v.a.i.i.d., por la ley fuerte de los grandes números,

$$\frac{S_n}{n} \xrightarrow[n \rightarrow \infty]{\text{c.s.}} \mathbb{E}[X_1] = \frac{1}{10}.$$

(b) Tenemos que $\forall n \in \mathbb{N} : \mathbb{E}[S_n - n/10] = n \cdot \mathbb{E}[X_1] - n/10 = 0$. Como $\mathbb{V}(X_j) = 9/100$, las X_j están en $\mathcal{L}^2$ y, por el teorema central del límite, se tiene que

$$\frac{S_n - n/10}{\sqrt{n} \sqrt{9/100}} \xrightarrow[n \rightarrow \infty]{\text{d}} \mathcal{N}(0, 1).$$

Luego sospechamos que $S_n - n/10$ no va a converger casi seguro a una constante. Veámoslo formalmente: Sea $\varepsilon > 0$, entonces

$$\begin{aligned} \mathbb{P} \left(\limsup_{n \rightarrow \infty} \left\{ \frac{S_n - n/10}{\sqrt{n} \sqrt{9/100}} > \varepsilon \right\} \right) &\stackrel{\text{Fatou}}{\geq} \limsup_{n \rightarrow \infty} \mathbb{P} \left(\frac{|S_n - n/10|}{\sqrt{9/100}} > \frac{\varepsilon}{\sqrt{9/100}} \right) = \\ &\stackrel{\text{TCL}}{\geq} \mathbb{P} \left(|Z| > \frac{\varepsilon}{\sqrt{9/100}} \right) > 0 \end{aligned}$$

donde Z es una normal de media 0 y varianza 1. Por tanto, $S_n - n/10$ no converge casi seguro a una constante.

(c) Por el teorema central del límite, $\frac{S_n - n/10}{\sqrt{n}} \xrightarrow[n \rightarrow \infty]{\text{d}} \mathcal{N}(0, \mathbb{V}(X_1))$.

Como $\mathbb{V}(X_1) = 9/100 \neq 0$, $\frac{S_n - n/10}{\sqrt{n}}$ no puede converger casi seguro a una constante.

(d) Veamos que $G_n := \frac{S_n - n/10}{n^{2/3}}$ converge en distribución a $X \equiv 0$. Tenemos que la función de distribución de X viene dada por

$$\forall t \in \mathbb{R} : F_X(t) = \mathbb{P}(X \leq t) = \begin{cases} 0 & \text{si } t < 0 \\ 1 & \text{si } t \geq 0. \end{cases}$$

Tomamos $t \in \mathbb{R}$ punto de continuidad de F_X , entonces

$$\begin{aligned}\mathbb{P}(G_n \leq t) &= \mathbb{P}\left(\frac{S_n - n/10}{n^{2/3}} \leq t\right) = \mathbb{P}\left(\frac{S_n - n/10}{\sqrt{n}} \leq tn^{1/6}\right) \\ &= \mathbb{P}\left(\frac{S_n - n/10}{\sqrt{n}\sqrt{9/100}} \leq \frac{tn^{1/6}}{\sqrt{9/100}}\right)\end{aligned}$$

Para $t > 0$, podemos fijar $M > \frac{tn^{1/6}}{\sqrt{9/100}} > 0$. Entonces, para n suficientemente grande, por el teorema central del límite, tenemos que

$$\mathbb{P}(G_n \leq t) = \mathbb{P}\left(\frac{S_n - n/10}{\sqrt{n}\sqrt{9/100}} \leq M\right) \xrightarrow[M \rightarrow \infty]{n \rightarrow \infty} 1 = F_X(t).$$

Si $t < 0$, un argumento similar nos lleva a que $\mathbb{P}(G_n \leq t) \xrightarrow{n \rightarrow \infty} 0 = F_X(t)$.

Por tanto, $G_n \xrightarrow[n \rightarrow \infty]{d} X$.

13. Una variable aleatoria X tiene distribución de Poisson de parámetro $\lambda > 0$ si

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k \in \{0, 1, 2, 3, \dots\}.$$

- (a) Demostrar que la fórmula de arriba define la distribución de probabilidad de X .
- (b) Calcular $\varphi_X(t)$.
- (c) Demostrar que si X_j son independientes y tienen distribución de Poisson de parámetros λ_j , entonces su suma tiene distribución de Poisson de parámetro $\sum_j \lambda_j$.

14. Sea $(X_n)_{n \in \mathbb{N}}$ un proceso adaptado a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$ tal que $\forall j \in \mathbb{N} : \mathbb{E}[X_j] = 1$. Sea $P_n = \prod_{j=1}^n X_j$.

- (a) Demostrar que P_n es una martingala.
- (b) Si además $X_j \geq 0$ casi seguro, demostrar que P_n converge casi seguro.
- (c) En las hipótesis del apartado anterior, estudiar la convergencia casi seguro de $P_n^{1/n}$ si las X_j están idénticamente distribuidas.

Solución:

(a) Tenemos que comprobar que $\mathbb{E}[P_{n+1} \mid \mathcal{F}_n] = P_n$ casi seguro:

$$\begin{aligned}\mathbb{E}[P_{n+1} \mid \mathcal{F}_n] &= \mathbb{E}\left[X_{n+1} \prod_{j=1}^n X_j \mid \mathcal{F}_n\right] \\ &= \prod_{j=1}^n X_j \cdot \mathbb{E}[X_{n+1} \mid \mathcal{F}_n] = P_n \cdot \mathbb{E}[X_{n+1} \mid \mathcal{F}_n].\end{aligned}$$

Ahora bien, si P fuese una martingala, tendríamos que $\mathbb{E}[X_{n+1} \mid \mathcal{F}_n] \equiv \mathbb{E}[X_{n+1}] = 1$ casi seguro. Esta es una caracterización de la independencia de $\sigma(X_{n+1})$ y $\mathcal{F}_n$ (Proposición 4.1.4), luego en el enunciado falta una hipótesis de independencia entre X_{n+1} y $\mathcal{F}_n$ para que P_n sea una martingala. ■

(b) Tenemos que $\mathbb{E}[P_n] = \prod_{j=1}^n \mathbb{E}[X_j] = 1$. Como $X_j \geq 0$ casi seguro, $P_n \geq 0$ casi seguro. Por lo tanto, $\sup_n \|P_n\|_1 = \sup_n \mathbb{E}[P_n] = 1 < \infty$.

Entonces, por el teorema de convergencia de martingalas, P_n converge casi seguro.

(c) Como (por el apartado anterior) P_n converge casi seguro, $\exists P$ variable aleatoria tal que $P_n^{1/n} \xrightarrow[n \rightarrow \infty]{\text{c.s.}} P$. Tomando logaritmos, tenemos que

$$\log(P_n^{1/n}) = \frac{1}{n} \log\left(\prod_{j=1}^n X_j\right) = \frac{1}{n} \sum_{j=1}^n \log X_j \xrightarrow[n \rightarrow \infty]{\text{c.s.}} \log P.$$

[15.] Supón que las X_j están idénticamente distribuidas, $\text{Var}(X_1) = \sigma^2 \in (0, 1)$, $\mathbb{E}[X_1] = 1$, y $X_1 \geq 0$ casi seguro. Demuestra que

$$\sqrt{n}(S_n - n) \rightarrow \mathcal{N}(0, \sigma^2)$$

en distribución, donde $\mathcal{N}(0, \sigma^2)$ tiene densidad

$$f(t) = \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}.$$

A. Entrega

Notación: En esta entrega $\forall N \in \mathbb{N} : \mathbb{N}_N := \{1, 2, \dots, N\} = \{n \in \mathbb{N} : n \leq N\}$.

A.1 El *Quijote* finito

Ya sabemos que, dado tiempo infinito, un mono aporreando un teclado escribirá el *Quijote*. Formalmente, sea N el número de caracteres distintos que empleó Miguel de Cervantes para escribir el *Quijote*, L la longitud del libro en esos caracteres, y $(Q_j)_{j \in \mathbb{N}_L} : \forall j \in \mathbb{N}_L : Q_j \in \mathbb{N}_N$ la secuencia de caracteres de longitud L que constituye el *Quijote*.

Consideramos $(X_j)_{j \in \mathbb{N}}$ una sucesión de variables aleatorias independientes e idénticamente distribuidas en un espacio de probabilidad $(\Omega, \Sigma, \mathbb{P})$ con $\forall j \in \mathbb{N} : X_j \sim \text{Unif}(\mathbb{N}_N)$. Entonces, si definimos

$$\forall n \in \mathbb{N} : A_n := \{\omega \in \Omega : \forall i \in \mathbb{N}_L : X_{(n-1)L+i} = Q_i\},$$

A_n es el suceso en que el mono escribe el *Quijote* entre los caracteres $(n-1)L+1$ y nL , es decir, en el n -ésimo bloque de longitud L . Como las variables aleatorias son independientes,

$$\begin{aligned} \forall n \in \mathbb{N} : \mathbb{P}(A_n) &= \mathbb{P}(\{X_{(n-1)L+1} = Q_1\} \cap \dots \cap \{X_{nL} = Q_L\}) \\ &\stackrel{\substack{\uparrow \\ \text{indep}}}{=} \mathbb{P}(X_{(n-1)L+1} = Q_1) \cdot \dots \cdot \mathbb{P}(X_{nL} = Q_L) = \left(\frac{1}{N}\right)^L. \end{aligned}$$

Además, los A_n son independientes (porque las X_j lo son) y $\sum_{n \in \mathbb{N}} \mathbb{P}(A_n) = \sum_{n \in \mathbb{N}} \left(\frac{1}{N}\right)^L = \infty$.

Entonces, por el lema de Borel-Cantelli II, $\mathbb{P}\left(\limsup_{n \rightarrow \infty} A_n\right) = 1$.

Es decir, el mono no solo escribirá el *Quijote* una vez, sino que lo hará infinitas veces.

A.2 Un *Quijote* infinito

Imaginemos por un momento que requerimos una secuencia infinita de caracteres $(Q_j)_{j \in \mathbb{N}}$ tal que $\forall j \in \mathbb{N} : Q_j \in \mathbb{N}_N$ para escribir el *Quijote*. En tal caso, ¿escribiría el mono este *Quijote* infinito?

Debemos precisar esta pregunta antes de tratar de contestarla. Estudiaremos varias posibles interpretaciones y sus respuestas:

A.2.1 Un *Quijote* con infinitos capítulos finitos

Supongamos que este libro se encuentra dividido en infinitos capítulos $(C^k)_{k \in \mathbb{N}}$, cada uno con longitud finita $L_k \in \mathbb{N}$. Es decir, $\forall k \in \mathbb{N} : \forall j \in \mathbb{N}_{L_k} : C_j^k = Q_{j+\sum_{l=1}^{k-1} L_l}$.

$$\underbrace{Q_1, Q_2, \dots, Q_{L_1}}_{C^1}, \underbrace{Q_{L_1+1}, \dots, Q_{L_1+L_2}}_{C^2}, \dots, \underbrace{Q_{1+\sum_{l=1}^{k-1} L_l}, \dots, Q_{\sum_{l=1}^k L_l}}_{C^k}, \dots$$

Supongamos también que nos basta con que el mono escriba cada capítulo al menos una vez, sin importar el orden. Entonces, podemos interpretar cada capítulo como un *Quijote* finito y aplicar el razonamiento de la sección A.1:

$$A_n^k := \left\{ \omega \in \Omega : \forall i \in \mathbb{N}_{L_k} : X_{(n-1)L_k+i} = C_i^k \right\} \implies \forall k \in \mathbb{N} : \mathbb{P} \left(\limsup_{n \rightarrow \infty} (A_n^k) \right) = 1.$$

Por tanto, el mono escribirá cada capítulo infinitas veces con probabilidad 1.

Ahora bien, no necesariamente lo hará en orden, puede que escriba el capítulo número 39458423 antes que el primero. Además, puede que algunos capítulos aparezcan solapados, por ejemplo si las últimas letras de uno coinciden con las primeras de otro.

En ambos escenarios, hasta que el mono llegue al primer capítulo podremos ignorar todo lo que escriba, de la misma manera hasta que llegue al segundo capítulo y así sucesivamente:

$$A := \left\{ \omega \in \Omega : \exists (n_k)_{k \in \mathbb{N}} \subset \mathbb{N} : \forall k \in \mathbb{N} : n_k + L_k \leq n_{k+1} \wedge \omega \in A_{n_k}^k \right\} \implies \mathbb{P}(A) = 1.$$

Es decir, existe (con probabilidad 1) una sucesión de índices $(n_k)_{k \in \mathbb{N}}$ tales que el mono escribe el capítulo k entre los caracteres n_k y $n_k + L_k - 1$, sin que se solape con los demás capítulos. Por tanto, bajo esta interpretación de la pregunta, el mono sí escribirá el *Quijote* infinito.

A.2.2 Un *Quijote* infinito e indivisible

Ahora bien, si queremos que los capítulos se escriban en orden sin ningún carácter entre ellos, estamos pidiendo que, a partir de algún índice, el mono escriba todo el *Quijote* infinito de seguido. Por tanto, queremos calcular la probabilidad de

$$B := \left\{ \omega \in \Omega : \exists n \in \mathbb{N} : \forall j \in \mathbb{N} : X_{n-1+j} = Q_j \right\}.$$

Para ello, definimos B_n como el suceso de que se escriba el *Quijote* a partir del carácter n :

$$\forall n \in \mathbb{N} : B_n := \left\{ \omega \in \Omega : \forall j \in \mathbb{N} : X_{n-1+j} = Q_j \right\} \implies B = \bigcup_{n \in \mathbb{N}} B_n.$$

Además, definimos $B_{n,k}$ como el suceso en que el mono escribe los primeros k caracteres del *Quijote* infinito a partir del n -ésimo:

$$\forall n \in \mathbb{N}, k \in \mathbb{N} : B_{n,k} := \{\omega \in \Omega : \forall j \in \mathbb{N}_k : X_{n-1+j} = Q_j\} \implies B_n = \bigcap_{k \in \mathbb{N}} B_{n,k}.$$

- (1) Como $(B_{n,k})_{k \in \mathbb{N}}$ es una sucesión decreciente y estamos en un espacio de medida finito, por el teorema de convergencia monótona, tenemos que

$$\mathbb{P} \left(\bigcap_{k \in \mathbb{N}} B_{n,k} \right) = \lim_{k \rightarrow \infty} \mathbb{P}(B_{n,k}).$$

- (2) Como además las X_j son independientes, sabemos que

$$\mathbb{P}(B_{n,k}) = \mathbb{P}(\{X_n = Q_1\} \cap \dots \cap \{X_{n+k} = Q_k\}) = \prod_{j=1}^k \mathbb{P}(X_{n+j} = Q_j) = \left(\frac{1}{N}\right)^k.$$

Entonces, podemos calcular la probabilidad de cada B_n :

$$\forall n \in \mathbb{N} : \mathbb{P}(B_n) = \mathbb{P} \left(\bigcap_{k \in \mathbb{N}} B_{n,k} \right) \stackrel{(1)}{=} \lim_{k \rightarrow \infty} \mathbb{P}(B_{n,k}) \stackrel{(2)}{=} \lim_{k \rightarrow \infty} \left(\frac{1}{N}\right)^k = 0.$$

Por tanto, por subaditividad de la medida, tenemos que

$$\mathbb{P}(B) = \mathbb{P} \left(\bigcup_{n \in \mathbb{N}} B_n \right) \leq \sum_{n \in \mathbb{N}} \mathbb{P}(B_n) = 0.$$

Es decir, es casi seguro que el mono no escribirá el *Quijote* infinito de seguido.

A.3 Conexión con la medida de Lebesgue en $[0, 1]$

Se puede dibujar una conexión entre este problema y la medida de Lebesgue en el intervalo $[0, 1]$ que nos ofrece una forma alternativa de demostrar el resultado de la subsección A.2.2. Podemos interpretar la sucesión de variables aleatorias $(X_j - 1)_{j \in \mathbb{N}}$ como la expresión en base N de un número real en el intervalo $[0, 1]$ (sin incluir el 0 inicial).

Por ejemplo, $0 = 0.000 \dots$ vendría de la observación $(X_k(\omega))_{j \in \mathbb{N}} = (1)_{j \in \mathbb{N}}$ y $1 = 0.(N-1) \dots$ vendría de la observación $(X_k(\omega))_{j \in \mathbb{N}} = (N)_{j \in \mathbb{N}}$. Por tanto, definimos

$$Y : \Omega \longrightarrow [0, 1]$$

$$\omega \longmapsto \sum_{j \in \mathbb{N}} (X_j(\omega) - 1) \cdot N^{-j} = 0.(X_1(\omega) - 1)(X_2(\omega) - 1) \dots \text{ en base } N.$$

Veamos que entonces $Y \sim \text{Unif}([0, 1])$. Sea $y \in [0, 1]$, basta probar que $\mathbb{P}(Y \leq y) = y$.

Definimos $Y_k: \Omega \rightarrow [0, 1]$ dada por

$$\forall k \in \mathbb{N} : Y_k := \sum_{j=1}^k (X_j - 1) N^{-j},$$

$$\implies \forall k \in \mathbb{N}, \omega \in \Omega : Y_k(\omega) \in \left\{ 0, \frac{1}{N}, \dots, \frac{N^k - 1}{N^k} \right\} \text{ con } \forall r \in \mathbb{N}_{N^k} : \mathbb{P} \left(Y_k = \frac{r-1}{N^k} \right) = \frac{1}{N^k}.$$

Además, el máximo valor de Y_k que no excede y es $\lfloor N^k y \rfloor / N^k$, donde $\lfloor \cdot \rfloor$ es la función suelo

$$\implies \mathbb{P}(Y_k \leq y) = \sum_{r=1}^{\lfloor N^k y \rfloor} \mathbb{P} \left(Y_k = \frac{r-1}{N^k} \right) = \frac{\lfloor N^k y \rfloor}{N^k}.$$

Como $Y_1 \leq Y_2 \leq \dots$, la sucesión de conjuntos $(\{Y_k \leq y\})_{k \in \mathbb{N}}$ es decreciente y podemos aplicar el teorema de convergencia monótona (porque estamos en un espacio de medida finito)

$$\implies \lim_{k \rightarrow \infty} \mathbb{P}(Y_k \leq y) = \mathbb{P} \left(\lim_{k \rightarrow \infty} Y_k \leq y \right) = \mathbb{P}(Y \leq y).$$

Por tanto, concluimos que $\mathbb{P}(Y \leq y) = \lim_{k \rightarrow \infty} \frac{\lfloor N^k y \rfloor}{N^k} = y$. Es decir, $Y \sim \text{Unif}([0, 1])$

$$\implies \forall E \in \mathcal{B}([0, 1]) : \mathbb{P}(Y \in E) = m(E) \text{ donde } m \text{ es la medida de Lebesgue en } [0, 1].$$

Entonces, al reinterpretar el resultado de la subsección A.2.2, estamos diciendo que, si escogemos aleatoria y uniformemente un número real en $[0, 1]$, hay probabilidad nula de que su expresión en base N sea, a partir de algún punto, de una forma dada.

Observamos ahora que, efectivamente, solo hay una cantidad numerable de elementos en $[0, 1]$ que tienen esta propiedad ya que, determinados todos los dígitos de la expresión a partir del n -ésimo, solo hay $N^{(n-1)}$ posibles elecciones para los primeros $n-1$ dígitos:

$$0. \underbrace{d_1 \ d_2 \ d_3 \ \dots \ d_{n-1} \ d_n \ d_{n+1} \ \dots}_{\text{fijos}}$$

$$\begin{aligned} \implies \mathbb{P}(B) &= \mathbb{P}(Y = 0.d_1 d_2 \dots : \exists n \in \mathbb{N} : \forall j \geq n : d_j + 1 = Q_j) \\ &= m \left(\bigcup_{n \in \mathbb{N}} \underbrace{\{0.d_1 d_2 \dots : \forall j \geq n : d_j + 1 = Q_j\}}_{\text{contiene } N^{(n-1)} \text{ elementos}} \right) = 0. \end{aligned}$$

Así, hemos encontrado una forma alternativa de demostrar el resultado de la subsección A.2.2 mediante una relación con la medida de Lebesgue en $[0, 1]$.

Bibliografía

Durrett, R. (2019). *Probability: Theory and examples* (Fifth edition). Cambridge University Press. https://services.math.duke.edu/~rtd/PTE/PTE5_011119.pdf