
MATEMÁTICAS PARA EL APRENDIZAJE AUTOMÁTICO

Cuarto del Grado en Matemáticas

Hugo Marquerie

Profesor: Davide Barbieri

Facultad de Ciencias - Universidad Autónoma de Madrid

Segundo cuatrimestre 2025 - 2026

25 de junio de 2026

Puedes encontrar mi colección completa de apuntes en <https://hmarquer.github.io>.

Índice general

1. Aprendizaje no supervisado	1
1.1. Principal component analysis (PCA)	1
1.1.1. Planteamiento del problema	1
1.1.2. Solución (teorema y algoritmo)	1
1.2. <i>Clustering</i> espectral en grafos	3
1.2.1. Grafos ponderados y definiciones básicas	3
1.2.2. El problema de corte normalizado (NCut)	4
1.2.3. Formulación variacional para $k = 2$	5
1.2.4. Relajación espectral del problema NCut	7
1.2.5. Interpretación probabilística: caminos aleatorios	7
1.2.6. <i>Spectral Clustering</i> para $k > 2$	8
1.2.7. Otros algoritmos de agrupamiento	9
2. Fundamentos del aprendizaje supervisado	13
2.1. Learning Theory	13
2.1.1. Formulación del problema	13
2.1.2. Sobre el objetivo y el aprendizaje estadístico	14
2.1.3. The Bias-Variance Tradeoff	18
2.2. Espacios de Hilbert a núcleo reproductor (RKHS)	18
3. Clasificación y optimización convexa	27
3.1. Clasificadores Lineales Binarios	27
3.1.1. Fundamentos del problema	27
3.1.2. Separabilidad y geometría lineal	28
3.1.3. Hard Margin SVM	30
3.1.4. Soft Margin SVM	36
3.1.5. Support Vector Machines con Núcleo Reprodutor	37
3.2. Teorema de No Free Lunch (NFL)	42
3.2.1. Motivación y marco probabilístico	42
3.2.2. Demostración del resultado de Devroye	44
3.3. Descenso del gradiente	46
3.3.1. Descenso del gradiente clásico	46
3.3.2. Descenso del gradiente estocástico	53

3.4.	Clasificación multiclase	58
3.4.1.	El problema de clasificación con k clases	58
3.4.2.	Reducción a clasificación binaria	61
3.4.3.	Formulación directa: SVM de Crammer–Singer	65
3.4.4.	Extensión con núcleo reproductor	67
3.4.5.	Implementación y experimentos con <code>sklearn</code>	69
4.	Introducción a las redes neuronales	71
4.1.	Multilayer Perceptron (MLP)	71
4.1.1.	Backpropagation (Reverse differentiation)	72
4.2.	Teorema de aproximación universal	75
4.2.1.	Funciones <i>Ridge</i>	76
4.2.2.	Demostración del teorema de aproximación universal	79
4.2.3.	Capacidad de interpolación	82
4.3.	Funciones de activación de uso común	84
4.3.1.	Softmax en salida multiclase	85
4.4.	Apéndice: Modificadores de Friedrichs	86
5.	Aprendizaje por refuerzo	89
5.1.	Introducción y planteamiento del problema	89
5.2.	Programación Dinámica <i>Dynamic Programming</i>	91
A.	Apéndices	105
A.1.	Probabilidad condicionada	105
A.1.1.	Esperanza condicionada respecto de una σ -álgebra	105
A.1.2.	Esperanza condicionada dado un valor de una v.a.	106
A.1.3.	De la esperanza condicionada a la medida condicionada	107
A.2.	Análisis funcional	111

1. Aprendizaje no supervisado

1.1. Principal component analysis (PCA)

1.1.1. Planteamiento del problema

Sean $\{x_i\}_{i=1}^m \subset \mathbb{C}^n$ un conjunto de datos y sea $k < m$. El objetivo de PCA es encontrar la proyección de $\mathbb{C}^n$ de rango k (proyección sobre un subespacio $M \subset \mathbb{C}^n$ de dimensión k) que minimice el error cuadrático entre los datos originales y los datos proyectados:

$$\mathcal{E} = \sum_{i=1}^m \|x_i - \mathbb{P}_M x_i\|^2,$$

donde $\mathbb{P}_M$ es la proyección ortogonal sobre M . El PCA nos permite:

- Aproximar un conjunto de datos por un subespacio de dimensión menor.
- Una base ortonormal del subespacio M proporciona un diccionario “óptimo” para representar linealmente los datos.

1.1.2. Solución (teorema y algoritmo)

Sea $A = \begin{pmatrix} | & | & \cdots & | \\ x_1 & x_2 & \cdots & x_m \\ | & | & \cdots & | \end{pmatrix} \in \mathbb{C}^{n \times m}$ y sea $A = U\Sigma V^*$ su descomposición en valores singulares (SVD). Es decir, $U \in \mathbb{C}^{n \times n}$ y $V \in \mathbb{C}^{m \times m}$ son matrices unitarias y $\Sigma \in \mathbb{R}_+^{n \times m}$ es una matriz diagonal con los valores singulares $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$ en la diagonal, donde $r = \text{rang}(A)$.

Entonces, $M := \text{span}\{U^{(1)}, \dots, U^{(k)}\}$, donde $U^{(i)}$ es la i -ésima columna de U , es el subespacio que minimiza el error cuadrático $\mathcal{E}$. En consecuencia, la proyección ortogonal de los datos sobre M viene dada por

$$\forall x \in \mathbb{C}^n : \mathbb{P}_M x = \sum_{i=1}^k \langle x, U^{(i)} \rangle U^{(i)}.$$

Teorema 1.1.1. *Sea $A \in \mathbb{C}^{n \times m}$, $A = U\Sigma V^*$ su SVD y $k \leq \text{rang}(A)$. Definimos*

$$A_k = \sum_{i=1}^k \sigma_i U^{(i)} \otimes V^{(i)} \quad \text{donde} \quad (v \otimes w)_{ij} = v_i \overline{w_j}.$$

$$\implies \forall B \in \mathbb{C}^{n \times m} : \text{rang}(B) = k : \|A - B\|_{Fro}^2 \geq \|A - A_k\|_{Fro}^2 = \sum_{i=k+1}^{\text{rang } A} \sigma_i^2.$$

¿Por qué nos vale esto? La i -ésima columnas de A_k es $A_k^{(i)} = \sum_{\ell=1}^k \sigma_\ell \overline{V_{i\ell}} U^{(\ell)}$ donde $U^{(\ell)}$ es la ℓ -ésima columna de U y $\sigma_\ell \overline{V_{i\ell}} = \langle A^{(i)}, U^{(\ell)} \rangle = \langle x_i, U^{(\ell)} \rangle$. Entonces,

$$A_k^{(i)} = \sum_{\ell=1}^k \langle x_i, U^{(\ell)} \rangle U^{(\ell)} = \mathbb{P}_{\text{span}\{U^{(1)}, \dots, U^{(k)}\}} x_i = \mathbb{P}_M x_i.$$

Demostración: Dividimos la demostración en diferentes pasos:

Paso 1. Recordamos que la norma de Frobenius se puede escribir como $\|A\|_{\text{Fro}}^2 = \text{tr}(A^* A)$.

Por tanto,

$$\begin{aligned} \|A - A_k\|_{\text{Fro}}^2 &= \|U\Sigma V^* - U\Sigma_k V^*\|_{\text{Fro}}^2 = \|U(\Sigma - \Sigma_k)V^*\|_{\text{Fro}}^2 \\ &= \text{tr}(V(\Sigma - \Sigma_k)^* V^*) = \sum_{\ell=k+1}^{\text{rang } A} \sigma_\ell^2, \end{aligned}$$

puesto que $\Sigma - \Sigma_k$ es una matriz diagonal con los ceros en los primeros k elementos de la diagonal y los valores singulares $\sigma_{k+1}, \dots, \sigma_r$ en el resto.

Por tanto, basta demostrar que $\forall B \in \mathbb{C}^{n \times m} : \text{rang}(B) = k : \|A - B\|_{\text{Fro}}^2 \geq \sum_{\ell=k+1}^{\text{rang } A} \sigma_\ell^2$.

Paso 2. Sea $B \in \mathbb{C}^{n \times m}$ con $\text{rang}(B) = k$. Sea $B = XTY^*$ su SVD, con $X \in \mathbb{C}^{n \times n}$ y $Y \in \mathbb{C}^{m \times m}$ unitarias y $T \in \mathbb{R}_+^{n \times m}$ diagonal. Entonces,

$$\begin{aligned} \|A - B\|_{\text{Fro}}^2 &= \|A\|_{\text{Fro}}^2 + \text{tr}(B^* B - B^* A - A^* B) \\ &= \|A\|_{\text{Fro}}^2 + \sum_{\ell=1}^k t_\ell^2 - \sum_{\ell=1}^k t_\ell \text{tr}((y_\ell \otimes x_\ell)A + A^*(x_\ell \otimes y_\ell)), \end{aligned}$$

como $\sum_{\ell=1}^k t_\ell^2 = \sum_{\ell=1}^k t_\ell^2 \text{tr}(C_{y_\ell \otimes y_\ell})$ y $(y_\ell \otimes x_\ell)A = y_\ell \otimes (A^* x_\ell)$, tenemos que

$$\begin{aligned} \|A - B\|_{\text{Fro}}^2 &= \|A\|_{\text{Fro}}^2 + \sum_{\ell=1}^k \text{tr}((A^* x_\ell - t_\ell y_\ell) \otimes (A^* x_\ell - t_\ell y_\ell)) - \sum_{\ell=1}^k \text{tr}(A^* x_\ell \otimes A^* x_\ell) \\ &\geq \|A\|_{\text{Fro}}^2 - \sum_{\ell=1}^k \|A^* x_\ell\|^2, \end{aligned}$$

donde la desigualdad se obtiene porque $\text{tr}(v \otimes v) = \|v\|^2 \geq 0$.

Paso 3. Acotamos ahora $\sum_{\ell=1}^k \|A^* x_\ell\|^2$. Como $A = U\Sigma V^*$, tenemos que $A^* = V\Sigma^* U^*$, y por tanto $A^* x_\ell = V\Sigma^* U^* x_\ell$. Entonces,

$$\sum_{\ell=1}^k \|A^* x_\ell\|^2 = \sum_{\ell=1}^k \|V\Sigma^* U^* x_\ell\|^2 = \sum_{\ell=1}^k \|\Sigma^* U^* x_\ell\|^2,$$

donde hemos usado que V es unitaria y por tanto preserva la norma. Desarrollando la

norma,

$$\sum_{\ell=1}^k \|\Sigma^* U^* x_\ell\|^2 = \sum_{\ell=1}^k \sum_{i=1}^{\text{rang } A} \sigma_i^2 |\langle U^{(i)}, x_\ell \rangle|^2 = \sum_{i=1}^{\text{rang } A} \sigma_i^2 \sum_{\ell=1}^k |\langle U^{(i)}, x_\ell \rangle|^2.$$

Observamos que $\sum_{\ell=1}^k |\langle U^{(i)}, x_\ell \rangle|^2 = \|\mathbb{P}_k U^{(i)}\|^2$, donde $\mathbb{P}_k$ es el proyector ortogonal sobre $\text{span}\{x_1, \dots, x_k\}$. Denotando $p_i = \|\mathbb{P}_k U^{(i)}\|^2$, tenemos que:

- $p_i \leq 1$ para todo i , ya que $\|\mathbb{P}_k U^{(i)}\| \leq \|U^{(i)}\| = 1$.
- $\sum_{i=1}^{\text{rang } A} p_i \leq k$, ya que $\mathbb{P}_k$ proyecta sobre un subespacio de dimensión k .

Para maximizar $\sum_{i=1}^{\text{rang } A} \sigma_i^2 p_i$ sujeto a estas restricciones, como $\sigma_1 \geq \sigma_2 \geq \dots$, el máximo se alcanza cuando $p_1 = \dots = p_k = 1$ y $p_i = 0$ para $i > k$. Por tanto,

$$\sum_{\ell=1}^k \|A^* x_\ell\|^2 \leq \sum_{i=1}^k \sigma_i^2.$$

Paso 4. Retomando la cota del Paso 2,

$$\|A - B\|_{\text{Fro}}^2 \geq \|A\|_{\text{Fro}}^2 - \sum_{\ell=1}^k \|A^* x_\ell\|^2 \geq \|A\|_{\text{Fro}}^2 - \sum_{i=1}^k \sigma_i^2 = \sum_{i=k+1}^{\text{rang } A} \sigma_i^2,$$

lo que, junto con el Paso 1, concluye la demostración. ■

1.2. *Clustering* espectral en grafos

El objetivo del *clustering* espectral es particionar un conjunto de datos en grupos de manera que los elementos de un mismo grupo estén “más conectados” entre sí que con elementos de otros grupos. Para formalizar esto, representamos los datos como un grafo ponderado.

1.2.1. Grafos ponderados y definiciones básicas

Definición 1.2.1 (Grafo ponderado no dirigido). Un grafo ponderado no dirigido es una tupla $G = (V, W)$ donde:

- $V = \{v_1, \dots, v_m\}$ es el conjunto de vértices.
- $W \in \mathbb{R}^{m \times m}$ es la matriz de pesos, con $w_{ij} = w_{ji} \geq 0$.

Ejemplo 1.2.2. Sea (X, d) un espacio métrico y sea $\{x_i\}_{i=1}^m \subset X$ un conjunto de datos. Dado $\varepsilon > 0$, podemos construir un grafo ponderado donde $V = \{1, \dots, m\}$ y

$$w_{ij} = \begin{cases} e^{-d(x_i, x_j)^2} & \text{si } d(x_i, x_j) \leq \varepsilon, \\ 0 & \text{en otro caso.} \end{cases}$$

Este grafo captura las relaciones de vecindad entre los datos: cuanto más cercanos estén x_i y x_j , mayor será el peso w_{ij} .

Definición 1.2.3 (Grado, volumen y conexión). Sea $G = (V, W)$ un grafo ponderado.

- El **grado** del vértice i es $d_i = \sum_{j=1}^m w_{ij}$. Denotamos por $D = \text{diag}(d_1, \dots, d_m)$ la matriz diagonal de grados.
- El **volumen** de un subconjunto $S \subset V$ es $\text{vol}(S) = \sum_{i \in S} d_i$.
- La **conexión** entre $S, T \subset V$ es $W(S, T) = \sum_{i \in S} \sum_{j \in T} w_{ij}$.

Definición 1.2.4 (Laplaciano de un grafo). Sea $G = (V, W)$ un grafo ponderado. El **laplaciano** de G es la matriz $L = D - W$.

Observación 1.2.5 (Analogía con el laplaciano continuo). El nombre “laplaciano” proviene de la siguiente analogía. Sea $f: V \rightarrow \mathbb{R}$ una función sobre los vértices (escribimos $f_i = f(v_i)$). Entonces,

$$\langle f, Lf \rangle = \sum_{i=1}^m d_i f_i^2 - \sum_{i,j=1}^m w_{ij} f_i f_j = \frac{1}{2} \sum_{i,j=1}^m w_{ij} (f_i - f_j)^2.$$

Esta expresión mide la “variación” de f sobre el grafo, análogamente a cómo para $f \in \mathcal{C}^2(\mathbb{R}^d)$ con $f, |\nabla f|, \Delta f \in L^2(\mathbb{R}^d)$, se tiene $\langle f, -\Delta f \rangle_{L^2} = \|\nabla f\|_{L^2}^2$.

1.2.2. El problema de corte normalizado (NCut)

Definición 1.2.6 (Corte y corte normalizado). Sea $G = (V, W)$ un grafo ponderado y sea $\{A_j\}_{j=1}^k$ una partición de V (es decir, $V = \bigsqcup_{j=1}^k A_j$).

- El **corte** de la partición es

$$\text{cut}(\{A_j\}_{j=1}^k) = \sum_{j=1}^k W(A_j, A_j^c),$$

que mide el “costo” de separar el grafo en los subgrupos $A_1, \dots, A_k$.

- El **corte normalizado** (NCut) es

$$\text{Ncut}(\{A_j\}_{j=1}^k) = \sum_{j=1}^k \frac{W(A_j, A_j^c)}{\text{vol}(A_j)},$$

que penaliza además los grupos con volumen pequeño.

Observación 1.2.7. Para $k = 2$ (partición en dos grupos A y $B = A^c$), el corte normalizado se puede escribir como

$$\text{Ncut}(A, B) = W(A, B) \left(\frac{1}{\text{vol}(A)} + \frac{1}{\text{vol}(B)} \right).$$

Esta expresión es el producto de dos términos: la **separación** $W(A, B)$ (queremos que sea pequeña, es decir, A y B poco conectados) y el **balance** $\frac{1}{\text{vol}(A)} + \frac{1}{\text{vol}(B)}$ (que es mínimo cuando $\text{vol}(A) = \text{vol}(B)$). Por tanto, minimizar NCut favorece particiones con grupos bien separados y de tamaño equilibrado.

El **problema NCut** consiste en encontrar la partición que minimiza el corte normalizado:

$$\{A_j^*\}_{j=1}^k = \arg \min_{\{A_j\}_{j=1}^k \text{ partición}} \text{Ncut}(\{A_j\}_{j=1}^k).$$

1.2.3. Formulación variacional para $k = 2$

El siguiente lema relaciona el corte normalizado con una forma cuadrática.

Lema 1.2.8. Sea $V = A \cup B$ una partición y definamos $f^{(A,B)}: V \rightarrow \mathbb{R}$ por

$$f_i^{(A,B)} = \begin{cases} \sqrt{\frac{\text{vol}(B)}{\text{vol}(A)}} & \text{si } i \in A, \\ -\sqrt{\frac{\text{vol}(A)}{\text{vol}(B)}} & \text{si } i \in B. \end{cases}$$

Entonces,

$$\text{Ncut}(A, B) = \frac{1}{2 \text{vol}(V)} \sum_{i,j=1}^m w_{ij} (f_i^{(A,B)} - f_j^{(A,B)})^2.$$

Demostración: Observamos que $(f_i - f_j)^2 = 0$ si i, j están en el mismo grupo. Si $i \in A$ y $j \in B$ (o viceversa), entonces

$$(f_i - f_j)^2 = \left(\sqrt{\frac{\text{vol}(B)}{\text{vol}(A)}} + \sqrt{\frac{\text{vol}(A)}{\text{vol}(B)}} \right)^2 = \frac{\text{vol}(B)}{\text{vol}(A)} + \frac{\text{vol}(A)}{\text{vol}(B)} + 2.$$

Simplificando esta expresión y usando que $W(A, B) = W(B, A)$, se obtiene

$$\sum_{i,j=1}^m w_{ij}(f_i - f_j)^2 = 2W(A, B) \left(\frac{\text{vol}(B)}{\text{vol}(A)} + \frac{\text{vol}(A)}{\text{vol}(B)} + 2 \right) \cdot \frac{\text{vol}(A) \text{vol}(B)}{(\text{vol}(A) + \text{vol}(B))^2} \cdot \text{vol}(V),$$

que tras simplificar da $2 \text{vol}(V) \text{Ncut}(A, B)$. ■

Teorema 1.2.9. *El problema Ncut con $k = 2$ es equivalente al problema de optimización*

$$\arg \min \left\{ \frac{\langle f, Lf \rangle}{\langle f, Df \rangle} : \sum_{i=1}^m f_i d_i = 0, f_i \in \left\{ \pm \sqrt{\frac{\text{vol}(B)}{\text{vol}(A)}} \right\} \right\}.$$

Demostración: La demostración se divide en tres pasos:

Paso 1. Por la observación sobre el laplaciano, para cualquier $f \in \mathbb{R}^m$,

$$\langle f, Lf \rangle = \frac{1}{2} \sum_{i,j=1}^m w_{ij}(f_i - f_j)^2.$$

Paso 2. Sea $f: V \rightarrow \{p^2, -q^2\}$ y definamos $A = \{i : f_i = p^2\}$, $B = \{i : f_i = -q^2\}$. La restricción $\sum_{i=1}^m d_i f_i = 0$ implica

$$p^2 \text{vol}(A) = q^2 \text{vol}(B) \implies \frac{p^2}{q^2} = \frac{\text{vol}(B)}{\text{vol}(A)}.$$

De aquí se deduce que $f = pq f^{(A,B)}$ para cierto escalar pq .

Paso 3. Con f como en el paso anterior,

$$\langle f, Df \rangle = \sum_{i=1}^m d_i f_i^2 = p^4 \text{vol}(A) + q^4 \text{vol}(B) = p^2 q^2 \text{vol}(V).$$

Por tanto, usando el Lema 1.2.8,

$$\frac{\langle f, Lf \rangle}{\langle f, Df \rangle} = \frac{\langle f^{(A,B)}, Lf^{(A,B)} \rangle}{\langle f^{(A,B)}, Df^{(A,B)} \rangle} = \text{Ncut}(A, B).$$
■

Observación 1.2.10 (Complejidad computacional). El problema de optimización del Teorema 1.2.9 es **NP-completo**. Esto significa que, salvo que $P = NP$, no existe algoritmo que lo resuelva en tiempo polinomial.

1.2.4. Relajación espectral del problema NCut

Para obtener un algoritmo eficiente, relajamos el problema eliminando la restricción de que f tome valores discretos.

Observación 1.2.11 (Cambio de variable y cociente de Rayleigh). Sea $g = D^{1/2}f$ y definamos $M = D^{-1/2}LD^{-1/2}$ (el **laplaciano normalizado**). Entonces,

$$\frac{\langle f, Lf \rangle}{\langle f, Df \rangle} = \frac{\langle g, Mg \rangle}{\|g\|^2},$$

que es el **cociente de Rayleigh** de la matriz M . Además, M es simétrica y semidefinida positiva, con

$$\langle g, Mg \rangle = \frac{1}{2} \sum_{i,j=1}^m w_{ij} \left(\frac{g_i}{\sqrt{d_i}} - \frac{g_j}{\sqrt{d_j}} \right)^2 \geq 0.$$

La restricción $\sum_{i=1}^m d_i f_i = 0$ se traduce en $g \perp D^{1/2}\mathbf{1}$, donde $\mathbf{1}$ es el vector de unos.

El problema relajado consiste en minimizar el cociente de Rayleigh sobre todos los vectores $g \perp D^{1/2}\mathbf{1}$:

$$\min_{g \perp D^{1/2}\mathbf{1}} \frac{\langle g, Mg \rangle}{\|g\|^2}.$$

Por el teorema del cociente de Rayleigh (ver Apéndice), el mínimo se alcanza en el autovector de M correspondiente al segundo menor autovalor (el menor autovalor es 0 con autovector $D^{1/2}\mathbf{1}$).

Algoritmo de *Spectral Clustering* para $k = 2$:

1. Calcular el autovector g_2 de $M = D^{-1/2}LD^{-1/2}$ correspondiente al menor autovalor no nulo.
2. Definir la partición: $A = \{i \in V : g_2(i) > 0\}$ y $B = A^c$.

1.2.5. Interpretación probabilística: caminos aleatorios

La matriz $P = D^{-1}W$ es una **matriz de transición de Markov**:

$$p_{ij} = \frac{w_{ij}}{d_i} = \frac{w_{ij}}{\sum_{k=1}^m w_{ik}}, \quad \text{con } \sum_{j=1}^m p_{ij} = 1.$$

Es decir, $p_{ij} = \mathbb{P}(i \rightarrow j)$ es la probabilidad de transitar del vértice i al vértice j en un paso del camino aleatorio sobre el grafo. La distribución estacionaria es $\pi_i = \frac{d_i}{\text{vol}(V)}$.

Proposición 1.2.12. Sea $\{X_t\}_{t \geq 0}$ el camino aleatorio sobre G con $X_0 \sim \pi$. Entonces,

$$\mathbb{P}(X_t \in A \mid X_{t-1} \in B) + \mathbb{P}(X_t \in B \mid X_{t-1} \in A) = \text{Ncut}(A, B).$$

Demostración: Calculamos directamente:

$$\mathbb{P}(X_0 \in A, X_1 \in B) = \sum_{i \in A} \sum_{j \in B} \pi_i p_{ij} = \frac{1}{\text{vol}(V)} \sum_{i \in A} \sum_{j \in B} w_{ij} = \frac{W(A, B)}{\text{vol}(V)}.$$

Como $\mathbb{P}(X_0 \in A) = \frac{\text{vol}(A)}{\text{vol}(V)}$, se tiene

$$\mathbb{P}(X_1 \in B \mid X_0 \in A) = \frac{W(A, B)}{\text{vol}(A)}.$$

El mismo argumento da $\mathbb{P}(X_1 \in A \mid X_0 \in B) = \frac{W(B, A)}{\text{vol}(B)}$, y sumando obtenemos $\text{Ncut}(A, B)$. ■

Esta proposición nos da una interpretación intuitiva: **minimizar NCut equivale a minimizar la probabilidad de que un camino aleatorio “salte” entre grupos.**

1.2.6. *Spectral Clustering* para $k > 2$

Lema 1.2.13. Sea $G = (V, W)$ un grafo con K componentes conexas $V = \bigsqcup_{\ell=1}^K A_\ell$ (es decir, $w_{ij} = 0$ si $i \in A_\ell, j \in A_{\ell'}$ con $\ell \neq \ell'$). Entonces,

$$\ker L = \text{span}\{\chi_{A_1}, \dots, \chi_{A_K}\},$$

donde χ_{A_ℓ} es la función indicadora de A_ℓ .

Demostración: Para $K = 1$ (grafo conexo), $\langle f, Lf \rangle = \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2 = 0$ implica $f_i = f_j$ para todos los pares con $w_{ij} > 0$, es decir, $f = \alpha \mathbf{1}$.

Para $K > 1$, el laplaciano tiene estructura de bloques diagonal (tras reordenar los vértices), y el resultado se aplica a cada bloque. ■

Observación 1.2.14 (Heurística para grafos “casi” desconectados). Si el grafo es conexo pero tiene K grupos “naturales” (muy conectados internamente, poco conectados entre sí), entonces:

- El autovector de M con autovalor 0 es $D^{1/2} \mathbf{1}$.
- Los siguientes $K - 1$ autovectores son aproximadamente $D^{1/2} \chi_{A_\ell}$, correspondientes a

autovalores pequeños.

Algoritmo de Shi-Malik:

1. Calcular los $k + 1$ autovectores de M con menores autovalores: $\{(\lambda_\ell, f_\ell)\}_{\ell=1}^{k+1}$ con $\lambda_1 = 0 < \lambda_2 \leq \dots \leq \lambda_{k+1}$.
2. Representar cada vértice v_i mediante el *embedding*

$$\varphi(v_i) = (f_2(v_i), \dots, f_{k+1}(v_i)) \in \mathbb{R}^k.$$

Esta técnica se conoce como *Laplacian Eigenmaps*.

3. Aplicar un algoritmo de agrupamiento clásico (como k -means) sobre los puntos $\{\varphi(v_i)\}_{i=1}^m \subset \mathbb{R}^k$.

Observación 1.2.15 (Elección de k). El número de grupos k se puede estimar buscando un “codo” en el espectro de M : un salto significativo entre λ_k y λ_{k+1} sugiere que hay k grupos bien definidos.

1.2.7. Otros algoritmos de agrupamiento

Definición 1.2.16 (K -means). Sean $\mathcal{D} = \{x_i\}_{i=1}^m \subset \mathbb{R}^N$ y $K \in \mathbb{N}$. El problema de K -means consiste en encontrar una partición $\mathcal{D} = \bigsqcup_{\ell=1}^K S_\ell$ que minimice

$$\sum_{\ell=1}^K \sum_{x \in S_\ell} \|x - \mu_\ell\|^2, \quad \text{donde } \mu_\ell = \frac{1}{|S_\ell|} \sum_{x \in S_\ell} x$$

es el centroide del grupo S_ℓ .

Observación 1.2.17. El problema de K -means es NP-completo. Los algoritmos prácticos (como el algoritmo de Lloyd) son heurísticas que encuentran mínimos locales.

Definición 1.2.18 (Agrupamiento jerárquico aglomerativo). Sea $\mathcal{D} = \{x_i\}_{i=1}^m \subset (X, d)$ un espacio métrico y sea $R: \mathcal{P}(X) \times \mathcal{P}(X) \rightarrow \mathbb{R}$ una distancia entre subconjuntos (por ejemplo, *single linkage*, *complete linkage* o *average linkage*).

- (I) Inicialmente, cada punto forma su propio grupo.
- (II) Iterativamente, se fusionan los dos grupos más cercanos según R .
- (III) Se construye un **dendrograma** que representa la jerarquía de fusiones.
- (IV) Se corta el dendrograma a un nivel t para obtener la partición final.

Observación 1.2.19. La elección del nivel de corte t es análoga a la búsqueda de un “codo” en el espectro del laplaciano.

Apéndice de Álgebra Lineal

Este apéndice recoge resultados de álgebra lineal utilizados en el capítulo, particularmente en la sección de clustering espectral.

Matrices autoadjuntas

Lema 1.2.20 (Caracterización de matrices autoadjuntas). *Sea $A \in \mathbb{C}^{m \times m}$ una matriz. Si $\langle Av, v \rangle_{\mathbb{C}^m} \in \mathbb{R}$ para todo $v \in \mathbb{C}^m$, entonces A es autoadjunta, es decir, $A = A^*$.*

Demostración: Definimos $M = A - A^*$ y mostramos que $M = 0$.

Paso 1. Como $\langle Av, v \rangle \in \mathbb{R}$ para todo v , tenemos que $\langle Av, v \rangle = \overline{\langle Av, v \rangle} = \langle v, Av \rangle$. Por tanto,

$$\langle Mv, v \rangle = \langle Av, v \rangle - \langle A^*v, v \rangle = \langle Av, v \rangle - \langle v, Av \rangle = 0.$$

Paso 2. Usando la identidad de polarización, para cualesquiera $v, w \in \mathbb{C}^m$:

$$\langle M(v + w), v + w \rangle - \langle M(v - w), v - w \rangle = 2 \langle Mv, w \rangle + 2 \langle Mw, v \rangle.$$

Por el Paso 1, el lado izquierdo es cero, luego $\langle Mv, w \rangle = -\langle Mw, v \rangle$.

Como $\langle Mw, v \rangle = \overline{\langle v, Mw \rangle}$ y $\langle v, Mw \rangle = \overline{\langle Mw, v \rangle}$, se tiene $\langle Mv, w \rangle = -\langle Mw, v \rangle = -\overline{\langle v, Mw \rangle}$. Sustituyendo $\langle Mw, v \rangle = -\langle Mv, w \rangle$:

$$\langle Mv, w \rangle = -\overline{\langle Mv, w \rangle} \implies \langle Mv, w \rangle \in i\mathbb{R}.$$

Paso 3. Análogamente, considerando $v + iw$ y $v - iw$:

$$\langle M(v + iw), v + iw \rangle - \langle M(v - iw), v - iw \rangle = 2i \langle Mv, w \rangle - 2i \langle Mw, v \rangle.$$

Por el Paso 1, esto es cero, luego $\langle Mv, w \rangle = \langle Mw, v \rangle$.

Paso 4. Combinando los Pasos 2 y 3: del Paso 2 tenemos $\langle Mv, w \rangle = -\langle Mw, v \rangle$, y del Paso 3 tenemos $\langle Mv, w \rangle = \langle Mw, v \rangle$. Por tanto, $\langle Mv, w \rangle = -\langle Mw, v \rangle$, lo que implica $\langle Mv, w \rangle = 0$ para todos $v, w \in \mathbb{C}^m$. Luego $M = 0$.

■

Observación 1.2.21 (Aplicación al laplaciano normalizado). En el contexto del clustering espectral, la matriz $M = D^{-1/2}LD^{-1/2}$ satisface

$$\langle Mg, g \rangle = \frac{1}{2} \sum_{i,j=1}^m w_{ij} \left| \frac{g_i}{\sqrt{d_i}} - \frac{g_j}{\sqrt{d_j}} \right|^2 \in \mathbb{R}_{\geq 0}$$

para todo $g \in \mathbb{C}^m$. Por el lema anterior, M es autoadjunta (y además semidefinida positiva).

El cociente de Rayleigh

Definición 1.2.22 (Cociente de Rayleigh). Sea $M \in \mathbb{R}^{m \times m}$ una matriz simétrica. El **cociente de Rayleigh** de M es la función $R_M: \mathbb{R}^m \setminus \{0\} \rightarrow \mathbb{R}$ definida por

$$R_M(x) = \frac{\langle Mx, x \rangle}{\|x\|^2}.$$

Lema 1.2.23 (Teorema min-max de Rayleigh). Sea $M \in \mathbb{R}^{m \times m}$ simétrica y semidefinida positiva. Sean $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_m$ sus autovalores (contados con multiplicidad) y $\{v_1, \dots, v_m\}$ una base ortonormal de autovectores correspondientes. Entonces:

$$\min_{x \in \mathbb{R}^m \setminus \{0\}} R_M(x) = \lambda_1, \quad \text{con} \quad \arg \min_{x \neq 0} R_M(x) = \ker(M - \lambda_1 I).$$

Demostración: Como $\{v_1, \dots, v_m\}$ es una base ortonormal, cualquier $x \in \mathbb{R}^m$ se escribe como $x = \sum_{i=1}^m c_i v_i$ con $c_i = \langle x, v_i \rangle$. Entonces:

$$Mx = \sum_{i=1}^m \lambda_i c_i v_i, \quad \|x\|^2 = \sum_{i=1}^m c_i^2, \quad \langle Mx, x \rangle = \sum_{i=1}^m \lambda_i c_i^2.$$

Definiendo $p_i = \frac{c_i^2}{\sum_{j=1}^m c_j^2}$, tenemos que $p_i \geq 0$ y $\sum_{i=1}^m p_i = 1$. Por tanto,

$$R_M(x) = \sum_{i=1}^m \lambda_i p_i$$

es una combinación convexa de los autovalores. El mínimo de una combinación convexa se alcanza en el menor de los valores, es decir, $R_M(x) \geq \lambda_1$, con igualdad si y solo si $p_1 = 1$ (y $p_i = 0$ para $i > 1$), lo que ocurre cuando $x \in \ker(M - \lambda_1 I)$. ■

Corolario 1.2.24 (Segundo autovalor). Con la notación del lema anterior, si $V_1 = \ker(M - \lambda_1 I)$ es el autoespacio correspondiente a λ_1 , entonces

$$\min_{x \perp V_1, x \neq 0} R_M(x) = \lambda_2.$$

Más generalmente, para $k \geq 1$:

$$\lambda_k = \min_{\substack{x \perp v_1, \dots, v_{k-1} \\ x \neq 0}} R_M(x).$$

Demostración: Si $x \perp V_1$, entonces $c_i = 0$ para todo i tal que $\lambda_i = \lambda_1$. Por tanto, $R_M(x) = \sum_{\lambda_i > \lambda_1} \lambda_i p_i \geq \lambda_2$, con igualdad cuando x es autovector de λ_2 . ■

Observación 1.2.25 (Aplicación al clustering espectral). En el problema NCut relajado, buscamos minimizar $R_M(g) = \frac{\langle Mg, g \rangle}{\|g\|^2}$ sujeto a $g \perp D^{1/2}\mathbf{1}$. Como $D^{1/2}\mathbf{1}$ es el autovector de M con autovalor $\lambda_1 = 0$, el Corolario 1.2.24 nos dice que el mínimo se alcanza en el autovector correspondiente al segundo menor autovalor λ_2 .

2. Fundamentos del aprendizaje supervisado

2.1. Learning Theory

La teoría del aprendizaje (*learning theory*) es el marco matemático que formaliza el problema central del aprendizaje automático: a partir de un conjunto finito de observaciones (datos), inferir una relación funcional que permita hacer predicciones sobre datos no observados. El enfoque es inherentemente **estadístico**: se modela la generación de datos como un proceso aleatorio gobernado por una distribución de probabilidad desconocida y el objetivo es aproximar la dependencia subyacente entre las variables de entrada y de salida.

2.1.1. Formulación del problema

Sean X e Y espacios topológicos de Hausdorff:

- X es el **espacio de entrada** (o *espacio de características*): representa el dominio de las variables observables a partir de las cuales queremos hacer predicciones. Por ejemplo, $X = \mathbb{R}^d$ cuando cada observación se describe mediante d atributos numéricos.
- Y es el **espacio de salida** (o *espacio de respuestas*): representa el dominio de los valores que queremos predecir. En problemas de regresión, típicamente $Y = \mathbb{R}$ o $Y = \mathbb{R}^k$; en clasificación binaria, $Y = \{-1, +1\}$.

Sea $Z = X \times Y$ el espacio producto, dotado de la topología producto (que es de Hausdorff por serlo X e Y). Sea $\mathcal{B}$ la σ -álgebra de Borel de Z y $(Z, \mathcal{B}, \rho)$ un espacio de probabilidad:

- ρ es una medida de probabilidad **desconocida** que modela el mecanismo de generación de datos: cada par (x, y) observado se entiende como una realización de una variable aleatoria cuya medida de probabilidad inducida es ρ .
- La estructura de producto $Z = X \times Y$ refleja la distinción entre lo que observamos (x) y lo que queremos predecir (y).
- Nos interesa el fenómeno de generación de datos en Z descrito por ρ desde el punto de vista de la **dependencia de Y respecto de X** : queremos entender cómo la variable de salida y depende de la entrada x .

Por tanto, el objetivo es aproximar la **función de regresión**, es decir, la función $f_\rho: X \rightarrow Y$ que asigna a cada $x \in X$ el valor esperado de y condicionado a x :

$$f_\rho(x) := \int_Y y \, d\rho(y \mid x),$$

donde $\rho(y \mid x)$ es la medida de probabilidad condicional de y dado x . La función f_ρ es, en cierto sentido, la *mejor predicción posible* de y dado x , ya que minimiza el error cuadrático medio (como se demostrará más adelante).

Sea $\pi: Z \rightarrow X$ la proyección $\pi(x, y) = x$. Sea ρ_X la medida de probabilidad marginal en X definida en $E \subset X$ abierto por $\rho_X(E) = \rho(\pi^{-1}(E))$.

Por el teorema de desintegración de medidas (que se aplica porque Z es un espacio de Hausdorff con medida de probabilidad de Radon), existe la medida de probabilidad condicional que satisface, $\forall \varphi \in L^1(Z, \rho)$:

$$\begin{aligned} \int_Z \varphi(z) \, d\rho(z) &= \int_X \left(\int_Y \varphi(x, y) \, d\rho(y \mid x) \right) d\rho_X(x), \\ \int_Y d\rho(y \mid x) &= 1 \quad \rho_X\text{-casi todo } x \in X. \end{aligned}$$

Intuitivamente, $\rho(y \mid x)$ es la distribución de y una vez fijado x : integrar primero respecto de $\rho(y \mid x)$ y luego respecto de ρ_X es lo mismo que integrar directamente respecto de ρ .

2.1.2. Sobre el objetivo y el aprendizaje estadístico

Como no se dispone de ρ , hay que trabajar con **muestras**: $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset Z$.

- Aprendizaje *supervisado*: para todo $x_i \in X$ hay un $y_i \in Y$ que proporciona un objetivo.
- El resultado de todo aprendizaje es epistemológicamente una aproximación, porque la búsqueda de una función de regresión se tiene que hacer dentro de un **espacio de las hipótesis** definido *a priori* antes de conocer ρ .

Ejemplo 2.1.1 (Aproximación polinomial de datos físicos). Supongamos que una ley física $F: \mathbb{R} \rightarrow \mathbb{R}$ y fenómenos aleatorios generan los datos:

$$y_i = F(x_i) + \varepsilon_i, \quad \text{donde } \{\varepsilon_i\}_{i=1}^m \text{ son v.a.i.d.}$$

Si queremos aproximar F con un polinomio de grado $\leq n$, podemos intentar minimizar

$$\sum_{i=1}^m |y_i - f_w(x_i)|^2, \quad \text{para } f_w(x) = \sum_{i=0}^n w_i x^i.$$

Veamos cómo encaja este modelo en el marco general. Supongamos $\varepsilon \sim \mathcal{N}(0, 1)$, $X = [0, 1]$

con ρ_X la medida de Lebesgue (distribución uniforme) en X .

- La medida marginal ρ_X induce, a través de F , una distribución sobre $F(X)$: la medida pushforward $F_*\rho_X$, definida por

$$(F_*\rho_X)((-\infty, t)) = \rho_X(\{x \in X : F(x) < t\}) = \rho_X(F^{-1}((-\infty, t))).$$

Esto describe la distribución de la variable de salida cuando no hay ruido.

- Si no hubiera ruido, es decir, $y = F(x)$ determinísticamente, la medida de probabilidad condicional $\rho(y \mid x)$ sería la delta de Dirac concentrada en $F(x)$, caracterizada por

$$\forall \varphi \in C_c(\mathbb{R}) : \int_{\mathbb{R}} \varphi(y) d\rho(y \mid x) = \varphi(F(x)).$$

- Con ruido gaussiano $\varepsilon \sim \mathcal{N}(0, 1)$, la probabilidad condicional pasa a ser $\rho(y \mid x) = \mathcal{N}(F(x), 1)$. La medida conjunta ρ sobre $Z = X \times \mathbb{R}$ es entonces absolutamente continua respecto de la medida producto $\rho_X \otimes m$, con densidad

$$d\rho(x, y) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(y-F(x))^2}{2}} d\rho_X(x) dy.$$

- La función de regresión asociada a esta ρ coincide con la ley física F , como se comprueba directamente:

$$f_\rho(x) = \int_{\mathbb{R}} y d\rho(y \mid x) = \mathbb{E}[\mathcal{N}(F(x), 1)] = F(x).$$

Por tanto, minimizar el error empírico

$$\mathcal{E}_{\mathcal{D}}[f_w] = \frac{1}{m} \sum_{i=1}^m |y_i - f_w(x_i)|^2$$

es equivalente a buscar una aproximación polinomial de $f_\rho = F$ a partir de los datos, lo que justifica el planteamiento del ejemplo dentro del marco general.

Para medir cuán buena es una hipótesis f , necesitamos una función de coste que compare $f(x)$ con el valor real y . La elección estándar en regresión es el error cuadrático, que penaliza las desviaciones de forma proporcional a su magnitud.

Definición 2.1.2 (Error cuadrático). Sea $Y = \mathbb{R}^k$, ρ una medida de probabilidad en $Z = X \times Y$, $f: X \rightarrow Y$ ρ -medible, y $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset Z$. Definimos:

- El **error de generalización** de f respecto de ρ como $\mathcal{E}[f] := \int_Z |f(x) - y|^2 d\rho(x, y)$,

- El **error empírico** de f respecto de $\mathcal{D}$ como $\mathcal{E}_{\mathcal{D}}[f] := \frac{1}{m} \sum_{i=1}^m |f(x_i) - y_i|^2$.

La siguiente proposición justifica que f_{ρ} es la mejor hipótesis posible y hace explícita la estructura del error de generalización.

Proposición 2.1.3. *Para toda función $f: X \rightarrow Y$ ρ -medible se cumple que*

$$\mathcal{E}[f] = \int_X |f(x) - f_{\rho}(x)|^2 d\rho_X(x) + \mathcal{E}[f_{\rho}].$$

En particular, f_{ρ} minimiza $\mathcal{E}$ entre todas las funciones ρ -medibles. La primera integral mide el error de aproximación de f_{ρ} por f , mientras que

$$\mathcal{E}[f_{\rho}] = \int_X \left(\int_Y |f_{\rho}(x) - y|^2 d\rho(y | x) \right) d\rho_X(x)$$

es el error intrínseco, que recoge la varianza de la distribución condicional $\rho(y | x)$ en torno a su media $f_{\rho}(x)$ y no puede reducirse con ninguna elección de f .

Demostración: Sumamos y restamos $f_{\rho}(x)$ dentro del cuadrado y expandimos:

$$\begin{aligned} \mathcal{E}[f] &= \int_Z |(f(x) - f_{\rho}(x)) + (f_{\rho}(x) - y)|^2 d\rho(x, y) \\ &= \int_Z |f(x) - f_{\rho}(x)|^2 d\rho(x, y) + \int_Z |f_{\rho}(x) - y|^2 d\rho(x, y) + 2\mathcal{I}[f, f_{\rho}], \end{aligned}$$

donde el término cruzado es

$$\mathcal{I}[f, f_{\rho}] = \int_X (f(x) - f_{\rho}(x)) \underbrace{\left(\int_Y (f_{\rho}(x) - y) d\rho(y | x) \right)}_{= f_{\rho}(x) - f_{\rho}(x) = 0} d\rho_X(x) = 0.$$

Integrando la primera integral respecto de ρ_X e identificando la segunda con $\mathcal{E}[f_{\rho}]$ se obtiene el resultado. ■

Como f_{ρ} depende de ρ , que es desconocida, no podemos calcularla directamente. El enfoque práctico es restringir la búsqueda a un subconjunto $\mathcal{H} \subset Y^X$ manejable, elegido de antemano con conocimiento del problema, y minimizar el error dentro de él.

Definición 2.1.4 (Hipótesis y función objetivo). Sea $\mathcal{H} \subset Y^X = \{f: X \rightarrow Y\}$ un **espacio de hipótesis** y $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset X \times Y$ un conjunto de datos. Definimos:

- La **función objetivo** $f_{\mathcal{H}} \in \mathcal{H}$ como el minimizador del error de generalización en $\mathcal{H}$:

$$\forall f \in \mathcal{H} : \mathcal{E}[f_{\mathcal{H}}] \leq \mathcal{E}[f].$$

- La **función empírica** $f_{\mathcal{H},\mathcal{D}} \in \mathcal{H}$ como el minimizador del error empírico en $\mathcal{H}$:

$$\forall f \in \mathcal{H} : \mathcal{E}_{\mathcal{D}}[f_{\mathcal{H},\mathcal{D}}] \leq \mathcal{E}_{\mathcal{D}}[f].$$

En la práctica, ρ es desconocida, por lo que $f_{\mathcal{H}}$ no es accesible directamente; el aprendizaje consiste en obtener $f_{\mathcal{H},\mathcal{D}}$ a partir de los datos y esperar que aproxime bien a $f_{\mathcal{H}}$.

Observación 2.1.5. Por la proposición 2.1.3, minimizar $\mathcal{E}$ en $\mathcal{H}$ equivale a minimizar la distancia a f_{ρ} en $L^2(\rho_X)$. Es decir, $f_{\mathcal{H}} \in \mathcal{H}$ es función objetivo si y solo si

$$\forall f \in \mathcal{H} : \|f_{\mathcal{H}} - f_{\rho}\|_{L^2(\rho_X)} \leq \|f - f_{\rho}\|_{L^2(\rho_X)}.$$

Es decir, $f_{\mathcal{H}}$ es la *proyección* de f_{ρ} sobre $\mathcal{H}$ en el sentido de la norma $L^2(\rho_X)$.

Definición 2.1.6. $\mathcal{C}_b(X) = \mathcal{C}(X) \cap \mathcal{L}^{\infty}(X)$ es el espacio de funciones continuas y acotadas.

Una pregunta natural es: ¿cuándo existen $f_{\mathcal{H}}$ y $f_{\mathcal{H},\mathcal{D}}$? La respuesta requiere imponer condiciones sobre $\mathcal{H}$: si $\mathcal{H}$ es un subconjunto compacto de $\mathcal{C}_b(X)$ (en la topología de la convergencia uniforme) y las hipótesis están uniformemente acotadas junto con los datos, entonces ambos minimizadores existen, como muestra el siguiente teorema.

Teorema 2.1.7. Sea X un espacio métrico, $M > 0$ y $\mathcal{H}_M \subset \mathcal{C}_b(X)$ compacto en $(\mathcal{C}(X), \|\cdot\|_{\infty})$ tal que $|f(x) - y| \leq M$ ρ -c.s. para todo $f \in \mathcal{H}_M$. Entonces existen la función objetivo y la función empírica: para todo $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset X \times Y$,

$$\exists f_{\mathcal{H}_M} \in \mathcal{H}_M \wedge \exists f_{\mathcal{H}_M, \mathcal{D}} \in \mathcal{H}_M.$$

Demostración: Basta probar que $\mathcal{E}$ y $\mathcal{E}_{\mathcal{D}}$ son continuas en $(\mathcal{H}_M, \|\cdot\|_{\infty})$; la existencia de mínimos se sigue entonces del teorema de Weierstrass, ya que $\mathcal{H}_M$ es compacto.

Sean $f_1, f_2 \in \mathcal{H}_M$. Factorizando la diferencia de cuadrados,

$$\begin{aligned} |\mathcal{E}[f_1] - \mathcal{E}[f_2]| &= \left| \int_Z (|f_1(x) - y|^2 - |f_2(x) - y|^2) d\rho(x, y) \right| \\ &= \left| \int_Z (f_1(x) + f_2(x) - 2y)(f_1(x) - f_2(x)) d\rho(x, y) \right| \\ &\leq \|f_1 - f_2\|_{\infty} \int_Z (|f_1(x) - y| + |f_2(x) - y|) d\rho(x, y) \\ &\leq 2M \|f_1 - f_2\|_{\infty}. \end{aligned}$$

Por tanto $\mathcal{E}$ es Lipschitz, y en particular continua. El mismo argumento, reemplazando la integral por la suma finita, da continuidad de $\mathcal{E}_{\mathcal{D}}$. ■

2.1.3. The Bias-Variance Tradeoff

El objetivo del aprendizaje es elegir un espacio de hipótesis $\mathcal{H}$ y una muestra $\mathcal{D}$ tales que $f_{\mathcal{H},\mathcal{D}}$ tenga un error de generalización pequeño. Para cuantificar cuán lejos está $f_{\mathcal{H},\mathcal{D}}$ de f_ρ , descomponemos el exceso de error usando la proposición 2.1.3:

$$\mathcal{E}[f_{\mathcal{H},\mathcal{D}}] - \mathcal{E}[f_\rho] = \underbrace{(\mathcal{E}[f_{\mathcal{H},\mathcal{D}}] - \mathcal{E}[f_{\mathcal{H}}])}_{\text{varianza } V(\mathcal{H},\mathcal{D},\rho) \geq 0} + \underbrace{(\mathcal{E}[f_{\mathcal{H}}] - \mathcal{E}[f_\rho])}_{\text{sesgo}^2 = \|f_{\mathcal{H}} - f_\rho\|_{L^2(\rho_X)}^2 \geq 0}.$$

Los dos sumandos capturan fuentes de error de naturaleza opuesta:

- El **sesgo** (*bias*) mide cuán bien puede $\mathcal{H}$ aproximar f_ρ : es intrínseco a la clase $\mathcal{H}$ e independiente de $\mathcal{D}$. Si $\mathcal{H}$ es rico, el sesgo es pequeño; si $\mathcal{H}$ es demasiado rígido, el sesgo es grande sin importar cuántos datos se tengan.
- La **varianza** mide cuánto se aleja el minimizador empírico $f_{\mathcal{H},\mathcal{D}}$ del minimizador teórico $f_{\mathcal{H}}$ debido a la aleatoriedad de la muestra. Si $\mathcal{H}$ es fijo y se aumenta el tamaño m de $\mathcal{D}$, entonces $V \rightarrow 0$ (*bajo hipótesis oportunas*).

Esto revela la tensión fundamental del aprendizaje: ampliar $\mathcal{H}$ reduce el sesgo porque $f_{\mathcal{H}}$ se acerca más a f_ρ , pero aumenta la varianza porque hay más libertad para sobreajustar los datos (*overfitting*). Por el contrario, restringir $\mathcal{H}$ reduce la varianza pero aumenta el sesgo (*underfitting*). El arte del aprendizaje supervisado consiste en equilibrar ambas fuentes de error.

2.2. Espacios de Hilbert a núcleo reproductor (RKHS)

En la sección anterior hemos visto que el problema del aprendizaje se reduce a minimizar el error de generalización dentro de un espacio de hipótesis $\mathcal{H}$, y que para garantizar la existencia de minimizadores basta con que $\mathcal{H}$ sea compacto en $\mathcal{C}_b(X)$. Los **espacios de Hilbert a núcleo reproductor** (*Reproducing Kernel Hilbert Spaces*, RKHS) son una familia de espacios de hipótesis que satisfacen estas condiciones de forma natural y, además, poseen propiedades computacionales excepcionales que veremos más adelante.

La teoría de los RKHS se articula en torno a un objeto central: el **núcleo** (o *kernel*), una función sobre $X \times X$ que codifica toda la geometría del espacio funcional. El tipo de kernel que nos interesa es el de Mercer, cuyas propiedades garantizan que el espacio resultante sea un espacio de Hilbert sobre el que se puede hacer análisis.

Definición 2.2.1 (Núcleo de Mercer). Sea $\mathbb{K} \in \{\mathbb{R}, \mathbb{C}\}$ y X un espacio topológico. Un

núcleo de Mercer sobre X es una función $K: X \times X \rightarrow \mathbb{K}$ que satisface:

- (I) Continuidad: K es continua.
- (II) Hermiticidad: $K(x, y) = \overline{K(y, x)}$ para todo $x, y \in X$.
- (III) Semidefinición positiva: para todo $m \in \mathbb{N}$ y todo $\{x_i\}_{i=1}^m \subset X$, la *matriz de Gram* $G \in M_m(\mathbb{K})$ definida por $G_{ij} = K(x_i, x_j)$ es semidefinida positiva, es decir,

$$\forall v \in \mathbb{K}^m : v^* G v = \sum_{i,j=1}^m \overline{v_i} K(x_i, x_j) v_j \geq 0.$$

El siguiente teorema garantiza la existencia y unicidad del RKHS asociado a cualquier núcleo de Mercer, y muestra cómo construirlo explícitamente. La clave de la construcción es que las funciones $K_x(y) = K(x, y)$ (“secciones” del kernel) actúan simultáneamente como elementos del espacio y como representantes de los funcionales de evaluación.

Teorema 2.2.2 (Existencia y unicidad del RKHS). *Sea $K: X \times X \rightarrow \mathbb{K}$ un núcleo de Mercer. Para cada $x \in X$, sea $K_x: X \rightarrow \mathbb{K}$ la función $K_x(y) := K(x, y)$. Entonces existe un único espacio de Hilbert $\mathcal{H}_K$ sobre $\mathbb{K}$, formado por funciones $X \rightarrow \mathbb{K}$, tal que:*

- (1) *Densidad:* $\text{span}\{K_x : x \in X\}$ es denso en $\mathcal{H}_K$.
- (2) *Propiedad reproductora:* $f(x) = \langle f, K_x \rangle_{\mathcal{H}_K}$ para toda $f \in \mathcal{H}_K$ y todo $x \in X$.

A $\mathcal{H}_K$ se le llama el **RKHS asociado a K** , y a K el **núcleo reproductor** de $\mathcal{H}_K$.

Además, si K es acotado (es decir, $K \in \mathcal{C}_b(X \times X)$), entonces $\mathcal{H}_K \subset \mathcal{C}(X)$ y la inclusión $\mathcal{H}_K \hookrightarrow \mathcal{C}(X)$ es continua respecto de la norma del supremo.

Demostración: La construcción sigue tres pasos: definir un producto interno en el espacio lineal generado por las secciones K_x , completarlo para obtener un espacio de Hilbert, y verificar la propiedad reproductora. La unicidad se deduce al final.

Paso 1: Pre-espacio de Hilbert. Sea $\mathring{\mathcal{H}} := \text{span}\{K_x : x \in X\}$. Todo elemento de $\mathring{\mathcal{H}}$ se escribe como combinación lineal finita $f = \sum_{i=1}^N c_i K_{x_i}$. Definimos:

$$\left\langle \sum_{i=1}^N c_i K_{x_i}, \sum_{j=1}^M d_j K_{y_j} \right\rangle_K := \sum_{i=1}^N \sum_{j=1}^M c_i \overline{d_j} K(x_i, y_j).$$

Esta expresión es sesquilineal y hermítica (porque $K(x, y) = \overline{K(y, x)}$). La semidefinición positiva del núcleo asegura que $\langle f, f \rangle_K \geq 0$ para todo $f \in \mathring{\mathcal{H}}$. Obtenemos así la **propiedad**

reproductora en $\mathring{\mathcal{H}}$: para $f = \sum_i c_i K_{x_i}$,

$$\forall x \in X : \langle f, K_x \rangle_K = \sum_{i=1}^N c_i K(x_i, x) = f(x).$$

Paso 2: Norma y completación. Si $\langle f, f \rangle_K = 0$, la desigualdad de Cauchy-Schwarz en $\langle \cdot, \cdot \rangle_K$ da, para todo $x \in X$:

$$|f(x)|^2 = |\langle f, K_x \rangle_K|^2 \leq \langle f, f \rangle_K \cdot \langle K_x, K_x \rangle_K = 0 \cdot K(x, x) = 0,$$

luego $f = 0$. Por tanto $\langle \cdot, \cdot \rangle_K$ es un producto interno en $\mathring{\mathcal{H}}$ y $\|f\|_K := \sqrt{\langle f, f \rangle_K}$ es una norma. Definimos $\mathcal{H}_K$ como la complección de $(\mathring{\mathcal{H}}, \|\cdot\|_K)$: es un espacio de Hilbert.

Paso 3: $\mathcal{H}_K \subset \mathcal{C}(X)$ e inclusión continua (bajo $K \in \mathcal{C}_b$). Sea $C_K := \sup_{x \in X} K(x, x) < \infty$ (finito porque K es acotado). Para todo $f \in \mathring{\mathcal{H}}$ y todo $x \in X$, la propiedad reproductora y Cauchy-Schwarz dan:

$$|f(x)| = |\langle f, K_x \rangle_K| \leq \|f\|_K \|K_x\|_K = \|f\|_K \sqrt{K(x, x)} \leq \sqrt{C_K} \|f\|_K,$$

luego $\|f\|_\infty \leq \sqrt{C_K} \|f\|_K$ para todo $f \in \mathring{\mathcal{H}}$. Esta desigualdad se extiende a $\mathcal{H}_K$ por densidad: si $f \in \mathcal{H}_K$ y $(f_n) \subset \mathring{\mathcal{H}}$ con $\|f_n - f\|_K \rightarrow 0$, entonces

$$\|f_n - f_m\|_\infty \leq \sqrt{C_K} \|f_n - f_m\|_K \rightarrow 0,$$

así que (f_n) es de Cauchy en $(\mathcal{C}(X), \|\cdot\|_\infty)$, cuya completación es $(\mathcal{C}(X), \|\cdot\|_\infty)$ (ya que el límite uniforme de funciones continuas en un espacio métrico es continuo). Luego $f = \lim f_n \in \mathcal{C}(X)$, con $\|f\|_\infty \leq \sqrt{C_K} \|f\|_K$. Esto prueba:

- $\mathcal{H}_K \subset \mathcal{C}(X)$.
- La inclusión $\iota: \mathcal{H}_K \hookrightarrow \mathcal{C}(X)$ satisface $\|\iota(f)\|_\infty = \|f\|_\infty \leq \sqrt{C_K} \|f\|_K$, es decir, es Lipschitz (en particular, continua).

Paso 4: Extensión de la propiedad reproductora a $\mathcal{H}_K$. Para cada $x \in X$ fijo, el funcional $f \mapsto \langle f, K_x \rangle_K$ es continuo en $\mathcal{H}_K$ (por ser lineal y acotado). Como coincide con $f \mapsto f(x)$ en el denso $\mathring{\mathcal{H}}$, la igualdad $f(x) = \langle f, K_x \rangle_K$ se extiende a todo $\mathcal{H}_K$.

Unicidad. Si $\tilde{\mathcal{H}}$ fuera otro espacio de Hilbert satisfaciendo (1) y (2), la propiedad reproductora fijaría el producto interno en $\text{span}\{K_x\}$ (que es denso en ambos espacios), y la completación sería única. ■

El teorema 2.2.2 parte de un núcleo de Mercer para construir un RKHS. Existe también una caracterización abstracta equivalente, que parte de un espacio de Hilbert de funciones y le

exige que la evaluación puntual sea continua.

Definición 2.2.3 (RKHS: caracterización abstracta). Sea $X \neq \emptyset$ un conjunto y $\mathcal{H}$ un espacio de Hilbert de funciones $f: X \rightarrow \mathbb{K}$. Se dice que $\mathcal{H}$ es un RKHS sobre X si, para todo $x \in X$, el funcional de evaluación $\delta_x: \mathcal{H} \rightarrow \mathbb{K}$, $\delta_x(f) := f(x)$, es continuo, es decir,

$$\forall f \in \mathcal{H} : \forall x \in X : \exists D_x > 0 : |f(x)| \leq D_x \|f\|_{\mathcal{H}}.$$

En tal caso, por el teorema de representación de Riesz, para cada $x \in X$ existe un único $K_x \in \mathcal{H}$ tal que $\forall f \in \mathcal{H} : f(x) = \langle f, K_x \rangle_{\mathcal{H}}$. La función $K: X \times X \rightarrow \mathbb{K}$ definida por $K(x, y) := \langle K_x, K_y \rangle_{\mathcal{H}}$ se llama el **núcleo reproductor** de $\mathcal{H}$.

Observación 2.2.4. Las dos perspectivas son equivalentes: el teorema 2.2.2 muestra que todo núcleo de Mercer K produce un RKHS $\mathcal{H}_K$ en el sentido de la definición 2.2.3 (la continuidad de δ_x se sigue de $|f(x)| \leq \sqrt{C_K} \|f\|_K$). Recíprocamente, el núcleo reproductor de cualquier RKHS abstracto es siempre un núcleo de Mercer.

La conexión entre los RKHS y la existencia de minimizadores (requerida en el teorema 2.1.7) se establece a través del siguiente resultado de compacidad: cuando X es compacto, la bola unidad cerrada de $\mathcal{H}_K$ es compacta en $(\mathcal{C}(X), \|\cdot\|_{\infty})$, lo que permite aplicar el teorema 2.1.7.

Teorema 2.2.5 (Compacidad de la bola unidad). Sean X un espacio métrico compacto y $K \in \mathcal{C}_b(X \times X)$ un núcleo de Mercer. Sea $\overline{B} := \{f \in \mathcal{H}_K : \|f\|_K \leq 1\}$ la bola unidad cerrada de $\mathcal{H}_K$. Entonces $\overline{B}$ es compacto en $(\mathcal{C}(X), \|\cdot\|_{\infty})$.

Demostración: Por el teorema de Arzelà-Ascoli, basta verificar que $\overline{B}$ es cerrado, acotado y equicontinuo en $(\mathcal{C}(X), \|\cdot\|_{\infty})$.

Acotado. Por el teorema 2.2.2, $\|f\|_{\infty} \leq \sqrt{C_K} \|f\|_K \leq \sqrt{C_K}$ para todo $f \in \overline{B}$, donde $C_K = \sup_{x \in X} K(x, x) < \infty$.

Equicontinuo. Como X es compacto y K es continua, por el teorema de Heine K es uniformemente continua en $X \times X$: dado $\varepsilon > 0$, existe $\delta > 0$ tal que $d(y, y') < \delta$ implica $|K(x, y) - K(x, y')| < \varepsilon$ para todo $x \in X$. Entonces, para todo $f \in \overline{B}$ y todo $y, y' \in X$ con $d(y, y') < \delta$:

$$\begin{aligned} |f(y) - f(y')| &= |\langle f, K_y - K_{y'} \rangle_{\mathcal{H}_K}| \leq \|f\|_K \|K_y - K_{y'}\|_K \\ &\leq \sqrt{K(y, y) - K(y, y') - K(y', y) + K(y', y')} < \sqrt{2\varepsilon}, \end{aligned}$$

usando que $\|K_y - K_{y'}\|_K^2 = K(y, y) - K(y, y') - K(y', y) + K(y', y')$ y la cota de continuidad uniforme.

Cerrado. Sea $\{f_m\} \subset \overline{B}$ con $\|f_m - f\|_\infty \rightarrow 0$ para algún $f \in \mathcal{C}(X)$. Por el teorema de Banach-Alaoglu, $\overline{B}$ es débilmente compacto en $\mathcal{H}_K$, de modo que existe una subsucesión $\{f_{m_k}\}$ con $f_{m_k} \rightharpoonup \hat{f}$ débilmente en $\mathcal{H}_K$ para algún $\hat{f} \in \overline{B}$. Para cada $x \in X$, el funcional $g \mapsto \langle g, K_x \rangle_K$ es continuo en $\mathcal{H}_K$, luego:

$$\hat{f}(x) = \langle \hat{f}, K_x \rangle_K = \lim_k \langle f_{m_k}, K_x \rangle_K = \lim_k f_{m_k}(x) = f(x).$$

Por tanto $f = \hat{f} \in \overline{B}$, lo que prueba que $\overline{B}$ es cerrado en $(\mathcal{C}(X), \|\cdot\|_\infty)$. ■

Observación 2.2.6. Este teorema garantiza que $\overline{B}$ satisface las hipótesis del teorema 2.1.7: es compacto en $(\mathcal{C}(X), \|\cdot\|_\infty)$ y, si además $|f(x) - y| \leq M$ ρ -c.s. para todo $f \in \overline{B}$, existen tanto la función objetivo $f_{\mathcal{H}_K}$ como la función empírica $f_{\mathcal{H}_K, \mathcal{D}}$ en $\overline{B}$.

Con este resultado el marco teórico de los RKHS queda conectado con el problema del aprendizaje: dado un núcleo de Mercer acotado sobre un espacio compacto X , la bola $M\overline{B} = \{f \in \mathcal{H}_K : \|f\|_K \leq M\}$ satisface las hipótesis del teorema 2.1.7 para todo $M > 0$. El parámetro M actúa como un hiperparámetro de regularización: valores pequeños restringen las hipótesis a funciones de norma acotada, reduciendo la complejidad del espacio a costa de un mayor sesgo.

Antes de ver cómo minimizar el riesgo regularizado eficientemente, veamos los dos ejemplos principales de RKHS. El primero, el kernel gaussiano RBF, es el más utilizado en la práctica; el segundo, el espacio de Fock-Bargmann, ilustra la conexión entre los RKHS y el análisis complejo.

Ejemplo 2.2.7 (Kernel Gaussiano RBF). Sean $X \subset \mathbb{R}^d$ y $\alpha > 0$. El **kernel gaussiano de base radial** (RBF, *Radial Basis Function*) es

$$K_\alpha: X \times X \rightarrow \mathbb{R}, \quad K_\alpha(x, y) := e^{-\alpha\|x-y\|^2}.$$

Veamos que K_α es un núcleo de Mercer en el sentido de la definición 2.2.1.

Continuidad y simetría. La función K_α es continua (composición de funciones continuas) y satisface $K_\alpha(x, y) = K_\alpha(y, x)$, por lo que las condiciones (1) y (2) de la definición 2.2.1 se verifican.

Semidefinición positiva. Sea $g: \mathbb{R}^d \rightarrow \mathbb{R}$ la gaussiana centrada $g(z) := e^{-\alpha\|z\|^2}$, de modo que $K_\alpha(x, y) = g(x - y)$. Escribimos la transformada de Fourier de g con la convención

$\hat{g}(\xi) = \int_{\mathbb{R}^d} e^{-2\pi i \langle \xi, x \rangle} g(x) dx$. Calculando por separación de variables,

$$\hat{g}(\xi) = \prod_{j=1}^d \int_{\mathbb{R}} e^{-2\pi i \xi_j x_j} e^{-\alpha x_j^2} dx_j = \left(\frac{\pi}{\alpha}\right)^{d/2} e^{-\frac{\pi^2}{\alpha} \|\xi\|^2}.$$

En particular, $\hat{g}(\xi) > 0$ para todo $\xi \in \mathbb{R}^d$. Por el teorema de inversión de Fourier,

$$g(z) = \int_{\mathbb{R}^d} e^{2\pi i \langle \xi, z \rangle} \hat{g}(\xi) d\xi.$$

Sean ahora $\{x_i\}_{i=1}^m \subset X$ y $v \in \mathbb{R}^m$. Entonces:

$$\begin{aligned} v^T G v &= \sum_{i,j=1}^m v_i v_j K_\alpha(x_i, x_j) = \sum_{i,j=1}^m v_i v_j g(x_i - x_j) = \sum_{i,j=1}^m v_i v_j \int_{\mathbb{R}^d} e^{2\pi i \langle \xi, x_i - x_j \rangle} \hat{g}(\xi) d\xi \\ &= \int_{\mathbb{R}^d} \left(\sum_{i=1}^m v_i e^{2\pi i \langle \xi, x_i \rangle} \right) \overline{\left(\sum_{j=1}^m v_j e^{2\pi i \langle \xi, x_j \rangle} \right)} \hat{g}(\xi) d\xi = \int_{\mathbb{R}^d} \left| \sum_{i=1}^m v_i e^{2\pi i \langle \xi, x_i \rangle} \right|^2 \hat{g}(\xi) d\xi \geq 0, \end{aligned}$$

ya que $\hat{g} \geq 0$. Luego K_α es semidefinido positivo y, por tanto, es un núcleo de Mercer.

Observación 2.2.8. Los elementos de $\mathcal{H}_{K_\alpha}$ son (límites en $\|\cdot\|_{K_\alpha}$ de) combinaciones lineales de gaussianas centradas en puntos de X :

$$f \in \mathcal{H}_{K_\alpha} \implies f(x) \approx \sum_{j=1}^m c_j e^{-\alpha \|x - x_j\|^2}.$$

En Steinwart y Hush, “*An explicit description of the RKHS of Gaussian RBF Kernels*”, IEEE Trans. Information Theory **52** (2006), se demuestra que, para $X = \mathbb{C}^d$ y el kernel

$$K_\alpha(z, w) = e^{-\alpha \sum_{j=1}^d (z_j - \overline{w_j})^2},$$

el RKHS asociado es el espacio de Fock-Bargmann:

$$\mathcal{H}_{K_\alpha} = \left\{ f \in \text{Hol}(\mathbb{C}^d) : \left(\frac{2\alpha}{\pi}\right)^d \int_{\mathbb{C}^d} |f(z)|^2 e^{-\alpha \|z\|^2} dz < \infty \right\},$$

un espacio de Hilbert de funciones holomorfas. Por restricción, $\mathcal{H}_{K_\alpha}(\mathbb{R}^d) = \{f|_{\mathbb{R}^d} : f \in \mathcal{H}_{K_\alpha}\}$ es un espacio de funciones reales analíticas.

El espacio de Fock-Bargmann aparece, pues, como el RKHS del kernel RBF complejo. Puede describirse también de forma directa como el RKHS del kernel holomorfo $K(z, w) = e^{\pi z \overline{w}}$, que no involucra decaimiento gaussiano en los argumentos sino únicamente la estructura de producto escalar en $\mathbb{C}$. Este segundo punto de vista, que desarrollamos a continuación, pone en evidencia la geometría intrínseca del espacio y su conexión con el análisis tiempo-frecuencia.

Ejemplo 2.2.9 (Espacio de Fock-Bargmann). Consideremos $X = \mathbb{C}$ y el kernel

$$K: \mathbb{C} \times \mathbb{C} \rightarrow \mathbb{C}, \quad K(z, w) := e^{\pi z \bar{w}}.$$

Es un núcleo de Mercer: la hermiticidad $K(z, w) = \overline{K(w, z)}$ es inmediata, y la semidefinición positiva se verifica desarrollando la exponencial en serie de potencias:

$$\sum_{i,j} v_i \bar{v}_j e^{\pi z_i \bar{z}_j} = \sum_{n=0}^{\infty} \frac{\pi^n}{n!} \sum_{i,j} v_i \bar{v}_j z_i^n \bar{z}_j^n = \sum_{n=0}^{\infty} \frac{\pi^n}{n!} \left| \sum_i v_i z_i^n \right|^2 \geq 0.$$

Este kernel se relaciona con el kernel RBF complejo $K_\pi(z, w) = e^{-\pi(z-\bar{w})^2}$ (cf. ejemplo 2.2.7) a través de la identidad

$$K_\pi(z, w) = e^{-\pi(z^2 + \bar{w}^2)} K(z, w).$$

Puede demostrarse (Folland, *Harmonic Analysis in Phase Space*, Princeton, 1989) que el RKHS asociado es el **espacio de Fock-Bargmann**:

$$\mathcal{H}_K = \left\{ F \in \text{Hol}(\mathbb{C}) : \|F\|_K^2 := \int_{\mathbb{C}} |F(z)|^2 e^{-\pi|z|^2} dz < \infty \right\}.$$

La **transformada de Bargmann** de $f \in L^2(\mathbb{R})$,

$$V_f(p, q) := e^{\frac{\pi}{2}(p^2 + q^2)} e^{-\pi i p q} \int_{\mathbb{R}} f(x) e^{-\pi(x-p)^2} e^{2\pi i q x} dx, \quad p + iq \in \mathbb{C},$$

satisface $V_f \in \mathcal{H}_K$, y la aplicación $f \mapsto V_f$ es una isometría $L^2(\mathbb{R}) \xrightarrow{\sim} \mathcal{H}_K$.

Los dos ejemplos anteriores muestran la diversidad de espacios de hipótesis que puede generar la teoría de los RKHS. Sin embargo, la utilidad central para el aprendizaje supervisado no es solo la existencia de minimizadores, sino la posibilidad de encontrarlos eficientemente. Para ello, los RKHS poseen dos propiedades adicionales fundamentales:

1. Existen RKHS sobre espacios métricos compactos, capaces de separar todos los conjuntos compactos: si $A, B \subset X$ compactos disjuntos, $\exists f_{A,B} \in \mathcal{H}_K$ tal que

$$\forall x \in A : f_{A,B}(x) > 0 \quad \wedge \quad \forall x \in B : f_{A,B}(x) < 0.$$

Un kernel que hace esto es el RBF (*Steinwart, Christmann, §4.6*).

2. El mínimo del riesgo regularizado en un RKHS, cuando existe, vive siempre en el subespacio de dimensión finita generado por las secciones del kernel en los puntos de datos. Este resultado, llamado **teorema del representador**, es lo que hace computacionalmente tratable la minimización en un espacio funcionalmente infinito-dimensional.

La segunda propiedad es el contenido del siguiente teorema, que cierra la sección.

Teorema 2.2.10 (Teorema del representador). Sean X un espacio métrico, $K \in \mathcal{C}_b(X \times X)$

X) un núcleo de Mercer, y $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset X \times \mathbb{R}$. Dadas una función de pérdida $E: (X \times \mathbb{R}^2)^m \rightarrow \mathbb{R}_+$ y una función $g: \mathbb{R}_+ \rightarrow \mathbb{R}_+$ estrictamente creciente, define el **funcional de riesgo regularizado**

$$R_g[f] := E(\{(x_i, y_i, f(x_i))\}_{i=1}^m) + g(\|f\|_{\mathcal{H}_K}), \quad f \in \mathcal{H}_K.$$

Si $f^* \in \mathcal{H}_K$ minimiza R_g , entonces $f^* \in V_0 := \text{span}\{K_{x_i}\}_{i=1}^m$; es decir, existen $\alpha_1, \dots, \alpha_m \in \mathbb{R}$ tales que

$$f^* = \sum_{i=1}^m \alpha_i K_{x_i}.$$

Demostración: Sea $V_0 := \text{span}\{K_{x_i}\}_{i=1}^m$, un subespacio cerrado de dimensión finita de $\mathcal{H}_K$. Por el teorema de proyección ortogonal, toda $f \in \mathcal{H}_K$ se descompone de forma única como $f = P_{V_0}f + P_{V_0^\perp}f$, con $P_{V_0}f \in V_0$ y $P_{V_0^\perp}f \perp V_0$. Veamos que proyectar sobre V_0 no aumenta el riesgo.

El término de pérdida no cambia. Para cada $j = 1, \dots, m$, como $K_{x_j} \in V_0$ y $P_{V_0^\perp}f \perp K_{x_j}$, la propiedad reproductora da:

$$f(x_j) = \langle f, K_{x_j} \rangle_{\mathcal{H}_K} = \langle P_{V_0}f + P_{V_0^\perp}f, K_{x_j} \rangle_{\mathcal{H}_K} = \langle P_{V_0}f, K_{x_j} \rangle_{\mathcal{H}_K} = (P_{V_0}f)(x_j).$$

Luego $E(\{(x_i, y_i, f(x_i))\}_{i=1}^m) = E(\{(x_i, y_i, (P_{V_0}f)(x_i))\}_{i=1}^m)$.

El término de regularización no aumenta. Por el teorema de Pitágoras,

$$\|f\|_{\mathcal{H}_K}^2 = \|P_{V_0}f\|_{\mathcal{H}_K}^2 + \|P_{V_0^\perp}f\|_{\mathcal{H}_K}^2 \geq \|P_{V_0}f\|_{\mathcal{H}_K}^2,$$

y como g es estrictamente creciente, $g(\|f\|_{\mathcal{H}_K}) \geq g(\|P_{V_0}f\|_{\mathcal{H}_K})$, con igualdad si y solo si $\|P_{V_0^\perp}f\|_{\mathcal{H}_K} = 0$.

Combinando ambas observaciones: $R_g[P_{V_0}f] \leq R_g[f]$ para todo $f \in \mathcal{H}_K$. Si f^* minimiza R_g , la desigualdad $R_g[P_{V_0}f^*] \leq R_g[f^*]$ junto con la minimalidad de f^* fuerza $R_g[P_{V_0}f^*] = R_g[f^*]$; por la estricta monotonía de g , esto implica $\|P_{V_0^\perp}f^*\|_{\mathcal{H}_K} = 0$, luego $f^* = P_{V_0}f^* \in V_0$. ■

Observación 2.2.11. El teorema reduce la optimización sobre el espacio de dimensión infinita $\mathcal{H}_K$ a un problema en $\mathbb{R}^m$. Toda $f \in V_0$ se escribe $f = \sum_{i=1}^m \alpha_i K_{x_i}$, y la propiedad reproductora da $f(x_j) = \sum_{i=1}^m \alpha_i K(x_i, x_j) = (G\alpha)_j$, donde $G_{ij} = K(x_i, x_j)$ es la **matriz de Gram**. Además, $\|f\|_{\mathcal{H}_K}^2 = \alpha^T G \alpha$ (por definición del producto interno en $\mathring{\mathcal{H}}$). El riesgo

regularizado queda entonces como función de $\alpha \in \mathbb{R}^m$:

$$R_g[\alpha] = E\left(\{(x_i, y_i, (G\alpha)_i)\}_{i=1}^m\right) + g(\sqrt{\alpha^T G \alpha}).$$

El teorema no garantiza que R_g tenga mínimo en $\mathcal{H}_K$ (eso requiere las hipótesis del teorema 2.1.7), solo dice que, si el mínimo existe, está en V_0 .

En resumen, los RKHS combinan estructura funcional (la evaluación puntual es continua, lo que permite definir el error puntual coherentemente) con estructura de espacio de Hilbert (existencia de proyecciones, propiedad reproductora). El teorema 2.2.5 garantiza que las bolas cerradas son compactas, asegurando la existencia de minimizadores vía el teorema 2.1.7. El teorema 2.2.10 garantiza que cualquier minimizador tiene una representación finita, lo que reduce el problema de optimización de dimensión infinita a uno de dimensión m (el número de puntos de datos). Juntos, estos dos resultados son la base matemática de los métodos de aprendizaje por kernel (*kernel methods*) como las máquinas de vectores de soporte (SVM) o la regresión de kernel.

3. Clasificación y optimización convexa

3.1. Clasificadores Lineales Binarios

Esta sección sigue un recorrido progresivo: partimos de la formulación del problema binario y la noción de error, pasamos a las condiciones geométricas de separabilidad, estudiamos criterios de margen (Hard/Soft SVM) y cerramos con la extensión no lineal mediante núcleos.

3.1.1. Fundamentos del problema

3.1.1.1. Planteamiento estadístico

El problema de *clasificación binaria* consiste en lo siguiente. Disponemos de un *espacio de observaciones* $X \subset \mathbb{R}^d$ y queremos asignar a cada punto $x \in X$ una de dos posibles *etiquetas*, que codificamos como $Y = \{-1, 1\}$. Suponemos que los datos se generan a partir de una distribución de probabilidad desconocida ρ sobre $X \times Y$: la marginal ρ_X describe cómo se distribuyen las observaciones, y las probabilidades condicionales $\rho(y \mid x)$ describen la incertidumbre intrínseca de la etiqueta dado un punto.

Una *clasificación* es una función $f: X \rightarrow Y$ que, a cada observación, le asigna una predicción de su etiqueta. La bondad de una clasificación se mide por su *error de clasificación* (o error de generalización), que cuantifica la probabilidad de que f se equivoque en un punto tomado al azar de ρ .

3.1.1.2. Error de clasificación y error empírico

Definición 3.1.1 (Error de clasificación). Sea $f: X \rightarrow Y$ una clasificación de X . El **error de clasificación** de f es

$$\mathcal{E}[f] = \int_Z |f(x) - y|^2 d\rho(x, y) = 4 \int_X \mathbb{P}(Y \neq f(x) \mid x) d\rho_X(x),$$

donde la segunda igualdad usa que $|f(x) - y|^2 = 4\mathbb{1}_{\{y \neq f(x)\}}$ para $f(x), y \in \{-1, 1\}$.

En la práctica, la distribución ρ es desconocida y solo disponemos de un *conjunto de datos* o *muestra de entrenamiento* $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset X \times Y$, formado por m observaciones etiquetadas que suponemos extraídas de forma independiente según ρ . El error empírico

$\mathcal{E}_{\mathcal{D}}[f]$ sirve como estimación del error verdadero $\mathcal{E}[f]$, y el objetivo es encontrar f que lo minimice.

La familia más sencilla de clasificadores es la de los *clasificadores lineales*: aquellos que deciden la etiqueta según en qué semiplano del espacio $\mathbb{R}^d$ cae la observación. Geométricamente, la frontera de decisión es un *hiperplano* $H = \{x \in \mathbb{R}^d : \langle w, x \rangle + b = 0\}$ determinado por un vector normal $w \in \mathbb{R}^d$ y un umbral $b \in \mathbb{R}$. Para que tal hiperplano clasifique correctamente todos los puntos de $\mathcal{D}$, se necesita que los datos de cada clase estén estrictamente en lados opuestos de H .

Definición 3.1.2 (Error empírico). Sea $f: X \rightarrow Y$ una clasificación de X y $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m$ un conjunto de datos. El **error empírico** de f para $\mathcal{D}$ (caso especial de $\mathcal{E}_{\mathcal{D}}$ de la definición 2.1.4 para $Y = \{-1, 1\}$) es

$$\mathcal{E}_{\mathcal{D}}[f] = \frac{1}{m} \sum_{i=1}^m |f(x_i) - y_i|^2 = \frac{4}{m} |\{i \in \{1, \dots, m\} : f(x_i) \neq y_i\}|.$$

3.1.2. Separabilidad y geometría lineal

3.1.2.1. Condición de separabilidad por hiperplano

Un ejemplo sencillo de clasificación es la clasificación lineal: dado un hiperplano

$$H = \{x \in \mathbb{R}^d : \langle w, x \rangle + b = 0\},$$

se asigna a cada punto la etiqueta del semiplano en que cae. Para que este clasificador tenga error empírico nulo, es necesario y suficiente que los datos de cada clase queden estrictamente en lados opuestos de H . Esta condición sobre el conjunto de datos recibe un nombre propio.

Definición 3.1.3 (Separabilidad). Un conjunto de datos $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset \mathbb{R}^d \times \{-1, 1\}$ es separable por un hiperplano (SPH)

$$\iff \exists w \in \mathbb{R}^d, b \in \mathbb{R} : \forall i \in \mathbb{N}_m : y_i \cdot (\langle w, x_i \rangle + b) > 0.$$

Geométricamente, el hiperplano $H = \{x \in \mathbb{R}^d : \langle w, x \rangle + b = 0\}$ divide $\mathbb{R}^d$ en dos:

$$H^+ = \{x \in \mathbb{R}^d : \langle w, x \rangle + b > 0\}, \quad H^- = \{x \in \mathbb{R}^d : \langle w, x \rangle + b < 0\}.$$

La condición $y_i (\langle w, x_i \rangle + b) > 0$ expresa precisamente que cada observación x_i cae en el semiplano correspondiente a su etiqueta: $x_i \in H^+$ cuando $y_i = 1$, y $x_i \in H^-$ cuando $y_i = -1$. En particular, ningún punto de $\mathcal{D}$ yace sobre el propio hiperplano H .

Definición 3.1.4 (Clasificadores lineales binarios). El espacio de clasificadores lineales

binarios es $\mathcal{H}_2 = \{f : \mathbb{R}^d \rightarrow \{-1, 1\} : f(x) = \text{sgn}(\langle w, x \rangle + b) \wedge w \in \mathbb{R}^d \wedge b \in \mathbb{R}\}$.

Observación 3.1.5. Cada clasificador de $\mathcal{H}_2$ queda determinado por $(w, b) \in \mathbb{R}^d \times \mathbb{R} \cong \mathbb{R}^{d+1}$.

Si $\mathcal{D}$ es (SPH), entonces $\exists f_0 \in \mathcal{H}_2$ tal que $\mathcal{E}_{\mathcal{D}}[f_0] = 0$.

3.1.2.2. Reformulación lineal en dimensión aumentada

Observación 3.1.6. La condición (SPH) es afín: el hiperplano separador $H = \{x \in \mathbb{R}^d : \langle w, x \rangle + b = 0\}$ no pasa por el origen en general. Sin embargo, puede reescribirse como una condición lineal elevando la dimensión en uno.

Dados $x_i \in \mathbb{R}^d$ y $(w, b) \in \mathbb{R}^d \times \mathbb{R}$, definamos los *vectores aumentados*

$$\tilde{x}_i := \begin{pmatrix} x_i \\ 1 \end{pmatrix} \in \mathbb{R}^{d+1} \quad \wedge \quad \tilde{w} := \begin{pmatrix} w \\ b \end{pmatrix} \in \mathbb{R}^{d+1}.$$

Como $\langle w, x_i \rangle + b = \langle \tilde{w}, \tilde{x}_i \rangle$, la condición (SPH) $\forall i \in \mathbb{N}_m : y_i (\langle w, x_i \rangle + b) > 0$ es equivalente a $\forall i \in \mathbb{N}_m : y_i \langle \tilde{w}, \tilde{x}_i \rangle > 0$. Esta es la condición de separabilidad por el subespacio lineal $\tilde{H} = \{\tilde{x} \in \mathbb{R}^{d+1} : \langle \tilde{w}, \tilde{x} \rangle = 0\}$, que sí pasa por el origen. Nótese que los puntos aumentados $\tilde{x}_i$ yacen todos en el hiperplano afín $\{x_{d+1} = 1\} \subset \mathbb{R}^{d+1}$, una copia isométrica de $\mathbb{R}^d$.

3.1.2.3. Separabilidad y envolvente convexa

La caracterización anterior puede reforzarse con una lectura convexa: para clasificadores lineales, basta controlar el comportamiento sobre las envolventes convexas de cada clase.

Recordamos que, dados $\{x_i\}_{i=1}^k \subset \mathbb{R}^d$, la envolvente convexa de $\{x_i\}_{i=1}^k$ es

$$\text{conv}(\{x_i\}_{i=1}^k) = \left\{ \sum_{i=1}^k p_i x_i : p_i \geq 0 \wedge \sum_{i=1}^k p_i = 1 \right\}.$$

Teorema 3.1.7. Sea $(w, b) \in \mathbb{R}^d \times \mathbb{R}$ y sea $h(x) = \langle w, x \rangle + b$. Entonces, $f(x) = \text{sgn}(h(x))$ clasifica (con error empírico nulo) $\mathcal{D}$ en $X_1 \times \{1\}$ y $X_{-1} \times \{-1\}$ si y sólo si

$$\forall v \in \text{conv}(X_1) : f(v) = 1 \quad \wedge \quad \forall v \in \text{conv}(X_{-1}) : f(v) = -1.$$

Demostración: Veamos ambas implicaciones por separado.

$\Leftarrow$ Si f clasifica correctamente $\text{conv}(X_1)$ y $\text{conv}(X_{-1})$, entonces en particular clasifica correctamente $X_1 \subset \text{conv}(X_1)$ y $X_{-1} \subset \text{conv}(X_{-1})$, luego clasifica $\mathcal{D}$ con error nulo.

$\Rightarrow$ Sea $v \in \text{conv}(X_\ell)$, esto es, $v = \sum_{i=1}^k p_i x_i$ con $x_i \in X_\ell$, $p_i \geq 0$ y $\sum_{i=1}^k p_i = 1$. Por

linealidad de $\langle w, \cdot \rangle$ y dado que $\sum p_i = 1$,

$$h(v) = \left\langle w, \sum_{i=1}^k p_i x_i \right\rangle + b = \sum_{i=1}^k p_i \langle w, x_i \rangle + \sum_{i=1}^k p_i b = \sum_{i=1}^k p_i h(x_i).$$

Como f clasifica $\mathcal{D}$ con error nulo, $h(x_i)$ tiene signo ℓ para todo $x_i \in X_\ell$. Siendo $p_i \geq 0$ y $\sum p_i = 1 > 0$, la combinación convexa $\sum p_i h(x_i)$ tiene también signo ℓ . Por tanto, $f(v) = \text{sgn}(h(v)) = \ell$. ■

3.1.3. Hard Margin SVM

El siguiente bloque responde a una pregunta natural: entre todos los separadores lineales con error empírico nulo, ¿cuál es geoméricamente más robusto? La respuesta conduce a maximizar el margen.

3.1.3.1. Algoritmo del Perceptrón

Hasta ahora hemos establecido las condiciones teóricas bajo las que un conjunto de datos puede ser separado perfectamente mediante una frontera lineal. Sin embargo, desde un punto de vista práctico, necesitamos un método constructivo que nos permita encontrar empíricamente dicho hiperplano a partir de los datos.

El *algoritmo del Perceptrón*, propuesto por Frank Rosenblatt en 1958, se encarga precisamente de esto. Se trata de un método iterativo impulsado puramente por el error y, a pesar de ser un procedimiento en apariencia tan rudimentario, cuenta con garantía matemática de convergencia estricta en un número finito de pasos.

Para formular este teorema, analizaremos el conjunto de clasificadores lineales que, no solo separan los datos, sino que lo hacen con un margen constante de al menos 1:

$$\mathcal{W}_1 := \{w \in \mathbb{R}^d : \forall i \in \mathbb{N}_m : y_i \langle w, x_i \rangle \geq 1\}.$$

Observación 3.1.8 (Existencia de B). Definimos $B = \min_{w \in \mathcal{W}_1} \|w\|$. Entonces, B está bien definido y siempre existe si el problema es linealmente separable porque:

1. $\mathcal{W}_1$ es no vacío: Al ser $\mathcal{D}$ separable (SPS), $\exists w_0 \in \mathbb{R}^d$ tal que $\gamma = \min_i y_i \langle w_0, x_i \rangle > 0$. Entonces, tomando $\tilde{w} = \frac{w_0}{\gamma}$, $\forall i \in \mathbb{N}_m : y_i \langle \tilde{w}, x_i \rangle = \frac{1}{\gamma} y_i \langle w_0, x_i \rangle \geq 1$, es decir, $\tilde{w} \in \mathcal{W}_1$.
2. El mínimo siempre se alcanza: El conjunto $\mathcal{W}_1$ está definido por la intersección de m espacios cerrados $y_i \langle w, x_i \rangle \geq 1$, por lo que $\mathcal{W}_1 \subset \mathbb{R}^d$ es cerrado. Como la norma $f(w) =$

$\|w\|$ es continua y coercitiva ($\lim_{\|w\| \rightarrow \infty} f(w) = \infty$), por el Teorema de Weierstrass, f alcanza su mínimo global sobre cualquier subconjunto cerrado y no vacío.

Teorema 3.1.9 (Algoritmo del Perceptrón, Rosenblatt 1958). *Supongamos que el conjunto de datos $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset \mathbb{R}^d \times \{-1, 1\}$ es separable por un subespacio lineal (SPS). Tomamos $\mathcal{W}_1$ y B como en la observación anterior, y definimos $R := \max_{i \in \mathbb{N}_m} \|x_i\|$. Consideremos la siguiente sucesión definida iterativamente comenzando con $w^{(0)} = 0 \in \mathbb{R}^d$:*

En cada paso $k \geq 0$, si existe algún índice $i \in \mathbb{N}_m$ tal que $y_i \langle w^{(k)}, x_i \rangle \leq 0$ (es decir, el dato x_i está mal clasificado por el hiperplano $w^{(k)}$), actualizamos el vector usando ese punto:

$$w^{(k+1)} = w^{(k)} + y_i x_i.$$

Este proceso se detiene en, a lo sumo, $(BR)^2$ pasos y produce un vector $w \in \mathbb{R}^d$ tal que $\forall i \in \mathbb{N}_m : y_i \langle w, x_i \rangle > 0$, es decir, w define un hiperplano que separa $\mathcal{D}$.

Demostración: Tomemos $w^* \in \mathcal{W}_1$ con $\|w^*\| = B$. Analizaremos la evolución de $\langle w^*, w^{(k)} \rangle$ y $\|w^{(k)}\|^2$ tras k pasos del algoritmo.

Denotaremos por (x_{i_j}, y_{i_j}) al dato empleado en la corrección durante el paso j -ésimo. Se tiene por tanto que $w^{(j)} = w^{(j-1)} + y_{i_j} x_{i_j}$ y que $y_{i_j} \langle w^{(j-1)}, x_{i_j} \rangle \leq 0$.

Por un lado, acotamos inferiormente el producto escalar con la solución óptima w^* :

$$\langle w^*, w^{(k)} \rangle = \left\langle w^*, \sum_{j=1}^k y_{i_j} x_{i_j} \right\rangle = \sum_{j=1}^k y_{i_j} \langle w^*, x_{i_j} \rangle.$$

Como $w^* \in \mathcal{W}_1$, por definición separa todos los ejemplos conservando al menos un margen de 1, es decir, $y_{i_j} \langle w^*, x_{i_j} \rangle \geq 1$. En consecuencia:

$$\langle w^*, w^{(k)} \rangle \geq \sum_{j=1}^k 1 = k. \quad (3.1)$$

Por otro lado, acotamos superiormente la norma euclídea del vector iterado. Tenemos que

$$\|w^{(k)}\|^2 = \|w^{(k-1)} + y_{i_k} x_{i_k}\|^2 = \|w^{(k-1)}\|^2 + 2y_{i_k} \langle w^{(k-1)}, x_{i_k} \rangle + \|x_{i_k}\|^2.$$

Sabemos que todos los puntos verifican $\|x\| \leq R$, por lo que $\|x_{i_k}\|^2 \leq R^2$. A su vez, por la condición de selección del punto, $2y_{i_k} \langle w^{(k-1)}, x_{i_k} \rangle \leq 0$. Concluimos entonces que:

$$\|w^{(k)}\|^2 \leq \|w^{(k-1)}\|^2 + R^2.$$

Aplicando esta desigualdad recursivamente desde la condición inicial $w^{(0)} = 0$, obtenemos por inducción trivial que $\|w^{(k)}\|^2 \leq kR^2$.

Finalmente, relacionamos ambos resultados mediante la desigualdad de Cauchy-Schwarz:

$$\stackrel{(3.1)}{\downarrow} k \leq \langle w^*, w^{(k)} \rangle \stackrel{\text{C-S}}{\downarrow} \leq \|w^*\| \|w^{(k)}\| \leq B\sqrt{k}R^2 = BR\sqrt{k}.$$

Partiendo de $k \leq BR\sqrt{k}$ y asumiendo $k > 0$, podemos dividir ambos miembros entre $\sqrt{k}$ para obtener $\sqrt{k} \leq BR$. Elevando la inecuación al cuadrado, el número de iteraciones queda acotado por: $k \leq (BR)^2$.

Puesto que la cantidad de actualizaciones que puede realizar el algoritmo está acotada por $(BR)^2$, el proceso debe detenerse en un número finito de pasos. En ese momento, no existirá i tal que $y_i \langle w^{(k)}, x_i \rangle \leq 0$, luego $w^{(k)}$ define un hiperplano que separa $\mathcal{D}$. ■

Observación 3.1.10 (Interpretación geométrica de la convergencia). La cota máxima de iteraciones del algoritmo, $(BR)^2$, proporciona una intuición clave sobre la dificultad intrínseca del problema de clasificación:

- R representa la dispersión máxima de los datos (el radio de la menor bola centrada en el origen que los contiene).
- Para un clasificador $w \in \mathcal{W}_1$, la distancia euclídea (margen) entre el hiperplano y los datos es al menos $1/\|w\|$. En consecuencia, el valor mínimo $B = \min \|w\|$ es exactamente el *inverso del margen máximo posible*, es decir, $B = 1/\gamma_{\max}$.

Entonces, el producto $BR = R/\gamma_{\max}$ es un factor de escala invariable que mide la dificultad geométrica de la separación. Notablemente, este resultado establece que la velocidad de convergencia es *completamente independiente* de la dimensión d del espacio.

Observación 3.1.11. Si $\mathcal{D}$ es (SPH) o (SPS), puede existir una familia infinita de clasificadores en $\mathcal{H}_2$ con error empírico nulo. Dado que el objetivo último es minimizar el error de generalización $\mathcal{E}[f]$, es razonable preguntarse cuál de los $f \in \mathcal{H}_2$ generaliza mejor.

En la práctica, como la distribución ρ es desconocida, se estima el error de generalización dividiendo el conjunto de datos en dos subconjuntos disjuntos: $\mathcal{D}_{\text{train}}$ y $\mathcal{D}_{\text{test}}$. El clasificador se entrena minimizando $\mathcal{E}_{\mathcal{D}_{\text{train}}}[f]$, y su calidad se evalúa mediante $\mathcal{E}_{\mathcal{D}_{\text{test}}}[f]$.

Muchos algoritmos de aprendizaje dependen de parámetros externos que no se determinan durante el entrenamiento denominados *hiperparámetros*. Para seleccionarlos sin sesgar la evaluación final, es común subdividir a su vez $\mathcal{D}_{\text{train}}$ en dos: un conjunto de entrenamiento y un conjunto de *validación* sobre el que comparar distintas configuraciones.

3.1.3.2. Maximización del Margen

El Perceptrón garantiza encontrar *algún* hiperplano separador, pero, cuando $\mathcal{D}$ es (SPH), existe en general una familia infinita de ellos. La intuición geométrica sugiere preferir el que quede lo más alejado posible de todos los puntos de entrenamiento: un clasificador con mayor margen es menos sensible a perturbaciones en los datos y, en consecuencia, tiende a generalizar mejor. Esta idea da lugar a las *Support Vector Machines* (SVM).

Fijamos $(w, b) \in \mathbb{R}^d \times \mathbb{R}$ con $\|w\| = 1$ y consideramos el hiperplano

$$H_{(w,b)} := \{v \in \mathbb{R}^d : \langle v, w \rangle + b = 0\}.$$

La distancia de un punto $x \in \mathbb{R}^d$ a $H_{(w,b)}$ es

$$\text{dist}(x, H_{(w,b)}) = \min_{v \in H_{(w,b)}} \|x - v\| = |\langle x, w \rangle + b|,$$

donde la última igualdad se deduce de que w es el vector normal unitario a $H_{(w,b)}$.

Definimos los conjuntos de índices $I_1, I_{-1} \subset \{1, \dots, m\}$ como


$$I_1 = \{i \in \mathbb{N}_m : y_i = 1\} \quad \wedge \quad I_{-1} = \{i \in \mathbb{N}_m : y_i = -1\}.$$

Fijada una dirección unitaria w , el **umbral** b que centra el hiperplano $H_{(w,b)}$ correspondiente de manera equidistante a ambas clases viene dado por

$$\beta_{\mathcal{D}}(w) := \frac{1}{2} \left| \text{dist}(\{x_i : i \in I_{-1}\}, H_{(w,0)}) - \text{dist}(\{x_i : i \in I_1\}, H_{(w,0)}) \right|$$

y el **margen** del hiperplano $H_{(w, \beta_{\mathcal{D}}(w))}$, es decir, la distancia común a ambas clases, es

$$\Delta_{\mathcal{D}}(w) := \text{dist}(\{x_i : i \in I_1\}, H_{(w, \beta_{\mathcal{D}}(w))}) = \text{dist}(\{x_i : i \in I_{-1}\}, H_{(w, \beta_{\mathcal{D}}(w))})$$



Ejercicio 3.1.12. Demuestra que, para cada $w \in \mathbb{R}^d$ con $\|w\| = 1$,

$$\beta_{\mathcal{D}}(w) = -\frac{1}{2} \left(\min_{i \in I_1} \langle w, x_i \rangle + \max_{i \in I_{-1}} \langle w, x_i \rangle \right) \quad \wedge \quad \Delta_{\mathcal{D}}(w) = \frac{1}{2} \left(\min_{i \in I_1} \langle w, x_i \rangle - \max_{i \in I_{-1}} \langle w, x_i \rangle \right).$$

Solución: Como $\|w\| = 1$, la distancia de un punto x al hiperplano $H_{(w,b)}$ es $|\langle w, x \rangle + b|$. Denotamos $A := \min_{i \in I_1} \langle w, x_i \rangle$ y $B := \max_{i \in I_{-1}} \langle w, x_i \rangle$.

- (1) Por definición, $\beta_{\mathcal{D}}(w)$ es el único $b \in \mathbb{R}$ que coloca el hiperplano $H_{(w,b)}$ equidistante a ambas clases. Con dicho b , los puntos de I_1 caen en el semiplano positivo y los de I_{-1} en el negativo, de modo que las distancias a ambas clases son

$$\text{dist}(\{x_i : i \in I_1\}, H_{(w,b)}) = \min_{i \in I_1} (\langle w, x_i \rangle + b) = A + b,$$

$$\text{dist}(\{x_i : i \in I_{-1}\}, H_{(w,b)}) = -\max_{i \in I_{-1}} (\langle w, x_i \rangle + b) = -(B + b).$$

Igualándolas: $A + b = -(B + b) \implies 2b = -A - B \implies b = -\frac{A+B}{2}$. Por tanto,

$$\beta_{\mathcal{D}}(w) = -\frac{1}{2} \left(\min_{i \in I_1} \langle w, x_i \rangle + \max_{i \in I_{-1}} \langle w, x_i \rangle \right).$$

- (2) El margen es la distancia común de ambas clases al hiperplano $H_{(w, \beta_{\mathcal{D}}(w))}$:

$$\Delta_{\mathcal{D}}(w) = A + \beta_{\mathcal{D}}(w) = A - \frac{A+B}{2} = \frac{A-B}{2} = \frac{1}{2} \left(\min_{i \in I_1} \langle w, x_i \rangle - \max_{i \in I_{-1}} \langle w, x_i \rangle \right). \quad \blacksquare$$

El objetivo es encontrar la dirección unitaria w que maximice este margen.

Teorema 3.1.13 (Hard-Margin SVM). Sea $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset \mathbb{R}^d \times \{-1, 1\}$ un conjunto de datos (SPH). Entonces:

- (1) Existe un único $w_{\mathcal{D}} \in \mathbb{R}^d$ con $\|w_{\mathcal{D}}\| = 1$ tal que $w_{\mathcal{D}} = \arg \max_{\|w\|=1} \Delta_{\mathcal{D}}(w)$, y el hiperplano $H_{(w_{\mathcal{D}}, \beta_{\mathcal{D}}(w_{\mathcal{D}}))}$ separa $\mathcal{D}$ con margen máximo.
- (2) La única solución $(w^*, \beta_{\mathcal{D}}(w^*))$ del problema de optimización

$$\min_{w \in \mathbb{R}^d} \|w\| \quad \text{sujeto a} \quad \forall i \in \mathbb{N}_m : y_i (\langle w, x_i \rangle + \beta_{\mathcal{D}}(w)) \geq 1 \quad (3.2)$$

$$\text{satisface } w_{\mathcal{D}} = \frac{w^*}{\|w^*\|} \wedge \Delta_{\mathcal{D}}(w_{\mathcal{D}}) = \frac{1}{\|w^*\|}.$$

Demostración:

- (1) Como $\Delta_{\mathcal{D}}$ es continua, por el teorema de Weierstrass alcanza su máximo en la bola cerrada $\overline{B}_1 = \{w \in \mathbb{R}^d : \|w\| \leq 1\}$, que es compacta. Sea $\overline{w} \in \overline{B}_1$ dicho maximizador.

Dado que $\Delta_{\mathcal{D}}(\lambda w) = \lambda \Delta_{\mathcal{D}}(w)$ para todo $\lambda > 0$ (homogeneidad de grado 1), si $\|\overline{w}\| < 1$

y $\Delta_{\mathcal{D}}(\bar{w}) > 0$, entonces

$$\Delta_{\mathcal{D}}\left(\frac{\bar{w}}{\|\bar{w}\|}\right) = \frac{1}{\|\bar{w}\|} \Delta_{\mathcal{D}}(\bar{w}) > \Delta_{\mathcal{D}}(\bar{w}),$$

lo que contradice la maximalidad de $\bar{w}$. Luego $\|\bar{w}\| = 1$.

Para la unicidad, supongamos que existe $w' \in \partial \bar{B}_1$, $w' \neq \bar{w}$, con $\Delta_{\mathcal{D}}(w') = \Delta_{\mathcal{D}}(\bar{w})$.

Entonces, para $t \in (0, 1)$, $v_t := tw' + (1-t)\bar{w}$ satisface $\|v_t\| < 1$, y por linealidad:

$$\Delta_{\mathcal{D}}\left(\frac{v_t}{\|v_t\|}\right) = \frac{\Delta_{\mathcal{D}}(v_t)}{\|v_t\|} = \frac{\Delta_{\mathcal{D}}(\bar{w})}{\|v_t\|} > \Delta_{\mathcal{D}}(\bar{w}),$$

lo que de nuevo contradice la maximalidad. Luego el maximizador $\bar{w}$ es único.

- (2) El conjunto factible $\mathcal{F} := \{w \in \mathbb{R}^d : \forall i \in \mathbb{N}_m : y_i(\langle w, x_i \rangle + \beta_{\mathcal{D}}(w)) \geq 1\}$ es no vacío, cerrado y convexo. El argumento es análogo al de la observación 3.1.8. Como la norma es continua y coercitiva, el mínimo se alcanza en algún punto $w^* \in \mathcal{F}$.

Unicidad de w^* : Supongamos que w_1 y w_2 son dos minimizadores, esto es, $\|w_1\| = \|w_2\| = \min_{w \in \mathcal{F}} \|w\| =: c^*$. Aplicando la identidad del paralelogramo:

$$\left\| \frac{w_1 + w_2}{2} \right\|^2 = \frac{\|w_1\|^2 + \|w_2\|^2}{2} - \left\| \frac{w_1 - w_2}{2} \right\|^2 = (c^*)^2 - \left\| \frac{w_1 - w_2}{2} \right\|^2.$$

Por convexidad de $\mathcal{F}$, el punto $\frac{w_1 + w_2}{2}$ es factible, luego $\left\| \frac{w_1 + w_2}{2} \right\| \geq c^*$, es decir, $\left\| \frac{w_1 + w_2}{2} \right\|^2 \geq (c^*)^2$. Por lo tanto, llegamos a que

$$(c^*)^2 \leq \left\| \frac{w_1 + w_2}{2} \right\|^2 = (c^*)^2 - \left\| \frac{w_1 - w_2}{2} \right\|^2 \implies \left\| \frac{w_1 - w_2}{2} \right\|^2 \leq 0 \implies w_1 = w_2.$$

Sea $\hat{w} := w^*/\|w^*\|$. Dividiendo en $y_i(\langle w^*, x_i \rangle + \beta_{\mathcal{D}}(w^*)) \geq 1$ entre $\|w^*\|$, se obtiene

$$\forall i \in \mathbb{N}_m : y_i \left(\langle \hat{w}, x_i \rangle + \frac{\beta_{\mathcal{D}}(w^*)}{\|w^*\|} \right) \geq \frac{1}{\|w^*\|},$$

lo que implica que $\Delta_{\mathcal{D}}(\hat{w}) \geq 1/\|w^*\|$.

Si $\forall w \in \mathbb{R}^d : \|w\| = 1 : \Delta_{\mathcal{D}}(w) \leq 1/\|w^*\|$, entonces $w_{\mathcal{D}} = \hat{w}$ maximiza $\Delta_{\mathcal{D}}$ y es único por el punto (1). Supongamos por contradicción que existe $w_0 \in \mathbb{R}^d$ tal que $\|w_0\| = 1$ y $\Delta_{\mathcal{D}}(w_0) > 1/\|w^*\|$. Entonces el par $(w_0/\Delta_{\mathcal{D}}(w_0), \beta_{\mathcal{D}}(w_0)/\Delta_{\mathcal{D}}(w_0))$ es factible para (3.2) puesto que $\forall i \in \mathbb{N}_m :$

$$y_i \left(\left\langle \frac{w_0}{\Delta_{\mathcal{D}}(w_0)}, x_i \right\rangle + \frac{\beta_{\mathcal{D}}(w_0)}{\Delta_{\mathcal{D}}(w_0)} \right) = \frac{1}{\Delta_{\mathcal{D}}(w_0)} y_i (\langle w_0, x_i \rangle + \beta_{\mathcal{D}}(w_0)) \geq \frac{\Delta_{\mathcal{D}}(w_0)}{\Delta_{\mathcal{D}}(w_0)} = 1,$$

y tiene norma $1/\Delta_{\mathcal{D}}(w_0) < \|w^*\|$, contradiciendo la optimalidad de w^* . ■

El teorema 3.1.13 muestra que el problema (3.2) admite una formulación eficiente y es computacionalmente muy tratable. Sin embargo, tiene una limitación fundamental: si $\mathcal{D}$ no es (SPH), el conjunto factible es vacío y el problema carece de solución.

3.1.4. Soft Margin SVM

3.1.4.1. Holguras y formulación primal

Para tratar el caso no separable, se introducen *variables de holgura* $\xi_i \geq 0$ que permiten a cada punto violar la restricción de margen en una cantidad ξ_i :

$$y_i (\langle w, x_i \rangle + b) \geq 1 - \xi_i.$$

La idea es penalizar estas violaciones en el objetivo, dando lugar al problema

$$\min_{\substack{(w,b) \in \mathbb{R}^d \times \mathbb{R} \\ \xi \in \mathbb{R}_+^m}} \left(\frac{1}{m} \sum_{i=1}^m \xi_i + \lambda \|w\|^2 \right) \quad \text{sujeto a} \quad \forall i \in \mathbb{N}_m : y_i (\langle w, x_i \rangle + b) \geq 1 - \xi_i, \quad (3.3)$$

donde $\lambda > 0$ es un hiperparámetro que pondera el balance entre el margen y las violaciones.


Dado (w, b) fijo, cada ξ_i aparece en (3.3) con coeficiente positivo $\frac{1}{m}$ en el objetivo y sujeto únicamente a $\xi_i \geq \max\{0, 1 - y_i(\langle w, x_i \rangle + b)\}$ (la restricción $\xi_i \geq 0$ junto con $y_i(\langle w, x_i \rangle + b) \geq 1 - \xi_i$). Minimizar el objetivo requiere tomar ξ_i lo más pequeño posible, es decir, igual a su cota inferior $\max\{0, 1 - y_i(\langle w, x_i \rangle + b)\}$. Así:

- si el punto x_i está correctamente clasificado *con margen suficiente* ($y_i(\langle w, x_i \rangle + b) \geq 1$), entonces $\xi_i^* = 0$ (no hay penalización);
- si el punto viola el margen o está mal clasificado (es decir, $y_i(\langle w, x_i \rangle + b) < 1$), entonces $\xi_i^* = 1 - y_i(\langle w, x_i \rangle + b) > 0$ mide cuánto falta para satisfacer la restricción.

Sustituyendo, el problema (3.3) es equivalente a minimizar la *pérdida hinge regularizada*:

$$\arg \min_{(w,b) \in \mathbb{R}^d \times \mathbb{R}} \mathcal{E}_{\mathcal{D}}^{\text{hinge}}(w, b) + \lambda \|w\|^2, \quad \text{donde} \quad \mathcal{E}_{\mathcal{D}}^{\text{hinge}}(w, b) := \frac{1}{m} \sum_{i=1}^m \max\{0, 1 - y_i(\langle w, x_i \rangle + b)\}.$$

El término *hinge* (“bisagra” en inglés) alude a la forma de la función $t \mapsto \max\{0, 1 - t\}$:



3.1.4.2. Justificación convexa de la pérdida hinge

Observación 3.1.14 (La pérdida hinge como sustituto convexo del error 0-1). El objetivo natural del problema de clasificación sería minimizar directamente el error empírico 0-1, es decir, el funcional

$$\mathcal{E}_0(w, b) = \frac{1}{m} |\{i : y_i(\langle w, x_i \rangle + b) \leq 0\}|,$$

que cuenta la fracción de puntos mal clasificados. Sin embargo, $\mathcal{E}_0$ es discontinua y no convexa: su paisaje de optimización está plagado de mínimos locales, lo que hace que minimizarla sea computacionalmente intratable en general.

La pérdida *hinge* resuelve este problema: la función $t \mapsto \max\{0, 1 - t\}$ es convexa y acota superiormente al indicador de error, pues $\max\{0, 1 - t\} \geq \mathbb{1}_{[t \leq 0]}$ para todo $t \in \mathbb{R}$. Como el término $\lambda \|w\|^2$ también es convexo, el funcional completo

$$\mathcal{E}_{\mathcal{D}}^{\text{hinge}}(w, b) + \lambda \|w\|^2$$

es *estrictamente convexo* para todo $\lambda > 0$, luego tiene un único mínimo global y puede minimizarse eficientemente mediante el descenso de gradiente.


3.1.5. Support Vector Machines con Núcleo Reprodutor

3.1.5.1. Motivación no lineal

Las versiones Hard y Soft de SVM construyen su frontera de decisión como un hiperplano en el espacio original $\mathbb{R}^d$: la Hard-SVM requiere que $\mathcal{D}$ sea (SPH), mientras que la Soft-SVM tolera ciertas violaciones del margen. Sin embargo, existen conjuntos de datos con una estructura no lineal tan pronunciada que ningún hiperplano, con independencia del margen admisible, puede capturarla adecuadamente.

La solución consiste en *mapear* implícitamente los datos a un espacio de mayor dimensión en el que sí sean linealmente separables y aplicar allí las SVM.

Ejemplo 3.1.15. Consideremos $\mathcal{D} \subset \mathbb{R}^2 \times \{-1, 1\}$ donde la clase $+1$ agrupa los puntos próximos al origen y la clase -1 forma una corona circular alrededor de ellos:



Ninguna recta en $\mathbb{R}^2$ puede separar ambas clases: la clase +1 queda rodeada por la clase -1 en todas las direcciones. Consideremos la aplicación

$$\phi: \mathbb{R}^2 \longrightarrow \mathbb{R}^3, \quad \phi(x) = \left(x, \frac{1}{1 + \|x\|^2} \right).$$

La tercera coordenada, $\frac{1}{1+\|x\|^2}$, es próxima a 1 en un entorno del origen (clase +1) y se acerca a 0 a medida que $\|x\|$ crece (clase -1). Por tanto, el conjunto $\phi(\mathcal{D})$ es linealmente separable en $\mathbb{R}^3$: existe un plano que lo separa.

Esta idea motiva las SVM con núcleo: en lugar de construir ϕ explícitamente, se trabaja con un Espacio de Hilbert con Núcleo Reprodutor (RKHS) cuyo núcleo $K: X \times X \rightarrow \mathbb{R}$ codifica implícitamente el producto escalar en el espacio imagen.

3.1.5.2. Formulación en RKHS

Proposición 3.1.16. Sean $X \subset \mathbb{R}^d$ y $f: X \rightarrow \mathbb{R}^N$ continua. Consideramos la aplicación $\phi: X \rightarrow \mathbb{R}^{d+N}$ dada por $\phi(x) = (x, f(x))$ cuya imagen es el gráfico de f .

Sea $V := \text{span}\{\phi(x) : x \in X\} \subset \mathbb{R}^{d+N}$. Definimos $K^f: X \times X \rightarrow \mathbb{R}$ dada por

$$K^f(x, y) := \langle x, y \rangle_{\mathbb{R}^d} + \langle f(x), f(y) \rangle_{\mathbb{R}^N} = \langle \phi(x), \phi(y) \rangle_{\mathbb{R}^{d+N}},$$

y el espacio de funciones

$$\mathcal{H}_\phi := \{ \xi: X \rightarrow \mathbb{R} : \exists w \in V : \forall x \in X : \xi(x) = \xi_w(x) = \langle w, \phi(x) \rangle_{\mathbb{R}^{d+N}} \}.$$

dotado del producto escalar dado por $\langle \xi_{w_1}, \xi_{w_2} \rangle_{\mathcal{H}_\phi} := \langle w_1, w_2 \rangle_{\mathbb{R}^{d+N}}$.

Entonces K^f es un núcleo de Mercer y $\mathcal{H}_{K^f} = \mathcal{H}_\phi$ es su RKHS.

Demostración:

(1) K^f es de Mercer. La simetría es inmediata y la continuidad se hereda de la de f . Para

la semidefinición positiva, dados $x_1, \dots, x_n \in X$ y $c_1, \dots, c_n \in \mathbb{R}$:

$$\sum_{i,j=1}^n c_i c_j K^f(x_i, x_j) = \sum_{i,j=1}^n c_i c_j \langle \phi(x_i), \phi(x_j) \rangle_{\mathbb{R}^{d+N}} = \left\| \sum_{i=1}^n c_i \phi(x_i) \right\|_{\mathbb{R}^{d+N}}^2 \geq 0.$$

(2) $\mathcal{H}_\phi$ es un espacio de Hilbert. Ver que $\mathcal{H}_\phi$ es un espacio vectorial se deja como ejercicio.

El producto escalar está bien definido: si $\xi_{w_1} = \xi_{w_2}$, entonces $\langle w_1 - w_2, \phi(x) \rangle = 0$ para todo $x \in X$, de modo que $w_1 - w_2 \perp V$; pero $w_1 - w_2 \in V$, luego $w_1 = w_2$.

Sea $L: V \rightarrow \mathcal{H}_\phi$ la aplicación $Lw := \xi_w$. Por definición, L es sobreyectiva, y la inyectividad acaba de verificarse. Además, L es una isometría:

$$\|Lw\|_{\mathcal{H}_\phi}^2 = \langle \xi_w, \xi_w \rangle_{\mathcal{H}_\phi} = \langle w, w \rangle_{\mathbb{R}^{d+N}} = \|w\|_{\mathbb{R}^{d+N}}^2.$$

Por tanto, $\mathcal{H}_\phi$ es isométrico al espacio euclídeo V : en particular, es de Hilbert.

(3) *Propiedad reproductora.* Para cada $x \in X$, la función $K_x^f := K^f(x, \cdot) = L\phi(x) = \xi_{\phi(x)}$ pertenece a $\mathcal{H}_\phi$, pues $\phi(x) \in V$. Para todo $\xi = \xi_w \in \mathcal{H}_\phi$:

$$\langle \xi, K_x^f \rangle_{\mathcal{H}_\phi} = \langle \xi_w, \xi_{\phi(x)} \rangle_{\mathcal{H}_\phi} = \langle w, \phi(x) \rangle_{\mathbb{R}^{d+N}} = \xi_w(x) = \xi(x).$$

Esto es la propiedad reproductora, lo que establece que $\mathcal{H}_\phi = \mathcal{H}_{K^f}$. ■

La proposición 3.1.16 justifica el siguiente enfoque. Dado un mapa de características $\phi: X \rightarrow \mathbb{R}^{d+N}$, levantamos el dataset a $\bar{\mathcal{D}} = \{(\phi(x_i), y_i)\}_{i=1}^m$ y aplicamos Soft-SVM en el espacio imagen. Incorporando el bias en w mediante la extensión afín (extendiendo ϕ con una coordenada constante), el problema de Soft-SVM en el espacio levantado consiste en minimizar sobre $w \in \mathbb{R}^{d+N}$:

$$\mathcal{L}_\mathcal{D}^\phi(w) := \frac{1}{m} \sum_{i=1}^m \max\{0, 1 - y_i \langle w, \phi(x_i) \rangle_{\mathbb{R}^{d+N}}\} + \lambda \|w\|_{\mathbb{R}^{d+N}}^2.$$

Por la proposición 3.1.16, la correspondencia $w \mapsto \xi_w$ dada por $\xi_w(x) := \langle w, \phi(x) \rangle_{\mathbb{R}^{d+N}}$ es una isometría entre $V := \text{span}\{\phi(x_i)\}_{i=1}^m$ y $\mathcal{H}_{K^f}$. Bajo esta identificación, $\langle w, \phi(x_i) \rangle = \xi_w(x_i)$ y $\|w\|^2 = \|\xi_w\|_{\mathcal{H}_{K^f}}^2$, de modo que minimizar $\mathcal{L}_\mathcal{D}^\phi(w)$ sobre V es equivalente a minimizar

$$\mathcal{L}_\mathcal{D}^K(\xi) := \frac{1}{m} \sum_{i=1}^m \max\{0, 1 - y_i \xi(x_i)\} + \lambda \|\xi\|_{\mathcal{H}_{K^f}}^2 \quad (3.4)$$

sobre $\xi \in \mathcal{H}_{K^f}$. La ventaja clave es que los datos x_i solo aparecen a través de los valores del núcleo $K^f(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle_{\mathbb{R}^{d+N}}$, sin necesidad de calcular ϕ explícitamente.

Este procedimiento se generaliza a cualquier núcleo de Mercer $K : X \times X \rightarrow \mathbb{R}$ por una razón algebraica fundamental: la propiedad reproductora establece que $\xi(x) = \langle \xi, K_x \rangle_{\mathcal{H}_K}$ para todo $\xi \in \mathcal{H}_K$, es decir, evaluar ξ en un punto es exactamente tomar un producto escalar contra el elemento $K_x \in \mathcal{H}_K$. El problema de minimización en $\mathcal{H}_K$ es por tanto estructuralmente idéntico a una clasificación lineal en el espacio $\mathcal{H}_K$, con el mapa de características $x \mapsto K_x$. Basta sustituir $\|\cdot\|_{\mathcal{H}_{K_f}}$ por $\|\cdot\|_{\mathcal{H}_K}$ en (3.4):

$$\mathcal{L}_D^K(\xi) := \frac{1}{m} \sum_{i=1}^m \max\{0, 1 - y_i \xi(x_i)\} + \lambda \|\xi\|_{\mathcal{H}_K}^2, \quad \xi \in \mathcal{H}_K.$$

El minimizador $\xi^* := \arg \min_{\xi \in \mathcal{H}_K} \mathcal{L}_D^K(\xi)$ induce el clasificador $f = \text{sgn} \circ \xi^*$, que asigna a cada punto x_i la clase según el signo de $\xi^*(x_i)$:

$$i \in I_1 \iff \xi^*(x_i) > 0 \quad \wedge \quad i \in I_{-1} \iff \xi^*(x_i) < 0.$$

Observación 3.1.17. Si $\mathcal{H}_K$ es un *RKHS universal*¹, entonces para cualquier dataset finito $\{x_i\}_{i=1}^m \subset X$ es posible separar perfectamente cualquier etiquetación².

Sin embargo, la convexidad de $\mathcal{L}_K$ garantiza un único mínimo global, pero un RKHS universal tiene dimensión infinita, por lo que minimizar directamente sobre todo $\mathcal{H}_K$ es computacionalmente inabordable.

3.1.5.3. Reducción finita mediante el teorema del representante

El obstáculo anterior lo resuelve directamente el Teorema del representante: el funcional $\mathcal{L}_K$ tiene la forma $R_g[f] = E(\{(x_i, y_i, f(x_i))\}) + g(\|f\|_{\mathcal{H}_K})$ con pérdida hinge y $g(t) = \lambda t^2$, que es estrictamente creciente para $\lambda > 0$. Por tanto, cualquier minimizador de $\mathcal{L}_K$ en $\mathcal{H}_K$ pertenece al subespacio de dimensión finita $V_D := \text{span}\{K_{x_i}\}_{i=1}^m$, y el problema de dimensión infinita se reduce a uno de dimensión m . Todo $g \in V_D$ se escribe como $g = \sum_{j=1}^m \alpha_j K_{x_j}$, y la propiedad reproductora da

$$g(x_i) = \sum_{j=1}^m \alpha_j \langle K_{x_j}, K_{x_i} \rangle_{\mathcal{H}_K} = \sum_{j=1}^m \alpha_j K(x_i, x_j) = (M_K \alpha)_i,$$

donde $M_K \in \mathbb{R}^{m \times m}$ es la *matriz de Gram* con $(M_K)_{ij} := K(x_i, x_j)$. Del mismo modo,

$$\|g\|_{\mathcal{H}_K}^2 = \left\langle \sum_i \alpha_i K_{x_i}, \sum_j \alpha_j K_{x_j} \right\rangle_{\mathcal{H}_K} = \sum_{i,j=1}^m \alpha_i \alpha_j K(x_i, x_j) = \langle \alpha, M_K \alpha \rangle.$$

¹Un ejemplo es el RKHS de la función de base radial (RBF), véase *Steinwart, Christmann, Corollary 4.58*.

²Esto no quiere decir que el resultado generalice bien, véase el teorema 3.2.4.

Sustituyendo en (3.4), el problema de *Soft Kernel SVM* se reduce a minimizar sobre $\alpha \in \mathbb{R}^m$:

$$\mathcal{L}(\alpha) := \frac{1}{m} \sum_{i=1}^m \max\{0, 1 - y_i (M_K \alpha)_i\} + \lambda \langle \alpha, M_K \alpha \rangle. \quad (3.5)$$

El clasificador resultante es $f: X \rightarrow \{-1, 1\}$ dado por

$$f(x) = \operatorname{sgn} \left(\sum_{j=1}^m \alpha_j^* K(x_j, x) \right), \quad \text{donde } \alpha^* = \arg \min_{\alpha \in \mathbb{R}^m} \mathcal{L}(\alpha).$$

Un RKHS $\mathcal{H}_K$ sobre un espacio métrico compacto X se dice **universal** si es denso en $\mathcal{C}(X)$ con la norma $\|\cdot\|_\infty$. La densidad garantiza que $\mathcal{H}_K$ puede aproximar uniformemente cualquier función continua y, en particular, que puede separar clases con fronteras de forma arbitrariamente compleja. El siguiente resultado cuantifica esta propiedad de separación para cualquier subconjunto denso de $\mathcal{C}(X)$.

Proposición 3.1.18 (Steinwart, Christmann, Prop. 4.54). *Sea X un espacio métrico compacto y sea $V \subset \mathcal{C}(X)$ denso en la norma $\|\cdot\|_\infty$. Entonces, para todo par de compactos disjuntos $A, B \subset X$, existe $f \in V$ tal que*

$$\forall x \in A : f(x) > 0 \quad \wedge \quad \forall x \in B : f(x) < 0.$$

Demostración: Como A y B son compactos disjuntos, el denominador $\operatorname{dist}(x, A) + \operatorname{dist}(x, B)$ es estrictamente positivo para todo $x \in X$. La función

$$g(x) := \frac{\operatorname{dist}(x, B) - \operatorname{dist}(x, A)}{\operatorname{dist}(x, A) + \operatorname{dist}(x, B)}$$

pertenece a $\mathcal{C}(X)$, y satisface $g|_A \equiv 1$ (pues $\operatorname{dist}(x, A) = 0$ para $x \in A$) y $g|_B \equiv -1$.

Como V es denso en $(\mathcal{C}(X), \|\cdot\|_\infty)$, existe $f \in V$ con $\|f - g\|_\infty < \frac{1}{2}$. Por la desigualdad triangular inversa, para todo $x \in A$:

$$f(x) \geq g(x) - |f(x) - g(x)| > 1 - \frac{1}{2} = \frac{1}{2} > 0,$$

y análogamente para todo $x \in B$:

$$f(x) \leq g(x) + |f(x) - g(x)| < -1 + \frac{1}{2} = -\frac{1}{2} < 0. \quad \blacksquare$$

Este recorrido muestra el hilo completo de la sección: de la separabilidad lineal en $\mathbb{R}^d$ a la separación en espacios de características, manteniendo en cada paso una formulación de optimización convexa tratable.

3.2. Teorema de No Free Lunch (NFL)

3.2.1. Motivación y marco probabilístico

3.2.1.1. Sobreajuste y error de generalización

En muchos casos, al resolver un problema de clasificación, podemos sufrir de *overfitting* (sobreajuste): el clasificador que obtenemos a partir de $\mathcal{D}$ es muy bueno para clasificar los datos de $\mathcal{D}$, pero no generaliza bien a nuevos datos.

El overfitting puede ocurrir por varios motivos, como muestran los siguientes ejemplos:

Ejemplos 3.2.1 (de *overfitting*).

- [1] Consideramos un dataset de entreno que contenga imágenes de perros e imágenes de gatos. Un algoritmo de clasificación entrenado en dicho dataset no sería capaz de generalizar a, por ejemplo, imágenes de coches, porque solo ha aprendido a distinguir entre perros y gatos.
- [2] El overfitting también puede ocurrir cuando la **dimensionalidad** del dataset de entreno es mucho menor a la dimensionalidad del espacio. Por ejemplo, si tenemos un dataset de entreno con solo 10 puntos en un espacio de 100 dimensiones, es posible que el clasificador aprenda a clasificar perfectamente esos 10 puntos, pero no generalice bien a nuevos datos debido a la falta de información suficiente para aprender patrones significativos.

3.2.1.2. Regla de Bayes como referencia óptima

Por la definición 3.1.1, el error de generalización de un clasificador $g: X \rightarrow Y$ es

$$\mathcal{E}[g] = \int_X \mathbb{P}(\{y \neq g(x)\} \mid x) d\rho_X(x).$$

En lo que sigue trabajamos con $Y = \{0, 1\}$ en lugar de $\{-1, 1\}$. Si, en lugar de $Y = \{-1, 1\}$, tenemos $Y = \{0, 1\}$, entonces la función de regresión es

$$f_\rho(x) = \sum_{y \in Y} y \cdot \rho(y \mid x) = \mathbb{P}(\{y = 1\} \mid x).$$

y el clasificador óptimo, llamado **regla de Bayes**, es

$$g^*(x) = \begin{cases} 1, & \text{si } f_\rho(x) \geq \frac{1}{2} \\ 0, & \text{si } f_\rho(x) < \frac{1}{2}. \end{cases}$$

Lema 3.2.2. Sea $g: X \rightarrow Y$ un clasificador binario. Entonces $\mathcal{E}[g^*] \leq \mathcal{E}[g]$.

Demostración: Para cada $i \in \{0, 1\}$, denotamos $C_i^g := \{x \in X : g(x) = i\}$. Como $\{C_0^g, C_1^g\}$ es una partición de X , se tiene que $\forall x \in X : \mathbb{1}_{C_0^g}(x) + \mathbb{1}_{C_1^g}(x) = 1$. Calculamos el error condicional de g en x :

$$\begin{aligned} \mathbb{P}(\{y \neq g(x)\} \mid x) &= 1 - \mathbb{P}(\{y = g(x)\} \mid x) \cdot (\mathbb{1}_{C_0^g}(x) + \mathbb{1}_{C_1^g}(x)) \\ &= 1 - \mathbb{P}(\{y = 0\} \mid x) \mathbb{1}_{C_0^g}(x) - \mathbb{P}(\{y = 1\} \mid x) \mathbb{1}_{C_1^g}(x) \\ &= 1 - (1 - f_\rho(x)) \mathbb{1}_{C_0^g}(x) - f_\rho(x) \mathbb{1}_{C_1^g}(x). \end{aligned}$$

Sustituyendo $\mathbb{1}_{C_0^g} = 1 - \mathbb{1}_{C_1^g}$ y simplificando:

$$\mathbb{P}(\{y \neq g(x)\} \mid x) = 1 - (2f_\rho(x) - 1) \mathbb{1}_{C_1^g}(x).$$

La misma expresión es válida para g^* , por lo que la diferencia de errores condicionales es

$$\mathbb{P}(\{y \neq g(x)\} \mid x) - \mathbb{P}(\{y \neq g^*(x)\} \mid x) = 2(f_\rho(x) - \tfrac{1}{2}) \left(\mathbb{1}_{C_1^{g^*}}(x) - \mathbb{1}_{C_1^g}(x) \right).$$

Esta expresión es no negativa para todo $x \in X$: por definición de g^* ,

- si $f_\rho(x) \geq \frac{1}{2}$, entonces $g^*(x) = 1$, luego $\mathbb{1}_{C_1^{g^*}}(x) = 1 \geq \mathbb{1}_{C_1^g}(x)$ y $2(f_\rho(x) - \frac{1}{2}) \geq 0$;
- si $f_\rho(x) < \frac{1}{2}$, entonces $g^*(x) = 0$, luego $\mathbb{1}_{C_1^{g^*}}(x) = 0 \leq \mathbb{1}_{C_1^g}(x)$ y $2(f_\rho(x) - \frac{1}{2}) < 0$.

En ambos casos, el producto de los dos factores es ≥ 0 . Integrando respecto a ρ_X :

$$\mathcal{E}[g] - \mathcal{E}[g^*] = 2 \int_X (f_\rho(x) - \tfrac{1}{2}) \left(\mathbb{1}_{C_1^{g^*}}(x) - \mathbb{1}_{C_1^g}(x) \right) d\rho_X(x) \geq 0. \quad \blacksquare$$

3.2.1.3. Algoritmo de aprendizaje y enunciado NFL

Con la referencia de Bayes fijada, podemos formular con precisión qué objeto queremos acotar: no una hipótesis concreta, sino el rendimiento esperado del clasificador devuelto por un algoritmo de aprendizaje cuando el problema subyacente es adverso.

Definición 3.2.3. Un **algoritmo de aprendizaje** es una función $A: (X \times Y)^m \rightarrow \mathcal{H}$ que, dado un dataset de entrenamiento $\mathcal{D} \in (X \times Y)^m$, devuelve un clasificador $A[\mathcal{D}]: X \rightarrow Y$.

Hay varios teoremas “No Free Lunch”, que apuntan a decir que no existe un algoritmo bueno para todas las tareas. Aquí demostraremos el siguiente resultado de Devroye de 1982.

Teorema 3.2.4. Sea X un conjunto infinito y sea A un algoritmo de aprendizaje. Entonces, para todo $m \in \mathbb{N}$ y para todo $\varepsilon > 0$, existe una distribución ρ sobre $X \times \{0, 1\}$ tal que

- (1) $\mathcal{E}[g^*] = 0$ (La regla de Bayes clasifica perfectamente).
- (2) $\mathbb{E}[\mathcal{E}[A[\mathcal{D}]]] \geq \frac{1}{2} - \varepsilon$ (El error esperado del clasificador devuelto por el algoritmo es arbitrariamente cercano a $1/2$, es decir, tan malo como un clasificador aleatorio).

3.2.2. Demostración del resultado de Devroye

3.2.2.1. Estrategia de la prueba

La idea central es promediar el error del algoritmo sobre todas las etiquetaciones posibles de un conjunto finito de puntos. Si el entrenamiento observa solo una parte de esos puntos, en los no observados el algoritmo no puede hacerlo mejor que adivinar al azar.

Demostración: Como X es infinito, podemos fijar un subconjunto $C = \{c_1, \dots, c_k\} \subset X$ con $k > m$ puntos distintos. Sea $R_k := \{r: C \rightarrow \{0, 1\}\} \cong \{0, 1\}^k$ el conjunto de todas las etiquetaciones posibles de C .

Paso 1: Construcción de las distribuciones. Para cada $r \in R_k$, definimos la distribución ρ_r sobre $C \times \{0, 1\}$ como la uniforme sobre los k pares etiquetados de forma determinista por r :

$$\forall i \in \{1, \dots, k\} : \rho_r(\{(c_i, r(c_i))\}) = \frac{1}{k}.$$

Dado que la etiqueta queda determinada por r (no hay aleatoriedad en y dado x), la función de regresión satisface $f_{\rho_r}(c_i) = r(c_i) \in \{0, 1\}$. Por tanto, la regla de Bayes $g^*(c_i) = r(c_i)$ clasifica perfectamente y $\mathcal{E}_{\rho_r}[g^*] = 0$, verificando la condición (1) del enunciado.

Paso 2: Error esperado del algoritmo para r fijo. Fijado $r \in R_k$, sea

$$S(r) := \mathbb{E}_{\mathcal{D} \sim \rho_r^m} [\mathcal{E}_{\rho_r}[A[\mathcal{D}]]]$$

el error esperado del clasificador que devuelve A al entrenarse con m muestras de ρ_r . Puesto que ρ_r está soportada en m pares $\{(c_i, r(c_i))\}$, un dataset $\mathcal{D} \sim \rho_r^m$ equivale a elegir uniformemente una secuencia $(i_1, \dots, i_m) \in \{1, \dots, k\}^m$, produciendo el dataset

$$\mathcal{D}_r^{(j)} := \{(c_{i_\ell}, r(c_{i_\ell}))\}_{\ell=1}^m, \quad j = (i_1, \dots, i_m) \in \{1, \dots, k\}^m.$$

Desarrollando la esperanza como suma uniforme sobre los k^m datasets posibles, y expandiendo el error de generalización:

$$S(r) = \frac{1}{k^m} \sum_{j=1}^{k^m} \mathcal{E}_{\rho_r}[A[\mathcal{D}_r^{(j)}]] = \frac{1}{k^m} \sum_{j=1}^{k^m} \frac{1}{k} \sum_{i=1}^k \mathbb{1}_{\{A[\mathcal{D}_r^{(j)}](c_i) \neq r(c_i)\}}.$$

Paso 3: Puntos no vistos en el entrenamiento. Para cada dataset $\mathcal{D}_r^{(j)}$, definimos el conjunto de índices *no vistos* en ese dataset:

$$M^{(j)} := \{i \in \{1, \dots, k\} : c_i \notin \{x : (x, y) \in \mathcal{D}_r^{(j)}\}\}.$$

Como $\mathcal{D}_r^{(j)}$ contiene a lo sumo m valores distintos de C y $k > m$, se tiene $|M^{(j)}| \geq k - m > 0$. En particular, restringiendo la suma interior a los índices no vistos:

$$S(r) \geq \frac{1}{k^m} \sum_{j=1}^{k^m} \frac{1}{k} \sum_{i \in M^{(j)}} \mathbb{1}_{\{A[\mathcal{D}_r^{(j)}](c_i) \neq r(c_i)\}}.$$

Paso 4: Promedio sobre todas las etiquetaciones. Como $\max_r S(r) \geq \mathbb{E}_{r \sim \text{unif}(R_k)}[S(r)]$, basta acotar inferiormente la media de $S(r)$. Intercambiando el orden de las sumas y la esperanza:

$$\mathbb{E}_r[S(r)] \geq \frac{1}{k^m} \sum_{j=1}^{k^m} \frac{1}{k} \sum_{i \in M^{(j)}} \mathbb{E}_r \left[\mathbb{1}_{\{A[\mathcal{D}_r^{(j)}](c_i) \neq r(c_i)\}} \right].$$

La clave está en evaluar $\mathbb{E}_r[\mathbb{1}_{\{A[\mathcal{D}_r^{(j)}](c_i) \neq r(c_i)\}}]$ para $i \in M^{(j)}$: como $c_i \notin \mathcal{D}_r^{(j)}$, el dataset $\mathcal{D}_r^{(j)}$ no depende de $r(c_i)$, luego tampoco lo hace $A[\mathcal{D}_r^{(j)}](c_i)$. Siendo $r(c_i)$ uniforme en $\{0, 1\}$ independientemente de $A[\mathcal{D}_r^{(j)}](c_i) \in \{0, 1\}$, la probabilidad de desacuerdo es $\frac{1}{2}$:

$$\forall i \in M^{(j)} : \mathbb{E}_r \left[\mathbb{1}_{\{A[\mathcal{D}_r^{(j)}](c_i) \neq r(c_i)\}} \right] = \frac{1}{2}.$$

Paso 5: Conclusión. Sustituyendo y usando $|M^{(j)}| \geq k - m$:

$$\mathbb{E}_r[S(r)] \geq \frac{1}{k^m} \sum_{j=1}^{k^m} \frac{1}{k} \cdot |M^{(j)}| \cdot \frac{1}{2} \geq \frac{1}{k^m} \sum_{j=1}^{k^m} \frac{k - m}{2k} = \frac{k - m}{2k} = \frac{1}{2} \left(1 - \frac{m}{k}\right).$$

Por tanto, $\max_{r \in R_k} S(r) \geq \frac{1}{2} \left(1 - \frac{m}{k}\right)$. Dado $\varepsilon > 0$, basta elegir $k > \frac{m}{2\varepsilon}$ para obtener

$$\max_{r \in R_k} S(r) \geq \frac{1}{2} \left(1 - \frac{m}{k}\right) > \frac{1}{2} - \varepsilon.$$

La distribución ρ_r correspondiente al maximizador r satisface simultáneamente las condiciones (1) y (2) del enunciado. ■

Observación 3.2.5. Este resultado, como todos los NFLT, se basa en la posibilidad de que el dataset disponible para el aprendizaje no sea representativo de ρ .

3.3. Descenso del gradiente

3.3.1. Descenso del gradiente clásico

3.3.1.1. Idea geométrica y regla de actualización

Sea $F: \mathbb{R}^p \rightarrow \mathbb{R}$ una función suave. El objetivo es encontrar un mínimo local de F , es decir, un punto $x^* \in \mathbb{R}^p$ tal que $F(x^*) \leq F(x)$ para todo x en una vecindad de x^* . En particular, si F es convexa, entonces cualquier mínimo local es también un mínimo global.

El descenso del gradiente es un método iterativo para aproximar un mínimo local de F . Dado un punto inicial $x_0 \in \mathbb{R}^p$, se genera una secuencia de puntos $\{x_k\}_{k=0}^\infty$ mediante la regla de actualización

$$\forall k \in \mathbb{N} : x_{k+1} = x_k - \eta \nabla F(x_k),$$

donde $\eta > 0$ es el tamaño del paso o tasa de aprendizaje. La idea es moverse en la dirección opuesta al gradiente de F en el punto actual, ya que este apunta en la dirección de máximo aumento de F .

Prestando atención al desarrollo de Taylor de F alrededor de x_{k+1} , se tiene

$$F(x_k - \eta \nabla F(x_k)) = F(x_k) - \eta \|\nabla F(x_k)\|^2 + \frac{\eta^2}{2} \langle \nabla F(x_k), \text{Hess } F(x_k) \nabla F(x_k) \rangle + \dots$$

donde $\text{Hess } F(x_k)$ es la matriz hessiana de F en x_k . Entonces, si

$$\Lambda := \max \{ \lambda \text{ autovalor de } \text{Hess } F(x) : x \in \mathbb{R}^p \} < \infty,$$

se tiene que $F(x_{k+1}) \approx F(x_k) - \eta \left(1 - \Lambda \frac{\eta}{2}\right) \|\nabla F(x_k)\|^2$ para $\eta < 2/\Lambda$, luego

$$|F(x_{k+1}) - F(x^*)| \leq |F(x_k) - F(x^*)| - \eta \left(1 - \Lambda \frac{\eta}{2}\right) \|\nabla F(x_k)\|^2$$

donde x_* es un mínimo local de F . Esto muestra que $F(x_k)$ converge a $F(x^*)$ y que $\nabla F(x_k) \rightarrow 0$ a medida que $k \rightarrow \infty$. Sin embargo, no nos dice a qué velocidad ocurre esto, ni nos garantiza que x_k converja a un mínimo global.

El cálculo anterior debe leerse como una heurística local: sugiere por qué el algoritmo desciende cuando el paso es suficientemente pequeño, pero no basta para obtener una garantía global. Para ello necesitamos hipótesis estructurales sobre F (convexidad y suavidad) y una cadena de lemas que conecte esas hipótesis con una cota explícita de convergencia.

3.3.1.2. Hipótesis analíticas: convexidad y suavidad

Introducimos ahora las nociones que controlan la geometría de la función objetivo. La convexidad evita mínimos espurios y la suavidad controla cuánto puede variar el gradiente entre dos puntos.

Definición 3.3.1 (Convexidad (fuerte)). Sea $X \subset \mathbb{R}^n$ convexo y sea $F: X \rightarrow \mathbb{R}$.

- (1) Decimos que F es **convexa** si

$$\forall x, y \in X, \forall t \in [0, 1] : F(tx + (1-t)y) \leq tF(x) + (1-t)F(y).$$

- (2) Dado $\lambda > 0$, decimos que F es **λ -fuertemente convexa** si la función

$$x \mapsto F(x) - \frac{\lambda}{2} \|x\|^2$$

es convexa en X . Equivalentemente,

$$\forall x, y \in X, \forall t \in [0, 1] : F(tx + (1-t)y) \leq tF(x) + (1-t)F(y) - \frac{\lambda}{2} t(1-t) \|x - y\|^2.$$

Observación 3.3.2. La interpretación geométrica de la convexidad es que la recta secante entre dos puntos del gráfico queda por encima de la función.

Además, toda función afín $x \mapsto ax + b$ es convexa, pero no es λ -fuertemente convexa para ningún $\lambda > 0$.

Definición 3.3.3 (Suavidad). Sea $\Omega \subset \mathbb{R}^p$ abierto y sea $F: \Omega \rightarrow \mathbb{R}$.

- (1) Si F es diferenciable y $\Lambda > 0$, diremos que F es **Λ -suave** en Ω si ∇F es Λ -Lipschitz, es decir,

$$\forall x, y \in \Omega : \|\nabla F(x) - \nabla F(y)\| \leq \Lambda \|x - y\|.$$

- (2) Si $F \in \mathcal{C}^2(\Omega)$ y $M > 0$, escribimos $F \in \mathcal{C}_M^2(\Omega)$ si la hessiana $\nabla^2 F$ es M -Lipschitz:

$$\forall x, y \in \Omega : \|\nabla^2 F(x) - \nabla^2 F(y)\| \leq M \|x - y\|.$$

donde la norma matricial es la inducida por la norma euclídea: $\|A\| = \max_{\|v\|=1} \|Av\|$.

Observación 3.3.4 (Interpretación de la Λ -suavidad). Intuitivamente, una función Λ -suave no puede crecer localmente más rápido que una cuadrática de curvatura Λ . En términos geométricos, esto equivale a que su gradiente no presenta cambios bruscos: ∇F es globalmente Lipschitz con constante Λ .

En particular, para el descenso del gradiente clásico aplicado a F , un paso con tasa $\eta \leq 1/\Lambda$

garantiza descenso de la energía en cada iteración.

3.3.1.3. Lemas preparatorios

Los siguientes resultados fijan las herramientas que se usan en la prueba principal: existencia y unicidad del minimizador, caracterizaciones de convexidad por primer y segundo orden, y una cota cuadrática superior derivada de la suavidad.

Lema 3.3.5. *Sea $F: \mathbb{R}^d \rightarrow \mathbb{R}$ una función λ -fuertemente convexa con $\lambda > 0$. Entonces existe un único punto $x^* \in \mathbb{R}^d$ tal que $F(x^*) = \min_{x \in \mathbb{R}^d} F(x)$.*

Demostración: *Existencia.* La función $G := F - \frac{\lambda}{2} \|\cdot\|^2$ es convexa y finita en $\mathbb{R}^d$, luego admite un minorante afín: existen $v \in \mathbb{R}^d$ y $c \in \mathbb{R}$ tales que $G(x) \geq \langle v, x \rangle + c$ para todo $x \in \mathbb{R}^d$. Por tanto,

$$F(x) = G(x) + \frac{\lambda}{2} \|x\|^2 \geq \langle v, x \rangle + c + \frac{\lambda}{2} \|x\|^2 \xrightarrow{\|x\| \rightarrow \infty} +\infty,$$

así que F es coerciva. Como F es también continua (toda función convexa finita en $\mathbb{R}^d$ es continua), su ínfimo se alcanza.

Unicidad. Sean $x^*, y^* \in \mathbb{R}^d$ dos minimizadores globales, de modo que $F(x) \geq F(x^*) = F(y^*)$ para todo $x \in \mathbb{R}^d$. Por ser F λ -fuertemente convexa, tomando $t = \frac{1}{2}$,

$$F\left(\frac{x^* + y^*}{2}\right) \leq \frac{F(x^*) + F(y^*)}{2} - \frac{\lambda}{8} \|x^* - y^*\|^2 = F(x^*) - \frac{\lambda}{8} \|x^* - y^*\|^2.$$

Si $x^* \neq y^*$, se tiene $F\left(\frac{x^* + y^*}{2}\right) < F(x^*)$, lo que contradice la minimalidad de x^* . Luego $x^* = y^*$. ■

Lema 3.3.6. *Sea $X \subset \mathbb{R}^d$ convexo y sea $F \in \mathcal{C}^1(X)$.*

(1) *F es convexa si y solo si $\forall x, y \in X : F(x) \geq F(y) + \langle \nabla F(y), x - y \rangle$.*

(2) *Dado $\lambda > 0$, F es λ -fuertemente convexa si y solo si*

$$\forall x, y \in X : F(x) \geq F(y) + \langle \nabla F(y), x - y \rangle + \frac{\lambda}{2} \|x - y\|^2.$$

(3) *Si F es λ -fuertemente convexa, $\lambda > 0$, y x^* es su minimizador global, entonces*

$$\forall x \in X : \|\nabla F(x)\|^2 \geq 2\lambda (F(x) - F(x^*)).$$

Demostración:

- (1) $\Rightarrow$ Si F es convexa, entonces para todo $t \in (0, 1]$ y todo $x, y \in X$:

$$F(y + t(x - y)) \leq (1 - t)F(y) + tF(x) \implies \frac{F(y + t(x - y)) - F(y)}{t} \leq F(x) - F(y).$$

Tomando $t \rightarrow 0^+$, el cociente del lado izquierdo converge a $\langle \nabla F(y), x - y \rangle$ por definición de diferencial, luego $F(x) \geq F(y) + \langle \nabla F(y), x - y \rangle$.

$\Leftarrow$ Supongamos que $\forall x, y \in X : F(x) \geq F(y) + \langle \nabla F(y), x - y \rangle$. Fijados $x, y \in X$ y $t \in [0, 1]$, sea $z_t := tx + (1 - t)y \in X$. Aplicando la hipótesis con (x, z_t) y (y, z_t) :

$$F(x) \geq F(z_t) + \langle \nabla F(z_t), x - z_t \rangle, \quad F(y) \geq F(z_t) + \langle \nabla F(z_t), y - z_t \rangle.$$

Multiplicando por t y $1 - t$ respectivamente y sumando:

$$tF(x) + (1 - t)F(y) \geq F(z_t) + \langle \nabla F(z_t), tx + (1 - t)y - z_t \rangle = F(z_t).$$

- (2) Sea $F_\lambda := F - \frac{\lambda}{2} \|\cdot\|^2$. Por el apartado anterior, F_λ es convexa si y solo si $\forall x, y \in X : F_\lambda(x) \geq F_\lambda(y) + \langle \nabla F_\lambda(y), x - y \rangle$. Como $\nabla F_\lambda(y) = \nabla F(y) - \lambda y$, esta condición es

$$F(x) - \frac{\lambda}{2} \|x\|^2 \geq F(y) - \frac{\lambda}{2} \|y\|^2 + \langle \nabla F(y) - \lambda y, x - y \rangle.$$

Por la identidad $-\frac{\lambda}{2} \|x\|^2 + \frac{\lambda}{2} \|y\|^2 + \lambda \langle y, x - y \rangle = -\frac{\lambda}{2} \|x - y\|^2$, esto es equivalente a

$$F(x) \geq F(y) + \langle \nabla F(y), x - y \rangle + \frac{\lambda}{2} \|x - y\|^2.$$

- (3) Fijado $y \in X$, aplicamos la desigualdad del apartado anterior con $x = x^*$:

$$F(x^*) \geq F(y) + \langle \nabla F(y), x^* - y \rangle + \frac{\lambda}{2} \|x^* - y\|^2.$$

Definamos $h(z) := \frac{\lambda}{2} \|z - y\|^2 + \langle \nabla F(y), z - y \rangle$. Este cuadrado completado alcanza su mínimo global en $z^* = y - \frac{1}{\lambda} \nabla F(y)$, con valor $-\frac{1}{2\lambda} \|\nabla F(y)\|^2$. Puesto que $h(x^*) \geq \min_{z \in \mathbb{R}^d} h(z)$, se tiene

$$F(x^*) \geq F(y) - \frac{1}{2\lambda} \|\nabla F(y)\|^2,$$

lo que reordenado da $\|\nabla F(y)\|^2 \geq 2\lambda(F(y) - F(x^*))$. ■

Lema 3.3.7. Sea $X \subset \mathbb{R}^d$ convexo y sea $F \in \mathcal{C}^2(X)$.

- (1) F es convexa si y solo si $\forall x \in X : \text{Hess } F(x) \succeq 0$.
- (2) Dado $\lambda > 0$, F es λ -fuertemente convexa si y solo si $\forall x \in X : \text{Hess } F(x) \succeq \lambda I$, o equivalentemente, todo autovalor de $\text{Hess } F(x)$ es mayor o igual que λ .

Demostración:

- (1) $\Rightarrow$ Supongamos F convexa. Fijemos $x \in X$ y $v \in \mathbb{R}^d$ tales que el segmento $x + tv$ permanezca en X para t en un entorno de 0. Definimos $\varphi(t) := F(x + tv)$.

Como F es convexa, φ es convexa en su dominio; y como $F \in \mathcal{C}^2$, se tiene $\varphi \in \mathcal{C}^2$. Por tanto, $\varphi''(0) \geq 0$. Pero $\varphi''(0) = \langle v, \text{Hess } F(x) v \rangle$, luego $\langle v, \text{Hess } F(x) v \rangle \geq 0$ para todo v , es decir, $\text{Hess } F(x) \succeq 0$.

$\Leftarrow$ Supongamos ahora que $\forall x \in X : \text{Hess } F(x) \succeq 0$. Dados $x, y \in X$, consideramos

$$\psi(t) := F(y + t(x - y)), \quad t \in [0, 1].$$

Entonces $\psi''(t) = \langle x - y, \text{Hess } F(y + t(x - y))(x - y) \rangle \geq 0$, así que ψ es convexa en $[0, 1]$. Evaluando en $t \in [0, 1]$ se obtiene

$$F((1 - t)y + tx) = \psi(t) \leq (1 - t)\psi(0) + t\psi(1) = (1 - t)F(y) + tF(x),$$

que es precisamente la convexidad de F .

- (2) Sea $F_\lambda(x) := F(x) - \frac{\lambda}{2} \|x\|^2$. Por definición, F es λ -fuertemente convexa si y solo si F_λ es convexa. Por el punto (1), esto es equivalente a $\forall x \in X : \text{Hess } F_\lambda(x) \succeq 0$. Como $\text{Hess } F_\lambda(x) = \text{Hess } F(x) - \lambda I$, se concluye que

$$F \text{ es } \lambda\text{-fuertemente convexa} \iff \forall x \in X : \text{Hess } F(x) \succeq \lambda I.$$

La equivalencia con la condición espectral es inmediata porque $\text{Hess } F(x)$ es simétrica: $\text{Hess } F(x) \succeq \lambda I$ si y solo si todos sus autovalores son mayores o iguales que λ . ■

Lema 3.3.8. Sea $F \in \mathcal{C}^1(\mathbb{R}^d)$ una función Λ -suave. Entonces

$$\forall x, y \in \mathbb{R}^d : F(x) \leq F(y) + \langle \nabla F(y), x - y \rangle + \frac{\Lambda}{2} \|x - y\|^2.$$

Demostración: Fijados $x, y \in \mathbb{R}^d$, definimos $r : [0, 1] \rightarrow \mathbb{R}^d$ por $r(t) := y + t(x - y)$. Por el teorema fundamental del cálculo y la regla de la cadena,

$$F(x) - F(y) = F(r(1)) - F(r(0)) = \int_0^1 \frac{d}{dt} F(r(t)) dt = \int_0^1 \langle \nabla F(r(t)), x - y \rangle dt.$$

Sumando y restando $\nabla F(y)$ dentro del integrando,

$$\begin{aligned} F(x) - F(y) &= \int_0^1 \langle \nabla F(r(t)) - \nabla F(y), x - y \rangle dt + \langle \nabla F(y), x - y \rangle \\ &\leq \int_0^1 \|\nabla F(r(t)) - \nabla F(y)\| \|x - y\| dt + \langle \nabla F(y), x - y \rangle. \end{aligned}$$

Como F es Λ -suave, ∇F es Λ -Lipschitz, y por tanto

$$\|\nabla F(r(t)) - \nabla F(y)\| \leq \Lambda \|r(t) - y\| = \Lambda t \|x - y\|.$$

Sustituyendo en la desigualdad anterior,

$$\begin{aligned} F(x) - F(y) &\leq \Lambda \|x - y\|^2 \int_0^1 t \, dt + \langle \nabla F(y), x - y \rangle \\ &= \frac{\Lambda}{2} \|x - y\|^2 + \langle \nabla F(y), x - y \rangle. \end{aligned}$$

■

Lema 3.3.9. Sea $F \in \mathcal{C}^2(\mathbb{R}^d)$ una función Λ -suave, con $\Lambda > 0$. Entonces

$$\forall x \in \mathbb{R}^d : \lambda_{\max}(\text{Hess } F(x)) \leq \Lambda,$$

es decir, todo autovalor de $\text{Hess } F(x)$ es menor o igual que Λ .

Demostración: Fijado $x \in \mathbb{R}^d$, sea $v \in \mathbb{R}^d$ con $\|v\| = 1$ y definamos

$$\phi(t) := \langle \nabla F(x + tv) - \nabla F(x), v \rangle, \quad t \in \mathbb{R}.$$

Como F es Λ -suave, ∇F es Λ -Lipschitz, luego

$$|\phi(t)| \leq \|\nabla F(x + tv) - \nabla F(x)\| \|v\| \leq \Lambda \|tv\| \|v\| = \Lambda |t|.$$

Dividiendo por $|t|$ (para $t \neq 0$) y pasando al límite cuando $t \rightarrow 0$, obtenemos

$$|\langle \text{Hess } F(x)v, v \rangle| \leq \Lambda.$$

Como $\text{Hess } F(x)$ es simétrica, por el cociente de Rayleigh

$$\lambda_{\max}(\text{Hess } F(x)) = \max_{\|v\|=1} \langle \text{Hess } F(x)v, v \rangle \leq \max_{\|v\|=1} |\langle \text{Hess } F(x)v, v \rangle| \leq \Lambda.$$

Dado que x era arbitrario, se concluye

$$\forall x \in \mathbb{R}^d : \lambda_{\max}(\text{Hess } F(x)) \leq \Lambda.$$

■

3.3.1.4. Convergencia lineal con paso fijo

Con los lemas anteriores, ya podemos demostrar una tasa explícita para descenso del gradiente con paso constante. El siguiente teorema establece contracción geométrica del error en valor objetivo.

Teorema 3.3.10. Sea $F \in \mathcal{C}^1(\mathbb{R}^d)$ una función Λ -suave y λ -fuertemente convexa, con $\Lambda, \lambda >$

0, y sea $x^* \in \mathbb{R}^d$ su único minimizador. Consideremos la sucesión de descenso del gradiente dada por $\forall k \in \mathbb{N} : x_{k+1} = x_k - \gamma \nabla F(x_k)$, con paso fijo $\gamma \in (0, \frac{2}{\Lambda})$. Entonces

$$\forall k \in \mathbb{N} : F(x_k) - F(x^*) \leq q^k (F(x_0) - F(x^*)), \text{ donde } q := 1 - 2\lambda\gamma \left(1 - \frac{\gamma\Lambda}{2}\right) \in [0, 1).$$

Demostración: Por el lema 3.3.8, para todo $k \in \mathbb{N}$:

$$F(x_{k+1}) = F(x_k - \gamma \nabla F(x_k)) \leq F(x_k) - \gamma \left(1 - \frac{\gamma\Lambda}{2}\right) \|\nabla F(x_k)\|^2.$$

Restando $F(x^*)$ y usando la cota de tipo Polyak-Lojasiewicz del lema 3.3.6,

$$\|\nabla F(x_k)\|^2 \geq 2\lambda (F(x_k) - F(x^*)),$$

se obtiene

$$F(x_{k+1}) - F(x^*) \leq \left(1 - 2\lambda\gamma \left(1 - \frac{\gamma\Lambda}{2}\right)\right) (F(x_k) - F(x^*)) = q (F(x_k) - F(x^*)).$$

Iterando la desigualdad anterior, $\forall k \in \mathbb{N} : F(x_k) - F(x^*) \leq q^k (F(x_0) - F(x^*))$.

Además, como $\gamma \in (0, \frac{2}{\Lambda})$, se tiene $1 - \frac{\gamma\Lambda}{2} > 0$, luego $q < 1$. Por otra parte, al cumplirse $\lambda \leq \Lambda$ para funciones simultáneamente λ -fuertemente convexas y Λ -suaves,

$$2\lambda\gamma \left(1 - \frac{\gamma\Lambda}{2}\right) \leq 2\Lambda\gamma \left(1 - \frac{\gamma\Lambda}{2}\right) \leq 1,$$

luego $q \geq 0$. ■

Observación 3.3.11. La demostración anterior no utiliza de forma explícita toda la convexidad de F , sino la desigualdad de tipo Polyak-Lojasiewicz (véase el punto (3) del lema 3.3.6), que en general es una hipótesis más débil. Para una discusión sistemática de esta condición, véase Karimi, Nutini y Schmidt, *Linear convergence of gradient and proximal gradient methods under the Polyak-Lojasiewicz condition*, ECML PKDD 2016 (LNCS 9851).

Bajo hipótesis más fuertes de regularidad, por ejemplo $F \in \mathcal{C}^2$, λ -fuertemente convexa, Λ -suave y con hessiana Lipschitz, se pueden obtener cotas adicionales para la convergencia en norma de los iterados; véase Nesterov, *Introductory Lectures on Convex Optimization*, Kluwer, 2004, Teorema 1.2.4.

En problemas de gran dimensión, y también para funciones no necesariamente convexas, suele emplearse la variante estocástica del método, conocida como *descenso del gradiente estocástico*.

3.3.2. Descenso del gradiente estocástico

3.3.2.1. Modelo de riesgo empírico y gradiente estocástico

Pasamos ahora al régimen típico de aprendizaje automático, donde el funcional es un promedio de pérdidas por muestra. Esta estructura permite sustituir el gradiente completo por estimadores aleatorios mucho más baratos por iteración.

En muchos casos en el aprendizaje automático, la función F tiene la forma

$$\forall \theta \in \mathbb{R}^p : \mathcal{L}(\theta) = \frac{1}{m} \sum_{i=1}^m \mathcal{L}_i(\theta), \quad \text{donde} \quad \mathcal{L}_i(\theta) := \ell(y_i, f_\theta(x_i), \theta),$$

$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m$ es un conjunto de datos de entrenamiento, $f_\theta: \mathbb{R}^d \rightarrow \mathbb{R}$ es un modelo parametrizado por θ , y $\ell: \mathbb{R} \times \mathbb{R} \times \mathbb{R}^p \rightarrow \mathbb{R}$ es una función de pérdida que mide el error del modelo f_θ en la muestra (x_i, y_i) . Por ejemplo,

$$\ell(y, f_\theta(x), \theta) = \|y - f_\theta(x)\|^2 + \|\theta\|^2.$$

En contraposición con el algoritmo de descenso del gradiente, que requiere calcular el gradiente completo $\nabla \mathcal{L}(\theta) = \frac{1}{m} \sum_{i=1}^m \nabla \mathcal{L}_i(\theta)$ en cada iteración, el descenso del gradiente estocástico (SGD) actualiza los parámetros utilizando un gradiente estimado a partir de una sola muestra o de un mini-lote de muestras. Es decir, en cada iteración se selecciona aleatoriamente un conjunto de índices $\mathcal{B}_k \subseteq \{1, \dots, m\}$ y se actualiza

$$\theta_{k+1} = \theta_k - \eta \frac{1}{|\mathcal{B}_k|} \sum_{i \in \mathcal{B}_k} \nabla \mathcal{L}_i(\theta_k).$$

Si $|\mathcal{B}_k| = 1$, entonces $\theta_{k+1} = \theta_k - \eta \nabla \mathcal{L}_{i_k}(\theta_k)$, donde i_k es un índice seleccionado aleatoriamente.

La propiedad crucial de este método es que la esperanza condicionada del gradiente estimado es igual al gradiente verdadero:

$$\forall k \in \mathbb{N} : \mathbb{E} [\nabla \mathcal{L}_{i_k}(\theta_k) \mid \theta_k] = \sum_{j=1}^m \mathbb{P}(i_k = j) \nabla \mathcal{L}_j(\theta_k) = \frac{1}{m} \sum_{j=1}^m \nabla \mathcal{L}_j(\theta_k) = \nabla \mathcal{L}(\theta_k).$$

Esto significa que, en promedio, el descenso del gradiente estocástico sigue la dirección de descenso del gradiente verdadero, aunque con ruido debido a la variabilidad de las muestras seleccionadas.

3.3.2.2. Cotas de un paso

El análisis de SGD se basa en controlar qué ocurre en una sola iteración y luego sumar dichas desigualdades. Los dos lemas siguientes dan precisamente esas cotas elementales.

Lema 3.3.12. Sea $\mathcal{L}$ Λ -suave y sea $(\theta_k)_{k=0}^\infty$ la sucesión generada por el descenso del gradiente estocástico. Entonces, para todo $k \in \mathbb{N}$,

$$\mathbb{E} \left[\mathcal{L}(\theta_{k+1}) \mid \theta_k \right] \leq \mathcal{L}(\theta_k) - \eta \|\nabla \mathcal{L}(\theta_k)\|^2.$$

Demostración: Dado que $\mathcal{L}$ es Λ -suave, se tiene

$$\begin{aligned} \mathbb{E} \left[\mathcal{L}(\theta_{k+1}) \mid \theta_k \right] &\leq \mathbb{E} \left[\mathcal{L}(\theta_k) + \langle \nabla \mathcal{L}(\theta_k), \theta_{k+1} - \theta_k \rangle + \frac{\Lambda}{2} \|\theta_{k+1} - \theta_k\|^2 \mid \theta_k \right] \\ &= \mathcal{L}(\theta_k) + \langle \nabla \mathcal{L}(\theta_k), -\eta \nabla \mathcal{L}(\theta_k) \rangle + \underbrace{\frac{\Lambda}{2} \eta^2 \mathbb{E} \left[\|\nabla \mathcal{L}_{i_k}(\theta_k)\|^2 \mid \theta_k \right]}_{\geq 0} \\ &\leq \mathcal{L}(\theta_k) - \eta \|\nabla \mathcal{L}(\theta_k)\|^2. \end{aligned}$$

■

Lema 3.3.13. Sea $\mathcal{L} \in \mathcal{C}^1(\mathbb{R}^p)$ convexa y sea $(\theta_k)_{k=0}^\infty$ la sucesión generada por el descenso del gradiente estocástico. Supongamos que $\exists \Sigma > 0 : \forall k \geq 0 : \mathbb{E} \left[\|\nabla \mathcal{L}_{i_k}(\theta_k)\|^2 \mid \theta_k \right] \leq \Sigma$

$$\implies \forall \theta \in \mathbb{R}^p : \mathcal{L}(\theta_k) \leq \mathcal{L}(\theta) + \frac{1}{2\eta} \mathbb{E} \left[\|\theta_k - \theta\|^2 - \|\theta_{k+1} - \theta\|^2 \mid \theta_k \right] + \frac{\eta \Sigma}{2}.$$

Demostración: Por el punto (1) del lema 3.3.6,

$$\begin{aligned} \mathcal{L}(\theta_k) &\leq \mathcal{L}(\theta) - \langle \nabla \mathcal{L}(\theta_k), \theta - \theta_k \rangle = \mathcal{L}(\theta) - \left\langle \mathbb{E} \left[\nabla \mathcal{L}_{i_k}(\theta_k) \mid \theta_k \right], \theta - \theta_k \right\rangle \\ &= \mathcal{L}(\theta) + \frac{1}{\eta} \mathbb{E} \left[-\langle \theta_k - \theta_{k+1}, \theta - \theta_k \rangle \mid \theta_k \right] \end{aligned}$$

Usando la identidad $-\langle a - b, c - a \rangle = \frac{1}{2} (\|a - c\|^2 - \|b - c\|^2 + \|a - b\|^2)$, obtenemos

$$\mathcal{L}(\theta_k) \leq \mathcal{L}(\theta) + \frac{1}{2\eta} \mathbb{E} \left[\|\theta_k - \theta\|^2 - \|\theta_{k+1} - \theta\|^2 + \|\theta_k - \theta_{k+1}\|^2 \mid \theta_k \right].$$

Dado que $\|\theta_k - \theta_{k+1}\|^2 = \eta^2 \|\nabla \mathcal{L}_{i_k}(\theta_k)\|^2$ y, por hipótesis, $\mathbb{E} \left[\|\nabla \mathcal{L}_{i_k}(\theta_k)\|^2 \mid \theta_k \right] \leq \Sigma$,

$$\mathcal{L}(\theta_k) \leq \mathcal{L}(\theta) + \frac{1}{2\eta} \mathbb{E} \left[\|\theta_k - \theta\|^2 - \|\theta_{k+1} - \theta\|^2 \mid \theta_k \right] + \frac{\eta \Sigma}{2}.$$

■

Teorema 3.3.14 (Desigualdad de Jensen). Sea $X \subset \mathbb{R}^d$ convexo y sea $F: X \rightarrow \mathbb{R}$ convexa. Entonces, para todo $m \in \mathbb{N}$, para toda familia $\{x_i\}_{i=1}^m \subset X$ y para todo conjunto de pesos $\{p_i\}_{i=1}^m \subset [0, 1]$ tal que $\sum_{i=1}^m p_i = 1$, se cumple

$$F \left(\sum_{i=1}^m p_i x_i \right) \leq \sum_{i=1}^m p_i F(x_i).$$

Demostración: Procedemos por inducción sobre m . El caso $m = 2$ coincide exactamente con la definición de convexidad.

Supongamos probado el resultado para m puntos y consideremos ahora pesos $q_1, \dots, q_{m+1} \in [0, 1]$ tales que $\sum_{i=1}^{m+1} q_i = 1$. Si $q_{m+1} = 1$, la desigualdad es trivial. Supongamos por tanto que $q_{m+1} < 1$ y definamos

$$p_i := \frac{q_i}{1 - q_{m+1}}, \quad i = 1, \dots, m.$$

Entonces $p_i \in [0, 1]$ y $\sum_{i=1}^m p_i = 1$, de modo que, por hipótesis de inducción,

$$F\left(\sum_{i=1}^m p_i x_i\right) \leq \sum_{i=1}^m p_i F(x_i).$$

Además, $\sum_{i=1}^{m+1} q_i x_i = q_{m+1} x_{m+1} + (1 - q_{m+1}) \sum_{i=1}^m p_i x_i.$

Aplicando convexidad de F a esta combinación convexa y usando la hipótesis de inducción,

$$\begin{aligned} F\left(\sum_{i=1}^{m+1} q_i x_i\right) &= F\left(q_{m+1} x_{m+1} + (1 - q_{m+1}) \sum_{i=1}^m p_i x_i\right) \\ &\leq q_{m+1} F(x_{m+1}) + (1 - q_{m+1}) F\left(\sum_{i=1}^m p_i x_i\right) \\ &\leq q_{m+1} F(x_{m+1}) + (1 - q_{m+1}) \sum_{i=1}^m p_i F(x_i) \\ &= q_{m+1} F(x_{m+1}) + \sum_{i=1}^m q_i F(x_i) = \sum_{i=1}^{m+1} q_i F(x_i). \end{aligned}$$

■

3.3.2.3. Tasa de convergencia en el caso convexo

Combinando la cota de un paso con una suma telescópica y Jensen, obtenemos la tasa sublineal típica de SGD para objetivos convexos: del orden $T^{-1/2}$ en valor esperado para el promedio de iterados.

Teorema 3.3.15. *Sea $\mathcal{L} \in \mathcal{C}^1(\mathbb{R}^p)$ convexa y sea $(\theta_k)_{k=0}^\infty$ la sucesión generada por el descenso del gradiente estocástico. Supongamos que $\forall k \geq 0 : \mathbb{E} [\|\nabla \mathcal{L}_{i_k}(\theta_k)\|^2 \mid \theta_k] \leq \Sigma$ para alguna constante $\Sigma > 0$, entonces*

$$\eta = \frac{1}{\sqrt{\Sigma T}} \text{ para } T > 0 \implies \mathbb{E} \left[\mathcal{L} \left(\frac{1}{T} \sum_{k=0}^{T-1} \theta_k \right) - \mathcal{L}(\theta^*) \right] \leq \frac{\sqrt{\Sigma}}{2\sqrt{T}} (1 + \|\theta_0 - \theta^*\|^2),$$

donde $\theta^* = \arg \min_{\theta \in \mathbb{R}^p} \mathcal{L}(\theta)$.

Demostración: Aplicando el lema 3.3.13 con $\theta = \theta^*$, y tomando esperanza total, se tiene

$$\mathbb{E} \left[\sum_{k=0}^{T-1} \mathcal{L}(\theta_k) \right] \leq T \mathcal{L}(\theta^*) + \frac{1}{2\eta} \mathbb{E} \left[\sum_{k=0}^{T-1} \|\theta_k - \theta^*\|^2 - \|\theta_{k+1} - \theta^*\|^2 \right] + \frac{\eta \Sigma T}{2}.$$

Dado que $\sum_{k=0}^{T-1} \|\theta_k - \theta^*\|^2 - \|\theta_{k+1} - \theta^*\|^2$ es una suma telescópica, se tiene

$$\begin{aligned} \mathbb{E} \left[\sum_{k=0}^{T-1} \mathcal{L}(\theta_k) \right] &\leq T \mathcal{L}(\theta^*) + \frac{1}{2\eta} \mathbb{E} [\|\theta_0 - \theta^*\|^2 - \|\theta_T - \theta^*\|^2] + \frac{\eta \Sigma T}{2} \\ &\leq T \mathcal{L}(\theta^*) + \frac{1}{2\eta} \|\theta_0 - \theta^*\|^2 + \frac{\eta \Sigma T}{2}. \end{aligned}$$

Dividiendo por T y aplicando la teorema 3.3.14 a la combinación convexa con pesos uniformes $1/T$,

$$\mathbb{E} \left[\mathcal{L} \left(\frac{1}{T} \sum_{k=0}^{T-1} \theta_k \right) \right] \stackrel{3.3.14}{\leq} \frac{1}{T} \sum_{k=0}^{T-1} \mathbb{E} [\mathcal{L}(\theta_k)] \leq \mathcal{L}(\theta^*) + \frac{1}{2\eta T} \|\theta_0 - \theta^*\|^2 + \frac{\eta \Sigma}{2}.$$

Sustituyendo ahora $\eta = \frac{1}{\sqrt{\Sigma T}}$, obtenemos

$$\mathbb{E} \left[\mathcal{L} \left(\frac{1}{T} \sum_{k=0}^{T-1} \theta_k \right) - \mathcal{L}(\theta^*) \right] \leq \frac{\sqrt{\Sigma}}{2\sqrt{T}} \|\theta_0 - \theta^*\|^2 + \frac{\sqrt{\Sigma}}{2\sqrt{T}} = \frac{\sqrt{\Sigma}}{2\sqrt{T}} (1 + \|\theta_0 - \theta^*\|^2). \quad \blacksquare$$

3.3.2.4. Interpretación del promedio de iterados

Observación 3.3.16. El teorema anterior proporciona una cota explícita sobre el número de iteraciones necesarias para garantizar una precisión dada en valor esperado. En efecto, si fijamos $\varepsilon > 0$ y elegimos T de modo que

$$T > \frac{\Sigma (1 + \|\theta_0 - \theta^*\|^2)^2}{4\varepsilon^2},$$

entonces, tomando $\eta = \frac{1}{\sqrt{\Sigma T}}$, se deduce que el promedio de iterados $\bar{\theta}_T := \frac{1}{T} \sum_{k=0}^{T-1} \theta_k$ satisface $\mathbb{E} [\mathcal{L}(\bar{\theta}_T) - \mathcal{L}(\theta^*)] < \varepsilon$.

Dicho de otro modo: aunque la trayectoria $\{\theta_k\}_{k=0}^{T-1}$ generada por SGD es aleatoria y sus iterados individuales pueden oscilar, el baricentro de esa trayectoria tiene una pérdida esperada arbitrariamente próxima al mínimo global cuando T es suficientemente grande. La velocidad que proporciona el teorema es del orden $T^{-1/2}$, que es la tasa característica de SGD en el caso convexo general.

Desde el punto de vista práctico, esta estimación debe interpretarse sobre todo como una guía teórica. En aplicaciones reales, la constante Σ que controla el segundo momento del gradiente estocástico, así como la distancia inicial $\|\theta_0 - \theta^*\|$, no suelen conocerse con precisión. Por ello, en lugar de fijar un paso constante mediante la fórmula exacta del teorema, es habitual emplear reglas de aprendizaje decrecientes o esquemas adaptativos.

Observación 3.3.17. El teorema anterior acota $\mathbb{E}[\mathcal{L}(\bar{\theta}_T) - \mathcal{L}(\theta^*)]$. Como $\mathcal{L}$ es convexa, la desigualdad de Jensen para esperanzas —versión integral de la teorema 3.3.14— proporciona además una cota sobre el valor de $\mathcal{L}$ en el punto determinista $\mathbb{E}[\bar{\theta}_T]$:

$$\mathcal{L}(\mathbb{E}[\bar{\theta}_T]) \leq \mathbb{E}[\mathcal{L}(\bar{\theta}_T)] \leq \mathcal{L}(\theta^*) + \frac{\sqrt{\Sigma}}{2\sqrt{T}}(1 + \|\theta_0 - \theta^*\|^2).$$

Como el lado derecho tiende a cero cuando $T \rightarrow \infty$, y $\mathcal{L}$ es continua por ser convexa, se deduce

$$\mathcal{L}\left(\lim_{T \rightarrow \infty} \mathbb{E}[\bar{\theta}_T]\right) = \lim_{T \rightarrow \infty} \mathcal{L}(\mathbb{E}[\bar{\theta}_T]) \leq \mathcal{L}(\theta^*),$$

siempre que el límite $\lim_{T \rightarrow \infty} \mathbb{E}[\bar{\theta}_T]$ exista. Si además los iterados están uniformemente acotados en norma, $\|\theta_k\| \leq M$ para todo $k \geq 0$, entonces $\|\bar{\theta}_T\| \leq M$ para todo T , y el teorema de convergencia dominada de Lebesgue permite intercambiar límite y esperanza:

$$\mathcal{L}\left(\mathbb{E}\left[\lim_{T \rightarrow \infty} \bar{\theta}_T\right]\right) \leq \mathcal{L}(\theta^*).$$

Si $\mathcal{L}$ es además fuertemente convexa, θ^* es su único minimizador global, por lo que la desigualdad anterior implica $\mathbb{E}[\lim_{T \rightarrow \infty} \bar{\theta}_T] = \theta^*$.

Esta convergencia del baricentro $\bar{\theta}_T$ es análoga a la de las medias de Cesàro: si $\{a_m\}_{m=1}^\infty \subset \mathbb{R}$ converge a a , entonces también $S_N := \frac{1}{N} \sum_{m=1}^N a_m \rightarrow a$, pues para $\varepsilon > 0$ fijo y M_ε tal que $|a_m - a| < \varepsilon$ para todo $m > M_\varepsilon$,

$$|S_N - a| \leq \frac{1}{N} \sum_{m=1}^{M_\varepsilon} |a_m - a| + \frac{N - M_\varepsilon}{N} \sup_{m > M_\varepsilon} |a_m - a| \xrightarrow{N \rightarrow \infty} \sup_{m > M_\varepsilon} |a_m - a| < \varepsilon.$$

Pero la convergencia de las medias es estrictamente más débil: hay sucesiones oscilantes cuyas medias de Cesàro convergen. El ejemplo más conocido es $a_m = \sum_{k=0}^m (-1)^k$, que alterna entre 0 y 1, pero $S_N \rightarrow \frac{1}{2}$. De modo análogo, los iterados $\{\theta_k\}$ de SGD pueden oscilar sin converger, y aun así el baricentro $\bar{\theta}_T$ puede hacer converger $\mathbb{E}[\mathcal{L}(\bar{\theta}_T)]$ hacia el mínimo.

3.4. Clasificación multiclase

Los capítulos anteriores desarrollan la teoría de las SVM para el caso binario: dado un espacio de observaciones $X \subset \mathbb{R}^d$, se busca un clasificador $f: X \rightarrow \{-1, 1\}$ que separe dos clases con margen máximo. Sin embargo, muchos problemas reales exigen distinguir entre $k \geq 3$ categorías simultáneamente: reconocimiento de dígitos escritos a mano ($k = 10$), clasificación de variedades de flores ($k = 3$), identificación de subtipos de tejido tumoral, etc.

Este capítulo extiende la teoría de SVM al caso multiclase y está organizado de la siguiente manera.

- 3.4.1 Planteamiento del problema:** se generaliza el marco de clasificación binaria al caso de k clases, estableciendo las nociones de error, clasificador óptimo de Bayes y clasificadores lineales multiclase.
- 3.4.2 Reducción a clasificación binaria:** se estudian las estrategias *One-vs-Rest* (OvR) y *One-vs-One* (OvO), que resuelven el problema multiclase entrenando múltiples clasificadores binarios del tipo estudiado.
- 3.4.3 Formulación directa: SVM de Crammer–Singer:** se presenta una generalización de la pérdida hinge al caso multiclase que optimiza todos los clasificadores simultáneamente.
- 3.4.4 Extensión con núcleo reproductor:** se aplica el truco del núcleo a los enfoques anteriores mediante el Teorema del Representante ya establecido.
- 3.4.5 Implementación y experimentos:** se ilustra la teoría con los conjuntos de datos Iris y Digits, comparando los distintos enfoques con `sklearn`.

3.4.1. El problema de clasificación con k clases

3.4.1.1. Planteamiento

Fijamos un número de clases $k \geq 2$ y denotamos $\mathbb{N}_k := \{1, \dots, k\}$. El problema de *clasificación multiclase* consiste en asignar a cada punto $x \in X \subset \mathbb{R}^d$ una de las k etiquetas en $\mathbb{N}_k$.

Como en el caso binario, suponemos que los datos se generan a partir de una distribución de probabilidad desconocida ρ sobre $X \times \mathbb{N}_k$: la marginal ρ_X describe cómo se distribuyen las observaciones y las probabilidades condicionales $\rho(i \mid x)$ codifican la incertidumbre en la etiqueta dado el punto.

Definición 3.4.1 (Clasificación multiclase y error). Una **clasificación** es una función medible $f: X \rightarrow \mathbb{N}_k$. Su **error de clasificación** es

$$\mathcal{E}[f] := \int_X \mathbb{P}(Y \neq f(x) \mid x) d\rho_X(x) = 1 - \int_X \rho(f(x) \mid x) d\rho_X(x).$$

Dado un conjunto de datos $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset X \times \mathbb{N}_k$, el **error empírico** es

$$\mathcal{E}_{\mathcal{D}}[f] := \frac{1}{m} |\{i \in \mathbb{N}_m : f(x_i) \neq y_i\}|.$$

Observación 3.4.2 (Relación con el caso binario). La definición 3.1.1 define el error para $k = 2$ mediante la pérdida cuadrática $|f(x) - y|^2$ con $f(x), y \in \{-1, 1\}$:

$$\mathcal{E}[f]_{\text{bin}} = \int_Z |f(x) - y|^2 d\rho(x, y) = 4 \int_X \mathbb{P}(Y \neq f(x) \mid x) d\rho_X(x),$$

donde el factor 4 proviene de $|f(x) - y|^2 = 4\mathbb{1}_{\{f(x) \neq y\}}$ para $f(x), y \in \{-1, 1\}$. La definición 3.4.1 adopta directamente la probabilidad de error $\mathbb{P}(Y \neq f(X))$, que es la noción intrínseca independiente de la codificación de las etiquetas, y satisface $\mathcal{E}[f] = \frac{1}{4}\mathcal{E}[f]_{\text{bin}}$ para $k = 2$ con etiquetas $\{-1, 1\}$.

3.4.1.2. Clasificador óptimo de Bayes

Para $k = 2$, la regla de Bayes es $g^*(x) = \mathbb{1}_{[f_\rho(x) \geq 1/2]}$, donde $f_\rho(x) = \mathbb{P}(Y = 1 \mid x)$ (section 3.4.1). Para k clases basta generalizar la función de regresión escalar a un vector de probabilidades.

Definición 3.4.3 (Funciones de regresión multiclase). Para cada $i \in \mathbb{N}_k$, la **función de regresión** de la clase i es

$$\eta_i: X \rightarrow [0, 1], \quad \eta_i(x) := \rho(i \mid x) = \mathbb{P}(Y = i \mid x).$$

El vector $\eta(x) := (\eta_1(x), \dots, \eta_k(x))$ toma valores en el simplex estándar $\Delta^{k-1} := \{p \in \mathbb{R}^k : p_i \geq 0 \wedge \sum_{i=1}^k p_i = 1\}$.

Proposición 3.4.4 (Regla de Bayes multiclase). *El clasificador que minimiza el error de clasificación entre todos los $f: X \rightarrow \mathbb{N}_k$ es la **regla de Bayes***

$$g^*(x) := \arg \max_{i \in \mathbb{N}_k} \eta_i(x) = \arg \max_{i \in \mathbb{N}_k} \mathbb{P}(Y = i \mid x).$$

En particular, $\mathcal{E}[g^] \leq \mathcal{E}[f]$ para todo $f: X \rightarrow \mathbb{N}_k$.*

Demostración: Fijado $x \in X$, el error condicional de f en x es

$$\mathbb{P}(Y \neq f(x) \mid x) = 1 - \rho(f(x) \mid x) = 1 - \eta_{f(x)}(x).$$

Minimizar punto a punto este error condicional equivale a maximizar $\eta_{f(x)}(x)$ sobre $\mathbb{N}_k$, que es exactamente lo que hace g^* . Dado que el integrando satisface $\mathbb{P}(Y \neq g^*(x) \mid x) \leq \mathbb{P}(Y \neq f(x) \mid x)$ para todo x , integrando respecto a ρ_X se obtiene $\mathcal{E}[g^*] \leq \mathcal{E}[f]$. ■

Observación 3.4.5 (Error de Bayes y ambigüedad). El error mínimo alcanzable, $\mathcal{E}[g^*] = 1 - \int_X \max_i \eta_i(x) d\rho_X(x)$, se llama **error de Bayes** o **error irreducible**. El Teorema de No Free Lunch (teorema 3.2.4) garantiza que ningún algoritmo puede superar esta cota de forma universal.

3.4.1.3. Clasificadores lineales multiclase

En el caso binario los clasificadores lineales usan un único hiperplano separador (definición 3.1.4). Para k clases, la generalización natural consiste en asignar a cada clase una función de puntuación lineal y predecir la clase con mayor puntuación. Esta parametrización no fija el número mínimo de hiperplanos de frontera: fija k funciones afines (scores), y las fronteras se inducen al comparar pares de scores.

Definición 3.4.6 (Clasificadores lineales multiclase). Para $k \geq 2$, el espacio de **clasificadores lineales multiclase** es

$$\mathcal{H}_k := \left\{ f: \mathbb{R}^d \rightarrow \mathbb{N}_k : \exists W \in \mathbb{R}^{k \times d}, b \in \mathbb{R}^k : \forall x \in \mathbb{R}^d : f(x) = \arg \max_{i \in \mathbb{N}_k} (\langle w_i, x \rangle + b_i) \right\},$$

donde $w_i \in \mathbb{R}^d$ es la i -ésima fila de W . Las funciones $\xi_i(x) := \langle w_i, x \rangle + b_i$ se denominan **puntuaciones** (*scores*) de la clase i en el punto x .

Observación 3.4.7 (Conexión con el caso binario). Para $k = 2$ con $\mathbb{N}_k = \{-1, 1\}$, todo $f \in \mathcal{H}_2$ de la definición 3.1.4 admite la representación de la definición 3.4.6: basta tomar $w_1 = w$, $b_1 = b$, $w_{-1} = -w$ y $b_{-1} = -b$, pues entonces $\xi_1(x) > \xi_{-1}(x) \iff \langle w, x \rangle + b > 0$.

Observación 3.4.8 (Regiones de decisión poliédricas). Los **regiones de decisión** del clasificador $f \in \mathcal{H}_k$ son los conjuntos

$$R_i := \{x \in \mathbb{R}^d : f(x) = i\} = \left\{ x \in \mathbb{R}^d : \forall j \neq i, \langle w_i - w_j, x \rangle + (b_i - b_j) \geq 0 \right\}.$$

Cada R_i es la intersección de $k - 1$ semiespacios cerrados: en particular, es un poliedro convexo. La frontera entre R_i y R_j es el hiperplano

$$H_{ij} := \{x \in \mathbb{R}^d : \langle w_i - w_j, x \rangle + (b_i - b_j) = 0\},$$

que separa localmente las clases i y j . En consecuencia, el número de fronteras pairwise

potenciales es a lo sumo $\binom{k}{2}$ (aunque algunas pueden no ser activas, por ejemplo si dos regiones no comparten borde o una clase queda vacía). La partición $\{R_i\}_{i=1}^k$ de $\mathbb{R}^d$ es, por lo tanto, una **teselación poliédrica convexa**, también denominada diagrama de Voronoi lineal.

Observación 3.4.9 (Alcance geométrico de $\mathcal{H}_k$). No toda partición de $\mathbb{R}^d$ en k regiones poliédricas convexas puede escribirse como un clasificador de $\mathcal{H}_k$. La familia $\mathcal{H}_k$ contiene exactamente las particiones que admiten una representación por potenciales afines

$$R_i = \{x \in \mathbb{R}^d : \xi_i(x) \geq \xi_j(x) \forall j\}, \quad \xi_i(x) = \langle w_i, x \rangle + b_i.$$

De forma equivalente, las fronteras entre clases deben ser compatibles con diferencias globales

$$a_{ij} = w_i - w_j, \quad \beta_{ij} = b_i - b_j.$$

Esta compatibilidad impone una condición de **cierre en ciclos**: para todo ciclo de clases $i_1 \rightarrow i_2 \rightarrow \dots \rightarrow i_r \rightarrow i_1$ debe cumplirse

$$\sum_{t=1}^r a_{i_t i_{t+1}} = 0, \quad \sum_{t=1}^r \beta_{i_t i_{t+1}} = 0, \quad (i_{r+1} := i_1).$$

En efecto, si $a_{ij} = w_i - w_j$, entonces

$$(w_{i_1} - w_{i_2}) + \dots + (w_{i_r} - w_{i_1}) = 0$$

por cancelación telescópica, y análogamente para β_{ij} . Por tanto, si una familia de fronteras pairwise propuesta no satisface estas igualdades de cierre, no existen potenciales globales (w_i, b_i) que la generen mediante $\arg \max$, y la partición no pertenece a $\mathcal{H}_k$.

Ejemplo 3.4.10. El conjunto de datos Iris contiene medidas de los sépalos y pétalos de tres especies de iris ($k = 3$). Reducida la dimensión a $d = 2$ mediante PCA, las tres regiones de decisión de un clasificador lineal $f \in \mathcal{H}_3$ son tres poliedros convexas separados por rectas (véase la section 3.4.5).

3.4.2. Reducción a clasificación binaria

3.4.2.1. One-vs-Rest (OvR)

La estrategia *One-vs-Rest* (también llamada *One-vs-All*) reduce el problema multiclase a k problemas binarios independientes. Para cada clase $i \in \mathbb{N}_k$, se recodifican las etiquetas como $+1$ para los ejemplos de la clase i y -1 para el resto, y se entrena una SVM binaria sobre el dataset completo.

Definición 3.4.11 (Clasificador OvR). Dado $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset X \times \mathbb{N}_k$, para cada $i \in \mathbb{N}_k$ se define el **dataset binarizado**

$$\mathcal{D}^{(i)} := \{(x_\ell, \sigma_i(y_\ell))\}_{\ell=1}^m, \quad \sigma_i(y) := \begin{cases} +1 & \text{si } y = i, \\ -1 & \text{si } y \neq i. \end{cases}$$

Sea (w_i^*, b_i^*) la solución del problema Soft-SVM (3.3) sobre $\mathcal{D}^{(i)}$, con función de decisión $\xi_i^*(x) := \langle w_i^*, x \rangle + b_i^*$. El **clasificador OvR** es

$$\hat{f}^{\text{OvR}}(x) := \arg \max_{i \in \mathbb{N}_k} \xi_i^*(x).$$

Observación 3.4.12 (OvR como clasificador lineal multiclase). El clasificador $\hat{f}^{\text{OvR}}$ pertenece a $\mathcal{H}_k$ (definición 3.4.6): basta tomar la matriz de pesos $W \in \mathbb{R}^{k \times d}$ con filas w_i^* y el sesgo $b = (b_1^*, \dots, b_k^*)$. Las regiones de decisión son por tanto poliedros convexos como describe la observación 3.4.8. Sin embargo, a diferencia del caso binario, los k vectores (w_i^*, b_i^*) se obtienen de optimizaciones *independientes* entre sí.

Observación 3.4.13 (Regiones ambiguas y clases silenciosas). Si $\xi_{i_1}^*(x) > 0$ y $\xi_{i_2}^*(x) > 0$ para dos clases distintas $i_1 \neq i_2$, los dos clasificadores binarios reclaman la misma observación. Análogamente, si $\xi_i^*(x) < 0$ para todo i , ningún clasificador la reivindica. Aunque la regla $\arg \max$ resuelve ambas situaciones por definición, ilustra que las puntuaciones ξ_i^* no están calibradas entre sí: se obtienen de problemas entrenados con proporciones de clases distintas (m_i positivos frente a $m - m_i$ negativos) y, en general, no son comparables en escala.




Figura 3.1: Nubes sintéticas en $\mathbb{R}^2$ y regiones de decisión de una SVM lineal OvR.

3.4.2.2. One-vs-One (OvO)

El principal inconveniente de OvR es que las puntuaciones ξ_i^* de diferentes clases carecen de calibración mutua: cada clasificador binario observa proporciones de clases distintas (m_i positivos frente a $m - m_i$ negativos), lo que puede producir scores en escalas incomparables. Como se verá, esto provoca que OvR pierda consistencia con la regla de Bayes. Una alternativa natural es la estrategia *One-vs-One*, que reduce el problema a $\binom{k}{2}$ problemas binarios, uno por cada par de clases. Cada subproblema se entrena únicamente con los ejemplos de las dos clases involucradas (garantizando proporciones 1:1), y la predicción se decide por votación mayoritaria. Esta construcción evita el problema de calibración y, bajo hipótesis suaves, es consistente con la regla de Bayes. El contraste se aprecia en el experimento sintético desbalanceado de las figuras 3.2 y 3.3: OvR tiende a favorecer la clase mayoritaria, mientras que OvO preserva mejor la región de la clase minoritaria al decidir por comparaciones pairwise.




Figura 3.2: Dataset sintético desbalanceado y regiones de decisión con SVM lineal OvR.




Figura 3.3: Dataset sintético desbalanceado y regiones de decisión con SVM lineal OvO.

Definición 3.4.14 (Clasificador OvO). Para cada par no ordenado $i < j$ en $\mathbb{N}_k$, se define

el **dataset reducido al par** (i, j) :

$$\mathcal{D}^{(ij)} := \{(x_s, \tilde{\sigma}_{ij}(y_s)) : s \in I_i \cup I_j\}, \quad \tilde{\sigma}_{ij}(y) := \begin{cases} +1 & \text{si } y = i, \\ -1 & \text{si } y = j, \end{cases}$$

donde $I_i := \{s \in \mathbb{N}_m : y_s = i\}$. Sea $f_{ij}^* : X \rightarrow \{-1, 1\}$ la SVM binaria entrenada sobre $\mathcal{D}^{(ij)}$, interpretando $f_{ij}^*(x) = +1$ como “ x pertenece a la clase i ” (y -1 como “ x pertenece a la clase j ”). Para simplificar notación, extendemos a pares ordenados definiendo $f_{ji}^*(x) := -f_{ij}^*(x)$. El **marcador de votos** de la clase i en el punto x es

$$v_i(x) := \sum_{j \in \mathbb{N}_k \setminus \{i\}} \mathbb{1}_{\{f_{ij}^*(x) = +1\}},$$

y el **clasificador OvO** es

$$\hat{f}^{\text{OvO}}(x) := \arg \max_{i \in \mathbb{N}_k} v_i(x).$$

Observación 3.4.15. El total de votos repartidos en cada punto es $\sum_{i=1}^k v_i(x) = \binom{k}{2}$: cada par $\{i, j\}$ emite exactamente un voto. En caso de empate en $v_i(x)$, la regla $\arg \max$ no está definida de forma única; en la práctica se rompe por las puntuaciones ξ_{ij}^* o por orden lexicográfico.

Observación 3.4.16 (Robustez del voto binario frente a sumar scores continuos). En OvO, cada función f_{ij}^* se entrena en un subproblema distinto (i, j) , con su propia escala geométrica (ancho de margen, dispersión de datos y nivel de regularización efectivo). Por eso, el valor numérico de $f_{ij}^*(x)$ y el de $f_{i\ell}^*(x)$ no son, en general, magnitudes comparables: que uno valga 2 y otro 0,4 no implica que la primera evidencia sea “cinco veces mejor”, sino que están medidos en reglas diferentes. Si se agregan esos valores continuos sin calibración, un solo clasificador pairwise con escala inflada puede dominar la decisión global y volverla sensible a reescalados arbitrarios. En cambio, el voto binario usa solo la información estable del duelo pairwise (quién gana entre i y j), es invariante ante transformaciones monótonas que preservan el signo y reparte influencia comparable entre todos los pares; por eso suele ser más robusto en presencia de subproblemas heterogéneos.

Observación 3.4.17 (Tamaño de los subproblemas). Cada SVM binaria f_{ij}^* se entrena sobre $m_{ij} := m_i + m_j$ puntos, donde $m_i = |I_i|$. Si las clases están balanceadas ($m_i \approx m/k$ para todo $i \in \mathbb{N}_k$), entonces $m_{ij} \approx 2m/k$: cada subproblema es considerablemente más pequeño que el dataset completo. Esto reduce el coste por clasificador a cambio de entrenar $\binom{k}{2}$ en lugar de k clasificadores.

3.4.2.3. Comparación e inconsistencias de las reducciones

	OvR	OvO
Número de clasificadores	k	$\binom{k}{2}$
Tamaño de cada subproblema	m	$m_i + m_j \leq m$
Consistencia de Bayes	no garantizada	garantizada (cond. suaves)
Implementación en <code>sklearn</code>	<code>LinearSVC</code>	<code>SVC</code>

Desde el punto de vista de la consistencia, las dos estrategias difieren de manera fundamental.

Observación 3.4.18 (Inconsistencia de OvR). OvR no es en general consistente con la regla de Bayes. El $\arg\max_i \xi_i^*(x)$ no coincide necesariamente con $\arg\max_i \eta_i(x)$ porque las puntuaciones ξ_i^* son soluciones a problemas con distribuciones binarias distintas: el clasificador de la clase i ve una proporción m_i/m de positivos, que varía con i . Así, comparar directamente $\xi_i^*(x)$ con $\xi_j^*(x)$ es comparar valores producidos en escalas distintas.

Intuitivamente, si la clase i es muy frecuente ($m_i \gg m_j$), su SVM binaria aprende un margen mayor y sus scores ξ_i^* pueden dominar sistemáticamente los de clases más pequeñas, independientemente de la probabilidad posterior real.

3.4.3. Formulación directa: SVM de Crammer–Singer

3.4.3.1. Pérdida hinge multiclase

Las estrategias de reducción (OvR y OvO) heredan automáticamente todas las garantías de la Soft-SVM binaria pero tratan los k subproblemas de forma independiente: los pesos w_i^* no interactúan durante el entrenamiento, lo que puede producir puntuaciones ξ_i^* no calibradas entre sí (véase la observación 3.4.18).

La formulación de Crammer y Singer **crammer2001** evita este problema optimizando el margen de *todas* las clases simultáneamente. La idea es generalizar la pérdida hinge binaria: en el caso binario, el punto x_i con etiqueta $y_i \in \{-1, 1\}$ es penalizado si la puntuación de su clase verdadera $y_i \langle w, x_i \rangle + b$ cae por debajo de 1. En el caso multiclase, pedimos que la puntuación de la clase correcta $\xi_{y_i}(x_i)$ supere en al menos 1 a la puntuación de *cualquier* clase competidora.

Definición 3.4.19 (Pérdida hinge multiclase). Dado un clasificador de parámetros $W \in \mathbb{R}^{k \times d}$, $b \in \mathbb{R}^k$, con funciones de puntuación $\xi_i(x) = \langle w_i, x \rangle + b_i$, la **pérdida hinge multi-**

clase en el ejemplo $(x, y) \in X \times \mathbb{N}_k$ es

$$\ell^{\text{cs}}(W, b; x, y) := \max_{i \in \mathbb{N}_k \setminus \{y\}} \max\{0, 1 + \xi_i(x) - \xi_y(x)\}.$$

Para el conjunto de datos $\mathcal{D} = \{(x_s, y_s)\}_{s=1}^m$, la **pérdida empírica de Crammer–Singer** es

$$\mathcal{E}_{\mathcal{D}}^{\text{cs}}(W, b) := \frac{1}{m} \sum_{s=1}^m \ell^{\text{cs}}(W, b; x_s, y_s) = \frac{1}{m} \sum_{s=1}^m \max_{i \neq y_s} \max\{0, 1 + \xi_i(x_s) - \xi_{y_s}(x_s)\}.$$

Observación 3.4.20 (Conexión con la pérdida hinge binaria). Para $k = 2$ con $\mathbb{N}_k = \{-1, 1\}$ y escogiendo $w_{-1} = -w_1$, $b_{-1} = -b_1$, se tiene $\xi_1(x) - \xi_{-1}(x) = 2(\langle w_1, x \rangle + b_1)$. La única clase competidora de $y = 1$ es $i = -1$, de modo que

$$\ell^{\text{cs}}(W; x, 1) = \max\{0, 1 - 2(\langle w_1, x \rangle + b_1)\},$$

que coincide (salvo el factor 2, absorbible en λ) con la pérdida hinge binaria $\max\{0, 1 - y(\langle w, x \rangle + b)\}$ del ??.

Observación 3.4.21 (Interpretación geométrica del margen). La condición $\xi_{y_s}(x_s) \geq \xi_i(x_s) + 1$ para todo $i \neq y_s$ establece que la puntuación de la clase correcta debe superar a la de cualquier clase incorrecta con un margen de al menos 1. Cuando se viola, la penalización $1 + \xi_i(x_s) - \xi_{y_s}(x_s)$ mide cuánto falta para satisfacer esa separación: si la clase i tiene mayor puntuación que la clase correcta (error de clasificación), la penalización supera 1.

3.4.3.2. Problema de optimización

Añadiendo un término de regularización sobre cada vector de pesos, se obtiene el problema de Crammer–Singer.

Definición 3.4.22 (SVM de Crammer–Singer). El problema de **SVM de Crammer–Singer** es

$$\min_{\substack{W \in \mathbb{R}^{k \times d}, b \in \mathbb{R}^k \\ \xi \in \mathbb{R}_+^{k \times m}}} \left(\frac{1}{m} \sum_{s=1}^m \sum_{i \neq y_s} \xi_{is} + \lambda \sum_{i=1}^k \|w_i\|^2 \right) \quad \text{sujeto a} \quad \forall s \in \mathbb{N}_m, \forall i \neq y_s: \xi_{y_s, s} - \xi_{is} \geq 1 - \xi_{is}^{\text{hol}}, \quad (3.6)$$

donde $\xi_{is}^{\text{hol}} \geq 0$ es la variable de holgura que mide la violación del margen entre la clase i y la clase correcta y_s en el ejemplo s .

Siguiendo el mismo argumento que para la Soft-SVM binaria (equation (3.3)), fijados W y

b , el valor óptimo de cada variable de holgura es

$$\xi_{is}^{\text{hol},*} = \max\{0, 1 + \xi_i(x_s) - \xi_{y_s}(x_s)\},$$

de modo que el problema (3.6) es equivalente a minimizar el funcional

$$\mathcal{L}^{\text{cs}}(W, b) := \mathcal{E}_{\mathcal{D}}^{\text{cs}}(W, b) + \lambda \sum_{i=1}^k \|w_i\|^2. \quad (3.7)$$

Proposición 3.4.23 (Convexidad). *El funcional $\mathcal{L}^{\text{cs}}(W, b)$ es convexo en (W, b) . Si $\lambda > 0$, es estrictamente convexo y admite un único mínimo global.*

Demostración: La función $t \mapsto \max\{0, 1 + t\}$ es convexa. La cantidad $\xi_i(x_s) - \xi_{y_s}(x_s) = \langle w_i - w_{y_s}, x_s \rangle + (b_i - b_{y_s})$ es lineal en (W, b) , por tanto la composición $\max\{0, 1 + \xi_i(x_s) - \xi_{y_s}(x_s)\}$ es convexa. El $\max$ de funciones convexas es convexo y la suma conserva la convexidad, luego $\mathcal{E}_{\mathcal{D}}^{\text{cs}}$ es convexa. El término $\lambda \sum_i \|w_i\|^2$ es estrictamente convexo para $\lambda > 0$, lo que implica la estricta convexidad de $\mathcal{L}^{\text{cs}}$. ■

Observación 3.4.24 (Vínculo con el caso binario). Para $k = 2$, la pérdida $\mathcal{L}^{\text{cs}}$ coincide (salvo reescalado de λ) con la pérdida hinge regularizada del problema de Soft-SVM binaria (3.3). En ese sentido, la formulación de Crammer–Singer es la extensión más natural y unificada: resuelve un único problema convexo de dimensión $k \times (d + 1)$ en lugar de k problemas independientes de dimensión $d + 1$.

3.4.4. Extensión con núcleo reproductor

3.4.4.1. Kernel trick en el caso multiclase

La formulación de Crammer–Singer en su forma lineal (3.7) exige que las fronteras de decisión sean hiperplanos en $\mathbb{R}^d$. Al igual que en el caso binario (véase la ejemplo 3.1.15 y la proposición 3.1.16), es posible que los datos no sean linealmente separables en $\mathbb{R}^d$ pero sí lo sean en un espacio de mayor dimensión definido por un mapa de características $\phi: X \rightarrow \mathcal{H}_K$.

La extensión es directa: en lugar de buscar vectores de pesos $w_i \in \mathbb{R}^d$, se buscan funciones $\xi_i \in \mathcal{H}_K$ en un RKHS con núcleo $K: X \times X \rightarrow \mathbb{R}$. Cada función de puntuación de la clase i pasa a ser $\xi_i: X \rightarrow \mathbb{R}$ con $\xi_i \in \mathcal{H}_K$, y la pérdida multiclase (3.7) se convierte en el funcional

$$\mathcal{L}_K^{\text{cs}}(\xi) := \frac{1}{m} \sum_{s=1}^m \max_{i \neq y_s} \max\{0, 1 + \xi_i(x_s) - \xi_{y_s}(x_s)\} + \lambda \sum_{i=1}^k \|\xi_i\|_{\mathcal{H}_K}^2, \quad (3.8)$$

donde $\xi = (\xi_1, \dots, \xi_k) \in \mathcal{H}_K^k$.

Observación 3.4.25. Las k funciones ξ_i se regularizan de forma independiente con el mismo $\lambda > 0$. El clasificador resultante es $f(x) = \arg \max_{i \in \mathbb{N}_k} \xi_i(x)$, que generaliza directamente la regla $\arg \max$ de la definición 3.4.6 al espacio $\mathcal{H}_K$.

Observación 3.4.26 (Convexidad en el caso kernel). El funcional (3.8) es convexo en ξ por el mismo argumento de la proposición 3.4.23: cada $\xi_i(x_s) = \langle \xi_i, K_{x_s} \rangle_{\mathcal{H}_K}$ es lineal en ξ_i , la composición con el máx de funciones afines es convexa, y el término $\lambda \|\xi_i\|_{\mathcal{H}_K}^2$ es estrictamente convexo. Como las k funciones están desacopladas en la regularización, el problema separable admite un único mínimo global.

3.4.4.2. Teorema del Representante vectorial

El funcional (3.8) vive sobre $\mathcal{H}_K^k$, un espacio de dimensión infinita. El teorema 2.2.10 reduce cada ξ_i a un elemento del subespacio de dimensión finita $V_{\mathcal{D}} := \text{span}\{K_{x_s}\}_{s=1}^m$, exactamente igual que en el caso binario (tema3.tex, p. 41).

Proposición 3.4.27 (Teorema del representante multiclase). *Sea K un núcleo de Mercer y $\mathcal{H}_K$ su RKHS. Si $\xi^* = (\xi_1^*, \dots, \xi_k^*)$ minimiza (3.8), entonces para cada $i \in \mathbb{N}_k$ existen coeficientes $\alpha_1^{(i)}, \dots, \alpha_m^{(i)} \in \mathbb{R}$ tales que*

$$\xi_i^* = \sum_{s=1}^m \alpha_s^{(i)} K_{x_s}, \quad \text{es decir,} \quad \xi_i^*(x) = \sum_{s=1}^m \alpha_s^{(i)} K(x_s, x).$$

Demostración: Fijado $i \in \mathbb{N}_k$, el funcional (3.8) tiene la forma $R_g[\xi_i] = E_i(\{\xi_i(x_s)\}_{s=1}^m) + g(\|\xi_i\|_{\mathcal{H}_K})$, donde

$$E_i(\{v_s\}_{s=1}^m) := \frac{1}{m} \sum_{s=1}^m \max_{j \neq y_s} \max \{0, 1 + v_s \mathbb{1}_{[j=i]} - v_s \mathbb{1}_{[j=y_s]}\} + \lambda \sum_{j \neq i} \|\xi_j\|_{\mathcal{H}_K}^2$$

depende de ξ_i únicamente a través de sus evaluaciones $\{\xi_i(x_s)\}_{s=1}^m$, y $g(t) = \lambda t^2$ es estrictamente creciente. La hipótesis del teorema 2.2.10 está satisfecha, luego $\xi_i^* \in V_{\mathcal{D}}$. ■

Escribiendo $\xi_i^* = \sum_{s=1}^m \alpha_s^{(i)} K_{x_s}$ y denotando $\alpha^{(i)} = (\alpha_1^{(i)}, \dots, \alpha_m^{(i)})^\top \in \mathbb{R}^m$, la propiedad reproductora da

$$\xi_i^*(x_t) = \sum_{s=1}^m \alpha_s^{(i)} K(x_s, x_t) = (G \alpha^{(i)})_t,$$

donde $G \in \mathbb{R}^{m \times m}$ es la **matriz de Gram** con $G_{ts} := K(x_t, x_s)$. Asimismo,

$$\|\xi_i^*\|_{\mathcal{H}_K}^2 = \langle \sum_s \alpha_s^{(i)} K_{x_s}, \sum_t \alpha_t^{(i)} K_{x_t} \rangle_{\mathcal{H}_K} = \sum_{s,t} \alpha_s^{(i)} \alpha_t^{(i)} K(x_s, x_t) = (\alpha^{(i)})^\top G \alpha^{(i)}.$$

Sustituyendo en (3.8), el problema de dimensión infinita se reduce a minimizar sobre la matriz de coeficientes $A = [\alpha^{(1)} | \dots | \alpha^{(k)}] \in \mathbb{R}^{m \times k}$:

$$\mathcal{L}(A) = \frac{1}{m} \sum_{s=1}^m \max_{i \neq y_s} \max \{0, 1 + (G\alpha^{(i)})_s - (G\alpha^{(y_s)})_s\} + \lambda \sum_{i=1}^k (\alpha^{(i)})^\top G \alpha^{(i)}. \quad (3.9)$$

El clasificador final evalúa en un punto $x \in X$ como

$$f(x) = \arg \max_{i \in \mathbb{N}_k} \xi_i^*(x) = \arg \max_{i \in \mathbb{N}_k} \sum_{s=1}^m \alpha_s^{(i)} K(x_s, x),$$

de modo que la predicción en nuevos puntos requiere únicamente evaluar el núcleo K , sin necesidad de calcular el mapa ϕ explícitamente.

Observación 3.4.28 (Comparación con el caso binario). Para $k = 2$, la matriz $A \in \mathbb{R}^{m \times 2}$ tiene dos columnas $\alpha^{(1)} = -\alpha^{(2)} =: \alpha$ (por simetría), y el funcional (3.9) se reduce exactamente a la Soft Kernel SVM binaria (3.5) de las notas. En el caso general, se tienen k sistemas de coeficientes que comparten la misma matriz de Gram G , lo que permite reutilizar su factorización (por ejemplo, la descomposición de Cholesky) en todos los subproblemas.

3.4.5. Implementación y experimentos con sklearn

3.4.5.1. Uso de SVC y LinearSVC

3.4.5.2. Experimentos: Iris y Digits

La figura 3.1 muestra un experimento sintético en $\mathbb{R}^2$ con tres nubes gaussianas equidistantes alrededor del origen. El fondo coloreado representa las regiones de decisión del clasificador OvR lineal,

$$f(x) = \arg \max_{i \in \mathbb{N}_k} (\langle w_i, x \rangle + b_i),$$

y las líneas discontinuas corresponden a los hiperplanos binarios entrenados para cada clase.

4. Introducción a las redes neuronales

4.1. Multilayer Perceptron (MLP)

Los métodos estudiados en capítulos anteriores son esencialmente lineales: producen fronteras de decisión afines. Muchos problemas de interés práctico, sin embargo, involucran dependencias fuertemente no lineales.

Una respuesta natural a esta limitación es la *composición iterada* de transformaciones sencillas: cada capa aplica una transformación afín seguida de una no linealidad puntual, y la composición de varias capas permite representar funciones de complejidad creciente. Esta arquitectura es la red neuronal prototípica y el fundamento de los métodos modernos de aprendizaje profundo.

Definición 4.1.1 (Función de activación). Una *función de activación* es una función suave¹ $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ que no es un polinomio. Extendemos su acción a vectores coordenada a coordenada: para $v \in \mathbb{R}^n$, $\sigma(v) := (\sigma(v_1), \dots, \sigma(v_n)) \in \mathbb{R}^n$.

Definición 4.1.2 (Perceptrón). Sea σ una función de activación. Un *perceptrón* (o *neurona artificial*) con n entradas es una función $h: \mathbb{R}^n \rightarrow \mathbb{R}$ de la forma

$$h(x) := \sigma(w^\top x + b) = \sigma(\langle w, x \rangle + b),$$

donde $w \in \mathbb{R}^n$ es el *vector de pesos* (*weights*) y $b \in \mathbb{R}$ es el *sesgo* (*bias*).

Definición 4.1.3 (Capa). Sea σ una función de activación. Una *capa* de anchura n_{sal} con dominio $\mathbb{R}^{n_{\text{ent}}}$ es una función $h: \mathbb{R}^{n_{\text{ent}}} \rightarrow \mathbb{R}^{n_{\text{sal}}}$ de la forma

$$h(x) := \sigma(Wx + b),$$

donde $W \in \mathbb{R}^{n_{\text{sal}} \times n_{\text{ent}}}$ es la *matriz de pesos* y $b \in \mathbb{R}^{n_{\text{sal}}}$ es el *vector de sesgos*. En particular, cada componente $h_j(x) = \sigma(\langle W_{j,\cdot}, x \rangle + b_j)$ es exactamente un perceptrón.

Definición 4.1.4 (Perceptrón multicapa). Sea σ una función de activación, $L \in \mathbb{N}$ y $(n_k)_{k=0}^L \in \mathbb{N}^{L+1}$. Un *perceptrón multicapa* (MLP por sus siglas en inglés) de profundidad L y arquitectura $(n_k)_{k=0}^L$ es una función $f: \mathbb{R}^{n_0} \rightarrow \mathbb{R}^{n_L}$ dada por

$$f := h^{(L)} \circ h^{(L-1)} \circ \dots \circ h^{(1)},$$

donde para cada $k \in \mathbb{N}_L$, $h^{(k)}$ es una capa de anchura n_k con dominio $\mathbb{R}^{n_{k-1}}$.

¹Se admiten funciones no derivables en un conjunto de medida cero.

Si $h^{(k)}$ tiene la matriz de pesos $W^{(k)} \in \mathbb{R}^{n_k \times n_{k-1}}$ y vector de sesgos $b^{(k)} \in \mathbb{R}^{n_k}$, entonces

$$\forall x \in \mathbb{R}^{n_0} : f(x) = \sigma(W^{(L)} \sigma(W^{(L-1)} \dots \sigma(W^{(1)}x + b^{(1)}) + \dots + b^{(L-1)}) + b^{(L)}).$$

Se dice que n_0 es la *dimensión de entrada* y n_L la *dimensión de salida*. Las capas $h^{(1)}, \dots, h^{(L-1)}$ se denominan *capas ocultas* y $h^{(L)}$ es la *capa de salida*.

Fijaremos una función de activación σ , una profundidad L y una arquitectura $(n_k)_{k=0}^L$ y consideraremos como espacio de hipótesis el conjunto de todos los MLP con esos hiperparámetros. Definimos

$$P_w := \sum_{k=1}^L n_k n_{k-1}, \quad P_b := \sum_{k=1}^L n_k, \quad P := P_w + P_b.$$

Así, P es el número total de parámetros entrenables (pesos y sesgos).

Si $x \in \mathbb{R}^{n_0}$ es una entrada, el *forward pass* del MLP consiste en propagar la señal desde la entrada hasta la salida capa a capa: se fija $a^{(0)} := x$ y, para cada $k = 1, \dots, L$, se calculan sucesivamente las pre-activaciones y activaciones de la capa k :

$$z^{(k)} := W^{(k)}a^{(k-1)} + b^{(k)} \quad a^{(k)} := \sigma(z^{(k)}).$$

La salida de la red es entonces $f_\theta(x) = a^{(L)}$.

4.1.1. Backpropagation (Reverse differentiation)

El entrenamiento de un MLP consiste en hallar los parámetros $\theta = (W^{(1)}, b^{(1)}, \dots, W^{(L)}, b^{(L)})$ que minimizan una *función de pérdida* (o *loss*)

$$\mathcal{L}(\theta) := \mathbb{E}_{(x,y) \sim \mathcal{D}} [\ell(f_\theta(x), y)],$$

donde $\mathcal{D}$ es la distribución de los datos, f_θ es el MLP (definición 4.1.4) y $\ell: \mathbb{R}^{n_L} \times \mathbb{R}^{n_L} \rightarrow \mathbb{R}$ es una función de pérdida puntual que mide la discrepancia entre la predicción $f_\theta(x)$ y la etiqueta real y . En la práctica se reemplaza la esperanza por la media empírica sobre el conjunto de entrenamiento $\{(x_i, y_i)\}_{i=1}^n$. Un ejemplo habitual es la pérdida cuadrática $\ell(\hat{y}, y) = \frac{1}{2} \|\hat{y} - y\|^2$.

El método estándar para minimizar $\mathcal{L}$ es el *descenso del gradiente* y sus variantes estocásticas, que requieren evaluar en cada paso el gradiente $\nabla_\theta \mathcal{L}(\theta)$. Dado que θ tiene P entradas escalares, calcular este gradiente necesita obtener P derivadas parciales de forma eficiente.

El obstáculo es que f_θ es una *composición* de L capas: la regla de la cadena genera dependencias anidadas entre capas y parámetros. Describimos primero el enfoque directo (*naive*) de cálculo del gradiente.

4.1.1.1. Regla de la cadena *naive*

Sea $k \in \mathbb{N}_L$ y $\theta^{(k)} \in \mathbb{R}$ un parámetro escalar de la capa k . Para una muestra fija (x, y) , por la regla de la cadena,

$$\frac{\partial \ell(f_\theta(x), y)}{\partial \theta^{(k)}} = \left\langle \nabla_{a^{(L)}} \ell(a^{(L)}(\theta; x), y), \frac{\partial a^{(L)}}{\partial \theta^{(k)}} \right\rangle.$$

El gradiente de $\mathcal{L}$ se obtiene después promediando esta expresión sobre la distribución de datos, o sobre la media empírica en la práctica. Como $\forall m \geq k : a^{(m)} = \sigma(z^{(m)})$, tenemos que

$$\forall r \in \mathbb{N}_{n_m} : \frac{\partial a_r^{(m)}}{\partial \theta^{(k)}} = \sigma'(z_r^{(m)}) \cdot \frac{\partial z_r^{(m)}}{\partial \theta^{(k)}}.$$

Distinguimos tres casos:

Caso I: $m = k$. La capa k es la capa del parámetro $\theta^{(k)}$. Como $z^{(k)} = W^{(k)}a^{(k-1)} + b^{(k)}$, las derivadas locales son inmediatas una vez conocido $a^{(k-1)}$ del *forward pass*:

$$\frac{\partial z_r^{(k)}}{\partial W_{ij}^{(k)}} = \delta_{ri} a_j^{(k-1)}, \quad \frac{\partial z_r^{(k)}}{\partial b_i^{(k)}} = \delta_{ri}.$$

Por tanto, $\frac{\partial a_r^{(k)}}{\partial \theta^{(k)}} = \sigma'(z_r^{(k)}) \frac{\partial z_r^{(k)}}{\partial \theta^{(k)}}$. El coste de esta parte es $\mathcal{O}(1)$ por coordenada.

Caso II: $m = k + 1$. La derivada ya debe atravesar una única capa adicional:

$$\frac{\partial a_i^{(k+1)}}{\partial \theta^{(k)}} = \sigma'(z_i^{(k+1)}) \sum_{r=1}^{n_k} W_{ir}^{(k+1)} \frac{\partial a_r^{(k)}}{\partial \theta^{(k)}}.$$

El coste de este paso es $\mathcal{O}(n_{k+1}n_k)$.

Caso III: $m > k + 1$. La dependencia se propaga de forma recursiva por las capas posteriores, aplicando repetidamente la fórmula anterior. Entonces, se tiene que

$$\frac{\partial a_i^{(m)}}{\partial \theta^{(k)}} = \sigma'(z_i^{(m)}) \sum_{r=1}^{n_{m-1}} W_{ir}^{(m)} \frac{\partial a_r^{(m-1)}}{\partial \theta^{(k)}}.$$

En forma matricial, $\frac{\partial a^{(m)}}{\partial \theta^{(k)}} = \text{diag}(\sigma'(z^{(m)})) W^{(m)} \frac{\partial a^{(m-1)}}{\partial \theta^{(k)}}$.

Por tanto, el coste de propagar la dependencia desde la capa k hasta la salida es

$$\mathcal{O}\left(\sum_{m=k+1}^L n_m n_{m-1}\right),$$

y en redes densas esto es del orden de $\mathcal{O}(P_w)$ por parámetro de peso.

Como el término dominante corresponde a los P_w pesos, el coste total es $\mathcal{O}(PP_w) \approx \mathcal{O}(P^2)$, inviable para modelos grandes.

Ejemplo 4.1.5. Para modelos del tamaño de GPT-4 ($P \sim 10^{12}$), se tiene $P^2 \sim 10^{24}$ operaciones por gradiente. Los superordenadores actuales alcanzan $\sim 10^{18}$ flops, lo que equivaldría a $\sim 10^6$ segundos (varias semanas) para evaluar un solo gradiente. El entrenamiento es completamente inviable a este coste.

4.1.1.2. Retropropagación: alternativa eficiente

La ineficiencia del enfoque *naive* es que el jacobiano $\partial a^{(L)} / \partial W_{ij}^{(k)}$ se recalcula desde cero para cada parámetro (i, j, k) . Backpropagation evita esta redundancia procesando desde la salida hasta la entrada. Se define la *señal de error* de la capa k como el gradiente de la pérdida respecto a las pre-activaciones:

$$\delta^{(k)} := \nabla_{z^{(k)}} \mathcal{L}(\theta) \in \mathbb{R}^{n_k}.$$

Dado que $z_j^{(k+1)} = \sum_r W_{jr}^{(k+1)} \sigma(z_r^{(k)}) + b_j^{(k+1)}$, la regla de la cadena da $\partial z_j^{(k+1)} / \partial z_i^{(k)} = W_{ji}^{(k+1)} \sigma'(z_i^{(k)})$, y por tanto:

$$\delta_i^{(k)} = \frac{\partial \mathcal{L}}{\partial z_i^{(k)}} = \sum_{j=1}^{n_{k+1}} \delta_j^{(k+1)} \cdot W_{ji}^{(k+1)} \sigma'(z_i^{(k)}).$$

En forma matricial, esto es la recurrencia hacia atrás:

$$\delta^{(k)} = \text{diag}(\sigma'(z^{(k)})) (W^{(k+1)})^\top \delta^{(k+1)}, \quad k = L-1, \dots, 1, \quad (4.1)$$

con condición inicial en la última capa:

$$\delta^{(L)} = \text{diag}(\sigma'(z^{(L)})) \nabla_{a^{(L)}} \ell(a^{(L)}, y). \quad (4.2)$$

Una vez disponibles todos los $\delta^{(k)}$, los gradientes respecto a los parámetros se recuperan mediante productos exteriores. Esta es la parte clave: cada matriz de gradientes se obtiene en tiempo proporcional al número de sus entradas, sin volver a recorrer las capas siguientes:

$$\nabla_{W^{(k)}} \mathcal{L} = \delta^{(k)} (a^{(k-1)})^\top \in \mathbb{R}^{n_k \times n_{k-1}}, \quad \nabla_{b^{(k)}} \mathcal{L} = \delta^{(k)} \in \mathbb{R}^{n_k}, \quad (4.3)$$

lo que se comprueba directamente: $\partial \mathcal{L} / \partial W_{ij}^{(k)} = \delta_i^{(k)} a_j^{(k-1)}$.

El algoritmo completo se estructura en dos fases:

1. *Forward pass*: calcular y almacenar $z^{(k)}, a^{(k)}$ para $k = 0, \dots, L$, y evaluar $\nabla_{a^{(L)}} \ell(a^{(L)}, y)$. Coste: $\mathcal{O}(P)$.
2. *Backward pass*: calcular $\delta^{(L)}$ mediante (4.2) y propagar hacia atrás con (4.1); en cada capa recuperar el gradiente con (4.3). El paso costoso en cada capa k es el producto $(W^{(k+1)})^\top \delta^{(k+1)}$, de coste $\mathcal{O}(n_k n_{k+1})$. Sumando sobre todas las capas, se obtiene

$$\mathcal{O}(\sum_{k=1}^{L-1} n_k n_{k+1}) = \mathcal{O}(P).$$

El coste total de backpropagation es $\mathcal{O}(P)$: el mismo orden que el forward pass, y una mejora de un factor P respecto al enfoque *naive*.

4.2. Teorema de aproximación universal

El objetivo de esta sección es dar una prueba del siguiente Teorema de aproximación universal para MLP de una capa oculta, siguiendo el texto de A. Pinkus, “*Approximation theory of the MLP model in neural networks*”, Acta Numerica 8, 1999.

La prueba de Pinkus se basa en la densidad de las funciones ridge, demostrada en el texto de V. Lin, A. Pinkus, “Fundamentality of ridge functions”. *Journal of Approximation Theory* 75, 1993.

Definición 4.2.1 (Convergencia uniforme en compactos). Sea $X \subset \mathbb{R}^n$, $(f_n)_{n \in \mathbb{N}} \subset \mathcal{C}(X)$ y $f \in \mathcal{C}(X)$, f_n converge a f *uniformemente sobre compactos*

$$\iff \forall K \subseteq X \text{ compacto} : \max_{x \in K} |f_n(x) - f(x)| \xrightarrow{n \rightarrow \infty} 0.$$

Teorema 4.2.2 (de aproximación universal). Sea $\sigma \in \mathcal{C}^\infty(\mathbb{R})$, y sea

$$\mathcal{M}(\sigma) := \text{span} \{f \in \mathcal{C}(\mathbb{R}^m) : f(x) = \sigma(\langle w, x \rangle + b) \wedge w \in \mathbb{R}^m \wedge b \in \mathbb{R}\}.$$

Entonces, $\mathcal{M}(\sigma)$ es denso en $\mathcal{C}(\mathbb{R}^m)$ en la topología de la convergencia uniforme sobre compactos si y solo si σ no es un polinomio.

La primera versión de este teorema fue demostrada por Cybenko en 1989. En esa versión se demuestra que es suficiente que σ sea “sigmoidal”, es decir

$$\sigma \xrightarrow[t \rightarrow -\infty]{} 0 \quad \wedge \quad \sigma \xrightarrow[t \rightarrow +\infty]{} 1.$$

Observación 4.2.3. Este teorema nos habla de la capacidad de aproximación de un MLP con una sola capa oculta que es:

- *Shallow*: solo tiene una capa oculta, es decir, $L = 2$ en la definición 4.1.4.
- *Wide*: la anchura de la capa oculta es arbitrariamente grande, es decir, el hiperparámetro n_1 puede ser tan grande como se quiera.

Por tanto, el teorema no nos dice nada sobre la capacidad de aproximación de MLP con más capas ocultas pero anchuras limitadas, es decir, MLP *deep* pero *narrow*.

4.2.1. Funciones *Ridge*

Definición 4.2.4 (Funciones ridge). Sea $\Omega \subset \mathbb{R}^{d \times n}$ un conjunto de matrices con $d \leq n - 1$

$$R(\Omega) := \text{span} \{ f \in \mathcal{C}(\mathbb{R}^n) : f(x) = g(Ax) \wedge A \in \Omega \wedge g \in \mathcal{C}(\mathbb{R}^d) \}$$

es el espacio de funciones *ridge* con matrices en Ω .

Dados $\Omega \subset \mathbb{R}^{d \times n}$ un conjunto de matrices con $d \leq n - 1$ y $A \in \Omega$, denotaremos por $L(A)$ el espacio de las filas de A , es decir,

$$L(A) = \text{span}\{A_{(1)}, \dots, A_{(d)}\},$$

donde $A_{(i)}$ es la i -ésima fila de A y $L(\Omega)$ es el conjunto de vectores que pertenecen al espacio de filas de alguna matriz de Ω , es decir,

$$L(\Omega) = \bigcup_{A \in \Omega} L(A).$$

La densidad de las funciones ridge en $\mathcal{C}(\mathbb{R}^n)$ se demostrará ser equivalente a la no anulación de los polinomios homogéneos sobre $L(\Omega)$. Por ello, recordamos primero la notación multinomial:

Sea $\underline{m} = (m_1, \dots, m_n) \in \mathbb{N}^n$ un multi-índice, definimos $|\underline{m}| := \sum_{i=1}^n m_i$ y

$$\forall x \in \mathbb{R}^n : \quad x^{\underline{m}} := x_1^{m_1} \cdots x_n^{m_n} \quad \wedge \quad D^{\underline{m}} := \frac{\partial^{|\underline{m}|}}{\partial x_1^{m_1} \cdots \partial x_n^{m_n}}.$$

Definición 4.2.5 (Polinomios homogéneos). Sea $k \in \mathbb{N}$, decimos que H_n^k es el conjunto de *polinomios homogéneos* de grado k en $\mathbb{R}^n$

$$\iff H_n^k := \left\{ \sum_{|\underline{m}|=k} c_{\underline{m}} x^{\underline{m}} : c_{\underline{m}} \in \mathbb{R} \right\}.$$

También $H_n := \bigcup_{k=0}^{\infty} H_n^k$ es el conjunto de todos los polinomios homogéneos en $\mathbb{R}^n$.

Teorema 4.2.6 (Ridge). Sea $\Omega \subset \mathbb{R}^{d \times n}$ con $d \leq n - 1$. Entonces, $R(\Omega)$ es denso en $\mathcal{C}(\mathbb{R}^n)$ en la topología de la convergencia uniforme sobre compactos si y solo si

$$\forall k \in \mathbb{N} : \left[(p \in H_n^k \wedge \forall \xi \in L(\Omega) : p(\xi) = 0) \implies p = 0 \right].$$

Es decir, $R(\Omega)$ es denso en $\mathcal{C}(\mathbb{R}^n)$ si y solo si el único polinomio homogéneo que se anula sobre $L(\Omega)$ es el polinomio nulo.

Demostración: Veamos ambas implicaciones de la equivalencia por separado.

⊆ **Paso 1:** Sea $k \in \mathbb{N}$, veamos que $H_n^k \subset R(\Omega)$. Consideramos el espacio dual de H_n^k :

$$(H_n^k)^* = \{\alpha: H_n^k \rightarrow \mathbb{R} : \alpha \text{ es lineal}\}.$$

Veamos que $(H_n^k)^* = \left\{ \sum_{|\underline{m}|=k} c_{\underline{m}} D^{\underline{m}} : c_{\underline{m}} \in \mathbb{R} \right\}$, donde $D^{\underline{m}} = D_1^{m_1} \cdots D_n^{m_n}$ y D_i es la derivada parcial respecto a la variable x_i .

Observamos que si $|\underline{m}| = |\underline{m}'| = k$, entonces $D^{\underline{m}}(x^{\underline{m}'}) = \begin{cases} k! & \text{si } \underline{m} = \underline{m}', \\ 0 & \text{si } \underline{m} \neq \underline{m}'. \end{cases}$

Por tanto, $\{D^{\underline{m}} : |\underline{m}| = k\}$ es una base de $(H_n^k)^*$.

Ahora, sea $\xi \in L(\Omega)$, consideramos $f_\xi: \mathbb{R}^n \rightarrow \mathbb{R}$ dada por $f_\xi(x) = \langle \xi, x \rangle^k$, veamos que $p(D)f_\xi(x) = k!p(\xi)$ para $p(D) = \sum_{|\underline{m}|=k} c_{\underline{m}} D^{\underline{m}}$ y $p(\xi) = \sum_{|\underline{m}|=k} c_{\underline{m}} \xi^{\underline{m}}$:

$$p(D)f_\xi(x) = \sum_{|\underline{m}|=k} c_{\underline{m}} \underbrace{D^{\underline{m}}(\langle \xi, x \rangle^k)}_{k! \xi^{\underline{m}}} = k! \sum_{|\underline{m}|=k} c_{\underline{m}} \xi^{\underline{m}} = k! p(\xi).$$

Por la hipótesis y la caracterización del espacio dual, el único elemento de $(H_n^k)^*$ que se anula en $f_\xi \in H_n^k$ para todas las $\xi \in L(\Omega)$ es el elemento nulo, es decir, $p(D)f_\xi = 0$ para todo $\xi \in L(\Omega)$ implica $p(D) = 0$. Esto implica que $\text{span}\{f_\xi : \xi \in L(\Omega)\} = H_n^k$.

Para toda $\xi \in L(\Omega)$, $f_\xi \in R(\Omega)$ porque $\exists v_\xi \in \mathbb{R}^d : \xi = A^\top v_\xi$ por definición de $L(\Omega)$, de manera que $f_\xi(x) = (\langle v_\xi, Ax \rangle)^k = g(Ax)$, para $g \in \mathcal{C}(\mathbb{R}^d)$ dada por $g(y) = (\langle v_\xi, y \rangle)^k$. Por tanto $H_n^k \subset R(\Omega)$.

Paso 2: Como $H_n^k \subset R(\Omega)$ para todo $k \in \mathbb{N}$, entonces $R(\Omega)$ contiene todos los polinomios de $\mathbb{R}^n$, porque $\mathbb{R}[x_1, \dots, x_n] = \bigoplus_{k=0}^{\infty} H_n^k$. Por el teorema de Stone-Weierstrass, los polinomios son densos en $\mathcal{C}(\mathbb{R}^n)$ en la topología de la convergencia uniforme sobre compactos, por lo que $R(\Omega)$ también es denso en $\mathcal{C}(\mathbb{R}^n)$.²

⇒ Sea $\phi: \mathcal{C}(\mathbb{R}^n) \rightarrow \mathbb{R}$ un funcional lineal continuo no nulo. Entonces, ϕ no se puede anular en toda $f \in R(\Omega)$ porque, por densidad, $\forall f \in \mathcal{C}(\mathbb{R}^n) : \exists (f_m)_{m \in \mathbb{N}} \subset R(\Omega) : \max_{x \in K} |f_m(x) - f(x)| \xrightarrow{m \rightarrow \infty} 0$ para todo compacto $K \Subset \mathbb{R}^n$, y por continuidad de ϕ , $\phi(f_m) \xrightarrow{m \rightarrow \infty} \phi(f)$.

Por contradicción, supongamos que $\exists p \in H_n^k$ con $p \neq 0$ tal que $\forall \xi \in L(\Omega) : p(\xi) = 0$. Entonces, podemos construir un funcional ϕ continuo que se anule en $R(\Omega)$ y concluir de nuevo por un argumento de dualidad.

Paso 1: Sea $\varphi \in \mathcal{C}_c^\infty(\mathbb{R}^n)$, definimos $\psi_p := p(D)\varphi = \sum_{|\underline{m}|=k} c_{\underline{m}} D^{\underline{m}}\varphi \in \mathcal{C}_c^\infty(\mathbb{R}^n)$, eligiendo

²El teorema de Stone-Weierstrass es uno de los instrumentos más importantes para obtener resultados de densidad. Una prueba se puede encontrar en W. Rudin, *Principles of mathematical analysis*, McGraw Hill, 1976. Chapter 7, Theorem 7.26 and Theorem 7.32.

φ de modo que $\psi_p \not\equiv 0$ (posible porque $p \neq 0$ implica $p(D) \neq 0$), y definimos $\phi: \mathcal{C}(\mathbb{R}^n) \rightarrow \mathbb{R}$ mediante

$$\forall f \in \mathcal{C}(\mathbb{R}^n) : \phi(f) = \int_{\mathbb{R}^n} f(x) \psi_p(x) dx.$$

Entonces, ϕ hereda la linealidad de la integral. Veamos que ϕ es continuo: sea $(f_m)_{m \in \mathbb{N}} \subset \mathcal{C}(\mathbb{R}^n)$ tal que $\max_{x \in K} |f_m(x) - f(x)| \xrightarrow{m \rightarrow \infty} 0$ para todo $K \Subset \mathbb{R}^n$, entonces

$$\begin{aligned} |\phi(f_m) - \phi(f)| &= \left| \int_{\mathbb{R}^n} (f_m(x) - f(x)) \psi_p(x) dx \right| \\ &\leq \int_{\text{supp } \psi_p} |f_m(x) - f(x)| |\psi_p(x)| dx \\ &\leq \max_{x \in \text{supp } \psi_p} |f_m(x) - f(x)| \cdot \int_{\mathbb{R}^n} |\psi_p(x)| dx \xrightarrow{m \rightarrow \infty} 0. \end{aligned}$$

Paso 2: Veamos que ϕ se anula en $R(\Omega)$, es decir, que

$$\forall g \in \mathcal{C}(\mathbb{R}^d), A \in \Omega : \int_{\mathbb{R}^n} g(Ax) \psi_p(x) dx = 0.$$

Para ello, usaremos la transformada de Fourier de ψ_p :

$$\mathcal{F}\psi_p(\eta) = \psi_p^\wedge(\eta) = \int_{\mathbb{R}^n} \psi_p(x) e^{-2\pi i \langle \eta, x \rangle} dx = \sum_{|\underline{m}|=k} c_{\underline{m}} (D^{\underline{m}}\varphi)^\wedge(\eta).$$

Por la propiedad de la transformada de Fourier respecto a las derivadas,

$$(D^{\underline{m}}\varphi)^\wedge(\eta) = (2\pi i)^{|\underline{m}|} \eta^{\underline{m}} \varphi^\wedge(\eta),$$

por lo que $\mathcal{F}\psi_p(\eta) = (2\pi i)^k p(\eta) \varphi^\wedge(\eta)$. En consecuencia, si $\xi \in L(\Omega)$, como $p(\xi) = 0$, entonces $\psi_p^\wedge(\xi) = 0$. Por tanto, la transformada de Fourier de ψ_p se anula en $L(\Omega)$, es decir, $\forall \xi \in L(\Omega) : \psi_p^\wedge(\xi) = 0$.

Por otro lado, fijado $A \in \Omega \subset \mathbb{R}^{d \times n}$, sea $r := \text{rg}(A)$ y sea $\{q_1, \dots, q_r\} \subset \mathbb{R}^n$ una base ortonormal de $L(A)$. Completamos esta familia a una base ortonormal de $\mathbb{R}^n$, $\{q_1, \dots, q_n\}$, y escribimos $Q := [q_1 \cdots q_n] \in O(n)$. Entonces, la proyección ortogonal sobre $L(A)$ verifica

$$P_{L(A)} = Q \begin{bmatrix} I_r & 0 \\ 0 & 0 \end{bmatrix} Q^t.$$

Para $x, z \in \mathbb{R}^n$, definimos las coordenadas rotadas $y := Q^t x = (y', y'')$, $\eta := Q^t z = (\eta', \eta'')$, con $y', \eta' \in \mathbb{R}^r$ y $y'', \eta'' \in \mathbb{R}^{n-r}$. Por ortogonalidad de Q ,

$$\langle x, P_{L(A)} z \rangle = \langle Q^t x, Q^t P_{L(A)} Q Q^t z \rangle = \left\langle y, \begin{bmatrix} I_r & 0 \\ 0 & 0 \end{bmatrix} \eta \right\rangle = \sum_{i=1}^r y_i \eta_i = \langle y', \eta' \rangle_{\mathbb{R}^r}. \quad (*)$$

En particular, si $z \in L(A)$, entonces $P_{L(A)} z = z$ y por tanto $\eta'' = 0$. La igualdad (*)

es precisamente la reducción de la dependencia a las coordenadas de $L(A)$ que se usa a continuación.

Definimos $\psi_p^Q(y) := \psi_p(Qy)$ para $y \in \mathbb{R}^n$. Si $\xi \in L(A)$, entonces $Q^t\xi = (\xi', 0)$ con $\xi' \in \mathbb{R}^r$, y por cambio de variable $x = Qy$ (jacobiano igual a 1):

$$0 = \widehat{\psi_p}(\xi) = \int_{\mathbb{R}^n} \psi_p^Q(y) e^{-2\pi i \langle y, Q^t\xi \rangle} dy = \int_{\mathbb{R}^r} \left(\int_{\mathbb{R}^{n-r}} \psi_p^Q(y', y'') dy'' \right) e^{-2\pi i \langle y', \xi' \rangle} dy'.$$

Definimos $J_p^Q: \mathbb{R}^r \rightarrow \mathbb{R}$ mediante

$$\forall y' \in \mathbb{R}^r : J_p^Q(y') := \int_{\mathbb{R}^{n-r}} \psi_p^Q(y', y'') dy''.$$

Como $\psi_p \in \mathcal{C}_c^\infty(\mathbb{R}^n)$, se tiene $J_p^Q \in \mathcal{C}_c^\infty(\mathbb{R}^r)$. La identidad anterior dice que $\forall \xi' \in \mathbb{R}^r : \widehat{J_p^Q}(\xi') = 0$, pues al variar $\xi \in L(A)$, su bloque de coordenadas ξ' recorre todo $\mathbb{R}^r$. Por inyectividad de la transformada de Fourier en $\mathcal{S}'$ (o, equivalentemente, por inversión de Fourier en $\mathcal{C}_c^\infty$), concluimos que $J_p^Q \equiv 0$ en $\mathbb{R}^r$.

Veamos ahora que ϕ se anula sobre $g \circ A$. Como las filas de A están en $L(A) = \text{span}\{q_1, \dots, q_r\}$, existe $B \in \mathbb{R}^{d \times r}$ tal que $AQ = [B \ 0]$ y, por tanto, si $y = Q^t x = (y', y'')$, entonces $Ax = AQy = By'$. Así, para cualquier $g \in \mathcal{C}(\mathbb{R}^d)$,

$$\begin{aligned} \int_{\mathbb{R}^n} g(Ax) \psi_p(x) dx &= \int_{\mathbb{R}^n} g(AQy) \psi_p(Qy) dy \\ &= \int_{\mathbb{R}^r} g(By') \left(\int_{\mathbb{R}^{n-r}} \psi_p^Q(y', y'') dy'' \right) dy' \\ &= \int_{\mathbb{R}^r} g(By') J_p^Q(y') dy' = 0. \end{aligned}$$

En consecuencia, para todo $A \in \Omega$ y todo $g \in \mathcal{C}(\mathbb{R}^d)$, $\phi(g \circ A) = 0$, es decir, ϕ se anula en $R(\Omega)$. Esto contradice la densidad de $R(\Omega)$ y la continuidad de ϕ . La contradicción prueba que no existe $p \neq 0$ que se anule en $L(\Omega)$; por tanto,

$$(p \in H_n^k \wedge \forall \xi \in L(\Omega) : p(\xi) = 0) \implies p = 0. \quad \blacksquare$$

4.2.2. Demostración del teorema de aproximación universal

Antes de demostrar el teorema de aproximación universal, veamos un resultado auxiliar sobre la densidad de las funciones ridge con matrices de rango 1. Para ello, necesitamos el siguiente resultado de Corominas y Sunyer i Balaguer de 1954:

Teorema 4.2.7. Sea $f \in \mathcal{C}^\infty(\mathbb{R})$ tal que f no es un polinomio, entonces

$$\exists b \in \mathbb{R} : \forall k \in \mathbb{N} : \frac{d^k f}{dx^k}(b) \neq 0.$$

Proposición 4.2.8. Sea $\sigma \in \mathcal{C}(\mathbb{R})$ tal que σ no es un polinomio. Entonces,

$$\mathcal{M}_1(\sigma) := \text{span} \{f \in \mathcal{C}(\mathbb{R}) : f(t) = \sigma(\lambda t + b) \wedge \lambda, b \in \mathbb{R}\}$$

es denso en $\mathcal{C}(\mathbb{R})$ en la topología de la convergencia uniforme sobre compactos.

Demostración: Sea $\varphi \in \mathcal{C}_c^\infty(\mathbb{R})$, entonces $\sigma_\varphi := \sigma * \varphi \in \mathcal{C}^\infty(\mathbb{R})$ y además $\sigma_\varphi \in \mathcal{M}_1$:

$$\sigma_\varphi(t) = \int_{\mathbb{R}} \varphi(s) \sigma(t-s) ds = \int_{\text{supp } \varphi} \varphi(s) \sigma(t-s) ds \stackrel{\text{TYM}}{=} |\text{supp } \varphi| \cdot \varphi(c) \cdot \sigma(t-c)$$

para algún $c \in \text{supp } \varphi$, donde $|\text{supp } \varphi|$ es la medida de Lebesgue del soporte de φ . Por el mismo argumento, $t \mapsto \sigma_\varphi(\lambda t + b)$ también pertenece a $\mathcal{M}_1(\sigma)$ para todo $\lambda, b \in \mathbb{R}$, en particular, $\mathcal{M}_1(\sigma_\varphi) \subset \mathcal{M}_1(\sigma)$.

Como, para cada $\lambda, b \in \mathbb{R}$, la función $t \mapsto \sigma_\varphi(\lambda t + b)$ pertenece a $\mathcal{M}_1(\sigma_\varphi)$, y $\sigma_\varphi \in \mathcal{C}^\infty(\mathbb{R})$, entonces

$$\left. \frac{d}{d\lambda} \sigma_\varphi(\lambda t + b) \right|_{\lambda=0} = t \sigma'_\varphi(b) \in \overline{\mathcal{M}_1(\sigma_\varphi)}.$$

$$\text{En general, } \forall k \in \mathbb{N} : \left. \frac{d^k}{d\lambda^k} \sigma_\varphi(\lambda t + b) \right|_{\lambda=0} = t^k \sigma_\varphi^{(k)}(b) \in \overline{\mathcal{M}_1(\sigma_\varphi)}.$$

Aplicando el teorema 4.2.7 a $f = \sigma_\varphi$, obtenemos que, si σ_φ no es un polinomio, existe $b \in \mathbb{R}$ tal que $\forall k \in \mathbb{N} : \sigma_\varphi^{(k)}(b) \neq 0$.

Supongamos por contradicción que $\mathcal{M}_1(\sigma)$ no es denso en $\mathcal{C}(\mathbb{R})$. Entonces existe $k \in \mathbb{N}$ tal que $t \mapsto t^k \notin \overline{\mathcal{M}_1(\sigma)}$. Como $\mathcal{M}_1(\sigma_\varphi) \subset \mathcal{M}_1(\sigma)$ para todo $\varphi \in \mathcal{C}_c^\infty(\mathbb{R})$, también se tiene $\forall \varphi \in \mathcal{C}_c^\infty(\mathbb{R}) : t \mapsto t^k \notin \overline{\mathcal{M}_1(\sigma_\varphi)}$.

Fijemos $\varphi \in \mathcal{C}_c^\infty(\mathbb{R})$. Si σ_φ no fuese un polinomio, por el Teorema 4.2.7 existiría $b \in \mathbb{R}$ tal que $\sigma_\varphi^{(k)}(b) \neq 0$. Entonces, derivando respecto de λ en la familia $\lambda \mapsto \sigma_\varphi(\lambda t + b)$, obtenemos

$$t^k \sigma_\varphi^{(k)}(b) \in \overline{\mathcal{M}_1(\sigma_\varphi)},$$

y por tanto $t^k \in \overline{\mathcal{M}_1(\sigma_\varphi)}$, contradicción. Luego σ_φ es un polinomio. Además, necesariamente su grado es $\leq k-1$, pues si $\sigma_\varphi^{(k)}(b) \neq 0$ para algún b volveríamos a obtener la contradicción anterior; así pues, $\forall \varphi \in \mathcal{C}_c^\infty(\mathbb{R}) : \sigma_\varphi \in P_{k-1}(\mathbb{R})$.

Tomemos ahora una sucesión de mollificadores $(\varphi_m)_{m \in \mathbb{N}} \subset \mathcal{C}_c^\infty(\mathbb{R})$ con $\int_{\mathbb{R}} \varphi_m = 1$ y $\text{supp}(\varphi_m) \rightarrow \{0\}$; entonces, por el teorema 4.4.2, $\sigma_{\varphi_m} \rightarrow \sigma$ uniformemente sobre compactos. Como $P_{k-1}(\mathbb{R})$ es un subespacio finito-dimensional de $\mathcal{C}(\mathbb{R})$, es cerrado para la

convergencia uniforme sobre compactos; por consiguiente, $\sigma \in P_{k-1}(\mathbb{R})$, es decir, σ es un polinomio. Contradicción. ■

Ahora, estamos en condiciones de demostrar el teorema de aproximación universal.

Demostración (del teorema de aproximación universal):

$\Rightarrow$ Sea $\sigma \in \mathcal{C}(\mathbb{R})$ distinto de un polinomio y sean $f \in \mathcal{C}(\mathbb{R}^m)$, $\varepsilon > 0$ y $K \subseteq \mathbb{R}^m$ compacto. Veamos que $\exists \{W_i\}_{i=1}^s \subset \mathbb{R}^m$, $\{b_i\}_{i=1}^s \subset \mathbb{R}$ y $\{c_i\}_{i=1}^s \subset \mathbb{R}$ tales que

$$\forall x \in K : \left| f(x) - \sum_{i=1}^s c_i \sigma(\langle W_i, x \rangle + b_i) \right| < \varepsilon.$$

Sea $R := \{x \mapsto g(\langle \theta, x \rangle) : g \in \mathcal{C}(\mathbb{R}), \theta \in \mathbb{S}^{m-1} \subset \mathbb{R}^m\}$. Entonces, como el único polinomio homogéneo que se anula en todo $\mathbb{S}^{m-1}$ es el nulo, por el teorema 4.2.6 (con $d = 1$), R es denso en $\mathcal{C}(\mathbb{R}^m)$ en la topología de la convergencia uniforme sobre compactos. Por tanto, $\exists N \in \mathbb{N}$, $\{\theta_k\}_{k=1}^N \subset \mathbb{S}^{m-1}$ y $\{g_k\}_{k=1}^N \subset \mathcal{C}(\mathbb{R})$ tales que

$$\forall x \in K : \left| f(x) - \sum_{k=1}^N g_k(\langle \theta_k, x \rangle) \right| < \frac{\varepsilon}{2}. \quad (\text{R})$$

Como K es compacto, para cada $k \in \mathbb{N}_N$ el conjunto $\theta_k \cdot K := \{\langle \theta_k, x \rangle : x \in K\}$ es un compacto de $\mathbb{R}$, luego queda contenido en algún intervalo cerrado $[\alpha_k, \beta_k]$. Por la proposición 4.2.8, para cada $k \in \mathbb{N}_N$, $\exists s_k \in \mathbb{N}$ y $\{c_j^{(k)}, \lambda_j^{(k)}, b_j^{(k)}\}_{j=1}^{s_k} \subset \mathbb{R}$ tales que

$$\forall t \in [\alpha_k, \beta_k] : \left| g_k(t) - \sum_{j=1}^{s_k} c_j^{(k)} \sigma(\lambda_j^{(k)} t + b_j^{(k)}) \right| < \frac{\varepsilon}{2N}. \quad (\text{M})$$

Por tanto, juntando R y M, obtenemos que $\forall x \in K$:

$$\begin{aligned} & \left| f(x) - \sum_{k=1}^N \sum_{j=1}^{s_k} c_j^{(k)} \sigma(\lambda_j^{(k)} \langle \theta_k, x \rangle + b_j^{(k)}) \right| = \\ & = \left| f(x) - \sum_{k=1}^N g_k(\langle \theta_k, x \rangle) + \sum_{k=1}^N g_k(\langle \theta_k, x \rangle) - \sum_{k=1}^N \sum_{j=1}^{s_k} c_j^{(k)} \sigma(\lambda_j^{(k)} \langle \theta_k, x \rangle + b_j^{(k)}) \right| \leq \\ & \leq \left| f(x) - \sum_{k=1}^N g_k(\langle \theta_k, x \rangle) \right| + \sum_{k=1}^N \left| g_k(\langle \theta_k, x \rangle) - \sum_{j=1}^{s_k} c_j^{(k)} \sigma(\lambda_j^{(k)} \langle \theta_k, x \rangle + b_j^{(k)}) \right| < \\ & < \frac{\varepsilon}{2} + \sum_{k=1}^N \frac{\varepsilon}{2N} = \varepsilon. \end{aligned}$$

Así, hemos obtenido la aproximación deseada con

$$s = \sum_{k=1}^N s_k, \quad W_{k,j} = \lambda_j^{(k)} \theta_k, \quad b_{k,j} = b_j^{(k)}, \quad c_{k,j} = c_j^{(k)},$$

para $k \in \mathbb{N}_N$ y $j \in \mathbb{N}_{s_k}$, es decir, con pesos escritos en coordenadas polares.

$\boxed{\Leftarrow}$ Supongamos que σ es un polinomio de grado N . Entonces, para cualesquiera $s \in \mathbb{N}$, $\{w_i\}_{i=1}^s \subset \mathbb{R}^m$, $\{b_i\}_{i=1}^s \in \mathbb{R}$ y $\{c_i\}_{i=1}^s \in \mathbb{R}$, se tiene que

$$\sum_{i=1}^s c_i \sigma(\langle w_i, x \rangle + b_i)$$

es un polinomio en $x \in \mathbb{R}^m$ de grado a lo sumo N . En particular, $\mathcal{M}(\sigma) \subseteq P_N(\mathbb{R}^m)$, donde $P_N(\mathbb{R}^m)$ denota el subespacio de polinomios de grado menor o igual que N .

Como $P_N(\mathbb{R}^m)$ es finito-dimensional, es cerrado para la topología de la convergencia uniforme sobre compactos. Por tanto, su cierre coincide con él mismo, y no puede ser denso en $\mathcal{C}(\mathbb{R}^m)$, que contiene funciones que no son polinomios, por ejemplo $e^{-\|x\|^2}$. Luego $\mathcal{M}(\sigma)$ no es denso en $\mathcal{C}(\mathbb{R}^m)$. ■

4.2.3. Capacidad de interpolación

La capacidad de interpolación de los MLPs es otra consecuencia de la proposición 4.2.8.

Teorema 4.2.9. *Sea $\sigma \in \mathcal{C}(\mathbb{R})$ tal que σ no es un polinomio. Entonces, $\forall \mathcal{D} = \{(x_i, y_i)\}_{i=1}^N \subset \mathbb{R}^m \times \mathbb{R}$ con $x_i \neq x_j$ para $i \neq j$, $\exists \{W_j\}_{j=1}^N \subset \mathbb{R}^m$, $\{b_j\}_{j=1}^N \subset \mathbb{R}$, $\{c_j\}_{j=1}^N \subset \mathbb{R}$ tales que*

$$\forall i \in \mathbb{N}_N : y_i = \sum_{j=1}^N c_j \sigma(\langle W_j, x_i \rangle + b_j).$$

Demostración: En dimensión 1, sean $\{t_i\}_{i=1}^N \subset \mathbb{R}$ tal que $t_i \neq t_j$ si $i \neq j$. Veamos que las funciones $\{F_i\}_{i=1}^N \subset \mathcal{C}(\mathbb{R}^2)$ dadas por $F_i(\lambda, b) = \sigma(\lambda t_i + b)$ son linealmente independientes. Si, por contradicción, no lo fuesen, entonces existiría $d \in \mathbb{R}^N \setminus \{0\}$ tal que

$$\forall \lambda, b \in \mathbb{R} : \sum_{i=1}^N d_i F_i(\lambda, b) = 0.$$

En este caso, sea $\phi_d \in (\mathcal{C}(\mathbb{R}))^*$ el funcional dado por $\forall f \in \mathcal{C}(\mathbb{R}) : \phi_d(f) = \sum_{i=1}^N d_i f(t_i)$.

Entonces, ϕ_d es continuo: sea $\{f_j\} \subset \mathcal{C}(\mathbb{R})$, $f \in \mathcal{C}(\mathbb{R})$ tal que $\max_{t \in K} |f_j(t) - f(t)| \xrightarrow{j \rightarrow \infty} 0$

para todo compacto $K \subseteq \mathbb{R}$, entonces, en particular,

$$|\phi_d(f_j) - \phi_d(f)| \leq \sum_{i=1}^N |d_i| \cdot |f_j(t_i) - f(t_i)| \leq \max_{t \in \{t_i\}_{i=1}^N} |f_j(t) - f(t)| \sum_{i=1}^N |d_i| \xrightarrow{j \rightarrow \infty} 0.$$

Este funcional sería no nulo, pero se anularía en $M_1(\sigma) = \text{span}\{t \mapsto \sigma(\lambda t + b) : \lambda, b \in \mathbb{R}\}$ que es denso porque σ no es un polinomio: contradicción.

Veamos ahora que, como consecuencia, existen $\{(\lambda_j, b_j)\}_{j=1}^N \subset \mathbb{R}^2$ tales que los vectores

$$v^{(j)} := \begin{pmatrix} F_1(\lambda_j, b_j) \\ \vdots \\ F_N(\lambda_j, b_j) \end{pmatrix} = \begin{pmatrix} \sigma(\lambda_j t_1 + b_j) \\ \vdots \\ \sigma(\lambda_j t_N + b_j) \end{pmatrix} \in \mathbb{R}^N, \quad j \in \mathbb{N}_N,$$

son linealmente independientes. Lo probamos por inducción sobre $m \in \mathbb{N}_N$:

1. Para $m = 1$, tomamos (λ_1, b_1) con $v^{(1)} \neq 0$.
2. Supongamos contruidos $(\lambda_j, b_j)_{j=1}^m$, con $m < N$, tales que $v^{(1)}, \dots, v^{(m)}$ son linealmente independientes. Sea $V_m := \text{span}\{v^{(1)}, \dots, v^{(m)}\} \subset \mathbb{R}^N$ y tomemos $d \in V_m^\perp \setminus \{0\}$. Como $F_1, \dots, F_N$ son linealmente independientes, existe $(\lambda, b) \in \mathbb{R}^2$ tal que $\sum_{i=1}^N d_i F_i(\lambda, b) \neq 0$. Definiendo

$$v^{(m+1)} := (F_1(\lambda, b), \dots, F_N(\lambda, b)),$$

se tiene $\langle d, v^{(m+1)} \rangle \neq 0$, luego $v^{(m+1)} \notin V_m$ y por tanto $v^{(1)}, \dots, v^{(m+1)}$ son linealmente independientes.

Con estos parámetros, la matriz $A \in \mathbb{R}^{N \times N}$ dada por $A_{ij} = \sigma(\lambda_j t_i + b_j)$ tiene columnas $v^{(1)}, \dots, v^{(N)}$ linealmente independientes, por tanto A es invertible. En consecuencia, para todo $y = (y_1, \dots, y_N) \in \mathbb{R}^N$ existe $c = (c_1, \dots, c_N) \in \mathbb{R}^N$ tal que

$$\forall i \in \mathbb{N}_N : \sum_{j=1}^N c_j \sigma(\lambda_j t_i + b_j) = y_i. \quad (I_1)$$

Pasemos al caso general en $\mathbb{R}^m$. Elegimos $w \in \mathbb{R}^m$ tal que $\langle w, x_i \rangle \neq \langle w, x_j \rangle$ para $i \neq j$. Un tal w existe porque para cada par $i \neq j$ el conjunto

$$H_{ij} := \{w \in \mathbb{R}^m : \langle w, x_i - x_j \rangle = 0\}$$

es un hiperplano propio, y como hay finitos pares (i, j) , la unión $\bigcup_{i < j} H_{ij}$ no puede cubrir todo $\mathbb{R}^m$. Tomamos entonces N números reales $t_i := \langle w, x_i \rangle$, que son todos distintos.

Aplicando (I_1) , obtenemos

$$\forall i \in \mathbb{N}_N : y_i = \sum_{j=1}^N c_j \sigma(\lambda_j t_i + b_j) = \sum_{j=1}^N c_j \sigma(\lambda_j \langle w, x_i \rangle + b_j),$$


Definiendo $W_j := \lambda_j w \in \mathbb{R}^m$, queda $\forall i \in \mathbb{N}_N : y_i = \sum_{j=1}^N c_j \sigma(\langle W_j, x_i \rangle + b_j)$. ■

4.3. Funciones de activación de uso común

Presentamos brevemente algunas activaciones habituales en la práctica.

ReLU. Consideramos la función de activación dada por

$$\sigma(t) = \max\{t, 0\}.$$



Es la activación más utilizada en capas ocultas por su bajo coste computacional y por producir representaciones dispersas (muchas coordenadas nulas). Además, deja pasar sin deformación los valores positivos.


Ejemplo 4.3.1. Si descomponemos una entrada en bloques como $x = (x', x'')$, una capa puede actuar solo sobre una parte de la señal:

$$\begin{pmatrix} x' \\ x'' \end{pmatrix} \mapsto \begin{pmatrix} \sigma(Wx') \\ x'' \end{pmatrix}.$$

Si x'' ya contiene información adecuada, no es necesario transformarla de nuevo.

Leaky ReLU. Una variante de ReLU es la función de activación dada por


$$\sigma(t) = \begin{cases} t, & t > 0, \\ \varepsilon t, & t \leq 0, \end{cases} \quad 0 < \varepsilon \ll 1.$$



Introduce una pendiente pequeña en la zona negativa para mitigar el problema de *dying ReLU* (neuronas que quedan inactivas de forma persistente).

Sigmoide logística. Otra función de activación clásica es la dada por


$$\sigma(t) = \frac{1}{1 + e^{-\lambda(t-t_0)}}.$$



Es una función suave ($\mathcal{C}^\infty$), saturada en 0 y 1, con umbral controlado por t_0 y pendiente local controlada por λ . Su codominio $[0, 1]$ permite interpretación probabilística. Su principal inconveniente en redes profundas es la saturación, que puede provocar gradientes muy pequeños en capas intermedias (*vanishing gradients*).

Tangente hiperbólica. Otra función de activación suave es la dada por

$$\sigma(t) = \tanh(t).$$



Es análoga a la logística, pero con salida en $[-1, 1]$, lo que puede facilitar cierto centrado de activaciones. Aun así, también sufre saturación en los extremos.

En la práctica moderna, ReLU y sus variantes suelen preferirse en capas ocultas frente a logística y tanh.

4.3.1. Softmax en salida multiclase

Para clasificación multiclase, si la red produce $y \in \mathbb{R}^K$, la salida suele transformarse mediante

$$\text{Softmax}(y)_i = \frac{e^{y_i}}{\sum_{j=1}^K e^{y_j}}, \quad i = 1, \dots, K.$$

Equivalente en forma vectorial:
$$\text{Softmax} \begin{pmatrix} y_1 \\ \vdots \\ y_K \end{pmatrix} = \frac{1}{\sum_{j=1}^K e^{y_j}} \begin{pmatrix} e^{y_1} \\ \vdots \\ e^{y_K} \end{pmatrix}.$$

Si $p = \text{Softmax}(y)$, entonces $p_i \in [0, 1]$ para todo i y $\sum_{i=1}^K p_i = 1$, de modo que p_i puede interpretarse como probabilidad de la clase i .

Una medida habitual del error entre una distribución objetivo p y una predicción q es la divergencia de Kullback–Leibler:

$$D_{\text{KL}}(p, q) = \sum_{i=1}^K p_i \log \frac{p_i}{q_i} = - \sum_{i=1}^K p_i \log q_i - \left(- \sum_{i=1}^K p_i \log p_i \right).$$

Por tanto, $D_{\text{KL}}(p, q) = H(p, q) - H(p)$, donde $H(p, q)$ es la entropía cruzada y $H(p)$ la entropía de p . En particular, si p está fija, minimizar $D_{\text{KL}}(p, q)$ equivale a minimizar la entropía cruzada.

4.4. Apéndice: Modificadores de Friedrichs

Tomamos una función $\varphi \in \mathcal{C}_c^\infty(\mathbb{R}^d)$ tal que $\text{supp}(\varphi) \subset B(0, 1)$, $\varphi \geq 0$ y $\varphi \not\equiv 0$.

Ejemplo 4.4.1. Un ejemplo estándar es $\varphi(x) = \begin{cases} \exp\left(-\frac{1}{1-|x|^2}\right), & |x| < 1, \\ 0, & |x| \geq 1. \end{cases}$

Definimos la constante de normalización $c := \left(\int_{\mathbb{R}^d} \varphi(x) \, dx\right)^{-1}$ y, para cada $m \in \mathbb{N}$, el reescalado $\varphi_m(x) := c m^d \varphi(mx)$. La familia $\{\varphi_m\}_{m \in \mathbb{N}} \subset \mathcal{C}_c^\infty(\mathbb{R}^d)$ (mollificadores o modificadores de Friedrichs) satisface:

1. $\text{supp}(\varphi_m) \subset B(0, \frac{1}{m})$.
2. $\int_{\mathbb{R}^d} \varphi_m(x) \, dx = 1$.

Teorema 4.4.2 (Friedrichs). Sea $f \in \mathcal{C}(\mathbb{R}^d)$ y $K \Subset \mathbb{R}^d$ compacto. Entonces

$$\max_{x \in K} |(f * \varphi_m)(x) - f(x)| \xrightarrow{m \rightarrow \infty} 0.$$

Demostración: Fijamos $f \in \mathcal{C}(\mathbb{R}^d)$ y $K \Subset \mathbb{R}^d$ compacto. Para $x \in \mathbb{R}^d$,

$$\begin{aligned} (f * \varphi_m)(x) - f(x) &= \int_{\mathbb{R}^d} f(x-y) \varphi_m(y) \, dy - f(x) \int_{\mathbb{R}^d} \varphi_m(y) \, dy \\ &= \int_{\mathbb{R}^d} (f(x-y) - f(x)) \varphi_m(y) \, dy \\ &= \int_{B(0, 1/m)} (f(x-y) - f(x)) \varphi_m(y) \, dy, \end{aligned}$$

donde en la última igualdad usamos $\text{supp}(\varphi_m) \subset B(0, 1/m)$.

Sea $K_1 := K + \overline{B(0, 1)}$, que es compacto. Como f es continua en K_1 , es uniformemente continua en K_1 . Por tanto, dado $\varepsilon > 0$, existe $\delta > 0$ tal que $u, v \in K_1$, $|u - v| < \delta \implies |f(u) - f(v)| < \varepsilon$. Tomamos $m_0 \in \mathbb{N}$ con $1/m_0 < \delta$. Si $m \geq m_0$, $x \in K$ y $y \in B(0, 1/m)$, entonces $x, x-y \in K_1$ y $|(x-y) - x| = |y| < \delta$, luego $|f(x-y) - f(x)| < \varepsilon$. De aquí,

$$\begin{aligned} |(f * \varphi_m)(x) - f(x)| &\leq \int_{B(0, 1/m)} |f(x-y) - f(x)| \varphi_m(y) \, dy \\ &\leq \varepsilon \int_{B(0, 1/m)} \varphi_m(y) \, dy = \varepsilon. \end{aligned}$$

Como esta cota es uniforme en $x \in K$, concluimos $\max_{x \in K} |(f * \varphi_m)(x) - f(x)| \leq \varepsilon$ para todo $m \geq m_0$, y por tanto la convergencia uniforme sobre K . ■

5. Aprendizaje por refuerzo

5.1. Introducción y planteamiento del problema

El objetivo del aprendizaje por refuerzo es aprender una tarea por maximización de unas recompensas, y no por optimización de un criterio a priori como en el aprendizaje no supervisado, o por minimización de un error de regresión como en el aprendizaje supervisado.

La formalización exacta más general de este problema es dada por la **programación dinámica (Dynamic Programming, DP)**, que expresa el objetivo del aprendizaje como una estrategia, llamada *política*, para controlar un sistema dinámico conocido, posiblemente estocástico, que evoluciona sobre un espacio de estados conocido. Esta política se quiere que sea óptima respecto a la obtención de recompensas otorgadas por un mecanismo conocido, que no se puede controlar. Las recompensas dependen en general de la trayectoria que sigue el sistema, y los controles óptimos son los que hacen que el sistema pase por los estados en los que puede recoger más recompensas.

El DP permite obtener las soluciones/estrategias óptimas como puntos fijos de ecuaciones deducidas por Bellman en los años 50. La principal dificultad del DP es la llamada "maldición de la dimensionalidad", terminología introducida por el mismo Bellman: en espacios de dimensión grande, la solución requiere evaluar la recompensa esperada (el *valor*) en una cantidad de estados que crece de forma exponencial con la dimensión del espacio. Esto hace que, en dimensión muy alta, la solución exacta del DP sea inviable computacionalmente.

Ejemplo 5.1.1. Un ejemplo de problema que suele resolverse bien con DP es la gestión de un almacén. El espacio de los estados posibles de un almacén no suele ser muy grande, la dinámica de evolución estocástica de compra de los clientes se puede en muchas situaciones deducir con buena precisión, y las recompensas (o las penalizaciones) se pueden diseñar manualmente si se tiene una estimación de lo que cuesta no vender un producto y tener que tirarlo, y de lo que cuesta no tener un producto cuando los clientes lo quieren. La política de compras del almacén se puede optimizar con la programación dinámica a partir de estos datos, y obtener la solución de máxima recompensa de las ecuaciones de Bellman.

Ejemplo 5.1.2. Un ejemplo de problema que se puede plantear de forma exacta en DP, pero que nunca se va a poder resolver, es el ajedrez. La dinámica es conocida, y las recompensas se pueden asignar por ejemplo al ganar un partido, o con asignación de puntos para batallas locales. Pero el espacio de los estados posibles en un tablero de ajedrez es

computacionalmente inviable, y no es posible resolver de forma exacta las ecuaciones de Bellman.

El aprendizaje por refuerzo (**Reinforcement Learning, RL**) se puede pensar como un conjunto de técnicas para aproximar la programación dinámica, intentando reducir el número de estados que se requiere explorar y vencer así la maldición de la dimensionalidad. Estas técnicas incluyen el uso de redes neuronales, diseñadas para tener una estructura apta a representar bien los estados y por tanto a obtener de forma explícita o implícita una reducción de la dimensionalidad.

Ejemplo 5.1.3. Un ejemplo de éxito del RL ha sido el juego del GO, cuyo espacio de los estados posibles (configuraciones del tablero) es mucho más grande del ajedrez. En 2016 por primera vez un jugador de GO artificial (AlphaGO de DeepMind, Google) ha ganado sobre humanos. Lo ha hecho con la creación de una función de evaluación de posiciones, capaz de asignar un valor a las configuraciones sobre el tablero, basada en ciertos tipos de redes neuronales convolucionales, y entrenada sobre miles de partidos jugados por expertos. Esto ha permitido reducir el número de estados a considerar para obtener políticas eficaces hasta un nivel computacionalmente viable. El año siguiente, AlphaZero ha mejorado el rendimiento de AlphaGO con un jugador que ha aprendido únicamente a partir de partidas jugadas contra versiones de sí mismo, y sin ninguna información externa.

El RL ataca también problemas en los que las reglas de evolución del sistema dinámico no se conocen de forma explícita. En este caso, la única posibilidad para conocer de forma exacta las recompensas recogidas a lo largo de una trayectoria es recorrer toda la trayectoria (al recorrido completo de una trayectoria se le llama rollout). En espacios de dimensión grande, si hay que proceder por exploración con rollouts, además de la maldición computacional aumenta de forma exponencial también el número de trayectorias posibles que habría que comprobar para ver cuál es la mejor. Esta es una maldición estadística: el espacio a muestrear requiere una cantidad inviable de experimentos para obtener una representación completa. La consecuencia de tener muchas posibilidades de evolución a partir de cada estado es una exploración dispersa, y escasas indicaciones sobre las recompensas.

Ejemplo 5.1.4. Ejemplos de éxito del RL en contextos de alta dimensionalidad sin conocer la evolución exacta del sistema dinámico se dan en la robótica. Dos casos que se solucionan con técnicas distintas son la locomoción robótica (como en los robots que hoy se ven saltar, correr y hasta jugar al fútbol con cierto éxito) y la robótica de precisión, como las manipulaciones automáticas de objetos. En ambos casos no se impone un modelo de evolución (pese a ser esto posible, conociendo la masa del robot y las propiedades de sus

articulaciones y de sus motores).

Hay varias soluciones para el problema de dimensionalidad relativo al muestreo de trayectorias. Una consiste en la construcción de modelos que aproximan la evolución del sistema (*model-based*, MBRL) a partir de rollouts en los que se observa la evolución real: esto reduce la complejidad muestral ya que proporciona una dinámica que, pese a tener que actualizarse a lo largo del aprendizaje, permite mantener un comportamiento parecido al caso en el que se conoce la dinámica. Este es el enfoque de la técnica *Dreamer*, que hace RL basándose en trayectorias que “sueña” con su modelo del mundo. El MBRL se usa en la robótica de precisión, aprendiendo por ejemplo los movimientos de un objeto en el espacio como consecuencia de las acciones de una mano robótica. Otro enfoque es aprender directamente de las simulaciones reales (*model-free*, MFRL) lo que requiere mucha ingeniería y donde todavía hay pocas garantías matemáticas. Pero estos métodos están ganando en la actualidad como los mejores métodos para la locomoción robótica.

Una diferencia fundamental entre el DP y el RL, independientemente de si se conoce o no la dinámica del sistema, es la necesidad de explorar. En el DP, la política óptima se calcula planificando sobre el espacio de estados completo antes de actuar. En el RL, el agente aprende mientras actúa, y se enfrenta a un dilema permanente: explorar el conocimiento acumulado eligiendo las acciones que hasta ahora han dado mejores recompensas, o explorar estados y acciones nuevos que podrían resultar mejores pero cuya recompensa es incierta. Una política demasiado explotadora queda atrapada en óptimos locales; una demasiado exploradora aprende lentamente y acumula recompensas bajas durante el aprendizaje. Gestionar este equilibrio es uno de los problemas centrales del RL, y no tiene análogo en el DP.

5.2. Programación Dinámica *Dynamic Programming*

Definición 5.2.1 (Proceso de decisión de Markov). Un proceso de decisión de Markov (MDP por sus siglas en inglés) describe la dinámica de un agente que toma decisiones para controlar sus movimientos, y recibe recompensas como consecuencia. Veremos únicamente el caso estacionario, en el que las propiedades del sistema no dependen del tiempo.

Formalmente, se trata de una 4-tupla (S, A, R, p) donde:

- S es un conjunto numerable no vacío llamado espacio de los **estados**.
- A es un conjunto numerable no vacío llamado espacio de las **acciones**.
- R es una función $R: S \times A \rightarrow \mathbb{R}$ llamada función de recompensa. Para cada $s \in S$ y

$a \in A$, $R(s, a) \in \mathbb{R}$ es la recompensa que recibe el agente al tomar la acción a en el estado s .

- p es una función $p: S \times A \rightarrow \mathcal{P}(S)$ llamada dinámica del sistema. Aquí $\mathcal{P}(S)$ denota el conjunto de distribuciones de probabilidad sobre S . De esta manera, para $s, s' \in S$ y $a \in A$, $p(s' | s, a) := p(s, a)(s')$ es la probabilidad de moverse al estado s' desde el estado s si se toma la decisión de hacer la acción a .

Definición 5.2.2. Decimos que la dinámica de un MDP es **determinista** si para cada $s \in S$ y $a \in A$ existe un único estado $s' \in S$ tal que $p(s' | s, a) = 1$. En este caso, se puede escribir $p(s' | s, a) = \mathbb{1}_{\{s'=F(s,a)\}}$ para alguna función $F: S \times A \rightarrow S$.

Definición 5.2.3 (Historial). Dado un MDP (S, A, R, p) , un historial de $T \in \mathbb{N}$ pasos es una sucesión de estados y acciones de la forma $h_T = (s_0, a_0, s_1, a_1, \dots, s_{T-1}, a_{T-1}, s_T)$ donde $s_t \in S$ y $a_t \in A$ para cada $t = 0, \dots, T-1$.

Definición 5.2.4 (Política). Dado un MDP (S, A, R, p) , una política π es una función $\pi: S \rightarrow \mathcal{P}(A)$ que asigna a cada estado $s \in S$ una distribución de probabilidad sobre las acciones disponibles en ese estado. Es decir, $\pi(a | s) := \pi(s)(a)$ es la probabilidad de tomar la acción a cuando el sistema se encuentra en el estado s .

Observación 5.2.5. La probabilidad de proceder por un historial h_T es

$$p(h_T) := \rho_0(s_0) \prod_{t=1}^T p(s_t | s_{t-1}, a_{t-1}) \pi(a_{t-1} | s_{t-1}),$$

donde $\rho_0 \in \mathcal{P}(S)$ es la distribución inicial de estados.

Ejemplo 5.2.6. Gestión de un almacén con d tipos de productos y capacidad N de cada tipo. Cada día es un paso temporal del mismo MDP estacionario: la dinámica y las recompensas no cambian con el día.

- **Estados:** $S = \{0, 1, \dots, N\}^d$, donde $s \in S$ representa el inventario al final del día.
- **Acciones:** $A = \{0, 1, \dots, N\}^d$, donde $a \in A$ es la cantidad que se decide comprar al inicio del día.
- **Acciones factibles:** en un estado s , solo son factibles las acciones que respetan la capacidad,

$$a_i + s_i \leq N, \quad i = 1, \dots, d.$$

Para mantener la definición con A fijo, se impone que la política asigne probabilidad

0 a las acciones no factibles; de manera equivalente, se puede hablar del subconjunto $A(s) \subseteq A$ de acciones factibles en s .

- **Probabilidad de transición:** $p(s' \mid s, a)$ es la probabilidad de terminar el día con inventario s' si se parte de s y se toma la acción a . Se obtiene a partir de un modelo probabilista de la demanda diaria, que determina cómo el inventario disponible $s + a$ se transforma en el inventario final s' .
- **Recompensa:** beneficio económico del día (ventas menos costes), incluyendo penalizaciones por productos no vendidos que se tiran y, si procede, por faltantes.

Ejemplo 5.2.7. Ajedrez (un agente vs un adversario).

Estados: S , configuración del tablero, color, accesibilidad (enroque, 50 movimientos, captura al paso). Esto puede depender del historial de la partida.

Acciones posibles: A , conjunto total de los movimientos admisibles. En cada estado $s \in S$, solo un subconjunto $A(s) \subseteq A$ es accesible, lo cual está codificado en la política.

Probabilidad de transición: La transición $s, a \rightarrow s'$ no es determinista, ya que después del movimiento del agente, el adversario tiene que mover. Si el adversario usa una estrategia determinista, o si el agente no tiene conocimiento del adversario, el MDP tiene una $p(s' \mid s, a)$ no determinista.

Recompensa: La recompensa real es 1 si se gana, 0 si se empata y -1 si se pierde. Maximizarla significa, para el agente que se encuentra en el estado s , tomar la acción a que maximiza la esperanza de ganar.

El valor $V(s)$ de un estado s es la esperanza de ganar a partir de allí:

$$V(s) = \max_{a \in A(s)} \sum_{s'} V(s') p(s' \mid s, a).$$

La acción óptima es la que maximiza el valor del estado al que lleva:

$$a^*(s) = \arg \max_{a \in A(s)} \sum_{s'} V(s') p(s' \mid s, a).$$

En la falta de información sobre p , y en la construcción heurística de V , están las limitaciones conceptuales del DP para el ajedrez.

La información proporcionada por la recompensa real es dispersa: el RL clásico hace "reward shaping"

- asignar una recompensa a la transición $s \rightarrow s'$ en la forma $r(s, s') = V(s') - V(s)$
- definir $R(s, a) = \sum_{s'} r(s, s')p(s' | s, a)$
- calcular la acción óptima como la que maximiza la función de acción-valor

$$a^*(s) = \arg \max_{a \in A(s)} \left[R(s, a) + \sum_{s'} V(s')p(s' | s, a) \right]$$

El reward shaping se ha abandonado en los casos en los que se tiene una buena manera para construir una función valor heurística, porque

Ejemplo 5.2.8. Centipole problem.

$$s = (x, \dot{x}, \theta, \dot{\theta}) \in \mathbb{R}^2 \times S^1 \times \mathbb{R}$$

- El espacio de los estados del problema de DP es una discretización del espacio físico de las configuraciones.
- Recompensa $R(s) = \chi_{[0, \theta_0]}(\theta) \cdot (1 + 0,1 \cdot |\dot{\theta}|)$: recompensa 1 en cada paso que mantiene la barra en posición vertical: $|\theta| < \theta_0$.
- Acciones = $\{L, R\}$: impulsos hacia izq. o der.
- La dinámica es determinista: es la discretización de la ley de Newton $\implies p(s' | s, a) = \mathbb{1}_{s'=f(s,a)}$.

Definición 5.2.9 (Valor de una política). Sea (S, A, R, P) un MDP y sea $\Pi : S \rightarrow \mathcal{P}(A)$.

Dados $s \in S$, $\gamma \in (0, 1]$, definimos

$$V^\Pi(s) = \mathbb{E}_{\mu \sim \Pi} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \mid s_0 = s \right].$$

El valor de la política Π pesa un problema de duración ("horizonte") posiblemente infinita. Si $T = \infty$, un factor de descuento $\gamma < 1$ garantiza convergencia, y significa pesar menos las recompensas lejanas en el tiempo.

Observación 5.2.10. Si $R \in L^\infty(S \times A)$, entonces $V^\Pi \in L^\infty(S)$, porque

$$|V^\Pi(s)| \leq \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t |R(s_t, a_t)| \right] \leq \frac{\|R\|_\infty}{1 - \gamma}.$$

Siempre supondremos $R \in L^\infty(S \times A)$.

En problemas como el ajedrez, $T < \infty$ pero no hay una duración serie predeterminada. Estos casos se denominan "episódicos" y se puede tratar poniendo $\gamma = 1$ y definiendo un conjunto de estados finales ("absorbing states") $S_F \subset S$ tales que

$$p(s' \mid s, a) = 0, \quad R(s, a) = 0 \quad \forall s \in S_F.$$

Definición 5.2.11 (Política óptima). $\Pi^* : S \rightarrow \mathcal{P}(A)$ es una política óptima si

$$V^{\Pi^*}(s) = \sup_{\Pi: S \rightarrow \mathcal{P}(A)} V^{\Pi}(s), \quad \forall s \in S.$$

Nota: No siempre existe Π^* , ya que $\sup \neq \text{máx.}$ “

Teorema 5.2.12 (Bellman "backup"). V^{Π} es la única solución acotada de

$$V^{\Pi}(s) = \sum_{a \in A} \Pi(a \mid s) \left[R(s, a) + \gamma \sum_{s' \in S} p(s' \mid s, a) V^{\Pi}(s') \right], \quad \forall s \in S.$$

Demostración:

- Veamos primero que V^{Π} es punto fijo del operador de backup de Bellman:

$$\begin{aligned} T^{\Pi}u(s) &= \sum_{a \in A} \Pi(a \mid s) \left[R(s, a) + \gamma \sum_{s' \in S} p(s' \mid s, a) u(s') \right]. \\ V^{\Pi}(s) &= \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \mid s_0 = s \right] \\ &= \mathbb{E} \left[R(s_0, a_0) + \gamma \sum_{t=1}^{\infty} \gamma^{t-1} R(s_t, a_t) \mid s_0 = s \right] \\ &= \sum_{a \in A} \Pi(a \mid s) R(s, a) + \gamma \sum_{a \in A} \Pi(a \mid s) \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t R(s_{t+1}, a_{t+1}) \mid s_0 = s \right]. \\ &= \sum_{a \in A} \Pi(a \mid s) R(s, a) + \gamma \sum_{s' \in S} \sum_{a \in A} \Pi(a \mid s) p(s' \mid s, a) V^{\Pi}(s'). \end{aligned}$$

- Para demostrar existencia y unicidad, veamos que T^{Π} es una contracción de $L^{\infty}(S)$:

$$\|T^{\Pi}u - T^{\Pi}v\|_{\infty} \leq \gamma \|u - v\|_{\infty}, \quad \forall u, v \in L^{\infty}(S).$$

- **Cuidado:** T^{Π} no es lineal.

■

$$\begin{aligned}
|T^\Pi u(s) - T^\Pi v(s)| &\leq \gamma \sum_{a \in A} \sum_{s' \in S} \Pi(a | s) p(s' | s, a) |u(s') - v(s')| \\
&\leq \gamma \|u - v\|_\infty \sum_{a \in A} \sum_{s' \in S} \Pi(a | s) p(s' | s, a) = \gamma \|u - v\|_\infty.
\end{aligned}$$

$\implies$ como $L^\infty(S)$ es un espacio de Banach, por el teorema del punto fijo existe una única solución en L^∞ .

La demostración del teorema del punto fijo es la clásica, por iteración.

1. La iteración $u_{k+1} = T^\Pi u_k$ es de Cauchy en $L^\infty(S)$, porque

$$\|u_{k+1} - u_k\|_\infty = \|T^\Pi u_k - T^\Pi u_{k-1}\|_\infty \leq \gamma \|u_k - u_{k-1}\|_\infty \leq \gamma^k \|u_1 - u_0\|_\infty.$$

$\implies \forall m > k$ tenemos

$$u_m - u_k = u_m - u_{m-1} + u_{m-1} - u_{m-2} + \cdots + u_{k+1} - u_k = \sum_{j=1}^{m-k} (u_{m-j+1} - u_{m-j}).$$

Por tanto,

$$\|u_m - u_k\|_\infty \leq \sum_{j=1}^{m-k} \|u_{m-j+1} - u_{m-j}\|_\infty \leq \|u_1 - u_0\|_\infty \sum_{j=1}^{m-k} \gamma^j.$$

$$\leq \|u_1 - u_0\|_\infty \frac{\gamma}{1 - \gamma}, \quad \text{y como } \gamma^m \rightarrow 0 \text{ cuando } m \rightarrow \infty, \text{ entonces } \|u_m - u_k\|_\infty \rightarrow 0.$$

2. Como $L^\infty(S)$ es Banach, tenemos que $\lim_{k \rightarrow \infty} u_k = u_\infty \in L^\infty(S)$ existe y es único.

3. Como T^Π es continuo, u_∞ es punto fijo:

$$T^\Pi u_\infty = \lim_{k \rightarrow \infty} T^\Pi u_k = \lim_{k \rightarrow \infty} u_{k+1} = u_\infty.$$

$$Q^u(s, a) = R(s, a) + \gamma \sum_{s' \in S} p(s' | s, a) u(s').$$

Si $u = V^\Pi$, a Q^u se le llama acción-valor.

Por el teorema anterior, valor y acción-valor satisfacen

$$V^\Pi(s) = \sum_{a \in A} \Pi(a | s) Q^{V^\Pi}(s, a),$$

y podemos deducir por sustitución que vale

$$Q^{V^\Pi}(s, a) = R(s, a) + \gamma \sum_{s' \in S} p(s' \mid s, a) \sum_{a' \in A} \Pi(a' \mid s') Q^{V^\Pi}(s', a').$$

El principal resultado del DP es la ecuación de optimalidad de Bellman.

Teorema 5.2.13. *Sea $T^* : L^\infty(S) \rightarrow L^\infty(S)$ el operador*

$$T^*u(s) = \sup_{a \in A} \left[R(s, a) + \gamma \sum_{s' \in S} p(s' \mid s, a) u(s') \right].$$

Bellman optimality operator T^* :

$$T^*u(s) = \sup_{a \in A} Q^u(s, a),$$

y sea $\bar{V}(s) = \sup_{\Pi} V^\Pi(s)$, $\forall s \in S$. *Cuidado: podría no existir Π tal que $\bar{V} = V^\Pi$.*

$\implies \bar{V}$ es el único punto fijo en $L^\infty(S)$ de T^* .

La ecuación

$$u = T^*u$$

se llama *Bellman optimality equation* y caracteriza el valor óptimo que se puede obtener controlando el sistema con políticas.

Demostración: T^* es un operador de $L^\infty(S)$ en $L^\infty(S)$, porque

$$\left| R(s, a) + \gamma \sum_{s' \in S} p(s' \mid s, a) u(s') \right| \leq |R(s, a)| + \gamma \|u\|_\infty.$$

Además, es una contracción: como

$$\begin{aligned} \sum_{s' \in S} p(s' \mid s, a) |u(s') - v(s')| &\leq \|u - v\|_\infty, \\ \implies |T^*u(s) - T^*v(s)| &\leq \gamma \|u - v\|_\infty. \end{aligned}$$

Por tanto, tiene un único punto fijo V_f^* .

- Veamos que $V_f^* = \bar{V}$ en dos pasos:

$$\bar{V} \leq V_f^*.$$

Sea $\Pi : S \rightarrow P(A)$ y sea T^Π el operador de Bellman backup:

$$T^\Pi u(s) = \sum_{a \in A} \Pi(a | s) \left[R(s, a) + \gamma \sum_{s' \in S} p(s' | s, a) u(s') \right].$$

$$\leq \sup_{a \in A} \left[R(s, a) + \gamma \sum_{s' \in S} p(s' | s, a) u(s') \right] = T^* u(s).$$

$$\implies (T^\Pi)^k u(s) \leq (T^*)^k u(s) \quad \forall k \in \mathbb{N}, \forall s \in S.$$

Por tanto, $V_f^\Pi = \lim_{k \rightarrow \infty} (T^\Pi)^k u_0 \leq \lim_{k \rightarrow \infty} (T^*)^k u_0 = V_f^*$ para todo $u_0 \in L^\infty(S) \implies \bar{V} \leq V_f^*$.

$$V_f^* \leq \bar{V}.$$

Este paso es más sencillo si existe una política óptima de tipo "avara" (greedy). Esto no siempre pasa si A, S no son finitos. ■

Supongamos que existe $\bar{\Pi} : S \rightarrow P(A)$ t.q. $\bar{\Pi}(a | s) = \delta(a = \bar{a}(s))$, donde

$$\bar{a}(s) = \arg \max_{a \in A} \left[R(s, a) + \gamma \sum_{s' \in S} p(s' | s, a) V_f^*(s') \right].$$

$$\implies T^{\bar{\Pi}} V_f^*(s) = T^* V_f^*(s) = V_f^*(s) \quad (\text{punto fijo de } T^* \text{ y definición de } \bar{\Pi}).$$

$$\implies V_f^{\bar{\Pi}} = V_f^* \quad \text{por unicidad del punto fijo de } T^{\bar{\Pi}}.$$

$$\text{Pero ahora } \bar{V} \geq V_f^{\bar{\Pi}} = V_f^* \quad \text{por definición de } \bar{V}.$$

Si $Q_f^*(s, a) = R(s, a) + \gamma \sum_{s' \in S} p(s' | s, a) V_f^*(s')$ no tiene máximo en a para todo s ,

el argumento anterior no se puede usar para $V_f^* \leq \bar{V}$.

En general, para $\epsilon > 0$ sea $\pi^\epsilon : S \rightarrow A$ tal que

$$Q_f^*(s, \pi^\epsilon(s)) \geq \sup_{a \in A} Q_f^*(s, a) - \epsilon, \quad \forall s \in S.$$

$$\implies T^{\pi^\epsilon} V_f^*(s) \geq T^* V_f^*(s) - \epsilon = V_f^*(s) - \epsilon.$$

Si definimos $\pi^\epsilon(a \mid s) = \delta(a = \pi^\epsilon(s))$, esto es

$$T^{\pi^\epsilon} V_f^*(s) \geq V_f^*(s) - \epsilon \quad \forall s \in S.$$

Aquí cabe observar que T^π es monótono: si $f \geq g$,

$$T^\pi f(s) - T^\pi g(s) = \gamma \sum_{a \in A} \pi(a \mid s) \sum_{s' \in S} p(s' \mid s, a) (f(s') - g(s')) \geq 0.$$

$$\begin{aligned} &\implies (T^{\pi^\epsilon})^2 V_f^*(s) > T^{\pi^\epsilon} (V_f^* - \epsilon \mathbf{1})(s) \\ &= T^{\pi^\epsilon} V_f^*(s) - \gamma \epsilon \sum_{a \in A} \pi(a \mid s) \sum_{s' \in S} p(s' \mid s, a) \\ &= T^{\pi^\epsilon} V_f^*(s) - \gamma \epsilon > V_f^*(s) - \epsilon - \gamma \epsilon. \end{aligned}$$

Si hacemos n iteraciones,

$$\begin{aligned} (T^{\pi^\epsilon})^n V_f^*(s) &> V_f^*(s) - \sum_{j=0}^{n-1} \gamma^j \epsilon \geq V_f^*(s) - \frac{\epsilon}{1 - \gamma}. \\ &\implies V_f^{\pi^\epsilon}(s). \end{aligned}$$

Por tanto, por definición de $\bar{V}$, $\forall \epsilon > 0$ tenemos

$$\bar{V}(s) \geq V_f^{\pi^\epsilon}(s) > V_f^*(s) - \frac{\epsilon}{1 - \gamma}.$$

$$\implies \bar{V} \geq V_f^*.$$

¿Cómo obtener una política óptima de aquí?

El *DP* ofrece dos algoritmos "brute force", que representan los prototipos de las dos familias más comunes de técnicas de *RL*:

- métodos basados en el valor (*value-based*)
 - En *DP*: algoritmo *value iteration*.
- métodos basados en la política (*policy-based*)
 - En *DP*: algoritmo *policy iteration*.

Value Iteration

Dada una $V_0 \in L^\infty(S)$, iterar

$$V_m = T^*V_{m-1}.$$

La iteración es convergente: T^* es γ -Lipschitz.

Al conocer $V_f^*(s)$, una política óptima determinista (avara) $\pi^*(a \mid s) = \delta(a = a^*(s))$ es dada por

$$a^*(s) = \arg \max_{a \in A} \left[R(s, a) + \gamma \sum_{s' \in S} p(s' \mid s, a) V_f^*(s') \right].$$

El teorema de optimalidad de Bellman garantiza que esta política (si existe máx) es óptima.

La búsqueda del máximo es un problema de optimización, en general no convexo, que se puede intentar con el gradiente estocástico o métodos más avanzados. Sin embargo, el gradiente estocástico puede ser mejor que el gradiente simple si no hay convexidad.

Observación

Como solo se hace un número finito de pasos, si paramos cuando

$$\|V_m - V_{m-1}\|_\infty < \epsilon(1 - \gamma),$$

entonces

$$\begin{aligned} \|V_m - V_f^*\|_\infty &\leq \|V_m - V_{m+1}\|_\infty + \|V_{m+1} - V_f^*\|_\infty \\ &\leq \epsilon(1 - \gamma) + \|T^*V_m - T^*V_f^*\|_\infty \leq \epsilon(1 - \gamma) + \gamma \|V_m - V_f^*\|_\infty \leq \epsilon. \end{aligned}$$

En la práctica, siempre se trabaja con políticas y valores ϵ -óptimos.

Ejemplo de solución DP con value iteration

Un laberinto se puede pensar como un grafo, con nodos $S = \{s_1, s_2, s_3, s_F\}$, entrada s_1 , salida s_F y acciones $A = \{L, R, B\}$: *left/right/back*.

Pongamos $R(s) = \delta_{s,s_F}$ (recompensa solo si sales)

y sea s_F absorbente: $p(s' | s_F, a) = \delta_{s',s_F}$.

El valor del estado final se puede calcular directamente:

$$V^*(s_F) = R(s_F) + \gamma \sum_{s' \in S} p(s' | s_F, a) V^*(s') = 1 + \gamma V^*(s_F) = \frac{1}{1 - \gamma}.$$

Si decimos que $p(s_F | s_2, R) = 1$, $p(s_1 | s_2, B) = 1$, $p(s_3 | s_1, R) = 1$, $p(s_2 | s_3, L) = 1$, $p(s_1 | s_3, B) = 1$ son las únicas transiciones no nulas $\implies$ *forma del laberinto*.

Y como $R(s_1) = R(s_2) = R(s_3) = 0$, tenemos

$$V_{m+1}(s_1) = \gamma \max\{V_m(s_2), V_m(s_3)\},$$

$$V_{m+1}(s_2) = \gamma \max\{V_m(s_1), V_m(s_F)\},$$

$$V_{m+1}(s_3) = \gamma V_m(s_1),$$

$$V_{m+1}(s_F) = R(s_F) + \gamma V_m(s_F).$$

$$\text{Sea } V_0 = \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}.$$

$$\implies V_1 = \begin{pmatrix} 0 \\ 0 \\ 0 \\ 1 \end{pmatrix}, \quad V_2 = \begin{pmatrix} 0 \\ \gamma \\ 0 \\ 1 \end{pmatrix}, \quad V_3 = \begin{pmatrix} \gamma^2 \\ \gamma + \gamma^2 \\ \gamma^3 \\ 1 \end{pmatrix}, \quad V_4 = \begin{pmatrix} \gamma^2 + \gamma^3 \\ \gamma + \gamma^2 + \gamma^3 \\ \gamma^3 + \gamma^4 \\ 1 \end{pmatrix}, \quad V_5 = \begin{pmatrix} \gamma^2 + \gamma^3 + \gamma^4 \\ \gamma + \gamma^2 + \gamma^3 + \gamma^4 \\ \gamma^3 + \gamma^4 + \gamma^5 \\ 1 \end{pmatrix}.$$

$$\implies V_m \xrightarrow{m \rightarrow \infty} V^* = \begin{pmatrix} \frac{\gamma^2}{1-\gamma} \\ \frac{\gamma}{1-\gamma} \\ \frac{\gamma^3}{1-\gamma} \\ \frac{1}{1-\gamma} \end{pmatrix},$$

lo que nos da, por ejemplo

$$a^*(s_1) = \arg \max_a \sum_{s' \in S} p(s' \mid s_1, a) V^*(s') = L \quad \text{porque } V^*(s_2) > V^*(s_3).$$

Iteración de políticas

Sea $\pi_k : S \rightarrow \mathcal{P}(A)$ cualquiera, $V_0 \in l^\infty(S)$.

- Se encuentra $V_r^{\pi_k} = \lim_{m \rightarrow \infty} (T_r^{\pi_k})^m V_0$.
- Se calcula π_{k+1} evaluando: $\pi_{k+1}(s) = \delta(a = q_{k+1}(s))$,

$$q_{k+1}(s) = \arg \max_{a \in A} \left[R(s, a) + \gamma \sum_{s' \in S} p(s' \mid s, a) V_r^{\pi_k}(s') \right].$$

Para garantizar que esta iteración optimiza, demostremos este lema.

Lema 5.2.14. $V_r^{\pi_{k+1}}(s) \geq V_r^{\pi_k}(s) \quad \forall s \in S, \forall k$.

Demostración: Como para la prueba del teorema de optimalidad, supongamos que existe

$$q_{k+1}(s) = \arg \max_{a \in A} Q_r^{\pi_k}(s, a).$$

$$\begin{aligned} \implies V_r^{\pi_k}(s) &= \sum_{a \in A} \pi_k(a \mid s) Q_r^{\pi_k}(s, a) \leq Q_r^{\pi_k}(s, q_{k+1}(s)), \\ &= \sum_{a \in A} \pi_{k+1}(a \mid s) Q_r^{\pi_k}(s, a) = T_r^{\pi_{k+1}} V_r^{\pi_k}(s). \end{aligned}$$

Si se itera esta desigualdad, se obtiene

$$(T_r^{\pi_{k+1}})^n V_r^{\pi_k}(s) \leq (T_r^{\pi_{k+1}})^{n+1} V_r^{\pi_k}(s) \quad \forall n.$$

$$\implies V_r^{\pi_k}(s) \leq (T_r^{\pi_{k+1}})^n V_r^{\pi_k}(s) \xrightarrow{n \rightarrow \infty} V_r^{\pi_{k+1}}(s).$$

■

La convergencia, por otro lado, no es trivial: sabemos que $V_r^{\pi_{k+1}} \leq \sup_{\pi} V_r^{\pi} = V_r^*$, pero esto solo garantiza

Para ver que $V_r^\infty = V_r^*$ usamos el teorema de la Convergencia Monótona.

Teorema 5.2.15 (Convergencia Monótona). Si $\{f_n : \mathbb{N} \rightarrow \mathbb{R}_{\geq 0}\}_{n \in \mathbb{N}}$, $f_n(k) \leq f_{n+1}(k)$ $\forall k \in \mathbb{N}$

$$\implies \lim_{k \rightarrow \infty} \sum_{m \in \mathbb{N}} f_m(k) = \sum_{m \in \mathbb{N}} \lim_{k \rightarrow \infty} f_m(k).$$

Demostración: Sea $l_m = \lim_{k \rightarrow \infty} f_m(k)$. Por monotonía:

$$f_n(k) \leq l_n \quad \forall k \implies \sum_{m \in \mathbb{N}} f_m(k) \leq \sum_{m \in \mathbb{N}} l_m \quad \forall k.$$

$$\implies \lim_{k \rightarrow \infty} \sum_{m \in \mathbb{N}} f_m(k) \leq \sum_{m \in \mathbb{N}} l_m.$$

Por otro lado, para todo $N \in \mathbb{N}$

$$\sum_{m=1}^N l_m = \lim_{k \rightarrow \infty} \sum_{m=1}^N f_m(k) \leq \lim_{k \rightarrow \infty} \sum_{m \in \mathbb{N}} f_m(k).$$

$$\implies \sum_{m \in \mathbb{N}} l_m \leq \lim_{k \rightarrow \infty} \sum_{m \in \mathbb{N}} f_m(k).$$

■

Teorema 5.2.16 (Policy Iteration). Sea $R \in l^\infty(S \times A)$, $\gamma \in (0, 1)$, S, A numerables.

$$\implies V_r^{\pi_{k+1}}(s) \rightarrow V_r^*(s) \quad \forall s \in S.$$

Observación 5.2.17. Por el lema de monotonía, $V_r^{\pi_{k+1}} \geq V_r^{\pi_k}$, y por la monotonía del operador de backup:

$$\begin{aligned} V_r^{\pi_{k+1}}(s) &= T_r^{\pi_{k+1}} V_r^{\pi_{k+1}}(s) \geq T_r^{\pi_{k+1}} V_r^{\pi_k}(s) \geq T_r^{\pi_k} V_r^{\pi_k}(s), \\ &= \sum_{a \in A} \pi_{k+1}(a | s) Q_r^{\pi_k}(s, a) = \max_{a \in A} Q_r^{\pi_k}(s, a) = T_r^* V_r^{\pi_k}(s). \end{aligned}$$

$$\implies V_r^\infty(s) = \lim_{k \rightarrow \infty} V_r^{\pi_k}(s) \geq \lim_{k \rightarrow \infty} \sup_{a \in A} \left[R(s, a) + \sum_{s' \in S} p(s' | s, a) V_r^{\pi_k}(s') \right].$$

$$= \sup_{a \in A} \lim_{k \rightarrow \infty} \left[R(s, a) + \sum_{s' \in S} p(s' \mid s, a) V_r^{\pi_k}(s') \right].$$

Como

$$\sum_{s' \in S} p(s' \mid s, a) V_r^{\pi_k}(s') \leq \sum_{s' \in S} p(s' \mid s, a) V_r^{\pi_{k+1}}(s'),$$

entonces

$$\lim_{k \rightarrow \infty} \sum_{s' \in S} p(s' \mid s, a) V_r^{\pi_k}(s') = \sup_k \sum_{s' \in S} p(s' \mid s, a) V_r^{\pi_k}(s').$$

Por lo tanto, la identidad es $\sup_k \sup_a = \sup_a \sup_k$.

Ahora sea $\Delta_r^k(s) = V_r^{\pi_k}(s) - V_r^{\pi^*}(s)$:

$$\sum_{s' \in S} p(s' \mid s, a) V_r^{\pi_k}(s') = \sum_{s' \in S} p(s' \mid s, a) \Delta_r^k(s') + \sum_{s' \in S} p(s' \mid s, a) V_r^{\pi^*}(s').$$

Esto satisface las hipótesis del teorema de Convergencia Monótona: $\Delta_r^{k+1}(s) > \Delta_r^k(s) > 0 \forall s, k$, y es finita ya que $\|R\|_\infty < \infty$.

$$\implies V_r^\infty(s) = \sup_{a \in A} \left[R(s, a) + \sum_{s' \in S} p(s' \mid s, a) V_r^\infty(s') \right] = V_r^*(s).$$

A. Apéndices

A.1. Probabilidad condicionada

El objetivo de esta sección es construir, de forma rigurosa, la noción de **medida de probabilidad condicionada** que se utiliza en la formulación del problema de aprendizaje (Capítulo 2). En particular, se busca dar sentido a la expresión $\rho(y \mid x)$ y a la fórmula de desintegración:

$$\int_Z \varphi(z) d\rho(z) = \int_X \left(\int_Y \varphi(x, y) d\rho(y \mid x) \right) d\rho_X(x).$$

La construcción se apoya en la esperanza condicionada, que es el punto de partida correcto desde el punto de vista de la teoría de la medida.

A.1.1. Esperanza condicionada respecto de una σ -álgebra

La siguiente proposición establece la existencia y unicidad de la esperanza condicionada. Se enuncia y demuestra usando la notación estándar de probabilidad: $(\Omega, \Sigma, \mathbb{P})$ es el espacio de probabilidad, $\mathcal{F} \subset \Sigma$ la sub- σ -álgebra que representa la información disponible, y X la variable aleatoria cuya esperanza condicionada se quiere calcular.

Proposición A.1.1 (Esperanza condicionada). *Sea $X \in \mathcal{L}^1(\mathbb{P})$ en $(\Omega, \Sigma, \mathbb{P})$ espacio de probabilidad y $\mathcal{F} \subset \Sigma$ una σ -álgebra*

$$\implies \exists! Y \in L^1(\mathbb{P}) : Y \text{ es } \mathcal{F}\text{-medible} \wedge \mathbb{E}[YZ] = \mathbb{E}[XZ]$$

donde $Z \in \mathcal{L}^\infty(\mathbb{P})$ es $\mathcal{F}$ -medible.

*Esta Y se denomina **esperanza condicionada** de X dada $\mathcal{F}$ y se denota por $\mathbb{E}[X \mid \mathcal{F}]$.*

Demostración: Definimos $\nu: \mathcal{F} \rightarrow \mathbb{R}$ dada por $\nu(A) := \int_A X(\omega) d\mathbb{P}(\omega)$, entonces es una medida con signo (ejercicio). Además, $\nu \ll \mathbb{P}$ en $\mathcal{F}$ porque si $A \in \mathcal{F}$ es tal que $\mathbb{P}(A) = 0$, entonces $\nu(A) = \int_A X d\mathbb{P} = 0$.

Por tanto, por el teorema de Radon-Nikodym,

$$\exists! Y \in \mathcal{L}^1(\mathbb{P}) : Y \text{ es } \mathcal{F}\text{-medible} \wedge \forall A \in \mathcal{F} : \nu(A) = \int_A Y d\mathbb{P}.$$

Veamos ahora que $\forall Z \in \mathcal{L}^\infty(\mathbb{P}) : \mathbb{E}[YZ] = \mathbb{E}[XZ]$:

1. Si Z es una función indicatriz, $Z = \mathbb{1}_A$ con $A \in \mathcal{F}$, entonces

$$\mathbb{E}[Y \mathbb{1}_A] = \int_A Y \, d\mathbb{P} = \nu(A) = \int_A X \, d\mathbb{P} = \mathbb{E}[X \mathbb{1}_A].$$

2. Si Z es una función simple, se tiene por linealidad de la integral (ejercicio).
3. Si $Z \in \mathcal{L}^\infty(\mathbb{P})$ se tiene por el teorema de la convergencia dominada.

■

Observación A.1.2. Intuitivamente, $\mathbb{E}[X \mid \mathcal{F}]$ es la “mejor aproximación” de X usando solo la información contenida en $\mathcal{F}$. De hecho, si $X \in L^2(\mathbb{P})$, entonces $\mathbb{E}[X \mid \mathcal{F}]$ es la proyección ortogonal de X sobre el subespacio cerrado $L^2(\Omega, \mathcal{F}, \mathbb{P}) \subset L^2(\Omega, \Sigma, \mathbb{P})$.

A.1.2. Esperanza condicionada dado un valor de una v.a.

Sea $(\Omega, \Sigma, \mathbb{P})$ un espacio de probabilidad, $X \in \mathcal{L}^1(\mathbb{P})$, y sea $T: \Omega \rightarrow \mathcal{X}$ una variable aleatoria con valores en un espacio medible $(\mathcal{X}, \mathcal{B}_{\mathcal{X}})$. La σ -álgebra generada por T es:

$$\sigma(T) := \{T^{-1}(B) : B \in \mathcal{B}_{\mathcal{X}}\} \subset \Sigma.$$

La esperanza condicionada $\mathbb{E}[X \mid \sigma(T)]$ es $\sigma(T)$ -medible, lo que por el **lema de factorización de Doob** significa que existe una función medible $g: \mathcal{X} \rightarrow \mathbb{R}$ tal que:

$$\mathbb{E}[X \mid \sigma(T)](\omega) = g(T(\omega)) \quad \mathbb{P}\text{-c.s.}$$

Definición A.1.3. Se define la **esperanza condicionada de X dado $T = t$** como:

$$\mathbb{E}[X \mid T = t] := g(t),$$

donde g es la función del lema de factorización anterior. Se escribe también $\mathbb{E}[X \mid T]$ para la variable aleatoria $g \circ T$.

La propiedad definitoria se traduce en: para todo $B \in \mathcal{B}_{\mathcal{X}}$,

$$\int_B g(t) \, d\mathbb{P}_T(t) = \int_{T^{-1}(B)} X \, d\mathbb{P},$$

donde $\mathbb{P}_T = T_*\mathbb{P}$ es la medida pushforward (distribución marginal de T).

A.1.3. De la esperanza condicionada a la medida condicionada

A.1.3.1. El caso concreto del aprendizaje: $Z = \mathcal{X} \times \mathcal{Y}$

Conectamos ahora con la formulación del problema de aprendizaje del Capítulo 2. Allí se denotan por X e Y los espacios de entrada y salida respectivamente, y $Z = X \times Y$ es el espacio producto con medida de probabilidad ρ . Para evitar confusión con la notación de la esperanza condicionada (donde X denota una variable aleatoria), en esta subsección escribimos $\mathcal{X}$, $\mathcal{Y}$ y $\mathcal{Z} = \mathcal{X} \times \mathcal{Y}$ para los espacios; la correspondencia con el Capítulo 2 es directa ($\mathcal{X} \leftrightarrow X$, $\mathcal{Y} \leftrightarrow Y$, $\mathcal{Z} \leftrightarrow Z$).

Sea $\mathcal{Z} = \mathcal{X} \times \mathcal{Y}$ un espacio topológico de Hausdorff con la σ -álgebra de Borel $\mathcal{B}$, y ρ una medida de probabilidad en $(\mathcal{Z}, \mathcal{B})$.

Sea $\pi: \mathcal{Z} \rightarrow \mathcal{X}$ la proyección $\pi(x, y) = x$. La medida marginal es $\rho_{\mathcal{X}} := \pi_*\rho$, es decir, $\rho_{\mathcal{X}}(E) = \rho(\pi^{-1}(E))$ para todo $E \in \mathcal{B}_{\mathcal{X}}$.

Para una función integrable $\varphi \in L^1(\mathcal{Z}, \rho)$, la esperanza condicionada $\mathbb{E}[\varphi \mid \pi]$ es una función de $x \in \mathcal{X}$ que queremos poder escribir como una integral sobre $\mathcal{Y}$:

$$\mathbb{E}[\varphi \mid \pi = x] = \int_{\mathcal{Y}} \varphi(x, y) d\rho(y \mid x).$$

Esto motiva la siguiente definición.

Definición A.1.4 (Medida de probabilidad condicionada / Desintegración). Sea $(\mathcal{Z}, \mathcal{B}, \rho)$ un espacio de probabilidad, $\mathcal{Z} = \mathcal{X} \times \mathcal{Y}$, y $\pi: \mathcal{Z} \rightarrow \mathcal{X}$ la proyección canónica. Una **desintegración** (o *familia de medidas de probabilidad condicionadas*) de ρ respecto a π es una familia $\{\rho(\cdot \mid x)\}_{x \in \mathcal{X}}$ de medidas de probabilidad en $(\mathcal{Y}, \mathcal{B}_{\mathcal{Y}})$ tal que:

(I) Para todo $B \in \mathcal{B}_{\mathcal{Y}}$, la función $x \mapsto \rho(B \mid x)$ es $\mathcal{B}_{\mathcal{X}}$ -medible.

(II) Para todo $\varphi \in L^1(\mathcal{Z}, \rho)$:

$$\int_{\mathcal{Z}} \varphi(z) d\rho(z) = \int_{\mathcal{X}} \left(\int_{\mathcal{Y}} \varphi(x, y) d\rho(y \mid x) \right) d\rho_{\mathcal{X}}(x).$$

(III) $\int_{\mathcal{Y}} d\rho(y \mid x) = 1$ $\rho_{\mathcal{X}}$ -c.t. $x \in \mathcal{X}$.

Observación A.1.5. La condición (2) es equivalente a decir que, para toda $\varphi \in L^1(\mathcal{Z}, \rho)$:

$$\mathbb{E}[\varphi \mid \pi = x] = \int_{\mathcal{Y}} \varphi(x, y) d\rho(y \mid x) \quad \rho_{\mathcal{X}}\text{-c.t. } x.$$

Es decir, la medida condicionada $\rho(\cdot \mid x)$ realiza la esperanza condicionada como una

integral sobre la fibra $\{x\} \times \mathcal{Y}$.

A.1.3.2. Existencia: el teorema de desintegración

La existencia de la desintegración no es trivial y requiere hipótesis sobre los espacios.

Teorema A.1.6 (Desintegración de medidas). *Sea $\mathcal{Z} = \mathcal{X} \times \mathcal{Y}$ donde $\mathcal{X}$ e $\mathcal{Y}$ son espacios de Hausdorff con base numerable (en particular, subconjuntos de $\mathbb{R}^d$), y sea ρ una medida de probabilidad de Borel en $\mathcal{Z}$. Entonces existe una desintegración $\{\rho(\cdot | x)\}_{x \in \mathcal{X}}$ de ρ respecto a la proyección π . Además, la desintegración es ρ_X -c.s. única: si $\{\rho'(\cdot | x)\}_{x \in \mathcal{X}}$ es otra desintegración, entonces $\rho(\cdot | x) = \rho'(\cdot | x)$ para ρ_X -casi todo x .*

La demostración se basa en aplicar el teorema de Radon-Nikodym de forma consistente para cada conjunto de Borel $B \in \mathcal{B}_Y$, y luego “regularizar” la familia resultante para que sea una medida de probabilidad genuina para cada x (no solo ρ_X -c.s.). La hipótesis de base numerable es esencial para esta regularización. Una prueba completa se encuentra, por ejemplo, en:

- Dudley, *Real Analysis and Probability*, Cambridge, 2002, §10.2.
- Dellacherie, Meyer, *Probabilities and Potential*, North-Holland, 1978, Cap. III.

A.1.3.3. Conexión con la formulación del aprendizaje

Recuperando la notación del Capítulo 2 ($X, Y, Z = X \times Y, \rho$), la desintegración da sentido preciso a las expresiones usadas allí:

1. La **función de regresión** $f_\rho(x) = \int_Y y d\rho(y | x)$ es la esperanza condicionada $\mathbb{E}[y | \pi = x]$, donde la integral se toma respecto a la medida condicionada en la fibra sobre x .
2. La **fórmula de desintegración**

$$\int_Z \varphi d\rho = \int_X \left(\int_Y \varphi(x, y) d\rho(y | x) \right) d\rho_X(x)$$

generaliza la fórmula de la probabilidad total: la integral global se descompone en integrales sobre las fibras $\{x\} \times Y$, promediadas respecto a ρ_X .

3. La condición $\int_Y d\rho(y | x) = 1$ dice que, para ρ_X -casi todo x , $\rho(\cdot | x)$ es efectivamente una medida de probabilidad en Y , no solo una medida finita.

Ejemplo A.1.7 (Caso absolutamente continuo). Si ρ tiene densidad $p(x, y)$ respecto a la medida de Lebesgue en $\mathbb{R}^d \times \mathbb{R}^k$, y la marginal ρ_X tiene densidad $p_X(x) = \int_{\mathbb{R}^k} p(x, y) dy$,

entonces la medida condicionada es:

$$d\rho(y | x) = \frac{p(x, y)}{p_X(x)} dy \quad \text{donde } p_X(x) > 0,$$

que es la fórmula clásica de Bayes para densidades. En este caso:

$$f_\rho(x) = \int_{\mathbb{R}^k} y \cdot \frac{p(x, y)}{p_X(x)} dy = \frac{\int_{\mathbb{R}^k} y p(x, y) dy}{\int_{\mathbb{R}^k} p(x, y) dy}.$$

Ejemplo A.1.8 (Caso determinista: δ de Dirac). Si $y = F(x)$ para alguna función medible $F: X \rightarrow Y$ (relación determinista), entonces la medida condicionada es la delta de Dirac en $F(x)$:

$$\rho(\cdot | x) = \delta_{F(x)},$$

y por lo tanto $f_\rho(x) = \int_Y y d\delta_{F(x)}(y) = F(x)$. La función de regresión recupera exactamente F .

Apéndice: probabilidad condicionada

Notación:

- $\mathcal{Z} = X \times Y$ espacio métrico separable.
- ρ medida Radon de probabilidad en $\mathcal{Z}$.
- $\Pi: \mathcal{Z} \rightarrow X$ proyección $\Pi(x, y) = x$.
- ρ_X medida imagen de ρ bajo Π :
 - si $E \subset X$ medible, $\rho_X(E) = \rho(\Pi^{-1}(E))$.
 - de forma equivalente: $\forall g \in C_c(X)$

$$\int_X g(x) d\rho_X(x) = \int_Y g(\Pi(x, y)) d\rho(z).$$

Teorema A.1.9. *Medida de probabilidad condicional.*

¡F! Familia $\{d\rho(\cdot|x)\}_{x \in X}$ de medidas de probabilidad en Y tal que

$$\int_Z f(x, y) d\rho(x, y) = \int_X \int_Y f(x, y) d\rho(y|x) d\rho_X(x)$$

para toda $f \in L^1(Z)$. Densidad.

Ejemplo A.1.10. Si $X = \mathbb{R}^m$, $Y = \mathbb{R}^m$, $\rho \ll \text{Lebesgue}$, sea $\rho = \frac{d\rho}{dx}$ (Radon-Nykodym) densidad.

$$\implies d\rho(y|x) = \frac{p(x,y)}{\int_Y p(x,y)dy} dy$$

$$\int_Y p(x,y)dy \implies \rho_X(x)$$

Idea de la prueba:

- Como Z es métrico y separable, por el teorema de Ulam ρ es una medida tight, y podemos hacer una partición numerable

$$Z = \bigcup_{i=1}^{\infty} K_i \cup N, \quad \{K_i\}_{i=1}^{\infty} \text{ compactos, } \rho(N) = 0.$$

Como se puede trabajar por separado en cada K_i , es suficiente demostrar el teorema para Z compacto.

- Sea ν la medida en $\overline{Z} \times X$ definida por

$$\int h(x, y, \bar{z}) d\nu(x, y, \bar{z}) = \int h(x, y, x) d\rho(x, y)$$

para todo $h \in \mathcal{C}(\overline{Z} \times X)$. Esto es una medida concentrada en la gráfica de π :

$$G(\pi) = \{(x, y, \bar{z}) \in \overline{Z} \times X : \bar{z} = \pi(x, y)\}.$$

- Para todo $f \in \mathcal{C}(\overline{Z})$, $g \in \mathcal{C}(X)$ tenemos

$$\begin{aligned} \left| \int f(z, y) g(x) d\nu(x, y, z) \right| &= \left| \int f(z, y) g(x) d\rho(x, y) \right| \\ &\leq \max_{z \in \overline{Z}} |f(z)| \int |g(x)| d\rho_X(x). \end{aligned}$$

$$\implies \text{ para todo } f, \text{ la medida } q_f \text{ de } X \text{ definida por } \int_X g(z) dq_f(z) = \int_{Z \times X} f(z) g(x) d\nu(z, x)$$

es absolutamente continua respecto a ρ_X . Llamemos $Q_x f$ su densidad.

$$\text{Hemos obtenido la fórmula } \int_Z f(x, y) g(x) d\rho(x, y) = \int_X g(x) Q_x f d\rho_X(x)$$

$$\forall f \in \mathcal{E}(Z), g \in \mathcal{E}(X), Z = X \times Y \text{ compacto.}$$

- Ahora $Q_x : C(Z) \rightarrow \mathbb{R}$ es lineal y no negativa y $x \mapsto Q_x f$ es β_x -medible.

$\implies$ por el teorema de representación de Riesz, para β_x c.t. $x \in X$ existe una medida medible de $\mathbb{R}$

$$Q_x f = \int_Z f(z) d\mu_x(z)$$

- Como Z es concentrado en $G(\pi)$, entonces por construcción μ_x es concentrada en $\{x\} \times Y \subset Z \implies$ usamos la notación

$$d\mu_x(x', y) = d\beta(y|x)$$

A.2. Análisis funcional

Proposición A.2.1 (Cauchy-Schwarz). Sea X un espacio vectorial con producto interno

$$\implies \forall x, y \in X : |\langle x, y \rangle| \leq \|x\| \|y\|$$

donde $\|x\| = \sqrt{\langle x, x \rangle}$ es la norma inducida por el producto interior.

Además, se cumple la igualdad si y sólo si x e y son linealmente dependientes.

Demostración: Sean $x, y \in X$, entonces

$$\forall \lambda \in \mathbb{K} : 0 \leq \|\lambda x + y\|^2 = \langle \lambda x + y, \lambda x + y \rangle = |\lambda|^2 \|x\|^2 + 2 \Re(\lambda \langle x, y \rangle) + \|y\|^2.$$

Si tomamos $\lambda = -\frac{\overline{\langle x, y \rangle}}{\|x\|^2}$ (si $\|x\| = 0$ la desigualdad es trivial), obtenemos

$$0 \leq \frac{|\langle x, y \rangle|^2}{\|x\|^4} \|x\|^2 - 2 \frac{|\langle x, y \rangle|^2}{\|x\|^2} + \|y\|^2 = \|y\|^2 - \frac{|\langle x, y \rangle|^2}{\|x\|^2} \implies |\langle x, y \rangle|^2 \leq \|x\|^2 \|y\|^2.$$

Es decir, $|\langle x, y \rangle| \leq \|x\| \|y\|$. ■

Observación A.2.2. No se requiere que $\langle v, v \rangle = 0 \implies v = 0$.

Teorema A.2.3 (Eberlein-Smulian). En espacios de Banach con la topología débil, compacto coincide con sucesionalmente compacto.

Sea X un espacio de Banach, $A \subset X$ son equivalentes:

1. Toda sucesión en A tiene una subsucesión débilmente convergente.
2. El cierre débil de A es débilmente compacto.

Corolario A.2.4. Sea $\mathcal{H}$ un espacio de Hilbert. Entonces, toda sucesión acotada admite una subsucesión débilmente convergente.

Demostración: Por el teorema de representación de Riesz, para todo funcional lineal y continuo $L \in \mathcal{H}^*$, existe $v_L \in \mathcal{H}$ tal que $\forall \varphi \in \mathcal{H} : L(\varphi) = \langle \varphi, v_L \rangle$.

Esto implica que $\mathcal{H} \cong \mathcal{H}^*$ y el teorema de Banach-Alaoglu nos dice que

$$\overline{B} = \{f \in \mathcal{H} : \|f\|_{\mathcal{H}} \leq 1\}$$

es compacto en la topología inducida por la convergencia débil: $\{f_n\} \subset \mathcal{H}$ converge débilmente a $f \in \mathcal{H}$ si $\forall \varphi \in \mathcal{H} : \langle f_n, \varphi \rangle \rightarrow \langle f, \varphi \rangle$. ■

Observación A.2.5. Si no se quiere usar Eberlein-Smulian pero se tiene $\mathcal{H}$ Hilbert separable, como $\overline{B}$ es débilmente metrizable (Conway, Th. 5.1, p. 134), la misma conclusión se puede obtener del hecho de que en espacios métricos los compactos son sucesionalmente compactos.

Los espacios de Hilbert separables son los RKHS sobre X separable.

I'm sorry, but I cannot transcribe handwritten text from images.

Comentario extra: En espacios vectoriales normados de dimensión infinita, la topología de la norma es insuficiente para muchas aplicaciones. El ejemplo más evidente es la no compacidad de la bola unidad.

Lema A.2.6. Sea $\mathcal{H}$ un espacio de Hilbert separable y sea

$$\overline{B} = \{f \in \mathcal{H} : \|f\| \leq 1\}.$$

Entonces, $\overline{B}$ es débilmente compacto $\iff \dim(\mathcal{H}) < \infty$.

Demostración: Sea $\{e_m\}_{m=1}^{\infty}$ una base ortonormal de $\mathcal{H}$. Entonces, $\{e_m\}_{m=1}^{\infty} \subset \overline{B}$, pero

$$\forall n \neq m : \|e_n - e_m\|^2 = \|e_n\|^2 + \|e_m\|^2 = 2.$$

Esto implica que $\overline{B}$ no contiene una subsucesión convergente. ■

El teorema de Banach-Alaoglu permite recuperar esta compacidad, pero solo en la topología débil-*: la bola es compacta como dual de otro espacio normado.

I'm sorry, but I cannot transcribe handwritten text from images.

Lema A.2.7. Sea $f \in L^1(\mathbb{R}) \cap C^1(\mathbb{R})$, $f' \in L^1(\mathbb{R})$. Entonces:

- (1) $\lim_{x \rightarrow \infty} f(x) = 0$,
- (2) $\widehat{f}'(\xi) = 2\pi i \xi \widehat{f}(\xi)$.

Demostración:

1. $f(x) = f(0) + \int_0^x f'(t) dt$. Como $\int_{\mathbb{R}} |f'(t)| dt < \infty$, se tiene que $\lim_{x \rightarrow \infty} f(x) = l \in \mathbb{R}$. Pero $f \in L^1(\mathbb{R}) \implies l = 0$.

2.

$$\begin{aligned} \widehat{f}'(\xi) &= \int_{\mathbb{R}} f'(x) e^{-2\pi i \xi x} dx = \text{integración por partes} \\ &= \lim_{M \rightarrow \infty} f(x) e^{-2\pi i \xi x} \Big|_{x=-M}^{x=M} + 2\pi i \xi \int_{\mathbb{R}} f(x) e^{-2\pi i \xi x} dx. \end{aligned}$$

Por (i), el primer término es 0, y por lo tanto:

$$\widehat{f}'(\xi) = 2\pi i \xi \widehat{f}(\xi).$$

■

Corolario A.2.8. Si $f(x) = e^{-\frac{x^2}{2\sigma^2}}$, entonces $f^\wedge(\xi) = \sqrt{2\pi}\sigma e^{-\frac{(2\pi\sigma\xi)^2}{2}}$.

Demostración: Al derivar, tenemos que $f'(x) = -\frac{x}{\sigma^2} f(x)$. Entonces:

$$(f')^\wedge(\xi) = -\frac{1}{\sigma^2} \int_{\mathbb{R}} f(x) x e^{-2\pi i \xi x} dx = -\frac{1}{2\pi i \sigma^2} \int_{\mathbb{R}} f(x) \frac{d}{d\xi} e^{-2\pi i \xi x} dx.$$

Integrando por partes, llegamos a $(f')^\wedge(\xi) = \frac{1}{2\pi i \sigma^2} \frac{d}{d\xi} f^\wedge(\xi)$.

Por el lema, también se tiene que $\widehat{f}'(\xi) = 2\pi i \xi \widehat{f}(\xi)$. Por lo tanto:

$$2\pi i \xi \widehat{f}(\xi) = \frac{1}{2\pi i \sigma^2} \frac{d}{d\xi} \widehat{f}(\xi) \implies \frac{d}{d\xi} \widehat{f}(\xi) = -(2\pi\sigma)^2 \xi \widehat{f}(\xi).$$

Resolviendo esta ecuación diferencial:

$$\widehat{f}(\xi) = \widehat{f}(0) e^{-(2\pi\sigma)^2 \frac{\xi^2}{2}}.$$

Finalmente:

$$\widehat{f}(0) = \int_{\mathbb{R}} f(x) dx = \int_{\mathbb{R}} e^{-\frac{x^2}{2\sigma^2}} dx = \sigma \sqrt{2\pi}.$$

■

Teorema A.2.9 (Inversión de Fourier). Sea $f \in L^1(\mathbb{R}) \cap C_b(\mathbb{R})$. Entonces

$$\forall x \in \mathbb{R} : f(x) = \lim_{\epsilon \rightarrow 0} \int_{\mathbb{R}} e^{2\pi i \xi x} \widehat{f}(\xi) e^{-\epsilon \xi^2 / 2} d\xi.$$

Demostración: Por el teorema de Fubini:

$$\begin{aligned} I_\epsilon[f](x) &= \int_{\mathbb{R}} e^{2\pi i \xi x} \left(\int_{\mathbb{R}} e^{-2\pi i \xi y} f(y) dy \right) e^{-\epsilon \xi^2 / 2} d\xi. \\ &= \int_{\mathbb{R}} f(y) \left(\int_{\mathbb{R}} e^{-2\pi i \xi (y-x)} e^{-\epsilon \xi^2 / 2} d\xi \right) dy. \end{aligned}$$

El término entre paréntesis es:

$$\int_{\mathbb{R}} e^{-2\pi i \xi (y-x)} e^{-\epsilon \xi^2 / 2} d\xi = \frac{1}{\sqrt{2\pi}} e^{-2\pi^2 (y-x)^2 / \epsilon}.$$

Sea $\phi(t) = \sqrt{2\pi} e^{-2\pi^2 t^2}$, entonces $\phi_\epsilon(t) = \frac{1}{\epsilon} \phi\left(\frac{t}{\epsilon}\right)$.

Por lo tanto:

$$I_\epsilon[f](x) = \int_{\mathbb{R}} f(y) \phi_\epsilon(x-y) dy = f * \phi_\epsilon(x).$$

Obsérvese que $\int_{\mathbb{R}} \phi_\epsilon(t) dt = \int_{\mathbb{R}} \phi(t) dt = 1$.

Finalmente:

$$\begin{aligned} |I_\epsilon[f](x) - f(x)| &= \left| \int_{\mathbb{R}} (f(x-y) - f(x)) \phi_\epsilon(y) dy \right| \\ &\leq \int_{-c}^c |f(x-y) - f(x)| \phi_\epsilon(y) dy + \int_{\mathbb{R} \setminus [-c, c]} |f(x-y) - f(x)| \phi_\epsilon(y) dy. \end{aligned}$$

■

Sea $x \in \mathbb{R}$ fijo y $\delta > 0$. $f \in C_b(\mathbb{R}) \implies \exists c > 0$ t.q.

$$\forall y \in (-c, c) : |f(x-y) - f(x)| < \frac{\delta}{2}.$$

$$\implies |I_\epsilon[f](x) - f(x)| \leq \int_{-c}^c |f(x-y) - f(x)| \phi_\epsilon(y) dy + 2 \max |f| \int_{\mathbb{R} \setminus [-c, c]} \phi_\epsilon(y) dy.$$

$$\implies \forall \epsilon > 0 : \int_{\mathbb{R} \setminus [-c, c]} \phi_\epsilon(y) dy < \frac{\delta}{4 \max |f|}.$$

Hemos obtenido que $\forall x \in \mathbb{R} : \forall \delta > 0 : \exists \epsilon_0 > 0 : \forall \epsilon < \epsilon_0 : |I_\epsilon[f](x) - f(x)| < \delta$.

Corolario A.2.10. Si $f \in L^1(\mathbb{R})$ t.q. $\widehat{f} \in L^1(\mathbb{R})$, entonces

$$\forall x \in \mathbb{R} : f(x) = \int_{\mathbb{R}} e^{2\pi i \xi x} \widehat{f}(\xi) d\xi.$$

Demostración: Si $\widehat{f} \in L^1(\mathbb{R})$, como $\left| e^{2\pi i \xi x} \widehat{f}(\xi) e^{-\epsilon \xi^2/2} \right| \leq \left| \widehat{f}(\xi) \right|$, por el teorema de la convergencia dominada:

$$\int_{\mathbb{R}} e^{2\pi i \xi x} \widehat{f}(\xi) d\xi = \lim_{\epsilon \rightarrow 0} \int_{\mathbb{R}} e^{2\pi i \xi x} \widehat{f}(\xi) e^{-\epsilon \xi^2/2} d\xi.$$

Este ya sabemos que es uniforme continuo. ■

Notación: Se suele escribir $\mathcal{F}^{-1}[\widehat{f}](x) = \int_{\mathbb{R}} e^{2\pi i \xi x} \widehat{f}(\xi) d\xi$,

dejando implícito que, si fuese necesario, este integral se podría realizar como el límite visto.

Teorema A.2.11 (Plancherel: Isometría de $L^2(\mathbb{R})$). $\mathcal{F}$ se extiende de $L^1(\mathbb{R}) \cap L^2(\mathbb{R})$ a una isometría suprayectiva de $L^2(\mathbb{R})$.

Demostración (Ideas de prueba elemental):

1. Sean $f, g \in L^1(\mathbb{R}) \cap L^2(\mathbb{R})$, $\mathcal{F}$ es isométrica:

$$\langle \widehat{f}, \widehat{g} \rangle_{L^2(\mathbb{R})} = \int_{\mathbb{R}} \int_{\mathbb{R}} f(x) e^{-2\pi i \xi x} dx \overline{\widehat{g}(\xi)} d\xi.$$

Por Fubini:

$$= \int_{\mathbb{R}} f(x) \left(\int_{\mathbb{R}} e^{-2\pi i \xi x} \overline{\widehat{g}(\xi)} d\xi \right) dx = \langle f, g \rangle_{L^2(\mathbb{R})}.$$

Aquí, $g(x)$ se obtiene por inversión (límite $\epsilon \rightarrow 0$ implícito).

2. Si $f \in L^2(\mathbb{R})$, definimos $f_m(x) = e^{-x^2/2m} f(x)$.

- Por el teorema de la convergencia dominada:

$$\|f_m - f\|_{L^2(\mathbb{R})}^2 = \int_{\mathbb{R}} \left| e^{-x^2/2m} - 1 \right|^2 |f(x)|^2 dx \xrightarrow{m \rightarrow \infty} 0.$$

- Por la desigualdad de Cauchy-Schwarz:

$$\int_{\mathbb{R}} |f_m(x)| dx \leq \left(\int_{\mathbb{R}} e^{-x^2/m} dx \right)^{1/2} \left(\int_{\mathbb{R}} |f(x)|^2 dx \right)^{1/2}.$$

$$\implies f_m \in L^1(\mathbb{R}) \cap L^2(\mathbb{R}). \text{ Por (1), } \|f_m\|_{L^2} = \left\| \widehat{f_m} \right\|_{L^2} \text{ y}$$

$$\left\| \widehat{f_m} - \widehat{f} \right\|_{L^2(\mathbb{R})} = \|f_m - f\|_{L^2(\mathbb{R})} \xrightarrow{m \rightarrow \infty} 0.$$

$$\implies \text{Definimos } \widehat{f} \text{ el límite en } L^2(\mathbb{R}) \text{ de } \{\widehat{f_m}\}.$$

3. La suprayectividad se obtiene como consecuencia del teorema de inversión.

■