
MATEMÁTICAS PARA EL APRENDIZAJE AUTOMÁTICO

Cuarto del Grado en Matemáticas

Hugo Marquerie

Profesor: Davide Barbieri

Facultad de Ciencias - Universidad Autónoma de Madrid

Segundo cuatrimestre

fecha

Puedes encontrar mi colección completa de apuntes en <https://hmarquer.github.io>.

Índice

1	Aprendizaje no supervisado	1
1.1	Principal component analysis (PCA)	1
1.1.1	Planteamiento del problema	1
1.1.2	Solución (teorema y algoritmo)	1
1.2	<i>Clustering</i> espectral en grafos	3
1.2.1	Grafos ponderados y definiciones básicas	3
1.2.2	El problema de corte normalizado (NCut)	4
1.2.3	Formulación variacional para $k = 2$	5
1.2.4	Relajación espectral del problema NCut	7
1.2.5	Interpretación probabilística: caminos aleatorios	7
1.2.6	<i>Spectral Clustering</i> para $k > 2$	8
1.2.7	Otros algoritmos de agrupamiento	9
2	Aprendizaje supervisado	13
2.1	Learning Theory	13
2.1.1	Formulación del problema	13
2.1.2	Sobre el objetivo y el aprendizaje estadístico	14
2.1.3	The Bias-Variance Tradeoff	17
2.2	Reproducing Kernel Hilbert Spaces	17
2.3	Clasificadores Lineales Binarios	22
2.3.1	Planteamiento del problema	22
2.3.2	Separabilidad por un hiperplano	23
2.3.3	Algoritmo del Perceptrón	25
2.3.4	Maximización del Margen: SVM	28
2.3.5	Soft-Margin SVM	31
2.3.6	Teorema de No Free Lunch (NFL)	35
3	Introducción a las redes neuronales	39
3.1	Multilayer Perceptron (MLP)	39
3.1.1	Backpropagation (Reverse differentiation)	40
A	Apéndices	45
A.1	Probabilidad condicionada	45
A.1.1	Esperanza condicionada respecto de una σ -álgebra	45

A.1.2	Esperanza condicionada dado un valor de una v.a.	46
A.1.3	De la esperanza condicionada a la medida condicionada	47
A.2	Análisis funcional	51

1. Aprendizaje no supervisado

1.1 Principal component analysis (PCA)

1.1.1 Planteamiento del problema

Sean $\{x_i\}_{i=1}^m \subset \mathbb{C}^n$ un conjunto de datos y sea $k < m$. El objetivo de PCA es encontrar la proyección de $\mathbb{C}^n$ de rango k (proyección sobre un subespacio $M \subset \mathbb{C}^n$ de dimensión k) que minimice el error cuadrático entre los datos originales y los datos proyectados:

$$\mathcal{E} = \sum_{i=1}^m \|x_i - \mathbb{P}_M x_i\|^2,$$

donde $\mathbb{P}_M$ es la proyección ortogonal sobre M . El PCA nos permite:

- Aproximar un conjunto de datos por un subespacio de dimensión menor.
- Una base ortonormal del subespacio M proporciona un diccionario “óptimo” para representar linealmente los datos.

1.1.2 Solución (teorema y algoritmo)

Sea $A = \begin{pmatrix} | & | & \cdots & | \\ x_1 & x_2 & \cdots & x_m \\ | & | & \cdots & | \end{pmatrix} \in \mathbb{C}^{n \times m}$ y sea $A = U\Sigma V^*$ su descomposición en valores singulares (SVD). Es decir, $U \in \mathbb{C}^{n \times n}$ y $V \in \mathbb{C}^{m \times m}$ son matrices unitarias y $\Sigma \in \mathbb{R}_+^{n \times m}$ es una matriz diagonal con los valores singulares $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$ en la diagonal, donde $r = \text{rang}(A)$.

Entonces, $M := \text{span}\{U^{(1)}, \dots, U^{(k)}\}$, donde $U^{(i)}$ es la i -ésima columna de U , es el subespacio que minimiza el error cuadrático $\mathcal{E}$. En consecuencia, la proyección ortogonal de los datos sobre M viene dada por

$$\forall x \in \mathbb{C}^n : \mathbb{P}_M x = \sum_{i=1}^k \langle x, U^{(i)} \rangle U^{(i)}.$$

Teorema 1.1.1. Sea $A \in \mathbb{C}^{n \times m}$, $A = U\Sigma V^*$ su SVD y $k \leq \text{rang}(A)$. Definimos

$$A_k = \sum_{i=1}^k \sigma_i U^{(i)} \otimes V^{(i)} \quad \text{donde} \quad (v \otimes w)_{ij} = v_i \overline{w_j}.$$

$$\implies \forall B \in \mathbb{C}^{n \times m} : \text{rang}(B) = k : \|A - B\|_{Fro}^2 \geq \|A - A_k\|_{Fro}^2 = \sum_{i=k+1}^{\text{rang } A} \sigma_i^2.$$

¿Por qué nos vale esto? La i -ésima columnas de A_k es $A_k^{(i)} = \sum_{\ell=1}^k \sigma_\ell \overline{V_{i\ell}} U^{(\ell)}$ donde $U^{(\ell)}$ es la ℓ -ésima columna de U y $\sigma_\ell \overline{V_{i\ell}} = \langle A^{(i)}, U^{(\ell)} \rangle = \langle x_i, U^{(\ell)} \rangle$. Entonces,

$$A_k^{(i)} = \sum_{\ell=1}^k \langle x_i, U^{(\ell)} \rangle U^{(\ell)} = \mathbb{P}_{\text{span}\{U^{(1)}, \dots, U^{(k)}\}} x_i = \mathbb{P}_M x_i.$$

Demostración: Dividimos la demostración en diferentes pasos:

Paso 1. Recordamos que la norma de Frobenius se puede escribir como $\|A\|_{\text{Fro}}^2 = \text{tr}(A^* A)$.

Por tanto,

$$\begin{aligned} \|A - A_k\|_{\text{Fro}}^2 &= \|U\Sigma V^* - U\Sigma_k V^*\|_{\text{Fro}}^2 = \|U(\Sigma - \Sigma_k)V^*\|_{\text{Fro}}^2 \\ &= \text{tr}(V(\Sigma - \Sigma_k)^* V^*) = \sum_{\ell=k+1}^{\text{rang } A} \sigma_\ell^2, \end{aligned}$$

puesto que $\Sigma - \Sigma_k$ es una matriz diagonal con los ceros en los primeros k elementos de la diagonal y los valores singulares $\sigma_{k+1}, \dots, \sigma_r$ en el resto.

Por tanto, basta demostrar que $\forall B \in \mathbb{C}^{n \times m} : \text{rang}(B) = k : \|A - B\|_{\text{Fro}}^2 \geq \sum_{\ell=k+1}^{\text{rang } A} \sigma_\ell^2$.

Paso 2. Sea $B \in \mathbb{C}^{n \times m}$ con $\text{rang}(B) = k$. Sea $B = XTY^*$ su SVD, con $X \in \mathbb{C}^{n \times n}$ y $Y \in \mathbb{C}^{m \times m}$ unitarias y $T \in \mathbb{R}_+^{n \times m}$ diagonal. Entonces,

$$\begin{aligned} \|A - B\|_{\text{Fro}}^2 &= \|A\|_{\text{Fro}}^2 + \text{tr}(B^* B - B^* A - A^* B) \\ &= \|A\|_{\text{Fro}}^2 + \sum_{\ell=1}^k t_\ell^2 - \sum_{\ell=1}^k t_\ell \text{tr}((y_\ell \otimes x_\ell)A + A^*(x_\ell \otimes y_\ell)), \end{aligned}$$

como $\sum_{\ell=1}^k t_\ell^2 = \sum_{\ell=1}^k t_\ell^2 \text{tr}(C_{y_\ell \otimes y_\ell})$ y $(y_\ell \otimes x_\ell)A = y_\ell \otimes (A^* x_\ell)$, tenemos que

$$\begin{aligned} \|A - B\|_{\text{Fro}}^2 &= \|A\|_{\text{Fro}}^2 + \sum_{\ell=1}^k \text{tr}((A^* x_\ell - t_\ell y_\ell) \otimes (A^* x_\ell - t_\ell y_\ell)) - \sum_{\ell=1}^k \text{tr}(A^* x_\ell \otimes A^* x_\ell) \\ &\geq \|A\|_{\text{Fro}}^2 - \sum_{\ell=1}^k \|A^* x_\ell\|^2, \end{aligned}$$

donde la desigualdad se obtiene porque $\text{tr}(v \otimes v) = \|v\|^2 \geq 0$.

Paso 3. Acotamos ahora $\sum_{\ell=1}^k \|A^* x_\ell\|^2$. Como $A = U\Sigma V^*$, tenemos que $A^* = V\Sigma^* U^*$, y por tanto $A^* x_\ell = V\Sigma^* U^* x_\ell$. Entonces,

$$\sum_{\ell=1}^k \|A^* x_\ell\|^2 = \sum_{\ell=1}^k \|V\Sigma^* U^* x_\ell\|^2 = \sum_{\ell=1}^k \|\Sigma^* U^* x_\ell\|^2,$$

donde hemos usado que V es unitaria y por tanto preserva la norma. Desarrollando la

norma,

$$\sum_{\ell=1}^k \|\Sigma^* U^* x_\ell\|^2 = \sum_{\ell=1}^k \sum_{i=1}^{\text{rang } A} \sigma_i^2 |\langle U^{(i)}, x_\ell \rangle|^2 = \sum_{i=1}^{\text{rang } A} \sigma_i^2 \sum_{\ell=1}^k |\langle U^{(i)}, x_\ell \rangle|^2.$$

Observamos que $\sum_{\ell=1}^k |\langle U^{(i)}, x_\ell \rangle|^2 = \|\mathbb{P}_k U^{(i)}\|^2$, donde $\mathbb{P}_k$ es el proyector ortogonal sobre $\text{span}\{x_1, \dots, x_k\}$. Denotando $p_i = \|\mathbb{P}_k U^{(i)}\|^2$, tenemos que:

- $p_i \leq 1$ para todo i , ya que $\|\mathbb{P}_k U^{(i)}\| \leq \|U^{(i)}\| = 1$.
- $\sum_{i=1}^{\text{rang } A} p_i \leq k$, ya que $\mathbb{P}_k$ proyecta sobre un subespacio de dimensión k .

Para maximizar $\sum_{i=1}^{\text{rang } A} \sigma_i^2 p_i$ sujeto a estas restricciones, como $\sigma_1 \geq \sigma_2 \geq \dots$, el máximo se alcanza cuando $p_1 = \dots = p_k = 1$ y $p_i = 0$ para $i > k$. Por tanto,

$$\sum_{\ell=1}^k \|A^* x_\ell\|^2 \leq \sum_{i=1}^k \sigma_i^2.$$

Paso 4. Retomando la cota del Paso 2,

$$\|A - B\|_{\text{Fro}}^2 \geq \|A\|_{\text{Fro}}^2 - \sum_{\ell=1}^k \|A^* x_\ell\|^2 \geq \|A\|_{\text{Fro}}^2 - \sum_{i=1}^k \sigma_i^2 = \sum_{i=k+1}^{\text{rang } A} \sigma_i^2,$$

lo que, junto con el Paso 1, concluye la demostración. ■

1.2 *Clustering* espectral en grafos

El objetivo del *clustering* espectral es particionar un conjunto de datos en grupos de manera que los elementos de un mismo grupo estén “más conectados” entre sí que con elementos de otros grupos. Para formalizar esto, representamos los datos como un grafo ponderado.

1.2.1 Grafos ponderados y definiciones básicas

Definición 1.2.1 (Grafo ponderado no dirigido). Un grafo ponderado no dirigido es una tupla $G = (V, W)$ donde:

- $V = \{v_1, \dots, v_m\}$ es el conjunto de vértices.
- $W \in \mathbb{R}^{m \times m}$ es la matriz de pesos, con $w_{ij} = w_{ji} \geq 0$.

Ejemplo 1.2.1. Sea (X, d) un espacio métrico y sea $\{x_i\}_{i=1}^m \subset X$ un conjunto de datos. Dado $\varepsilon > 0$, podemos construir un grafo ponderado donde $V = \{1, \dots, m\}$ y

$$w_{ij} = \begin{cases} e^{-d(x_i, x_j)^2} & \text{si } d(x_i, x_j) \leq \varepsilon, \\ 0 & \text{en otro caso.} \end{cases}$$

Este grafo captura las relaciones de vecindad entre los datos: cuanto más cercanos estén x_i y x_j , mayor será el peso w_{ij} .

Definición 1.2.2 (Grado, volumen y conexión). Sea $G = (V, W)$ un grafo ponderado.

- El **grado** del vértice i es $d_i = \sum_{j=1}^m w_{ij}$. Denotamos por $D = \text{diag}(d_1, \dots, d_m)$ la matriz diagonal de grados.
- El **volumen** de un subconjunto $S \subset V$ es $\text{vol}(S) = \sum_{i \in S} d_i$.
- La **conexión** entre $S, T \subset V$ es $W(S, T) = \sum_{i \in S} \sum_{j \in T} w_{ij}$.

Definición 1.2.3 (Laplaciano de un grafo). Sea $G = (V, W)$ un grafo ponderado. El **laplaciano** de G es la matriz $L = D - W$.

Observación 1.2.4 (Analogía con el laplaciano continuo). El nombre “laplaciano” proviene de la siguiente analogía. Sea $f: V \rightarrow \mathbb{R}$ una función sobre los vértices (escribimos $f_i = f(v_i)$). Entonces,

$$\langle f, Lf \rangle = \sum_{i=1}^m d_i f_i^2 - \sum_{i,j=1}^m w_{ij} f_i f_j = \frac{1}{2} \sum_{i,j=1}^m w_{ij} (f_i - f_j)^2.$$

Esta expresión mide la “variación” de f sobre el grafo, análogamente a cómo para $f \in \mathcal{C}^2(\mathbb{R}^d)$ con $f, |\nabla f|, \Delta f \in L^2(\mathbb{R}^d)$, se tiene $\langle f, -\Delta f \rangle_{L^2} = \|\nabla f\|_{L^2}^2$.

1.2.2 El problema de corte normalizado (NCut)

Definición 1.2.5 (Corte y corte normalizado). Sea $G = (V, W)$ un grafo ponderado y sea $\{A_j\}_{j=1}^k$ una partición de V (es decir, $V = \bigsqcup_{j=1}^k A_j$).

- El **corte** de la partición es

$$\text{cut}(\{A_j\}_{j=1}^k) = \sum_{j=1}^k W(A_j, A_j^c),$$

que mide el “costo” de separar el grafo en los subgrupos $A_1, \dots, A_k$.

- El **corte normalizado** (NCut) es

$$\text{Ncut}(\{A_j\}_{j=1}^k) = \sum_{j=1}^k \frac{W(A_j, A_j^c)}{\text{vol}(A_j)},$$

que penaliza además los grupos con volumen pequeño.

Observación 1.2.6. Para $k = 2$ (partición en dos grupos A y $B = A^c$), el corte normalizado se puede escribir como

$$\text{Ncut}(A, B) = W(A, B) \left(\frac{1}{\text{vol}(A)} + \frac{1}{\text{vol}(B)} \right).$$

Esta expresión es el producto de dos términos: la **separación** $W(A, B)$ (queremos que sea pequeña, es decir, A y B poco conectados) y el **balance** $\frac{1}{\text{vol}(A)} + \frac{1}{\text{vol}(B)}$ (que es mínimo cuando $\text{vol}(A) = \text{vol}(B)$). Por tanto, minimizar NCut favorece particiones con grupos bien separados y de tamaño equilibrado.

El **problema NCut** consiste en encontrar la partición que minimiza el corte normalizado:

$$\{A_j^*\}_{j=1}^k = \arg \min_{\{A_j\}_{j=1}^k \text{ partición}} \text{Ncut}(\{A_j\}_{j=1}^k).$$

1.2.3 Formulación variacional para $k = 2$

El siguiente lema relaciona el corte normalizado con una forma cuadrática.

Lema 1.2.1. Sea $V = A \cup B$ una partición y definamos $f^{(A,B)}: V \rightarrow \mathbb{R}$ por

$$f_i^{(A,B)} = \begin{cases} \sqrt{\frac{\text{vol}(B)}{\text{vol}(A)}} & \text{si } i \in A, \\ -\sqrt{\frac{\text{vol}(A)}{\text{vol}(B)}} & \text{si } i \in B. \end{cases}$$

Entonces,

$$\text{Ncut}(A, B) = \frac{1}{2 \text{vol}(V)} \sum_{i,j=1}^m w_{ij} (f_i^{(A,B)} - f_j^{(A,B)})^2.$$

Demostración: Observamos que $(f_i - f_j)^2 = 0$ si i, j están en el mismo grupo. Si $i \in A$ y $j \in B$ (o viceversa), entonces

$$(f_i - f_j)^2 = \left(\sqrt{\frac{\text{vol}(B)}{\text{vol}(A)}} + \sqrt{\frac{\text{vol}(A)}{\text{vol}(B)}} \right)^2 = \frac{\text{vol}(B)}{\text{vol}(A)} + \frac{\text{vol}(A)}{\text{vol}(B)} + 2.$$

Simplificando esta expresión y usando que $W(A, B) = W(B, A)$, se obtiene

$$\sum_{i,j=1}^m w_{ij}(f_i - f_j)^2 = 2W(A, B) \left(\frac{\text{vol}(B)}{\text{vol}(A)} + \frac{\text{vol}(A)}{\text{vol}(B)} + 2 \right) \cdot \frac{\text{vol}(A) \text{vol}(B)}{(\text{vol}(A) + \text{vol}(B))^2} \cdot \text{vol}(V),$$

que tras simplificar da $2 \text{vol}(V) \text{Ncut}(A, B)$. ■

Teorema 1.2.2. *El problema Ncut con $k = 2$ es equivalente al problema de optimización*

$$\arg \min \left\{ \frac{\langle f, Lf \rangle}{\langle f, Df \rangle} : \sum_{i=1}^m f_i d_i = 0, f_i \in \left\{ \pm \sqrt{\frac{\text{vol}(B)}{\text{vol}(A)}} \right\} \right\}.$$

Demostración: La demostración se divide en tres pasos:

Paso 1. Por la observación sobre el laplaciano, para cualquier $f \in \mathbb{R}^m$,

$$\langle f, Lf \rangle = \frac{1}{2} \sum_{i,j=1}^m w_{ij}(f_i - f_j)^2.$$

Paso 2. Sea $f: V \rightarrow \{p^2, -q^2\}$ y definamos $A = \{i : f_i = p^2\}$, $B = \{i : f_i = -q^2\}$. La restricción $\sum_{i=1}^m d_i f_i = 0$ implica

$$p^2 \text{vol}(A) = q^2 \text{vol}(B) \implies \frac{p^2}{q^2} = \frac{\text{vol}(B)}{\text{vol}(A)}.$$

De aquí se deduce que $f = pq f^{(A,B)}$ para cierto escalar pq .

Paso 3. Con f como en el paso anterior,

$$\langle f, Df \rangle = \sum_{i=1}^m d_i f_i^2 = p^4 \text{vol}(A) + q^4 \text{vol}(B) = p^2 q^2 \text{vol}(V).$$

Por tanto, usando el Lema 1.2.1,

$$\frac{\langle f, Lf \rangle}{\langle f, Df \rangle} = \frac{\langle f^{(A,B)}, Lf^{(A,B)} \rangle}{\langle f^{(A,B)}, Df^{(A,B)} \rangle} = \text{Ncut}(A, B).$$
■

Observación 1.2.7 (Complejidad computacional). El problema de optimización del Teorema 1.2.2 es **NP-completo**. Esto significa que, salvo que $P = NP$, no existe algoritmo que lo resuelva en tiempo polinomial.

1.2.4 Relajación espectral del problema NCut

Para obtener un algoritmo eficiente, relajamos el problema eliminando la restricción de que f tome valores discretos.

Observación 1.2.8 (Cambio de variable y cociente de Rayleigh). Sea $g = D^{1/2}f$ y definamos $M = D^{-1/2}LD^{-1/2}$ (el **laplaciano normalizado**). Entonces,

$$\frac{\langle f, Lf \rangle}{\langle f, Df \rangle} = \frac{\langle g, Mg \rangle}{\|g\|^2},$$

que es el **cociente de Rayleigh** de la matriz M . Además, M es simétrica y semidefinida positiva, con

$$\langle g, Mg \rangle = \frac{1}{2} \sum_{i,j=1}^m w_{ij} \left(\frac{g_i}{\sqrt{d_i}} - \frac{g_j}{\sqrt{d_j}} \right)^2 \geq 0.$$

La restricción $\sum_{i=1}^m d_i f_i = 0$ se traduce en $g \perp D^{1/2}\mathbf{1}$, donde $\mathbf{1}$ es el vector de unos.

El problema relajado consiste en minimizar el cociente de Rayleigh sobre todos los vectores $g \perp D^{1/2}\mathbf{1}$:

$$\min_{g \perp D^{1/2}\mathbf{1}} \frac{\langle g, Mg \rangle}{\|g\|^2}.$$

Por el teorema del cociente de Rayleigh (ver Apéndice), el mínimo se alcanza en el autovector de M correspondiente al segundo menor autovalor (el menor autovalor es 0 con autovector $D^{1/2}\mathbf{1}$).

Algoritmo de *Spectral Clustering* para $k = 2$:

1. Calcular el autovector g_2 de $M = D^{-1/2}LD^{-1/2}$ correspondiente al menor autovalor no nulo.
2. Definir la partición: $A = \{i \in V : g_2(i) > 0\}$ y $B = A^c$.

1.2.5 Interpretación probabilística: caminos aleatorios

La matriz $P = D^{-1}W$ es una **matriz de transición de Markov**:

$$p_{ij} = \frac{w_{ij}}{d_i} = \frac{w_{ij}}{\sum_{k=1}^m w_{ik}}, \quad \text{con } \sum_{j=1}^m p_{ij} = 1.$$

Es decir, $p_{ij} = \mathbb{P}(i \rightarrow j)$ es la probabilidad de transitar del vértice i al vértice j en un paso del camino aleatorio sobre el grafo. La distribución estacionaria es $\pi_i = \frac{d_i}{\text{vol}(V)}$.

Proposición 1.2.3. Sea $\{X_t\}_{t \geq 0}$ el camino aleatorio sobre G con $X_0 \sim \pi$. Entonces,

$$\mathbb{P}(X_t \in A \mid X_{t-1} \in B) + \mathbb{P}(X_t \in B \mid X_{t-1} \in A) = \text{Ncut}(A, B).$$

Demostración: Calculamos directamente:

$$\mathbb{P}(X_0 \in A, X_1 \in B) = \sum_{i \in A} \sum_{j \in B} \pi_i p_{ij} = \frac{1}{\text{vol}(V)} \sum_{i \in A} \sum_{j \in B} w_{ij} = \frac{W(A, B)}{\text{vol}(V)}.$$

Como $\mathbb{P}(X_0 \in A) = \frac{\text{vol}(A)}{\text{vol}(V)}$, se tiene

$$\mathbb{P}(X_1 \in B \mid X_0 \in A) = \frac{W(A, B)}{\text{vol}(A)}.$$

El mismo argumento da $\mathbb{P}(X_1 \in A \mid X_0 \in B) = \frac{W(B, A)}{\text{vol}(B)}$, y sumando obtenemos $\text{Ncut}(A, B)$. ■

Esta proposición nos da una interpretación intuitiva: **minimizar NCut equivale a minimizar la probabilidad de que un camino aleatorio “salte” entre grupos.**

1.2.6 Spectral Clustering para $k > 2$

Lema 1.2.4. Sea $G = (V, W)$ un grafo con K componentes conexas $V = \bigsqcup_{\ell=1}^K A_\ell$ (es decir, $w_{ij} = 0$ si $i \in A_\ell, j \in A_{\ell'}$ con $\ell \neq \ell'$). Entonces,

$$\ker L = \text{span}\{\chi_{A_1}, \dots, \chi_{A_K}\},$$

donde χ_{A_ℓ} es la función indicadora de A_ℓ .

Demostración: Para $K = 1$ (grafo conexo), $\langle f, Lf \rangle = \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2 = 0$ implica $f_i = f_j$ para todos los pares con $w_{ij} > 0$, es decir, $f = \alpha \mathbf{1}$.

Para $K > 1$, el laplaciano tiene estructura de bloques diagonal (tras reordenar los vértices), y el resultado se aplica a cada bloque. ■

Observación 1.2.9 (Heurística para grafos “casi” desconectados). Si el grafo es conexo pero tiene K grupos “naturales” (muy conectados internamente, poco conectados entre sí), entonces:

- El autovector de M con autovalor 0 es $D^{1/2} \mathbf{1}$.
- Los siguientes $K - 1$ autovectores son aproximadamente $D^{1/2} \chi_{A_\ell}$, correspondientes a

autovalores pequeños.

Algoritmo de Shi-Malik:

1. Calcular los $k + 1$ autovectores de M con menores autovalores: $\{(\lambda_\ell, f_\ell)\}_{\ell=1}^{k+1}$ con $\lambda_1 = 0 < \lambda_2 \leq \dots \leq \lambda_{k+1}$.
2. Representar cada vértice v_i mediante el *embedding*

$$\varphi(v_i) = (f_2(v_i), \dots, f_{k+1}(v_i)) \in \mathbb{R}^k.$$

Esta técnica se conoce como *Laplacian Eigenmaps*.

3. Aplicar un algoritmo de agrupamiento clásico (como k -means) sobre los puntos $\{\varphi(v_i)\}_{i=1}^m \subset \mathbb{R}^k$.

Observación 1.2.10 (Elección de k). El número de grupos k se puede estimar buscando un “codo” en el espectro de M : un salto significativo entre λ_k y λ_{k+1} sugiere que hay k grupos bien definidos.

1.2.7 Otros algoritmos de agrupamiento

Definición 1.2.11 (K -means). Sean $\mathcal{D} = \{x_i\}_{i=1}^m \subset \mathbb{R}^N$ y $K \in \mathbb{N}$. El problema de K -means consiste en encontrar una partición $\mathcal{D} = \bigsqcup_{\ell=1}^K S_\ell$ que minimice

$$\sum_{\ell=1}^K \sum_{x \in S_\ell} \|x - \mu_\ell\|^2, \quad \text{donde } \mu_\ell = \frac{1}{|S_\ell|} \sum_{x \in S_\ell} x$$

es el centroide del grupo S_ℓ .

Observación 1.2.12. El problema de K -means es NP-completo. Los algoritmos prácticos (como el algoritmo de Lloyd) son heurísticas que encuentran mínimos locales.

Definición 1.2.13 (Agrupamiento jerárquico aglomerativo). Sea $\mathcal{D} = \{x_i\}_{i=1}^m \subset (X, d)$ un espacio métrico y sea $R: \mathcal{P}(X) \times \mathcal{P}(X) \rightarrow \mathbb{R}$ una distancia entre subconjuntos (por ejemplo, *single linkage*, *complete linkage* o *average linkage*).

- (i) Inicialmente, cada punto forma su propio grupo.
- (ii) Iterativamente, se fusionan los dos grupos más cercanos según R .
- (iii) Se construye un **dendrograma** que representa la jerarquía de fusiones.
- (iv) Se corta el dendrograma a un nivel t para obtener la partición final.

Observación 1.2.14. La elección del nivel de corte t es análoga a la búsqueda de un “codo” en el espectro del laplaciano.

Apéndice de Álgebra Lineal

Este apéndice recoge resultados de álgebra lineal utilizados en el capítulo, particularmente en la sección de clustering espectral.

Matrices autoadjuntas

Lema 1.2.5 (Caracterización de matrices autoadjuntas). *Sea $A \in \mathbb{C}^{m \times m}$ una matriz. Si $\langle Av, v \rangle_{\mathbb{C}^m} \in \mathbb{R}$ para todo $v \in \mathbb{C}^m$, entonces A es autoadjunta, es decir, $A = A^*$.*

Demostración: Definimos $M = A - A^*$ y mostramos que $M = 0$.

Paso 1. Como $\langle Av, v \rangle \in \mathbb{R}$ para todo v , tenemos que $\langle Av, v \rangle = \overline{\langle Av, v \rangle} = \langle v, Av \rangle$. Por tanto,

$$\langle Mv, v \rangle = \langle Av, v \rangle - \langle A^*v, v \rangle = \langle Av, v \rangle - \langle v, Av \rangle = 0.$$

Paso 2. Usando la identidad de polarización, para cualesquiera $v, w \in \mathbb{C}^m$:

$$\langle M(v + w), v + w \rangle - \langle M(v - w), v - w \rangle = 2 \langle Mv, w \rangle + 2 \langle Mw, v \rangle.$$

Por el Paso 1, el lado izquierdo es cero, luego $\langle Mv, w \rangle = -\langle Mw, v \rangle$.

Como $\langle Mw, v \rangle = \overline{\langle v, Mw \rangle}$ y $\langle v, Mw \rangle = \overline{\langle Mw, v \rangle}$, se tiene $\langle Mv, w \rangle = -\langle Mw, v \rangle = -\overline{\langle v, Mw \rangle}$. Sustituyendo $\langle Mw, v \rangle = -\langle Mv, w \rangle$:

$$\langle Mv, w \rangle = -\overline{\langle Mv, w \rangle} \implies \langle Mv, w \rangle \in i\mathbb{R}.$$

Paso 3. Análogamente, considerando $v + iw$ y $v - iw$:

$$\langle M(v + iw), v + iw \rangle - \langle M(v - iw), v - iw \rangle = 2i \langle Mv, w \rangle - 2i \langle Mw, v \rangle.$$

Por el Paso 1, esto es cero, luego $\langle Mv, w \rangle = \langle Mw, v \rangle$.

Paso 4. Combinando los Pasos 2 y 3: del Paso 2 tenemos $\langle Mv, w \rangle = -\langle Mw, v \rangle$, y del Paso 3 tenemos $\langle Mv, w \rangle = \langle Mw, v \rangle$. Por tanto, $\langle Mv, w \rangle = -\langle Mw, v \rangle$, lo que implica $\langle Mv, w \rangle = 0$ para todos $v, w \in \mathbb{C}^m$. Luego $M = 0$.

■

Observación 1.2.15 (Aplicación al laplaciano normalizado). En el contexto del clustering espectral, la matriz $M = D^{-1/2}LD^{-1/2}$ satisface

$$\langle Mg, g \rangle = \frac{1}{2} \sum_{i,j=1}^m w_{ij} \left| \frac{g_i}{\sqrt{d_i}} - \frac{g_j}{\sqrt{d_j}} \right|^2 \in \mathbb{R}_{\geq 0}$$

para todo $g \in \mathbb{C}^m$. Por el lema anterior, M es autoadjunta (y además semidefinida positiva).

El cociente de Rayleigh

Definición 1.2.16 (Cociente de Rayleigh). Sea $M \in \mathbb{R}^{m \times m}$ una matriz simétrica. El **cociente de Rayleigh** de M es la función $R_M: \mathbb{R}^m \setminus \{0\} \rightarrow \mathbb{R}$ definida por

$$R_M(x) = \frac{\langle Mx, x \rangle}{\|x\|^2}.$$

Lema 1.2.6 (Teorema min-max de Rayleigh). Sea $M \in \mathbb{R}^{m \times m}$ simétrica y semidefinida positiva. Sean $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_m$ sus autovalores (contados con multiplicidad) y $\{v_1, \dots, v_m\}$ una base ortonormal de autovectores correspondientes. Entonces:

$$\min_{x \in \mathbb{R}^m \setminus \{0\}} R_M(x) = \lambda_1, \quad \text{con} \quad \arg \min_{x \neq 0} R_M(x) = \ker(M - \lambda_1 I).$$

Demostración: Como $\{v_1, \dots, v_m\}$ es una base ortonormal, cualquier $x \in \mathbb{R}^m$ se escribe como $x = \sum_{i=1}^m c_i v_i$ con $c_i = \langle x, v_i \rangle$. Entonces:

$$Mx = \sum_{i=1}^m \lambda_i c_i v_i, \quad \|x\|^2 = \sum_{i=1}^m c_i^2, \quad \langle Mx, x \rangle = \sum_{i=1}^m \lambda_i c_i^2.$$

Definiendo $p_i = \frac{c_i^2}{\sum_{j=1}^m c_j^2}$, tenemos que $p_i \geq 0$ y $\sum_{i=1}^m p_i = 1$. Por tanto,

$$R_M(x) = \sum_{i=1}^m \lambda_i p_i$$

es una combinación convexa de los autovalores. El mínimo de una combinación convexa se alcanza en el menor de los valores, es decir, $R_M(x) \geq \lambda_1$, con igualdad si y solo si $p_1 = 1$ (y $p_i = 0$ para $i > 1$), lo que ocurre cuando $x \in \ker(M - \lambda_1 I)$. ■

Corolario 1.2.7 (Segundo autovalor). Con la notación del lema anterior, si $V_1 = \ker(M - \lambda_1 I)$ es el autoespacio correspondiente a λ_1 , entonces

$$\min_{x \perp V_1, x \neq 0} R_M(x) = \lambda_2.$$

Más generalmente, para $k \geq 1$:

$$\lambda_k = \min_{\substack{x \perp v_1, \dots, v_{k-1} \\ x \neq 0}} R_M(x).$$

Demostración: Si $x \perp V_1$, entonces $c_i = 0$ para todo i tal que $\lambda_i = \lambda_1$. Por tanto, $R_M(x) = \sum_{\lambda_i > \lambda_1} \lambda_i p_i \geq \lambda_2$, con igualdad cuando x es autovector de λ_2 . ■

Observación 1.2.17 (Aplicación al clustering espectral). En el problema NCut relajado, buscamos minimizar $R_M(g) = \frac{\langle Mg, g \rangle}{\|g\|^2}$ sujeto a $g \perp D^{1/2}\mathbf{1}$. Como $D^{1/2}\mathbf{1}$ es el autovector de M con autovalor $\lambda_1 = 0$, el Corolario 1.2.7 nos dice que el mínimo se alcanza en el autovector correspondiente al segundo menor autovalor λ_2 .

2. Aprendizaje supervisado

2.1 Learning Theory

La *teoría del aprendizaje* (*learning theory*) es el marco matemático que formaliza el problema central del aprendizaje automático: a partir de un conjunto finito de observaciones (datos), inferir una relación funcional que permita hacer predicciones sobre datos no observados. El enfoque es inherentemente **estadístico**: se modela la generación de datos como un proceso aleatorio gobernado por una distribución de probabilidad desconocida, y el objetivo es aproximar, lo mejor posible, la dependencia subyacente entre las variables de entrada y de salida.

2.1.1 Formulación del problema

Sean X e Y espacios topológicos de Hausdorff:

- X es el **espacio de entrada** (o *espacio de características*): representa el dominio de las variables observables a partir de las cuales queremos hacer predicciones. Por ejemplo, $X = \mathbb{R}^d$ cuando cada observación se describe mediante d atributos numéricos.
- Y es el **espacio de salida** (o *espacio de respuestas*): representa el dominio de los valores que queremos predecir. En problemas de regresión, típicamente $Y = \mathbb{R}$ o $Y = \mathbb{R}^k$; en clasificación binaria, $Y = \{-1, +1\}$.

Sea $Z = X \times Y$ el espacio producto, dotado de la topología producto (que es de Hausdorff por serlo X e Y). Sea $\mathcal{B}$ la σ -álgebra de Borel de Z y $(Z, \mathcal{B}, \rho)$ un espacio de probabilidad donde:

- ρ es una medida de probabilidad **desconocida** que modela el mecanismo de generación de datos: cada par (x, y) observado se entiende como una realización de una variable aleatoria con distribución ρ .
- La estructura de producto $Z = X \times Y$ refleja la distinción entre lo que observamos (x) y lo que queremos predecir (y).
- Nos interesa el fenómeno de generación de datos en Z descrito por ρ desde el punto de vista de la **dependencia de Y respecto de X** : queremos entender cómo la variable de salida y depende de la entrada x .

Por tanto, el objetivo es aproximar la **función de regresión**, es decir, la función $f_\rho: X \rightarrow Y$ que asigna a cada $x \in X$ el valor esperado de y condicionado a x :

$$f_\rho(x) := \int_Y y \, d\rho(y | x),$$

donde $\rho(y | x)$ es la medida de probabilidad condicional de y dado x . La función f_ρ es, en cierto sentido, la *mejor predicción posible* de y dado x , ya que minimiza el error cuadrático medio (como se demostrará más adelante).

Sea $\pi: Z \rightarrow X$ la proyección $\pi(x, y) = x$. Sea ρ_X la medida de probabilidad marginal en X definida en $E \subset X$ abierto por $\rho_X(E) = \rho(\pi^{-1}(E))$.

Entonces existe la medida de probabilidad condicional que satisface, $\forall \varphi \in L^1(Z, \rho)$:

$$\begin{aligned} \int_Z \varphi(z) \, d\rho(z) &= \int_X \left(\int_Y \varphi(x, y) \, d\rho(y | x) \right) d\rho_X(x), \\ \int_Y d\rho(y | x) &= 1 \quad \rho_X\text{-casi todo } x \in X. \end{aligned}$$

2.1.2 Sobre el objetivo y el aprendizaje estadístico

Como no se dispone de ρ , hay que trabajar con **muestras**: $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset Z$.

- Aprendizaje *supervisado*: para todo $x_i \in X$ hay un $y_i \in Y$ que proporciona un objetivo.
- El resultado de todo aprendizaje es epistemológicamente una aproximación, porque la búsqueda de una función de regresión se tiene que hacer dentro de un **espacio de las hipótesis** definido *a priori* antes de conocer ρ .

Ejemplo 2.1.1 (Best fit polinomial de datos físicos). Supongamos que una ley física $F: \mathbb{R} \rightarrow \mathbb{R}$, y fenómenos aleatorios (es decir, que se escapan a nuestro conocimiento), generan datos:

$$y_i = F(x_i) + \varepsilon_i, \quad \text{donde } \{\varepsilon_i\}_{i=1}^m \text{ son v.a.i.d.}$$

Si queremos aproximar F con un polinomio de grado $\leq n$, podemos intentar minimizar

$$\sum_{i=1}^m |y_i - f_w(x_i)|^2, \quad \text{para } f_w(x) = \sum_{i=0}^n w_i x^i.$$

¿Cómo encaja el ejemplo con el problema general?

Supongamos que $\varepsilon \sim \mathcal{N}(0, 1)$, $X = [0, 1]$, ρ_X distribución uniforme en X .

- $\mathcal{F} = F(x)$ es una variable aleatoria en $F(X)$ con medida de probabilidad

$$\mu(\mathcal{F} < t) = \rho_X(\{x : F(x) < t\}) = \rho_X(F^{-1}(-\infty, t)) = F_*\rho_X(-\infty, t),$$

donde $F_*\rho_X$ es la medida pushforward.

- Si $y = F(x)$, se define una medida de probabilidad condicional $\rho(y | x)$ tal que

$$\int_{\mathbb{R}} \varphi(y) d\rho(y | x) = \varphi(F(x)) \quad \forall \varphi \in C_c(\mathbb{R}),$$

que corresponde a una δ de Dirac en $y = F(x)$.

- La probabilidad condicional $\rho(y | x)$ para $y = F(x) + \varepsilon$ es $\mathcal{N}(F(x), 1)$, por lo que

$$d\rho(x, y) = e^{-\frac{(y-F(x))^2}{2}} \rho_X(dx) dy.$$

- Por lo tanto, tenemos que

$$f_\rho(x) = \int_Y y d\rho(y | x) = F(x).$$

La minimización de

$$\sum_{i=1}^m |y_i - f_w(x_i)|^2$$

proporciona una aproximación polinomial empírica de la ley F .

Definición 2.1.1 (Error cuadrático). Sea $Y = \mathbb{R}^k$, ρ una probabilidad en $\mathcal{Z} = X \times Y$, $f : X \rightarrow Y$ una función ρ -medible, y $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset \mathcal{Z}$ un conjunto de datos. Definimos:

$$\mathcal{E}[f] := \int_{\mathcal{Z}} |f(x) - y|^2 d\rho(x, y) \quad (\text{Error de generalización}),$$

$$\mathcal{E}_{\mathcal{D}}[f] := \frac{1}{m} \sum_{i=1}^m |f(x_i) - y_i|^2 \quad (\text{Error empírico}).$$

Proposición 2.1.1. Para toda función $f : X \rightarrow Y$ ρ -medible, se cumple que:

$$\mathcal{E}[f] = \int_X |f(x) - f_\rho(x)|^2 d\rho_X(x) + \mathcal{E}[f_\rho],$$

donde $f_\rho(x)$ es el valor esperado condicional definido como:

$$f_\rho(x) = \int_Y y d\rho(y | x).$$

La primera integral representa el *error de aproximar* f_ρ con f , mientras que $\mathcal{E}[f_\rho]$ es el *error intrínseco* debido a la variabilidad de la distribución conjunta ρ en Z . Más específicamente:

$$\mathcal{E}[f_\rho] = \int_X \left(\int_Y |f_\rho(x) - y|^2 d\rho(y | x) \right) d\rho_X(x),$$

donde el término interno mide la *varianza en y* de la distribución condicional $\rho(y | x)$ respecto a su valor medio $f_\rho(x)$.

Demostración:

$$\begin{aligned} \mathcal{E}[f] &= \int_{X \times Y} |f(x) - y|^2 d\rho(x, y) \\ &= \int_{X \times Y} |f(x) - y + f_\rho(x) - f_\rho(x)|^2 d\rho(x, y) \\ &= \int_{X \times Y} |f(x) - f_\rho(x)|^2 d\rho(x, y) + \int_{X \times Y} |f_\rho(x) - y|^2 d\rho(x, y) \\ &\quad + 2 \int_{X \times Y} (f(x) - f_\rho(x))(f_\rho(x) - y) d\rho(x, y) \\ &= \int_X |f(x) - f_\rho(x)|^2 d\rho_X(x) + \mathcal{E}[f_\rho] + 2\mathcal{I}[f, f_\rho], \\ \mathcal{I}[f, f_\rho] &= \int_X (f(x) - f_\rho(x)) \left(\int_Y (f_\rho(x) - y) d\rho(y | x) \right) d\rho_X(x). \end{aligned}$$

■

Definición 2.1.2 (Hipótesis y función objetivo). Sea $\mathcal{H}$ un conjunto de funciones $X \rightarrow Y$ y $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset X \times Y$ un conjunto de datos. Denotamos por $f_{\mathcal{H}}$ y por $f_{\mathcal{H}, \mathcal{D}}$ a las funciones de $\mathcal{H}$ tales que:

$$\forall f \in \mathcal{H} : \mathcal{E}[f_{\mathcal{H}}] \leq \mathcal{E}[f],$$

$$\forall f \in \mathcal{H} : \mathcal{E}_{\mathcal{D}}[f_{\mathcal{H}, \mathcal{D}}] \leq \mathcal{E}_{\mathcal{D}}[f].$$

Observación 2.1.3. $g = f_{\mathcal{H}} \iff \forall f \in \mathcal{H} : \|f_{\mathcal{H}} - f_\rho\|_{L^2(\rho_X)} \leq \|f - f_\rho\|_{L^2(\rho_X)}.$

Definición 2.1.4. $\mathcal{C}_b(X) = \mathcal{C}(X) \cap \mathcal{L}^\infty(X).$

Teorema 2.1.2. Sea X un espacio métrico, $M > 0$ y $\mathcal{H}_M \subset \mathcal{C}_b(X)$ compacto en $(\mathcal{C}(X), \|\cdot\|_\infty)$ tal que $\forall f \in \mathcal{H}_M : |f(x) - y| \leq M$ ρ -c.s..

$$\implies \exists f_{\mathcal{H}_M} \in \mathcal{H}_M \wedge \forall \mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset X \times Y : \exists f_{\mathcal{H}_M, \mathcal{D}}.$$

Demostración: La prueba consiste en demostrar que $\mathcal{E}$ y $\mathcal{E}_{\mathcal{D}}$ son continuas como funciones de $\mathcal{H}_M \rightarrow \mathbb{R}_+$ según la norma $\|\cdot\|_{\infty}$ en $\mathcal{H}_M$ y la usual en $\mathbb{R}_+$. Sean $f_1, f_2 \in \mathcal{H}_M$, entonces

$$\begin{aligned} |\mathcal{E}[f_1] - \mathcal{E}[f_2]| &= \left| \int_Z (|f_1(x) - y|^2 - |f_2(x) - y|^2) d\rho(x, y) \right| \\ &= \left| \int_Z ((f_1(x) + f_2(x) - 2y) \cdot (f_1(x) - f_2(x))) d\rho(x, y) \right| \\ &\leq \|f_1 - f_2\|_{\infty} \int_Z (|f_1(x) - y| + |f_2(x) - y|) d\rho(x, y) \\ &\leq 2M \|f_1 - f_2\|_{\infty}. \end{aligned}$$

Por tanto, $\mathcal{E}$ es continua. Análogamente, $\mathcal{E}_{\mathcal{D}}$ es continua.

Como $\mathcal{H}_M$ es compacto, entonces existen $f_{\mathcal{H}_M}$ y $f_{\mathcal{H}_M, \mathcal{D}}$ que minimizan $\mathcal{E}$ y $\mathcal{E}_{\mathcal{D}}$ respectivamente (por el teorema de Weierstrass). ■

2.1.3 The Bias-Variance Tradeoff

El objetivo del aprendizaje es establecer una clase $\mathcal{H}$ buena y encontrar $f_{\mathcal{H}, \mathcal{D}}$ tal que exista $f_{\mathcal{H}, \infty}$ y sea pequeño el error de generalización $\mathcal{E}[f_{\mathcal{H}, \mathcal{D}}]$.

Si reescribimos

$$\mathcal{E}[f_{\mathcal{H}, \mathcal{D}}] = \mathcal{E}[f_{\mathcal{H}, \infty}] - \mathcal{E}[f_{\mathcal{H}}] + \mathcal{E}[f_{\mathcal{H}}],$$

donde

$$\text{VARIANCE } V(\mathcal{H}, \mathcal{D}, \rho) \quad \text{y} \quad \text{BIAS.}$$

- Si $\mathcal{H}$ es fijo y se aumenta el tamaño m de la muestra $\mathcal{D}$, entonces $V \rightarrow 0$ (bajo hipótesis oportunas).
- Si fijamos la muestra $\mathcal{D}$ y ampliamos $\mathcal{H}$, $\mathcal{E}[f_{\mathcal{H}}]$ se puede hacer pequeño, porque se reduce el error de aproximación $\|f_{\mathcal{H}} - f_{\rho}\|_{L^2(\rho_X)}$, pero se observa que V crece, por el fenómeno del *overfitting*: un modelo $\mathcal{H}$ demasiado grande hace $\mathcal{E}_{\mathcal{D}}(f_{\mathcal{H}, \mathcal{D}})$ muy pequeño, pero generaliza mal.

2.2 Reproducing Kernel Hilbert Spaces

Definición 2.2.1. Un núcleo de Mercer sobre un espacio topológico X es una $K : X \times X \rightarrow \mathbb{F}$ t.q.:

- (i) continua,

(ii) hermítica: $K(x, y) = \overline{K(y, x)}$,

(iii) semidefinida positiva: $\forall \{x_i\}_{i=1}^m \subset X$, la matriz $M_{ij} = K(x_i, x_j)$ es $M \geq 0$.

Teorema 2.2.1. Sea $K : X \times X \rightarrow \mathbb{F}$ un núcleo de Mercer y para $x \in X$, sea $K_x : X \rightarrow \mathbb{F}$, $K_x(y) = K(y, x)$. Entonces, existe un único espacio de Hilbert H_K sobre $\mathbb{F}$ t.q.:

- (1) $\{K_x : x \in X\}$ denso en H_K ,
- (2) $\forall f \in H_K$, $f(x) = \langle f, K_x \rangle_{H_K} \quad \forall x \in X$.

A H_K se le llama RKHS asociado a K .

Además, si K es acotado ($K \in C_b(X \times X)$) entonces $H_K \subset C(X)$ (y la inclusión es continua).

Demostración: H_K se construye como la completación de $\mathring{H} = \text{span}\{K_x : x \in X\} \subset C(X)$.

- Sean $f, g \in \mathring{H}$, con $f = \sum_{j=1}^N c_j K_{x_j}$ y $g = \sum_{j=1}^N d_j K_{x_j}$. Definimos:

$$\langle f, g \rangle_K := \sum_{i,j=1}^N c_i \overline{d_j} K(x_i, x_j).$$

- Como K es un núcleo de Mercer, se tiene $\langle f, f \rangle_K \geq 0 \quad \forall f \in \mathring{H}$. Además, por definición, si $f \in \mathring{H}$:

$$f(x) = \sum_{j=1}^N c_j K_{x_j}(x) = \langle f, K_x \rangle_K.$$

- Para todo $f \in \mathring{H}$, si $\langle f, f \rangle_K = 0$, entonces $f = 0$, porque:

$$|f(x)|^2 = |\langle f, K_x \rangle_K|^2 \leq \langle f, f \rangle_K K(x, x) \quad (\text{desigualdad de Cauchy-Schwarz}).$$

Por lo tanto, definimos la norma:

$$\|f\|_K := \sqrt{\langle f, f \rangle_K}.$$

Así, $H_K := \overline{\mathring{H}}^{\|\cdot\|_K}$ es un espacio de Hilbert.

- Por la desigualdad de Cauchy-Schwarz, si $K \in C_b$, entonces $\sup_{x \in X} K(x, x) = C_K < \infty$. Por lo tanto:

$$\|f\|_\infty \leq C_K \|f\|_K \quad \forall f \in H_K.$$

Esto implica que si $f \in H_K$, entonces $\{f_\nu\} \subset H_K \implies \{f_\nu\} \subset C(X)$ y:

$$\|f_\nu - f\|_\infty \leq C_K \|f_\nu - f\|_K \rightarrow 0 \implies f \in C(X).$$

■

Ejemplo 2.2.1 (Gaussian RBF (Radial Basis Function)). Sean $X \subset \mathbb{R}^d$, $\alpha > 0$, $K_\alpha(x, y) := e^{-\alpha\|x-y\|^2}$. Entonces $K \in C_b(X \times X)$ y $K(x, y) = K(y, x)$.

Veamos que K_α es semidefinido positivo.

1. Sea $\alpha = \pi$ (sin pérdida de generalidad). Entonces $K_\pi(x, y) = g(x - y)$, donde $g(x) = e^{-\pi\|x\|^2}$.

2. Sea $\mathcal{F} : L^2(\mathbb{R}^d) \rightarrow L^2(\mathbb{R}^d)$ la transformada de Fourier. Para $f \in L^2(\mathbb{R}^d)$, definimos:

$$\mathcal{F}(f)(\xi) := \int_{\mathbb{R}^d} e^{-2\pi i \langle \xi, x \rangle} f(x) dx.$$

Entonces:

$$\mathcal{F}(g)(\xi) = \int_{\mathbb{R}^d} e^{-2\pi i \langle \xi, x \rangle} e^{-\pi\|x\|^2} dx.$$

Como $x = (x_1, \dots, x_d) \in \mathbb{R}^d$, tenemos:

$$\mathcal{F}(g)(\xi) = \prod_{j=1}^d \int_{\mathbb{R}} e^{-2\pi i \xi_j x_j} e^{-\pi x_j^2} dx_j = e^{-\pi\|\xi\|^2}.$$

Por lo tanto, g es autofunción del operador $\mathcal{F}$.

Además, por el teorema de inversión de $\mathcal{F}$:

$$g(x) = \int_{\mathbb{R}^d} e^{2\pi i \langle \xi, x \rangle} e^{-\pi\|\xi\|^2} d\xi.$$

3. Sean $\{x_i\}_{i=1}^m \subset \mathbb{R}^d$, $M_{ij} = K(x_i, x_j)$ y $v \in \mathbb{R}^m$. Entonces:

$$\langle v, Mv \rangle_{\mathbb{R}^m} = \sum_{i,j=1}^m v_i K(x_i, x_j) v_j = \sum_{i,j=1}^m v_i v_j g(x_i - x_j).$$

Sustituyendo $g(x) = \int_{\mathbb{R}^d} e^{-2\pi i \langle \xi, x \rangle} e^{-\pi\|\xi\|^2} d\xi$, obtenemos:

$$\langle v, Mv \rangle_{\mathbb{R}^m} = \sum_{i,j=1}^m \int_{\mathbb{R}^d} (v_i e^{2\pi i \langle \xi, x_i \rangle}) (v_j e^{-2\pi i \langle \xi, x_j \rangle}) e^{-\pi\|\xi\|^2} d\xi.$$

Reordenando:

$$\langle v, Mv \rangle_{\mathbb{R}^m} = \int_{\mathbb{R}^d} \left| \sum_{i=1}^m v_i e^{2\pi i \langle \xi, x_i \rangle} \right|^2 e^{-\pi \|\xi\|^2} d\xi \geq 0.$$

“ Los elementos del Gaussian RBF RKHS son (límites de) combinaciones lineales de gaussianas centradas en varios puntos de $\mathbb{R}^d$:

$$f \in \mathcal{H}_{K_\alpha} \implies f(x) = \sum_{j=1}^m c_j e^{-\alpha \|x - x_j\|^2}.$$

Note: en Steinwart, Hush "An explicit description of the RKHS of Gaussian RBF Kernels", *IEEE Trans. Information Theory* 52 (2006) se demuestra que, en $X = \mathbb{C}^d$, si tomamos

$$K_\alpha(z, w) = e^{-\alpha \sum_{j=1}^d (z_j - \bar{w}_j)^2},$$

entonces

$$\mathcal{H}_{K_\alpha} = \left\{ f \in \text{Hol}(\mathbb{C}^d) \text{ tales que } \|f\| := \left(\frac{2^d \alpha^d}{\pi^d} \int_{\mathbb{C}^d} |f(z)|^2 e^{\alpha \sum_{j=1}^d |z_j|^2} dz \right)^{1/2} < \infty \right\},$$

un espacio de Hilbert de funciones holomorfas.

$$\implies \mathcal{H}_{K_\alpha}(\mathbb{R}^d) = \{f|_{\mathbb{R}^d} : f \in \mathcal{H}_{K_\alpha}\}, \text{ funciones reales analíticas.}$$

(restricción a $\mathbb{R}^d$ de las funciones de $\mathcal{H}_{K_\alpha}$)

El RKHS de $K_\alpha(x, y) = e^{-\alpha \|x - y\|^2}$, con $X = \mathbb{R}^d$. “

Peso II: $\overline{B} \subset C(X)$ es equicontinuo

$$\forall x \in X, \forall \varepsilon > 0 \exists V^\varepsilon \text{ abierto: } \forall x, y \in V, \forall f \in \overline{B} \text{ vale } |f(x) - f(y)| < \varepsilon.$$

- Como X es compacto y K es Heineano $\implies K$ es uniformemente continuo en $X \times X$.
- Sean $\varepsilon, \delta > 0$ tales que $\forall x, y, y' \in X$

$$|K(x, y) - K(x, y')| < \varepsilon \quad \forall d(y, y') < \delta.$$

- $\implies \forall f \in \overline{B}, \forall d(y, y') < \delta$

$$|f(y) - f(y')| = |\langle f, K_y - K_{y'} \rangle_{\mathcal{H}_K}| \leq \|f\|_{\mathcal{H}_K} \|K_y - K_{y'}\|_{\mathcal{H}_K}.$$

$$\begin{aligned} &\leq \sqrt{\langle K_y - K_{y'}, K_y - K_{y'} \rangle}. \\ &= \sqrt{K(y, y) - K(y, y') + K(y', y') - K(y', y)} < \sqrt{2\varepsilon}. \end{aligned}$$

Peso III: Arzelà-Ascoli

El teorema de A.-A. nos dice que si X es compacto y $S \subset C(X)$, entonces S es compacto $\iff S$ es cerrado, acotado y equicontinuo.

(Una prueba completa de A.-A. en espacios métricos: Royden, Fitzpatrick, "Real Analysis", 4th ed., 2010)

Además de proporcionar espacios de hipótesis donde existen mínimos de los errores de generalización y en

1. Existen RKHS sobre espacios métricos compactos, capaces de separar todos los conjuntos compactos: si $A, B \subset X$ compactos disjuntos, $\exists f_{A,B} \in \mathcal{H}_K$ tal que

$$f_{A,B}(x) > 0 \quad \forall x \in A, \quad f_{A,B}(x) < 0 \quad \forall x \in B.$$

Un kernel que hace esto es el RBF (*Steinwart, Christmann, §4.6*).

2. El mínimo del error empírico en un RKHS, cuando existe, se escribe como combinación lineal del kernel evaluado en los datos. Este es el llamado *representer theorem*.

Teorema 2.2.2. Sea X espacio métrico, $K \in C_b(X \times X)$ un kernel de Mercer y sea $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset X \times \mathbb{R}$. Sean $E : (X \times \mathbb{R})^m \rightarrow \mathbb{R}_+$ y $g : \mathbb{R}_+ \rightarrow \mathbb{R}_+$ monótono.

Si $\mathcal{F} = \{f \in \mathcal{H}_K \mid f \text{ minimiza en } \mathcal{H}_K\}$, entonces

$$R_g[F] = E(\{(x_i, y_i, f(x_i))\}_{i=1}^m) + g(\|f\|_{\mathcal{H}_K}).$$

$$\implies \exists \{\alpha_i\}_{i=1}^m \subset \mathbb{R} : \rho_E^{\mathcal{H}_K, \mathcal{D}} = \sum_{i=1}^m \alpha_i K_{x_i}.$$

Demostración:

$V_0 := \text{span}\{K_{x_i}\}_{i=1}^m$ es un subespacio de $\mathcal{H}_K$.

$$\implies \text{si } f \in \mathcal{H}_K, \quad f = P_{V_0}f + P_{V_0^\perp}f.$$

1)

$$f(x_j) = \langle f, K_{x_j} \rangle = \langle P_{V_0} f, K_{x_j} \rangle \quad \forall j = 1, \dots, m.$$

$$\implies E(\{(x_i, y_i, f(x_i))\}_{i=1}^m) = E(\{(x_i, y_i, P_{V_0} f(x_i))\}_{i=1}^m).$$

2) g es monótona, así que

$$g(\|f\|_{\mathcal{H}_K}) = g\left(\sqrt{\|P_{V_0} f\|_{\mathcal{H}_K}^2 + \|P_{V_0^\perp} f\|_{\mathcal{H}_K}^2}\right) \geq g(\|P_{V_0} f\|_{\mathcal{H}_K}).$$

$$\implies \forall f \in \mathcal{H}_K, R_\infty[P_{V_0} f] \leq R_\infty[f].$$

■

Observación 2.2.2.

- Esto no dice que R_∞ tiene mínimo en $\mathcal{H}_K$, ni dice que, si R_∞ tiene mínimos en $\mathcal{H}_K$, no hay algunos que no estén en V_0 .
- La utilidad de este teorema está en la posibilidad de buscar un mínimo en V_0 , que es de dimensión finita.

2.3 Clasificadores Lineales Binarios

2.3.1 Planteamiento del problema

El problema de *clasificación binaria* consiste en lo siguiente. Disponemos de un *espacio de observaciones* $X \subset \mathbb{R}^d$ y queremos asignar a cada punto $x \in X$ una de dos posibles *etiquetas*, que codificamos como $Y = \{-1, 1\}$. Suponemos que los datos se generan a partir de una distribución de probabilidad desconocida ρ sobre $X \times Y$: la marginal ρ_X describe cómo se distribuyen las observaciones, y las probabilidades condicionales $\rho(y | x)$ describen la incertidumbre intrínseca de la etiqueta dado un punto.

Una *clasificación* es una función $f: X \rightarrow Y$ que, a cada observación, le asigna una predicción de su etiqueta. La bondad de una clasificación se mide por su *error de clasificación* (o error de generalización), que cuantifica la probabilidad de que f se equivoque en un punto tomado al azar de ρ .

Definición 2.3.1 (Error de clasificación). Sea $f: X \rightarrow Y$ una clasificación de X , $\mathcal{E}[f]$

es el error de clasificación de f

$$\begin{aligned} \iff \mathcal{E}[f] &= \int_Z |f(x) - y|^2 d\rho(x, y) = 4 \int_{X \times Y} \mathbb{1}_{(y \neq f(x))} d\rho(x, y) \\ &= 4 \int_X \left(\sum_{y \in \{-1, 1\}} \delta(y \neq f(x)) \rho(y | x) \right) \rho_X(x) dx = 4 \int_X \mathbb{P}(Y \neq f(x) | x) d\rho_X(x). \end{aligned}$$

En la práctica, la distribución ρ es desconocida y solo disponemos de un *conjunto de datos* o *muestra de entrenamiento* $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset X \times Y$, formado por m observaciones etiquetadas que suponemos extraídas de forma independiente según ρ . El error empírico $\mathcal{E}_{\mathcal{D}}[f]$ sirve como estimación del error verdadero $\mathcal{E}[f]$, y el objetivo es encontrar f que lo minimice.

La familia más sencilla de clasificadores es la de los *clasificadores lineales*: aquellos que deciden la etiqueta según en qué semiplano del espacio $\mathbb{R}^d$ cae la observación. Geométricamente, la frontera de decisión es un *hiperplano* $H = \{x \in \mathbb{R}^d : \langle w, x \rangle + b = 0\}$ determinado por un vector normal $w \in \mathbb{R}^d$ y un umbral $b \in \mathbb{R}$. Para que tal hiperplano clasifique correctamente todos los puntos de $\mathcal{D}$, se necesita que los datos de cada clase estén estrictamente en lados opuestos de H .

Definición 2.3.2 (Error empírico). Sea $f: X \rightarrow Y$ una clasificación de X y $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m$ un conjunto de datos. $\mathcal{E}_{\mathcal{D}}[f]$ es el error empírico de f para $\mathcal{D}$

$$\iff \mathcal{E}_{\mathcal{D}}[f] = \frac{1}{m} \sum_{i=1}^m |f(x_i) - y_i|^2 = \frac{4}{m} |\{i \in \{1, \dots, m\} : f(x_i) \neq y_i\}|.$$

2.3.2 Separabilidad por un hiperplano

Un ejemplo sencillo de clasificación es la clasificación lineal: dado un hiperplano

$$H = \{x \in \mathbb{R}^d : \langle w, x \rangle + b = 0\},$$

se asigna a cada punto la etiqueta del semiplano en que cae. Para que este clasificador tenga error empírico nulo, es necesario y suficiente que los datos de cada clase queden estrictamente en lados opuestos de H . Esta condición sobre el conjunto de datos recibe un nombre propio.

Definición 2.3.3 (Separabilidad). Un conjunto de datos $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset \mathbb{R}^d \times \{-1, 1\}$ es separable por un hiperplano (SPH)

$$\iff \exists w \in \mathbb{R}^d, b \in \mathbb{R} : \forall i \in \mathbb{N}_m : y_i \cdot (\langle w, x_i \rangle + b) > 0.$$

Geoméricamente, el hiperplano $H = \{x \in \mathbb{R}^d : \langle w, x \rangle + b = 0\}$ divide $\mathbb{R}^d$ en dos:

$$H^+ = \{x \in \mathbb{R}^d : \langle w, x \rangle + b > 0\}, \quad H^- = \{x \in \mathbb{R}^d : \langle w, x \rangle + b < 0\}.$$

La condición $y_i (\langle w, x_i \rangle + b) > 0$ expresa precisamente que cada observación x_i cae en el semiplano correspondiente a su etiqueta: $x_i \in H^+$ cuando $y_i = 1$, y $x_i \in H^-$ cuando $y_i = -1$. En particular, ningún punto de $\mathcal{D}$ yace sobre el propio hiperplano H .

Definición 2.3.4 (Clasificadores lineales binarios). El espacio de clasificadores lineales binarios es $\mathcal{H}_2 = \{f : \mathbb{R}^d \rightarrow \{-1, 1\} : f(x) = \text{sgn}(\langle w, x \rangle + b) \wedge w \in \mathbb{R}^d \wedge b \in \mathbb{R}\}$.

Observación 2.3.5. Cada clasificador de $\mathcal{H}_2$ queda determinado por $(w, b) \in \mathbb{R}^d \times \mathbb{R} \cong \mathbb{R}^{d+1}$.

Si $\mathcal{D}$ es (SPH), entonces $\exists f_0 \in \mathcal{H}_2$ tal que $\mathcal{E}_{\mathcal{D}}[f_0] = 0$.

Observación 2.3.6. La condición (SPH) es afín: el hiperplano separador $H = \{x \in \mathbb{R}^d : \langle w, x \rangle + b = 0\}$ no pasa por el origen en general. Sin embargo, puede reescribirse como una condición lineal elevando la dimensión en uno.

Dados $x_i \in \mathbb{R}^d$ y $(w, b) \in \mathbb{R}^d \times \mathbb{R}$, definamos los *vectores aumentados*

$$\tilde{x}_i := \begin{pmatrix} x_i \\ 1 \end{pmatrix} \in \mathbb{R}^{d+1} \quad \wedge \quad \tilde{w} := \begin{pmatrix} w \\ b \end{pmatrix} \in \mathbb{R}^{d+1}.$$

Como $\langle w, x_i \rangle + b = \langle \tilde{w}, \tilde{x}_i \rangle$, la condición (SPH) $\forall i \in \mathbb{N}_m : y_i (\langle w, x_i \rangle + b) > 0$ es equivalente a $\forall i \in \mathbb{N}_m : y_i \langle \tilde{w}, \tilde{x}_i \rangle > 0$. Esta es la condición de separabilidad por el subespacio lineal $\tilde{H} = \{\tilde{x} \in \mathbb{R}^{d+1} : \langle \tilde{w}, \tilde{x} \rangle = 0\}$, que sí pasa por el origen. Nótese que los puntos aumentados $\tilde{x}_i$ yacen todos en el hiperplano afín $\{x_{d+1} = 1\} \subset \mathbb{R}^{d+1}$, una copia isométrica de $\mathbb{R}^d$.

2.3.2.1 Separabilidad y envolvente convexa

Recordamos que, dados $\{x_i\}_{i=1}^k \subset \mathbb{R}^d$, la envolvente convexa de $\{x_i\}_{i=1}^k$ es

$$\text{conv}(\{x_i\}_{i=1}^k) = \left\{ \sum_{i=1}^k p_i x_i : p_i \geq 0 \wedge \sum_{i=1}^k p_i = 1 \right\}.$$

Teorema 2.3.1. Sea $(w, b) \in \mathbb{R}^d \times \mathbb{R}$ y sea $h(x) = \langle w, x \rangle + b$. Entonces, $f(x) = \text{sgn}(h(x))$ clasifica (con error empírico nulo) $\mathcal{D}$ en $X_1 \times \{1\}$ y $X_{-1} \times \{-1\}$ si y sólo si

$$\forall v \in \text{conv}(X_1) : f(v) = 1 \quad \wedge \quad \forall v \in \text{conv}(X_{-1}) : f(v) = -1.$$

Demostración: Veamos ambas implicaciones por separado.

⇐ Si f clasifica correctamente $\text{conv}(X_1)$ y $\text{conv}(X_{-1})$, entonces en particular clasifica

correctamente $X_1 \subset \text{conv}(X_1)$ y $X_{-1} \subset \text{conv}(X_{-1})$, luego clasifica $\mathcal{D}$ con error nulo.

$\Rightarrow$ Sea $v \in \text{conv}(X_\ell)$, esto es, $v = \sum_{i=1}^k p_i x_i$ con $x_i \in X_\ell$, $p_i \geq 0$ y $\sum_{i=1}^k p_i = 1$. Por linealidad de $\langle w, \cdot \rangle$ y dado que $\sum p_i = 1$,

$$h(v) = \left\langle w, \sum_{i=1}^k p_i x_i \right\rangle + b = \sum_{i=1}^k p_i \langle w, x_i \rangle + \sum_{i=1}^k p_i b = \sum_{i=1}^k p_i h(x_i).$$

Como f clasifica $\mathcal{D}$ con error nulo, $h(x_i)$ tiene signo ℓ para todo $x_i \in X_\ell$. Siendo $p_i \geq 0$ y $\sum p_i = 1 > 0$, la combinación convexa $\sum p_i h(x_i)$ tiene también signo ℓ . Por tanto, $f(v) = \text{sgn}(h(v)) = \ell$. ■

2.3.3 Algoritmo del Perceptrón

Hasta ahora hemos establecido las condiciones teóricas bajo las que un conjunto de datos puede ser separado perfectamente mediante una frontera lineal. Sin embargo, desde un punto de vista práctico, necesitamos un método constructivo que nos permita encontrar empíricamente dicho hiperplano a partir de los datos.

El *algoritmo del Perceptrón*, propuesto por Frank Rosenblatt en 1958, se encarga precisamente de esto. Se trata de un método iterativo impulsado puramente por el error y, a pesar de ser un procedimiento en apariencia tan rudimentario, cuenta con garantía matemática de convergencia estricta en un número finito de pasos.

Para formular este teorema, analizaremos el conjunto de clasificadores lineales que, no solo separan los datos, sino que lo hacen con un margen constante de al menos 1:

$$\mathcal{W}_1 := \{w \in \mathbb{R}^d : \forall i \in \mathbb{N}_m : y_i \langle w, x_i \rangle \geq 1\}.$$

Observación 2.3.7 (Existencia de B). Definimos $B = \min_{w \in \mathcal{W}_1} \|w\|$. Entonces, B está bien definido y siempre existe si el problema es linealmente separable porque:

1. $\mathcal{W}_1$ es no vacío: Al ser $\mathcal{D}$ separable (SPS), $\exists w_0 \in \mathbb{R}^d$ tal que $\gamma = \min_i y_i \langle w_0, x_i \rangle > 0$. Entonces, tomando $\tilde{w} = \frac{w_0}{\gamma}$, $\forall i \in \mathbb{N}_m : y_i \langle \tilde{w}, x_i \rangle = \frac{1}{\gamma} y_i \langle w_0, x_i \rangle \geq 1$, es decir, $\tilde{w} \in \mathcal{W}_1$.
2. El mínimo siempre se alcanza: El conjunto $\mathcal{W}_1$ está definido por la intersección de m espacios cerrados $y_i \langle w, x_i \rangle \geq 1$, por lo que $\mathcal{W}_1 \subset \mathbb{R}^d$ es cerrado. Como la norma $f(w) = \|w\|$ es continua y coercitiva ($\lim_{\|w\| \rightarrow \infty} f(w) = \infty$), por el Teorema de Weierstrass, f alcanza su mínimo global sobre cualquier subconjunto cerrado y no vacío.

Teorema 2.3.2 (Algoritmo del Perceptrón, Rosenblatt 1958). *Supongamos que el conjunto de datos $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset \mathbb{R}^d \times \{-1, 1\}$ es separable por un subespacio lineal (SPS).*

Tomamos $\mathcal{W}_1$ y B como en la observación anterior, y definimos $R := \max_{i \in \mathbb{N}_m} \|x_i\|$. Consideremos la siguiente sucesión definida iterativamente comenzando con $w^{(0)} = 0 \in \mathbb{R}^d$:

En cada paso $k \geq 0$, si existe algún índice $i \in \mathbb{N}_m$ tal que $y_i \langle w^{(k)}, x_i \rangle \leq 0$ (es decir, el dato x_i está mal clasificado por el hiperplano $w^{(k)}$), actualizamos el vector usando ese punto:

$$w^{(k+1)} = w^{(k)} + y_i x_i.$$

Este proceso se detiene en, a lo sumo, $(BR)^2$ pasos y produce un vector $w \in \mathbb{R}^d$ tal que $\forall i \in \mathbb{N}_m : y_i \langle w, x_i \rangle > 0$, es decir, w define un hiperplano que separa $\mathcal{D}$.

Demostración: Tomemos $w^* \in \mathcal{W}_1$ con $\|w^*\| = B$. Analizaremos la evolución de $\langle w^*, w^{(k)} \rangle$ y $\|w^{(k)}\|^2$ tras k pasos del algoritmo.

Denotaremos por (x_{i_j}, y_{i_j}) al dato empleado en la corrección durante el paso j -ésimo. Se tiene por tanto que $w^{(j)} = w^{(j-1)} + y_{i_j} x_{i_j}$ y que $y_{i_j} \langle w^{(j-1)}, x_{i_j} \rangle \leq 0$.

Por un lado, acotamos inferiormente el producto escalar con la solución óptima w^* :

$$\langle w^*, w^{(k)} \rangle = \left\langle w^*, \sum_{j=1}^k y_{i_j} x_{i_j} \right\rangle = \sum_{j=1}^k y_{i_j} \langle w^*, x_{i_j} \rangle.$$

Como $w^* \in \mathcal{W}_1$, por definición separa todos los ejemplos conservando al menos un margen de 1, es decir, $y_{i_j} \langle w^*, x_{i_j} \rangle \geq 1$. En consecuencia:

$$\langle w^*, w^{(k)} \rangle \geq \sum_{j=1}^k 1 = k. \quad (2.1)$$

Por otro lado, acotamos superiormente la norma euclídea del vector iterado. Tenemos que

$$\|w^{(k)}\|^2 = \|w^{(k-1)} + y_{i_k} x_{i_k}\|^2 = \|w^{(k-1)}\|^2 + 2y_{i_k} \langle w^{(k-1)}, x_{i_k} \rangle + \|x_{i_k}\|^2.$$

Sabemos que todos los puntos verifican $\|x\| \leq R$, por lo que $\|x_{i_k}\|^2 \leq R^2$. A su vez, por la condición de selección del punto, $2y_{i_k} \langle w^{(k-1)}, x_{i_k} \rangle \leq 0$. Concluimos entonces que:

$$\|w^{(k)}\|^2 \leq \|w^{(k-1)}\|^2 + R^2.$$

Aplicando esta desigualdad recursivamente desde la condición inicial $w^{(0)} = 0$, obtenemos por inducción trivial que $\|w^{(k)}\|^2 \leq kR^2$.

Finalmente, relacionamos ambos resultados mediante la desigualdad de Cauchy-Schwarz:

$$k \stackrel{(2.1)}{\leq} \langle w^*, w^{(k)} \rangle \stackrel{\text{C-S}}{\leq} \|w^*\| \|w^{(k)}\| \leq B\sqrt{k}R^2 = BR\sqrt{k}.$$

Partiendo de $k \leq BR\sqrt{k}$ y asumiendo $k > 0$, podemos dividir ambos miembros entre $\sqrt{k}$ para obtener $\sqrt{k} \leq BR$. Elevando la inecuación al cuadrado, el número de iteraciones queda acotado por: $k \leq (BR)^2$.

Puesto que la cantidad de actualizaciones que puede realizar el algoritmo está acotada por $(BR)^2$, el proceso debe detenerse en un número finito de pasos. En ese momento, no existirá i tal que $y_i \langle w^{(k)}, x_i \rangle \leq 0$, luego $w^{(k)}$ define un hiperplano que separa $\mathcal{D}$. ■

Observación 2.3.8 (Interpretación geométrica de la convergencia). La cota máxima de iteraciones del algoritmo, $(BR)^2$, proporciona una intuición clave sobre la dificultad intrínseca del problema de clasificación:

- R representa la dispersión máxima de los datos (el radio de la menor bola centrada en el origen que los contiene).
- Para un clasificador $w \in \mathcal{W}_1$, la distancia euclídea (margen) entre el hiperplano y los datos es al menos $1/\|w\|$. En consecuencia, el valor mínimo $B = \min \|w\|$ es exactamente el *inverso del margen máximo posible*, es decir, $B = 1/\gamma_{\max}$.

Entonces, el producto $BR = R/\gamma_{\max}$ es un factor de escala invariable que mide la dificultad geométrica de la separación. Notablemente, este resultado establece que la velocidad de convergencia es *completamente independiente* de la dimensión d del espacio.

Observación 2.3.9. Si $\mathcal{D}$ es (SPH) o (SPS), puede existir una familia infinita de clasificadores en $\mathcal{H}_2$ con error empírico nulo. Dado que el objetivo último es minimizar el error de generalización $\mathcal{E}[f]$, es razonable preguntarse cuál de los $f \in \mathcal{H}_2$ generaliza mejor.

En la práctica, como la distribución ρ es desconocida, se estima el error de generalización dividiendo el conjunto de datos en dos subconjuntos disjuntos: $\mathcal{D}_{\text{train}}$ y $\mathcal{D}_{\text{test}}$. El clasificador se entrena minimizando $\mathcal{E}_{\mathcal{D}_{\text{train}}}[f]$, y su calidad se evalúa mediante $\mathcal{E}_{\mathcal{D}_{\text{test}}}[f]$.

Muchos algoritmos de aprendizaje dependen de parámetros externos que no se determinan durante el entrenamiento denominados *hiperparámetros*. Para seleccionarlos sin sesgar la evaluación final, es común subdividir a su vez $\mathcal{D}_{\text{train}}$ en dos: un conjunto de entrenamiento y un conjunto de *validación* sobre el que comparar distintas configuraciones.

2.3.4 Maximización del Margen: SVM

El Perceptrón garantiza encontrar *algún* hiperplano separador, pero, cuando $\mathcal{D}$ es (SPH), existe en general una familia infinita de ellos. La intuición geométrica sugiere preferir el que quede lo más alejado posible de todos los puntos de entrenamiento: un clasificador con mayor margen es menos sensible a perturbaciones en los datos y, en consecuencia, tiende a generalizar mejor. Esta idea da lugar a las *Support Vector Machines* (SVM).

Fijamos $(w, b) \in \mathbb{R}^d \times \mathbb{R}$ con $\|w\| = 1$ y consideramos el hiperplano

$$H_{(w,b)} := \{v \in \mathbb{R}^d : \langle v, w \rangle + b = 0\}.$$

La distancia de un punto $x \in \mathbb{R}^d$ a $H_{(w,b)}$ es

$$\text{dist}(x, H_{(w,b)}) = \min_{v \in H_{(w,b)}} \|x - v\| = |\langle x, w \rangle + b|,$$

donde la última igualdad se deduce de que w es el vector normal unitario a $H_{(w,b)}$.

Definimos los conjuntos de índices $I_1, I_{-1} \subset \{1, \dots, m\}$ como

$$I_1 = \{i \in \mathbb{N}_m : y_i = 1\} \quad \wedge \quad I_{-1} = \{i \in \mathbb{N}_m : y_i = -1\}.$$

Fijada una dirección unitaria w , el **umbral** b que centra el hiperplano $H_{(w,b)}$ correspondiente de manera equidistante a ambas clases viene dado por

$$\beta_{\mathcal{D}}(w) := \frac{1}{2} \left| \text{dist}(\{x_i : i \in I_{-1}\}, H_{(w,0)}) - \text{dist}(\{x_i : i \in I_1\}, H_{(w,0)}) \right|$$

y el **margen** del hiperplano $H_{(w,\beta_{\mathcal{D}}(w))}$, es decir, la distancia común a ambas clases, es

$$\Delta_{\mathcal{D}}(w) := \text{dist}(\{x_i : i \in I_1\}, H_{(w,\beta_{\mathcal{D}}(w))}) = \text{dist}(\{x_i : i \in I_{-1}\}, H_{(w,\beta_{\mathcal{D}}(w))})$$

El objetivo es encontrar la dirección unitaria w que maximize este margen.

Ejercicio 2.3.1. Demuestra que, para cada $w \in \mathbb{R}^d$ con $\|w\| = 1$,

$$\beta_{\mathcal{D}}(w) = -\frac{1}{2} \left(\min_{i \in I_1} \langle w, x_i \rangle + \max_{i \in I_{-1}} \langle w, x_i \rangle \right) \quad \wedge \quad \Delta_{\mathcal{D}}(w) = \frac{1}{2} \left(\min_{i \in I_1} \langle w, x_i \rangle - \max_{i \in I_{-1}} \langle w, x_i \rangle \right).$$

Solución: Como $\|w\| = 1$, la distancia de un punto x al hiperplano $H_{(w,b)}$ es $|\langle w, x \rangle + b|$.

Denotamos $A := \min_{i \in I_1} \langle w, x_i \rangle$ y $B := \max_{i \in I_{-1}} \langle w, x_i \rangle$.

- (1) Por definición, $\beta_{\mathcal{D}}(w)$ es el único $b \in \mathbb{R}$ que coloca el hiperplano $H_{(w,b)}$ equidistante a ambas clases. Con dicho b , los puntos de I_1 caen en el semiplano positivo y los de I_{-1}

en el negativo, de modo que las distancias a ambas clases son

$$\text{dist}(\{x_i : i \in I_1\}, H_{(w,b)}) = \min_{i \in I_1} (\langle w, x_i \rangle + b) = A + b,$$

$$\text{dist}(\{x_i : i \in I_{-1}\}, H_{(w,b)}) = -\max_{i \in I_{-1}} (\langle w, x_i \rangle + b) = -(B + b).$$

Igualándolas: $A + b = -(B + b) \implies 2b = -A - B \implies b = -\frac{A+B}{2}$. Por tanto,

$$\beta_{\mathcal{D}}(w) = -\frac{1}{2} \left(\min_{i \in I_1} \langle w, x_i \rangle + \max_{i \in I_{-1}} \langle w, x_i \rangle \right).$$

(2) El margen es la distancia común de ambas clases al hiperplano $H_{(w, \beta_{\mathcal{D}}(w))}$:

$$\Delta_{\mathcal{D}}(w) = A + \beta_{\mathcal{D}}(w) = A - \frac{A+B}{2} = \frac{A-B}{2} = \frac{1}{2} \left(\min_{i \in I_1} \langle w, x_i \rangle - \max_{i \in I_{-1}} \langle w, x_i \rangle \right). \quad \blacksquare$$

Teorema 2.3.3 (Hard-Margin SVM). Sea $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset \mathbb{R}^d \times \{-1, 1\}$ un conjunto de datos (SPH). Entonces:

(1) Existe un único $w_{\mathcal{D}} \in \mathbb{R}^d$ con $\|w_{\mathcal{D}}\| = 1$ tal que $w_{\mathcal{D}} = \arg \max_{\|w\|=1} \Delta_{\mathcal{D}}(w)$, y el hiperplano

$H_{(w_{\mathcal{D}}, \beta_{\mathcal{D}}(w_{\mathcal{D}}))}$ separa $\mathcal{D}$ con margen máximo.

(2) La única solución $(w^*, \beta_{\mathcal{D}}(w^*))$ del problema de optimización

$$\min_{w \in \mathbb{R}^d} \|w\| \quad \text{sujeto a} \quad \forall i \in \mathbb{N}_m : y_i (\langle w, x_i \rangle + \beta_{\mathcal{D}}(w)) \geq 1 \quad (2.2)$$

$$\text{satisface } w_{\mathcal{D}} = \frac{w^*}{\|w^*\|} \wedge \Delta_{\mathcal{D}}(w_{\mathcal{D}}) = \frac{1}{\|w^*\|}.$$

Demostración:

(1) Como $\Delta_{\mathcal{D}}$ es continua, por el teorema de Weierstrass alcanza su máximo en la bola cerrada $\overline{B}_1 = \{w \in \mathbb{R}^d : \|w\| \leq 1\}$, que es compacta. Sea $\overline{w} \in \overline{B}_1$ dicho maximizador.

Dado que $\Delta_{\mathcal{D}}(\lambda w) = \lambda \Delta_{\mathcal{D}}(w)$ para todo $\lambda > 0$ (homogeneidad de grado 1), si $\|\overline{w}\| < 1$ y $\Delta_{\mathcal{D}}(\overline{w}) > 0$, entonces

$$\Delta_{\mathcal{D}}\left(\frac{\overline{w}}{\|\overline{w}\|}\right) = \frac{1}{\|\overline{w}\|} \Delta_{\mathcal{D}}(\overline{w}) > \Delta_{\mathcal{D}}(\overline{w}),$$

lo que contradice la maximalidad de $\overline{w}$. Luego $\|\overline{w}\| = 1$.

Para la unicidad, supongamos que existe $w' \in \partial \overline{B}_1$, $w' \neq \overline{w}$, con $\Delta_{\mathcal{D}}(w') = \Delta_{\mathcal{D}}(\overline{w})$.

Entonces, para $t \in (0, 1)$, $v_t := tw' + (1 - t)\bar{w}$ satisface $\|v_t\| < 1$, y por linealidad:

$$\Delta_{\mathcal{D}}\left(\frac{v_t}{\|v_t\|}\right) = \frac{\Delta_{\mathcal{D}}(v_t)}{\|v_t\|} = \frac{\Delta_{\mathcal{D}}(\bar{w})}{\|v_t\|} > \Delta_{\mathcal{D}}(\bar{w}),$$

lo que de nuevo contradice la maximalidad. Luego el maximizador $\bar{w}$ es único.

- (2) El conjunto factible $\mathcal{F} := \{w \in \mathbb{R}^d : \forall i \in \mathbb{N}_m : y_i(\langle w, x_i \rangle + \beta_{\mathcal{D}}(w)) \geq 1\}$ es no vacío, cerrado y convexo. El argumento es análogo al de la Observación 2.3.7. Como la norma es continua y coercitiva, el mínimo se alcanza en algún punto $w^* \in \mathcal{F}$.

Unicidad de w^* : Supongamos que w_1 y w_2 son dos minimizadores, esto es, $\|w_1\| = \|w_2\| = \min_{w \in \mathcal{F}} \|w\| =: c^*$. Aplicando la identidad del paralelogramo:

$$\left\|\frac{w_1 + w_2}{2}\right\|^2 = \frac{\|w_1\|^2 + \|w_2\|^2}{2} - \left\|\frac{w_1 - w_2}{2}\right\|^2 = (c^*)^2 - \left\|\frac{w_1 - w_2}{2}\right\|^2.$$

Por convexidad de $\mathcal{F}$, el punto $\frac{w_1 + w_2}{2}$ es factible, luego $\left\|\frac{w_1 + w_2}{2}\right\| \geq c^*$, es decir, $\left\|\frac{w_1 + w_2}{2}\right\|^2 \geq (c^*)^2$. Por lo tanto, llegamos a que

$$(c^*)^2 \leq \left\|\frac{w_1 + w_2}{2}\right\|^2 = (c^*)^2 - \left\|\frac{w_1 - w_2}{2}\right\|^2 \implies \left\|\frac{w_1 - w_2}{2}\right\|^2 \leq 0 \implies w_1 = w_2.$$

Sea $\hat{w} := w^*/\|w^*\|$. Dividiendo en $y_i(\langle w^*, x_i \rangle + \beta_{\mathcal{D}}(w^*)) \geq 1$ entre $\|w^*\|$, se obtiene

$$\forall i \in \mathbb{N}_m : y_i \left(\langle \hat{w}, x_i \rangle + \frac{\beta_{\mathcal{D}}(w^*)}{\|w^*\|} \right) \geq \frac{1}{\|w^*\|},$$

lo que implica que $\Delta_{\mathcal{D}}(\hat{w}) \geq 1/\|w^*\|$.

Si $\forall w \in \mathbb{R}^d : \|w\| = 1 : \Delta_{\mathcal{D}}(w) \leq 1/\|w^*\|$, entonces $w_{\mathcal{D}} = \hat{w}$ maximiza $\Delta_{\mathcal{D}}$ y es único por el punto (1). Supongamos por contradicción que existe $w_0 \in \mathbb{R}^d$ tal que $\|w_0\| = 1$ y $\Delta_{\mathcal{D}}(w_0) > 1/\|w^*\|$. Entonces el par $(w_0/\Delta_{\mathcal{D}}(w_0), \beta_{\mathcal{D}}(w_0)/\Delta_{\mathcal{D}}(w_0))$ es factible para (2.2) puesto que $\forall i \in \mathbb{N}_m :$

$$y_i \left(\left\langle \frac{w_0}{\Delta_{\mathcal{D}}(w_0)}, x_i \right\rangle + \frac{\beta_{\mathcal{D}}(w_0)}{\Delta_{\mathcal{D}}(w_0)} \right) = \frac{1}{\Delta_{\mathcal{D}}(w_0)} y_i (\langle w_0, x_i \rangle + \beta_{\mathcal{D}}(w_0)) \geq \frac{\Delta_{\mathcal{D}}(w_0)}{\Delta_{\mathcal{D}}(w_0)} = 1,$$

y tiene norma $1/\Delta_{\mathcal{D}}(w_0) < \|w^*\|$, contradiciendo la optimalidad de w^* . ■

El Teorema 2.3.3 muestra que el problema (2.2) admite una formulación eficiente y es computacionalmente muy tratable. Sin embargo, tiene una limitación fundamental: si $\mathcal{D}$ no es (SPH), el conjunto factible es vacío y el problema carece de solución.

2.3.5 Soft-Margin SVM

Para tratar el caso no separable, se introducen *variables de holgura* $\xi_i \geq 0$ que permiten a cada punto violar la restricción de margen en una cantidad ξ_i :

$$y_i (\langle w, x_i \rangle + b) \geq 1 - \xi_i.$$

La idea es penalizar estas violaciones en el objetivo, dando lugar al problema

$$\min_{\substack{(w,b) \in \mathbb{R}^d \times \mathbb{R} \\ \xi \in \mathbb{R}_+^m}} \left(\frac{1}{m} \sum_{i=1}^m \xi_i + \lambda \|w\|^2 \right) \quad \text{sujeto a} \quad \forall i \in \mathbb{N}_m : y_i (\langle w, x_i \rangle + b) \geq 1 - \xi_i, \quad (2.3)$$

donde $\lambda > 0$ es un hiperparámetro que pondera el balance entre el margen y las violaciones.

Dado (w, b) fijo, cada ξ_i aparece en (2.3) con coeficiente positivo $\frac{1}{m}$ en el objetivo y sujeto únicamente a $\xi_i \geq \max\{0, 1 - y_i(\langle w, x_i \rangle + b)\}$ (la restricción $\xi_i \geq 0$ junto con $y_i(\langle w, x_i \rangle + b) \geq 1 - \xi_i$). Minimizar el objetivo requiere tomar ξ_i lo más pequeño posible, es decir, igual a su cota inferior $\max\{0, 1 - y_i(\langle w, x_i \rangle + b)\}$. Así:

- si el punto x_i está correctamente clasificado *con margen suficiente* ($y_i(\langle w, x_i \rangle + b) \geq 1$), entonces $\xi_i^* = 0$ (no hay penalización);
- si el punto viola el margen o está mal clasificado (es decir, $y_i(\langle w, x_i \rangle + b) < 1$), entonces $\xi_i^* = 1 - y_i(\langle w, x_i \rangle + b) > 0$ mide cuánto falta para satisfacer la restricción.

Sustituyendo, el problema (2.3) es equivalente a minimizar la *pérdida hinge regularizada*:

$$\arg \min_{(w,b) \in \mathbb{R}^d \times \mathbb{R}} \mathcal{E}_{\text{hinge}}(w, b) + \lambda \|w\|^2, \quad \text{donde} \quad \mathcal{E}_{\text{hinge}}(w, b) := \frac{1}{m} \sum_{i=1}^m \max\{0, 1 - y_i(\langle w, x_i \rangle + b)\}.$$

El término *hinge* (“bisagra” en inglés) alude a la forma de la función $t \mapsto \max\{0, 1 - t\}$:

Observación 2.3.10. A diferencia del error 0-1 empírico

$$\mathcal{E}_0(w, b) = \frac{1}{m} \left| \{i : y_i(\langle w, x_i \rangle + b) \leq 0\} \right|,$$

que en general no es convexo (puede tener múltiples mínimos locales), el funcional $\mathcal{E}_{\text{hinge}}(w, b) + \lambda \|w\|^2$ es *convexo* para todo $\lambda > 0$: $t \mapsto \max\{0, 1 - t\}$ es convexa y $w \mapsto \|w\|^2$ también lo es, luego su combinación es convexa.

Algunos datasets $D \subset \mathbb{R}^d \times \{-1, 1\}$ no solo no son (SPH), sino que también SOFT-SVM no proporciona buenos resultados.

Ejemplo 2.3.2. Para separar este conjunto con un hiperplano es necesario hacer una inmersión en un espacio más grande.

Reemplacemos un dato $x \in \mathbb{R}^2$ con $y = \left(x, \frac{1}{1+\|x\|^2}\right) \in \mathbb{R}^3$. Entonces, un hiperplano que separe existe.

Esta idea se generaliza haciendo una inmersión en un RKHS.

Si $X \subset \mathbb{R}^d$, $f : X \rightarrow \mathbb{R}^N$ continua, digamos

$$K^f(x, y) := \langle x, y \rangle_{\mathbb{R}^d} + \langle f(x), f(y) \rangle_{\mathbb{R}^N}$$

- K^f es de Mercer: continua, hermítico, > 0 .

- Sea $\phi : X \rightarrow \mathbb{R}^d \times \mathbb{R}^N$, $\phi(x) = (x, f(x))$

$$\implies K^f(x, y) = \langle \phi(x), \phi(y) \rangle_{\mathbb{R}^d \times \mathbb{R}^N}$$

$\phi(X) = G_f$, gráfico de f .

- El RKHS de K^f es $\mathcal{H}_{K^f} = \mathcal{H}_\phi$, donde

$$\mathcal{H}_\phi := \{g : X \rightarrow \mathbb{R} \mid \exists w \in \text{span}\{\phi(x) : x \in X\} : g(x) = g_w(x) = \langle w, \phi(x) \rangle_{\mathbb{R}^{d+N}} \forall x \in X\}$$

Si $g_{w_1}, g_{w_2} \in \mathcal{H}_\phi$,

$$\langle g_{w_1}, g_{w_2} \rangle_{\mathcal{H}_\phi} := \langle w_1, w_2 \rangle_{\mathbb{R}^{d+N}}$$

Demostración:

1. $\mathcal{H}_\phi$ es un espacio vectorial.
2. Sea $V = \text{span}\{\phi(x) : x \in X\} \subset \mathbb{R}^{d+N}$.

Sea $L : \mathbb{R}^{d+N} \rightarrow \mathcal{H}_\phi$, $Lw = \langle w, \phi(\cdot) \rangle_{\mathbb{R}^{d+N}}$.

- $\ker L = V^\perp$: si $\xi \in \mathcal{H}_\phi$, $\exists! w = L^{-1}\xi \in V$.

- $\|Lw\|_{\mathcal{H}_\phi} = \|w\|_{\mathbb{R}^{d+N}}$ por definición.

$\implies \mathcal{H}_\phi, \|\cdot\|_{\mathcal{H}_\phi}$ es norma y L es isometría.

3. $\xi(x) = \langle w, \phi(x) \rangle_V = \langle L^{-1}\xi, \phi(x) \rangle_V = \langle \xi, L\phi(x) \rangle_{\mathcal{H}_\phi}$.

Donde $(L\phi(x))(y) = \langle \phi(x), \phi(y) \rangle_V = k^\phi(x, y)$.

$\implies \mathcal{H}_\phi$ tiene la reproducibility property.

■

De aquí que, si tenemos una inmersión ϕ de los $\{x_i, y_i\}_{i=1}^m$ de $\mathcal{D}$ en un espacio más grande, y queremos separar $\bar{\mathcal{D}} = \{(\phi(x_i), y_i)\}_{i=1}^m$

$\implies$ vamos a minimizar (incorporando el bias en $\mathbf{w}$ con la extensión afín mencionada)

$$L_\phi(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \max\{0, 1 - y_i \langle \mathbf{w}, \phi(x_i) \rangle\} + \lambda \|\mathbf{w}\|^2.$$

Por la construcción anterior, esta función de $\mathbf{w}$ es un funcional de $\mathcal{H}_\phi = \mathcal{H}_K$: si $\mathbf{g} \in \mathcal{H}_K$

$$(*) \quad L_\phi(\mathbf{g}) = \frac{1}{m} \sum_{i=1}^m \max\{0, 1 - y_i \mathbf{g}(x_i)\} + \lambda \|\mathbf{g}\|_{\mathcal{H}_K}^2.$$

Este procedimiento es general para todo RKHS: si $k : X \times X \rightarrow \mathbb{R}$ es Mercer, toda $\mathbf{g} \in \mathcal{H}_k$ es (límite de) una combinación lineal

$$\mathbf{g}(x) = \sum_j \alpha_j k_{x_j}(x) = \left\langle \sum_j \alpha_j k_{x_j}, k_x \right\rangle = \langle w, \phi(x) \rangle$$

$\implies$ el problema de la clasificación lineal en RKHS por minimización de ℓ^* produce un clasificador $\mathbf{g}_\infty \in$

$$\begin{aligned} i \in I_1 &\iff \mathbf{g}_\infty(x_i) > 0 \quad (\text{sgn}(\mathbf{g}_\infty(x_i)) = y_i = 1) \\ i \in I_{-1} &\iff \mathbf{g}_\infty(x_i) < 0 \quad (\text{sgn}(\mathbf{g}_\infty(x_i)) = y_i = -1) \end{aligned}$$

Observación 2.3.11. Si usamos un RKHS universal, como $\{x_i\}_{i=1}^m$ siempre va a estar en un compacto, podemos separar **todos** los datasets.

Esto no garantiza que el resultado generalice bien: ver No Free Lunch Theorem.

Steinwart, Christmann, Prop. 4.54.

Como $\mathcal{L}$ es convexa, tiene un único mínimo, pero un RKHS universal como RBF tiene dimensión infinita.

Problema para la búsqueda.

se resuelve con el **REPRESENTER THEOREM**

$$\forall \mathcal{H}_K(X), \forall \mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset X \times \mathbb{R}$$

$$\min_{g \in \mathcal{H}_K} L_{\mathcal{D}}^K(g) = \min_{g \in V_{\mathcal{D}}} L_{\mathcal{D}}^K(g)$$

donde $V_{\mathcal{D}} = \text{span} \{K_{x_i}\}_{i=1}^m$ (solo los datos: DIMENSIÓN FINITA)

esto proporciona una reformulación final del problema como problema en $\mathbb{R}^m$

$$\text{Si } \xi \in V_0 \implies \xi(x_i) = \sum_{j=1}^m \alpha_j K(x_i, x_j)$$

$$\text{y } \|\xi\|_{\mathcal{H}_K}^2 = \sum_{j=1}^m \alpha_i \alpha_j K(x_i, x_j).$$

Por tanto, si, a partir de $\mathcal{D}$, construimos la matriz M_K^0

$$(M_K^0)_{ij} = K(x_i, x_j)$$

$\implies$ el problema de minimizar $(*)$

se traduce en el problema

SOFT KERNEL SVM: minimizar

$$\mathcal{L}(\alpha) = \frac{1}{m} \sum_{i=1}^m \max\{0, 1 - y_i(\mathbf{M}^k \alpha)_i\} + \lambda \langle \alpha, \mathbf{M}^k \alpha \rangle$$

sobre $\alpha \in \mathbb{F}^m$. El clasificador que resulta es $f : X \rightarrow Y$ dado por

$$f(x) = \text{sgn} \left(\sum_{j=1}^m \alpha_j k(x_j, x) \right).$$

Sobre la "universalidad" (de un RKHS y no solo):

Proposición 2.3.4 (Steinwart, Christmann, Prop. 4.54). *Sea X espacio métrico compacto, y sea $V \subset C(X)$ un conjunto denso en la norma $\|\cdot\|_{\infty}$.*

$$\implies \forall A, B \subset X \text{ compactos disjuntos} \quad \exists f \in V : f(x) > 0 \ \forall x \in A, \ f(x) < 0 \ \forall x \in B$$

Demostración: La siguiente es una función continua:

$$g(x) = \frac{\text{dist}(x, B)}{\text{dist}(x, A) + \text{dist}(x, B)} - \frac{\text{dist}(x, A)}{\text{dist}(x, A) + \text{dist}(x, B)}$$

Además, $g(x) = 1 \ \forall x \in A$, $g(x) = -1 \ \forall x \in B$.

Sea $\varepsilon < \frac{1}{2}$, y sea $f \in V : \max_{x \in X} |f(x) - g(x)| = \|f - g\|_\infty < \varepsilon$.

$$\implies \begin{cases} \forall x \in A, f(x) = f(x) + g(x) \geq 1 - |f(x) - g(x)| > \frac{1}{2} \\ \forall x \in B, f(x) = f(x) + g(x) \leq -1 + |f(x) - g(x)| < -\frac{1}{2} \end{cases}$$

$\implies$ a una función así se le llama también "clasificador de Bayes". ■

Un ejemplo de RKHS universal es el RBF (*Steinwart, Christmann, Corollary 4.58*).

2.3.6 Teorema de No Free Lunch (NFL)

En muchos casos, al resolver un problema de clasificación, podemos sufrir de **overfitting** (sobreajuste): el clasificador que obtenemos a partir de $\mathcal{D}$ es muy bueno para clasificar los datos de $\mathcal{D}$, pero no generaliza bien a nuevos datos.

El overfitting puede ocurrir por varios motivos, como muestran los siguientes ejemplos:

Ejemplos 2.3.3 (de overfitting).

- [1] Consideramos un dataset de entreno que contenga imágenes de perros e imágenes de gatos. Un algoritmo de clasificación entrenado en dicho dataset no sería capaz de generalizar a, por ejemplo, imágenes de coches, porque solo ha aprendido a distinguir entre perros y gatos.
- [2] El overfitting también puede ocurrir cuando la **dimensionalidad** del dataset de entreno es mucho menor a la dimensionalidad del espacio. Por ejemplo, si tenemos un dataset de entreno con solo 10 puntos en un espacio de 100 dimensiones, es posible que el clasificador aprenda a clasificar perfectamente esos 10 puntos, pero no generalice bien a nuevos datos debido a la falta de información suficiente para aprender patrones significativos.

Recordemos que para clasificadores binarios, el error de generalización es

$$\mathcal{E}[g] = \int_X \mathbb{P}(\{y \neq g(x)\} \mid x) d\rho_X(x) = \mathbb{P}(\{y \neq f(x)\}).$$

Si, en lugar de $Y = \{-1, 1\}$, tenemos $Y = \{0, 1\}$, entonces la función de regresión es

$$f_\rho(x) = \sum_{y \in Y} y \cdot \rho(y | x) = \mathbb{P}(\{y = 1\} | x).$$

y el clasificador óptimo, llamado **regla de Bayes**, es

$$g^*(x) = \begin{cases} 1, & \text{si } f_\rho(x) \geq \frac{1}{2} \\ 0, & \text{si } f_\rho(x) < \frac{1}{2}. \end{cases}$$

Lema 2.3.5. Sea $g: X \rightarrow Y$ un clasificador binario. Entonces $\mathcal{E}[g^*] \leq \mathcal{E}[g]$.

Demostración: Para cada $i \in \{0, 1\}$, denotamos $C_i^g := \{x \in X : g(x) = i\}$. Como $\{C_0^g, C_1^g\}$ es una partición de X , se tiene que $\forall x \in X : \mathbb{1}_{C_0^g}(x) + \mathbb{1}_{C_1^g}(x) = 1$. Calculamos el error condicional de g en x :

$$\begin{aligned} \mathbb{P}(\{y \neq g(x)\} | x) &= 1 - \mathbb{P}(\{y = g(x)\} | x) \cdot (\mathbb{1}_{C_0^g}(x) + \mathbb{1}_{C_1^g}(x)) \\ &= 1 - \mathbb{P}(\{y = 0\} | x) \mathbb{1}_{C_0^g}(x) - \mathbb{P}(\{y = 1\} | x) \mathbb{1}_{C_1^g}(x) \\ &= 1 - (1 - f_\rho(x)) \mathbb{1}_{C_0^g}(x) - f_\rho(x) \mathbb{1}_{C_1^g}(x). \end{aligned}$$

Sustituyendo $\mathbb{1}_{C_0^g} = 1 - \mathbb{1}_{C_1^g}$ y simplificando:

$$\mathbb{P}(\{y \neq g(x)\} | x) = 1 - (2f_\rho(x) - 1) \mathbb{1}_{C_1^g}(x).$$

La misma expresión es válida para g^* , por lo que la diferencia de errores condicionales es

$$\mathbb{P}(\{y \neq g(x)\} | x) - \mathbb{P}(\{y \neq g^*(x)\} | x) = 2(f_\rho(x) - \frac{1}{2}) \left(\mathbb{1}_{C_1^{g^*}}(x) - \mathbb{1}_{C_1^g}(x) \right).$$

Esta expresión es no negativa para todo $x \in X$: por definición de g^* ,

- si $f_\rho(x) \geq \frac{1}{2}$, entonces $g^*(x) = 1$, luego $\mathbb{1}_{C_1^{g^*}}(x) = 1 \geq \mathbb{1}_{C_1^g}(x)$ y $2(f_\rho(x) - \frac{1}{2}) \geq 0$;
- si $f_\rho(x) < \frac{1}{2}$, entonces $g^*(x) = 0$, luego $\mathbb{1}_{C_1^{g^*}}(x) = 0 \leq \mathbb{1}_{C_1^g}(x)$ y $2(f_\rho(x) - \frac{1}{2}) < 0$.

En ambos casos, el producto de los dos factores es ≥ 0 . Integrando respecto a ρ_X :

$$\mathcal{E}[g] - \mathcal{E}[g^*] = 2 \int_X (f_\rho(x) - \frac{1}{2}) \left(\mathbb{1}_{C_1^{g^*}}(x) - \mathbb{1}_{C_1^g}(x) \right) d\rho_X(x) \geq 0. \quad \blacksquare$$

Definición 2.3.12. Un **algoritmo de aprendizaje** es una función $A: (X \times Y)^m \rightarrow \mathcal{H}$ que, dado un dataset de entrenamiento $\mathcal{D} \in (X \times Y)^m$, devuelve un clasificador $A[\mathcal{D}]: X \rightarrow Y$.

Hay varios teoremas “No Free Lunch”, que apuntan a decir que no existe un algoritmo bueno para todas las tareas. Aquí demostraremos el siguiente resultado de Devroye de 1982.

Teorema 2.3.6. Sea X un conjunto infinito y sea A un algoritmo de aprendizaje. Entonces, para todo $m \in \mathbb{N}$ y para todo $\varepsilon > 0$, existe una distribución ρ sobre $X \times \{0, 1\}$ tal que

- (1) $\mathcal{E}[g^*] = 0$ (La regla de Bayes clasifica perfectamente).
- (2) $\mathbb{E}[\mathcal{E}[A[\mathcal{D}]]] \geq \frac{1}{2} - \varepsilon$ (El error esperado del clasificador devuelto por el algoritmo es arbitrariamente cercano a $1/2$, es decir, tan malo como un clasificador aleatorio).

Demostración: Como X es infinito, podemos fijar un subconjunto $C = \{c_1, \dots, c_k\} \subset X$ con $k > m$ puntos distintos. Sea $R_k := \{r: C \rightarrow \{0, 1\}\} \cong \{0, 1\}^k$ el conjunto de todas las etiquetaciones posibles de C .

Paso 1: Construcción de las distribuciones. Para cada $r \in R_k$, definimos la distribución ρ_r sobre $C \times \{0, 1\}$ como la uniforme sobre los k pares etiquetados de forma determinista por r :

$$\rho_r(\{(c_i, r(c_i))\}) = \frac{1}{k} \quad \forall i \in \{1, \dots, k\}.$$

Dado que la etiqueta queda determinada por r (no hay aleatoriedad en y dado x), la función de regresión satisface $f_{\rho_r}(c_i) = r(c_i) \in \{0, 1\}$. Por tanto, la regla de Bayes $g^*(c_i) = r(c_i)$ clasifica perfectamente y $\mathcal{E}_{\rho_r}[g^*] = 0$, verificando la condición (1) del enunciado.

Paso 2: Error esperado del algoritmo para r fijo. Fijado $r \in R_k$, sea

$$S(r) := \mathbb{E}_{\mathcal{D} \sim \rho_r^m} [\mathcal{E}_{\rho_r}[A[\mathcal{D}]]]$$

el error esperado del clasificador que devuelve A al entrenarse con m muestras de ρ_r . Puesto que ρ_r está soportada en m pares $\{(c_i, r(c_i))\}$, un dataset $\mathcal{D} \sim \rho_r^m$ equivale a elegir uniformemente una secuencia $(i_1, \dots, i_m) \in \{1, \dots, k\}^m$, produciendo el dataset

$$\mathcal{D}_r^{(j)} := \{(c_{i_\ell}, r(c_{i_\ell}))\}_{\ell=1}^m, \quad j = (i_1, \dots, i_m) \in \{1, \dots, k\}^m.$$

Desarrollando la esperanza como suma uniforme sobre los k^m datasets posibles, y expandiendo el error de generalización:

$$S(r) = \frac{1}{k^m} \sum_{j=1}^{k^m} \mathcal{E}_{\rho_r}[A[\mathcal{D}_r^{(j)}]] = \frac{1}{k^m} \sum_{j=1}^{k^m} \frac{1}{k} \sum_{i=1}^k \mathbb{1}_{\{A[\mathcal{D}_r^{(j)}](c_i) \neq r(c_i)\}}.$$

Paso 3: Puntos no vistos en el entrenamiento. Para cada dataset $\mathcal{D}_r^{(j)}$, definimos el conjunto de índices *no vistos* en ese dataset:

$$M^{(j)} := \{i \in \{1, \dots, k\} : c_i \notin \{x : (x, y) \in \mathcal{D}_r^{(j)}\}\}.$$

Como $\mathcal{D}_r^{(j)}$ contiene a lo sumo m valores distintos de C y $k > m$, se tiene $|M^{(j)}| \geq k - m > 0$.

En particular, restringiendo la suma interior a los índices no vistos:

$$S(r) \geq \frac{1}{k^m} \sum_{j=1}^{k^m} \frac{1}{k} \sum_{i \in M^{(j)}} \mathbb{1}_{\{A[\mathcal{D}_r^{(j)}](c_i) \neq r(c_i)\}}.$$

Paso 4: Promedio sobre todas las etiquetaciones. Como $\max_r S(r) \geq \mathbb{E}_{r \sim \text{unif}(R_k)}[S(r)]$, basta acotar inferiormente la media de $S(r)$. Intercambiando el orden de las sumas y la esperanza:

$$\mathbb{E}_r[S(r)] \geq \frac{1}{k^m} \sum_{j=1}^{k^m} \frac{1}{k} \sum_{i \in M^{(j)}} \mathbb{E}_r \left[\mathbb{1}_{\{A[\mathcal{D}_r^{(j)}](c_i) \neq r(c_i)\}} \right].$$

La clave está en evaluar $\mathbb{E}_r[\mathbb{1}_{\{A[\mathcal{D}_r^{(j)}](c_i) \neq r(c_i)\}}]$ para $i \in M^{(j)}$: como $c_i \notin \mathcal{D}_r^{(j)}$, el dataset $\mathcal{D}_r^{(j)}$ no depende de $r(c_i)$, luego tampoco lo hace $A[\mathcal{D}_r^{(j)}](c_i)$. Siendo $r(c_i)$ uniforme en $\{0, 1\}$ independientemente de $A[\mathcal{D}_r^{(j)}](c_i) \in \{0, 1\}$, la probabilidad de desacuerdo es $\frac{1}{2}$:

$$\forall i \in M^{(j)} : \mathbb{E}_r \left[\mathbb{1}_{\{A[\mathcal{D}_r^{(j)}](c_i) \neq r(c_i)\}} \right] = \frac{1}{2}.$$

Paso 5: Conclusión. Sustituyendo y usando $|M^{(j)}| \geq k - m$:

$$\mathbb{E}_r[S(r)] \geq \frac{1}{k^m} \sum_{j=1}^{k^m} \frac{1}{k} \cdot |M^{(j)}| \cdot \frac{1}{2} \geq \frac{1}{k^m} \sum_{j=1}^{k^m} \frac{k - m}{2k} = \frac{k - m}{2k} = \frac{1}{2} \left(1 - \frac{m}{k} \right).$$

Por tanto, $\max_{r \in R_k} S(r) \geq \frac{1}{2} \left(1 - \frac{m}{k} \right)$. Dado $\varepsilon > 0$, basta elegir $k > \frac{m}{2\varepsilon}$ para obtener

$$\max_{r \in R_k} S(r) \geq \frac{1}{2} \left(1 - \frac{m}{k} \right) > \frac{1}{2} - \varepsilon.$$

La distribución ρ_r correspondiente al maximizador r satisface simultáneamente las condiciones (1) y (2) del enunciado. ■

Observación 2.3.13. Este resultado, como todos los NFLT, se basa en la posibilidad de que el dataset disponible para el aprendizaje no sea representativo de ρ .

2.4 Descenso del gradiente

2.4.1 Planteamiento del problema

Sea $F: \mathbb{R}^p \rightarrow \mathbb{R}$ una función suave. El objetivo es encontrar un mínimo local de F , es decir, un punto $x^* \in \mathbb{R}^p$ tal que $F(x^*) \leq F(x)$ para todo x en una vecindad de x^* . En particular,

si F es convexa, entonces cualquier mínimo local es también un mínimo global.

El descenso del gradiente es un método iterativo para aproximar un mínimo local de F . Dado un punto inicial $x_0 \in \mathbb{R}^p$, se generan una secuencia de puntos $\{x_k\}_{k=0}^{\infty}$ mediante la regla de actualización

$$\forall k \in \mathbb{N} : x_{k+1} = x_k - \eta \nabla F(x_k),$$

donde $\eta > 0$ es el tamaño del paso o tasa de aprendizaje. La idea es moverse en la dirección opuesta al gradiente de F en el punto actual, ya que el gradiente apunta en la dirección de máximo aumento de F .

Prestando atención al desarrollo de Taylor de F alrededor de x_{k+1} , se tiene

$$F(x_k - \eta \nabla F(x_k)) = F(x_k) - \eta \|\nabla F(x_k)\|^2 + \frac{\eta^2}{2} \langle \nabla F(x_k), \text{Hess } F(x_k) \nabla F(x_k) \rangle + \dots$$

donde $\text{Hess } F(x_k)$ es la matriz hessiana de F en x_k . Definimos

$$\Lambda := \max \{ \lambda \text{ autovalor de } \text{Hess } F(x) : x \in \mathbb{R}^p \}.$$

Si $\Lambda < \infty$, entonces $F(x_{k+1}) \approx F(x_k) - \eta \left(1 - \Lambda \frac{\eta}{2}\right) \|\nabla F(x_k)\|^2$ para $\eta < 2/\Lambda$, luego

$$|F(x_{k+1}) - F(x_k)| \leq |F(x_k) - F(x^*)| - \eta \left(1 - \Lambda \frac{\eta}{2}\right) \|\nabla F(x_k)\|^2$$

donde x_* es un mínimo local de F . Esto muestra que $F(x_k)$ converge a $F(x^*)$ y que $\nabla F(x_k) \rightarrow 0$ a medida que $k \rightarrow \infty$. Sin embargo, no nos dice a qué velocidad ocurre esto, ni nos garantiza que x_k converja a un mínimo global.

2.4.2 Descenso del gradiente estocástico

En muchos casos, como en el aprendizaje automático, la función F tiene la forma

$$\forall \theta \in \mathbb{R}^p : \mathcal{L}(\theta) = \frac{1}{m} \sum_{i=1}^m \mathcal{L}_i(\theta), \quad \text{donde } \mathcal{L}_i(\theta) := \ell(y_i, f_\theta(x_i), \theta),$$

$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m$ es un conjunto de datos de entrenamiento, $f_\theta : \mathbb{R}^d \rightarrow \mathbb{R}$ es un modelo parametrizado por θ , y $\ell : \mathbb{R} \times \mathbb{R} \times \mathbb{R}^p \rightarrow \mathbb{R}$ es una función de pérdida que mide el error del modelo f_θ en la muestra (x_i, y_i) . Por ejemplo,

$$\ell(y, f_\theta(x), \theta) = \|y - f_\theta(x)\|^2 + \|\theta\|^2.$$

En contraposición con el algoritmo de descenso del gradiente, que requiere calcular el gradiente completo $\nabla \mathcal{L}(\theta) = \frac{1}{m} \sum_{i=1}^m \nabla \mathcal{L}_i(\theta)$ en cada iteración, el descenso del gradiente estocástico (SGD) actualiza los parámetros utilizando un gradiente estimado a partir de una sola muestra o de un mini-lote de muestras. Es decir, en cada iteración se selecciona aleato-

riamente un conjunto de índices $\mathcal{B}_k \subseteq \{1, \dots, m\}$ y se actualiza

$$\theta_{k+1} = \theta_k - \eta \frac{1}{|\mathcal{B}_k|} \sum_{i \in \mathcal{B}_k} \nabla \mathcal{L}_i(\theta_k).$$

Si $|\mathcal{B}_k| = 1$, entonces $\theta_{k+1} = \theta_k - \eta \nabla \mathcal{L}_{i_k}(\theta_k)$, donde i_k es un índice seleccionado aleatoriamente.

La propiedad crucial de este método es que la esperanza condicionada del gradiente estimado es igual al gradiente verdadero:

$$\forall k \in \mathbb{N} : \mathbb{E} \left[\nabla \mathcal{L}_{i_k}(\theta_k) \mid \theta_k \right] = \sum_{j=1}^m \mathbb{P}(i_k = j) \nabla \mathcal{L}_j(\theta_k) = \frac{1}{m} \sum_{j=1}^m \nabla \mathcal{L}_j(\theta_k) = \nabla \mathcal{L}(\theta_k).$$

Esto significa que, en promedio, el descenso del gradiente estocástico sigue la dirección de descenso del gradiente verdadero, aunque con ruido debido a la variabilidad de las muestras seleccionadas.

Definición 2.4.1. Sea $\Lambda > 0$ y $\mathcal{L} \in \mathcal{C}^1(\mathbb{R}^p)$, $\mathcal{L}$ es Λ -suave

$$\iff \forall x, y \in \mathbb{R}^p : \mathcal{L}(y) \leq \mathcal{L}(x) + \langle \nabla \mathcal{L}(x), y - x \rangle + \frac{\Lambda}{2} \|y - x\|^2.$$

Intuitivamente, ser Λ -suave significa que la función $\mathcal{L}$ no puede crecer más rápido que una función cuadrática con curvatura Λ . Esto implica que el gradiente de $\mathcal{L}$ no puede cambiar demasiado rápidamente, lo que es una condición importante para garantizar la convergencia del descenso del gradiente.

Ejercicio 2.4.1. Demuestra que si $\mathcal{L} \in \mathcal{C}^2(\mathbb{R}^p)$, entonces $\mathcal{L}$ es Λ -suave si y solo si todo autovalor de la matriz hessiana $\text{Hess } \mathcal{L}(x)$ es menor o igual a Λ para todo $x \in \mathbb{R}^p$.

Lema 2.4.1. Sea $\mathcal{L}$ Λ -suave y sea $(\theta_k)_{k=0}^\infty$ la sucesión generada por el descenso del gradiente estocástico. Entonces, para todo $k \in \mathbb{N}$,

$$\mathbb{E} \left[\mathcal{L}(\theta_{k+1}) \mid \theta_k \right] \leq \mathcal{L}(\theta_k) - \eta \|\nabla \mathcal{L}(\theta_k)\|^2.$$

Demostración: Dado que $\mathcal{L}$ es Λ -suave, se tiene

$$\begin{aligned} \mathbb{E} \left[\mathcal{L}(\theta_{k+1}) \mid \theta_k \right] &\leq \mathbb{E} \left[\mathcal{L}(\theta_k) + \langle \nabla \mathcal{L}(\theta_k), \theta_{k+1} - \theta_k \rangle + \frac{\Lambda}{2} \|\theta_{k+1} - \theta_k\|^2 \mid \theta_k \right] \\ &= \mathcal{L}(\theta_k) + \langle \nabla \mathcal{L}(\theta_k), -\eta \nabla \mathcal{L}(\theta_k) \rangle + \underbrace{\frac{\Lambda}{2} \eta^2 \mathbb{E} [\|\nabla \mathcal{L}_{i_k}(\theta_k)\|^2 \mid \theta_k]}_{\geq 0} \\ &\leq \mathcal{L}(\theta_k) - \eta \|\nabla \mathcal{L}(\theta_k)\|^2. \end{aligned}$$

■

Ejercicio 2.4.2. Demuestra que si $\mathcal{L} \in \mathcal{C}^1(\mathbb{R}^p)$ entonces $\mathcal{L}$ es convexa si y solo si

$$\forall x, y \in \mathbb{R}^p : \mathcal{L}(y) \leq \mathcal{L}(x) - \langle \nabla \mathcal{L}(x), x - y \rangle.$$

Lema 2.4.2. Sea $\mathcal{L} \in \mathcal{C}^1(\mathbb{R}^p)$ convexa y sea $(\theta_k)_{k=0}^\infty$ la sucesión generada por el descenso del gradiente estocástico. Supongamos que $\forall k \geq 0 : \mathbb{E}[\|\nabla \mathcal{L}_{i_k}(\theta_k)\|^2 \mid \theta_k] \leq \Sigma$ para alguna constante $\Sigma > 0$, entonces

$$\forall \theta \in \mathbb{R}^p : \mathcal{L}(\theta_k) \leq \mathcal{L}(\theta) + \frac{1}{2\eta} \mathbb{E}[\|\theta_k - \theta\|^2 - \|\theta_{k+1} - \theta\|^2 \mid \theta_k] + \frac{\Sigma}{2\eta}.$$

Demostración: Por convexidad de $\mathcal{L}$ y descenso del gradiente estocástico, se tiene

$$\begin{aligned} \mathcal{L}(\theta_k) &\leq \mathcal{L}(\theta) - \langle \nabla \mathcal{L}(\theta_k), \theta - \theta_k \rangle = \mathcal{L}(\theta) - \left\langle \mathbb{E}[\nabla \mathcal{L}_{i_k}(\theta_k) \mid \theta_k], \theta - \theta_k \right\rangle \\ &= \mathcal{L}(\theta) + \frac{1}{\eta} \mathbb{E}[-\langle \theta_k - \theta_{k+1}, \theta - \theta_k \rangle \mid \theta_k] \end{aligned}$$

Por la conocida identidad $-\langle a - b, c - a \rangle = \frac{1}{2} (\|a - c\|^2 - \|b - c\|^2 - \|a - b\|^2)$, se tiene

$$\mathcal{L}(\theta_k) \leq \mathcal{L}(\theta) + \frac{1}{2\eta} \mathbb{E}[\|\theta_k - \theta\|^2 - \|\theta_{k+1} - \theta\|^2 - \|\theta_k - \theta_{k+1}\|^2 \mid \theta_k].$$

Dado que $\|\theta_k - \theta_{k+1}\|^2 = \eta^2 \|\nabla \mathcal{L}_{i_k}(\theta_k)\|^2$ y, por hipótesis, $\mathbb{E}[\|\nabla \mathcal{L}_{i_k}(\theta_k)\|^2 \mid \theta_k] \leq \Sigma$,

$$\mathcal{L}(\theta_k) \leq \mathcal{L}(\theta) + \frac{1}{2\eta} \mathbb{E}[\|\theta_k - \theta\|^2 - \|\theta_{k+1} - \theta\|^2] + \frac{\Sigma}{2\eta}. \quad \blacksquare$$

Teorema 2.4.3. Sea $\mathcal{L} \in \mathcal{C}^1(\mathbb{R}^p)$ convexa y sea $(\theta_k)_{k=0}^\infty$ la sucesión generada por el descenso del gradiente estocástico. Supongamos que $\forall k \geq 0 : \mathbb{E}[\|\nabla \mathcal{L}_{i_k}(\theta_k)\|^2 \mid \theta_k] \leq \Sigma$ para alguna constante $\Sigma > 0$, entonces

$$\eta \leq \frac{1}{\sqrt{\Sigma T}} \text{ para } T > 0 \implies \mathbb{E} \left[\mathcal{L} \left(\frac{1}{T} \sum_{k=0}^{T-1} \theta_k \right) - \mathcal{L}(\theta^*) \right] \leq \frac{\sqrt{\Sigma}}{2\sqrt{T}} (1 + \|\theta_0 - \theta^*\|^2),$$

donde $\theta^* = \arg \min_{\theta \in \mathbb{R}^p} \mathcal{L}(\theta)$.

Demostración: Aplicando el lema anterior con $\theta = \theta^*$, se tiene

$$\mathbb{E} \left[\sum_{k=0}^{T-1} \mathcal{L}(\theta_k) \right] \leq T \mathcal{L}(\theta^*) + \frac{1}{2\eta} \mathbb{E} \left[\sum_{k=0}^{T-1} \|\theta_k - \theta^*\|^2 - \|\theta_{k+1} - \theta^*\|^2 \right] + \frac{\Sigma}{2\eta}$$

Dado que $\sum_{k=0}^{T-1} \|\theta_k - \theta^*\|^2 - \|\theta_{k+1} - \theta^*\|^2$ es una suma telescópica, se tiene

$$\begin{aligned} \mathbb{E} \left[\sum_{k=0}^{T-1} \mathcal{L}(\theta_k) \right] &\leq T \mathcal{L}(\theta^*) + \frac{1}{2\eta} \mathbb{E} [\|\theta_0 - \theta^*\|^2 - \|\theta_T - \theta^*\|^2] + \frac{\Sigma}{2\eta} \\ &\leq T \mathcal{L}(\theta^*) + \frac{1}{2\eta} \|\theta_0 - \theta^*\|^2 + \frac{\Sigma}{2\eta}. \end{aligned}$$

Al dividir por T y aplicar convexidad de $\mathcal{L}$, se tiene

$$\frac{1}{T} \sum_{k=0}^{T-1} \mathbb{E} [\mathcal{L}(\theta_k)] - \mathcal{L}(\theta^*) \leq \frac{1}{2\eta T} \|\theta_0 - \theta^*\|^2 + \frac{\Sigma}{2\eta T} = \frac{\sqrt{\Sigma}}{2\sqrt{T}} (1 + \|\theta_0 - \theta^*\|^2).$$

■

3. Introducción a las redes neuronales

3.1 Multilayer Perceptron (MLP)

Los métodos estudiados en capítulos anteriores —el Perceptrón de Rosenblatt y las SVM— son esencialmente lineales: producen fronteras de decisión afines. Muchos problemas de interés práctico, sin embargo, involucran dependencias fuertemente no lineales.

Una respuesta natural a esta limitación es la *composición iterada* de transformaciones sencillas: cada capa aplica una transformación afín seguida de una no linealidad puntual, y la composición de varias capas permite representar funciones de complejidad creciente. Esta arquitectura es la red neuronal prototípica y el fundamento de los métodos modernos de aprendizaje profundo.

Definición 3.1.1 (Función de activación). Una *función de activación* es una función $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ que no es un polinomio. Extendemos su acción a vectores coordenada a coordenada: para $v \in \mathbb{R}^n$, $\sigma(v) := (\sigma(v_1), \dots, \sigma(v_n)) \in \mathbb{R}^n$.

Definición 3.1.2 (Perceptrón). Sea σ una función de activación. Un *perceptrón* (o *neurona artificial*) con n entradas es una función $h: \mathbb{R}^n \rightarrow \mathbb{R}$ de la forma

$$h(x) := \sigma(w^\top x + b),$$

donde $w \in \mathbb{R}^n$ es el *vector de pesos* (*weights*) y $b \in \mathbb{R}$ es el *sesgo* (*bias*).

Definición 3.1.3 (Capa). Sea σ una función de activación. Una *capa* de anchura n_{sal} con dominio $\mathbb{R}^{n_{\text{ent}}}$ es una función $h: \mathbb{R}^{n_{\text{ent}}} \rightarrow \mathbb{R}^{n_{\text{sal}}}$ de la forma

$$h(x) := \sigma(Wx + b),$$

donde $W \in \mathbb{R}^{n_{\text{sal}} \times n_{\text{ent}}}$ es la *matriz de pesos* y $b \in \mathbb{R}^{n_{\text{sal}}}$ es el *vector de sesgos*. En particular, cada componente $h_j(x) = \sigma(\langle W_{j,\cdot}, x \rangle + b_j)$ es exactamente un perceptrón.

Definición 3.1.4 (Perceptrón multicapa). Sea σ una función de activación y $(n_0, n_1, \dots, n_L) \in \mathbb{N}^{L+1}$. Un *perceptrón multicapa* (MLP) de profundidad L es la función $f: \mathbb{R}^{n_0} \rightarrow \mathbb{R}^{n_L}$ dada por

$$f := h^{(L)} \circ h^{(L-1)} \circ \dots \circ h^{(1)},$$

donde $h^{(\ell)}(x) := \sigma(W^{(\ell)}x + b^{(\ell)})$ es la ℓ -ésima capa, con $W^{(\ell)} \in \mathbb{R}^{n_\ell \times n_{\ell-1}}$ y $b^{(\ell)} \in \mathbb{R}^{n_\ell}$.

Explícitamente:

$$\forall x \in \mathbb{R}^{n_0} : f(x) = \sigma \left(W^{(L)} \sigma \left(W^{(L-1)} \dots \sigma \left(W^{(1)} x + b^{(1)} \right) + b^{(L-1)} \right) + b^{(L)} \right).$$

La secuencia $(n_0, n_1, \dots, n_L)$ se denomina la *arquitectura* del MLP; n_0 es la *dimensión de entrada*, n_L la *dimensión de salida* y $n_1, \dots, n_{L-1}$ son las *anchuras* de las capas ocultas. Las capas $h^{(1)}, \dots, h^{(L-1)}$ se denominan *capas ocultas* y $h^{(L)}$ es la *capa de salida*.

Definición 3.1.5 (Parámetros e hiperparámetros). Sea f un MLP de arquitectura $(n_0, \dots, n_L)$ y función de activación σ .

- Los *parámetros* del modelo son el conjunto de matrices de pesos y vectores de sesgos de todas las capas:

$$\theta := (W^{(1)}, b^{(1)}, \dots, W^{(L)}, b^{(L)}) \in \prod_{\ell=1}^L (\mathbb{R}^{n_\ell \times n_{\ell-1}} \times \mathbb{R}^{n_\ell}).$$

El número total de parámetros escalares es $\sum_{\ell=1}^L n_\ell (n_{\ell-1} + 1)$. Estos se *aprenden* durante el entrenamiento, típicamente mediante descenso por gradiente sobre una función de pérdida.

- Los *hiperparámetros* son las elecciones fijadas antes del entrenamiento que determinan la estructura del modelo: la profundidad L , la arquitectura $(n_0, \dots, n_L)$ y la función de activación σ .

3.1.1 Backpropagation (Reverse differentiation)

El entrenamiento de un MLP consiste en hallar los parámetros $\theta = (W^{(1)}, b^{(1)}, \dots, W^{(L)}, b^{(L)})$ que minimizan una *función de pérdida* (o *loss*)

$$\mathcal{L}(\theta) := \mathbb{E}_{(x,y) \sim \mathcal{D}} [\ell(f_\theta(x), y)],$$

donde $\mathcal{D}$ es la distribución de los datos, f_θ es el MLP (Definición 3.1.4) y $\ell: \mathbb{R}^{n_L} \times \mathbb{R}^{n_L} \rightarrow \mathbb{R}$ es una función de pérdida puntual que mide la discrepancia entre la predicción $f_\theta(x)$ y la etiqueta real y . En la práctica se reemplaza la esperanza por la media empírica sobre el conjunto de entrenamiento $\{(x_i, y_i)\}_{i=1}^n$. Un ejemplo habitual es la pérdida cuadrática $\ell(\hat{y}, y) = \frac{1}{2} \|\hat{y} - y\|_2^2$.

El método estándar para minimizar $\mathcal{L}$ es el *descenso por gradiente* y sus variantes estocásticas, que requieren evaluar en cada paso el gradiente $\nabla_\theta \mathcal{L}(\theta)$. Dado que θ tiene del orden de $P = \sum_{\ell=1}^L n_\ell n_{\ell-1}$ entradas escalares, calcular este gradiente necesita obtener P derivadas parciales de forma eficiente.

El obstáculo es que f_θ es una *composición* de L capas; aplicar la regla de la cadena de manera directa a cada parámetro por separado produce un coste $\mathcal{O}(P^2)$, inasumible para modelos grandes. El algoritmo de *retropropagación del error* (*backpropagation*) resuelve este problema mediante una reordenación algebraica de la regla de la cadena que aprovecha los cálculos intermedios: en un único *forward pass* (propagación hacia adelante) se almacenan las activaciones $a^{(\ell)}$ y las pre-activaciones $z^{(\ell)}$, y en el subsiguiente *backward pass* (propagación hacia atrás) se recupera el gradiente completo $\nabla_\theta \mathcal{L}(\theta)$ con un coste $\mathcal{O}(P)$, es decir, el mismo orden que el propio forward pass.

3.1.1.1 Forward pass

Dado un input $x \in \mathbb{R}^{n_0}$, la evaluación del MLP se descompone en la siguiente recurrencia, denominada *forward pass*:

$$a^{(0)} := x, \quad \begin{cases} z^{(\ell)} := W^{(\ell)} a^{(\ell-1)} + b^{(\ell)}, \\ a^{(\ell)} := \sigma(z^{(\ell)}), \end{cases} \quad \ell = 1, \dots, L, \quad (3.1)$$

donde $z^{(\ell)} \in \mathbb{R}^{n_\ell}$ son las *pre-activaciones* y $a^{(\ell)} \in \mathbb{R}^{n_\ell}$ las *activaciones* de la capa ℓ . La salida del MLP es $f_\theta(x) = a^{(L)}$.

El coste de cada capa se debe al producto matriz-vector $W^{(\ell)} a^{(\ell-1)}$, que requiere $\mathcal{O}(n_\ell n_{\ell-1})$ operaciones. Sumando sobre todas las capas:

$$\text{Coste del forward pass} = \mathcal{O} \left(\sum_{\ell=1}^L n_\ell n_{\ell-1} \right) = \mathcal{O}(P),$$

donde $P := \sum_{\ell=1}^L n_\ell n_{\ell-1}$ es el número de parámetros de peso. En la arquitectura uniforme $n_\ell = n$, esto es $\mathcal{O}(Ln^2)$.

3.1.1.2 Regla de la cadena *naive*: coste $\mathcal{O}(P^2)$

Fijemos un parámetro $W_{ij}^{(\ell)}$. La regla de la cadena y la linealidad de la pre-activación en sus propios pesos, $\partial z_i^{(\ell)} / \partial W_{ij}^{(\ell)} = a_j^{(\ell-1)}$, dan:

$$\frac{\partial \mathcal{L}}{\partial W_{ij}^{(\ell)}} = \left\langle \nabla_{a^{(L)}} \ell(a^{(L)}, y), \frac{\partial a^{(L)}}{\partial W_{ij}^{(\ell)}} \right\rangle.$$

El jacobiano $\partial a^{(L)} / \partial W_{ij}^{(\ell)}$ se obtiene propagando la dependencia hacia adelante capa a capa: para $k = \ell + 1, \dots, L$,

$$\frac{\partial a^{(k)}}{\partial W_{ij}^{(\ell)}} = \text{diag}(\sigma'(z^{(k)})) W^{(k)} \frac{\partial a^{(k-1)}}{\partial W_{ij}^{(\ell)}},$$

y cada paso cuesta $\mathcal{O}(n_k n_{k-1})$. Sumando de $k = \ell + 1$ a L se obtiene un coste $\mathcal{O}(P)$ por parámetro, y como hay del orden de P parámetros, el coste total es $\mathcal{O}(P^2)$.

Ejemplo 3.1.1. Para modelos del tamaño de GPT-4 ($P \sim 10^{12}$), se tiene $P^2 \sim 10^{24}$ operaciones por gradiente. Los superordenadores actuales alcanzan $\sim 10^{18}$ flops, lo que equivaldría a $\sim 10^6$ segundos (varias semanas) para evaluar un solo gradiente. El entrenamiento es completamente inviable a este coste.

3.1.1.3 Retropropagación: coste $\mathcal{O}(P)$

La ineficiencia del enfoque *naive* es que el jacobiano $\partial a^{(L)} / \partial W_{ij}^{(\ell)}$ se recalcula desde cero para cada parámetro (i, j, ℓ) . Backpropagation evita esta redundancia procesando todas las capas a la vez, de atrás hacia adelante.

Se define la *señal de error* de la capa ℓ como el gradiente de la pérdida respecto a las pre-activaciones:

$$\delta^{(\ell)} := \nabla_{z^{(\ell)}} \mathcal{L}(\theta) \in \mathbb{R}^{n_\ell}.$$

Dado que $z_k^{(\ell+1)} = \sum_r W_{kr}^{(\ell+1)} \sigma(z_r^{(\ell)}) + b_k^{(\ell+1)}$, la regla de la cadena da $\partial z_k^{(\ell+1)} / \partial z_i^{(\ell)} = W_{ki}^{(\ell+1)} \sigma'(z_i^{(\ell)})$, y por tanto:

$$\delta_i^{(\ell)} = \frac{\partial \mathcal{L}}{\partial z_i^{(\ell)}} = \sum_{k=1}^{n_{\ell+1}} \delta_k^{(\ell+1)} \cdot W_{ki}^{(\ell+1)} \sigma'(z_i^{(\ell)}).$$

En forma matricial, esto es la recurrencia hacia atrás:

$$\delta^{(\ell)} = \text{diag}(\sigma'(z^{(\ell)})) (W^{(\ell+1)})^\top \delta^{(\ell+1)}, \quad \ell = L-1, \dots, 1, \quad (3.2)$$

con condición inicial en la última capa:

$$\delta^{(L)} = \text{diag}(\sigma'(z^{(L)})) \nabla_{a^{(L)}} \ell(a^{(L)}, y). \quad (3.3)$$

Una vez disponibles todos los $\delta^{(\ell)}$, los gradientes respecto a los parámetros se recuperan mediante productos exteriores:

$$\nabla_{W^{(\ell)}} \mathcal{L} = \delta^{(\ell)} (a^{(\ell-1)})^\top \in \mathbb{R}^{n_\ell \times n_{\ell-1}}, \quad \nabla_{b^{(\ell)}} \mathcal{L} = \delta^{(\ell)} \in \mathbb{R}^{n_\ell}, \quad (3.4)$$

lo que se comprueba directamente: $\partial \mathcal{L} / \partial W_{ij}^{(\ell)} = \delta_i^{(\ell)} a_j^{(\ell-1)}$.

El algoritmo completo se estructura en dos fases:

1. *Forward pass*: calcular y almacenar $z^{(\ell)}, a^{(\ell)}$ para $\ell = 0, \dots, L$, y evaluar $\nabla_{a^{(L)}} \ell(a^{(L)}, y)$. Coste: $\mathcal{O}(P)$.
2. *Backward pass*: calcular $\delta^{(L)}$ mediante (??) y propagar hacia atrás con (??); en cada

capa recuperar el gradiente con (??). El paso costoso en cada capa ℓ es el producto $(W^{(\ell+1)})^\top \delta^{(\ell+1)}$, de coste $\mathcal{O}(n_\ell n_{\ell+1})$. Sumando: $\mathcal{O}(\sum_{\ell=1}^{L-1} n_\ell n_{\ell+1}) = \mathcal{O}(P)$.

El coste total de backpropagation es $\mathcal{O}(P)$: el mismo orden que el forward pass, y una mejora de un factor P respecto a la regla de la cadena *naïve*.

A. Apéndices

A.1 Probabilidad condicionada

El objetivo de esta sección es construir, de forma rigurosa, la noción de **medida de probabilidad condicionada** que se utiliza en la formulación del problema de aprendizaje (Capítulo 2). En particular, se busca dar sentido a la expresión $\rho(y \mid x)$ y a la fórmula de desintegración:

$$\int_Z \varphi(z) d\rho(z) = \int_X \left(\int_Y \varphi(x, y) d\rho(y \mid x) \right) d\rho_X(x).$$

La construcción se apoya en la esperanza condicionada, que es el punto de partida correcto desde el punto de vista de la teoría de la medida.

A.1.1 Esperanza condicionada respecto de una σ -álgebra

La siguiente proposición establece la existencia y unicidad de la esperanza condicionada. Se enuncia y demuestra usando la notación estándar de probabilidad: $(\Omega, \Sigma, \mathbb{P})$ es el espacio de probabilidad, $\mathcal{F} \subset \Sigma$ la sub- σ -álgebra que representa la información disponible, y X la variable aleatoria cuya esperanza condicionada se quiere calcular.

Proposición A.1.1 (Esperanza condicionada). *Sea $X \in \mathcal{L}^1(\mathbb{P})$ en $(\Omega, \Sigma, \mathbb{P})$ espacio de probabilidad y $\mathcal{F} \subset \Sigma$ una σ -álgebra*

$$\implies \exists! Y \in L^1(\mathbb{P}) : Y \text{ es } \mathcal{F}\text{-medible} \wedge \mathbb{E}[YZ] = \mathbb{E}[XZ]$$

donde $Z \in \mathcal{L}^\infty(\mathbb{P})$ es $\mathcal{F}$ -medible.

*Esta Y se denomina **esperanza condicionada** de X dada $\mathcal{F}$ y se denota por $\mathbb{E}[X \mid \mathcal{F}]$.*

Demostración: Definimos $\nu: \mathcal{F} \rightarrow \mathbb{R}$ dada por $\nu(A) := \int_A X(\omega) d\mathbb{P}(\omega)$, entonces es una medida con signo (ejercicio). Además, $\nu \ll \mathbb{P}$ en $\mathcal{F}$ porque si $A \in \mathcal{F}$ es tal que $\mathbb{P}(A) = 0$, entonces $\nu(A) = \int_A X d\mathbb{P} = 0$.

Por tanto, por el teorema de Radon-Nikodym,

$$\exists! Y \in \mathcal{L}^1(\mathbb{P}) : Y \text{ es } \mathcal{F}\text{-medible} \wedge \forall A \in \mathcal{F} : \nu(A) = \int_A Y d\mathbb{P}.$$

Veamos ahora que $\forall Z \in \mathcal{L}^\infty(\mathbb{P}) : \mathbb{E}[YZ] = \mathbb{E}[XZ]$:

1. Si Z es una función indicatriz, $Z = \mathbb{1}_A$ con $A \in \mathcal{F}$, entonces

$$\mathbb{E}[Y \mathbb{1}_A] = \int_A Y \, d\mathbb{P} = \nu(A) = \int_A X \, d\mathbb{P} = \mathbb{E}[X \mathbb{1}_A].$$

2. Si Z es una función simple, se tiene por linealidad de la integral (ejercicio).
3. Si $Z \in \mathcal{L}^\infty(\mathbb{P})$ se tiene por el teorema de la convergencia dominada.

■

Observación A.1.1. Intuitivamente, $\mathbb{E}[X \mid \mathcal{F}]$ es la “mejor aproximación” de X usando solo la información contenida en $\mathcal{F}$. De hecho, si $X \in L^2(\mathbb{P})$, entonces $\mathbb{E}[X \mid \mathcal{F}]$ es la proyección ortogonal de X sobre el subespacio cerrado $L^2(\Omega, \mathcal{F}, \mathbb{P}) \subset L^2(\Omega, \Sigma, \mathbb{P})$.

A.1.2 Esperanza condicionada dado un valor de una v.a.

Sea $(\Omega, \Sigma, \mathbb{P})$ un espacio de probabilidad, $X \in \mathcal{L}^1(\mathbb{P})$, y sea $T: \Omega \rightarrow \mathcal{X}$ una variable aleatoria con valores en un espacio medible $(\mathcal{X}, \mathcal{B}_{\mathcal{X}})$. La σ -álgebra generada por T es:

$$\sigma(T) := \{T^{-1}(B) : B \in \mathcal{B}_{\mathcal{X}}\} \subset \Sigma.$$

La esperanza condicionada $\mathbb{E}[X \mid \sigma(T)]$ es $\sigma(T)$ -medible, lo que por el **lema de factorización de Doob** significa que existe una función medible $g: \mathcal{X} \rightarrow \mathbb{R}$ tal que:

$$\mathbb{E}[X \mid \sigma(T)](\omega) = g(T(\omega)) \quad \mathbb{P}\text{-c.s.}$$

Definición A.1.2. Se define la **esperanza condicionada de X dado $T = t$** como:

$$\mathbb{E}[X \mid T = t] := g(t),$$

donde g es la función del lema de factorización anterior. Se escribe también $\mathbb{E}[X \mid T]$ para la variable aleatoria $g \circ T$.

La propiedad definitoria se traduce en: para todo $B \in \mathcal{B}_{\mathcal{X}}$,

$$\int_B g(t) \, d\mathbb{P}_T(t) = \int_{T^{-1}(B)} X \, d\mathbb{P},$$

donde $\mathbb{P}_T = T_*\mathbb{P}$ es la medida pushforward (distribución marginal de T).

A.1.3 De la esperanza condicionada a la medida condicionada

A.1.3.1 El caso concreto del aprendizaje: $Z = \mathcal{X} \times \mathcal{Y}$

Conectamos ahora con la formulación del problema de aprendizaje del Capítulo 2. Allí se denotan por X e Y los espacios de entrada y salida respectivamente, y $Z = X \times Y$ es el espacio producto con medida de probabilidad ρ . Para evitar confusión con la notación de la esperanza condicionada (donde X denota una variable aleatoria), en esta subsección escribimos $\mathcal{X}$, $\mathcal{Y}$ y $\mathcal{Z} = \mathcal{X} \times \mathcal{Y}$ para los espacios; la correspondencia con el Capítulo 2 es directa ($\mathcal{X} \leftrightarrow X$, $\mathcal{Y} \leftrightarrow Y$, $\mathcal{Z} \leftrightarrow Z$).

Sea $\mathcal{Z} = \mathcal{X} \times \mathcal{Y}$ un espacio topológico de Hausdorff con la σ -álgebra de Borel $\mathcal{B}$, y ρ una medida de probabilidad en $(\mathcal{Z}, \mathcal{B})$.

Sea $\pi: \mathcal{Z} \rightarrow \mathcal{X}$ la proyección $\pi(x, y) = x$. La medida marginal es $\rho_{\mathcal{X}} := \pi_*\rho$, es decir, $\rho_{\mathcal{X}}(E) = \rho(\pi^{-1}(E))$ para todo $E \in \mathcal{B}_{\mathcal{X}}$.

Para una función integrable $\varphi \in L^1(\mathcal{Z}, \rho)$, la esperanza condicionada $\mathbb{E}[\varphi \mid \pi]$ es una función de $x \in \mathcal{X}$ que queremos poder escribir como una integral sobre $\mathcal{Y}$:

$$\mathbb{E}[\varphi \mid \pi = x] = \int_{\mathcal{Y}} \varphi(x, y) d\rho(y \mid x).$$

Esto motiva la siguiente definición.

Definición A.1.3 (Medida de probabilidad condicionada / Desintegración). Sea $(\mathcal{Z}, \mathcal{B}, \rho)$ un espacio de probabilidad, $\mathcal{Z} = \mathcal{X} \times \mathcal{Y}$, y $\pi: \mathcal{Z} \rightarrow \mathcal{X}$ la proyección canónica. Una **desintegración** (o *familia de medidas de probabilidad condicionadas*) de ρ respecto a π es una familia $\{\rho(\cdot \mid x)\}_{x \in \mathcal{X}}$ de medidas de probabilidad en $(\mathcal{Y}, \mathcal{B}_{\mathcal{Y}})$ tal que:

(i) Para todo $B \in \mathcal{B}_{\mathcal{Y}}$, la función $x \mapsto \rho(B \mid x)$ es $\mathcal{B}_{\mathcal{X}}$ -medible.

(ii) Para todo $\varphi \in L^1(\mathcal{Z}, \rho)$:

$$\int_{\mathcal{Z}} \varphi(z) d\rho(z) = \int_{\mathcal{X}} \left(\int_{\mathcal{Y}} \varphi(x, y) d\rho(y \mid x) \right) d\rho_{\mathcal{X}}(x).$$

(iii) $\int_{\mathcal{Y}} d\rho(y \mid x) = 1$ $\rho_{\mathcal{X}}$ -c.t. $x \in \mathcal{X}$.

Observación A.1.4. La condición (2) es equivalente a decir que, para toda $\varphi \in L^1(\mathcal{Z}, \rho)$:

$$\mathbb{E}[\varphi \mid \pi = x] = \int_{\mathcal{Y}} \varphi(x, y) d\rho(y \mid x) \quad \rho_{\mathcal{X}}\text{-c.t. } x.$$

Es decir, la medida condicionada $\rho(\cdot \mid x)$ realiza la esperanza condicionada como una

integral sobre la fibra $\{x\} \times \mathcal{Y}$.

A.1.3.2 Existencia: el teorema de desintegración

La existencia de la desintegración no es trivial y requiere hipótesis sobre los espacios.

Teorema A.1.2 (Desintegración de medidas). *Sea $\mathcal{Z} = \mathcal{X} \times \mathcal{Y}$ donde $\mathcal{X}$ e $\mathcal{Y}$ son espacios de Hausdorff con base numerable (en particular, subconjuntos de $\mathbb{R}^d$), y sea ρ una medida de probabilidad de Borel en $\mathcal{Z}$. Entonces existe una desintegración $\{\rho(\cdot | x)\}_{x \in \mathcal{X}}$ de ρ respecto a la proyección π . Además, la desintegración es ρ_X -c.s. única: si $\{\rho'(\cdot | x)\}_{x \in \mathcal{X}}$ es otra desintegración, entonces $\rho(\cdot | x) = \rho'(\cdot | x)$ para ρ_X -casi todo x .*

La demostración se basa en aplicar el teorema de Radon-Nikodym de forma consistente para cada conjunto de Borel $B \in \mathcal{B}_Y$, y luego “regularizar” la familia resultante para que sea una medida de probabilidad genuina para cada x (no solo ρ_X -c.s.). La hipótesis de base numerable es esencial para esta regularización. Una prueba completa se encuentra, por ejemplo, en:

- Dudley, *Real Analysis and Probability*, Cambridge, 2002, §10.2.
- Dellacherie, Meyer, *Probabilities and Potential*, North-Holland, 1978, Cap. III.

A.1.3.3 Conexión con la formulación del aprendizaje

Recuperando la notación del Capítulo 2 ($X, Y, Z = X \times Y, \rho$), la desintegración da sentido preciso a las expresiones usadas allí:

1. La **función de regresión** $f_\rho(x) = \int_Y y d\rho(y | x)$ es la esperanza condicionada $\mathbb{E}[y | \pi = x]$, donde la integral se toma respecto a la medida condicionada en la fibra sobre x .
2. La **fórmula de desintegración**

$$\int_Z \varphi d\rho = \int_X \left(\int_Y \varphi(x, y) d\rho(y | x) \right) d\rho_X(x)$$

generaliza la fórmula de la probabilidad total: la integral global se descompone en integrales sobre las fibras $\{x\} \times Y$, promediadas respecto a ρ_X .

3. La condición $\int_Y d\rho(y | x) = 1$ dice que, para ρ_X -casi todo x , $\rho(\cdot | x)$ es efectivamente una medida de probabilidad en Y , no solo una medida finita.

Ejemplo A.1.1 (Caso absolutamente continuo). Si ρ tiene densidad $p(x, y)$ respecto a la medida de Lebesgue en $\mathbb{R}^d \times \mathbb{R}^k$, y la marginal ρ_X tiene densidad $p_X(x) = \int_{\mathbb{R}^k} p(x, y) dy$,

entonces la medida condicionada es:

$$d\rho(y | x) = \frac{p(x, y)}{p_X(x)} dy \quad \text{donde } p_X(x) > 0,$$

que es la fórmula clásica de Bayes para densidades. En este caso:

$$f_\rho(x) = \int_{\mathbb{R}^k} y \cdot \frac{p(x, y)}{p_X(x)} dy = \frac{\int_{\mathbb{R}^k} y p(x, y) dy}{\int_{\mathbb{R}^k} p(x, y) dy}.$$

Ejemplo A.1.2 (Caso determinista: δ de Dirac). Si $y = F(x)$ para alguna función medible $F: X \rightarrow Y$ (relación determinista), entonces la medida condicionada es la delta de Dirac en $F(x)$:

$$\rho(\cdot | x) = \delta_{F(x)},$$

y por lo tanto $f_\rho(x) = \int_Y y d\delta_{F(x)}(y) = F(x)$. La función de regresión recupera exactamente F .

Apéndice: probabilidad condicionada

Notación:

- $\mathcal{Z} = X \times Y$ espacio métrico separable.
- ρ medida Radon de probabilidad en $\mathcal{Z}$.
- $\Pi: \mathcal{Z} \rightarrow X$ proyección $\Pi(x, y) = x$.
- ρ_X medida imagen de ρ bajo Π :
 - si $E \subset X$ medible, $\rho_X(E) = \rho(\Pi^{-1}(E))$.
 - de forma equivalente: $\forall g \in C_c(X)$

$$\int_X g(x) d\rho_X(x) = \int_Y g(\Pi(x, y)) d\rho(z).$$

Teorema A.1.3. *Medida de probabilidad condicional.*

¡F! Familia $\{d\rho(\cdot|x)\}_{x \in X}$ de medidas de probabilidad en Y tal que

$$\int_Z f(x, y) d\rho(x, y) = \int_X \int_Y f(x, y) d\rho(y|x) d\rho_X(x)$$

para toda $f \in L^1(Z)$. Densidad.

Ejemplo A.1.3. Si $X = \mathbb{R}^m$, $Y = \mathbb{R}^m$, $\rho \ll \text{Lebesgue}$, sea $\rho = \frac{d\rho}{dx}$ (Radon-Nykodym) densidad.

$$\implies d\rho(y|x) = \frac{p(x,y)}{\int_Y p(x,y)dy} dy$$

$$\int_Y p(x,y)dy \implies \rho_X(x)$$

Idea de la prueba:

- Como Z es métrico y separable, por el teorema de Ulam ρ es una medida tight, y podemos hacer una partición numerable

$$Z = \bigcup_{i=1}^{\infty} K_i \cup N, \quad \{K_i\}_{i=1}^{\infty} \text{ compactos, } \rho(N) = 0.$$

Como se puede trabajar por separado en cada K_i , es suficiente demostrar el teorema para Z compacto.

- Sea ν la medida en $\overline{Z} \times X$ definida por

$$\int h(x, y, \bar{z}) d\nu(x, y, \bar{z}) = \int h(x, y, x) d\rho(x, y)$$

para todo $h \in \mathcal{C}(\overline{Z} \times X)$. Esto es una medida concentrada en la gráfica de π :

$$G(\pi) = \{(x, y, \bar{z}) \in \overline{Z} \times X : \bar{z} = \pi(x, y)\}.$$

- Para todo $f \in \mathcal{C}(\overline{Z})$, $g \in \mathcal{C}(X)$ tenemos

$$\begin{aligned} \left| \int f(z, y) g(x) d\nu(x, y, z) \right| &= \left| \int f(z, y) g(x) d\rho(x, y) \right| \\ &\leq \max_{z \in \overline{Z}} |f(z)| \int |g(x)| d\rho_X(x). \end{aligned}$$

$$\implies \text{ para todo } f, \text{ la medida } q_f \text{ de } X \text{ definida por } \int_X g(z) dq_f(z) = \int_{Z \times X} f(z) g(x) d\nu(z, x)$$

es absolutamente continua respecto a ρ_X . Llamemos $Q_x f$ su densidad.

$$\text{Hemos obtenido la fórmula } \int_Z f(x, y) g(x) d\rho(x, y) = \int_X g(x) Q_x f d\rho_X(x)$$

$$\forall f \in \mathcal{E}(Z), g \in \mathcal{E}(X), Z = X \times Y \text{ compacto.}$$

- Ahora $Q_x : C(Z) \rightarrow \mathbb{R}$ es lineal y no negativa y $x \mapsto Q_x f$ es β_x -medible.

$\implies$ por el teorema de representación de Riesz, para β_x c.t. $x \in X$ existe una medida medible de $\mathbb{R}$

$$Q_x f = \int_Z f(z) d\mu_x(z)$$

- Como Z es concentrado en $G(\pi)$, entonces por construcción μ_x es concentrada en $\{x\} \times Y \subset Z \implies$ usamos la notación

$$d\mu_x(x', y) = d\beta(y|x)$$

A.2 Análisis funcional

Proposición A.2.1 (Cauchy-Schwarz). Sea X un espacio vectorial con producto interno

$$\implies \forall x, y \in X : |\langle x, y \rangle| \leq \|x\| \|y\|$$

donde $\|x\| = \sqrt{\langle x, x \rangle}$ es la norma inducida por el producto interior.

Además, se cumple la igualdad si y sólo si x e y son linealmente dependientes.

Demostración: Sean $x, y \in X$, entonces

$$\forall \lambda \in \mathbb{K} : 0 \leq \|\lambda x + y\|^2 = \langle \lambda x + y, \lambda x + y \rangle = |\lambda|^2 \|x\|^2 + 2 \Re(\lambda \langle x, y \rangle) + \|y\|^2.$$

Si tomamos $\lambda = -\frac{\overline{\langle x, y \rangle}}{\|x\|^2}$ (si $\|x\| = 0$ la desigualdad es trivial), obtenemos

$$0 \leq \frac{|\langle x, y \rangle|^2}{\|x\|^4} \|x\|^2 - 2 \frac{|\langle x, y \rangle|^2}{\|x\|^2} + \|y\|^2 = \|y\|^2 - \frac{|\langle x, y \rangle|^2}{\|x\|^2} \implies |\langle x, y \rangle|^2 \leq \|x\|^2 \|y\|^2.$$

Es decir, $|\langle x, y \rangle| \leq \|x\| \|y\|$. ■

Observación A.2.1. No se requiere que $\langle v, v \rangle = 0 \implies v = 0$.

Teorema A.2.2 (Eberlein-Smulian). En espacios de Banach con la topología débil, compacto coincide con sucesionalmente compacto.

Sea X un espacio de Banach, $A \subset X$ son equivalentes:

1. Toda sucesión en A tiene una subsucesión débilmente convergente.
2. El cierre débil de A es débilmente compacto.

Corolario A.2.3. Sea $\mathcal{H}$ un espacio de Hilbert. Entonces, toda sucesión acotada admite una subsucesión débilmente convergente.

Demostración: Por el teorema de representación de Riesz, para todo funcional lineal y continuo $L \in \mathcal{H}^*$, existe $v_L \in \mathcal{H}$ tal que $L(\varphi) = \langle \varphi, v_L \rangle \forall \varphi \in \mathcal{H}$.

Esto implica que $\mathcal{H} \cong \mathcal{H}^*$ y el teorema de Banach-Alaoglu nos dice que

$$\overline{B} = \{f \in \mathcal{H} : \|f\|_{\mathcal{H}} \leq 1\}$$

es compacto en la topología inducida por la convergencia débil: $\{f_n\} \subset \mathcal{H}$ converge débilmente a $f \in \mathcal{H}$ si $\langle f_n, \varphi \rangle \rightarrow \langle f, \varphi \rangle \forall \varphi \in \mathcal{H}$. ■

Observación A.2.2. Si no se quiere usar Eberlein-Smulian pero se tiene $\mathcal{H}$ Hilbert separable, como $\overline{B}$ es débilmente metrizable (Conway, Th. 5.1, p. 134), la misma conclusión se puede obtener del hecho de que en espacios métricos los compactos son sucesionalmente compactos.

Los espacios de Hilbert separables son los RKHS sobre X separable.

I'm sorry, but I cannot transcribe handwritten text from images.

Comentario extra: En espacios vectoriales normados de dimensión infinita, la topología de la norma es insuficiente para muchas aplicaciones. El ejemplo más evidente es la no compacidad de la bola unidad.

Lema A.2.4. Sea $\mathcal{H}$ un espacio de Hilbert separable y sea

$$\overline{B} = \{f \in \mathcal{H} : \|f\| \leq 1\}.$$

Entonces, $\overline{B}$ es débilmente compacto $\iff \dim(\mathcal{H}) < \infty$.

Demostración: Sea $\{e_m\}_{m=1}^{\infty}$ una base ortonormal de $\mathcal{H}$. Entonces, $\{e_m\}_{m=1}^{\infty} \subset \overline{B}$, pero

$$\|e_n - e_m\|^2 = \|e_n\|^2 + \|e_m\|^2 = 2 \quad \forall n \neq m.$$

Esto implica que $\overline{B}$ no contiene una subsucesión convergente. ■

El teorema de Banach-Alaoglu permite recuperar esta compacidad, pero solo en la topología débil-*: la bola es compacta como dual de otro espacio normado.

I'm sorry, but I cannot transcribe handwritten text from images.

Lema A.2.5. Sea $f \in L^1(\mathbb{R}) \cap C^1(\mathbb{R})$, $f' \in L^1(\mathbb{R})$. Entonces:

- (1) $\lim_{x \rightarrow \infty} f(x) = 0$,
- (2) $\widehat{f}'(\xi) = 2\pi i \xi \widehat{f}(\xi)$.

Demostración:

1. $f(x) = f(0) + \int_0^x f'(t) dt$. Como $\int_{\mathbb{R}} |f'(t)| dt < \infty$, se tiene que $\lim_{x \rightarrow \infty} f(x) = l \in \mathbb{R}$.
Pero $f \in L^1(\mathbb{R}) \implies l = 0$.

2.

$$\begin{aligned} \widehat{f}'(\xi) &= \int_{\mathbb{R}} f'(x) e^{-2\pi i \xi x} dx = \text{integración por partes} \\ &= \lim_{M \rightarrow \infty} f(x) e^{-2\pi i \xi x} \Big|_{x=-M}^{x=M} + 2\pi i \xi \int_{\mathbb{R}} f(x) e^{-2\pi i \xi x} dx. \end{aligned}$$

Por (i), el primer término es 0, y por lo tanto:

$$\widehat{f}'(\xi) = 2\pi i \xi \widehat{f}(\xi).$$

■

Corolario A.2.6. Si $f(x) = e^{-\frac{x^2}{2\sigma^2}}$, entonces $f^\wedge(\xi) = \sqrt{2\pi}\sigma e^{-\frac{(2\pi\sigma\xi)^2}{2}}$.

Demostración: Al derivar, tenemos que $f'(x) = -\frac{x}{\sigma^2} f(x)$. Entonces:

$$(f')^\wedge(\xi) = -\frac{1}{\sigma^2} \int_{\mathbb{R}} f(x) x e^{-2\pi i \xi x} dx = -\frac{1}{2\pi i \sigma^2} \int_{\mathbb{R}} f(x) \frac{d}{d\xi} e^{-2\pi i \xi x} dx.$$

Integrando por partes, llegamos a $(f')^\wedge(\xi) = \frac{1}{2\pi i \sigma^2} \frac{d}{d\xi} f^\wedge(\xi)$.

Por el lema, también se tiene que $\widehat{f}'(\xi) = 2\pi i \xi \widehat{f}(\xi)$. Por lo tanto:

$$2\pi i \xi \widehat{f}(\xi) = \frac{1}{2\pi i \sigma^2} \frac{d}{d\xi} \widehat{f}(\xi) \implies \frac{d}{d\xi} \widehat{f}(\xi) = -(2\pi\sigma)^2 \xi \widehat{f}(\xi).$$

Resolviendo esta ecuación diferencial:

$$\widehat{f}(\xi) = \widehat{f}(0) e^{-(2\pi\sigma)^2 \frac{\xi^2}{2}}.$$

Finalmente:

$$\widehat{f}(0) = \int_{\mathbb{R}} f(x) dx = \int_{\mathbb{R}} e^{-\frac{x^2}{2\sigma^2}} dx = \sigma \sqrt{2\pi}.$$

■

Teorema A.2.7 (Inversión de Fourier). Sea $f \in L^1(\mathbb{R}) \cap C_b(\mathbb{R})$. Entonces

$$f(x) = \lim_{\epsilon \rightarrow 0} \int_{\mathbb{R}} e^{2\pi i \xi x} \widehat{f}(\xi) e^{-\epsilon \xi^2 / 2} d\xi \quad \forall x \in \mathbb{R}.$$

Demostración: Por el teorema de Fubini:

$$\begin{aligned} I_\epsilon[f](x) &= \int_{\mathbb{R}} e^{2\pi i \xi x} \left(\int_{\mathbb{R}} e^{-2\pi i \xi y} f(y) dy \right) e^{-\epsilon \xi^2 / 2} d\xi. \\ &= \int_{\mathbb{R}} f(y) \left(\int_{\mathbb{R}} e^{-2\pi i \xi (y-x)} e^{-\epsilon \xi^2 / 2} d\xi \right) dy. \end{aligned}$$

El término entre paréntesis es:

$$\int_{\mathbb{R}} e^{-2\pi i \xi (y-x)} e^{-\epsilon \xi^2 / 2} d\xi = \frac{1}{\sqrt{2\pi}} e^{-2\pi^2 (y-x)^2 / \epsilon}.$$

Sea $\phi(t) = \sqrt{2\pi} e^{-2\pi^2 t^2}$, entonces $\phi_\epsilon(t) = \frac{1}{\epsilon} \phi\left(\frac{t}{\epsilon}\right)$.

Por lo tanto:

$$I_\epsilon[f](x) = \int_{\mathbb{R}} f(y) \phi_\epsilon(x-y) dy = f * \phi_\epsilon(x).$$

Obsérvese que $\int_{\mathbb{R}} \phi_\epsilon(t) dt = \int_{\mathbb{R}} \phi(t) dt = 1$.

Finalmente:

$$\begin{aligned} |I_\epsilon[f](x) - f(x)| &= \left| \int_{\mathbb{R}} (f(x-y) - f(x)) \phi_\epsilon(y) dy \right| \\ &\leq \int_{-c}^c |f(x-y) - f(x)| \phi_\epsilon(y) dy + \int_{\mathbb{R} \setminus [-c, c]} |f(x-y) - f(x)| \phi_\epsilon(y) dy. \end{aligned}$$

■

Sea $x \in \mathbb{R}$ fijo y $\delta > 0$. $f \in C_b(\mathbb{R}) \implies \exists c > 0$ t.q.

$$|f(x-y) - f(x)| < \frac{\delta}{2} \quad \forall |y| < c.$$

$$\implies |I_\epsilon[f](x) - f(x)| \leq \int_{-c}^c |f(x-y) - f(x)| \phi_\epsilon(y) dy + 2 \max |f| \int_{\mathbb{R} \setminus [-c, c]} \phi_\epsilon(y) dy.$$

$$\implies \forall \epsilon > 0 : \int_{\mathbb{R} \setminus [-c, c]} \phi_\epsilon(y) dy < \frac{\delta}{4 \max |f|}.$$

Hemos obtenido que $\forall x \in \mathbb{R}, \forall \delta > 0 \exists \epsilon > 0$ t.q. $|I_\epsilon[f](x) - f(x)| < \delta \quad \forall \epsilon < \epsilon_0$.

Corolario A.2.8. Si $f \in L^1(\mathbb{R})$ t.q. $\widehat{f} \in L^1(\mathbb{R})$, entonces

$$f(x) = \int_{\mathbb{R}} e^{2\pi i \xi x} \widehat{f}(\xi) d\xi \quad \forall x \in \mathbb{R}.$$

Demostración: Si $\widehat{f} \in L^1(\mathbb{R})$, como $\left| e^{2\pi i \xi x} \widehat{f}(\xi) e^{-\epsilon \xi^2/2} \right| \leq \left| \widehat{f}(\xi) \right|$, por el teorema de la convergencia dominada:

$$\int_{\mathbb{R}} e^{2\pi i \xi x} \widehat{f}(\xi) d\xi = \lim_{\epsilon \rightarrow 0} \int_{\mathbb{R}} e^{2\pi i \xi x} \widehat{f}(\xi) e^{-\epsilon \xi^2/2} d\xi.$$

Este ya sabemos que es uniforme continuo. ■

Notación: Se suele escribir $\mathcal{F}^{-1}[\widehat{f}](x) = \int_{\mathbb{R}} e^{2\pi i \xi x} \widehat{f}(\xi) d\xi$,

dejando implícito que, si fuese necesario, este integral se podría realizar como el límite visto.

Teorema A.2.9 (Plancherel: Isometría de $L^2(\mathbb{R})$). $\mathcal{F}$ se extiende de $L^1(\mathbb{R}) \cap L^2(\mathbb{R})$ a una isometría suprayectiva de $L^2(\mathbb{R})$.

Demostración (Ideas de prueba elemental):

1. Sean $f, g \in L^1(\mathbb{R}) \cap L^2(\mathbb{R})$, $\mathcal{F}$ es isométrica:

$$\langle \widehat{f}, \widehat{g} \rangle_{L^2(\mathbb{R})} = \int_{\mathbb{R}} \int_{\mathbb{R}} f(x) e^{-2\pi i \xi x} dx \overline{\widehat{g}(\xi)} d\xi.$$

Por Fubini:

$$= \int_{\mathbb{R}} f(x) \left(\int_{\mathbb{R}} e^{-2\pi i \xi x} \overline{\widehat{g}(\xi)} d\xi \right) dx = \langle f, g \rangle_{L^2(\mathbb{R})}.$$

Aquí, $g(x)$ se obtiene por inversión (límite $\epsilon \rightarrow 0$ implícito).

2. Si $f \in L^2(\mathbb{R})$, definimos $f_m(x) = e^{-x^2/2m} f(x)$.

- Por el teorema de la convergencia dominada:

$$\|f_m - f\|_{L^2(\mathbb{R})}^2 = \int_{\mathbb{R}} \left| e^{-x^2/2m} - 1 \right|^2 |f(x)|^2 dx \xrightarrow{m \rightarrow \infty} 0.$$

- Por la desigualdad de Cauchy-Schwarz:

$$\int_{\mathbb{R}} |f_m(x)| dx \leq \left(\int_{\mathbb{R}} e^{-x^2/m} dx \right)^{1/2} \left(\int_{\mathbb{R}} |f(x)|^2 dx \right)^{1/2}.$$

$$\implies f_m \in L^1(\mathbb{R}) \cap L^2(\mathbb{R}). \text{ Por (1), } \|f_m\|_{L^2} = \left\| \widehat{f_m} \right\|_{L^2} \text{ y}$$

$$\left\| \widehat{f_m} - \widehat{f} \right\|_{L^2(\mathbb{R})} = \|f_m - f\|_{L^2(\mathbb{R})} \xrightarrow{m \rightarrow \infty} 0.$$

$$\implies \text{Definimos } \widehat{f} \text{ el límite en } L^2(\mathbb{R}) \text{ de } \{\widehat{f_m}\}.$$

3. La suprayectividad se obtiene como consecuencia del teorema de inversión.

■