
MATEMÁTICAS PARA EL APRENDIZAJE AUTOMÁTICO

Cuarto del Grado en Matemáticas

Hugo Marquerie

Profesor: Davide Barbieri

Facultad de Ciencias - Universidad Autónoma de Madrid

Segundo cuatrimestre

fecha

Puedes encontrar mi colección completa de apuntes en <https://hmarquer.github.io>.

Índice

1	Aprendizaje no supervisado	iii
1.1	Principal component analysis (PCA)	iii
1.1.1	Planteamiento del problema	iii
1.1.2	Solución (teorema y algoritmo)	iii
1.2	<i>Clustering</i> espectral en grafos	iv
2	Aprendizaje supervisado	vii
2.1	Learning Theory	vii
2.1.1	Sobre el objetivo y el aprendizaje estadístico	vii

1. Aprendizaje no supervisado

1.1 Principal component analysis (PCA)

1.1.1 Planteamiento del problema

Sean $\{x_i\}_{i=1}^m \subset \mathbb{C}^n$ un conjunto de datos y sea $k < m$. El objetivo de PCA es encontrar la proyección de $\mathbb{C}^n$ de rango k (proyección sobre un subespacio $M \subset \mathbb{C}^n$ de dimensión k) que minimice el error cuadrático entre los datos originales y los datos proyectados:

$$\mathcal{E} = \sum_{i=1}^m \|x_i - \mathbb{P}_M x_i\|^2,$$

donde $\mathbb{P}_M$ es la proyección ortogonal sobre M . El PCA nos permite:

- Aproximar un conjunto de datos por un subespacio de dimensión menor.
- Una base ortonormal del subespacio M proporciona un diccionario “óptimo” para representar linealmente los datos.

1.1.2 Solución (teorema y algoritmo)

Sea $A = \begin{pmatrix} | & | & \cdots & | \\ x_1 & x_2 & \cdots & x_m \\ | & | & \cdots & | \end{pmatrix} \in \mathbb{C}^{n \times m}$ y sea $A = U\Sigma V^*$ su descomposición en valores singulares (SVD). Es decir, $U \in \mathbb{C}^{n \times n}$ y $V \in \mathbb{C}^{m \times m}$ son matrices unitarias y $\Sigma \in \mathbb{R}_+^{n \times m}$ es una matriz diagonal con los valores singulares $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$ en la diagonal, donde $r = \text{rang}(A)$.

Entonces, $M := \text{span}\{U^{(1)}, \dots, U^{(k)}\}$, donde $U^{(i)}$ es la i -ésima columna de U , es el subespacio que minimiza el error cuadrático $\mathcal{E}$. En consecuencia, la proyección ortogonal de los datos sobre M viene dada por

$$\forall x \in \mathbb{C}^n : \mathbb{P}_M x = \sum_{i=1}^k \langle x, U^{(i)} \rangle U^{(i)}.$$

Teorema 1.1.1. Sea $A \in \mathbb{C}^{n \times m}$, $A = U\Sigma V^*$ su SVD y $k \leq \text{rang}(A)$. Definimos

$$A_k = \sum_{i=1}^k \sigma_i U^{(i)} \otimes V^{(i)} \quad \text{donde} \quad (v \otimes w)_{ij} = v_i \overline{w_j}.$$

$$\implies \forall B \in \mathbb{C}^{n \times m} : \text{rang}(B) = k : \|A - B\|_{Fro}^2 \geq \|A - A_k\|_{Fro}^2 = \sum_{i=k+1}^{\text{rang } A} \sigma_i^2.$$

¿Por qué nos vale esto? La i -ésima columnas de A_k es $A_k^{(i)} = \sum_{\ell=1}^k \sigma_\ell \overline{V_{i\ell}} U^{(\ell)}$ donde $U^{(\ell)}$ es la ℓ -ésima columna de U y $\sigma_\ell \overline{V_{i\ell}} = \langle A^{(i)}, U^{(\ell)} \rangle = \langle x_i, U^{(\ell)} \rangle$. Entonces,

$$A_k^{(i)} = \sum_{\ell=1}^k \langle x_i, U^{(\ell)} \rangle U^{(\ell)} = \mathbb{P}_{\text{span}\{U^{(1)}, \dots, U^{(k)}\}} x_i = \mathbb{P}_M x_i.$$

Demostración: Dividimos la demostración en diferentes pasos:

Paso 1. Recordamos que la norma de Frobenius se puede escribir como $\|A\|_{\text{Fro}}^2 = \text{tr}(A^* A)$.

Por tanto,

$$\begin{aligned} \|A - A_k\|_{\text{Fro}}^2 &= \|U\Sigma V^* - U\Sigma_k V^*\|_{\text{Fro}}^2 = \|U(\Sigma - \Sigma_k)V^*\|_{\text{Fro}}^2 \\ &= \text{tr}(V(\Sigma - \Sigma_k)^* V^*) = \sum_{\ell=k+1}^{\text{rang } A} \sigma_\ell^2, \end{aligned}$$

puesto que $\Sigma - \Sigma_k$ es una matriz diagonal con los ceros en los primeros k elementos de la diagonal y los valores singulares $\sigma_{k+1}, \dots, \sigma_r$ en el resto.

Por tanto, basta demostrar que $\forall B \in \mathbb{C}^{n \times m} : \text{rang}(B) = k : \|A - B\|_{\text{Fro}}^2 \geq \sum_{\ell=k+1}^{\text{rang } A} \sigma_\ell^2$.

Paso 2. Sea $B \in \mathbb{C}^{n \times m}$ con $\text{rang}(B) = k$. Sea $B = XTY^*$ su SVD, con $X \in \mathbb{C}^{n \times n}$ y $Y \in \mathbb{C}^{m \times m}$ unitarias y $T \in \mathbb{R}_+^{n \times m}$ diagonal. Entonces,

$$\begin{aligned} \|A - B\|_{\text{Fro}}^2 &= \|A\|_{\text{Fro}}^2 + \text{tr}(B^* B - B^* A - A^* B) \\ &= \|A\|_{\text{Fro}}^2 + \sum_{\ell=1}^k t_\ell^2 - \sum_{\ell=1}^k t_\ell \text{tr}((y_\ell \otimes x_\ell)A + A^*(x_\ell \otimes y_\ell)), \end{aligned}$$

como $\sum_{\ell=1}^k t_\ell^2 = \sum_{\ell=1}^k t_\ell^2 \text{tr}(C_{y_\ell \otimes y_\ell})$ y $(y_\ell \otimes x_\ell)A = y_\ell \otimes (A^* x_\ell)$, tenemos que

$$\begin{aligned} \|A - B\|_{\text{Fro}}^2 &= \|A\|_{\text{Fro}}^2 + \sum_{\ell=1}^k \text{tr}((A^* x_\ell - t_\ell y_\ell) \otimes (A^* x_\ell - t_\ell y_\ell)) - \sum_{\ell=1}^k \text{tr}(A^* x_\ell \otimes A^* x_\ell) \\ &\geq \|A\|_{\text{Fro}}^2 - \sum_{\ell=1}^k \|A^* x_\ell\|^2, \end{aligned}$$

donde la desigualdad se obtiene porque $\text{tr}(v \otimes v) = \|v\|^2 \geq 0$.

Paso 3. Acotamos ahora $\sum_{\ell=1}^k \|A^* x_\ell\|^2$. Como $A = U\Sigma V^*$, tenemos que $A^* = V\Sigma^* U^*$, y por tanto $A^* x_\ell = V\Sigma^* U^* x_\ell$. Entonces,

$$\sum_{\ell=1}^k \|A^* x_\ell\|^2 = \sum_{\ell=1}^k \|V\Sigma^* U^* x_\ell\|^2 = \sum_{\ell=1}^k \|\Sigma^* U^* x_\ell\|^2,$$

donde hemos usado que V es unitaria y por tanto preserva la norma. Desarrollando la

norma,

$$\sum_{\ell=1}^k \|\Sigma^* U^* x_\ell\|^2 = \sum_{\ell=1}^k \sum_{i=1}^{\text{rang } A} \sigma_i^2 |\langle U^{(i)}, x_\ell \rangle|^2 = \sum_{i=1}^{\text{rang } A} \sigma_i^2 \sum_{\ell=1}^k |\langle U^{(i)}, x_\ell \rangle|^2.$$

Observamos que $\sum_{\ell=1}^k |\langle U^{(i)}, x_\ell \rangle|^2 = \|\mathbb{P}_k U^{(i)}\|^2$, donde $\mathbb{P}_k$ es el proyector ortogonal sobre $\text{span}\{x_1, \dots, x_k\}$. Denotando $p_i = \|\mathbb{P}_k U^{(i)}\|^2$, tenemos que:

- $p_i \leq 1$ para todo i , ya que $\|\mathbb{P}_k U^{(i)}\| \leq \|U^{(i)}\| = 1$.
- $\sum_{i=1}^{\text{rang } A} p_i \leq k$, ya que $\mathbb{P}_k$ proyecta sobre un subespacio de dimensión k .

Para maximizar $\sum_{i=1}^{\text{rang } A} \sigma_i^2 p_i$ sujeto a estas restricciones, como $\sigma_1 \geq \sigma_2 \geq \dots$, el máximo se alcanza cuando $p_1 = \dots = p_k = 1$ y $p_i = 0$ para $i > k$. Por tanto,

$$\sum_{\ell=1}^k \|A^* x_\ell\|^2 \leq \sum_{i=1}^k \sigma_i^2.$$

Paso 4. Retomando la cota del Paso 2,

$$\|A - B\|_{\text{Fro}}^2 \geq \|A\|_{\text{Fro}}^2 - \sum_{\ell=1}^k \|A^* x_\ell\|^2 \geq \|A\|_{\text{Fro}}^2 - \sum_{i=1}^k \sigma_i^2 = \sum_{i=k+1}^{\text{rang } A} \sigma_i^2,$$

lo que, junto con el Paso 1, concluye la demostración. ■

1.2 *Clustering* espectral en grafos

El objetivo del *clustering* espectral es particionar un conjunto de datos en grupos de manera que los elementos de un mismo grupo estén “más conectados” entre sí que con elementos de otros grupos. Para formalizar esto, representamos los datos como un grafo ponderado.

1.2.1 Grafos ponderados y definiciones básicas

Definición 1.2.1 (Grafo ponderado no dirigido). Un grafo ponderado no dirigido es una tupla $G = (V, W)$ donde:

- $V = \{v_1, \dots, v_m\}$ es el conjunto de vértices.
- $W \in \mathbb{R}^{m \times m}$ es la matriz de pesos, con $w_{ij} = w_{ji} \geq 0$.

Ejemplo 1.2.1. Sea (X, d) un espacio métrico y sea $\{x_i\}_{i=1}^m \subset X$ un conjunto de datos. Dado $\varepsilon > 0$, podemos construir un grafo ponderado donde $V = \{1, \dots, m\}$ y

$$w_{ij} = \begin{cases} e^{-d(x_i, x_j)^2} & \text{si } d(x_i, x_j) \leq \varepsilon, \\ 0 & \text{en otro caso.} \end{cases}$$

Este grafo captura las relaciones de vecindad entre los datos: cuanto más cercanos estén x_i y x_j , mayor será el peso w_{ij} .

Definición 1.2.2 (Grado, volumen y conexión). Sea $G = (V, W)$ un grafo ponderado.

- El **grado** del vértice i es $d_i = \sum_{j=1}^m w_{ij}$. Denotamos por $D = \text{diag}(d_1, \dots, d_m)$ la matriz diagonal de grados.
- El **volumen** de un subconjunto $S \subset V$ es $\text{vol}(S) = \sum_{i \in S} d_i$.
- La **conexión** entre $S, T \subset V$ es $W(S, T) = \sum_{i \in S} \sum_{j \in T} w_{ij}$.

Definición 1.2.3 (Laplaciano de un grafo). Sea $G = (V, W)$ un grafo ponderado. El **laplaciano** de G es la matriz $L = D - W$.

Observación 1.2.4 (Analogía con el laplaciano continuo). El nombre “laplaciano” proviene de la siguiente analogía. Sea $f: V \rightarrow \mathbb{R}$ una función sobre los vértices (escribimos $f_i = f(v_i)$). Entonces,

$$\langle f, Lf \rangle = \sum_{i=1}^m d_i f_i^2 - \sum_{i,j=1}^m w_{ij} f_i f_j = \frac{1}{2} \sum_{i,j=1}^m w_{ij} (f_i - f_j)^2.$$

Esta expresión mide la “variación” de f sobre el grafo, análogamente a cómo para $f \in \mathcal{C}^2(\mathbb{R}^d)$ con $f, |\nabla f|, \Delta f \in L^2(\mathbb{R}^d)$, se tiene $\langle f, -\Delta f \rangle_{L^2} = \|\nabla f\|_{L^2}^2$.

1.2.2 El problema de corte normalizado (NCut)

Definición 1.2.5 (Corte y corte normalizado). Sea $G = (V, W)$ un grafo ponderado y sea $\{A_j\}_{j=1}^k$ una partición de V (es decir, $V = \bigsqcup_{j=1}^k A_j$).

- El **corte** de la partición es

$$\text{cut}(\{A_j\}_{j=1}^k) = \sum_{j=1}^k W(A_j, A_j^c),$$

que mide el “costo” de separar el grafo en los subgrupos $A_1, \dots, A_k$.

- El **corte normalizado** (NCut) es

$$\text{Ncut}(\{A_j\}_{j=1}^k) = \sum_{j=1}^k \frac{W(A_j, A_j^c)}{\text{vol}(A_j)},$$

que penaliza además los grupos con volumen pequeño.

Observación 1.2.6. Para $k = 2$ (partición en dos grupos A y $B = A^c$), el corte normalizado se puede escribir como

$$\text{Ncut}(A, B) = W(A, B) \left(\frac{1}{\text{vol}(A)} + \frac{1}{\text{vol}(B)} \right).$$

Esta expresión es el producto de dos términos: la **separación** $W(A, B)$ (queremos que sea pequeña, es decir, A y B poco conectados) y el **balance** $\frac{1}{\text{vol}(A)} + \frac{1}{\text{vol}(B)}$ (que es mínimo cuando $\text{vol}(A) = \text{vol}(B)$). Por tanto, minimizar NCut favorece particiones con grupos bien separados y de tamaño equilibrado.

El **problema NCut** consiste en encontrar la partición que minimiza el corte normalizado:

$$\{A_j^*\}_{j=1}^k = \arg \min_{\{A_j\}_{j=1}^k \text{ partición}} \text{Ncut}(\{A_j\}_{j=1}^k).$$

1.2.3 Formulación variacional para $k = 2$

El siguiente lema relaciona el corte normalizado con una forma cuadrática.

Lema 1.2.1. Sea $V = A \cup B$ una partición y definamos $f^{(A,B)}: V \rightarrow \mathbb{R}$ por

$$f_i^{(A,B)} = \begin{cases} \sqrt{\frac{\text{vol}(B)}{\text{vol}(A)}} & \text{si } i \in A, \\ -\sqrt{\frac{\text{vol}(A)}{\text{vol}(B)}} & \text{si } i \in B. \end{cases}$$

Entonces,

$$\text{Ncut}(A, B) = \frac{1}{2 \text{vol}(V)} \sum_{i,j=1}^m w_{ij} (f_i^{(A,B)} - f_j^{(A,B)})^2.$$

Demostración: Observamos que $(f_i - f_j)^2 = 0$ si i, j están en el mismo grupo. Si $i \in A$ y $j \in B$ (o viceversa), entonces

$$(f_i - f_j)^2 = \left(\sqrt{\frac{\text{vol}(B)}{\text{vol}(A)}} + \sqrt{\frac{\text{vol}(A)}{\text{vol}(B)}} \right)^2 = \frac{\text{vol}(B)}{\text{vol}(A)} + \frac{\text{vol}(A)}{\text{vol}(B)} + 2.$$

Simplificando esta expresión y usando que $W(A, B) = W(B, A)$, se obtiene

$$\sum_{i,j=1}^m w_{ij}(f_i - f_j)^2 = 2W(A, B) \left(\frac{\text{vol}(B)}{\text{vol}(A)} + \frac{\text{vol}(A)}{\text{vol}(B)} + 2 \right) \cdot \frac{\text{vol}(A) \text{vol}(B)}{(\text{vol}(A) + \text{vol}(B))^2} \cdot \text{vol}(V),$$

que tras simplificar da $2 \text{vol}(V) \text{Ncut}(A, B)$. ■

Teorema 1.2.2. *El problema Ncut con $k = 2$ es equivalente al problema de optimización*

$$\arg \min \left\{ \frac{\langle f, Lf \rangle}{\langle f, Df \rangle} : \sum_{i=1}^m f_i d_i = 0, f_i \in \left\{ \pm \sqrt{\frac{\text{vol}(B)}{\text{vol}(A)}} \right\} \right\}.$$

Demostración: La demostración se divide en tres pasos:

Paso 1. Por la observación sobre el laplaciano, para cualquier $f \in \mathbb{R}^m$,

$$\langle f, Lf \rangle = \frac{1}{2} \sum_{i,j=1}^m w_{ij}(f_i - f_j)^2.$$

Paso 2. Sea $f: V \rightarrow \{p^2, -q^2\}$ y definamos $A = \{i : f_i = p^2\}$, $B = \{i : f_i = -q^2\}$. La restricción $\sum_{i=1}^m d_i f_i = 0$ implica

$$p^2 \text{vol}(A) = q^2 \text{vol}(B) \implies \frac{p^2}{q^2} = \frac{\text{vol}(B)}{\text{vol}(A)}.$$

De aquí se deduce que $f = pq f^{(A,B)}$ para cierto escalar pq .

Paso 3. Con f como en el paso anterior,

$$\langle f, Df \rangle = \sum_{i=1}^m d_i f_i^2 = p^4 \text{vol}(A) + q^4 \text{vol}(B) = p^2 q^2 \text{vol}(V).$$

Por tanto, usando el Lema ??,

$$\frac{\langle f, Lf \rangle}{\langle f, Df \rangle} = \frac{\langle f^{(A,B)}, Lf^{(A,B)} \rangle}{\langle f^{(A,B)}, Df^{(A,B)} \rangle} = \text{Ncut}(A, B).$$
■

Observación 1.2.7 (Complejidad computacional). El problema de optimización del Teorema ?? es **NP-completo**. Esto significa que, salvo que $P = NP$, no existe algoritmo que lo resuelva en tiempo polinomial.

1.2.4 Relajación espectral del problema NCut

Para obtener un algoritmo eficiente, relajamos el problema eliminando la restricción de que f tome valores discretos.

Observación 1.2.8 (Cambio de variable y cociente de Rayleigh). Sea $g = D^{1/2}f$ y definamos $M = D^{-1/2}LD^{-1/2}$ (el **laplaciano normalizado**). Entonces,

$$\frac{\langle f, Lf \rangle}{\langle f, Df \rangle} = \frac{\langle g, Mg \rangle}{\|g\|^2},$$

que es el **cociente de Rayleigh** de la matriz M . Además, M es simétrica y semidefinida positiva, con

$$\langle g, Mg \rangle = \frac{1}{2} \sum_{i,j=1}^m w_{ij} \left(\frac{g_i}{\sqrt{d_i}} - \frac{g_j}{\sqrt{d_j}} \right)^2 \geq 0.$$

La restricción $\sum_{i=1}^m d_i f_i = 0$ se traduce en $g \perp D^{1/2}\mathbf{1}$, donde $\mathbf{1}$ es el vector de unos.

El problema relajado consiste en minimizar el cociente de Rayleigh sobre todos los vectores $g \perp D^{1/2}\mathbf{1}$:

$$\min_{g \perp D^{1/2}\mathbf{1}} \frac{\langle g, Mg \rangle}{\|g\|^2}.$$

Por el teorema del cociente de Rayleigh (ver Apéndice), el mínimo se alcanza en el autovector de M correspondiente al segundo menor autovalor (el menor autovalor es 0 con autovector $D^{1/2}\mathbf{1}$).

Algoritmo de *Spectral Clustering* para $k = 2$:

1. Calcular el autovector g_2 de $M = D^{-1/2}LD^{-1/2}$ correspondiente al menor autovalor no nulo.
2. Definir la partición: $A = \{i \in V : g_2(i) > 0\}$ y $B = A^c$.

1.2.5 Interpretación probabilística: caminos aleatorios

La matriz $P = D^{-1}W$ es una **matriz de transición de Markov**:

$$p_{ij} = \frac{w_{ij}}{d_i} = \frac{w_{ij}}{\sum_{k=1}^m w_{ik}}, \quad \text{con } \sum_{j=1}^m p_{ij} = 1.$$

Es decir, $p_{ij} = \mathbb{P}(i \rightarrow j)$ es la probabilidad de transitar del vértice i al vértice j en un paso del camino aleatorio sobre el grafo. La distribución estacionaria es $\pi_i = \frac{d_i}{\text{vol}(V)}$.

Proposición 1.2.3. Sea $\{X_t\}_{t \geq 0}$ el camino aleatorio sobre G con $X_0 \sim \pi$. Entonces,

$$\mathbb{P}(X_t \in A \mid X_{t-1} \in B) + \mathbb{P}(X_t \in B \mid X_{t-1} \in A) = \text{Ncut}(A, B).$$

Demostración: Calculamos directamente:

$$\mathbb{P}(X_0 \in A, X_1 \in B) = \sum_{i \in A} \sum_{j \in B} \pi_i p_{ij} = \frac{1}{\text{vol}(V)} \sum_{i \in A} \sum_{j \in B} w_{ij} = \frac{W(A, B)}{\text{vol}(V)}.$$

Como $\mathbb{P}(X_0 \in A) = \frac{\text{vol}(A)}{\text{vol}(V)}$, se tiene

$$\mathbb{P}(X_1 \in B \mid X_0 \in A) = \frac{W(A, B)}{\text{vol}(A)}.$$

El mismo argumento da $\mathbb{P}(X_1 \in A \mid X_0 \in B) = \frac{W(B, A)}{\text{vol}(B)}$, y sumando obtenemos $\text{Ncut}(A, B)$. ■

Esta proposición nos da una interpretación intuitiva: **minimizar NCut equivale a minimizar la probabilidad de que un camino aleatorio “salte” entre grupos.**

1.2.6 Spectral Clustering para $k > 2$

Lema 1.2.4. Sea $G = (V, W)$ un grafo con K componentes conexas $V = \bigsqcup_{\ell=1}^K A_\ell$ (es decir, $w_{ij} = 0$ si $i \in A_\ell, j \in A_{\ell'}$ con $\ell \neq \ell'$). Entonces,

$$\ker L = \text{span}\{\chi_{A_1}, \dots, \chi_{A_K}\},$$

donde χ_{A_ℓ} es la función indicadora de A_ℓ .

Demostración: Para $K = 1$ (grafo conexo), $\langle f, Lf \rangle = \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2 = 0$ implica $f_i = f_j$ para todos los pares con $w_{ij} > 0$, es decir, $f = \alpha \mathbf{1}$.

Para $K > 1$, el laplaciano tiene estructura de bloques diagonal (tras reordenar los vértices), y el resultado se aplica a cada bloque. ■

Observación 1.2.9 (Heurística para grafos “casi” desconectados). Si el grafo es conexo pero tiene K grupos “naturales” (muy conectados internamente, poco conectados entre sí), entonces:

- El autovector de M con autovalor 0 es $D^{1/2} \mathbf{1}$.
- Los siguientes $K - 1$ autovectores son aproximadamente $D^{1/2} \chi_{A_\ell}$, correspondientes a

autovalores pequeños.

Algoritmo de Shi-Malik:

1. Calcular los $k + 1$ autovectores de M con menores autovalores: $\{(\lambda_\ell, f_\ell)\}_{\ell=1}^{k+1}$ con $\lambda_1 = 0 < \lambda_2 \leq \dots \leq \lambda_{k+1}$.
2. Representar cada vértice v_i mediante el *embedding*

$$\varphi(v_i) = (f_2(v_i), \dots, f_{k+1}(v_i)) \in \mathbb{R}^k.$$

Esta técnica se conoce como *Laplacian Eigenmaps*.

3. Aplicar un algoritmo de agrupamiento clásico (como k -means) sobre los puntos $\{\varphi(v_i)\}_{i=1}^m \subset \mathbb{R}^k$.

Observación 1.2.10 (Elección de k). El número de grupos k se puede estimar buscando un “codo” en el espectro de M : un salto significativo entre λ_k y λ_{k+1} sugiere que hay k grupos bien definidos.

1.2.7 Otros algoritmos de agrupamiento

Definición 1.2.11 (K -means). Sean $\mathcal{D} = \{x_i\}_{i=1}^m \subset \mathbb{R}^N$ y $K \in \mathbb{N}$. El problema de K -means consiste en encontrar una partición $\mathcal{D} = \bigsqcup_{\ell=1}^K S_\ell$ que minimice

$$\sum_{\ell=1}^K \sum_{x \in S_\ell} \|x - \mu_\ell\|^2, \quad \text{donde } \mu_\ell = \frac{1}{|S_\ell|} \sum_{x \in S_\ell} x$$

es el centroide del grupo S_ℓ .

Observación 1.2.12. El problema de K -means es NP-completo. Los algoritmos prácticos (como el algoritmo de Lloyd) son heurísticas que encuentran mínimos locales.

Definición 1.2.13 (Agrupamiento jerárquico aglomerativo). Sea $\mathcal{D} = \{x_i\}_{i=1}^m \subset (X, d)$ un espacio métrico y sea $R: \mathcal{P}(X) \times \mathcal{P}(X) \rightarrow \mathbb{R}$ una distancia entre subconjuntos (por ejemplo, *single linkage*, *complete linkage* o *average linkage*).

- (i) Inicialmente, cada punto forma su propio grupo.
- (ii) Iterativamente, se fusionan los dos grupos más cercanos según R .
- (iii) Se construye un **dendrograma** que representa la jerarquía de fusiones.
- (iv) Se corta el dendrograma a un nivel t para obtener la partición final.

Observación 1.2.14. La elección del nivel de corte t es análoga a la búsqueda de un “codo” en el espectro del laplaciano.

Apéndice de Álgebra Lineal

Este apéndice recoge resultados de álgebra lineal utilizados en el capítulo, particularmente en la sección de clustering espectral.

Matrices autoadjuntas

Lema 1.2.5 (Caracterización de matrices autoadjuntas). *Sea $A \in \mathbb{C}^{m \times m}$ una matriz. Si $\langle Av, v \rangle_{\mathbb{C}^m} \in \mathbb{R}$ para todo $v \in \mathbb{C}^m$, entonces A es autoadjunta, es decir, $A = A^*$.*

Demostración: Definimos $M = A - A^*$ y mostramos que $M = 0$.

Paso 1. Como $\langle Av, v \rangle \in \mathbb{R}$ para todo v , tenemos que $\langle Av, v \rangle = \overline{\langle Av, v \rangle} = \langle v, Av \rangle$. Por tanto,

$$\langle Mv, v \rangle = \langle Av, v \rangle - \langle A^*v, v \rangle = \langle Av, v \rangle - \langle v, Av \rangle = 0.$$

Paso 2. Usando la identidad de polarización, para cualesquiera $v, w \in \mathbb{C}^m$:

$$\langle M(v + w), v + w \rangle - \langle M(v - w), v - w \rangle = 2 \langle Mv, w \rangle + 2 \langle Mw, v \rangle.$$

Por el Paso 1, el lado izquierdo es cero, luego $\langle Mv, w \rangle = -\langle Mw, v \rangle$.

Como $\langle Mw, v \rangle = \overline{\langle v, Mw \rangle}$ y $\langle v, Mw \rangle = \overline{\langle Mw, v \rangle}$, se tiene $\langle Mv, w \rangle = -\langle Mw, v \rangle = -\overline{\langle v, Mw \rangle}$. Sustituyendo $\langle Mw, v \rangle = -\langle Mv, w \rangle$:

$$\langle Mv, w \rangle = -\overline{\langle Mv, w \rangle} \implies \langle Mv, w \rangle \in i\mathbb{R}.$$

Paso 3. Análogamente, considerando $v + iw$ y $v - iw$:

$$\langle M(v + iw), v + iw \rangle - \langle M(v - iw), v - iw \rangle = 2i \langle Mv, w \rangle - 2i \langle Mw, v \rangle.$$

Por el Paso 1, esto es cero, luego $\langle Mv, w \rangle = \langle Mw, v \rangle$.

Paso 4. Combinando los Pasos 2 y 3: del Paso 2 tenemos $\langle Mv, w \rangle = -\langle Mw, v \rangle$, y del Paso 3 tenemos $\langle Mv, w \rangle = \langle Mw, v \rangle$. Por tanto, $\langle Mv, w \rangle = -\langle Mw, v \rangle$, lo que implica $\langle Mv, w \rangle = 0$ para todos $v, w \in \mathbb{C}^m$. Luego $M = 0$.

■

Observación 1.2.15 (Aplicación al laplaciano normalizado). En el contexto del clustering espectral, la matriz $M = D^{-1/2}LD^{-1/2}$ satisface

$$\langle Mg, g \rangle = \frac{1}{2} \sum_{i,j=1}^m w_{ij} \left| \frac{g_i}{\sqrt{d_i}} - \frac{g_j}{\sqrt{d_j}} \right|^2 \in \mathbb{R}_{\geq 0}$$

para todo $g \in \mathbb{C}^m$. Por el lema anterior, M es autoadjunta (y además semidefinida positiva).

El cociente de Rayleigh

Definición 1.2.16 (Cociente de Rayleigh). Sea $M \in \mathbb{R}^{m \times m}$ una matriz simétrica. El **cociente de Rayleigh** de M es la función $R_M: \mathbb{R}^m \setminus \{0\} \rightarrow \mathbb{R}$ definida por

$$R_M(x) = \frac{\langle Mx, x \rangle}{\|x\|^2}.$$

Lema 1.2.6 (Teorema min-max de Rayleigh). Sea $M \in \mathbb{R}^{m \times m}$ simétrica y semidefinida positiva. Sean $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_m$ sus autovalores (contados con multiplicidad) y $\{v_1, \dots, v_m\}$ una base ortonormal de autovectores correspondientes. Entonces:

$$\min_{x \in \mathbb{R}^m \setminus \{0\}} R_M(x) = \lambda_1, \quad \text{con} \quad \arg \min_{x \neq 0} R_M(x) = \ker(M - \lambda_1 I).$$

Demostración: Como $\{v_1, \dots, v_m\}$ es una base ortonormal, cualquier $x \in \mathbb{R}^m$ se escribe como $x = \sum_{i=1}^m c_i v_i$ con $c_i = \langle x, v_i \rangle$. Entonces:

$$Mx = \sum_{i=1}^m \lambda_i c_i v_i, \quad \|x\|^2 = \sum_{i=1}^m c_i^2, \quad \langle Mx, x \rangle = \sum_{i=1}^m \lambda_i c_i^2.$$

Definiendo $p_i = \frac{c_i^2}{\sum_{j=1}^m c_j^2}$, tenemos que $p_i \geq 0$ y $\sum_{i=1}^m p_i = 1$. Por tanto,

$$R_M(x) = \sum_{i=1}^m \lambda_i p_i$$

es una combinación convexa de los autovalores. El mínimo de una combinación convexa se alcanza en el menor de los valores, es decir, $R_M(x) \geq \lambda_1$, con igualdad si y solo si $p_1 = 1$ (y $p_i = 0$ para $i > 1$), lo que ocurre cuando $x \in \ker(M - \lambda_1 I)$. ■

Corolario 1.2.7 (Segundo autovalor). Con la notación del lema anterior, si $V_1 = \ker(M - \lambda_1 I)$ es el autoespacio correspondiente a λ_1 , entonces

$$\min_{x \perp V_1, x \neq 0} R_M(x) = \lambda_2.$$

Más generalmente, para $k \geq 1$:

$$\lambda_k = \min_{\substack{x \perp v_1, \dots, v_{k-1} \\ x \neq 0}} R_M(x).$$

Demostración: Si $x \perp V_1$, entonces $c_i = 0$ para todo i tal que $\lambda_i = \lambda_1$. Por tanto, $R_M(x) = \sum_{\lambda_i > \lambda_1} \lambda_i p_i \geq \lambda_2$, con igualdad cuando x es autovector de λ_2 . ■

Observación 1.2.17 (Aplicación al clustering espectral). En el problema NCut relajado, buscamos minimizar $R_M(g) = \frac{\langle Mg, g \rangle}{\|g\|^2}$ sujeto a $g \perp D^{1/2}\mathbf{1}$. Como $D^{1/2}\mathbf{1}$ es el autovector de M con autovalor $\lambda_1 = 0$, el Corolario ?? nos dice que el mínimo se alcanza en el autovector correspondiente al segundo menor autovalor λ_2 .

2. Aprendizaje supervisado

2.1 Learning Theory

Sea Z un espacio topológico de Hausdorff, y sea $\mathcal{B}$ la σ -álgebra de Borel de Z . Sea $(Z, \mathcal{B}, \rho)$ un espacio de probabilidad.

- ρ medida desconocida.
- Z tiene estructura natural de producto $Z = X \times Y$ (la proporcionada por el problema concreto).
- Nos interesa el fenómeno de generación de datos en Z descrito por ρ desde el punto de vista de la dependencia de Y de X .

El objetivo es aproximar la **función de regresión**, es decir, la función $f_\rho: X \rightarrow Y$ que asigna a cada $x \in X$ el valor esperado de y condicionado a x :

$$f_\rho(x) := \int_Y y \, d\rho(y \mid x),$$

donde $\rho(y \mid x)$ es la medida de probabilidad condicional de y dado x .

Sea $\pi: Z \rightarrow X$ la proyección $\pi(x, y) = x$. Sea ρ_X la medida de probabilidad marginal en X definida en $E \subset X$ abierto por $\rho_X(E) = \rho(\pi^{-1}(E))$.

Entonces existe la medida de probabilidad condicional que satisface, $\forall \varphi \in L^1(Z, \rho)$:

$$\begin{aligned} \int_Z \varphi(z) \, d\rho(z) &= \int_X \left(\int_Y \varphi(x, y) \, d\rho(y \mid x) \right) d\rho_X(x), \\ \int_Y d\rho(y \mid x) &= 1 \quad \rho_X\text{-casi todo } x \in X. \end{aligned}$$

2.1.1 Sobre el objetivo y el aprendizaje estadístico

- Como no se dispone de ρ (desconocida), hay que trabajar con **muestras**:

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset Z.$$

- Aprendizaje *supervisado*: para todo $x_i \in X$ hay un $y_i \in Y$ que proporciona un objetivo.
- El resultado de todo aprendizaje es epistemológicamente una aproximación, porque la búsqueda de una función de regresión se tiene que hacer dentro de un **espacio de las**

hipótesis definido *a priori* antes de conocer ρ .

Ejemplo 2.1.1 (Best fit polinomial de datos físicos). Supongamos que una ley física $F: \mathbb{R} \rightarrow \mathbb{R}$, y fenómenos aleatorios (es decir, que se escapan a nuestro conocimiento), generan datos:

$$y_i = F(x_i) + \varepsilon_i, \quad \text{donde } \{\varepsilon_i\}_{i=1}^m \text{ son v.a.i.i.d.}$$

Si queremos aproximar F con un polinomio de grado $\leq n$, podemos intentar minimizar

$$\sum_{i=1}^m |y_i - f_w(x_i)|^2, \quad \text{para } f_w(x) = \sum_{i=0}^n w_i x^i.$$

¿Cómo encaja el ejemplo con el problema general?

Supongamos que $\varepsilon \sim \mathcal{N}(0, 1)$, $X = [0, 1]$, ρ_X distribución uniforme en X .

- $\mathcal{F} = F(x)$ es una variable aleatoria en $F(X)$ con medida de probabilidad

$$\mu(\mathcal{F} < t) = \rho_X(\{x : F(x) < t\}) = \rho_X(F^{-1}(-\infty, t)) = F_*\rho_X(-\infty, t),$$

donde $F_*\rho_X$ es la medida pushforward.

- Si $y = F(x)$, se define una medida de probabilidad condicional $\rho(y | x)$ tal que

$$\int_{\mathbb{R}} \varphi(y) d\rho(y | x) = \varphi(F(x)) \quad \forall \varphi \in C_c(\mathbb{R}),$$

que corresponde a una δ de Dirac en $y = F(x)$.

- La probabilidad condicional $\rho(y | x)$ para $y = F(x) + \varepsilon$ es $\mathcal{N}(F(x), 1)$, por lo que

$$d\rho(x, y) = e^{-\frac{(y-F(x))^2}{2}} \rho_X(dx) dy.$$

- Por lo tanto, tenemos que

$$f_\rho(x) = \int_Y y d\rho(y | x) = F(x).$$

La minimización de

$$\sum_{i=1}^m |y_i - f_w(x_i)|^2$$

proporciona una aproximación polinomial empírica de la ley F .

Definición 2.1.1 (Error cuadrático). Sea $Y = \mathbb{R}^k$, ρ una probabilidad en $\mathcal{Z} = X \times Y$, $f : X \rightarrow Y$ una función ρ -medible, y $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset \mathcal{Z}$ un conjunto de datos. Definimos:

$$\mathcal{E}[f] := \int_{\mathcal{Z}} |f(x) - y|^2 d\rho(x, y) \quad (\text{Error de generalización}),$$

$$\mathcal{E}_{\mathcal{D}}[f] := \frac{1}{m} \sum_{i=1}^m |f(x_i) - y_i|^2 \quad (\text{Error empírico}).$$

Proposición 2.1.1. *Para toda función $f : X \rightarrow Y$ ρ -medible, se cumple que:*

$$\mathcal{E}[f] = \int_X |f(x) - f_{\rho}(x)|^2 d\rho_X(x) + \mathcal{E}[f_{\rho}],$$

donde $f_{\rho}(x)$ es el valor esperado condicional definido como:

$$f_{\rho}(x) = \int_Y y d\rho(y | x).$$

La primera integral representa el *error de aproximar f_{ρ} con f* , mientras que $\mathcal{E}[f_{\rho}]$ es el *error intrínseco* debido a la variabilidad de la distribución conjunta ρ en Z . Más específicamente:

$$\mathcal{E}[f_{\rho}] = \int_X \left(\int_Y |f_{\rho}(x) - y|^2 d\rho(y | x) \right) d\rho_X(x),$$

donde el término interno mide la *varianza en y* de la distribución condicional $\rho(y | x)$ respecto a su valor medio $f_{\rho}(x)$.

Demostración:

$$\begin{aligned} \mathcal{E}[f] &= \int_{X \times Y} |f(x) - y|^2 d\rho(x, y) \\ &= \int_{X \times Y} |f(x) - y + f_{\rho}(x) - f_{\rho}(x)|^2 d\rho(x, y) \\ &= \int_{X \times Y} |f(x) - f_{\rho}(x)|^2 d\rho(x, y) + \int_{X \times Y} |f_{\rho}(x) - y|^2 d\rho(x, y) \\ &\quad + 2 \int_{X \times Y} (f(x) - f_{\rho}(x))(f_{\rho}(x) - y) d\rho(x, y) \\ &= \int_X |f(x) - f_{\rho}(x)|^2 d\rho_X(x) + \mathcal{E}[f_{\rho}] + 2\mathcal{I}[f, f_{\rho}], \\ \mathcal{I}[f, f_{\rho}] &= \int_X (f(x) - f_{\rho}(x)) \left(\int_Y (f_{\rho}(x) - y) d\rho(y | x) \right) d\rho_X(x). \end{aligned}$$

■

Definición 2.1.2 (Hipótesis y función objetivo). Sea $\mathcal{H}$ un conjunto de funciones $X \rightarrow Y$ y $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset X \times Y$ un conjunto de datos. Llamaremos $f_{\mathcal{H}}, f_{\rho}, f_{\mathcal{D}}$ funciones de $\mathcal{H}$ tales que:

$$\mathcal{E}[f_{\mathcal{H}}] \leq \mathcal{E}[f] \quad \forall f \in \mathcal{H},$$

$$\mathcal{E}_{\mathcal{D}}[f_{\mathcal{D}}] \leq \mathcal{E}_{\mathcal{D}}[f] \quad \forall f \in \mathcal{H}.$$

Esto es equivalente a:

$$\|f_{\mathcal{H}} - f_{\rho}\|_{L^2(\rho_X)} \leq \|f - f_{\rho}\|_{L^2(\rho_X)} \quad \forall f \in \mathcal{H}.$$

Teorema 2.1.2. Sea X un espacio métrico, sea $M > 0$ y sea $\mathcal{H}_M \subset \mathcal{C}(X)$ compacto tal que

$$|f(x) - y| \leq M \quad \rho\text{-c.s.}, \quad \forall f \in \mathcal{H}_M.$$

Entonces, $\exists f_{\mathcal{H}_M}$ y, $\forall \mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset X \times Y$, $\exists f_{\mathcal{H}_M, \mathcal{D}}$.

Demostración: La prueba consiste en demostrar que, si el espacio de las hipótesis satisface $(*)_M$, entonces $\mathcal{E}$ y $\mathcal{E}_{\mathcal{D}}$ son continuas $\mathcal{H}_M \rightarrow \mathbb{R}_+$.

$$\begin{aligned} |\mathcal{E}[f_1] - \mathcal{E}[f_2]| &= \left| \int_Z (|f_1(x) - y|^2 - |f_2(x) - y|^2) d\rho(x, y) \right| \\ &= \left| \int_Z ((f_1(x) + f_2(x) - 2y) \cdot (f_1(x) - f_2(x))) d\rho(x, y) \right| \\ &\leq \|f_1 - f_2\|_{\infty} \int_Z (|f_1(x) - y| + |f_2(x) - y|) d\rho(x, y) \\ &\leq 2M \|f_1 - f_2\|_{\infty} \quad (\text{continuidad en la norma de } \mathcal{C}(X)). \end{aligned}$$

La prueba para $\mathcal{E}_{\mathcal{D}}$ es la misma. ■

The Bias-Variance Tradeoff

El objetivo del aprendizaje es establecer una clase $\mathcal{H}$ buena y encontrar $f_{\mathcal{H}, \mathcal{D}}$ tal que exista $f_{\mathcal{H}, \infty}$ y sea pequeño el error de generalización $\mathcal{E}[f_{\mathcal{H}, \mathcal{D}}]$.

Si reescribimos

$$\mathcal{E}[f_{\mathcal{H}, \mathcal{D}}] = \mathcal{E}[f_{\mathcal{H}, \infty}] - \mathcal{E}[f_{\mathcal{H}}] + \mathcal{E}[f_{\mathcal{H}}],$$

donde

VARIANCE $V(\mathcal{H}, \mathcal{D}, \rho)$ y BIAS.

- Si $\mathcal{H}$ es fijo y se aumenta el tamaño m de la muestra $\mathcal{D}$, entonces $V \rightarrow 0$ (*bajo hipótesis oportunas*).
- Si fijamos la muestra $\mathcal{D}$ y ampliamos $\mathcal{H}$, $\mathcal{E}[f_{\mathcal{H}}]$ se puede hacer pequeño, porque se reduce el error de aproximación $\|f_{\mathcal{H}} - f_{\rho}\|_{L^2(\rho_X)}$, pero se observa que V crece, por el fenómeno del *overfitting*: un modelo $\mathcal{H}$ demasiado grande hace $\mathcal{E}_{\mathcal{D}}(f_{\mathcal{H}, \mathcal{D}})$ muy pequeño, pero generaliza mal.