
MATEMÁTICAS PARA EL APRENDIZAJE AUTOMÁTICO

Cuarto del Grado en Matemáticas

Hugo Marquerie

Profesor: Davide Barbieri

Facultad de Ciencias - Universidad Autónoma de Madrid

Segundo cuatrimestre

fecha

Puedes encontrar mi colección completa de apuntes en <https://hmarquer.github.io>.

Índice

1	Aprendizaje no supervisado	iii
1.1	Principal component analysis (PCA)	iii
1.1.1	Planteamiento del problema	iii
1.1.2	Solución (teorema y algoritmo)	iii
1.2	<i>Clustering</i> espectral en grafos	iv

1. Aprendizaje no supervisado

1.1 Principal component analysis (PCA)

1.1.1 Planteamiento del problema

Sean $\{x_i\}_{i=1}^m \subset \mathbb{C}^n$ un conjunto de datos y sea $k < m$. El objetivo de PCA es encontrar la proyección de $\mathbb{C}^n$ de rango k (proyección sobre un subespacio $M \subset \mathbb{C}^n$ de dimensión k) que minimice el error cuadrático entre los datos originales y los datos proyectados:

$$\mathcal{E} = \sum_{i=1}^m \|x_i - \mathbb{P}_M x_i\|^2,$$

donde $\mathbb{P}_M$ es la proyección ortogonal sobre M . El PCA nos permite:

- Aproximar un conjunto de datos por un subespacio de dimensión menor.
- Una base ortonormal del subespacio M proporciona un diccionario “óptimo” para representar linealmente los datos.

1.1.2 Solución (teorema y algoritmo)

Sea $A = \begin{pmatrix} | & | & \cdots & | \\ x_1 & x_2 & \cdots & x_m \\ | & | & \cdots & | \end{pmatrix} \in \mathbb{C}^{n \times m}$ y sea $A = U\Sigma V^*$ su descomposición en valores singulares (SVD). Es decir, $U \in \mathbb{C}^{n \times n}$ y $V \in \mathbb{C}^{m \times m}$ son matrices unitarias y $\Sigma \in \mathbb{R}_+^{n \times m}$ es una matriz diagonal con los valores singulares $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$ en la diagonal, donde $r = \text{rang}(A)$. Entonces, $M = \text{span}\{U^{(1)}, \dots, U^{(k)}\}$, donde $U^{(i)}$ es la i -ésima columna de U , es el subespacio que minimiza el error cuadrático $\mathcal{E}$. En consecuencia, la proyección ortogonal de los datos sobre M viene dada por

$$\forall x \in \mathbb{C}^n : \mathbb{P}_M x = \sum_{i=1}^k \langle x, U^{(i)} \rangle U^{(i)}.$$

Teorema 1.1.1. Sea $A \in \mathbb{C}^{n \times m}$, $A = U\Sigma V^*$ su SVD y $k \leq \text{rang}(A)$. Definimos

$$A_k = \sum_{i=1}^k \sigma_i U^{(i)} \otimes V^{(i)} \quad \text{donde} \quad (v \otimes w)_{ij} = v_i \overline{w_j}.$$

$$\implies \forall B \in \mathbb{C}^{n \times m} : \text{rang}(B) = k : \|A - B\|_{Fro}^2 \geq \|A - A_k\|_{Fro}^2 = \sum_{i=k+1}^{\text{rang } A} \sigma_i^2.$$

¿Por qué nos vale esto? La i -ésima columnas de A_k es $A_k^{(i)} = \sum_{\ell=1}^k \sigma_\ell \overline{V_{i\ell}} U^{(\ell)}$ donde $U^{(\ell)}$ es la ℓ -ésima columna de U y $\sigma_\ell \overline{V_{i\ell}} = \langle A^{(i)}, U^{(\ell)} \rangle = \langle x_i, U^{(\ell)} \rangle$. Entonces,

$$A_k^{(i)} = \sum_{\ell=1}^k \langle x_i, U^{(\ell)} \rangle U^{(\ell)} = \mathbb{P}_{\text{span}\{U^{(1)}, \dots, U^{(k)}\}} x_i = \mathbb{P}_M x_i.$$

Demostración: Dividimos la demostración en diferentes pasos:

Paso 1. Recordamos que la norma de Frobenius se puede escribir como $\|A\|_{\text{Fro}}^2 = \text{tr}(A^* A)$.

Por tanto,

$$\begin{aligned} \|A - A_k\|_{\text{Fro}}^2 &= \|U \Sigma V^* - U \Sigma_k V^*\|_{\text{Fro}}^2 = \|U(\Sigma - \Sigma_k) V^*\|_{\text{Fro}}^2 \\ &= \text{tr}(V(\Sigma - \Sigma_k)^* V^*) = \sum_{\ell=k+1}^{\text{rang } A} \sigma_\ell^2, \end{aligned}$$

puesto que $\Sigma - \Sigma_k$ es una matriz diagonal con los ceros en los primeros k elementos de la diagonal y los valores singulares $\sigma_{k+1}, \dots, \sigma_r$ en el resto.

Por tanto, basta demostrar que $\forall B \in \mathbb{C}^{n \times m} : \text{rang}(B) = k : \|A - B\|_{\text{Fro}}^2 \geq \sum_{\ell=k+1}^{\text{rang } A} \sigma_\ell^2$.

Paso 2. Sea $B \in \mathbb{C}^{n \times m}$ con $\text{rang}(B) = k$. Sea $B = XTY^*$ su SVD, con $X \in \mathbb{C}^{n \times n}$ y $Y \in \mathbb{C}^{m \times m}$ unitarias y $T \in \mathbb{R}_+^{n \times m}$ diagonal. Entonces,

$$\begin{aligned} \|A - B\|_{\text{Fro}}^2 &= \|A\|_{\text{Fro}}^2 + \text{tr}(B^* B - B^* A - A^* B) \\ &= \|A\|_{\text{Fro}}^2 + \sum_{\ell=1}^k t_\ell^2 - \sum_{\ell=1}^k t_\ell \text{tr}((y_\ell \otimes x_\ell) A + A^*(x_\ell \otimes y_\ell)), \end{aligned}$$

como $\sum_{\ell=1}^k t_\ell^2 = \sum_{\ell=1}^k t_\ell^2 \text{tr}(C_{y_\ell \otimes y_\ell})$ y $(y_\ell \otimes x_\ell) A = y_\ell \otimes (A^* x_\ell)$, tenemos que

$$\begin{aligned} \|A - B\|_{\text{Fro}}^2 &= \|A\|_{\text{Fro}}^2 + \sum_{\ell=1}^k \text{tr}((A^* x_\ell - t_\ell y_\ell) \otimes (A^* x_\ell - t_\ell y_\ell)) - \sum_{\ell=1}^k \text{tr}(A^* x_\ell \otimes A^* x_\ell) \\ &\geq \|A\|_{\text{Fro}}^2 - \sum_{\ell=1}^k \|A^* x_\ell\|_{\mathbb{C}}^2, \end{aligned}$$

Paso 3.

■

1.2 *Clustering* espectral en grafos

Definición 1.2.1 (Grafo). $G = (V, A)$ es un grafo $\iff V \neq \emptyset \wedge A \subset \{a \in \mathcal{P}(V) : |a| = 2\}$.

Definición 1.2.2 (Grafo ponderado). $G = (V, A, w)$ es un grafo ponderado

$$\iff (V, A) \text{ es un grafo } \wedge w: A \longrightarrow \mathbb{R}.$$

Ejemplo 1.2.1. Sea (X, d) un espacio métrico y sea $\{x_i\}_{i=1}^n \subset X$ un conjunto de datos.

Entonces, dado $\varepsilon > 0$, $G = (V, A, W)$ donde

$$V = \{1, \dots, n\}, \quad A = \{(i, j) : d(x_i, x_j) \leq \varepsilon\}, \quad W(i, j) = \exp(-d(x_i, x_j)^2),$$

es un grafo ponderado que representa las relaciones de vecindad entre los datos.

Definición 1.2.3 (Grado). Sea $G = (V, A, w)$ un grafo ponderado y $v \in V$,

$$\deg v \text{ es el grado de } v \iff \deg v = \sum_{u:(v,u) \in A} w(v, u).$$

Denotamos por D la matriz diagonal de los grados, es decir, $D_{ii} = \deg v_i$.

Definición 1.2.4 (Volumen). Sea $G = (V, A, w)$ un grafo ponderado y $S \subset V$,

$$\text{vol } S \text{ es el volumen de } S \iff \text{vol } S = \sum_{v \in S} \deg v.$$

Definición 1.2.5 (Conexión). Sea $G = (V, A, w)$ un grafo ponderado y $S, T \subset V$,

$$\text{conn}(S, T) \text{ es la conexión entre } S \text{ y } T \iff \text{conn}(S, T) = \sum_{(u,v) \in A: u \in S, v \in T} w(u, v).$$

Definición 1.2.6 (Laplaciano de un grafo). Sea $G = (V, A, w)$ un grafo ponderado, L es el laplaciano de $G \iff L = D - W$, donde D es la matriz diagonal de los grados y W es la matriz de adyacencia ponderada.

¿Por qué se le llama Laplaciano?

Sea $V = \mathbb{N}_n$ y sea $f: V \rightarrow \mathbb{R}$ (escribimos $\forall i \in V : f_i := f(i)$). Entonces,

$$\langle f, Lf \rangle = \sum_{i=1}^n d_i f_i^2 - \sum_{i,j=1}^n w_{ij} f_i f_j = \sum_{i,j=1}^n w_{ij} (f_i^2 - f_i f_j) = \frac{1}{2} \sum_{i,j=1}^n w_{ij} (f_i - f_j)^2.$$

Para $f \in \mathcal{C}^2(\mathbb{R}^d)$ tal que $f, |\nabla f|, \Delta f \in L^2(\mathbb{R}^d)$, tenemos que $\langle f, \Delta f \rangle = \|\nabla f\|_{L^2(\mathbb{R}^d)}^2$.

2. Aprendizaje supervisado

2.1 Learning Theory

Sea Z un espacio topológico de Hausdorff, y sea $\mathcal{B}$ la σ -álgebra de Borel de Z . Sea $(Z, \mathcal{B}, \rho)$ un espacio de probabilidad.

- ρ medida desconocida.
- Z tiene estructura natural de producto $Z = X \times Y$ (la proporcionada por el problema concreto).
- Nos interesa el fenómeno de generación de datos en Z descrito por ρ desde el punto de vista de la dependencia de Y de X .

El objetivo es aproximar la **función de regresión**, es decir, la función $f_\rho: X \rightarrow Y$ que asigna a cada $x \in X$ el valor esperado de y condicionado a x :

$$f_\rho(x) := \int_Y y \, d\rho(y \mid x),$$

donde $\rho(y \mid x)$ es la medida de probabilidad condicional de y dado x .

Sea $\pi: Z \rightarrow X$ la proyección $\pi(x, y) = x$. Sea ρ_X la medida de probabilidad marginal en X definida en $E \subset X$ abierto por $\rho_X(E) = \rho(\pi^{-1}(E))$.

Entonces existe la medida de probabilidad condicional que satisface, $\forall \varphi \in L^1(Z, \rho)$:

$$\begin{aligned} \int_Z \varphi(z) \, d\rho(z) &= \int_X \left(\int_Y \varphi(x, y) \, d\rho(y \mid x) \right) d\rho_X(x), \\ \int_Y d\rho(y \mid x) &= 1 \quad \rho_X\text{-casi todo } x \in X. \end{aligned}$$

2.1.1 Sobre el objetivo y el aprendizaje estadístico

- Como no se dispone de ρ (desconocida), hay que trabajar con **muestras**:

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset Z.$$

- Aprendizaje *supervisado*: para todo $x_i \in X$ hay un $y_i \in Y$ que proporciona un objetivo.
- El resultado de todo aprendizaje es epistemológicamente una aproximación, porque la búsqueda de una función de regresión se tiene que hacer dentro de un **espacio de las**

hipótesis definido *a priori* antes de conocer ρ .

Ejemplo 2.1.1 (Best fit polinomial de datos físicos). Supongamos que una ley física $F: \mathbb{R} \rightarrow \mathbb{R}$, y fenómenos aleatorios (es decir, que se escapan a nuestro conocimiento), generan datos:

$$y_i = F(x_i) + \varepsilon_i, \quad \text{donde } \{\varepsilon_i\}_{i=1}^m \text{ son v.a.i.i.d.}$$

Si queremos aproximar F con un polinomio de grado $\leq n$, podemos intentar minimizar

$$\sum_{i=1}^m |y_i - f_w(x_i)|^2, \quad \text{para } f_w(x) = \sum_{i=0}^n w_i x^i.$$

¿Cómo encaja el ejemplo con el problema general?

Supongamos que $\varepsilon \sim \mathcal{N}(0, 1)$, $X = [0, 1]$, ρ_X distribución uniforme en X .

- $\mathcal{F} = F(x)$ es una variable aleatoria en $F(X)$ con medida de probabilidad

$$\mu(\mathcal{F} < t) = \rho_X(\{x : F(x) < t\}) = \rho_X(F^{-1}(-\infty, t)) = F_*\rho_X(-\infty, t),$$

donde $F_*\rho_X$ es la medida pushforward.

- Si $y = F(x)$, se define una medida de probabilidad condicional $\rho(y | x)$ tal que

$$\int_{\mathbb{R}} \varphi(y) d\rho(y | x) = \varphi(F(x)) \quad \forall \varphi \in C_c(\mathbb{R}),$$

que corresponde a una δ de Dirac en $y = F(x)$.

- La probabilidad condicional $\rho(y | x)$ para $y = F(x) + \varepsilon$ es $\mathcal{N}(F(x), 1)$, por lo que

$$d\rho(x, y) = e^{-\frac{(y-F(x))^2}{2}} \rho_X(dx) dy.$$

- Por lo tanto, tenemos que

$$f_\rho(x) = \int_Y y d\rho(y | x) = F(x).$$

La minimización de

$$\sum_{i=1}^m |y_i - f_w(x_i)|^2$$

proporciona una aproximación polinomial empírica de la ley F .

Definición 2.1.1 (Error cuadrático). Sea $Y = \mathbb{R}^k$, ρ una probabilidad en $\mathcal{Z} = X \times Y$, $f : X \rightarrow Y$ una función ρ -medible, y $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset \mathcal{Z}$ un conjunto de datos. Definimos:

$$\mathcal{E}[f] := \int_{\mathcal{Z}} |f(x) - y|^2 d\rho(x, y) \quad (\text{Error de generalización}),$$

$$\mathcal{E}_{\mathcal{D}}[f] := \frac{1}{m} \sum_{i=1}^m |f(x_i) - y_i|^2 \quad (\text{Error empírico}).$$

Proposición 2.1.1. *Para toda función $f : X \rightarrow Y$ ρ -medible, se cumple que:*

$$\mathcal{E}[f] = \int_X |f(x) - f_{\rho}(x)|^2 d\rho_X(x) + \mathcal{E}[f_{\rho}],$$

donde $f_{\rho}(x)$ es el valor esperado condicional definido como:

$$f_{\rho}(x) = \int_Y y d\rho(y | x).$$

La primera integral representa el *error de aproximar f_{ρ} con f* , mientras que $\mathcal{E}[f_{\rho}]$ es el *error intrínseco* debido a la variabilidad de la distribución conjunta ρ en Z . Más específicamente:

$$\mathcal{E}[f_{\rho}] = \int_X \left(\int_Y |f_{\rho}(x) - y|^2 d\rho(y | x) \right) d\rho_X(x),$$

donde el término interno mide la *varianza en y* de la distribución condicional $\rho(y | x)$ respecto a su valor medio $f_{\rho}(x)$.

Demostración:

$$\begin{aligned} \mathcal{E}[f] &= \int_{X \times Y} |f(x) - y|^2 d\rho(x, y) \\ &= \int_{X \times Y} |f(x) - y + f_{\rho}(x) - f_{\rho}(x)|^2 d\rho(x, y) \\ &= \int_{X \times Y} |f(x) - f_{\rho}(x)|^2 d\rho(x, y) + \int_{X \times Y} |f_{\rho}(x) - y|^2 d\rho(x, y) \\ &\quad + 2 \int_{X \times Y} (f(x) - f_{\rho}(x))(f_{\rho}(x) - y) d\rho(x, y) \\ &= \int_X |f(x) - f_{\rho}(x)|^2 d\rho_X(x) + \mathcal{E}[f_{\rho}] + 2\mathcal{I}[f, f_{\rho}], \\ \mathcal{I}[f, f_{\rho}] &= \int_X (f(x) - f_{\rho}(x)) \left(\int_Y (f_{\rho}(x) - y) d\rho(y | x) \right) d\rho_X(x). \end{aligned}$$

■

Definición 2.1.2 (Hipótesis y función objetivo). Sea $\mathcal{H}$ un conjunto de funciones $X \rightarrow Y$ y $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset X \times Y$ un conjunto de datos. Llamaremos $f_{\mathcal{H}}, f_{\rho}, f_{\mathcal{D}}$ funciones de $\mathcal{H}$ tales que:

$$\mathcal{E}[f_{\mathcal{H}}] \leq \mathcal{E}[f] \quad \forall f \in \mathcal{H},$$

$$\mathcal{E}_{\mathcal{D}}[f_{\mathcal{D}}] \leq \mathcal{E}_{\mathcal{D}}[f] \quad \forall f \in \mathcal{H}.$$

Esto es equivalente a:

$$\|f_{\mathcal{H}} - f_{\rho}\|_{L^2(\rho_X)} \leq \|f - f_{\rho}\|_{L^2(\rho_X)} \quad \forall f \in \mathcal{H}.$$

Teorema 2.1.2. Sea X un espacio métrico, sea $M > 0$ y sea $\mathcal{H}_M \subset \mathcal{C}(X)$ compacto tal que

$$|f(x) - y| \leq M \quad \rho\text{-c.s.}, \quad \forall f \in \mathcal{H}_M.$$

Entonces, $\exists f_{\mathcal{H}_M}$ y, $\forall \mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset X \times Y$, $\exists f_{\mathcal{H}_M, \mathcal{D}}$.

Demostración: La prueba consiste en demostrar que, si el espacio de las hipótesis satisface $(*)_M$, entonces $\mathcal{E}$ y $\mathcal{E}_{\mathcal{D}}$ son continuas $\mathcal{H}_M \rightarrow \mathbb{R}_+$.

$$\begin{aligned} |\mathcal{E}[f_1] - \mathcal{E}[f_2]| &= \left| \int_Z (|f_1(x) - y|^2 - |f_2(x) - y|^2) d\rho(x, y) \right| \\ &= \left| \int_Z ((f_1(x) + f_2(x) - 2y) \cdot (f_1(x) - f_2(x))) d\rho(x, y) \right| \\ &\leq \|f_1 - f_2\|_{\infty} \int_Z (|f_1(x) - y| + |f_2(x) - y|) d\rho(x, y) \\ &\leq 2M \|f_1 - f_2\|_{\infty} \quad (\text{continuidad en la norma de } \mathcal{C}(X)). \end{aligned}$$

La prueba para $\mathcal{E}_{\mathcal{D}}$ es la misma. ■

The Bias-Variance Tradeoff

El objetivo del aprendizaje es establecer una clase $\mathcal{H}$ buena y encontrar $f_{\mathcal{H}, \mathcal{D}}$ tal que exista $f_{\mathcal{H}, \infty}$ y sea pequeño el error de generalización $\mathcal{E}[f_{\mathcal{H}, \mathcal{D}}]$.

Si reescribimos

$$\mathcal{E}[f_{\mathcal{H}, \mathcal{D}}] = \mathcal{E}[f_{\mathcal{H}, \infty}] - \mathcal{E}[f_{\mathcal{H}}] + \mathcal{E}[f_{\mathcal{H}}],$$

donde

VARIANCE $V(\mathcal{H}, \mathcal{D}, \rho)$ y BIAS.

- Si $\mathcal{H}$ es fijo y se aumenta el tamaño m de la muestra $\mathcal{D}$, entonces $V \rightarrow 0$ (*bajo hipótesis oportunas*).
- Si fijamos la muestra $\mathcal{D}$ y ampliamos $\mathcal{H}$, $\mathcal{E}[f_{\mathcal{H}}]$ se puede hacer pequeño, porque se reduce el error de aproximación $\|f_{\mathcal{H}} - f_{\rho}\|_{L^2(\rho_X)}$, pero se observa que V crece, por el fenómeno del *overfitting*: un modelo $\mathcal{H}$ demasiado grande hace $\mathcal{E}_{\mathcal{D}}(f_{\mathcal{H}, \mathcal{D}})$ muy pequeño, pero generaliza mal.