
MATEMÁTICAS PARA EL APRENDIZAJE AUTOMÁTICO

Cuarto del Grado en Matemáticas

Hugo Marquerie

Profesor: Davide Barbieri

Facultad de Ciencias - Universidad Autónoma de Madrid

Segundo cuatrimestre

fecha

Puedes encontrar mi colección completa de apuntes en <https://hmarquer.github.io>.

Índice

1	Aprendizaje no supervisado	iii
1.1	Principal component analysis (PCA)	iii
1.1.1	Planteamiento del problema	iii
1.1.2	Solución (teorema y algoritmo)	iii

1. Aprendizaje no supervisado

1.1 Principal component analysis (PCA)

1.1.1 Planteamiento del problema

Sean $\{x_i\}_{i=1}^m \subset \mathbb{C}^n$ un conjunto de datos y sea $k < m$. El objetivo de PCA es encontrar la proyección de $\mathbb{C}^n$ de rango k (proyección sobre un subespacio $M \subset \mathbb{C}^n$ de dimensión k) que minimice el error cuadrático entre los datos originales y los datos proyectados:

$$\mathcal{E} = \sum_{i=1}^m \|x_i - \mathbb{P}_M x_i\|^2,$$

donde $\mathbb{P}_M$ es la proyección ortogonal sobre M . El PCA nos permite:

- Aproximar un conjunto de datos por un subespacio de dimensión menor.
- Una base ortonormal del subespacio M proporciona un diccionario “óptimo” para representar linealmente los datos.

1.1.2 Solución (teorema y algoritmo)

Sea $A = \begin{pmatrix} | & | & \cdots & | \\ x_1 & x_2 & \cdots & x_m \\ | & | & \cdots & | \end{pmatrix} \in \mathbb{C}^{n \times m}$ y sea $A = U\Sigma V^*$ su descomposición en valores singulares (SVD). Es decir, $U \in \mathbb{C}^{n \times n}$ y $V \in \mathbb{C}^{m \times m}$ son matrices unitarias y $\Sigma \in \mathbb{R}_+^{n \times m}$ es una matriz diagonal con los valores singulares $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$ en la diagonal, donde $r = \text{rang}(A)$. Entonces, $M = \text{span}\{U^{(1)}, \dots, U^{(k)}\}$, donde $U^{(i)}$ es la i -ésima columna de U , es el subespacio que minimiza el error cuadrático $\mathcal{E}$. En consecuencia, la proyección ortogonal de los datos sobre M viene dada por

$$\forall x \in \mathbb{C}^n : \mathbb{P}_M x = \sum_{i=1}^k \langle x, U^{(i)} \rangle U^{(i)}.$$

Teorema 1.1.1. Sea $A \in \mathbb{C}^{n \times m}$, $A = U\Sigma V^*$ su SVD y $k \leq \text{rang}(A)$. Definimos

$$A_k = \sum_{i=1}^k \sigma_i U^{(i)} \otimes V^{(i)} \quad \text{donde} \quad (v \otimes w)_{ij} = v_i \overline{w_j}.$$

$$\implies \forall B \in \mathbb{C}^{n \times m} : \text{rang}(B) = k : \|A - B\|_{Fro}^2 \geq \|A - A_k\|_{Fro}^2 = \sum_{i=k+1}^{\text{rang } A} \sigma_i^2.$$

¿Por qué nos vale esto? La i -ésima columnas de A_k es $A_k^{(i)} = \sum_{\ell=1}^k \sigma_\ell \overline{V_{i\ell}} U^{(\ell)}$ donde $U^{(\ell)}$ es la ℓ -ésima columna de U y $\sigma_\ell \overline{V_{i\ell}} = \langle A^{(i)}, U^{(\ell)} \rangle = \langle x_i, U^{(\ell)} \rangle$. Entonces,

$$A_k^{(i)} = \sum_{\ell=1}^k \langle x_i, U^{(\ell)} \rangle U^{(\ell)} = \mathbb{P}_{\text{span}\{U^{(1)}, \dots, U^{(k)}\}} x_i = \mathbb{P}_M x_i.$$

Demostración: Dividimos la demostración en diferentes pasos:

Paso 1. Recordamos que la norma de Frobenius se puede escribir como $\|A\|_{\text{Fro}}^2 = \text{tr}(A^* A)$.

Por tanto,

$$\begin{aligned} \|A - A_k\|_{\text{Fro}}^2 &= \|U \Sigma V^* - U \Sigma_k V^*\|_{\text{Fro}}^2 = \|U(\Sigma - \Sigma_k) V^*\|_{\text{Fro}}^2 \\ &= \text{tr}(V(\Sigma - \Sigma_k)^* V^*) = \sum_{\ell=k+1}^{\text{rang } A} \sigma_\ell^2, \end{aligned}$$

puesto que $\Sigma - \Sigma_k$ es una matriz diagonal con los ceros en los primeros k elementos de la diagonal y los valores singulares $\sigma_{k+1}, \dots, \sigma_r$ en el resto.

Por tanto, basta demostrar que $\forall B \in \mathbb{C}^{n \times m} : \text{rang}(B) = k : \|A - B\|_{\text{Fro}}^2 \geq \sum_{\ell=k+1}^{\text{rang } A} \sigma_\ell^2$.

Paso 2. Sea $B \in \mathbb{C}^{n \times m}$ con $\text{rang}(B) = k$. Sea $B = XTY^*$ su SVD, con $X \in \mathbb{C}^{n \times n}$ y $Y \in \mathbb{C}^{m \times m}$ unitarias y $T \in \mathbb{R}_+^{n \times m}$ diagonal. Entonces,

$$\begin{aligned} \|A - B\|_{\text{Fro}}^2 &= \|A\|_{\text{Fro}}^2 + \text{tr}(B^* B - B^* A - A^* B) \\ &= \|A\|_{\text{Fro}}^2 + \sum_{\ell=1}^k t_\ell^2 - \sum_{\ell=1}^k t_\ell \text{tr}((y_\ell \otimes x_\ell) A + A^*(x_\ell \otimes y_\ell)), \end{aligned}$$

como $\sum_{\ell=1}^k t_\ell^2 = \sum_{\ell=1}^k t_\ell^2 \text{tr}(C_{y_\ell \otimes y_\ell})$ y $(y_\ell \otimes x_\ell) A = y_\ell \otimes (A^* x_\ell)$, tenemos que

$$\begin{aligned} \|A - B\|_{\text{Fro}}^2 &= \|A\|_{\text{Fro}}^2 + \sum_{\ell=1}^k \text{tr}((A^* x_\ell - t_\ell y_\ell) \otimes (A^* x_\ell - t_\ell y_\ell)) - \sum_{\ell=1}^k \text{tr}(A^* x_\ell \otimes A^* x_\ell) \\ &\geq \|A\|_{\text{Fro}}^2 - \sum_{\ell=1}^k \|A^* x_\ell\|_{\mathbb{C}}^2, \end{aligned}$$

Paso 3.

■

1.2 *Clustering* espectral en grafos

Definición 1.2.1 (Grafo). $G = (V, A)$ es un grafo $\iff V \neq \emptyset \wedge A \subset \{a \in \mathcal{P}(V) : |a| = 2\}$.

Definición 1.2.2 (Grafo ponderado). $G = (V, A, w)$ es un grafo ponderado

$$\iff (V, A) \text{ es un grafo } \wedge w: A \longrightarrow \mathbb{R}.$$

Ejemplo 1.2.1. Sea (X, d) un espacio métrico y sea $\{x_i\}_{i=1}^n \subset X$ un conjunto de datos.

Entonces, dado $\varepsilon > 0$, $G = (V, A, W)$ donde

$$V = \{1, \dots, n\}, \quad A = \{(i, j) : d(x_i, x_j) \leq \varepsilon\}, \quad W(i, j) = \exp(-d(x_i, x_j)^2),$$

es un grafo ponderado que representa las relaciones de vecindad entre los datos.

Definición 1.2.3 (Grado). Sea $G = (V, A, w)$ un grafo ponderado y $v \in V$,

$$\deg v \text{ es el grado de } v \iff \deg v = \sum_{u:(v,u) \in A} w(v, u).$$

Denotamos por D la matriz diagonal de los grados, es decir, $D_{ii} = \deg v_i$.

Definición 1.2.4 (Volumen). Sea $G = (V, A, w)$ un grafo ponderado y $S \subset V$,

$$\text{vol } S \text{ es el volumen de } S \iff \text{vol } S = \sum_{v \in S} \deg v.$$

Definición 1.2.5 (Conexión). Sea $G = (V, A, w)$ un grafo ponderado y $S, T \subset V$,

$$\text{conn}(S, T) \text{ es la conexión entre } S \text{ y } T \iff \text{conn}(S, T) = \sum_{(u,v) \in A: u \in S, v \in T} w(u, v).$$

Definición 1.2.6 (Laplaciano de un grafo). Sea $G = (V, A, w)$ un grafo ponderado, L es el laplaciano de $G \iff L = D - W$, donde D es la matriz diagonal de los grados y W es la matriz de adyacencia ponderada.

¿Por qué se le llama Laplaciano?

Sea $V = \mathbb{N}_n$ y sea $f: V \rightarrow \mathbb{R}$ (escribimos $\forall i \in V : f_i := f(i)$). Entonces,

$$\langle f, Lf \rangle = \sum_{i=1}^n d_i f_i^2 - \sum_{i,j=1}^n w_{ij} f_i f_j = \sum_{i,j=1}^n w_{ij} (f_i^2 - f_i f_j) = \frac{1}{2} \sum_{i,j=1}^n w_{ij} (f_i - f_j)^2.$$

Para $f \in \mathcal{C}^2(\mathbb{R}^d)$ tal que $f, |\nabla f|, \Delta f \in L^2(\mathbb{R}^d)$, tenemos que $\langle f, \Delta f \rangle = \|\nabla f\|_{L^2(\mathbb{R}^d)}^2$.