

---

# MATEMÁTICAS PARA EL APRENDIZAJE AUTOMÁTICO

---

Cuarto del Grado en Matemáticas

**Hugo Marquerie**

Profesor: Davide Barbieri

Facultad de Ciencias - Universidad Autónoma de Madrid

Segundo cuatrimestre

fecha

*Puedes encontrar mi colección completa de apuntes en <https://hmarquer.github.io>.*

# Índice

|          |                                    |            |
|----------|------------------------------------|------------|
| <b>1</b> | <b>Aprendizaje no supervisado</b>  | <b>iii</b> |
| 1.1      | Principal component analysis (PCA) | iii        |
| 1.1.1    | Planteamiento del problema         | iii        |
| 1.1.2    | Solución (teorema y algoritmo)     | iii        |



# 1. Aprendizaje no supervisado

## 1.1 Principal component analysis (PCA)

### 1.1.1 Planteamiento del problema

Sean  $\{x_i\}_{i=1}^m \subset \mathbb{C}^n$  un conjunto de datos y sea  $k < m$ . El objetivo de PCA es encontrar la proyección de  $\mathbb{C}^n$  de rango  $k$  (proyección sobre un subespacio  $M \subset \mathbb{C}^n$  de dimensión  $k$ ) que minimice el error cuadrático entre los datos originales y los datos proyectados:

$$\mathcal{E} = \sum_{i=1}^m \|x_i - \mathbb{P}_M x_i\|^2,$$

donde  $\mathbb{P}_M$  es la proyección ortogonal sobre  $M$ . El PCA nos permite:

- Aproximar un conjunto de datos por un subespacio de dimensión menor.
- Una base ortonormal del subespacio  $M$  proporciona un diccionario “óptimo” para representar linealmente los datos.

### 1.1.2 Solución (teorema y algoritmo)

Sea  $A = \begin{pmatrix} | & | & \cdots & | \\ x_1 & x_2 & \cdots & x_m \\ | & | & \cdots & | \end{pmatrix} \in \mathbb{C}^{n \times m}$  y sea  $A = U\Sigma V^*$  su descomposición en valores singulares (SVD). Es decir,  $U \in \mathbb{C}^{n \times n}$  y  $V \in \mathbb{C}^{m \times m}$  son matrices unitarias y  $\Sigma \in \mathbb{R}_+^{n \times m}$  es una matriz diagonal con los valores singulares  $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$  en la diagonal, donde  $r = \text{rang}(A)$ . Entonces,  $M = \text{span}\{U^{(1)}, \dots, U^{(k)}\}$ , donde  $U^{(i)}$  es la  $i$ -ésima columna de  $U$ , es el subespacio que minimiza el error cuadrático  $\mathcal{E}$ . En consecuencia, la proyección ortogonal de los datos sobre  $M$  viene dada por

$$\forall x \in \mathbb{C}^n : \mathbb{P}_M x = \sum_{i=1}^k \langle x, U^{(i)} \rangle U^{(i)}.$$

**Teorema 1.1.1.** Sea  $A \in \mathbb{C}^{n \times m}$ ,  $A = U\Sigma V^*$  su SVD y  $k \leq \text{rang}(A)$ . Definimos

$$A_k = \sum_{i=1}^k \sigma_i U^{(i)} \otimes V^{(i)} \quad \text{donde} \quad (v \otimes w)_{ij} = v_i \overline{w_j}.$$

$$\implies \forall B \in \mathbb{C}^{n \times m} : \text{rang}(B) = k : \|A - B\|_{Fro}^2 \geq \|A - A_k\|_{Fro}^2 = \sum_{i=k+1}^{\text{rang } A} \sigma_i^2.$$

**¿Por qué nos vale esto?** La  $i$ -ésima columnas de  $A_k$  es  $A_k^{(i)} = \sum_{\ell=1}^k \sigma_\ell \overline{V_{i\ell}} U^{(\ell)}$  donde  $U^{(\ell)}$  es la  $\ell$ -ésima columna de  $U$  y  $\sigma_\ell \overline{V_{i\ell}} = \langle A^{(i)}, U^{(\ell)} \rangle = \langle x_i, U^{(\ell)} \rangle$ . Entonces,

$$A_k^{(i)} = \sum_{\ell=1}^k \langle x_i, U^{(\ell)} \rangle U^{(\ell)} = \mathbb{P}_{\text{span}\{U^{(1)}, \dots, U^{(k)}\}} x_i = \mathbb{P}_M x_i.$$

**Demostración:** Dividimos la demostración en diferentes pasos:

**Paso 1.** Recordamos que la norma de Frobenius se puede escribir como  $\|A\|_{\text{Fro}}^2 = \text{tr}(A^* A)$ .

Por tanto,

$$\begin{aligned} \|A - A_k\|_{\text{Fro}}^2 &= \|U\Sigma V^* - U\Sigma_k V^*\|_{\text{Fro}}^2 = \|U(\Sigma - \Sigma_k)V^*\|_{\text{Fro}}^2 \\ &= \text{tr}(V(\Sigma - \Sigma_k)^* V^*) = \sum_{\ell=k+1}^{\text{rang } A} \sigma_\ell^2, \end{aligned}$$

puesto que  $\Sigma - \Sigma_k$  es una matriz diagonal con los ceros en los primeros  $k$  elementos de la diagonal y los valores singulares  $\sigma_{k+1}, \dots, \sigma_r$  en el resto.

Por tanto, basta demostrar que  $\forall B \in \mathbb{C}^{n \times m} : \text{rang}(B) = k : \|A - B\|_{\text{Fro}}^2 \geq \sum_{\ell=k+1}^{\text{rang } A} \sigma_\ell^2$ .

**Paso 2.** Sea  $B \in \mathbb{C}^{n \times m}$  con  $\text{rang}(B) = k$ . Sea  $B = XTY^*$  su SVD, con  $X \in \mathbb{C}^{n \times n}$  y  $Y \in \mathbb{C}^{m \times m}$  unitarias y  $T \in \mathbb{R}_+^{n \times m}$  diagonal. Entonces,

$$\begin{aligned} \|A - B\|_{\text{Fro}}^2 &= \|A\|_{\text{Fro}}^2 + \text{tr}(B^* B - B^* A - A^* B) \\ &= \|A\|_{\text{Fro}}^2 + \sum_{\ell=1}^k t_\ell^2 - \sum_{\ell=1}^k t_\ell \text{tr}((y_\ell \otimes x_\ell)A + A^*(x_\ell \otimes y_\ell)), \end{aligned}$$

como  $\sum_{\ell=1}^k t_\ell^2 = \sum_{\ell=1}^k t_\ell^2 \text{tr}(C_{y_\ell \otimes y_\ell})$  y  $(y_\ell \otimes x_\ell)A = y_\ell \otimes (A^* x_\ell)$ , tenemos que

$$\begin{aligned} \|A - B\|_{\text{Fro}}^2 &= \|A\|_{\text{Fro}}^2 + \sum_{\ell=1}^k \text{tr}((A^* x_\ell - t_\ell y_\ell) \otimes (A^* x_\ell - t_\ell y_\ell)) - \sum_{\ell=1}^k \text{tr}(A^* x_\ell \otimes A^* x_\ell) \\ &\geq \|A\|_{\text{Fro}}^2 - \sum_{\ell=1}^k \|A^* x_\ell\|_{\mathbb{C}}^2, \end{aligned}$$

**Paso 3.**

■