
MATEMÁTICAS PARA EL APRENDIZAJE AUTOMÁTICO

Cuarto del Grado en Matemáticas

Hugo Marquerie

Profesor: Davide Barbieri

Facultad de Ciencias - Universidad Autónoma de Madrid

Segundo cuatrimestre

fecha

Puedes encontrar mi colección completa de apuntes en <https://hmarquer.github.io>.

Índice

1	Aprendizaje no supervisado	iii
1.1	Principal component analysis (PCA)	iii
1.1.1	Planteamiento del problema	iii
1.1.2	Solución (teorema y algoritmo)	iii
1.2	<i>Clustering</i> espectral en grafos	v
1.2.1	Grafos ponderados y definiciones básicas	v
1.2.2	El problema de corte normalizado (NCut)	vi
1.2.3	Formulación variacional para $k = 2$	vii
1.2.4	Relajación espectral del problema NCut	ix
1.2.5	Interpretación probabilística: caminos aleatorios	ix
1.2.6	<i>Spectral Clustering</i> para $k > 2$	x
1.2.7	Otros algoritmos de agrupamiento	xi
2	Aprendizaje supervisado	xv
2.1	Learning Theory	xv
2.1.1	Sobre el objetivo y el aprendizaje estadístico	xv

1. Aprendizaje no supervisado

1.1 Principal component analysis (PCA)

1.1.1 Planteamiento del problema

Sean $\{x_i\}_{i=1}^m \subset \mathbb{C}^n$ un conjunto de datos y sea $k < m$. El objetivo de PCA es encontrar la proyección de $\mathbb{C}^n$ de rango k (proyección sobre un subespacio $M \subset \mathbb{C}^n$ de dimensión k) que minimice el error cuadrático entre los datos originales y los datos proyectados:

$$\mathcal{E} = \sum_{i=1}^m \|x_i - \mathbb{P}_M x_i\|^2,$$

donde $\mathbb{P}_M$ es la proyección ortogonal sobre M . El PCA nos permite:

- Aproximar un conjunto de datos por un subespacio de dimensión menor.
- Una base ortonormal del subespacio M proporciona un diccionario “óptimo” para representar linealmente los datos.

1.1.2 Solución (teorema y algoritmo)

Sea $A = \begin{pmatrix} | & | & \cdots & | \\ x_1 & x_2 & \cdots & x_m \\ | & | & \cdots & | \end{pmatrix} \in \mathbb{C}^{n \times m}$ y sea $A = U\Sigma V^*$ su descomposición en valores singulares (SVD). Es decir, $U \in \mathbb{C}^{n \times n}$ y $V \in \mathbb{C}^{m \times m}$ son matrices unitarias y $\Sigma \in \mathbb{R}_+^{n \times m}$ es una matriz diagonal con los valores singulares $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$ en la diagonal, donde $r = \text{rang}(A)$.

Entonces, $M := \text{span}\{U^{(1)}, \dots, U^{(k)}\}$, donde $U^{(i)}$ es la i -ésima columna de U , es el subespacio que minimiza el error cuadrático $\mathcal{E}$. En consecuencia, la proyección ortogonal de los datos sobre M viene dada por

$$\forall x \in \mathbb{C}^n : \mathbb{P}_M x = \sum_{i=1}^k \langle x, U^{(i)} \rangle U^{(i)}.$$

Teorema 1.1.1. Sea $A \in \mathbb{C}^{n \times m}$, $A = U\Sigma V^*$ su SVD y $k \leq \text{rang}(A)$. Definimos

$$A_k = \sum_{i=1}^k \sigma_i U^{(i)} \otimes V^{(i)} \quad \text{donde} \quad (v \otimes w)_{ij} = v_i \overline{w_j}.$$

$$\implies \forall B \in \mathbb{C}^{n \times m} : \text{rang}(B) = k : \|A - B\|_{Fro}^2 \geq \|A - A_k\|_{Fro}^2 = \sum_{i=k+1}^{\text{rang } A} \sigma_i^2.$$

¿Por qué nos vale esto? La i -ésima columnas de A_k es $A_k^{(i)} = \sum_{\ell=1}^k \sigma_\ell \overline{V_{i\ell}} U^{(\ell)}$ donde $U^{(\ell)}$ es la ℓ -ésima columna de U y $\sigma_\ell \overline{V_{i\ell}} = \langle A^{(i)}, U^{(\ell)} \rangle = \langle x_i, U^{(\ell)} \rangle$. Entonces,

$$A_k^{(i)} = \sum_{\ell=1}^k \langle x_i, U^{(\ell)} \rangle U^{(\ell)} = \mathbb{P}_{\text{span}\{U^{(1)}, \dots, U^{(k)}\}} x_i = \mathbb{P}_M x_i.$$

Demostración: Dividimos la demostración en diferentes pasos:

Paso 1. Recordamos que la norma de Frobenius se puede escribir como $\|A\|_{\text{Fro}}^2 = \text{tr}(A^* A)$.

Por tanto,

$$\begin{aligned} \|A - A_k\|_{\text{Fro}}^2 &= \|U\Sigma V^* - U\Sigma_k V^*\|_{\text{Fro}}^2 = \|U(\Sigma - \Sigma_k)V^*\|_{\text{Fro}}^2 \\ &= \text{tr}(V(\Sigma - \Sigma_k)^* V^*) = \sum_{\ell=k+1}^{\text{rang } A} \sigma_\ell^2, \end{aligned}$$

puesto que $\Sigma - \Sigma_k$ es una matriz diagonal con los ceros en los primeros k elementos de la diagonal y los valores singulares $\sigma_{k+1}, \dots, \sigma_r$ en el resto.

Por tanto, basta demostrar que $\forall B \in \mathbb{C}^{n \times m} : \text{rang}(B) = k : \|A - B\|_{\text{Fro}}^2 \geq \sum_{\ell=k+1}^{\text{rang } A} \sigma_\ell^2$.

Paso 2. Sea $B \in \mathbb{C}^{n \times m}$ con $\text{rang}(B) = k$. Sea $B = XTY^*$ su SVD, con $X \in \mathbb{C}^{n \times n}$ y $Y \in \mathbb{C}^{m \times m}$ unitarias y $T \in \mathbb{R}_+^{n \times m}$ diagonal. Entonces,

$$\begin{aligned} \|A - B\|_{\text{Fro}}^2 &= \|A\|_{\text{Fro}}^2 + \text{tr}(B^* B - B^* A - A^* B) \\ &= \|A\|_{\text{Fro}}^2 + \sum_{\ell=1}^k t_\ell^2 - \sum_{\ell=1}^k t_\ell \text{tr}((y_\ell \otimes x_\ell)A + A^*(x_\ell \otimes y_\ell)), \end{aligned}$$

como $\sum_{\ell=1}^k t_\ell^2 = \sum_{\ell=1}^k t_\ell^2 \text{tr}(C_{y_\ell \otimes y_\ell})$ y $(y_\ell \otimes x_\ell)A = y_\ell \otimes (A^* x_\ell)$, tenemos que

$$\begin{aligned} \|A - B\|_{\text{Fro}}^2 &= \|A\|_{\text{Fro}}^2 + \sum_{\ell=1}^k \text{tr}((A^* x_\ell - t_\ell y_\ell) \otimes (A^* x_\ell - t_\ell y_\ell)) - \sum_{\ell=1}^k \text{tr}(A^* x_\ell \otimes A^* x_\ell) \\ &\geq \|A\|_{\text{Fro}}^2 - \sum_{\ell=1}^k \|A^* x_\ell\|^2, \end{aligned}$$

donde la desigualdad se obtiene porque $\text{tr}(v \otimes v) = \|v\|^2 \geq 0$.

Paso 3. Acotamos ahora $\sum_{\ell=1}^k \|A^* x_\ell\|^2$. Como $A = U\Sigma V^*$, tenemos que $A^* = V\Sigma^* U^*$, y por tanto $A^* x_\ell = V\Sigma^* U^* x_\ell$. Entonces,

$$\sum_{\ell=1}^k \|A^* x_\ell\|^2 = \sum_{\ell=1}^k \|V\Sigma^* U^* x_\ell\|^2 = \sum_{\ell=1}^k \|\Sigma^* U^* x_\ell\|^2,$$

donde hemos usado que V es unitaria y por tanto preserva la norma. Desarrollando la

norma,

$$\sum_{\ell=1}^k \|\Sigma^* U^* x_\ell\|^2 = \sum_{\ell=1}^k \sum_{i=1}^{\text{rang } A} \sigma_i^2 |\langle U^{(i)}, x_\ell \rangle|^2 = \sum_{i=1}^{\text{rang } A} \sigma_i^2 \sum_{\ell=1}^k |\langle U^{(i)}, x_\ell \rangle|^2.$$

Observamos que $\sum_{\ell=1}^k |\langle U^{(i)}, x_\ell \rangle|^2 = \|\mathbb{P}_k U^{(i)}\|^2$, donde $\mathbb{P}_k$ es el proyector ortogonal sobre $\text{span}\{x_1, \dots, x_k\}$. Denotando $p_i = \|\mathbb{P}_k U^{(i)}\|^2$, tenemos que:

- $p_i \leq 1$ para todo i , ya que $\|\mathbb{P}_k U^{(i)}\| \leq \|U^{(i)}\| = 1$.
- $\sum_{i=1}^{\text{rang } A} p_i \leq k$, ya que $\mathbb{P}_k$ proyecta sobre un subespacio de dimensión k .

Para maximizar $\sum_{i=1}^{\text{rang } A} \sigma_i^2 p_i$ sujeto a estas restricciones, como $\sigma_1 \geq \sigma_2 \geq \dots$, el máximo se alcanza cuando $p_1 = \dots = p_k = 1$ y $p_i = 0$ para $i > k$. Por tanto,

$$\sum_{\ell=1}^k \|A^* x_\ell\|^2 \leq \sum_{i=1}^k \sigma_i^2.$$

Paso 4. Retomando la cota del Paso 2,

$$\|A - B\|_{\text{Fro}}^2 \geq \|A\|_{\text{Fro}}^2 - \sum_{\ell=1}^k \|A^* x_\ell\|^2 \geq \|A\|_{\text{Fro}}^2 - \sum_{i=1}^k \sigma_i^2 = \sum_{i=k+1}^{\text{rang } A} \sigma_i^2,$$

lo que, junto con el Paso 1, concluye la demostración. ■

1.2 *Clustering* espectral en grafos

El objetivo del *clustering* espectral es particionar un conjunto de datos en grupos de manera que los elementos de un mismo grupo estén “más conectados” entre sí que con elementos de otros grupos. Para formalizar esto, representamos los datos como un grafo ponderado.

1.2.1 Grafos ponderados y definiciones básicas

Definición 1.2.1 (Grafo ponderado no dirigido). Un grafo ponderado no dirigido es una tupla $G = (V, W)$ donde:

- $V = \{v_1, \dots, v_m\}$ es el conjunto de vértices.
- $W \in \mathbb{R}^{m \times m}$ es la matriz de pesos, con $w_{ij} = w_{ji} \geq 0$.

Ejemplo 1.2.1. Sea (X, d) un espacio métrico y sea $\{x_i\}_{i=1}^m \subset X$ un conjunto de datos. Dado $\varepsilon > 0$, podemos construir un grafo ponderado donde $V = \{1, \dots, m\}$ y

$$w_{ij} = \begin{cases} e^{-d(x_i, x_j)^2} & \text{si } d(x_i, x_j) \leq \varepsilon, \\ 0 & \text{en otro caso.} \end{cases}$$

Este grafo captura las relaciones de vecindad entre los datos: cuanto más cercanos estén x_i y x_j , mayor será el peso w_{ij} .

Definición 1.2.2 (Grado, volumen y conexión). Sea $G = (V, W)$ un grafo ponderado.

- El **grado** del vértice i es $d_i = \sum_{j=1}^m w_{ij}$. Denotamos por $D = \text{diag}(d_1, \dots, d_m)$ la matriz diagonal de grados.
- El **volumen** de un subconjunto $S \subset V$ es $\text{vol}(S) = \sum_{i \in S} d_i$.
- La **conexión** entre $S, T \subset V$ es $W(S, T) = \sum_{i \in S} \sum_{j \in T} w_{ij}$.

Definición 1.2.3 (Laplaciano de un grafo). Sea $G = (V, W)$ un grafo ponderado. El **laplaciano** de G es la matriz $L = D - W$.

Observación 1.2.4 (Analogía con el laplaciano continuo). El nombre “laplaciano” proviene de la siguiente analogía. Sea $f: V \rightarrow \mathbb{R}$ una función sobre los vértices (escribimos $f_i = f(v_i)$). Entonces,

$$\langle f, Lf \rangle = \sum_{i=1}^m d_i f_i^2 - \sum_{i,j=1}^m w_{ij} f_i f_j = \frac{1}{2} \sum_{i,j=1}^m w_{ij} (f_i - f_j)^2.$$

Esta expresión mide la “variación” de f sobre el grafo, análogamente a cómo para $f \in \mathcal{C}^2(\mathbb{R}^d)$ con $f, |\nabla f|, \Delta f \in L^2(\mathbb{R}^d)$, se tiene $\langle f, -\Delta f \rangle_{L^2} = \|\nabla f\|_{L^2}^2$.

1.2.2 El problema de corte normalizado (NCut)

Definición 1.2.5 (Corte y corte normalizado). Sea $G = (V, W)$ un grafo ponderado y sea $\{A_j\}_{j=1}^k$ una partición de V (es decir, $V = \bigsqcup_{j=1}^k A_j$).

- El **corte** de la partición es

$$\text{cut}(\{A_j\}_{j=1}^k) = \sum_{j=1}^k W(A_j, A_j^c),$$

que mide el “costo” de separar el grafo en los subgrupos $A_1, \dots, A_k$.

- El **corte normalizado** (NCut) es

$$\text{Ncut}(\{A_j\}_{j=1}^k) = \sum_{j=1}^k \frac{W(A_j, A_j^c)}{\text{vol}(A_j)},$$

que penaliza además los grupos con volumen pequeño.

Observación 1.2.6. Para $k = 2$ (partición en dos grupos A y $B = A^c$), el corte normalizado se puede escribir como

$$\text{Ncut}(A, B) = W(A, B) \left(\frac{1}{\text{vol}(A)} + \frac{1}{\text{vol}(B)} \right).$$

Esta expresión es el producto de dos términos: la **separación** $W(A, B)$ (queremos que sea pequeña, es decir, A y B poco conectados) y el **balance** $\frac{1}{\text{vol}(A)} + \frac{1}{\text{vol}(B)}$ (que es mínimo cuando $\text{vol}(A) = \text{vol}(B)$). Por tanto, minimizar NCut favorece particiones con grupos bien separados y de tamaño equilibrado.

El **problema NCut** consiste en encontrar la partición que minimiza el corte normalizado:

$$\{A_j^*\}_{j=1}^k = \arg \min_{\{A_j\}_{j=1}^k \text{ partición}} \text{Ncut}(\{A_j\}_{j=1}^k).$$

1.2.3 Formulación variacional para $k = 2$

El siguiente lema relaciona el corte normalizado con una forma cuadrática.

Lema 1.2.1. Sea $V = A \cup B$ una partición y definamos $f^{(A,B)}: V \rightarrow \mathbb{R}$ por

$$f_i^{(A,B)} = \begin{cases} \sqrt{\frac{\text{vol}(B)}{\text{vol}(A)}} & \text{si } i \in A, \\ -\sqrt{\frac{\text{vol}(A)}{\text{vol}(B)}} & \text{si } i \in B. \end{cases}$$

Entonces,

$$\text{Ncut}(A, B) = \frac{1}{2 \text{vol}(V)} \sum_{i,j=1}^m w_{ij} (f_i^{(A,B)} - f_j^{(A,B)})^2.$$

Demostración: Observamos que $(f_i - f_j)^2 = 0$ si i, j están en el mismo grupo. Si $i \in A$ y $j \in B$ (o viceversa), entonces

$$(f_i - f_j)^2 = \left(\sqrt{\frac{\text{vol}(B)}{\text{vol}(A)}} + \sqrt{\frac{\text{vol}(A)}{\text{vol}(B)}} \right)^2 = \frac{\text{vol}(B)}{\text{vol}(A)} + \frac{\text{vol}(A)}{\text{vol}(B)} + 2.$$

Simplificando esta expresión y usando que $W(A, B) = W(B, A)$, se obtiene

$$\sum_{i,j=1}^m w_{ij}(f_i - f_j)^2 = 2W(A, B) \left(\frac{\text{vol}(B)}{\text{vol}(A)} + \frac{\text{vol}(A)}{\text{vol}(B)} + 2 \right) \cdot \frac{\text{vol}(A) \text{vol}(B)}{(\text{vol}(A) + \text{vol}(B))^2} \cdot \text{vol}(V),$$

que tras simplificar da $2 \text{vol}(V) \text{Ncut}(A, B)$. ■

Teorema 1.2.2. *El problema Ncut con $k = 2$ es equivalente al problema de optimización*

$$\arg \min \left\{ \frac{\langle f, Lf \rangle}{\langle f, Df \rangle} : \sum_{i=1}^m f_i d_i = 0, f_i \in \left\{ \pm \sqrt{\frac{\text{vol}(B)}{\text{vol}(A)}} \right\} \right\}.$$

Demostración: La demostración se divide en tres pasos:

Paso 1. Por la observación sobre el laplaciano, para cualquier $f \in \mathbb{R}^m$,

$$\langle f, Lf \rangle = \frac{1}{2} \sum_{i,j=1}^m w_{ij}(f_i - f_j)^2.$$

Paso 2. Sea $f: V \rightarrow \{p^2, -q^2\}$ y definamos $A = \{i : f_i = p^2\}$, $B = \{i : f_i = -q^2\}$. La restricción $\sum_{i=1}^m d_i f_i = 0$ implica

$$p^2 \text{vol}(A) = q^2 \text{vol}(B) \implies \frac{p^2}{q^2} = \frac{\text{vol}(B)}{\text{vol}(A)}.$$

De aquí se deduce que $f = pq f^{(A,B)}$ para cierto escalar pq .

Paso 3. Con f como en el paso anterior,

$$\langle f, Df \rangle = \sum_{i=1}^m d_i f_i^2 = p^4 \text{vol}(A) + q^4 \text{vol}(B) = p^2 q^2 \text{vol}(V).$$

Por tanto, usando el Lema 1.2.1,

$$\frac{\langle f, Lf \rangle}{\langle f, Df \rangle} = \frac{\langle f^{(A,B)}, Lf^{(A,B)} \rangle}{\langle f^{(A,B)}, Df^{(A,B)} \rangle} = \text{Ncut}(A, B).$$
■

Observación 1.2.7 (Complejidad computacional). El problema de optimización del Teorema 1.2.2 es **NP-completo**. Esto significa que, salvo que $P = NP$, no existe algoritmo que lo resuelva en tiempo polinomial.

1.2.4 Relajación espectral del problema NCut

Para obtener un algoritmo eficiente, relajamos el problema eliminando la restricción de que f tome valores discretos.

Observación 1.2.8 (Cambio de variable y cociente de Rayleigh). Sea $g = D^{1/2}f$ y definamos $M = D^{-1/2}LD^{-1/2}$ (el **laplaciano normalizado**). Entonces,

$$\frac{\langle f, Lf \rangle}{\langle f, Df \rangle} = \frac{\langle g, Mg \rangle}{\|g\|^2},$$

que es el **cociente de Rayleigh** de la matriz M . Además, M es simétrica y semidefinida positiva, con

$$\langle g, Mg \rangle = \frac{1}{2} \sum_{i,j=1}^m w_{ij} \left(\frac{g_i}{\sqrt{d_i}} - \frac{g_j}{\sqrt{d_j}} \right)^2 \geq 0.$$

La restricción $\sum_{i=1}^m d_i f_i = 0$ se traduce en $g \perp D^{1/2}\mathbf{1}$, donde $\mathbf{1}$ es el vector de unos.

El problema relajado consiste en minimizar el cociente de Rayleigh sobre todos los vectores $g \perp D^{1/2}\mathbf{1}$:

$$\min_{g \perp D^{1/2}\mathbf{1}} \frac{\langle g, Mg \rangle}{\|g\|^2}.$$

Por el teorema del cociente de Rayleigh (ver Apéndice), el mínimo se alcanza en el autovector de M correspondiente al segundo menor autovalor (el menor autovalor es 0 con autovector $D^{1/2}\mathbf{1}$).

Algoritmo de *Spectral Clustering* para $k = 2$:

1. Calcular el autovector g_2 de $M = D^{-1/2}LD^{-1/2}$ correspondiente al menor autovalor no nulo.
2. Definir la partición: $A = \{i \in V : g_2(i) > 0\}$ y $B = A^c$.

1.2.5 Interpretación probabilística: caminos aleatorios

La matriz $P = D^{-1}W$ es una **matriz de transición de Markov**:

$$p_{ij} = \frac{w_{ij}}{d_i} = \frac{w_{ij}}{\sum_{k=1}^m w_{ik}}, \quad \text{con } \sum_{j=1}^m p_{ij} = 1.$$

Es decir, $p_{ij} = \mathbb{P}(i \rightarrow j)$ es la probabilidad de transitar del vértice i al vértice j en un paso del camino aleatorio sobre el grafo. La distribución estacionaria es $\pi_i = \frac{d_i}{\text{vol}(V)}$.

Proposición 1.2.3. Sea $\{X_t\}_{t \geq 0}$ el camino aleatorio sobre G con $X_0 \sim \pi$. Entonces,

$$\mathbb{P}(X_t \in A \mid X_{t-1} \in B) + \mathbb{P}(X_t \in B \mid X_{t-1} \in A) = \text{Ncut}(A, B).$$

Demostración: Calculamos directamente:

$$\mathbb{P}(X_0 \in A, X_1 \in B) = \sum_{i \in A} \sum_{j \in B} \pi_i p_{ij} = \frac{1}{\text{vol}(V)} \sum_{i \in A} \sum_{j \in B} w_{ij} = \frac{W(A, B)}{\text{vol}(V)}.$$

Como $\mathbb{P}(X_0 \in A) = \frac{\text{vol}(A)}{\text{vol}(V)}$, se tiene

$$\mathbb{P}(X_1 \in B \mid X_0 \in A) = \frac{W(A, B)}{\text{vol}(A)}.$$

El mismo argumento da $\mathbb{P}(X_1 \in A \mid X_0 \in B) = \frac{W(B, A)}{\text{vol}(B)}$, y sumando obtenemos $\text{Ncut}(A, B)$. ■

Esta proposición nos da una interpretación intuitiva: **minimizar NCut equivale a minimizar la probabilidad de que un camino aleatorio “salte” entre grupos.**

1.2.6 Spectral Clustering para $k > 2$

Lema 1.2.4. Sea $G = (V, W)$ un grafo con K componentes conexas $V = \bigsqcup_{\ell=1}^K A_\ell$ (es decir, $w_{ij} = 0$ si $i \in A_\ell, j \in A_{\ell'}$ con $\ell \neq \ell'$). Entonces,

$$\ker L = \text{span}\{\chi_{A_1}, \dots, \chi_{A_K}\},$$

donde χ_{A_ℓ} es la función indicadora de A_ℓ .

Demostración: Para $K = 1$ (grafo conexo), $\langle f, Lf \rangle = \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2 = 0$ implica $f_i = f_j$ para todos los pares con $w_{ij} > 0$, es decir, $f = \alpha \mathbf{1}$.

Para $K > 1$, el laplaciano tiene estructura de bloques diagonal (tras reordenar los vértices), y el resultado se aplica a cada bloque. ■

Observación 1.2.9 (Heurística para grafos “casi” desconectados). Si el grafo es conexo pero tiene K grupos “naturales” (muy conectados internamente, poco conectados entre sí), entonces:

- El autovector de M con autovalor 0 es $D^{1/2} \mathbf{1}$.
- Los siguientes $K - 1$ autovectores son aproximadamente $D^{1/2} \chi_{A_\ell}$, correspondientes a

autovalores pequeños.

Algoritmo de Shi-Malik:

1. Calcular los $k + 1$ autovectores de M con menores autovalores: $\{(\lambda_\ell, f_\ell)\}_{\ell=1}^{k+1}$ con $\lambda_1 = 0 < \lambda_2 \leq \dots \leq \lambda_{k+1}$.
2. Representar cada vértice v_i mediante el *embedding*

$$\varphi(v_i) = (f_2(v_i), \dots, f_{k+1}(v_i)) \in \mathbb{R}^k.$$

Esta técnica se conoce como *Laplacian Eigenmaps*.

3. Aplicar un algoritmo de agrupamiento clásico (como k -means) sobre los puntos $\{\varphi(v_i)\}_{i=1}^m \subset \mathbb{R}^k$.

Observación 1.2.10 (Elección de k). El número de grupos k se puede estimar buscando un “codo” en el espectro de M : un salto significativo entre λ_k y λ_{k+1} sugiere que hay k grupos bien definidos.

1.2.7 Otros algoritmos de agrupamiento

Definición 1.2.11 (K -means). Sean $\mathcal{D} = \{x_i\}_{i=1}^m \subset \mathbb{R}^N$ y $K \in \mathbb{N}$. El problema de K -means consiste en encontrar una partición $\mathcal{D} = \bigsqcup_{\ell=1}^K S_\ell$ que minimice

$$\sum_{\ell=1}^K \sum_{x \in S_\ell} \|x - \mu_\ell\|^2, \quad \text{donde } \mu_\ell = \frac{1}{|S_\ell|} \sum_{x \in S_\ell} x$$

es el centroide del grupo S_ℓ .

Observación 1.2.12. El problema de K -means es NP-completo. Los algoritmos prácticos (como el algoritmo de Lloyd) son heurísticas que encuentran mínimos locales.

Definición 1.2.13 (Agrupamiento jerárquico aglomerativo). Sea $\mathcal{D} = \{x_i\}_{i=1}^m \subset (X, d)$ un espacio métrico y sea $R: \mathcal{P}(X) \times \mathcal{P}(X) \rightarrow \mathbb{R}$ una distancia entre subconjuntos (por ejemplo, *single linkage*, *complete linkage* o *average linkage*).

- (i) Inicialmente, cada punto forma su propio grupo.
- (ii) Iterativamente, se fusionan los dos grupos más cercanos según R .
- (iii) Se construye un **dendrograma** que representa la jerarquía de fusiones.
- (iv) Se corta el dendrograma a un nivel t para obtener la partición final.

Observación 1.2.14. La elección del nivel de corte t es análoga a la búsqueda de un “codo” en el espectro del laplaciano.

Apéndice de Álgebra Lineal

Este apéndice recoge resultados de álgebra lineal utilizados en el capítulo, particularmente en la sección de clustering espectral.

Matrices autoadjuntas

Lema 1.2.5 (Caracterización de matrices autoadjuntas). *Sea $A \in \mathbb{C}^{m \times m}$ una matriz. Si $\langle Av, v \rangle_{\mathbb{C}^m} \in \mathbb{R}$ para todo $v \in \mathbb{C}^m$, entonces A es autoadjunta, es decir, $A = A^*$.*

Demostración: Definimos $M = A - A^*$ y mostramos que $M = 0$.

Paso 1. Como $\langle Av, v \rangle \in \mathbb{R}$ para todo v , tenemos que $\langle Av, v \rangle = \overline{\langle Av, v \rangle} = \langle v, Av \rangle$. Por tanto,

$$\langle Mv, v \rangle = \langle Av, v \rangle - \langle A^*v, v \rangle = \langle Av, v \rangle - \langle v, Av \rangle = 0.$$

Paso 2. Usando la identidad de polarización, para cualesquiera $v, w \in \mathbb{C}^m$:

$$\langle M(v + w), v + w \rangle - \langle M(v - w), v - w \rangle = 2 \langle Mv, w \rangle + 2 \langle Mw, v \rangle.$$

Por el Paso 1, el lado izquierdo es cero, luego $\langle Mv, w \rangle = -\langle Mw, v \rangle$.

Como $\langle Mw, v \rangle = \overline{\langle v, Mw \rangle}$ y $\langle v, Mw \rangle = \overline{\langle Mw, v \rangle}$, se tiene $\langle Mv, w \rangle = -\langle Mw, v \rangle = -\overline{\langle v, Mw \rangle}$. Sustituyendo $\langle Mw, v \rangle = -\langle Mv, w \rangle$:

$$\langle Mv, w \rangle = -\overline{\langle Mv, w \rangle} \implies \langle Mv, w \rangle \in i\mathbb{R}.$$

Paso 3. Análogamente, considerando $v + iw$ y $v - iw$:

$$\langle M(v + iw), v + iw \rangle - \langle M(v - iw), v - iw \rangle = 2i \langle Mv, w \rangle - 2i \langle Mw, v \rangle.$$

Por el Paso 1, esto es cero, luego $\langle Mv, w \rangle = \langle Mw, v \rangle$.

Paso 4. Combinando los Pasos 2 y 3: del Paso 2 tenemos $\langle Mv, w \rangle = -\langle Mw, v \rangle$, y del Paso 3 tenemos $\langle Mv, w \rangle = \langle Mw, v \rangle$. Por tanto, $\langle Mv, w \rangle = -\langle Mw, v \rangle$, lo que implica $\langle Mv, w \rangle = 0$ para todos $v, w \in \mathbb{C}^m$. Luego $M = 0$.

■

Observación 1.2.15 (Aplicación al laplaciano normalizado). En el contexto del clustering espectral, la matriz $M = D^{-1/2}LD^{-1/2}$ satisface

$$\langle Mg, g \rangle = \frac{1}{2} \sum_{i,j=1}^m w_{ij} \left| \frac{g_i}{\sqrt{d_i}} - \frac{g_j}{\sqrt{d_j}} \right|^2 \in \mathbb{R}_{\geq 0}$$

para todo $g \in \mathbb{C}^m$. Por el lema anterior, M es autoadjunta (y además semidefinida positiva).

El cociente de Rayleigh

Definición 1.2.16 (Cociente de Rayleigh). Sea $M \in \mathbb{R}^{m \times m}$ una matriz simétrica. El **cociente de Rayleigh** de M es la función $R_M: \mathbb{R}^m \setminus \{0\} \rightarrow \mathbb{R}$ definida por

$$R_M(x) = \frac{\langle Mx, x \rangle}{\|x\|^2}.$$

Lema 1.2.6 (Teorema min-max de Rayleigh). Sea $M \in \mathbb{R}^{m \times m}$ simétrica y semidefinida positiva. Sean $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_m$ sus autovalores (contados con multiplicidad) y $\{v_1, \dots, v_m\}$ una base ortonormal de autovectores correspondientes. Entonces:

$$\min_{x \in \mathbb{R}^m \setminus \{0\}} R_M(x) = \lambda_1, \quad \text{con} \quad \arg \min_{x \neq 0} R_M(x) = \ker(M - \lambda_1 I).$$

Demostración: Como $\{v_1, \dots, v_m\}$ es una base ortonormal, cualquier $x \in \mathbb{R}^m$ se escribe como $x = \sum_{i=1}^m c_i v_i$ con $c_i = \langle x, v_i \rangle$. Entonces:

$$Mx = \sum_{i=1}^m \lambda_i c_i v_i, \quad \|x\|^2 = \sum_{i=1}^m c_i^2, \quad \langle Mx, x \rangle = \sum_{i=1}^m \lambda_i c_i^2.$$

Definiendo $p_i = \frac{c_i^2}{\sum_{j=1}^m c_j^2}$, tenemos que $p_i \geq 0$ y $\sum_{i=1}^m p_i = 1$. Por tanto,

$$R_M(x) = \sum_{i=1}^m \lambda_i p_i$$

es una combinación convexa de los autovalores. El mínimo de una combinación convexa se alcanza en el menor de los valores, es decir, $R_M(x) \geq \lambda_1$, con igualdad si y solo si $p_1 = 1$ (y $p_i = 0$ para $i > 1$), lo que ocurre cuando $x \in \ker(M - \lambda_1 I)$. ■

Corolario 1.2.7 (Segundo autovalor). Con la notación del lema anterior, si $V_1 = \ker(M - \lambda_1 I)$ es el autoespacio correspondiente a λ_1 , entonces

$$\min_{x \perp V_1, x \neq 0} R_M(x) = \lambda_2.$$

Más generalmente, para $k \geq 1$:

$$\lambda_k = \min_{\substack{x \perp v_1, \dots, v_{k-1} \\ x \neq 0}} R_M(x).$$

Demostración: Si $x \perp V_1$, entonces $c_i = 0$ para todo i tal que $\lambda_i = \lambda_1$. Por tanto, $R_M(x) = \sum_{\lambda_i > \lambda_1} \lambda_i p_i \geq \lambda_2$, con igualdad cuando x es autovector de λ_2 . ■

Observación 1.2.17 (Aplicación al clustering espectral). En el problema NCut relajado, buscamos minimizar $R_M(g) = \frac{\langle Mg, g \rangle}{\|g\|^2}$ sujeto a $g \perp D^{1/2}\mathbf{1}$. Como $D^{1/2}\mathbf{1}$ es el autovector de M con autovalor $\lambda_1 = 0$, el Corolario 1.2.7 nos dice que el mínimo se alcanza en el autovector correspondiente al segundo menor autovalor λ_2 .

2. Aprendizaje supervisado

2.1 Learning Theory

Sea Z un espacio topológico de Hausdorff, y sea $\mathcal{B}$ la σ -álgebra de Borel de Z . Sea $(Z, \mathcal{B}, \rho)$ un espacio de probabilidad.

- ρ medida desconocida.
- Z tiene estructura natural de producto $Z = X \times Y$ (la proporcionada por el problema concreto).
- Nos interesa el fenómeno de generación de datos en Z descrito por ρ desde el punto de vista de la dependencia de Y de X .

El objetivo es aproximar la **función de regresión**, es decir, la función $f_\rho: X \rightarrow Y$ que asigna a cada $x \in X$ el valor esperado de y condicionado a x :

$$f_\rho(x) := \int_Y y \, d\rho(y \mid x),$$

donde $\rho(y \mid x)$ es la medida de probabilidad condicional de y dado x .

Sea $\pi: Z \rightarrow X$ la proyección $\pi(x, y) = x$. Sea ρ_X la medida de probabilidad marginal en X definida en $E \subset X$ abierto por $\rho_X(E) = \rho(\pi^{-1}(E))$.

Entonces existe la medida de probabilidad condicional que satisface, $\forall \varphi \in L^1(Z, \rho)$:

$$\begin{aligned} \int_Z \varphi(z) \, d\rho(z) &= \int_X \left(\int_Y \varphi(x, y) \, d\rho(y \mid x) \right) d\rho_X(x), \\ \int_Y d\rho(y \mid x) &= 1 \quad \rho_X\text{-casi todo } x \in X. \end{aligned}$$

2.1.1 Sobre el objetivo y el aprendizaje estadístico

- Como no se dispone de ρ (desconocida), hay que trabajar con **muestras**:

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset Z.$$

- Aprendizaje *supervisado*: para todo $x_i \in X$ hay un $y_i \in Y$ que proporciona un objetivo.
- El resultado de todo aprendizaje es epistemológicamente una aproximación, porque la búsqueda de una función de regresión se tiene que hacer dentro de un **espacio de las**

hipótesis definido *a priori* antes de conocer ρ .

Ejemplo 2.1.1 (Best fit polinomial de datos físicos). Supongamos que una ley física $F: \mathbb{R} \rightarrow \mathbb{R}$, y fenómenos aleatorios (es decir, que se escapan a nuestro conocimiento), generan datos:

$$y_i = F(x_i) + \varepsilon_i, \quad \text{donde } \{\varepsilon_i\}_{i=1}^m \text{ son v.a.i.i.d.}$$

Si queremos aproximar F con un polinomio de grado $\leq n$, podemos intentar minimizar

$$\sum_{i=1}^m |y_i - f_w(x_i)|^2, \quad \text{para } f_w(x) = \sum_{i=0}^n w_i x^i.$$

¿Cómo encaja el ejemplo con el problema general?

Supongamos que $\varepsilon \sim \mathcal{N}(0, 1)$, $X = [0, 1]$, ρ_X distribución uniforme en X .

- $\mathcal{F} = F(x)$ es una variable aleatoria en $F(X)$ con medida de probabilidad

$$\mu(\mathcal{F} < t) = \rho_X(\{x : F(x) < t\}) = \rho_X(F^{-1}(-\infty, t)) = F_*\rho_X(-\infty, t),$$

donde $F_*\rho_X$ es la medida pushforward.

- Si $y = F(x)$, se define una medida de probabilidad condicional $\rho(y | x)$ tal que

$$\int_{\mathbb{R}} \varphi(y) d\rho(y | x) = \varphi(F(x)) \quad \forall \varphi \in C_c(\mathbb{R}),$$

que corresponde a una δ de Dirac en $y = F(x)$.

- La probabilidad condicional $\rho(y | x)$ para $y = F(x) + \varepsilon$ es $\mathcal{N}(F(x), 1)$, por lo que

$$d\rho(x, y) = e^{-\frac{(y-F(x))^2}{2}} \rho_X(dx) dy.$$

- Por lo tanto, tenemos que

$$f_\rho(x) = \int_Y y d\rho(y | x) = F(x).$$

La minimización de

$$\sum_{i=1}^m |y_i - f_w(x_i)|^2$$

proporciona una aproximación polinomial empírica de la ley F .

Definición 2.1.1 (Error cuadrático). Sea $Y = \mathbb{R}^k$, ρ una probabilidad en $\mathcal{Z} = X \times Y$, $f : X \rightarrow Y$ una función ρ -medible, y $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset \mathcal{Z}$ un conjunto de datos. Definimos:

$$\mathcal{E}[f] := \int_{\mathcal{Z}} |f(x) - y|^2 d\rho(x, y) \quad (\text{Error de generalización}),$$

$$\mathcal{E}_{\mathcal{D}}[f] := \frac{1}{m} \sum_{i=1}^m |f(x_i) - y_i|^2 \quad (\text{Error empírico}).$$

Proposición 2.1.1. *Para toda función $f : X \rightarrow Y$ ρ -medible, se cumple que:*

$$\mathcal{E}[f] = \int_X |f(x) - f_{\rho}(x)|^2 d\rho_X(x) + \mathcal{E}[f_{\rho}],$$

donde $f_{\rho}(x)$ es el valor esperado condicional definido como:

$$f_{\rho}(x) = \int_Y y d\rho(y | x).$$

La primera integral representa el *error de aproximar f_{ρ} con f* , mientras que $\mathcal{E}[f_{\rho}]$ es el *error intrínseco* debido a la variabilidad de la distribución conjunta ρ en Z . Más específicamente:

$$\mathcal{E}[f_{\rho}] = \int_X \left(\int_Y |f_{\rho}(x) - y|^2 d\rho(y | x) \right) d\rho_X(x),$$

donde el término interno mide la *varianza en y* de la distribución condicional $\rho(y | x)$ respecto a su valor medio $f_{\rho}(x)$.

Demostración:

$$\begin{aligned} \mathcal{E}[f] &= \int_{X \times Y} |f(x) - y|^2 d\rho(x, y) \\ &= \int_{X \times Y} |f(x) - y + f_{\rho}(x) - f_{\rho}(x)|^2 d\rho(x, y) \\ &= \int_{X \times Y} |f(x) - f_{\rho}(x)|^2 d\rho(x, y) + \int_{X \times Y} |f_{\rho}(x) - y|^2 d\rho(x, y) \\ &\quad + 2 \int_{X \times Y} (f(x) - f_{\rho}(x))(f_{\rho}(x) - y) d\rho(x, y) \\ &= \int_X |f(x) - f_{\rho}(x)|^2 d\rho_X(x) + \mathcal{E}[f_{\rho}] + 2\mathcal{I}[f, f_{\rho}], \\ \mathcal{I}[f, f_{\rho}] &= \int_X (f(x) - f_{\rho}(x)) \left(\int_Y (f_{\rho}(x) - y) d\rho(y | x) \right) d\rho_X(x). \end{aligned}$$

■

Definición 2.1.2 (Hipótesis y función objetivo). Sea $\mathcal{H}$ un conjunto de funciones $X \rightarrow Y$ y $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset X \times Y$ un conjunto de datos. Denotamos por $f_{\mathcal{H}}$ y por $f_{\mathcal{H}, \mathcal{D}}$ a las funciones de $\mathcal{H}$ tales que:

$$\forall f \in \mathcal{H} : \mathcal{E}[f_{\mathcal{H}}] \leq \mathcal{E}[f],$$

$$\forall f \in \mathcal{H} : \mathcal{E}_{\mathcal{D}}[f_{\mathcal{H}, \mathcal{D}}] \leq \mathcal{E}_{\mathcal{D}}[f].$$

Observación 2.1.3. $g = f_{\mathcal{H}} \iff \forall f \in \mathcal{H} : \|f_{\mathcal{H}} - f_{\rho}\|_{L^2(\rho_X)} \leq \|f - f_{\rho}\|_{L^2(\rho_X)}.$

Definición 2.1.4. $\mathcal{C}_b(X) = \mathcal{C}(X) \cap \mathcal{L}^{\infty}(X).$

Teorema 2.1.2. Sea X un espacio métrico, $M > 0$ y $\mathcal{H}_M \subset \mathcal{C}_b(X)$ compacto en $(\mathcal{C}(X), \|\cdot\|_{\infty})$ tal que $\forall f \in \mathcal{H}_M : |f(x) - y| \leq M$ ρ -c.s..

$$\implies \exists f_{\mathcal{H}_M} \in \mathcal{H}_M \wedge \forall \mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset X \times Y : \exists f_{\mathcal{H}_M, \mathcal{D}}.$$

Demostración: La prueba consiste en demostrar que $\mathcal{E}$ y $\mathcal{E}_{\mathcal{D}}$ son continuas como funciones de $\mathcal{H}_M \rightarrow \mathbb{R}_+$ según la norma $\|\cdot\|_{\infty}$ en $\mathcal{H}_M$ y la usual en $\mathbb{R}_+$. Sean $f_1, f_2 \in \mathcal{H}_M$, entonces

$$\begin{aligned} |\mathcal{E}[f_1] - \mathcal{E}[f_2]| &= \left| \int_Z (|f_1(x) - y|^2 - |f_2(x) - y|^2) d\rho(x, y) \right| \\ &= \left| \int_Z ((f_1(x) + f_2(x) - 2y) \cdot (f_1(x) - f_2(x))) d\rho(x, y) \right| \\ &\leq \|f_1 - f_2\|_{\infty} \int_Z (|f_1(x) - y| + |f_2(x) - y|) d\rho(x, y) \\ &\leq 2M \|f_1 - f_2\|_{\infty}. \end{aligned}$$

Por tanto, $\mathcal{E}$ es continua. Análogamente, $\mathcal{E}_{\mathcal{D}}$ es continua.

Como $\mathcal{H}_M$ es compacto, entonces existen $f_{\mathcal{H}_M}$ y $f_{\mathcal{H}_M, \mathcal{D}}$ que minimizan $\mathcal{E}$ y $\mathcal{E}_{\mathcal{D}}$ respectivamente (por el teorema de Weierstrass). ■

The Bias-Variance Tradeoff

El objetivo del aprendizaje es establecer una clase $\mathcal{H}$ buena y encontrar $f_{\mathcal{H}, \mathcal{D}}$ tal que exista $f_{\mathcal{H}, \infty}$ y sea pequeño el error de generalización $\mathcal{E}[f_{\mathcal{H}, \mathcal{D}}]$.

Si reescribimos

$$\mathcal{E}[f_{\mathcal{H}, \mathcal{D}}] = \mathcal{E}[f_{\mathcal{H}, \infty}] - \mathcal{E}[f_{\mathcal{H}}] + \mathcal{E}[f_{\mathcal{H}}],$$

donde

VARIANCE $V(\mathcal{H}, \mathcal{D}, \rho)$ y BIAS.

- Si $\mathcal{H}$ es fijo y se aumenta el tamaño m de la muestra $\mathcal{D}$, entonces $V \rightarrow 0$ (bajo hipótesis oportunas).
- Si fijamos la muestra $\mathcal{D}$ y ampliamos $\mathcal{H}$, $\mathcal{E}[f_{\mathcal{H}}]$ se puede hacer pequeño, porque se reduce el error de aproximación $\|f_{\mathcal{H}} - f_{\rho}\|_{L^2(\rho_X)}$, pero se observa que V crece, por el fenómeno del *overfitting*: un modelo $\mathcal{H}$ demasiado grande hace $\mathcal{E}_{\mathcal{D}}(f_{\mathcal{H}, \mathcal{D}})$ muy pequeño, pero generaliza mal.

2.2 Reproducing Kernel Hilbert Spaces

Definición 2.2.1. Un núcleo de Mercer sobre un espacio topológico X es una $K : X \times X \rightarrow \mathbb{F}$ t.q.:

- (i) continua,
- (ii) hermitica: $K(x, y) = \overline{K(y, x)}$,
- (iii) semidefinida positiva: $\forall \{x_i\}_{i=1}^m \subset X$, la matriz $M_{ij} = K(x_i, x_j)$ es $M \geq 0$.

Teorema 2.2.1. Sea $K : X \times X \rightarrow \mathbb{F}$ un núcleo de Mercer y para $x \in X$, sea $K_x : X \rightarrow \mathbb{F}$, $K_x(y) = K(y, x)$. Entonces, existe un único espacio de Hilbert H_K sobre $\mathbb{F}$ t.q.:

- (1) $\{K_x : x \in X\}$ denso en H_K ,
- (2) $\forall f \in H_K$, $f(x) = \langle f, K_x \rangle_{H_K} \quad \forall x \in X$.

A H_K se le llama RKHS asociado a K .

Además, si K es acotado ($K \in C_b(X \times X)$) entonces $H_K \subset C(X)$ (y la inclusión es continua).

Demostración: H_K se construye como la completación de $\mathring{H} = \text{span}\{K_x : x \in X\} \subset C(X)$.

- Sean $f, g \in \mathring{H}$, con $f = \sum_{j=1}^N c_j K_{x_j}$ y $g = \sum_{j=1}^N d_j K_{x_j}$. Definimos:

$$\langle f, g \rangle_K := \sum_{i,j=1}^N c_i \overline{d_j} K(x_i, x_j).$$

- Como K es un núcleo de Mercer, se tiene $\langle f, f \rangle_K \geq 0 \quad \forall f \in \mathring{H}$. Además, por

definición, si $f \in \mathring{H}$:

$$f(x) = \sum_{j=1}^N c_j K_{x_j}(x) = \langle f, K_x \rangle_K.$$

- Para todo $f \in \mathring{H}$, si $\langle f, f \rangle_K = 0$, entonces $f = 0$, porque:

$$|f(x)|^2 = |\langle f, K_x \rangle_K|^2 \leq \langle f, f \rangle_K K(x, x) \quad (\text{desigualdad de Cauchy-Schwarz}).$$

Por lo tanto, definimos la norma:

$$\|f\|_K := \sqrt{\langle f, f \rangle_K}.$$

Así, $H_K := \mathring{H}^{\|\cdot\|_K}$ es un espacio de Hilbert.

- Por la desigualdad de Cauchy-Schwarz, si $K \in C_b$, entonces $\sup_{x \in X} K(x, x) = C_K < \infty$. Por lo tanto:

$$\|f\|_\infty \leq C_K \|f\|_K \quad \forall f \in H_K.$$

Esto implica que si $f \in H_K$, entonces $\{f_\nu\} \subset H_K \implies \{f_\nu\} \subset C(X)$ y:

$$\|f_\nu - f\|_\infty \leq C_K \|f_\nu - f\|_K \rightarrow 0 \implies f \in C(X).$$

■

Ejemplo 2.2.1 (Gaussian RBF (Radial Basis Function)). Sean $X \subset \mathbb{R}^d$, $\alpha > 0$, $K_\alpha(x, y) := e^{-\alpha\|x-y\|^2}$. Entonces $K \in C_b(X \times X)$ y $K(x, y) = K(y, x)$.

Veamos que K_α es semidefinido positivo.

1. Sea $\alpha = \pi$ (sin pérdida de generalidad). Entonces $K_\pi(x, y) = g(x - y)$, donde $g(x) = e^{-\pi\|x\|^2}$.
2. Sea $\mathcal{F} : L^2(\mathbb{R}^d) \rightarrow L^2(\mathbb{R}^d)$ la transformada de Fourier. Para $f \in L^2(\mathbb{R}^d)$, definimos:

$$\mathcal{F}(f)(\xi) := \int_{\mathbb{R}^d} e^{-2\pi i \langle \xi, x \rangle} f(x) dx.$$

Entonces:

$$\mathcal{F}(g)(\xi) = \int_{\mathbb{R}^d} e^{-2\pi i \langle \xi, x \rangle} e^{-\pi\|x\|^2} dx.$$

Como $x = (x_1, \dots, x_d) \in \mathbb{R}^d$, tenemos:

$$\mathcal{F}(g)(\xi) = \prod_{j=1}^d \int_{\mathbb{R}} e^{-2\pi i \xi_j x_j} e^{-\pi x_j^2} dx_j = e^{-\pi\|\xi\|^2}.$$

Por lo tanto, g es autofunción del operador $\mathcal{F}$.

Además, por el teorema de inversión de $\mathcal{F}$:

$$g(x) = \int_{\mathbb{R}^d} e^{2\pi i \langle \xi, x \rangle} e^{-\pi \|\xi\|^2} d\xi.$$

3. Sean $\{x_i\}_{i=1}^m \subset \mathbb{R}^d$, $M_{ij} = K(x_i, x_j)$ y $v \in \mathbb{R}^m$. Entonces:

$$\langle v, Mv \rangle_{\mathbb{R}^m} = \sum_{i,j=1}^m v_i K(x_i, x_j) v_j = \sum_{i,j=1}^m v_i v_j g(x_i - x_j).$$

Sustituyendo $g(x) = \int_{\mathbb{R}^d} e^{-2\pi i \langle \xi, x \rangle} e^{-\pi \|\xi\|^2} d\xi$, obtenemos:

$$\langle v, Mv \rangle_{\mathbb{R}^m} = \sum_{i,j=1}^m \int_{\mathbb{R}^d} (v_i e^{2\pi i \langle \xi, x_i \rangle}) (v_j e^{-2\pi i \langle \xi, x_j \rangle}) e^{-\pi \|\xi\|^2} d\xi.$$

Reordenando:

$$\langle v, Mv \rangle_{\mathbb{R}^m} = \int_{\mathbb{R}^d} \left| \sum_{i=1}^m v_i e^{2\pi i \langle \xi, x_i \rangle} \right|^2 e^{-\pi \|\xi\|^2} d\xi \geq 0.$$

“ Los elementos del Gaussian RBF RKHS son (límites de) combinaciones lineales de gaussianas centradas en varios puntos de $\mathbb{R}^d$:

$$f \in \mathcal{H}_{K_\alpha} \implies f(x) = \sum_{j=1}^m c_j e^{-\alpha \|x - x_j\|^2}.$$

Note: en Steinwart, Hush ”An explicit description of the RKHS of Gaussian RBF Kernels”, *IEEE Trans. Information Theory* 52 (2006) se demuestra que, en $X = \mathbb{C}^d$, si tomamos

$$K_\alpha(z, w) = e^{-\alpha \sum_{j=1}^d (z_j - \bar{w}_j)^2},$$

entonces

$$\mathcal{H}_{K_\alpha} = \left\{ f \in \text{Hol}(\mathbb{C}^d) \text{ tales que } \|f\| := \left(\frac{2^d \alpha^d}{\pi^d} \int_{\mathbb{C}^d} |f(z)|^2 e^{\alpha \sum_{j=1}^d |z_j|^2} dz \right)^{1/2} < \infty \right\},$$

un espacio de Hilbert de funciones holomorfas.

$$\implies \mathcal{H}_{K_\alpha}(\mathbb{R}^d) = \{f|_{\mathbb{R}^d} : f \in \mathcal{H}_{K_\alpha}\}, \text{ funciones reales analíticas.}$$

(restricción a $\mathbb{R}^d$ de las funciones de $\mathcal{H}_{K_\alpha}$)

El RKHS de $K_\alpha(x, y) = e^{-\alpha \|x - y\|^2}$, con $X = \mathbb{R}^d$. “

Peso II: $\overline{B} \subset C(X)$ es equicontinuo

$\forall x \in X, \forall \varepsilon > 0 \exists V^\varepsilon$ abierto: $\forall x, y \in V, \forall f \in \overline{B}$ vale $|f(x) - f(y)| < \varepsilon$.

- Como X es compacto y K es Heineano $\implies K$ es uniformemente continuo en $X \times X$.
- Sean $\varepsilon, \delta > 0$ tales que $\forall x, y, y' \in X$

$$|K(x, y) - K(x, y')| < \varepsilon \quad \forall d(y, y') < \delta.$$

- $\implies \forall f \in \overline{B}, \forall d(y, y') < \delta$

$$\begin{aligned} |f(y) - f(y')| &= |\langle f, K_y - K_{y'} \rangle_{\mathcal{H}_K}| \leq \|f\|_{\mathcal{H}_K} \|K_y - K_{y'}\|_{\mathcal{H}_K} \\ &\leq \sqrt{\langle K_y - K_{y'}, K_y - K_{y'} \rangle} \\ &= \sqrt{K(y, y) - K(y, y') + K(y', y') - K(y', y)} < \sqrt{2\varepsilon}. \end{aligned}$$

Peso III: Arzelà-Ascoli

El teorema de A.-A. nos dice que si X es compacto y $S \subset C(X)$, entonces S es compacto $\iff S$ es cerrado, acotado y equicontinuo.

(Una prueba completa de A.-A. en espacios métricos: Royden, Fitzpatrick, "Real Analysis", 4th ed., 2010)

Además de proporcionar espacios de hipótesis donde existen mínimos de los errores de generalización y en

1. Existen RKHS sobre espacios métricos compactos, capaces de separar todos los conjuntos compactos: si $A, B \subset X$ compactos disjuntos, $\exists f_{A,B} \in \mathcal{H}_K$ tal que

$$f_{A,B}(x) > 0 \quad \forall x \in A, \quad f_{A,B}(x) < 0 \quad \forall x \in B.$$

Un kernel que hace esto es el RBF (*Steinwart, Christmann, §4.6*).

2. El mínimo del error empírico en un RKHS, cuando existe, se escribe como combinación lineal del kernel evaluado en los datos. Este es el llamado *representer theorem*.

Teorema 2.2.2. Sea X espacio métrico, $K \in C_b(X \times X)$ un kernel de Mercer y sea $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset X \times \mathbb{R}$. Sean $E : (X \times \mathbb{R})^m \rightarrow \mathbb{R}_+$ y $g : \mathbb{R}_+ \rightarrow \mathbb{R}_+$ monótono.

Si $\mathcal{F} = \{f \in \mathcal{H}_K \mid f \text{ minimiza en } \mathcal{H}_K\}$, entonces

$$R_g[F] = E(\{(x_i, y_i, f(x_i))\}_{i=1}^m) + g(\|f\|_{\mathcal{H}_K}).$$

$$\implies \exists \{\alpha_i\}_{i=1}^m \subset \mathbb{R} : \rho_E^{\mathcal{H}_K, \mathcal{D}} = \sum_{i=1}^m \alpha_i K_{x_i}.$$

Demostración:

$V_0 := \text{span}\{K_{x_i}\}_{i=1}^m$ es un subespacio de $\mathcal{H}_K$.

$$\implies \text{si } f \in \mathcal{H}_K, \quad f = P_{V_0}f + P_{V_0^\perp}f.$$

1)

$$f(x_j) = \langle f, K_{x_j} \rangle = \langle P_{V_0}f, K_{x_j} \rangle \quad \forall j = 1, \dots, m.$$

$$\implies E(\{(x_i, y_i, f(x_i))\}_{i=1}^m) = E(\{(x_i, y_i, P_{V_0}f(x_i))\}_{i=1}^m).$$

2) g es monótona, así que

$$g(\|f\|_{\mathcal{H}_K}) = g\left(\sqrt{\|P_{V_0}f\|_{\mathcal{H}_K}^2 + \|P_{V_0^\perp}f\|_{\mathcal{H}_K}^2}\right) \geq g(\|P_{V_0}f\|_{\mathcal{H}_K}).$$

$$\implies \forall f \in \mathcal{H}_K, \quad R_\infty[P_{V_0}f] \leq R_\infty[f].$$

■

Observación 2.2.2.

- Esto no dice que R_∞ tiene mínimo en $\mathcal{H}_K$, ni dice que, si R_∞ tiene mínimos en $\mathcal{H}_K$, no hay algunos que no estén en V_0 .
- La utilidad de este teorema está en la posibilidad de buscar un mínimo en V_0 , que es de dimensión finita.

““

Apéndice: Análisis Funcional

Teorema 2.2.3 (Desigualdad de Cauchy-Schwarz). Sea V un espacio vectorial sobre un cuerpo $\mathbb{F}$. Sea $\langle \cdot, \cdot \rangle : V \times V \rightarrow \mathbb{F}$ tal que:

- $\langle v, v \rangle \geq 0 \quad \forall v \in V,$
- $\langle v, w \rangle = \overline{\langle w, v \rangle} \quad \forall v, w \in V,$
- $\langle \alpha v_1 + \beta v_2, w \rangle = \alpha \langle v_1, w \rangle + \beta \langle v_2, w \rangle \quad \forall v_1, v_2, w \in V, \forall \alpha, \beta \in \mathbb{F}.$

Entonces,

$$|\langle v, w \rangle|^2 \leq \langle v, v \rangle \langle w, w \rangle \quad \forall v, w \in V.$$

Demostración: Para todo $\alpha \in \mathbb{F}$ vale

$$0 \leq \langle v - \alpha w, v - \alpha w \rangle.$$

Expandiendo,

$$\langle v - \alpha w, v - \alpha w \rangle = \langle v, v \rangle - \alpha \langle w, v \rangle - \bar{\alpha} \langle v, w \rangle + |\alpha|^2 \langle w, w \rangle.$$

Sea $b > 0$, $\theta \in [0, 2\pi)$ tal que $\langle v, w \rangle = be^{i\theta}$, y sea $\alpha = te^{-i\theta}$ para un $t \in \mathbb{R}$. Entonces,

$$0 \leq \langle v, v \rangle - 2bt + t^2 \langle w, w \rangle.$$

Esto define una parábola en t . Para que esta desigualdad sea válida para todo t , es necesario que $\Delta \leq 0$, donde

$$\Delta = b^2 - \langle w, w \rangle \langle v, v \rangle = |\langle v, w \rangle|^2 - \langle v, v \rangle \langle w, w \rangle.$$

Por lo tanto, $|\langle v, w \rangle|^2 \leq \langle v, v \rangle \langle w, w \rangle$. ■

Observación 2.2.3. No se requiere que $\langle v, v \rangle = 0 \implies v = 0$.

““

I'm sorry, I cannot transcribe handwritten text from images.

Teorema 2.2.4 (Eberlein-Smulian). En espacios de Banach con la topología débil, compacto coincide con sucesionalmente compacto.

Sea X un espacio de Banach, $A \subset X$ son equivalentes:

1. Toda sucesión en A tiene una subsucesión débilmente convergente.

2. El cierre débil de A es débilmente compacto.

Corolario 2.2.5. *Sea $\mathcal{H}$ un espacio de Hilbert. Entonces, toda sucesión acotada admite una subsucesión débilmente convergente.*

Demostración: Por el teorema de representación de Riesz, para todo funcional lineal y continuo $L \in \mathcal{H}^*$, existe $v_L \in \mathcal{H}$ tal que $L(\varphi) = \langle \varphi, v_L \rangle \forall \varphi \in \mathcal{H}$.

Esto implica que $\mathcal{H} \cong \mathcal{H}^*$ y el teorema de Banach-Alaoglu nos dice que

$$\overline{B} = \{f \in \mathcal{H} : \|f\|_{\mathcal{H}} \leq 1\}$$

es compacto en la topología inducida por la convergencia débil: $\{f_n\} \subset \mathcal{H}$ converge débilmente a $f \in \mathcal{H}$ si $\langle f_n, \varphi \rangle \rightarrow \langle f, \varphi \rangle \forall \varphi \in \mathcal{H}$. ■

Observación 2.2.4. Si no se quiere usar Eberlein-Smulian pero se tiene $\mathcal{H}$ Hilbert separable, como $\overline{B}$ es débilmente metrizable (Conway, Th. 5.1, p. 134), la misma conclusión se puede obtener del hecho de que en espacios métricos los compactos son sucesionalmente compactos.

Los espacios de Hilbert separables son los RKHS sobre X separable.

I'm sorry, but I cannot transcribe handwritten text from images.

Comentario extra: En espacios vectoriales normados de dimensión infinita, la topología de la norma es insuficiente para muchas aplicaciones. El ejemplo más evidente es la no compacidad de la bola unidad.

Lema 2.2.6. *Sea $\mathcal{H}$ un espacio de Hilbert separable y sea*

$$\overline{B} = \{f \in \mathcal{H} : \|f\| \leq 1\}.$$

Entonces, $\overline{B}$ es débilmente compacto $\iff \dim(\mathcal{H}) < \infty$.

Demostración: Sea $\{e_m\}_{m=1}^{\infty}$ una base ortonormal de $\mathcal{H}$. Entonces, $\{e_m\}_{m=1}^{\infty} \subset \overline{B}$, pero

$$\|e_n - e_m\|^2 = \|e_n\|^2 + \|e_m\|^2 = 2 \quad \forall n \neq m.$$

Esto implica que $\overline{B}$ no contiene una subsucesión convergente. ■

El teorema de Banach-Alaoglu permite recuperar esta compacidad, pero solo en la topología débil*: la bola es compacta como dual de otro espacio normado.

I'm sorry, but I cannot transcribe handwritten text from images.

Lema 2.2.7. Sea $f \in L^1(\mathbb{R}) \cap C^1(\mathbb{R})$, $f' \in L^1(\mathbb{R})$. Entonces:

- (1) $\lim_{x \rightarrow \infty} f(x) = 0$,
- (2) $\widehat{f}'(\xi) = 2\pi i \xi \widehat{f}(\xi)$.

Demostración:

1. $f(x) = f(0) + \int_0^x f'(t) dt$. Como $\int_{\mathbb{R}} |f'(t)| dt < \infty$, se tiene que $\lim_{x \rightarrow \infty} f(x) = l \in \mathbb{R}$.

Pero $f \in L^1(\mathbb{R}) \implies l = 0$.

2.

$$\begin{aligned} \widehat{f}'(\xi) &= \int_{\mathbb{R}} f'(x) e^{-2\pi i \xi x} dx = \text{integración por partes} \\ &= \lim_{M \rightarrow \infty} f(x) e^{-2\pi i \xi x} \Big|_{x=-M}^{x=M} + 2\pi i \xi \int_{\mathbb{R}} f(x) e^{-2\pi i \xi x} dx. \end{aligned}$$

Por (i), el primer término es 0, y por lo tanto:

$$\widehat{f}'(\xi) = 2\pi i \xi \widehat{f}(\xi).$$

■

Corolario 2.2.8. Si $f(x) = e^{-\frac{x^2}{2\sigma^2}}$, entonces $\widehat{f}(\xi) = \sqrt{2\pi}\sigma e^{-\frac{(2\pi\sigma\xi)^2}{2}}$.

Demostración: $f'(x) = -\frac{x}{\sigma^2} f(x)$ (derivación de la gaussiana). Entonces:

$$\widehat{f}'(\xi) = -\frac{1}{\sigma^2} \int_{\mathbb{R}} f(x) x e^{-2\pi i \xi x} dx = -\frac{1}{2\pi i \sigma^2} \int_{\mathbb{R}} f(x) \frac{d}{d\xi} e^{-2\pi i \xi x} dx.$$

Integrando por partes:

$$\widehat{f}'(\xi) = \frac{1}{2\pi i \sigma^2} \frac{d}{d\xi} \widehat{f}(\xi).$$

Por el lema, también se tiene que $\widehat{f}'(\xi) = 2\pi i \xi \widehat{f}(\xi)$. Por lo tanto:

$$2\pi i \xi \widehat{f}(\xi) = \frac{1}{2\pi i \sigma^2} \frac{d}{d\xi} \widehat{f}(\xi) \implies \frac{d}{d\xi} \widehat{f}(\xi) = -(2\pi\sigma)^2 \xi \widehat{f}(\xi).$$

Resolviendo esta ecuación diferencial:

$$\widehat{f}(\xi) = \widehat{f}(0) e^{-(2\pi\sigma)^2 \frac{\xi^2}{2}}.$$

Finalmente:

$$\widehat{f}(0) = \int_{\mathbb{R}} f(x) dx = \int_{\mathbb{R}} e^{-\frac{x^2}{2\sigma^2}} dx = \sigma\sqrt{2\pi}.$$

■

Teorema 2.2.9 (Inversión de Fourier). Sea $f \in L^1(\mathbb{R}) \cap C_b(\mathbb{R})$. Entonces

$$f(x) = \lim_{\epsilon \rightarrow 0} \int_{\mathbb{R}} e^{2\pi i \xi x} \widehat{f}(\xi) e^{-\epsilon \xi^2 / 2} d\xi \quad \forall x \in \mathbb{R}.$$

Demostración: Por el teorema de Fubini:

$$\begin{aligned} I_{\epsilon}[f](x) &= \int_{\mathbb{R}} e^{2\pi i \xi x} \left(\int_{\mathbb{R}} e^{-2\pi i \xi y} f(y) dy \right) e^{-\epsilon \xi^2 / 2} d\xi. \\ &= \int_{\mathbb{R}} f(y) \left(\int_{\mathbb{R}} e^{-2\pi i \xi (y-x)} e^{-\epsilon \xi^2 / 2} d\xi \right) dy. \end{aligned}$$

El término entre paréntesis es:

$$\int_{\mathbb{R}} e^{-2\pi i \xi (y-x)} e^{-\epsilon \xi^2 / 2} d\xi = \frac{1}{\sqrt{2\pi}} e^{-2\pi^2 (y-x)^2 / \epsilon}.$$

Sea $\phi(t) = \sqrt{2\pi} e^{-2\pi^2 t^2}$, entonces $\phi_{\epsilon}(t) = \frac{1}{\epsilon} \phi\left(\frac{t}{\epsilon}\right)$.

Por lo tanto:

$$I_{\epsilon}[f](x) = \int_{\mathbb{R}} f(y) \phi_{\epsilon}(x-y) dy = f * \phi_{\epsilon}(x).$$

Obsérvese que $\int_{\mathbb{R}} \phi_{\epsilon}(t) dt = \int_{\mathbb{R}} \phi(t) dt = 1$.

Finalmente:

$$\begin{aligned} |I_{\epsilon}[f](x) - f(x)| &= \left| \int_{\mathbb{R}} (f(x-y) - f(x)) \phi_{\epsilon}(y) dy \right| \\ &\leq \int_{-c}^c |f(x-y) - f(x)| \phi_{\epsilon}(y) dy + \int_{\mathbb{R} \setminus [-c, c]} |f(x-y) - f(x)| \phi_{\epsilon}(y) dy. \end{aligned}$$

■

Sea $x \in \mathbb{R}$ fijo y $\delta > 0$. $f \in C_b(\mathbb{R}) \implies \exists c > 0$ t.q.

$$|f(x-y) - f(x)| < \frac{\delta}{2} \quad \forall |y| < c.$$

$$\implies |I_{\epsilon}[f](x) - f(x)| \leq \int_{-c}^c |f(x-y) - f(x)| \phi_{\epsilon}(y) dy + 2 \max |f| \int_{\mathbb{R} \setminus [-c, c]} \phi_{\epsilon}(y) dy.$$

$$\implies \forall \epsilon > 0 : \int_{\mathbb{R} \setminus [-c, c]} \phi_\epsilon(y) dy < \frac{\delta}{4 \max |f|}.$$

Hemos obtenido que $\forall x \in \mathbb{R}, \forall \delta > 0 \exists \epsilon > 0$ t.q. $|I_\epsilon[f](x) - f(x)| < \delta \quad \forall \epsilon < \epsilon_0$.

Corolario 2.2.10. Si $f \in L^1(\mathbb{R})$ t.q. $\widehat{f} \in L^1(\mathbb{R})$, entonces

$$f(x) = \int_{\mathbb{R}} e^{2\pi i \xi x} \widehat{f}(\xi) d\xi \quad \forall x \in \mathbb{R}.$$

Demostración: Si $\widehat{f} \in L^1(\mathbb{R})$, como $\left| e^{2\pi i \xi x} \widehat{f}(\xi) e^{-\epsilon \xi^2/2} \right| \leq \left| \widehat{f}(\xi) \right|$, por el teorema de la convergencia dominada:

$$\int_{\mathbb{R}} e^{2\pi i \xi x} \widehat{f}(\xi) d\xi = \lim_{\epsilon \rightarrow 0} \int_{\mathbb{R}} e^{2\pi i \xi x} \widehat{f}(\xi) e^{-\epsilon \xi^2/2} d\xi.$$

Este ya sabemos que es uniforme continuo. ■

$$\text{Notación: Se suele escribir } \mathcal{F}^{-1}[\widehat{f}](x) = \int_{\mathbb{R}} e^{2\pi i \xi x} \widehat{f}(\xi) d\xi,$$

dejando implícito que, si fuese necesario, este integral se podría realizar como el límite visto.

Teorema 2.2.11 (Plancherel: Isometría de $L^2(\mathbb{R})$). $\mathcal{F}$ se extiende de $L^1(\mathbb{R}) \cap L^2(\mathbb{R})$ a una isometría suprayectiva de $L^2(\mathbb{R})$.

Demostración (Ideas de prueba elemental):

1. Sean $f, g \in L^1(\mathbb{R}) \cap L^2(\mathbb{R})$, $\mathcal{F}$ es isométrica:

$$\langle \widehat{f}, \widehat{g} \rangle_{L^2(\mathbb{R})} = \int_{\mathbb{R}} \int_{\mathbb{R}} f(x) e^{-2\pi i \xi x} dx \overline{\widehat{g}(\xi)} d\xi.$$

Por Fubini:

$$= \int_{\mathbb{R}} f(x) \left(\int_{\mathbb{R}} e^{-2\pi i \xi x} \overline{\widehat{g}(\xi)} d\xi \right) dx = \langle f, g \rangle_{L^2(\mathbb{R})}.$$

Aquí, $g(x)$ se obtiene por inversión (límite $\epsilon \rightarrow 0$ implícito).

2. Si $f \in L^2(\mathbb{R})$, definimos $f_m(x) = e^{-x^2/2m} f(x)$.

- Por el teorema de la convergencia dominada:

$$\|f_m - f\|_{L^2(\mathbb{R})}^2 = \int_{\mathbb{R}} \left| e^{-x^2/2m} - 1 \right|^2 |f(x)|^2 dx \xrightarrow{m \rightarrow \infty} 0.$$

- Por la desigualdad de Cauchy-Schwarz:

$$\int_{\mathbb{R}} |f_m(x)| \, dx \leq \left(\int_{\mathbb{R}} e^{-x^2/m} \, dx \right)^{1/2} \left(\int_{\mathbb{R}} |f(x)|^2 \, dx \right)^{1/2}.$$

$$\implies f_m \in L^1(\mathbb{R}) \cap L^2(\mathbb{R}). \text{ Por (1), } \|f_m\|_{L^2} = \|\widehat{f_m}\|_{L^2} \text{ y}$$

$$\|\widehat{f_m} - \widehat{f}\|_{L^2(\mathbb{R})} = \|f_m - f\|_{L^2(\mathbb{R})} \xrightarrow{m \rightarrow \infty} 0.$$

$$\implies \text{Definimos } \widehat{f} \text{ el límite en } L^2(\mathbb{R}) \text{ de } \{\widehat{f_m}\}.$$

3. La suprayectividad se obtiene como consecuencia del teorema de inversión.

■