
MATEMÁTICAS PARA EL APRENDIZAJE AUTOMÁTICO

Cuarto del Grado en Matemáticas

Hugo Marquerie

Profesor: Davide Barbieri

Facultad de Ciencias - Universidad Autónoma de Madrid

Segundo cuatrimestre

fecha

Puedes encontrar mi colección completa de apuntes en <https://hmarquer.github.io>.

Índice

1	Aprendizaje no supervisado	iii
1.1	Principal component analysis (PCA)	iii
1.1.1	Planteamiento del problema	iii
1.1.2	Solución (teorema y algoritmo)	iii
1.2	<i>Clustering</i> espectral en grafos	v
1.2.1	Grafos ponderados y definiciones básicas	v
1.2.2	El problema de corte normalizado (NCut)	vi
1.2.3	Formulación variacional para $k = 2$	vii
1.2.4	Relajación espectral del problema NCut	ix
1.2.5	Interpretación probabilística: caminos aleatorios	ix
1.2.6	<i>Spectral Clustering</i> para $k > 2$	x
1.2.7	Otros algoritmos de agrupamiento	xi
2	Aprendizaje supervisado	xv
2.1	Learning Theory	xv
2.1.1	Sobre el objetivo y el aprendizaje estadístico	xv
2.2	Reproducing Kernel Hilbert Spaces	xix
2.3	Clasificadores Lineales Binarios	xxix
2.3.1	Maximización del Margen: SVM	xxxix

1. Aprendizaje no supervisado

1.1 Principal component analysis (PCA)

1.1.1 Planteamiento del problema

Sean $\{x_i\}_{i=1}^m \subset \mathbb{C}^n$ un conjunto de datos y sea $k < m$. El objetivo de PCA es encontrar la proyección de $\mathbb{C}^n$ de rango k (proyección sobre un subespacio $M \subset \mathbb{C}^n$ de dimensión k) que minimice el error cuadrático entre los datos originales y los datos proyectados:

$$\mathcal{E} = \sum_{i=1}^m \|x_i - \mathbb{P}_M x_i\|^2,$$

donde $\mathbb{P}_M$ es la proyección ortogonal sobre M . El PCA nos permite:

- Aproximar un conjunto de datos por un subespacio de dimensión menor.
- Una base ortonormal del subespacio M proporciona un diccionario “óptimo” para representar linealmente los datos.

1.1.2 Solución (teorema y algoritmo)

Sea $A = \begin{pmatrix} | & | & \cdots & | \\ x_1 & x_2 & \cdots & x_m \\ | & | & \cdots & | \end{pmatrix} \in \mathbb{C}^{n \times m}$ y sea $A = U\Sigma V^*$ su descomposición en valores singulares (SVD). Es decir, $U \in \mathbb{C}^{n \times n}$ y $V \in \mathbb{C}^{m \times m}$ son matrices unitarias y $\Sigma \in \mathbb{R}_+^{n \times m}$ es una matriz diagonal con los valores singulares $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$ en la diagonal, donde $r = \text{rang}(A)$.

Entonces, $M := \text{span}\{U^{(1)}, \dots, U^{(k)}\}$, donde $U^{(i)}$ es la i -ésima columna de U , es el subespacio que minimiza el error cuadrático $\mathcal{E}$. En consecuencia, la proyección ortogonal de los datos sobre M viene dada por

$$\forall x \in \mathbb{C}^n : \mathbb{P}_M x = \sum_{i=1}^k \langle x, U^{(i)} \rangle U^{(i)}.$$

Teorema 1.1.1. Sea $A \in \mathbb{C}^{n \times m}$, $A = U\Sigma V^*$ su SVD y $k \leq \text{rang}(A)$. Definimos

$$A_k = \sum_{i=1}^k \sigma_i U^{(i)} \otimes V^{(i)} \quad \text{donde} \quad (v \otimes w)_{ij} = v_i \overline{w_j}.$$

$$\implies \forall B \in \mathbb{C}^{n \times m} : \text{rang}(B) = k : \|A - B\|_{Fro}^2 \geq \|A - A_k\|_{Fro}^2 = \sum_{i=k+1}^{\text{rang } A} \sigma_i^2.$$

¿Por qué nos vale esto? La i -ésima columnas de A_k es $A_k^{(i)} = \sum_{\ell=1}^k \sigma_\ell \overline{V_{i\ell}} U^{(\ell)}$ donde $U^{(\ell)}$ es la ℓ -ésima columna de U y $\sigma_\ell \overline{V_{i\ell}} = \langle A^{(i)}, U^{(\ell)} \rangle = \langle x_i, U^{(\ell)} \rangle$. Entonces,

$$A_k^{(i)} = \sum_{\ell=1}^k \langle x_i, U^{(\ell)} \rangle U^{(\ell)} = \mathbb{P}_{\text{span}\{U^{(1)}, \dots, U^{(k)}\}} x_i = \mathbb{P}_M x_i.$$

Demostración: Dividimos la demostración en diferentes pasos:

Paso 1. Recordamos que la norma de Frobenius se puede escribir como $\|A\|_{\text{Fro}}^2 = \text{tr}(A^* A)$.

Por tanto,

$$\begin{aligned} \|A - A_k\|_{\text{Fro}}^2 &= \|U\Sigma V^* - U\Sigma_k V^*\|_{\text{Fro}}^2 = \|U(\Sigma - \Sigma_k)V^*\|_{\text{Fro}}^2 \\ &= \text{tr}(V(\Sigma - \Sigma_k)^* V^*) = \sum_{\ell=k+1}^{\text{rang } A} \sigma_\ell^2, \end{aligned}$$

puesto que $\Sigma - \Sigma_k$ es una matriz diagonal con los ceros en los primeros k elementos de la diagonal y los valores singulares $\sigma_{k+1}, \dots, \sigma_r$ en el resto.

Por tanto, basta demostrar que $\forall B \in \mathbb{C}^{n \times m} : \text{rang}(B) = k : \|A - B\|_{\text{Fro}}^2 \geq \sum_{\ell=k+1}^{\text{rang } A} \sigma_\ell^2$.

Paso 2. Sea $B \in \mathbb{C}^{n \times m}$ con $\text{rang}(B) = k$. Sea $B = XTY^*$ su SVD, con $X \in \mathbb{C}^{n \times n}$ y $Y \in \mathbb{C}^{m \times m}$ unitarias y $T \in \mathbb{R}_+^{n \times m}$ diagonal. Entonces,

$$\begin{aligned} \|A - B\|_{\text{Fro}}^2 &= \|A\|_{\text{Fro}}^2 + \text{tr}(B^* B - B^* A - A^* B) \\ &= \|A\|_{\text{Fro}}^2 + \sum_{\ell=1}^k t_\ell^2 - \sum_{\ell=1}^k t_\ell \text{tr}((y_\ell \otimes x_\ell)A + A^*(x_\ell \otimes y_\ell)), \end{aligned}$$

como $\sum_{\ell=1}^k t_\ell^2 = \sum_{\ell=1}^k t_\ell^2 \text{tr}(C_{y_\ell \otimes y_\ell})$ y $(y_\ell \otimes x_\ell)A = y_\ell \otimes (A^* x_\ell)$, tenemos que

$$\begin{aligned} \|A - B\|_{\text{Fro}}^2 &= \|A\|_{\text{Fro}}^2 + \sum_{\ell=1}^k \text{tr}((A^* x_\ell - t_\ell y_\ell) \otimes (A^* x_\ell - t_\ell y_\ell)) - \sum_{\ell=1}^k \text{tr}(A^* x_\ell \otimes A^* x_\ell) \\ &\geq \|A\|_{\text{Fro}}^2 - \sum_{\ell=1}^k \|A^* x_\ell\|^2, \end{aligned}$$

donde la desigualdad se obtiene porque $\text{tr}(v \otimes v) = \|v\|^2 \geq 0$.

Paso 3. Acotamos ahora $\sum_{\ell=1}^k \|A^* x_\ell\|^2$. Como $A = U\Sigma V^*$, tenemos que $A^* = V\Sigma^* U^*$, y por tanto $A^* x_\ell = V\Sigma^* U^* x_\ell$. Entonces,

$$\sum_{\ell=1}^k \|A^* x_\ell\|^2 = \sum_{\ell=1}^k \|V\Sigma^* U^* x_\ell\|^2 = \sum_{\ell=1}^k \|\Sigma^* U^* x_\ell\|^2,$$

donde hemos usado que V es unitaria y por tanto preserva la norma. Desarrollando la

norma,

$$\sum_{\ell=1}^k \|\Sigma^* U^* x_\ell\|^2 = \sum_{\ell=1}^k \sum_{i=1}^{\text{rang } A} \sigma_i^2 |\langle U^{(i)}, x_\ell \rangle|^2 = \sum_{i=1}^{\text{rang } A} \sigma_i^2 \sum_{\ell=1}^k |\langle U^{(i)}, x_\ell \rangle|^2.$$

Observamos que $\sum_{\ell=1}^k |\langle U^{(i)}, x_\ell \rangle|^2 = \|\mathbb{P}_k U^{(i)}\|^2$, donde $\mathbb{P}_k$ es el proyector ortogonal sobre $\text{span}\{x_1, \dots, x_k\}$. Denotando $p_i = \|\mathbb{P}_k U^{(i)}\|^2$, tenemos que:

- $p_i \leq 1$ para todo i , ya que $\|\mathbb{P}_k U^{(i)}\| \leq \|U^{(i)}\| = 1$.
- $\sum_{i=1}^{\text{rang } A} p_i \leq k$, ya que $\mathbb{P}_k$ proyecta sobre un subespacio de dimensión k .

Para maximizar $\sum_{i=1}^{\text{rang } A} \sigma_i^2 p_i$ sujeto a estas restricciones, como $\sigma_1 \geq \sigma_2 \geq \dots$, el máximo se alcanza cuando $p_1 = \dots = p_k = 1$ y $p_i = 0$ para $i > k$. Por tanto,

$$\sum_{\ell=1}^k \|A^* x_\ell\|^2 \leq \sum_{i=1}^k \sigma_i^2.$$

Paso 4. Retomando la cota del Paso 2,

$$\|A - B\|_{\text{Fro}}^2 \geq \|A\|_{\text{Fro}}^2 - \sum_{\ell=1}^k \|A^* x_\ell\|^2 \geq \|A\|_{\text{Fro}}^2 - \sum_{i=1}^k \sigma_i^2 = \sum_{i=k+1}^{\text{rang } A} \sigma_i^2,$$

lo que, junto con el Paso 1, concluye la demostración. ■

1.2 *Clustering* espectral en grafos

El objetivo del *clustering* espectral es particionar un conjunto de datos en grupos de manera que los elementos de un mismo grupo estén “más conectados” entre sí que con elementos de otros grupos. Para formalizar esto, representamos los datos como un grafo ponderado.

1.2.1 Grafos ponderados y definiciones básicas

Definición 1.2.1 (Grafo ponderado no dirigido). Un grafo ponderado no dirigido es una tupla $G = (V, W)$ donde:

- $V = \{v_1, \dots, v_m\}$ es el conjunto de vértices.
- $W \in \mathbb{R}^{m \times m}$ es la matriz de pesos, con $w_{ij} = w_{ji} \geq 0$.

Ejemplo 1.2.1. Sea (X, d) un espacio métrico y sea $\{x_i\}_{i=1}^m \subset X$ un conjunto de datos. Dado $\varepsilon > 0$, podemos construir un grafo ponderado donde $V = \{1, \dots, m\}$ y

$$w_{ij} = \begin{cases} e^{-d(x_i, x_j)^2} & \text{si } d(x_i, x_j) \leq \varepsilon, \\ 0 & \text{en otro caso.} \end{cases}$$

Este grafo captura las relaciones de vecindad entre los datos: cuanto más cercanos estén x_i y x_j , mayor será el peso w_{ij} .

Definición 1.2.2 (Grado, volumen y conexión). Sea $G = (V, W)$ un grafo ponderado.

- El **grado** del vértice i es $d_i = \sum_{j=1}^m w_{ij}$. Denotamos por $D = \text{diag}(d_1, \dots, d_m)$ la matriz diagonal de grados.
- El **volumen** de un subconjunto $S \subset V$ es $\text{vol}(S) = \sum_{i \in S} d_i$.
- La **conexión** entre $S, T \subset V$ es $W(S, T) = \sum_{i \in S} \sum_{j \in T} w_{ij}$.

Definición 1.2.3 (Laplaciano de un grafo). Sea $G = (V, W)$ un grafo ponderado. El **laplaciano** de G es la matriz $L = D - W$.

Observación 1.2.4 (Analogía con el laplaciano continuo). El nombre “laplaciano” proviene de la siguiente analogía. Sea $f: V \rightarrow \mathbb{R}$ una función sobre los vértices (escribimos $f_i = f(v_i)$). Entonces,

$$\langle f, Lf \rangle = \sum_{i=1}^m d_i f_i^2 - \sum_{i,j=1}^m w_{ij} f_i f_j = \frac{1}{2} \sum_{i,j=1}^m w_{ij} (f_i - f_j)^2.$$

Esta expresión mide la “variación” de f sobre el grafo, análogamente a cómo para $f \in \mathcal{C}^2(\mathbb{R}^d)$ con $f, |\nabla f|, \Delta f \in L^2(\mathbb{R}^d)$, se tiene $\langle f, -\Delta f \rangle_{L^2} = \|\nabla f\|_{L^2}^2$.

1.2.2 El problema de corte normalizado (NCut)

Definición 1.2.5 (Corte y corte normalizado). Sea $G = (V, W)$ un grafo ponderado y sea $\{A_j\}_{j=1}^k$ una partición de V (es decir, $V = \bigsqcup_{j=1}^k A_j$).

- El **corte** de la partición es

$$\text{cut}(\{A_j\}_{j=1}^k) = \sum_{j=1}^k W(A_j, A_j^c),$$

que mide el “costo” de separar el grafo en los subgrupos $A_1, \dots, A_k$.

- El **corte normalizado** (NCut) es

$$\text{Ncut}(\{A_j\}_{j=1}^k) = \sum_{j=1}^k \frac{W(A_j, A_j^c)}{\text{vol}(A_j)},$$

que penaliza además los grupos con volumen pequeño.

Observación 1.2.6. Para $k = 2$ (partición en dos grupos A y $B = A^c$), el corte normalizado se puede escribir como

$$\text{Ncut}(A, B) = W(A, B) \left(\frac{1}{\text{vol}(A)} + \frac{1}{\text{vol}(B)} \right).$$

Esta expresión es el producto de dos términos: la **separación** $W(A, B)$ (queremos que sea pequeña, es decir, A y B poco conectados) y el **balance** $\frac{1}{\text{vol}(A)} + \frac{1}{\text{vol}(B)}$ (que es mínimo cuando $\text{vol}(A) = \text{vol}(B)$). Por tanto, minimizar NCut favorece particiones con grupos bien separados y de tamaño equilibrado.

El **problema NCut** consiste en encontrar la partición que minimiza el corte normalizado:

$$\{A_j^*\}_{j=1}^k = \arg \min_{\{A_j\}_{j=1}^k \text{ partición}} \text{Ncut}(\{A_j\}_{j=1}^k).$$

1.2.3 Formulación variacional para $k = 2$

El siguiente lema relaciona el corte normalizado con una forma cuadrática.

Lema 1.2.1. Sea $V = A \cup B$ una partición y definamos $f^{(A,B)}: V \rightarrow \mathbb{R}$ por

$$f_i^{(A,B)} = \begin{cases} \sqrt{\frac{\text{vol}(B)}{\text{vol}(A)}} & \text{si } i \in A, \\ -\sqrt{\frac{\text{vol}(A)}{\text{vol}(B)}} & \text{si } i \in B. \end{cases}$$

Entonces,

$$\text{Ncut}(A, B) = \frac{1}{2 \text{vol}(V)} \sum_{i,j=1}^m w_{ij} (f_i^{(A,B)} - f_j^{(A,B)})^2.$$

Demostración: Observamos que $(f_i - f_j)^2 = 0$ si i, j están en el mismo grupo. Si $i \in A$ y $j \in B$ (o viceversa), entonces

$$(f_i - f_j)^2 = \left(\sqrt{\frac{\text{vol}(B)}{\text{vol}(A)}} + \sqrt{\frac{\text{vol}(A)}{\text{vol}(B)}} \right)^2 = \frac{\text{vol}(B)}{\text{vol}(A)} + \frac{\text{vol}(A)}{\text{vol}(B)} + 2.$$

Simplificando esta expresión y usando que $W(A, B) = W(B, A)$, se obtiene

$$\sum_{i,j=1}^m w_{ij}(f_i - f_j)^2 = 2W(A, B) \left(\frac{\text{vol}(B)}{\text{vol}(A)} + \frac{\text{vol}(A)}{\text{vol}(B)} + 2 \right) \cdot \frac{\text{vol}(A) \text{vol}(B)}{(\text{vol}(A) + \text{vol}(B))^2} \cdot \text{vol}(V),$$

que tras simplificar da $2 \text{vol}(V) \text{Ncut}(A, B)$. ■

Teorema 1.2.2. *El problema Ncut con $k = 2$ es equivalente al problema de optimización*

$$\arg \min \left\{ \frac{\langle f, Lf \rangle}{\langle f, Df \rangle} : \sum_{i=1}^m f_i d_i = 0, f_i \in \left\{ \pm \sqrt{\frac{\text{vol}(B)}{\text{vol}(A)}} \right\} \right\}.$$

Demostración: La demostración se divide en tres pasos:

Paso 1. Por la observación sobre el laplaciano, para cualquier $f \in \mathbb{R}^m$,

$$\langle f, Lf \rangle = \frac{1}{2} \sum_{i,j=1}^m w_{ij}(f_i - f_j)^2.$$

Paso 2. Sea $f: V \rightarrow \{p^2, -q^2\}$ y definamos $A = \{i : f_i = p^2\}$, $B = \{i : f_i = -q^2\}$. La restricción $\sum_{i=1}^m d_i f_i = 0$ implica

$$p^2 \text{vol}(A) = q^2 \text{vol}(B) \implies \frac{p^2}{q^2} = \frac{\text{vol}(B)}{\text{vol}(A)}.$$

De aquí se deduce que $f = pq f^{(A,B)}$ para cierto escalar pq .

Paso 3. Con f como en el paso anterior,

$$\langle f, Df \rangle = \sum_{i=1}^m d_i f_i^2 = p^4 \text{vol}(A) + q^4 \text{vol}(B) = p^2 q^2 \text{vol}(V).$$

Por tanto, usando el Lema 1.2.1,

$$\frac{\langle f, Lf \rangle}{\langle f, Df \rangle} = \frac{\langle f^{(A,B)}, Lf^{(A,B)} \rangle}{\langle f^{(A,B)}, Df^{(A,B)} \rangle} = \text{Ncut}(A, B).$$
■

Observación 1.2.7 (Complejidad computacional). El problema de optimización del Teorema 1.2.2 es **NP-completo**. Esto significa que, salvo que $P = NP$, no existe algoritmo que lo resuelva en tiempo polinomial.

1.2.4 Relajación espectral del problema NCut

Para obtener un algoritmo eficiente, relajamos el problema eliminando la restricción de que f tome valores discretos.

Observación 1.2.8 (Cambio de variable y cociente de Rayleigh). Sea $g = D^{1/2}f$ y definamos $M = D^{-1/2}LD^{-1/2}$ (el **laplaciano normalizado**). Entonces,

$$\frac{\langle f, Lf \rangle}{\langle f, Df \rangle} = \frac{\langle g, Mg \rangle}{\|g\|^2},$$

que es el **cociente de Rayleigh** de la matriz M . Además, M es simétrica y semidefinida positiva, con

$$\langle g, Mg \rangle = \frac{1}{2} \sum_{i,j=1}^m w_{ij} \left(\frac{g_i}{\sqrt{d_i}} - \frac{g_j}{\sqrt{d_j}} \right)^2 \geq 0.$$

La restricción $\sum_{i=1}^m d_i f_i = 0$ se traduce en $g \perp D^{1/2}\mathbf{1}$, donde $\mathbf{1}$ es el vector de unos.

El problema relajado consiste en minimizar el cociente de Rayleigh sobre todos los vectores $g \perp D^{1/2}\mathbf{1}$:

$$\min_{g \perp D^{1/2}\mathbf{1}} \frac{\langle g, Mg \rangle}{\|g\|^2}.$$

Por el teorema del cociente de Rayleigh (ver Apéndice), el mínimo se alcanza en el autovector de M correspondiente al segundo menor autovalor (el menor autovalor es 0 con autovector $D^{1/2}\mathbf{1}$).

Algoritmo de *Spectral Clustering* para $k = 2$:

1. Calcular el autovector g_2 de $M = D^{-1/2}LD^{-1/2}$ correspondiente al menor autovalor no nulo.
2. Definir la partición: $A = \{i \in V : g_2(i) > 0\}$ y $B = A^c$.

1.2.5 Interpretación probabilística: caminos aleatorios

La matriz $P = D^{-1}W$ es una **matriz de transición de Markov**:

$$p_{ij} = \frac{w_{ij}}{d_i} = \frac{w_{ij}}{\sum_{k=1}^m w_{ik}}, \quad \text{con } \sum_{j=1}^m p_{ij} = 1.$$

Es decir, $p_{ij} = \mathbb{P}(i \rightarrow j)$ es la probabilidad de transitar del vértice i al vértice j en un paso del camino aleatorio sobre el grafo. La distribución estacionaria es $\pi_i = \frac{d_i}{\text{vol}(V)}$.

Proposición 1.2.3. Sea $\{X_t\}_{t \geq 0}$ el camino aleatorio sobre G con $X_0 \sim \pi$. Entonces,

$$\mathbb{P}(X_t \in A \mid X_{t-1} \in B) + \mathbb{P}(X_t \in B \mid X_{t-1} \in A) = \text{Ncut}(A, B).$$

Demostración: Calculamos directamente:

$$\mathbb{P}(X_0 \in A, X_1 \in B) = \sum_{i \in A} \sum_{j \in B} \pi_i p_{ij} = \frac{1}{\text{vol}(V)} \sum_{i \in A} \sum_{j \in B} w_{ij} = \frac{W(A, B)}{\text{vol}(V)}.$$

Como $\mathbb{P}(X_0 \in A) = \frac{\text{vol}(A)}{\text{vol}(V)}$, se tiene

$$\mathbb{P}(X_1 \in B \mid X_0 \in A) = \frac{W(A, B)}{\text{vol}(A)}.$$

El mismo argumento da $\mathbb{P}(X_1 \in A \mid X_0 \in B) = \frac{W(B, A)}{\text{vol}(B)}$, y sumando obtenemos $\text{Ncut}(A, B)$. ■

Esta proposición nos da una interpretación intuitiva: **minimizar NCut equivale a minimizar la probabilidad de que un camino aleatorio “salte” entre grupos.**

1.2.6 Spectral Clustering para $k > 2$

Lema 1.2.4. Sea $G = (V, W)$ un grafo con K componentes conexas $V = \bigsqcup_{\ell=1}^K A_\ell$ (es decir, $w_{ij} = 0$ si $i \in A_\ell, j \in A_{\ell'}$ con $\ell \neq \ell'$). Entonces,

$$\ker L = \text{span}\{\chi_{A_1}, \dots, \chi_{A_K}\},$$

donde χ_{A_ℓ} es la función indicadora de A_ℓ .

Demostración: Para $K = 1$ (grafo conexo), $\langle f, Lf \rangle = \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2 = 0$ implica $f_i = f_j$ para todos los pares con $w_{ij} > 0$, es decir, $f = \alpha \mathbf{1}$.

Para $K > 1$, el laplaciano tiene estructura de bloques diagonal (tras reordenar los vértices), y el resultado se aplica a cada bloque. ■

Observación 1.2.9 (Heurística para grafos “casi” desconectados). Si el grafo es conexo pero tiene K grupos “naturales” (muy conectados internamente, poco conectados entre sí), entonces:

- El autovector de M con autovalor 0 es $D^{1/2} \mathbf{1}$.
- Los siguientes $K - 1$ autovectores son aproximadamente $D^{1/2} \chi_{A_\ell}$, correspondientes a

autovalores pequeños.

Algoritmo de Shi-Malik:

1. Calcular los $k + 1$ autovectores de M con menores autovalores: $\{(\lambda_\ell, f_\ell)\}_{\ell=1}^{k+1}$ con $\lambda_1 = 0 < \lambda_2 \leq \dots \leq \lambda_{k+1}$.
2. Representar cada vértice v_i mediante el *embedding*

$$\varphi(v_i) = (f_2(v_i), \dots, f_{k+1}(v_i)) \in \mathbb{R}^k.$$

Esta técnica se conoce como *Laplacian Eigenmaps*.

3. Aplicar un algoritmo de agrupamiento clásico (como k -means) sobre los puntos $\{\varphi(v_i)\}_{i=1}^m \subset \mathbb{R}^k$.

Observación 1.2.10 (Elección de k). El número de grupos k se puede estimar buscando un “codo” en el espectro de M : un salto significativo entre λ_k y λ_{k+1} sugiere que hay k grupos bien definidos.

1.2.7 Otros algoritmos de agrupamiento

Definición 1.2.11 (K -means). Sean $\mathcal{D} = \{x_i\}_{i=1}^m \subset \mathbb{R}^N$ y $K \in \mathbb{N}$. El problema de K -means consiste en encontrar una partición $\mathcal{D} = \bigsqcup_{\ell=1}^K S_\ell$ que minimice

$$\sum_{\ell=1}^K \sum_{x \in S_\ell} \|x - \mu_\ell\|^2, \quad \text{donde } \mu_\ell = \frac{1}{|S_\ell|} \sum_{x \in S_\ell} x$$

es el centroide del grupo S_ℓ .

Observación 1.2.12. El problema de K -means es NP-completo. Los algoritmos prácticos (como el algoritmo de Lloyd) son heurísticas que encuentran mínimos locales.

Definición 1.2.13 (Agrupamiento jerárquico aglomerativo). Sea $\mathcal{D} = \{x_i\}_{i=1}^m \subset (X, d)$ un espacio métrico y sea $R: \mathcal{P}(X) \times \mathcal{P}(X) \rightarrow \mathbb{R}$ una distancia entre subconjuntos (por ejemplo, *single linkage*, *complete linkage* o *average linkage*).

- (i) Inicialmente, cada punto forma su propio grupo.
- (ii) Iterativamente, se fusionan los dos grupos más cercanos según R .
- (iii) Se construye un **dendrograma** que representa la jerarquía de fusiones.
- (iv) Se corta el dendrograma a un nivel t para obtener la partición final.

Observación 1.2.14. La elección del nivel de corte t es análoga a la búsqueda de un “codo” en el espectro del laplaciano.

Apéndice de Álgebra Lineal

Este apéndice recoge resultados de álgebra lineal utilizados en el capítulo, particularmente en la sección de clustering espectral.

Matrices autoadjuntas

Lema 1.2.5 (Caracterización de matrices autoadjuntas). *Sea $A \in \mathbb{C}^{m \times m}$ una matriz. Si $\langle Av, v \rangle_{\mathbb{C}^m} \in \mathbb{R}$ para todo $v \in \mathbb{C}^m$, entonces A es autoadjunta, es decir, $A = A^*$.*

Demostración: Definimos $M = A - A^*$ y mostramos que $M = 0$.

Paso 1. Como $\langle Av, v \rangle \in \mathbb{R}$ para todo v , tenemos que $\langle Av, v \rangle = \overline{\langle Av, v \rangle} = \langle v, Av \rangle$. Por tanto,

$$\langle Mv, v \rangle = \langle Av, v \rangle - \langle A^*v, v \rangle = \langle Av, v \rangle - \langle v, Av \rangle = 0.$$

Paso 2. Usando la identidad de polarización, para cualesquiera $v, w \in \mathbb{C}^m$:

$$\langle M(v + w), v + w \rangle - \langle M(v - w), v - w \rangle = 2 \langle Mv, w \rangle + 2 \langle Mw, v \rangle.$$

Por el Paso 1, el lado izquierdo es cero, luego $\langle Mv, w \rangle = -\langle Mw, v \rangle$.

Como $\langle Mw, v \rangle = \overline{\langle v, Mw \rangle}$ y $\langle v, Mw \rangle = \overline{\langle Mw, v \rangle}$, se tiene $\langle Mv, w \rangle = -\langle Mw, v \rangle = -\overline{\langle v, Mw \rangle}$. Sustituyendo $\langle Mw, v \rangle = -\langle Mv, w \rangle$:

$$\langle Mv, w \rangle = -\overline{\langle Mv, w \rangle} \implies \langle Mv, w \rangle \in i\mathbb{R}.$$

Paso 3. Análogamente, considerando $v + iw$ y $v - iw$:

$$\langle M(v + iw), v + iw \rangle - \langle M(v - iw), v - iw \rangle = 2i \langle Mv, w \rangle - 2i \langle Mw, v \rangle.$$

Por el Paso 1, esto es cero, luego $\langle Mv, w \rangle = \langle Mw, v \rangle$.

Paso 4. Combinando los Pasos 2 y 3: del Paso 2 tenemos $\langle Mv, w \rangle = -\langle Mw, v \rangle$, y del Paso 3 tenemos $\langle Mv, w \rangle = \langle Mw, v \rangle$. Por tanto, $\langle Mv, w \rangle = -\langle Mw, v \rangle$, lo que implica $\langle Mv, w \rangle = 0$ para todos $v, w \in \mathbb{C}^m$. Luego $M = 0$.

■

Observación 1.2.15 (Aplicación al laplaciano normalizado). En el contexto del clustering espectral, la matriz $M = D^{-1/2}LD^{-1/2}$ satisface

$$\langle Mg, g \rangle = \frac{1}{2} \sum_{i,j=1}^m w_{ij} \left| \frac{g_i}{\sqrt{d_i}} - \frac{g_j}{\sqrt{d_j}} \right|^2 \in \mathbb{R}_{\geq 0}$$

para todo $g \in \mathbb{C}^m$. Por el lema anterior, M es autoadjunta (y además semidefinida positiva).

El cociente de Rayleigh

Definición 1.2.16 (Cociente de Rayleigh). Sea $M \in \mathbb{R}^{m \times m}$ una matriz simétrica. El **cociente de Rayleigh** de M es la función $R_M: \mathbb{R}^m \setminus \{0\} \rightarrow \mathbb{R}$ definida por

$$R_M(x) = \frac{\langle Mx, x \rangle}{\|x\|^2}.$$

Lema 1.2.6 (Teorema min-max de Rayleigh). Sea $M \in \mathbb{R}^{m \times m}$ simétrica y semidefinida positiva. Sean $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_m$ sus autovalores (contados con multiplicidad) y $\{v_1, \dots, v_m\}$ una base ortonormal de autovectores correspondientes. Entonces:

$$\min_{x \in \mathbb{R}^m \setminus \{0\}} R_M(x) = \lambda_1, \quad \text{con} \quad \arg \min_{x \neq 0} R_M(x) = \ker(M - \lambda_1 I).$$

Demostración: Como $\{v_1, \dots, v_m\}$ es una base ortonormal, cualquier $x \in \mathbb{R}^m$ se escribe como $x = \sum_{i=1}^m c_i v_i$ con $c_i = \langle x, v_i \rangle$. Entonces:

$$Mx = \sum_{i=1}^m \lambda_i c_i v_i, \quad \|x\|^2 = \sum_{i=1}^m c_i^2, \quad \langle Mx, x \rangle = \sum_{i=1}^m \lambda_i c_i^2.$$

Definiendo $p_i = \frac{c_i^2}{\sum_{j=1}^m c_j^2}$, tenemos que $p_i \geq 0$ y $\sum_{i=1}^m p_i = 1$. Por tanto,

$$R_M(x) = \sum_{i=1}^m \lambda_i p_i$$

es una combinación convexa de los autovalores. El mínimo de una combinación convexa se alcanza en el menor de los valores, es decir, $R_M(x) \geq \lambda_1$, con igualdad si y solo si $p_1 = 1$ (y $p_i = 0$ para $i > 1$), lo que ocurre cuando $x \in \ker(M - \lambda_1 I)$. ■

Corolario 1.2.7 (Segundo autovalor). Con la notación del lema anterior, si $V_1 = \ker(M - \lambda_1 I)$ es el autoespacio correspondiente a λ_1 , entonces

$$\min_{x \perp V_1, x \neq 0} R_M(x) = \lambda_2.$$

Más generalmente, para $k \geq 1$:

$$\lambda_k = \min_{\substack{x \perp v_1, \dots, v_{k-1} \\ x \neq 0}} R_M(x).$$

Demostración: Si $x \perp V_1$, entonces $c_i = 0$ para todo i tal que $\lambda_i = \lambda_1$. Por tanto, $R_M(x) = \sum_{\lambda_i > \lambda_1} \lambda_i p_i \geq \lambda_2$, con igualdad cuando x es autovector de λ_2 . ■

Observación 1.2.17 (Aplicación al clustering espectral). En el problema NCut relajado, buscamos minimizar $R_M(g) = \frac{\langle Mg, g \rangle}{\|g\|^2}$ sujeto a $g \perp D^{1/2}\mathbf{1}$. Como $D^{1/2}\mathbf{1}$ es el autovector de M con autovalor $\lambda_1 = 0$, el Corolario 1.2.7 nos dice que el mínimo se alcanza en el autovector correspondiente al segundo menor autovalor λ_2 .

2. Aprendizaje supervisado

2.1 Learning Theory

La *teoría del aprendizaje* (*learning theory*) es el marco matemático que formaliza el problema central del aprendizaje automático: a partir de un conjunto finito de observaciones (datos), inferir una relación funcional que permita hacer predicciones sobre datos no observados. El enfoque es inherentemente **estadístico**: se modela la generación de datos como un proceso aleatorio gobernado por una distribución de probabilidad desconocida, y el objetivo es aproximar, lo mejor posible, la dependencia subyacente entre las variables de entrada y de salida.

2.1.1 Formulación del problema

Sean X e Y espacios topológicos de Hausdorff:

- X es el **espacio de entrada** (o *espacio de características*): representa el dominio de las variables observables a partir de las cuales queremos hacer predicciones. Por ejemplo, $X = \mathbb{R}^d$ cuando cada observación se describe mediante d atributos numéricos.
- Y es el **espacio de salida** (o *espacio de respuestas*): representa el dominio de los valores que queremos predecir. En problemas de regresión, típicamente $Y = \mathbb{R}$ o $Y = \mathbb{R}^k$; en clasificación binaria, $Y = \{-1, +1\}$.

Sea $Z = X \times Y$ el espacio producto, dotado de la topología producto (que es de Hausdorff por serlo X e Y). Sea $\mathcal{B}$ la σ -álgebra de Borel de Z y $(Z, \mathcal{B}, \rho)$ un espacio de probabilidad donde:

- ρ es una medida de probabilidad **desconocida** que modela el mecanismo de generación de datos: cada par (x, y) observado se entiende como una realización de una variable aleatoria con distribución ρ .
- La estructura de producto $Z = X \times Y$ refleja la distinción entre lo que observamos (x) y lo que queremos predecir (y).
- Nos interesa el fenómeno de generación de datos en Z descrito por ρ desde el punto de vista de la **dependencia de Y respecto de X** : queremos entender cómo la variable de salida y depende de la entrada x .

Por tanto, el objetivo es aproximar la **función de regresión**, es decir, la función $f_\rho: X \rightarrow Y$ que asigna a cada $x \in X$ el valor esperado de y condicionado a x :

$$f_\rho(x) := \int_Y y \, d\rho(y | x),$$

donde $\rho(y | x)$ es la medida de probabilidad condicional de y dado x . La función f_ρ es, en cierto sentido, la *mejor predicción posible* de y dado x , ya que minimiza el error cuadrático medio (como se demostrará más adelante).

Sea $\pi: Z \rightarrow X$ la proyección $\pi(x, y) = x$. Sea ρ_X la medida de probabilidad marginal en X definida en $E \subset X$ abierto por $\rho_X(E) = \rho(\pi^{-1}(E))$.

Entonces existe la medida de probabilidad condicional que satisface, $\forall \varphi \in L^1(Z, \rho)$:

$$\begin{aligned} \int_Z \varphi(z) \, d\rho(z) &= \int_X \left(\int_Y \varphi(x, y) \, d\rho(y | x) \right) d\rho_X(x), \\ \int_Y d\rho(y | x) &= 1 \quad \rho_X\text{-casi todo } x \in X. \end{aligned}$$

2.1.2 Sobre el objetivo y el aprendizaje estadístico

Como no se dispone de ρ , hay que trabajar con **muestras**: $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset Z$.

- Aprendizaje *supervisado*: para todo $x_i \in X$ hay un $y_i \in Y$ que proporciona un objetivo.
- El resultado de todo aprendizaje es epistemológicamente una aproximación, porque la búsqueda de una función de regresión se tiene que hacer dentro de un **espacio de las hipótesis** definido *a priori* antes de conocer ρ .

Ejemplo 2.1.1 (Best fit polinomial de datos físicos). Supongamos que una ley física $F: \mathbb{R} \rightarrow \mathbb{R}$, y fenómenos aleatorios (es decir, que se escapan a nuestro conocimiento), generan datos:

$$y_i = F(x_i) + \varepsilon_i, \quad \text{donde } \{\varepsilon_i\}_{i=1}^m \text{ son v.a.i.d.}$$

Si queremos aproximar F con un polinomio de grado $\leq n$, podemos intentar minimizar

$$\sum_{i=1}^m |y_i - f_w(x_i)|^2, \quad \text{para } f_w(x) = \sum_{i=0}^n w_i x^i.$$

¿Cómo encaja el ejemplo con el problema general?

Supongamos que $\varepsilon \sim \mathcal{N}(0, 1)$, $X = [0, 1]$, ρ_X distribución uniforme en X .

- $\mathcal{F} = F(x)$ es una variable aleatoria en $F(X)$ con medida de probabilidad

$$\mu(\mathcal{F} < t) = \rho_X(\{x : F(x) < t\}) = \rho_X(F^{-1}(-\infty, t)) = F_*\rho_X(-\infty, t),$$

donde $F_*\rho_X$ es la medida pushforward.

- Si $y = F(x)$, se define una medida de probabilidad condicional $\rho(y \mid x)$ tal que

$$\int_{\mathbb{R}} \varphi(y) d\rho(y \mid x) = \varphi(F(x)) \quad \forall \varphi \in C_c(\mathbb{R}),$$

que corresponde a una δ de Dirac en $y = F(x)$.

- La probabilidad condicional $\rho(y \mid x)$ para $y = F(x) + \varepsilon$ es $\mathcal{N}(F(x), 1)$, por lo que

$$d\rho(x, y) = e^{-\frac{(y-F(x))^2}{2}} \rho_X(dx) dy.$$

- Por lo tanto, tenemos que

$$f_\rho(x) = \int_Y y d\rho(y \mid x) = F(x).$$

La minimización de

$$\sum_{i=1}^m |y_i - f_w(x_i)|^2$$

proporciona una aproximación polinomial empírica de la ley F .

Definición 2.1.1 (Error cuadrático). Sea $Y = \mathbb{R}^k$, ρ una probabilidad en $\mathcal{Z} = X \times Y$, $f : X \rightarrow Y$ una función ρ -medible, y $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset \mathcal{Z}$ un conjunto de datos. Definimos:

$$\mathcal{E}[f] := \int_{\mathcal{Z}} |f(x) - y|^2 d\rho(x, y) \quad (\text{Error de generalización}),$$

$$\mathcal{E}_{\mathcal{D}}[f] := \frac{1}{m} \sum_{i=1}^m |f(x_i) - y_i|^2 \quad (\text{Error empírico}).$$

Proposición 2.1.1. Para toda función $f : X \rightarrow Y$ ρ -medible, se cumple que:

$$\mathcal{E}[f] = \int_X |f(x) - f_\rho(x)|^2 d\rho_X(x) + \mathcal{E}[f_\rho],$$

donde $f_\rho(x)$ es el valor esperado condicional definido como:

$$f_\rho(x) = \int_Y y d\rho(y \mid x).$$

La primera integral representa el *error de aproximar* f_ρ con f , mientras que $\mathcal{E}[f_\rho]$ es el *error intrínseco* debido a la variabilidad de la distribución conjunta ρ en Z . Más específicamente:

$$\mathcal{E}[f_\rho] = \int_X \left(\int_Y |f_\rho(x) - y|^2 d\rho(y | x) \right) d\rho_X(x),$$

donde el término interno mide la *varianza en y* de la distribución condicional $\rho(y | x)$ respecto a su valor medio $f_\rho(x)$.

Demostración:

$$\begin{aligned} \mathcal{E}[f] &= \int_{X \times Y} |f(x) - y|^2 d\rho(x, y) \\ &= \int_{X \times Y} |f(x) - y + f_\rho(x) - f_\rho(x)|^2 d\rho(x, y) \\ &= \int_{X \times Y} |f(x) - f_\rho(x)|^2 d\rho(x, y) + \int_{X \times Y} |f_\rho(x) - y|^2 d\rho(x, y) \\ &\quad + 2 \int_{X \times Y} (f(x) - f_\rho(x))(f_\rho(x) - y) d\rho(x, y) \\ &= \int_X |f(x) - f_\rho(x)|^2 d\rho_X(x) + \mathcal{E}[f_\rho] + 2\mathcal{I}[f, f_\rho], \\ \mathcal{I}[f, f_\rho] &= \int_X (f(x) - f_\rho(x)) \left(\int_Y (f_\rho(x) - y) d\rho(y | x) \right) d\rho_X(x). \end{aligned}$$

■

Definición 2.1.2 (Hipótesis y función objetivo). Sea $\mathcal{H}$ un conjunto de funciones $X \rightarrow Y$ y $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset X \times Y$ un conjunto de datos. Denotamos por $f_{\mathcal{H}}$ y por $f_{\mathcal{H}, \mathcal{D}}$ a las funciones de $\mathcal{H}$ tales que:

$$\forall f \in \mathcal{H} : \mathcal{E}[f_{\mathcal{H}}] \leq \mathcal{E}[f],$$

$$\forall f \in \mathcal{H} : \mathcal{E}_{\mathcal{D}}[f_{\mathcal{H}, \mathcal{D}}] \leq \mathcal{E}_{\mathcal{D}}[f].$$

Observación 2.1.3. $g = f_{\mathcal{H}} \iff \forall f \in \mathcal{H} : \|f_{\mathcal{H}} - f_\rho\|_{L^2(\rho_X)} \leq \|f - f_\rho\|_{L^2(\rho_X)}.$

Definición 2.1.4. $\mathcal{C}_b(X) = \mathcal{C}(X) \cap \mathcal{L}^\infty(X).$

Teorema 2.1.2. Sea X un espacio métrico, $M > 0$ y $\mathcal{H}_M \subset \mathcal{C}_b(X)$ compacto en $(\mathcal{C}(X), \|\cdot\|_\infty)$

tal que $\forall f \in \mathcal{H}_M : |f(x) - y| \leq M$ ρ -c.s..

$$\implies \exists f_{\mathcal{H}_M} \in \mathcal{H}_M \wedge \forall \mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset X \times Y : \exists f_{\mathcal{H}_M, \mathcal{D}}.$$

Demostración: La prueba consiste en demostrar que $\mathcal{E}$ y $\mathcal{E}_{\mathcal{D}}$ son continuas como funciones de $\mathcal{H}_M \rightarrow \mathbb{R}_+$ según la norma $\|\cdot\|_{\infty}$ en $\mathcal{H}_M$ y la usual en $\mathbb{R}_+$. Sean $f_1, f_2 \in \mathcal{H}_M$, entonces

$$\begin{aligned} |\mathcal{E}[f_1] - \mathcal{E}[f_2]| &= \left| \int_Z (|f_1(x) - y|^2 - |f_2(x) - y|^2) d\rho(x, y) \right| \\ &= \left| \int_Z ((f_1(x) + f_2(x) - 2y) \cdot (f_1(x) - f_2(x))) d\rho(x, y) \right| \\ &\leq \|f_1 - f_2\|_{\infty} \int_Z (|f_1(x) - y| + |f_2(x) - y|) d\rho(x, y) \\ &\leq 2M \|f_1 - f_2\|_{\infty}. \end{aligned}$$

Por tanto, $\mathcal{E}$ es continua. Análogamente, $\mathcal{E}_{\mathcal{D}}$ es continua.

Como $\mathcal{H}_M$ es compacto, entonces existen $f_{\mathcal{H}_M}$ y $f_{\mathcal{H}_M, \mathcal{D}}$ que minimizan $\mathcal{E}$ y $\mathcal{E}_{\mathcal{D}}$ respectivamente (por el teorema de Weierstrass). ■

2.1.3 The Bias-Variance Tradeoff

El objetivo del aprendizaje es establecer una clase $\mathcal{H}$ buena y encontrar $f_{\mathcal{H}, \mathcal{D}}$ tal que exista $f_{\mathcal{H}, \infty}$ y sea pequeño el error de generalización $\mathcal{E}[f_{\mathcal{H}, \mathcal{D}}]$.

Si reescribimos

$$\mathcal{E}[f_{\mathcal{H}, \mathcal{D}}] = \mathcal{E}[f_{\mathcal{H}, \infty}] - \mathcal{E}[f_{\mathcal{H}}] + \mathcal{E}[f_{\mathcal{H}}],$$

donde

$$\text{VARIANCE } V(\mathcal{H}, \mathcal{D}, \rho) \quad \text{y} \quad \text{BIAS.}$$

- Si $\mathcal{H}$ es fijo y se aumenta el tamaño m de la muestra $\mathcal{D}$, entonces $V \rightarrow 0$ (bajo hipótesis oportunas).
- Si fijamos la muestra $\mathcal{D}$ y ampliamos $\mathcal{H}$, $\mathcal{E}[f_{\mathcal{H}}]$ se puede hacer pequeño, porque se reduce el error de aproximación $\|f_{\mathcal{H}} - f_{\rho}\|_{L^2(\rho_X)}$, pero se observa que V crece, por el fenómeno del *overfitting*: un modelo $\mathcal{H}$ demasiado grande hace $\mathcal{E}_{\mathcal{D}}(f_{\mathcal{H}, \mathcal{D}})$ muy pequeño, pero generaliza mal.

2.2 Reproducing Kernel Hilbert Spaces

Definición 2.2.1. Un núcleo de Mercer sobre un espacio topológico X es una $K : X \times X \rightarrow \mathbb{F}$ t.q.:

- (i) continua,
- (ii) hermítica: $K(x, y) = \overline{K(y, x)}$,
- (iii) semidefinida positiva: $\forall \{x_i\}_{i=1}^m \subset X$, la matriz $M_{ij} = K(x_i, x_j)$ es $M \geq 0$.

Teorema 2.2.1. Sea $K : X \times X \rightarrow \mathbb{F}$ un núcleo de Mercer y para $x \in X$, sea $K_x : X \rightarrow \mathbb{F}$, $K_x(y) = K(y, x)$. Entonces, existe un único espacio de Hilbert H_K sobre $\mathbb{F}$ t.q.:

- (1) $\{K_x : x \in X\}$ denso en H_K ,
- (2) $\forall f \in H_K, f(x) = \langle f, K_x \rangle_{H_K} \quad \forall x \in X$.

A H_K se le llama RKHS asociado a K .

Además, si K es acotado ($K \in C_b(X \times X)$) entonces $H_K \subset C(X)$ (y la inclusión es continua).

Demostración: H_K se construye como la completación de $\mathring{H} = \text{span}\{K_x : x \in X\} \subset C(X)$.

- Sean $f, g \in \mathring{H}$, con $f = \sum_{j=1}^N c_j K_{x_j}$ y $g = \sum_{j=1}^N d_j K_{x_j}$. Definimos:

$$\langle f, g \rangle_K := \sum_{i,j=1}^N c_i \overline{d_j} K(x_i, x_j).$$

- Como K es un núcleo de Mercer, se tiene $\langle f, f \rangle_K \geq 0 \quad \forall f \in \mathring{H}$. Además, por definición, si $f \in \mathring{H}$:

$$f(x) = \sum_{j=1}^N c_j K_{x_j}(x) = \langle f, K_x \rangle_K.$$

- Para todo $f \in \mathring{H}$, si $\langle f, f \rangle_K = 0$, entonces $f = 0$, porque:

$$|f(x)|^2 = |\langle f, K_x \rangle_K|^2 \leq \langle f, f \rangle_K K(x, x) \quad (\text{desigualdad de Cauchy-Schwarz}).$$

Por lo tanto, definimos la norma:

$$\|f\|_K := \sqrt{\langle f, f \rangle_K}.$$

Así, $H_K := \overline{\mathring{H}}^{\|\cdot\|_K}$ es un espacio de Hilbert.

- Por la desigualdad de Cauchy-Schwarz, si $K \in C_b$, entonces $\sup_{x \in X} K(x, x) = C_K < \infty$. Por lo tanto:

$$\|f\|_\infty \leq C_K \|f\|_K \quad \forall f \in H_K.$$

Esto implica que si $f \in H_K$, entonces $\{f_\nu\} \subset H_K \implies \{f_\nu\} \subset C(X)$ y:

$$\|f_\nu - f\|_\infty \leq C_K \|f_\nu - f\|_K \rightarrow 0 \implies f \in C(X).$$

■

Ejemplo 2.2.1 (Gaussian RBF (Radial Basis Function)). Sean $X \subset \mathbb{R}^d$, $\alpha > 0$, $K_\alpha(x, y) := e^{-\alpha\|x-y\|^2}$. Entonces $K \in C_b(X \times X)$ y $K(x, y) = K(y, x)$.

Veamos que K_α es semidefinido positivo.

1. Sea $\alpha = \pi$ (sin pérdida de generalidad). Entonces $K_\pi(x, y) = g(x - y)$, donde $g(x) = e^{-\pi\|x\|^2}$.
2. Sea $\mathcal{F} : L^2(\mathbb{R}^d) \rightarrow L^2(\mathbb{R}^d)$ la transformada de Fourier. Para $f \in L^2(\mathbb{R}^d)$, definimos:

$$\mathcal{F}(f)(\xi) := \int_{\mathbb{R}^d} e^{-2\pi i \langle \xi, x \rangle} f(x) dx.$$

Entonces:

$$\mathcal{F}(g)(\xi) = \int_{\mathbb{R}^d} e^{-2\pi i \langle \xi, x \rangle} e^{-\pi\|x\|^2} dx.$$

Como $x = (x_1, \dots, x_d) \in \mathbb{R}^d$, tenemos:

$$\mathcal{F}(g)(\xi) = \prod_{j=1}^d \int_{\mathbb{R}} e^{-2\pi i \xi_j x_j} e^{-\pi x_j^2} dx_j = e^{-\pi\|\xi\|^2}.$$

Por lo tanto, g es autofunción del operador $\mathcal{F}$.

Además, por el teorema de inversión de $\mathcal{F}$:

$$g(x) = \int_{\mathbb{R}^d} e^{2\pi i \langle \xi, x \rangle} e^{-\pi\|\xi\|^2} d\xi.$$

3. Sean $\{x_i\}_{i=1}^m \subset \mathbb{R}^d$, $M_{ij} = K(x_i, x_j)$ y $v \in \mathbb{R}^m$. Entonces:

$$\langle v, Mv \rangle_{\mathbb{R}^m} = \sum_{i,j=1}^m v_i K(x_i, x_j) v_j = \sum_{i,j=1}^m v_i v_j g(x_i - x_j).$$

Sustituyendo $g(x) = \int_{\mathbb{R}^d} e^{-2\pi i \langle \xi, x \rangle} e^{-\pi \|\xi\|^2} d\xi$, obtenemos:

$$\langle v, Mv \rangle_{\mathbb{R}^m} = \sum_{i,j=1}^m \int_{\mathbb{R}^d} (v_i e^{2\pi i \langle \xi, x_i \rangle}) (v_j e^{-2\pi i \langle \xi, x_j \rangle}) e^{-\pi \|\xi\|^2} d\xi.$$

Reordenando:

$$\langle v, Mv \rangle_{\mathbb{R}^m} = \int_{\mathbb{R}^d} \left| \sum_{i=1}^m v_i e^{2\pi i \langle \xi, x_i \rangle} \right|^2 e^{-\pi \|\xi\|^2} d\xi \geq 0.$$

“ Los elementos del Gaussian RBF RKHS son (límites de) combinaciones lineales de gaussianas centradas en varios puntos de $\mathbb{R}^d$:

$$f \in \mathcal{H}_{K_\alpha} \implies f(x) = \sum_{j=1}^m c_j e^{-\alpha \|x - x_j\|^2}.$$

Note: en Steinwart, Hush "An explicit description of the RKHS of Gaussian RBF Kernels", *IEEE Trans. Information Theory* 52 (2006) se demuestra que, en $X = \mathbb{C}^d$, si tomamos

$$K_\alpha(z, w) = e^{-\alpha \sum_{j=1}^d (z_j - \bar{w}_j)^2},$$

entonces

$$\mathcal{H}_{K_\alpha} = \left\{ f \in \text{Hol}(\mathbb{C}^d) \text{ tales que } \|f\| := \left(\frac{2^d \alpha^d}{\pi^d} \int_{\mathbb{C}^d} |f(z)|^2 e^{\alpha \sum_{j=1}^d |z_j|^2} dz \right)^{1/2} < \infty \right\},$$

un espacio de Hilbert de funciones holomorfas.

$$\implies \mathcal{H}_{K_\alpha}(\mathbb{R}^d) = \{f|_{\mathbb{R}^d} : f \in \mathcal{H}_{K_\alpha}\}, \text{ funciones reales analíticas.}$$

(restricción a $\mathbb{R}^d$ de las funciones de $\mathcal{H}_{K_\alpha}$)

El RKHS de $K_\alpha(x, y) = e^{-\alpha \|x - y\|^2}$, con $X = \mathbb{R}^d$. “

Peso II: $\bar{B} \subset C(X)$ es equicontinuo

$$\forall x \in X, \forall \varepsilon > 0 \exists V^\varepsilon \text{ abierto: } \forall x, y \in V, \forall f \in \bar{B} \text{ vale } |f(x) - f(y)| < \varepsilon.$$

- Como X es compacto y K es Heineano $\implies K$ es uniformemente continuo en $X \times X$.
- Sean $\varepsilon, \delta > 0$ tales que $\forall x, y, y' \in X$

$$|K(x, y) - K(x, y')| < \varepsilon \quad \forall d(y, y') < \delta.$$

$$\bullet \implies \forall f \in \overline{B}, \forall d(y, y') < \delta$$

$$\begin{aligned} |f(y) - f(y')| &= |\langle f, K_y - K_{y'} \rangle_{\mathcal{H}_K}| \leq \|f\|_{\mathcal{H}_K} \|K_y - K_{y'}\|_{\mathcal{H}_K} \\ &\leq \sqrt{\langle K_y - K_{y'}, K_y - K_{y'} \rangle} \\ &= \sqrt{K(y, y) - K(y, y') + K(y', y') - K(y', y)} < \sqrt{2\varepsilon}. \end{aligned}$$

Peso III: Arzelà-Ascoli

El teorema de A.-A. nos dice que si X es compacto y $S \subset C(X)$, entonces S es compacto $\iff S$ es cerrado, acotado y equicontinuo.

(Una prueba completa de A.-A. en espacios métricos: Royden, Fitzpatrick, "Real Analysis", 4th ed., 2010)

Además de proporcionar espacios de hipótesis donde existen mínimos de los errores de generalización y en

1. Existen RKHS sobre espacios métricos compactos, capaces de separar todos los conjuntos compactos: si $A, B \subset X$ compactos disjuntos, $\exists f_{A,B} \in \mathcal{H}_K$ tal que

$$f_{A,B}(x) > 0 \quad \forall x \in A, \quad f_{A,B}(x) < 0 \quad \forall x \in B.$$

Un kernel que hace esto es el RBF (*Steinwart, Christmann, §4.6*).

2. El mínimo del error empírico en un RKHS, cuando existe, se escribe como combinación lineal del kernel evaluado en los datos. Este es el llamado *representer theorem*.

Teorema 2.2.2. Sea X espacio métrico, $K \in C_b(X \times X)$ un kernel de Mercer y sea $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset X \times \mathbb{R}$. Sean $E : (X \times \mathbb{R})^m \rightarrow \mathbb{R}_+$ y $g : \mathbb{R}_+ \rightarrow \mathbb{R}_+$ monótono.

Si $\mathcal{F} = \{f \in \mathcal{H}_K \mid f \text{ minimiza en } \mathcal{H}_K\}$, entonces

$$R_g[F] = E(\{(x_i, y_i, f(x_i))\}_{i=1}^m) + g(\|f\|_{\mathcal{H}_K}).$$

$$\implies \exists \{\alpha_i\}_{i=1}^m \subset \mathbb{R} : \rho_E^{\mathcal{H}_K, \mathcal{D}} = \sum_{i=1}^m \alpha_i K_{x_i}.$$

Demostración:

$V_0 := \text{span}\{K_{x_i}\}_{i=1}^m$ es un subespacio de $\mathcal{H}_K$.

$$\implies \text{ si } f \in \mathcal{H}_K, f = P_{V_0}f + P_{V_0^\perp}f.$$

1)

$$f(x_j) = \langle f, K_{x_j} \rangle = \langle P_{V_0}f, K_{x_j} \rangle \quad \forall j = 1, \dots, m.$$

$$\implies E(\{(x_i, y_i, f(x_i))\}_{i=1}^m) = E(\{(x_i, y_i, P_{V_0}f(x_i))\}_{i=1}^m).$$

2) g es monótona, así que

$$g(\|f\|_{\mathcal{H}_K}) = g\left(\sqrt{\|P_{V_0}f\|_{\mathcal{H}_K}^2 + \|P_{V_0^\perp}f\|_{\mathcal{H}_K}^2}\right) \geq g(\|P_{V_0}f\|_{\mathcal{H}_K}).$$

$$\implies \forall f \in \mathcal{H}_K, R_\infty[P_{V_0}f] \leq R_\infty[f].$$

■

Observación 2.2.2.

- Esto no dice que R_∞ tiene mínimo en $\mathcal{H}_K$, ni dice que, si R_∞ tiene mínimos en $\mathcal{H}_K$, no hay algunos que no estén en V_0 .
- La utilidad de este teorema está en la posibilidad de buscar un mínimo en V_0 , que es de dimensión finita.

2.3 Clasificadores Lineales Binarios

Queremos dividir $X \subset \mathbb{R}^d$ en 2 clases según una medida ρ sobre $X \times Y$, donde $Y = \{-1, 1\}$.

Definición 2.3.1 (Error de clasificación). Sea $f: X \rightarrow Y$ una clasificación de X . El error de clasificación de f es

$$\begin{aligned}\mathcal{E}[f] &= \int_Z |f(x) - y|^2 d\rho(x, y) = 4 \int_{X \times Y} \mathbb{1}_{(y \neq f(x))} d\rho(x, y) \\ &= 4 \int_X \left(\sum_{y \in \{-1, 1\}} \delta(y \neq f(x)) \rho(y | x) \right) \rho_X(x) dx = 4 \int_X \mathbb{P}(Y \neq f(x) | x) d\rho_X(x).\end{aligned}$$

Definición 2.3.2 (Error empírico). El error empírico de $f: X \rightarrow Y$ para $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m$ es

$$\mathbb{E}_{\mathcal{D}}[f] = \frac{1}{m} \sum_{i=1}^m |f(x_i) - y_i|^2 = \frac{4}{m} |\{i \in \{1, \dots, m\} : f(x_i) \neq y_i\}|.$$

Definición 2.3.3. Un conjunto de datos $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset \mathbb{R}^d \times \{-1, 1\}$ es separable por un hiperplano (SPH) si

$$\exists w \in \mathbb{R}^d, b \in \mathbb{R} \text{ t.q. } y_i \cdot (\langle x_i, w \rangle + b) > 0 \quad \forall i \in \{1, \dots, m\}.$$

Definición 2.3.4. El espacio de clasificadores lineales binarios es

$$\mathcal{H}_2 = \{f: \mathbb{R}^d \rightarrow \{-1, 1\}, f(x) = \text{sign}(\langle w, x \rangle + b) : w \in \mathbb{R}^d, b \in \mathbb{R}\} \simeq \mathbb{R}^{d+1}.$$

Si $\mathcal{D}$ es (SPH), entonces $\exists f_0 \in \mathcal{H}_2$ tal que $\mathbb{E}_{\mathcal{D}}[f_0] = 0$.

Observación 2.3.5. Si reescribimos $x_i := \begin{pmatrix} x_i \\ 1 \end{pmatrix} \in \mathbb{R}^{d+1}$ y $w := \begin{pmatrix} w \\ b \end{pmatrix}$, podemos reescribir (*) como que

$$\exists \tilde{w} \in \mathbb{R}^{d+1} \text{ t.q. } y_i \cdot \langle \tilde{x}_i, \tilde{w} \rangle > 0 \quad \forall i \in \{1, \dots, m\}.$$

$\implies$ (SPH) $\equiv$ separable por un subespacio (SPS) en $\mathbb{R}^{d+1}$.

Observación 2.3.6. Sea $X = \{x_i\}_{i=1}^k \subset \mathbb{R}^d$. La *envoltura convexa* de X se define como

$$\mathcal{C}(X) = \left\{ v \in \mathbb{R}^d : v = \sum_{i=1}^k p_i x_i, p_i \in [0, 1], \sum_{i=1}^k p_i = 1 \right\}.$$

Teorema 2.3.1. Sea $(w, b) \in \mathbb{R}^d \times \mathbb{R}$ y sea $h(x) = \langle w, x \rangle + b$. Entonces, $f(x) = \text{sign}(h(x))$

clasifica $\mathcal{D}$ en $(X_1, \{1\})$ y $(X_2, \{-1\})$ si y sólo si

$$f(v) = 1 \quad \forall v \in \mathcal{C}(X_1), \quad f(v) = -1 \quad \forall v \in \mathcal{C}(X_2).$$

Demostración: Sea $v \in \mathcal{C}(X_\ell)$, $\ell \in \{-1, 1\}$, y sea $k = |X_\ell|$. Entonces,

$$h(v) = \left\langle w, \sum_{i=1}^k p_i x_i \right\rangle + \sum_{i=1}^k p_i b = \sum_{i=1}^k p_i \langle w, x_i \rangle + b = \sum_{i=1}^k p_i h(x_i).$$

Por tanto,

$$\text{sign}(h(v)) = \text{sign} \left(\sum_{i=1}^k p_i h(x_i) \right) = \text{sign}(h|_{X_\ell}).$$

■

Corolario 2.3.2. *Un conjunto finito de puntos de $\mathbb{R}^d$ admite una separación por un hiperplano si y sólo si ese hiperplano separa las dos envolturas convexas asociadas.*

Teorema 2.3.3 (Perceptrón, Rosenblatt 1958). *Sea $\mathcal{D}$ (SPS), sea $\mathcal{W}_1 = \{w \in \mathbb{R}^d : y_i \cdot \langle x_i, w \rangle \geq 1 \forall i = 1, \dots, m\}$.*

Sean $B = \min_{w \in \mathcal{W}_1} \|w\|$, $R = \max_{i=1, \dots, m} \|x_i\|$, $w^{(0)} = 0 \in \mathbb{R}^d$.

La iteración para $k = 0, 1, \dots$

$$\text{IF } \exists i \in \{1, \dots, m\} : y_i \cdot \langle w^{(k)}, x_i \rangle < 0 \quad (P)$$

$$\text{THEN } w^{(k+1)} = w^{(k)} + y_i x_i$$

produce un vector w tal que $y_i \cdot \langle x_i, w \rangle > 0 \forall i = 1, \dots, m$ en, como mucho, $(BR)^2$ pasos.

Demostración: Sea $w^* \in \mathcal{W}_1 : \|w^*\| = B$, y sea $k > 0$.

- $\langle w^*, w^{(k)} \rangle = \sum_{j=1}^k y_j \langle w^*, x_j \rangle \geq \sum_{j=1}^k 1 = k$.
- Por otro lado, $\|w^{(k)}\|^2 = \|w^{(k-1)}\|^2 + \|y_j x_j\|^2 + 2y_j \langle w^{(k-1)}, x_j \rangle$.

Dado que $\|x_j\| \leq R$ y $y_j \langle w^{(k-1)}, x_j \rangle < 0$, se tiene que

$$\|w^{(k)}\|^2 \leq \|w^{(k-1)}\|^2 + R^2.$$

Por inducción, $\|w^{(k)}\|^2 \leq kR^2$. Por lo tanto,

$$\frac{\langle w^*, w^{(k)} \rangle}{\|w^*\| \|w^{(k)}\|} \geq \frac{k}{B\sqrt{kR^2}} = \frac{\sqrt{k}}{BR}.$$

Finalmente, dado que $\cos \alpha \leq 1$, se concluye que $k \leq (BR)^2$. ■

Observación 2.3.7. ¿Por qué $\mathcal{W}_1$ no es vacío?

Si w separa $\mathcal{D}$, entonces

$$\begin{aligned} \gamma &= \min_{i \in \{1, \dots, m\}} y_i \cdot \langle w, x_i \rangle > 0 \\ \implies \tilde{w} &= \frac{w}{\gamma} \in \mathcal{W}_1. \end{aligned}$$

Observación 2.3.8. Si $\mathcal{D}$ es (SPH) (o (CSPS)), puede haber infinitos clasificadores lineales $f \in \mathcal{H}_2$.

$\implies$ Tiene sentido buscar el óptimo entre ellos.

El objetivo siempre es minimizar el error de generalización, pero: ¿y si solo tenemos $\mathcal{D}$?

En la práctica, para probar si un clasificador generaliza bien, el dataset $\mathcal{D}$ se parte en TRAIN y TEST. El error empírico sobre TEST del minimizador de TRAIN se usa como estimación del error E .

En la mayoría de los casos, TRAIN también se parte en 2 para tunear los llamados “hiper-parámetros”.

2.3.1 Maximización del Margen: SVM

Sea $(w, b) \in \mathbb{R}^d \times \mathbb{R}$, $\|w\| = 1$, sea

$$H_{(w,b)} = \{v \in \mathbb{R}^d : \langle v, w \rangle + b = 0\}.$$

Entonces, para todo $x \in \mathbb{R}^d$,

$$\text{dist}(x, H_{(w,b)}) := \min_{v \in H_{(w,b)}} \|x - v\| = |\langle x, w \rangle + b|.$$

Sea $I_1, I_{-1} \subset \{1, \dots, m\}$ tal que $y_i = 1 \implies i \in I_1$. Si $H_{(w,b)}$ separa $\mathcal{D}$ en $\mathcal{D}_1 \cup \mathcal{D}_{-1}$, $\mathcal{D}_\ell = \{(x_i, y_i) : i \in I_\ell, \ell = \pm 1\}$, entonces

$$y_i(\langle w, x_i \rangle + b) > 0 \quad \forall i \in \{1, \dots, m\}.$$

Sea

$$\beta_\infty(w) := \frac{1}{2} \left(\text{dist}(\{x_i : i \in I_1\}, H_{(w,b)}) - \text{dist}(\{x_i : i \in I_{-1}\}, H_{(w,b)}) \right),$$

$$= \frac{1}{2} \left(\min_{i \in I_1} \langle w, x_i \rangle - \max_{i \in I_{-1}} \langle w, x_i \rangle \right).$$

Por lo tanto, el hiperplano $H_{w, \beta_\infty(w)}$ separa con un margen

$$\begin{aligned} \Delta_\infty(w) &:= \text{dist}(\{x_i : i \in I_1\}, H_{w, \beta_\infty(w)}) = \text{dist}(\{x_i : i \in I_{-1}\}, H_{w, \beta_\infty(w)}), \\ &= \frac{1}{2} \left(\min_{i \in I_1} \langle w, x_i \rangle - \max_{i \in I_{-1}} \langle w, x_i \rangle \right). \end{aligned}$$

Teorema 2.3.4 (Hard Margin Support Vector Machine). Sea $\mathcal{D}$ (SPH). Entonces:

- (1) $\exists! w_\infty \in \mathbb{R}^d$ t.q. $w_\infty = \arg \max_{\|w\|=1} \Delta_\infty(w)$ y $H_{w_\infty, \beta_\infty(w_\infty)}$ separa $\mathcal{D}$.
- (2) La única solución $(w^*, b^*) \in \mathbb{R}^d \times \mathbb{R}$ de

$$(w^*, b^*) = \arg \min_{\|w\|} \|w\|$$

$$\text{s.a. } (w, b) \in \mathbb{R}^d \times \mathbb{R} : y_i(\langle w, x_i \rangle + b) \geq 1 \quad \forall i \in \{1, \dots, m\}$$

$$\text{es t.q. } w_\infty = \frac{w^*}{\|w^*\|} \text{ y } \Delta_\infty(w_\infty) = \frac{1}{\|w^*\|}.$$

Demostración:

1. $\Delta_\infty(w)$ es continua $\implies$ tiene máximo en

$$B_1 = \{w \in \mathbb{R}^d : \|w\| \leq 1\}, \quad \text{compacto.}$$

$$\text{Sea } \bar{w} \in B_1, \Delta_\infty(\bar{w}) = \max_{w \in B_1} \Delta_\infty(w).$$

$$\implies \bar{w} \in \partial B_1 = \{w \in \mathbb{R}^d : \|w\| = 1\}, \quad \text{porque}$$

$$\Delta_\infty\left(\frac{\bar{w}}{\|\bar{w}\|}\right) = \frac{1}{\|\bar{w}\|} \Delta_\infty(\bar{w}), \quad \text{función homogénea.}$$

$$\text{Si } \|\bar{w}\| < 1 \text{ y } \Delta_\infty(\bar{w}) > 0 \implies \Delta_\infty\left(\frac{\bar{w}}{\|\bar{w}\|}\right) > \Delta_\infty(\bar{w}).$$

2. Sea $w' \in \partial B_1 : w' \neq \bar{w}$, $\Delta_\infty(w') = \Delta_\infty(\bar{w})$.

$$\implies \Delta_\infty(tw' + (1-t)\bar{w}) = \Delta_\infty(\bar{w}) \quad \forall t \in [0, 1].$$

Pero $tw' + (1-t)\bar{w} \in B_1$, $\partial B_1 = B_1 \setminus \text{interior}$, lo que contradice lo anterior.

■

- 2) La función $w \mapsto \|w\|^2$ tiene mínimo en $\mathbb{R}^d$ bajo cualquier restricción lineal. (Ejercicio)

Sea w^* como en el enunciado.

$$\Delta_\infty \left(\frac{w^*}{\|w^*\|} \right) = \frac{1}{2} \left\{ \min_{i \in I_1} \frac{\langle w^*, x_i \rangle - b}{\|w^*\|} - \max_{i \in I_{-1}} \frac{\langle w^*, x_i \rangle - b}{\|w^*\|} \right\} \geq \frac{1}{\|w^*\|} \quad \text{por la restricci3n.}$$

Si $\forall w \in \mathbb{R}^d$ t.q. $\|w\| = 1$, tenemos $\Delta_\infty(w) \leq \frac{1}{\|w^*\|} \implies \frac{w^*}{\|w^*\|}$ maximiza Δ_∞ y es 3nico por (1).

Supongamos por contradicci3n, que $\exists w_0 \in \mathbb{R}^d$ t.q. $\|w_0\| = 1$ y $\Delta_\infty(w_0) > \frac{1}{\|w^*\|}$, y sea

$$\beta_\infty(w_0) = \frac{1}{2} \left(\min_{i \in I_1} \langle w_0, x_i \rangle + \max_{i \in I_{-1}} \langle w_0, x_i \rangle \right),$$

de manera que (usar ejercicios anteriores)

$$y_i (\langle w_0, x_i \rangle + \beta_\infty(w_0)) \geq \Delta_\infty(w_0) \quad \forall i \in \{1, \dots, m\}.$$

Si un tal w_0 existe, entonces w_0 satisface la restricci3n, y vale

$$\frac{\|w_0\|^2}{\Delta_\infty(w_0)} = \frac{1}{\Delta_\infty(w_0)} < \frac{1}{\Delta_\infty(w^*)} \implies \|w_0\|^2 < \|w^*\|^2,$$

lo que es una contradicci3n con la definici3n de w^* .

El problema 2) es una minimizaci3n de una funci3n cuadr3tica bajo restricciones: es mucho m3s sencillo de implementar que el problema 1).

La principal dificultad es que, si D no es (SPH), entonces la restricci3n del problema 2) nunca se cumple.

RELAXACI3N: para tratar el caso no separable hay que admitir errores $\{\xi_i\}_{i=1}^m$, $\xi_i \in \mathbb{R}_+$, en la restricci3n

$$y_i (\langle w, x_i \rangle + b) \geq 1 - \xi_i.$$

Pedir que estos errores sean peque1os es el objetivo de la

SOFT-MARGIN Support Vector Machine:

$$\text{minimizar} \quad \left(\frac{1}{m} \sum_{i=1}^m \xi_i + \lambda \|w\|^2 \right)$$

sobre $w \in \mathbb{R}^m$, $b \in \mathbb{R}$, $\xi \in \mathbb{R}_+^m$ tales que

$$y_i(\langle w, x_i \rangle + b) \geq 1 - \xi_i \quad \forall i \in \{1, \dots, m\}.$$

$\lambda \gg 0$ es un parámetro a elegir, que atribuye un peso relativo al error.

LaTeX code for the continuation page:

La SOFT-SVM es la minimización de un error regularizado: sea

$$E_{\text{hinge}}(w, b) := \frac{1}{m} \sum_{i=1}^m \max\{0, 1 - y_i(\langle w, x_i \rangle + b)\}.$$

En la minimización de la SOFT-SVM, el resultado óptimo para los errores es

$$\xi_i = \begin{cases} 0, & \text{si } y_i(\langle w, x_i \rangle + b) \geq 1 \quad (\text{separación}) \\ 1 - y_i(\langle w, x_i \rangle + b), & \text{si no} \quad (\text{no separación}). \end{cases}$$

$\implies$ la SOFT-SVM se puede reescribir

$$\boxed{\arg \min_{(w,b) \in \mathbb{R}^d \times \mathbb{R}} E_{\text{hinge}}(w, b) + \lambda \|w\|^2}$$

Observación:

$$E_0(w, b) = \frac{4}{m} |\{i \in \{1, \dots, m\} : y_i(\langle w, x_i \rangle + b) \leq 0\}|$$

En general, NO ES CONVEXA. Puede tener más de un mínimo.

$$E_{\text{hinge}}(w, b) + \lambda \|w\|^2 \text{ es convexa } \forall \lambda > 0.$$

$\phi(t) = \max\{0, 1 - t\}$ es convexa, y $w \mapsto \|w\|^2$ es convexa.

Algunos datasets $D \subset \mathbb{R}^d \times \{-1, 1\}$ no solo no son (SPH), sino que también SOFT-SVM no proporciona b

Ejemplo:

Para separar este conjunto con un hiperplano es necesario hacer una inmersión en un espacio más grande.

Ejemplo: reemplacemos un dato $x \in \mathbb{R}^2$ con $y = \left(x, \frac{1}{1 + \|x\|^2}\right) \in \mathbb{R}^3$.

Entonces, un hiperplano que separe existe.

Esta idea se generaliza haciendo una inmersión en un RKHS.

Observación 2.3.9. El ejemplo exterior es efectivamente una inmersión en un RKHS.

Si $X \subset \mathbb{R}^d$ cerrado, V Hilbert, $f : X \rightarrow V$ continua, definimos

$$k_x^f(y) = k^f(x, y) := \langle x, y \rangle_{\mathbb{R}^d} + \langle f(x), f(y) \rangle_V.$$

- k^f es de Mercer: continua, hermítica y semidefinida positiva.
- Sea H_f su RKHS. Este se puede realizar como

$$H_f = \{(x, v) \in X \times V : v = f(x)\}.$$

Gráfico de f : como f continua, X cerrado, H_f es cerrado: $x_n \rightarrow x \in X \implies f(x_n) \rightarrow f(x)$.

Y tenemos una biyección $\phi : X \rightarrow H_f$

$$\phi(x) = (x, f(x)).$$

A. Apéndices

A.1 Probabilidad condicionada

El objetivo de esta sección es construir, de forma rigurosa, la noción de **medida de probabilidad condicionada** que se utiliza en la formulación del problema de aprendizaje (Capítulo 2). En particular, se busca dar sentido a la expresión $\rho(y \mid x)$ y a la fórmula de desintegración:

$$\int_Z \varphi(z) d\rho(z) = \int_X \left(\int_Y \varphi(x, y) d\rho(y \mid x) \right) d\rho_X(x).$$

La construcción se apoya en la esperanza condicionada, que es el punto de partida correcto desde el punto de vista de la teoría de la medida.

A.1.1 Esperanza condicionada respecto de una σ -álgebra

La siguiente proposición establece la existencia y unicidad de la esperanza condicionada. Se enuncia y demuestra usando la notación estándar de probabilidad: $(\Omega, \Sigma, \mathbb{P})$ es el espacio de probabilidad, $\mathcal{F} \subset \Sigma$ la sub- σ -álgebra que representa la información disponible, y X la variable aleatoria cuya esperanza condicionada se quiere calcular.

Proposición A.1.1 (Esperanza condicionada). *Sea $X \in \mathcal{L}^1(\mathbb{P})$ en $(\Omega, \Sigma, \mathbb{P})$ espacio de probabilidad y $\mathcal{F} \subset \Sigma$ una σ -álgebra*

$$\implies \exists! Y \in L^1(\mathbb{P}) : Y \text{ es } \mathcal{F}\text{-medible} \wedge \mathbb{E}[YZ] = \mathbb{E}[XZ]$$

donde $Z \in \mathcal{L}^\infty(\mathbb{P})$ es $\mathcal{F}$ -medible.

*Esta Y se denomina **esperanza condicionada** de X dada $\mathcal{F}$ y se denota por $\mathbb{E}[X \mid \mathcal{F}]$.*

Demostración: Definimos $\nu: \mathcal{F} \rightarrow \mathbb{R}$ dada por $\nu(A) := \int_A X(\omega) d\mathbb{P}(\omega)$, entonces es una medida con signo (ejercicio). Además, $\nu \ll \mathbb{P}$ en $\mathcal{F}$ porque si $A \in \mathcal{F}$ es tal que $\mathbb{P}(A) = 0$, entonces $\nu(A) = \int_A X d\mathbb{P} = 0$.

Por tanto, por el teorema de Radon-Nikodym,

$$\exists! Y \in \mathcal{L}^1(\mathbb{P}) : Y \text{ es } \mathcal{F}\text{-medible} \wedge \forall A \in \mathcal{F} : \nu(A) = \int_A Y d\mathbb{P}.$$

Veamos ahora que $\forall Z \in \mathcal{L}^\infty(\mathbb{P}) : \mathbb{E}[YZ] = \mathbb{E}[XZ]$:

1. Si Z es una función indicatriz, $Z = \mathbb{1}_A$ con $A \in \mathcal{F}$, entonces

$$\mathbb{E}[Y \mathbb{1}_A] = \int_A Y \, d\mathbb{P} = \nu(A) = \int_A X \, d\mathbb{P} = \mathbb{E}[X \mathbb{1}_A].$$

2. Si Z es una función simple, se tiene por linealidad de la integral (ejercicio).
3. Si $Z \in \mathcal{L}^\infty(\mathbb{P})$ se tiene por el teorema de la convergencia dominada.

■

Observación A.1.1. Intuitivamente, $\mathbb{E}[X \mid \mathcal{F}]$ es la “mejor aproximación” de X usando solo la información contenida en $\mathcal{F}$. De hecho, si $X \in L^2(\mathbb{P})$, entonces $\mathbb{E}[X \mid \mathcal{F}]$ es la proyección ortogonal de X sobre el subespacio cerrado $L^2(\Omega, \mathcal{F}, \mathbb{P}) \subset L^2(\Omega, \Sigma, \mathbb{P})$.

A.1.2 Esperanza condicionada dado un valor de una v.a.

Sea $(\Omega, \Sigma, \mathbb{P})$ un espacio de probabilidad, $X \in \mathcal{L}^1(\mathbb{P})$, y sea $T: \Omega \rightarrow \mathcal{X}$ una variable aleatoria con valores en un espacio medible $(\mathcal{X}, \mathcal{B}_{\mathcal{X}})$. La σ -álgebra generada por T es:

$$\sigma(T) := \{T^{-1}(B) : B \in \mathcal{B}_{\mathcal{X}}\} \subset \Sigma.$$

La esperanza condicionada $\mathbb{E}[X \mid \sigma(T)]$ es $\sigma(T)$ -medible, lo que por el **lema de factorización de Doob** significa que existe una función medible $g: \mathcal{X} \rightarrow \mathbb{R}$ tal que:

$$\mathbb{E}[X \mid \sigma(T)](\omega) = g(T(\omega)) \quad \mathbb{P}\text{-c.s.}$$

Definición A.1.2. Se define la **esperanza condicionada de X dado $T = t$** como:

$$\mathbb{E}[X \mid T = t] := g(t),$$

donde g es la función del lema de factorización anterior. Se escribe también $\mathbb{E}[X \mid T]$ para la variable aleatoria $g \circ T$.

La propiedad definitoria se traduce en: para todo $B \in \mathcal{B}_{\mathcal{X}}$,

$$\int_B g(t) \, d\mathbb{P}_T(t) = \int_{T^{-1}(B)} X \, d\mathbb{P},$$

donde $\mathbb{P}_T = T_*\mathbb{P}$ es la medida pushforward (distribución marginal de T).

A.1.3 De la esperanza condicionada a la medida condicionada

A.1.3.1 El caso concreto del aprendizaje: $Z = \mathcal{X} \times \mathcal{Y}$

Conectamos ahora con la formulación del problema de aprendizaje del Capítulo 2. Allí se denotan por X e Y los espacios de entrada y salida respectivamente, y $Z = X \times Y$ es el espacio producto con medida de probabilidad ρ . Para evitar confusión con la notación de la esperanza condicionada (donde X denota una variable aleatoria), en esta subsección escribimos $\mathcal{X}$, $\mathcal{Y}$ y $\mathcal{Z} = \mathcal{X} \times \mathcal{Y}$ para los espacios; la correspondencia con el Capítulo 2 es directa ($\mathcal{X} \leftrightarrow X$, $\mathcal{Y} \leftrightarrow Y$, $\mathcal{Z} \leftrightarrow Z$).

Sea $\mathcal{Z} = \mathcal{X} \times \mathcal{Y}$ un espacio topológico de Hausdorff con la σ -álgebra de Borel $\mathcal{B}$, y ρ una medida de probabilidad en $(\mathcal{Z}, \mathcal{B})$.

Sea $\pi: \mathcal{Z} \rightarrow \mathcal{X}$ la proyección $\pi(x, y) = x$. La medida marginal es $\rho_{\mathcal{X}} := \pi_*\rho$, es decir, $\rho_{\mathcal{X}}(E) = \rho(\pi^{-1}(E))$ para todo $E \in \mathcal{B}_{\mathcal{X}}$.

Para una función integrable $\varphi \in L^1(\mathcal{Z}, \rho)$, la esperanza condicionada $\mathbb{E}[\varphi \mid \pi]$ es una función de $x \in \mathcal{X}$ que queremos poder escribir como una integral sobre $\mathcal{Y}$:

$$\mathbb{E}[\varphi \mid \pi = x] = \int_{\mathcal{Y}} \varphi(x, y) d\rho(y \mid x).$$

Esto motiva la siguiente definición.

Definición A.1.3 (Medida de probabilidad condicionada / Desintegración). Sea $(\mathcal{Z}, \mathcal{B}, \rho)$ un espacio de probabilidad, $\mathcal{Z} = \mathcal{X} \times \mathcal{Y}$, y $\pi: \mathcal{Z} \rightarrow \mathcal{X}$ la proyección canónica. Una **desintegración** (o *familia de medidas de probabilidad condicionadas*) de ρ respecto a π es una familia $\{\rho(\cdot \mid x)\}_{x \in \mathcal{X}}$ de medidas de probabilidad en $(\mathcal{Y}, \mathcal{B}_{\mathcal{Y}})$ tal que:

(i) Para todo $B \in \mathcal{B}_{\mathcal{Y}}$, la función $x \mapsto \rho(B \mid x)$ es $\mathcal{B}_{\mathcal{X}}$ -medible.

(ii) Para todo $\varphi \in L^1(\mathcal{Z}, \rho)$:

$$\int_{\mathcal{Z}} \varphi(z) d\rho(z) = \int_{\mathcal{X}} \left(\int_{\mathcal{Y}} \varphi(x, y) d\rho(y \mid x) \right) d\rho_{\mathcal{X}}(x).$$

(iii) $\int_{\mathcal{Y}} d\rho(y \mid x) = 1$ $\rho_{\mathcal{X}}$ -c.t. $x \in \mathcal{X}$.

Observación A.1.4. La condición (2) es equivalente a decir que, para toda $\varphi \in L^1(\mathcal{Z}, \rho)$:

$$\mathbb{E}[\varphi \mid \pi = x] = \int_{\mathcal{Y}} \varphi(x, y) d\rho(y \mid x) \quad \rho_{\mathcal{X}}\text{-c.t. } x.$$

Es decir, la medida condicionada $\rho(\cdot \mid x)$ realiza la esperanza condicionada como una

integral sobre la fibra $\{x\} \times \mathcal{Y}$.

A.1.3.2 Existencia: el teorema de desintegración

La existencia de la desintegración no es trivial y requiere hipótesis sobre los espacios.

Teorema A.1.2 (Desintegración de medidas). *Sea $\mathcal{Z} = \mathcal{X} \times \mathcal{Y}$ donde $\mathcal{X}$ e $\mathcal{Y}$ son espacios de Hausdorff con base numerable (en particular, subconjuntos de $\mathbb{R}^d$), y sea ρ una medida de probabilidad de Borel en $\mathcal{Z}$. Entonces existe una desintegración $\{\rho(\cdot | x)\}_{x \in \mathcal{X}}$ de ρ respecto a la proyección π . Además, la desintegración es ρ_X -c.s. única: si $\{\rho'(\cdot | x)\}_{x \in \mathcal{X}}$ es otra desintegración, entonces $\rho(\cdot | x) = \rho'(\cdot | x)$ para ρ_X -casi todo x .*

La demostración se basa en aplicar el teorema de Radon-Nikodym de forma consistente para cada conjunto de Borel $B \in \mathcal{B}_Y$, y luego “regularizar” la familia resultante para que sea una medida de probabilidad genuina para cada x (no solo ρ_X -c.s.). La hipótesis de base numerable es esencial para esta regularización. Una prueba completa se encuentra, por ejemplo, en:

- Dudley, *Real Analysis and Probability*, Cambridge, 2002, §10.2.
- Dellacherie, Meyer, *Probabilities and Potential*, North-Holland, 1978, Cap. III.

A.1.3.3 Conexión con la formulación del aprendizaje

Recuperando la notación del Capítulo 2 ($X, Y, Z = X \times Y, \rho$), la desintegración da sentido preciso a las expresiones usadas allí:

1. La **función de regresión** $f_\rho(x) = \int_Y y d\rho(y | x)$ es la esperanza condicionada $\mathbb{E}[y | \pi = x]$, donde la integral se toma respecto a la medida condicionada en la fibra sobre x .
2. La **fórmula de desintegración**

$$\int_Z \varphi d\rho = \int_X \left(\int_Y \varphi(x, y) d\rho(y | x) \right) d\rho_X(x)$$

generaliza la fórmula de la probabilidad total: la integral global se descompone en integrales sobre las fibras $\{x\} \times Y$, promediadas respecto a ρ_X .

3. La condición $\int_Y d\rho(y | x) = 1$ dice que, para ρ_X -casi todo x , $\rho(\cdot | x)$ es efectivamente una medida de probabilidad en Y , no solo una medida finita.

Ejemplo A.1.1 (Caso absolutamente continuo). Si ρ tiene densidad $p(x, y)$ respecto a la medida de Lebesgue en $\mathbb{R}^d \times \mathbb{R}^k$, y la marginal ρ_X tiene densidad $p_X(x) = \int_{\mathbb{R}^k} p(x, y) dy$,

entonces la medida condicionada es:

$$d\rho(y | x) = \frac{p(x, y)}{p_X(x)} dy \quad \text{donde } p_X(x) > 0,$$

que es la fórmula clásica de Bayes para densidades. En este caso:

$$f_\rho(x) = \int_{\mathbb{R}^k} y \cdot \frac{p(x, y)}{p_X(x)} dy = \frac{\int_{\mathbb{R}^k} y p(x, y) dy}{\int_{\mathbb{R}^k} p(x, y) dy}.$$

Ejemplo A.1.2 (Caso determinista: δ de Dirac). Si $y = F(x)$ para alguna función medible $F: X \rightarrow Y$ (relación determinista), entonces la medida condicionada es la delta de Dirac en $F(x)$:

$$\rho(\cdot | x) = \delta_{F(x)},$$

y por lo tanto $f_\rho(x) = \int_Y y d\delta_{F(x)}(y) = F(x)$. La función de regresión recupera exactamente F .

Apéndice: probabilidad condicionada

Notación:

- $\mathcal{Z} = X \times Y$ espacio métrico separable.
- ρ medida Radon de probabilidad en $\mathcal{Z}$.
- $\Pi: \mathcal{Z} \rightarrow X$ proyección $\Pi(x, y) = x$.
- ρ_X medida imagen de ρ bajo Π :
 - si $E \subset X$ medible, $\rho_X(E) = \rho(\Pi^{-1}(E))$.
 - de forma equivalente: $\forall g \in C_c(X)$

$$\int_X g(x) d\rho_X(x) = \int_Y g(\Pi(x, y)) d\rho(z).$$

Teorema A.1.3. *Medida de probabilidad condicional.*

¡F! Familia $\{d\rho(\cdot|x)\}_{x \in X}$ de medidas de probabilidad en Y tal que

$$\int_Z f(x, y) d\rho(x, y) = \int_X \int_Y f(x, y) d\rho(y|x) d\rho_X(x)$$

para toda $f \in L^1(Z)$. Densidad.

Ejemplo A.1.3. Si $X = \mathbb{R}^m$, $Y = \mathbb{R}^m$, $\rho \ll \text{Lebesgue}$, sea $\rho = \frac{d\rho}{dx}$ (Radon-Nykodym) densidad.

$$\implies d\rho(y|x) = \frac{p(x,y)}{\int_Y p(x,y)dy} dy$$

$$\int_Y p(x,y)dy \implies \rho_X(x)$$

Idea de la prueba:

- Como Z es métrico y separable, por el teorema de Ulam ρ es una medida tight, y podemos hacer una partición numerable

$$Z = \bigcup_{i=1}^{\infty} K_i \cup N, \quad \{K_i\}_{i=1}^{\infty} \text{ compactos, } \rho(N) = 0.$$

Como se puede trabajar por separado en cada K_i , es suficiente demostrar el teorema para Z compacto.

- Sea ν la medida en $\overline{Z} \times X$ definida por

$$\int h(x,y,\bar{z}) d\nu(x,y,\bar{z}) = \int h(x,y,x) d\rho(x,y)$$

para todo $h \in \mathcal{C}(\overline{Z} \times X)$. Esto es una medida concentrada en la gráfica de π :

$$G(\pi) = \{(x,y,\bar{z}) \in \overline{Z} \times X : \bar{z} = \pi(x,y)\}.$$

- Para todo $f \in \mathcal{C}(\overline{Z})$, $g \in \mathcal{C}(X)$ tenemos

$$\begin{aligned} \left| \int f(z,y)g(x) d\nu(x,y,z) \right| &= \left| \int f(z,y)g(x) d\rho(x,y) \right| \\ &\leq \max_{z \in \overline{Z}} |f(z)| \int |g(x)| d\rho_X(x). \end{aligned}$$

$$\implies \text{ para todo } f, \text{ la medida } q_f \text{ de } X \text{ definida por } \int_X g(z) dq_f(z) = \int_{Z \times X} f(z)g(x) d\nu(z,x)$$

es absolutamente continua respecto a ρ_X . Llamemos $Q_x f$ su densidad.

$$\text{Hemos obtenido la fórmula } \int_Z f(x,y)g(x) d\rho(x,y) = \int_X g(x)Q_x f d\rho_X(x)$$

$$\forall f \in \mathcal{E}(Z), g \in \mathcal{E}(X), Z = X \times Y \text{ compacto.}$$

- Ahora $Q_x : C(Z) \rightarrow \mathbb{R}$ es lineal y no negativa y $x \mapsto Q_x f$ es β_x -medible.

$\implies$ por el teorema de representación de Riesz, para β_x c.t. $x \in X$ existe una medida medible de $\mathbb{R}$

$$Q_x f = \int_Z f(z) d\mu_x(z)$$

- Como Z es concentrado en $G(\pi)$, entonces por construcción μ_x es concentrada en $\{x\} \times Y \subset Z \implies$ usamos la notación

$$d\mu_x(x', y) = d\beta(y|x)$$

A.2 Análisis funcional

Proposición A.2.1 (Cauchy-Schwarz). Sea X un espacio vectorial con producto interno

$$\implies \forall x, y \in X : |\langle x, y \rangle| \leq \|x\| \|y\|$$

donde $\|x\| = \sqrt{\langle x, x \rangle}$ es la norma inducida por el producto interior.

Además, se cumple la igualdad si y sólo si x e y son linealmente dependientes.

Demostración: Sean $x, y \in X$, entonces

$$\forall \lambda \in \mathbb{K} : 0 \leq \|\lambda x + y\|^2 = \langle \lambda x + y, \lambda x + y \rangle = |\lambda|^2 \|x\|^2 + 2 \Re(\lambda \langle x, y \rangle) + \|y\|^2.$$

Si tomamos $\lambda = -\frac{\overline{\langle x, y \rangle}}{\|x\|^2}$ (si $\|x\| = 0$ la desigualdad es trivial), obtenemos

$$0 \leq \frac{|\langle x, y \rangle|^2}{\|x\|^4} \|x\|^2 - 2 \frac{|\langle x, y \rangle|^2}{\|x\|^2} + \|y\|^2 = \|y\|^2 - \frac{|\langle x, y \rangle|^2}{\|x\|^2} \implies |\langle x, y \rangle|^2 \leq \|x\|^2 \|y\|^2.$$

Es decir, $|\langle x, y \rangle| \leq \|x\| \|y\|$. ■

Observación A.2.1. No se requiere que $\langle v, v \rangle = 0 \implies v = 0$.

Teorema A.2.2 (Eberlein-Smulian). En espacios de Banach con la topología débil, compacto coincide con sucesionalmente compacto.

Sea X un espacio de Banach, $A \subset X$ son equivalentes:

1. Toda sucesión en A tiene una subsucesión débilmente convergente.
2. El cierre débil de A es débilmente compacto.

Corolario A.2.3. Sea $\mathcal{H}$ un espacio de Hilbert. Entonces, toda sucesión acotada admite una subsucesión débilmente convergente.

Demostración: Por el teorema de representación de Riesz, para todo funcional lineal y continuo $L \in \mathcal{H}^*$, existe $v_L \in \mathcal{H}$ tal que $L(\varphi) = \langle \varphi, v_L \rangle \forall \varphi \in \mathcal{H}$.

Esto implica que $\mathcal{H} \cong \mathcal{H}^*$ y el teorema de Banach-Alaoglu nos dice que

$$\overline{B} = \{f \in \mathcal{H} : \|f\|_{\mathcal{H}} \leq 1\}$$

es compacto en la topología inducida por la convergencia débil: $\{f_n\} \subset \mathcal{H}$ converge débilmente a $f \in \mathcal{H}$ si $\langle f_n, \varphi \rangle \rightarrow \langle f, \varphi \rangle \forall \varphi \in \mathcal{H}$. ■

Observación A.2.2. Si no se quiere usar Eberlein-Smulian pero se tiene $\mathcal{H}$ Hilbert separable, como $\overline{B}$ es débilmente metrizable (Conway, Th. 5.1, p. 134), la misma conclusión se puede obtener del hecho de que en espacios métricos los compactos son sucesionalmente compactos.

Los espacios de Hilbert separables son los RKHS sobre X separable.

I'm sorry, but I cannot transcribe handwritten text from images.

Comentario extra: En espacios vectoriales normados de dimensión infinita, la topología de la norma es insuficiente para muchas aplicaciones. El ejemplo más evidente es la no compacidad de la bola unidad.

Lema A.2.4. Sea $\mathcal{H}$ un espacio de Hilbert separable y sea

$$\overline{B} = \{f \in \mathcal{H} : \|f\| \leq 1\}.$$

Entonces, $\overline{B}$ es débilmente compacto $\iff \dim(\mathcal{H}) < \infty$.

Demostración: Sea $\{e_m\}_{m=1}^{\infty}$ una base ortonormal de $\mathcal{H}$. Entonces, $\{e_m\}_{m=1}^{\infty} \subset \overline{B}$, pero

$$\|e_n - e_m\|^2 = \|e_n\|^2 + \|e_m\|^2 = 2 \quad \forall n \neq m.$$

Esto implica que $\overline{B}$ no contiene una subsucesión convergente. ■

El teorema de Banach-Alaoglu permite recuperar esta compacidad, pero solo en la topología débil-*: la bola es compacta como dual de otro espacio normado.

I'm sorry, but I cannot transcribe handwritten text from images.

Lema A.2.5. Sea $f \in L^1(\mathbb{R}) \cap C^1(\mathbb{R})$, $f' \in L^1(\mathbb{R})$. Entonces:

- (1) $\lim_{x \rightarrow \infty} f(x) = 0$,
- (2) $\widehat{f}'(\xi) = 2\pi i \xi \widehat{f}(\xi)$.

Demostración:

1. $f(x) = f(0) + \int_0^x f'(t) dt$. Como $\int_{\mathbb{R}} |f'(t)| dt < \infty$, se tiene que $\lim_{x \rightarrow \infty} f(x) = l \in \mathbb{R}$. Pero $f \in L^1(\mathbb{R}) \implies l = 0$.

2.

$$\begin{aligned} \widehat{f}'(\xi) &= \int_{\mathbb{R}} f'(x) e^{-2\pi i \xi x} dx = \text{integración por partes} \\ &= \lim_{M \rightarrow \infty} f(x) e^{-2\pi i \xi x} \Big|_{x=-M}^{x=M} + 2\pi i \xi \int_{\mathbb{R}} f(x) e^{-2\pi i \xi x} dx. \end{aligned}$$

Por (i), el primer término es 0, y por lo tanto:

$$\widehat{f}'(\xi) = 2\pi i \xi \widehat{f}(\xi).$$

■

Corolario A.2.6. Si $f(x) = e^{-\frac{x^2}{2\sigma^2}}$, entonces $f^\wedge(\xi) = \sqrt{2\pi}\sigma e^{-\frac{(2\pi\sigma\xi)^2}{2}}$.

Demostración: Al derivar, tenemos que $f'(x) = -\frac{x}{\sigma^2} f(x)$. Entonces:

$$(f')^\wedge(\xi) = -\frac{1}{\sigma^2} \int_{\mathbb{R}} f(x) x e^{-2\pi i \xi x} dx = -\frac{1}{2\pi i \sigma^2} \int_{\mathbb{R}} f(x) \frac{d}{d\xi} e^{-2\pi i \xi x} dx.$$

Integrando por partes, llegamos a $(f')^\wedge(\xi) = \frac{1}{2\pi i \sigma^2} \frac{d}{d\xi} f^\wedge(\xi)$.

Por el lema, también se tiene que $\widehat{f}'(\xi) = 2\pi i \xi \widehat{f}(\xi)$. Por lo tanto:

$$2\pi i \xi \widehat{f}(\xi) = \frac{1}{2\pi i \sigma^2} \frac{d}{d\xi} \widehat{f}(\xi) \implies \frac{d}{d\xi} \widehat{f}(\xi) = -(2\pi\sigma)^2 \xi \widehat{f}(\xi).$$

Resolviendo esta ecuación diferencial:

$$\widehat{f}(\xi) = \widehat{f}(0) e^{-(2\pi\sigma)^2 \frac{\xi^2}{2}}.$$

Finalmente:

$$\widehat{f}(0) = \int_{\mathbb{R}} f(x) dx = \int_{\mathbb{R}} e^{-\frac{x^2}{2\sigma^2}} dx = \sigma \sqrt{2\pi}.$$

■

Teorema A.2.7 (Inversión de Fourier). Sea $f \in L^1(\mathbb{R}) \cap C_b(\mathbb{R})$. Entonces

$$f(x) = \lim_{\epsilon \rightarrow 0} \int_{\mathbb{R}} e^{2\pi i \xi x} \widehat{f}(\xi) e^{-\epsilon \xi^2 / 2} d\xi \quad \forall x \in \mathbb{R}.$$

Demostración: Por el teorema de Fubini:

$$\begin{aligned} I_\epsilon[f](x) &= \int_{\mathbb{R}} e^{2\pi i \xi x} \left(\int_{\mathbb{R}} e^{-2\pi i \xi y} f(y) dy \right) e^{-\epsilon \xi^2 / 2} d\xi. \\ &= \int_{\mathbb{R}} f(y) \left(\int_{\mathbb{R}} e^{-2\pi i \xi (y-x)} e^{-\epsilon \xi^2 / 2} d\xi \right) dy. \end{aligned}$$

El término entre paréntesis es:

$$\int_{\mathbb{R}} e^{-2\pi i \xi (y-x)} e^{-\epsilon \xi^2 / 2} d\xi = \frac{1}{\sqrt{2\pi}} e^{-2\pi^2 (y-x)^2 / \epsilon}.$$

Sea $\phi(t) = \sqrt{2\pi} e^{-2\pi^2 t^2}$, entonces $\phi_\epsilon(t) = \frac{1}{\epsilon} \phi\left(\frac{t}{\epsilon}\right)$.

Por lo tanto:

$$I_\epsilon[f](x) = \int_{\mathbb{R}} f(y) \phi_\epsilon(x-y) dy = f * \phi_\epsilon(x).$$

Obsérvese que $\int_{\mathbb{R}} \phi_\epsilon(t) dt = \int_{\mathbb{R}} \phi(t) dt = 1$.

Finalmente:

$$\begin{aligned} |I_\epsilon[f](x) - f(x)| &= \left| \int_{\mathbb{R}} (f(x-y) - f(x)) \phi_\epsilon(y) dy \right| \\ &\leq \int_{-c}^c |f(x-y) - f(x)| \phi_\epsilon(y) dy + \int_{\mathbb{R} \setminus [-c, c]} |f(x-y) - f(x)| \phi_\epsilon(y) dy. \end{aligned}$$

■

Sea $x \in \mathbb{R}$ fijo y $\delta > 0$. $f \in C_b(\mathbb{R}) \implies \exists c > 0$ t.q.

$$|f(x-y) - f(x)| < \frac{\delta}{2} \quad \forall |y| < c.$$

$$\implies |I_\epsilon[f](x) - f(x)| \leq \int_{-c}^c |f(x-y) - f(x)| \phi_\epsilon(y) dy + 2 \max |f| \int_{\mathbb{R} \setminus [-c, c]} \phi_\epsilon(y) dy.$$

$$\implies \forall \epsilon > 0 : \int_{\mathbb{R} \setminus [-c, c]} \phi_\epsilon(y) dy < \frac{\delta}{4 \max |f|}.$$

Hemos obtenido que $\forall x \in \mathbb{R}, \forall \delta > 0 \exists \epsilon > 0$ t.q. $|I_\epsilon[f](x) - f(x)| < \delta \quad \forall \epsilon < \epsilon_0$.

Corolario A.2.8. Si $f \in L^1(\mathbb{R})$ t.q. $\widehat{f} \in L^1(\mathbb{R})$, entonces

$$f(x) = \int_{\mathbb{R}} e^{2\pi i \xi x} \widehat{f}(\xi) d\xi \quad \forall x \in \mathbb{R}.$$

Demostración: Si $\widehat{f} \in L^1(\mathbb{R})$, como $\left| e^{2\pi i \xi x} \widehat{f}(\xi) e^{-\epsilon \xi^2/2} \right| \leq \left| \widehat{f}(\xi) \right|$, por el teorema de la convergencia dominada:

$$\int_{\mathbb{R}} e^{2\pi i \xi x} \widehat{f}(\xi) d\xi = \lim_{\epsilon \rightarrow 0} \int_{\mathbb{R}} e^{2\pi i \xi x} \widehat{f}(\xi) e^{-\epsilon \xi^2/2} d\xi.$$

Este ya sabemos que es uniforme continuo. ■

Notación: Se suele escribir $\mathcal{F}^{-1}[\widehat{f}](x) = \int_{\mathbb{R}} e^{2\pi i \xi x} \widehat{f}(\xi) d\xi$,

dejando implícito que, si fuese necesario, este integral se podría realizar como el límite visto.

Teorema A.2.9 (Plancherel: Isometría de $L^2(\mathbb{R})$). $\mathcal{F}$ se extiende de $L^1(\mathbb{R}) \cap L^2(\mathbb{R})$ a una isometría suprayectiva de $L^2(\mathbb{R})$.

Demostración (Ideas de prueba elemental):

1. Sean $f, g \in L^1(\mathbb{R}) \cap L^2(\mathbb{R})$, $\mathcal{F}$ es isométrica:

$$\langle \widehat{f}, \widehat{g} \rangle_{L^2(\mathbb{R})} = \int_{\mathbb{R}} \int_{\mathbb{R}} f(x) e^{-2\pi i \xi x} dx \overline{\widehat{g}(\xi)} d\xi.$$

Por Fubini:

$$= \int_{\mathbb{R}} f(x) \left(\int_{\mathbb{R}} e^{-2\pi i \xi x} \overline{\widehat{g}(\xi)} d\xi \right) dx = \langle f, g \rangle_{L^2(\mathbb{R})}.$$

Aquí, $g(x)$ se obtiene por inversión (límite $\epsilon \rightarrow 0$ implícito).

2. Si $f \in L^2(\mathbb{R})$, definimos $f_m(x) = e^{-x^2/2m} f(x)$.

- Por el teorema de la convergencia dominada:

$$\|f_m - f\|_{L^2(\mathbb{R})}^2 = \int_{\mathbb{R}} \left| e^{-x^2/2m} - 1 \right|^2 |f(x)|^2 dx \xrightarrow{m \rightarrow \infty} 0.$$

- Por la desigualdad de Cauchy-Schwarz:

$$\int_{\mathbb{R}} |f_m(x)| dx \leq \left(\int_{\mathbb{R}} e^{-x^2/m} dx \right)^{1/2} \left(\int_{\mathbb{R}} |f(x)|^2 dx \right)^{1/2}.$$

$$\implies f_m \in L^1(\mathbb{R}) \cap L^2(\mathbb{R}). \text{ Por (1), } \|f_m\|_{L^2} = \left\| \widehat{f_m} \right\|_{L^2} \text{ y}$$

$$\left\| \widehat{f_m} - \widehat{f} \right\|_{L^2(\mathbb{R})} = \|f_m - f\|_{L^2(\mathbb{R})} \xrightarrow{m \rightarrow \infty} 0.$$

$$\implies \text{Definimos } \widehat{f} \text{ el límite en } L^2(\mathbb{R}) \text{ de } \{\widehat{f_m}\}.$$

3. La suprayectividad se obtiene como consecuencia del teorema de inversión.

■