
PROCESOS ESTOCÁSTICOS

Máster en Matemáticas y Aplicaciones

Hugo Marquerie

Profesor: Pablo Linares Ballesteros

Facultad de Ciencias - Universidad Autónoma de Madrid

Primer cuatrimestre

9 de octubre de 2026

Puedes encontrar mi colección completa de apuntes en <https://hmarquer.github.io>.

Índice general

0. Esperanza condicional	1
0.1. Introducción e intuición	1
0.2. Definición y propiedades principales	1
1. Martingalas a tiempo discreto	11
1.1. Filtraciones y martingalas	11
1.2. Procesos predecibles. La transformada de martingala	14
1.3. Tiempos de parada	16
1.4. Teorema de descomposición de Doob	18
1.5. Teorema de convergencia de martingalas de Doob	19
1.6. Desigualdad de Doob y convergencia en $\mathcal{L}^p$	21
1.7. Integrabilidad uniforme. Convergencia en $\mathcal{L}^1$	24
2. Cadenas de Markov	25
2.1. Primeros ejemplos	25
2.1.1. Paseos aleatorios	25
2.1.2. Modelos de difusión discretos	25
2.2. Núcleos de transición y cadenas de Markov	26
H. Hojas de ejercicios	31
H.1. Martingalas en tiempo discreto	31
E. Entregas	35
E.1. Martingalas y funciones armónicas	35

0. Esperanza condicional

0.1. Introducción e intuición

La idea clave de la esperanza condicional es calcular probabilidades en función de la información que tenemos disponible. Por ejemplo, si sabemos que un evento A ha ocurrido, podemos calcular la probabilidad de otro evento B condicionado a que A ha ocurrido. La esperanza condicional nos permite hacer esto de manera más general, considerando variables aleatorias y sigma-álgebras.

¿Por qué la medibilidad equivale a la información? En el espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$, sea $A \in \mathcal{F}$ un evento. La información de que A ha ocurrido se puede representar mediante la variable aleatoria indicadora $\mathbb{1}_A$, que toma el valor 1 si A ocurre y 0 en caso contrario. Esta variable aleatoria es medible con respecto a la sigma-álgebra generada por A (que es $\{\emptyset, A, A^c, \Omega\}$).

Para saber qué valor toma $\mathbb{1}_A$ en un punto $\omega \in \Omega$, basta con saber si $\omega \in A$ o no, dicho de otra manera, si sabemos que $\mathbb{1}_A(\omega) = 1$, esto solo nos dice que $\omega \in A$, pero no sabemos qué ω es exactamente.

Ejemplo 0.1.1. Veámoslo con un caso concreto: el del juego del tute. Consideramos

$$\Omega = \{\text{Todos los posibles repartos de cartas}\},$$

$$\mathcal{F} = \sigma\text{-álgebra generada por las cartas de mi mano.}$$

Entonces, dado un suceso $A \in \mathcal{F}$, cualquier reparto de cartas ω que respete mi mano A es posible. Sin embargo, no sabemos qué reparto de cartas es exactamente, solo que es uno de los posibles repartos que respetan mi mano.

El objetivo es ir actualizando la distribución de probabilidad a medida que vamos obteniendo información nueva.

0.2. Definición y propiedades principales

Teorema 0.2.1 (de Radon-Nikodym). Sea (X, Σ) un espacio medible, μ una medida σ -finita y ν una medida con signo finita, entonces $\exists! \lambda, s$ medidas con signo tales que

$$\nu = \lambda + s \quad \wedge \quad \lambda \ll \mu \quad \wedge \quad s \perp \mu \quad \wedge \quad \exists! f \in L^1(\mu) : \forall E \in \Sigma : \lambda(E) = \int_E f \, d\mu.$$

Esta f es la **derivada de Radon-Nikodym** de ν con respecto a μ y se denota por $d\nu/d\mu$.

Demostración: Supongamos primero que ν es una medida positiva y μ es finita. Sea

$$\mathcal{F} := \left\{ f: X \rightarrow [0, 1] : \forall E \in \Sigma : \int_E f d\mu \leq \nu(E) \right\}.$$

Observamos entonces que para $f, g \in \mathcal{F}$, $\max\{f, g\} \in \mathcal{F}$, porque si $D = \{x : f(x) > g(x)\}$,

$$\forall A \in \Sigma : \int_A \max(f, g) d\mu = \int_{A \cap D} f d\mu + \int_{A \cap D^c} g d\mu \leq \nu(A \cap D) + \nu(A \cap D^c) = \nu(A).$$

Sea ahora $a := \sup_{f \in \mathcal{F}} \int_X f d\mu$. Tenemos que $a \leq \nu(X) < \infty$. Por definición de supremo, $\exists (f_n)_{n \in \mathbb{N}} \subset \mathcal{F}$ tal que $\int_X f_n d\mu \xrightarrow{n \rightarrow \infty} a$. Entonces, tomando $g_n := \max\{f_1, \dots, f_n\}$ para cada $n \in \mathbb{N}$, tenemos que $(g_n)_{n \in \mathbb{N}} \subset \mathcal{F}$ es creciente y $\lim_{n \rightarrow \infty} \int_X g_n d\mu = a$. Definiendo

$$\forall x \in X : f_0(x) := \lim_{n \rightarrow \infty} g_n(x),$$

el teorema de la convergencia monótona nos asegura que

$$\int_X f_0 d\mu = \lim_{n \rightarrow \infty} \int_X g_n d\mu = a \leq \nu(X) < \infty.$$

Es decir, $f_0 \in \mathcal{F}$ y $f_0 \in \mathcal{L}^1(\mu)$.

Tomamos $s: \Sigma \rightarrow \mathbb{R}$ definida por

$$\forall E \in \Sigma : s(E) := \nu(E) - \int_E f_0 d\mu.$$

Como $f_0 \in \mathcal{F}$, s es una medida positiva. Sólo hace falta ver que $s \perp \mu$.

Por el **teo-descomposicion-hahn-jordan**/teorema 1, podemos descomponer ν en dos medidas positivas ν^+, ν^- tales que $\nu = \nu^+ - \nu^-$. ■

Podemos suponer que ν es medida positiva (o, si no, considerar ν^+, ν^- por separado, también supondremos μ finita o nos restringimos a $X = \bigcup X_n$, $\mu(X_n) < \infty$).

Sea $\mathcal{F} = \{f : X \rightarrow [0, 1] : \int_E f d\mu \leq \nu(E), \forall E \in \mathcal{M}\}$. Es decir, $f \in \mathcal{F} \iff d\nu - f d\mu$ es una medida positiva en $\mathcal{M}$.

Observamos que si $f, g \in \mathcal{F}$, entonces $h = \max(f, g) \in \mathcal{F}$, porque si $D = \{x : f(x) > g(x)\}$,

$$\int_A h d\mu = \int_{A \cap D} f d\mu + \int_{A \cap D^c} g d\mu \leq \nu(A \cap D) + \nu(A \cap D^c) = \nu(A).$$

Sea $a = \sup\{\int_X f d\mu : f \in \mathcal{F}\}$. Se tiene $a \leq \nu(X) < \infty$. Afirmamos que $\exists f_0 \in \mathcal{F}$ extremal, es decir, tal que $a = \int_X f_0 d\mu$ (en particular $f_0 \geq 0$ y $f_0 \in L^1(d\mu)$). Esto es porque $\exists f_n \in \mathcal{F}$ tal

que $\int_X f_n d\mu \longrightarrow a$, por definición de supremo.

Si $g_n = \max(f_1, \dots, f_n)$, g_n es creciente, $g_n \in \mathcal{F}$ y $\int_X g_n d\mu \longrightarrow a$. Definiendo $f_0(x) = \lim_{n \rightarrow \infty} g_n$, el T.C.M. prueba la afirmación.

Sea $d\lambda = d\nu - f_0 d\mu$. λ es una medida positiva, porque $f_0 \in \mathcal{F}$. Sólo hace falta ver que $d\lambda \perp d\mu$. Pero si no lo fuera, por el lema anterior, $\exists \epsilon > 0$, $E \in \mathcal{M}$ con $\mu(E) > 0$ tal que E es positivo para $d\lambda - \epsilon d\mu$. En particular, $d\lambda - \epsilon \chi_E d\mu = d\nu - (f_0 + \epsilon \chi_E) d\mu$ es una medida positiva. Pero entonces $f_0 + \epsilon \chi_E \in \mathcal{F}$, lo cual es absurdo porque

$$\int_X (f_0 + \epsilon \chi_E) d\mu = a + \epsilon \mu(E) > a.$$

Teorema 0.2.2 (Radon-Nikodym). *Sea (X, Σ) un espacio medible y μ, ν dos medidas σ -finitas en X tales que $\nu \ll \mu$. Entonces,*

$$\exists! g \geq 0 : \forall E \in \Sigma : \nu(E) = \int_E g d\mu.$$

Proposición 0.2.3 (Esperanza condicionada). *Sea $(\Omega, \Sigma, \mathbb{P})$ un espacio de probabilidad, $X \in \mathcal{L}^1(\Omega, \Sigma, \mathbb{P})$ y $\mathcal{F} \subset \Sigma$ una σ -álgebra. Entonces,*

$$\exists! Y \in L^1(\Omega, \mathcal{F}, \mathbb{P}) : \forall Z \in \mathcal{L}^\infty(\Omega, \mathcal{F}, \mathbb{P}) : \mathbb{E}[YZ] = \mathbb{E}[XZ].$$

En particular, $\forall A \in \mathcal{F} : \int_A Y d\mathbb{P} = \int_A X d\mathbb{P}$.

Esta Y se denomina **esperanza condicionada** de X dada $\mathcal{F}$ y se denota por $\mathbb{E}[X | \mathcal{F}]$.

Demostración: Definimos $\nu : \mathcal{F} \longrightarrow \mathbb{R}$ dada por $\nu(A) := \int_A X(\omega) d\mathbb{P}(\omega)$, entonces es una medida con signo (ejercicio). Además, $\nu \ll \mathbb{P}$ en $\mathcal{F}$ porque si $A \in \mathcal{F}$ es tal que $\mathbb{P}(A) = 0$, entonces $\nu(A) = \int_A X d\mathbb{P} = 0$.

Por tanto, por el teorema de Radon-Nikodym,

$$\exists! Y \in \mathcal{L}^1(\mathbb{P}) : Y \text{ es } \mathcal{F}\text{-medible} \wedge \forall A \in \mathcal{F} : \nu(A) = \int_A Y d\mathbb{P}.$$

Veamos ahora que $\forall Z \in \mathcal{L}^\infty(\mathbb{P}) : \mathbb{E}[YZ] = \mathbb{E}[XZ]$:

1. Si Z es una función indicatriz, $Z = \mathbb{1}_A$ con $A \in \mathcal{F}$, entonces

$$\mathbb{E}[Y \mathbb{1}_A] = \int_A Y d\mathbb{P} = \nu(A) = \int_A X d\mathbb{P} = \mathbb{E}[X \mathbb{1}_A].$$

2. Si Z es una función simple, se tiene por linealidad de la integral (ejercicio).

3. Si $Z \in \mathcal{L}^\infty(\mathbb{P})$ se tiene por el teorema de la convergencia dominada.

■

Ejemplo 0.2.4 (de esperanza condicional). En el espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$, sea $X \in \mathcal{L}^1$ una variable aleatoria y $A \in \mathcal{F}$ un evento y sea $\mathcal{G} = \sigma(A) = \{\emptyset, A, A^c, \Omega\}$. Entonces, si definimos

$$X_A := \frac{1}{\mathbb{P}(A)} \int_A X \, d\mathbb{P}, \quad X_{A^c} := \frac{1}{\mathbb{P}(A^c)} \int_{A^c} X \, d\mathbb{P},$$

tenemos que $\tilde{X} := X_A \mathbb{1}_A + X_{A^c} \mathbb{1}_{A^c}$ es la esperanza condicional de X con respecto a $\mathcal{G}$ ya que, para todo $B \in \mathcal{G}$, se cumple que

$$\begin{aligned} \int_B \tilde{X} \, d\mathbb{P} &= \int_B X_A \mathbb{1}_A \, d\mathbb{P} + \int_B X_{A^c} \mathbb{1}_{A^c} \, d\mathbb{P} = \int_B X \, d\mathbb{P} \\ &= \int_{A \cap B} X \, d\mathbb{P} + \int_{A^c \cap B} X \, d\mathbb{P} = \int_B X \, d\mathbb{P}. \end{aligned}$$

Proposición 0.2.5. Sea $X \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ y $\mathcal{G} \subset \mathcal{F}$. Entonces, la esperanza condicional de X con respecto a $\mathcal{G}$ existe y es única (salvo cambios en un conjunto de medida cero).

Demostración: Definimos $\forall A \in \mathcal{F} : \nu(A) := \int_A X \, d\mathbb{P}$ y consideramos las restricciones $\nu|_{\mathcal{G}}$ y $\mathbb{P}|_{\mathcal{G}}$. Entonces, $\nu|_{\mathcal{G}} \ll \mathbb{P}|_{\mathcal{G}}$ y, por el teorema de Radon-Nikodym, existe $Y \in \mathcal{L}^1(\Omega, \mathcal{G}, \mathbb{P})$ tal que $\forall B \in \mathcal{G} :$

$$\int_B Y \, d\mathbb{P} = \nu|_{\mathcal{G}}(B) = \int_B X \, d\mathbb{P}$$

y esta Y es única salvo cambios en un conjunto de medida cero. ■

Lema 0.2.6 (Ley de la esperanza total). Sea $X \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ y $\mathcal{G} \subset \mathcal{F}$. Entonces,

$$\mathbb{E}[\mathbb{E}[X | \mathcal{G}]] = \mathbb{E}[X].$$

Demostración: Tomando $B = \Omega$ en la definición de esperanza condicional, tenemos que

$$\int_{\Omega} X \, d\mathbb{P} = \int_{\Omega} \mathbb{E}[X | \mathcal{G}] \, d\mathbb{P}. \quad \blacksquare$$

Lema 0.2.7. Sea $X \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$, entonces $\mathbb{E}[X | \mathcal{F}] = X$.

Demostración: Sea $B \in \mathcal{F}$, entonces

$$\int_B X \, d\mathbb{P} = \int_B X \, d\mathbb{P}.$$

Por lo tanto, X cumple la definición de esperanza condicional con respecto a $\mathcal{F}$. ■

Proposición 0.2.8. Sea $X \in \mathcal{L}^1(\mathbb{P})$ y $\mathcal{F}$ una σ -álgebra independiente de $\sigma(X)$

$$\implies \mathbb{E}[X \mid \mathcal{F}] \equiv \mathbb{E}[X] \text{ c.s.}$$

Demostración: Sea $Z \in \mathcal{L}^\infty(\mathbb{P})$ $\mathcal{F}$ -medible, entonces $\mathbb{E}[Z \cdot \mathbb{E}[X \mid \mathcal{F}]] = \mathbb{E}[X \cdot Z]$. Como $\sigma(X)$ es independiente de $\mathcal{F}$, Z y X son independientes, por lo que

$$\mathbb{E}[Z \cdot \mathbb{E}[X \mid \mathcal{F}]] = \mathbb{E}[Z \cdot X] \stackrel{\text{prop-esperanza-prod-var-aleatorias-indep/1}}{=} \mathbb{E}[Z] \cdot \mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X] \cdot Z] \stackrel{\text{lineal}}{=}$$

Entonces, la función $Y := \mathbb{E}[X] \mathbb{1}_\Omega$ es $\mathcal{F}$ -medible y cumple $\mathbb{E}[Z \cdot Y] = \mathbb{E}[X \cdot Z]$ para todo Z $\mathcal{F}$ -medible. Por la unicidad de la esperanza condicionada, $Y = \mathbb{E}[X \mid \mathcal{F}]$ c.s. ■

Lema 0.2.9 (Linealidad de la esperanza condicional). Sean $X, Y \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ y $a, b \in \mathbb{R}$. Entonces, $\mathbb{E}[aX + bY \mid \mathcal{G}] = a\mathbb{E}[X \mid \mathcal{G}] + b\mathbb{E}[Y \mid \mathcal{G}]$.

Demostración: Se deja como ejercicio: se trata de usar la linealidad de la integral y la unicidad del teorema de Radon-Nikodym. ■

Lema 0.2.10 (Monotonía). Sean $X, Y \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ tales que $X \leq Y$ casi seguramente. Entonces, $\mathbb{E}[X \mid \mathcal{G}] \leq \mathbb{E}[Y \mid \mathcal{G}]$ casi seguramente.

Demostración: Basta probar que $\mathbb{P}(\mathbb{E}[X \mid \mathcal{G}] - \mathbb{E}[Y \mid \mathcal{G}] > 0) = 0$. Sea $\varepsilon > 0$, tomamos

$$A_\varepsilon := \{\omega \in \Omega : \mathbb{E}[X \mid \mathcal{G}](\omega) - \mathbb{E}[Y \mid \mathcal{G}](\omega) > \varepsilon\}.$$

Entonces, $A_\varepsilon \in \mathcal{G}$. Por un lado, por definición de A_ε ,

$$\int_{A_\varepsilon} (\mathbb{E}[X \mid \mathcal{G}] - \mathbb{E}[Y \mid \mathcal{G}]) \, d\mathbb{P} > \varepsilon \mathbb{P}(A_\varepsilon).$$

Por otro lado, por la definición de esperanza condicional, tenemos que

$$\int_{A_\varepsilon} (\mathbb{E}[X \mid \mathcal{G}] - \mathbb{E}[Y \mid \mathcal{G}]) \, d\mathbb{P} = \int_{A_\varepsilon} (X - Y) \, d\mathbb{P}.$$

Como $X - Y \leq 0$ casi seguramente, tenemos que $\int_{A_\varepsilon} (X - Y) d\mathbb{P} \leq 0$. Por lo tanto, $\varepsilon \mathbb{P}(A_\varepsilon) < 0$, lo que implica que $\mathbb{P}(A_\varepsilon) = 0$.

Si tomamos $A_0 := \bigcup_{n \in \mathbb{N}} A_{2^{-n}}$, tenemos que $\mathbb{P}(A_0) = \lim_{n \rightarrow \infty} \mathbb{P}(A_{2^{-n}}) = 0$. ■

Lema 0.2.11 (Convergencia monótona). Sean $(X_n)_{n \in \mathbb{N}} \subset \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ tales que $X_n \nearrow X \in \mathcal{L}^1$ c.s.. Entonces, $\mathbb{E}[X_n | \mathcal{G}] \nearrow \mathbb{E}[X | \mathcal{G}]$ c.s..

Demostración: Por monotonía de la esperanza condicional, tenemos que $\mathbb{E}[X_n | \mathcal{G}] \leq \mathbb{E}[X_{n+1} | \mathcal{G}]$ c.s., por lo que $(\mathbb{E}[X_n | \mathcal{G}])_{n \in \mathbb{N}}$ es una sucesión creciente de variables aleatorias. Entonces, por el teorema de convergencia monótona, tenemos que

$$\forall A \in \mathcal{G} : \lim_{n \rightarrow \infty} \int_A \mathbb{E}[X_n | \mathcal{G}] d\mathbb{P} = \int_A \lim_{n \rightarrow \infty} \mathbb{E}[X_n | \mathcal{G}] d\mathbb{P}.$$

Por otro lado, por definición de esperanza condicional, tenemos que

$$\forall A \in \mathcal{G} : \lim_{n \rightarrow \infty} \int_A \mathbb{E}[X_n | \mathcal{G}] d\mathbb{P} = \lim_{n \rightarrow \infty} \int_A X_n d\mathbb{P} = \int_A X d\mathbb{P} = \int_A \mathbb{E}[X | \mathcal{G}] d\mathbb{P}. \quad \blacksquare$$

Lema 0.2.12 (Desigualdad de Jensen condicional).

Sea $X \in \mathcal{L}^1(\mathbb{P})$ en $(\Omega, \Sigma, \mathbb{P})$, $\mathcal{F} \subset \Sigma$ una σ -álgebra y $\varphi: \mathbb{R} \rightarrow \mathbb{R}$ una función convexa

$$\implies \varphi(\mathbb{E}[X | \mathcal{F}]) \leq \mathbb{E}[\varphi(X) | \mathcal{F}] \text{ c.s.}$$

Demostración: La veremos el próximo día. Requiere una caracterización de la convexidad de una función en términos de aproximación puntual inferior por rectas que no intersecan a la función. ■

Lema 0.2.13. $\forall p \geq 1 : \|\mathbb{E}[X | \mathcal{G}]\|_p \leq \|X\|_p$.

Demostración: Por la desigualdad de Jensen condicional con la función convexa $f(x) = |x|^p$, tenemos que

$$\mathbb{E}[|\mathbb{E}[X | \mathcal{G}]|^p | \mathcal{G}] \leq \mathbb{E}[|X|^p | \mathcal{G}].$$

Por la ley de la esperanza total, concluimos que

$$\mathbb{E}[|\mathbb{E}[X | \mathcal{G}]|^p] \leq \mathbb{E}[|X|^p]. \quad \blacksquare$$

Lema 0.2.14 (Estabilidad). Sean $\mathcal{G}_1 \subset \mathcal{G}_2 \subset \mathcal{F}$ dos sub- σ -álgebras y $X \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$. Entonces, $\mathbb{E}[\mathbb{E}[X | \mathcal{G}_2] | \mathcal{G}_1] = \mathbb{E}[X | \mathcal{G}_1]$.

Demostración: Se sigue de que $\mathbb{E}[X | \mathcal{G}_2]$ es $\mathcal{G}_2$ -medible. ■

Lema 0.2.15 (Propiedad de la torre). Sean $\mathcal{G}_1 \subset \mathcal{G}_2 \subset \mathcal{F}$ dos sub- σ -álgebras y $X \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$. Entonces, $\mathbb{E}[\mathbb{E}[X | \mathcal{G}_1] | \mathcal{G}_2] = \mathbb{E}[X | \mathcal{G}_1]$.

Demostración: Sea $A \in \mathcal{G}_1$, entonces

$$\int_A \mathbb{E}[X | \mathcal{G}_1] d\mathbb{P} = \int_A X d\mathbb{P} = \int_A \mathbb{E}[X | \mathcal{G}_2] d\mathbb{P} = \int_A \mathbb{E}[\mathbb{E}[X | \mathcal{G}_2] | \mathcal{G}_1] d\mathbb{P}.$$

Ahora bien, como $\mathbb{E}[X | \mathcal{G}_1]$ es $\mathcal{G}_1$ -medible, tenemos que $\mathbb{E}[\mathbb{E}[X | \mathcal{G}_2] | \mathcal{G}_1] = \mathbb{E}[X | \mathcal{G}_1]$. ■

Observación 0.2.16. Sean $\mathcal{G}_1 \subset \mathcal{G}_2 \subset \mathcal{F}$ dos sub- σ -álgebras y $X \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$. Entonces, por la propiedad de la torre, tenemos que

$$\mathbb{E}[\mathbb{E}[X | \mathcal{G}_1] | \mathcal{G}_2] = \mathbb{E}[X | \mathcal{G}_1] = \mathbb{E}[\mathbb{E}[X | \mathcal{G}_2] | \mathcal{G}_1].$$

Pero cuidado, esto solo lo podemos afirmar si $\mathcal{G}_1, \mathcal{G}_2$ son comparables, es decir, si una de ellas está contenida en la otra.

Ejemplo 0.2.17. Sea $\Omega = \{a, b, c\}$, $\mathcal{F} = \mathcal{P}(\Omega)$ y $\mathbb{P}$ la medida de probabilidad uniforme. Consideramos las siguientes sub- σ -álgebras:

$$\mathcal{G}_1 = \{\emptyset, \{a\}, \{b, c\}, \Omega\}, \quad \mathcal{G}_2 = \{\emptyset, \{b\}, \{a, c\}, \Omega\}.$$

Sea $X \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ dada por

$$\forall \omega \in \Omega : X(\omega) = \mathbb{1}_{\{a\}}(\omega) - \mathbb{1}_{\{c\}}(\omega) = \begin{cases} 1, & \text{si } \omega = a, \\ 0, & \text{si } \omega = b, \\ 1, & \text{si } \omega = c. \end{cases}$$

Para calcular la esperanza condicional de X con respecto a $\mathcal{G}_1$, primero nos fijamos en que, como $\mathcal{G}_1$ es tan sencilla, se trata de una combinación lineal de las variables aleatorias indicatrices de los conjuntos $\{a\}$ y $\{b, c\}$. Es decir,

$$\exists \alpha, \beta \in \mathbb{R} : \mathbb{E}[X | \mathcal{G}_1] = \alpha \mathbb{1}_{\{a\}} + \beta \mathbb{1}_{\{b, c\}}.$$

Para calcular α y β , usamos la propiedad de la esperanza condicional:

$$\begin{aligned}\int_{\{a\}} (\alpha \mathbb{1}_{\{a\}} + \beta \mathbb{1}_{\{b,c\}}) d\mathbb{P} &= \int_{\{a\}} X d\mathbb{P} \implies \alpha \mathbb{P}(\{a\}) = \int_{\{a\}} X d\mathbb{P} = 1 \cdot \mathbb{P}(\{a\}), \\ \int_{\{b,c\}} (\alpha \mathbb{1}_{\{a\}} + \beta \mathbb{1}_{\{b,c\}}) d\mathbb{P} &= \int_{\{b,c\}} X d\mathbb{P} \implies \beta \mathbb{P}(\{b,c\}) = \int_{\{b,c\}} X d\mathbb{P} = -\frac{1}{2} \cdot \mathbb{P}(\{b,c\}).\end{aligned}$$

Por tanto, nos queda que $\alpha = 1$ y $\beta = -1/2$, luego $\mathbb{E}[X \mid \mathcal{G}_1] = \mathbb{1}_{\{a\}} - \frac{1}{2} \cdot \mathbb{1}_{\{b,c\}}$.

De manera similar, podemos volver a condicionar con respecto a $\mathcal{G}_2$. Esta vez la variable aleatoria resultante será una combinación lineal de las variables aleatorias indicatrices de los conjuntos $\{b\}$ y $\{a,c\}$. Es decir,

$$\exists \gamma, \delta \in \mathbb{R} : \mathbb{E}[\mathbb{E}[X \mid \mathcal{G}_1] \mid \mathcal{G}_2] = \gamma \mathbb{1}_{\{b\}} + \delta \mathbb{1}_{\{a,c\}}.$$

Para calcular γ y δ , usamos la propiedad de la esperanza condicional:

$$\begin{aligned}\int_{\{b\}} (\gamma \mathbb{1}_{\{b\}} + \delta \mathbb{1}_{\{a,c\}}) d\mathbb{P} &= \int_{\{b\}} \left(\mathbb{1}_{\{a\}} - \frac{1}{2} \cdot \mathbb{1}_{\{b,c\}} \right) d\mathbb{P} \implies \gamma \mathbb{P}(\{b\}) = -\frac{1}{2} \cdot \mathbb{P}(\{b\}), \\ \int_{\{a,c\}} (\gamma \mathbb{1}_{\{b\}} + \delta \mathbb{1}_{\{a,c\}}) d\mathbb{P} &= \int_{\{a,c\}} \left(\mathbb{1}_{\{a\}} - \frac{1}{2} \cdot \mathbb{1}_{\{b,c\}} \right) d\mathbb{P} \implies \delta \mathbb{P}(\{a,c\}) = \mathbb{P}(\{a\}) - \frac{1}{2} \cdot \mathbb{P}(\{c\}) = \frac{1}{2} \cdot \mathbb{P}(\{a,c\}).\end{aligned}$$

Por tanto, nos queda que $\gamma = -1/2$ y $\delta = 1/4$,

Si calculamos $\mathbb{E}[\mathbb{E}[X \mid \mathcal{G}_2] \mid \mathcal{G}_1]$, veremos que no coincide con $\mathbb{E}[\mathbb{E}[X \mid \mathcal{G}_1] \mid \mathcal{G}_2]$.

Lema 0.2.18 (Factores medibles). *Sea $\mathcal{G} \subset \mathcal{F}$ una sub- σ -álgebra, X una variable aleatoria $\mathcal{G}$ -medible y $Y \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ tales que $XY \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$. Entonces,*

$$\mathbb{E}[XY \mid \mathcal{G}] = X \mathbb{E}[Y \mid \mathcal{G}].$$

Demostración: Veámoslo por casos de complejidad creciente:

I. Si $X = \mathbb{1}_B$ para algún $B \in \mathcal{G}$, entonces

$$\begin{aligned}\int_A \mathbb{E}[\mathbb{1}_B Y \mid \mathcal{G}] d\mathbb{P} &= \int_A \mathbb{1}_B Y d\mathbb{P} = \int_{A \cap B} Y d\mathbb{P} \\ &= \int_{A \cap B} \mathbb{E}[Y \mid \mathcal{G}] d\mathbb{P} = \int_A \mathbb{1}_B \mathbb{E}[Y \mid \mathcal{G}] d\mathbb{P}.\end{aligned}$$

II. Sea $X = \sum_{i=1}^n \alpha_i \mathbb{1}_{B_i}$ una función simple $\mathcal{G}$ -medible (es decir, $\forall i \in \mathbb{N}_n : B_i \in \mathcal{G} \wedge \alpha_i \in \mathbb{R}$). Entonces, por linealidad de la esperanza condicional y el caso anterior, tenemos

que

$$\begin{aligned}\mathbb{E}[XY \mid \mathcal{G}] &= \mathbb{E}\left[\sum_{i=1}^n \alpha_i \mathbb{1}_{B_i} Y \mid \mathcal{G}\right] = \sum_{i=1}^n \alpha_i \mathbb{E}[\mathbb{1}_{B_i} Y \mid \mathcal{G}] \\ &= \sum_{i=1}^n \alpha_i \mathbb{1}_{B_i} \mathbb{E}[Y \mid \mathcal{G}] = X \mathbb{E}[Y \mid \mathcal{G}].\end{aligned}$$

III. Sea X una variable aleatoria $\mathcal{G}$ -medible no negativa. Entonces, existe una sucesión creciente de funciones simples $\mathcal{G}$ -medibles $(X_n)_{n \in \mathbb{N}}$ tal que $X_n \nearrow X$ c.s.. Por la linealidad de la esperanza condicional y el caso anterior, tenemos que

$$\begin{aligned}\mathbb{E}[X_n Y \mid \mathcal{G}] &= \mathbb{E}\left[\lim_{n \rightarrow \infty} X_n Y \mid \mathcal{G}\right] = \mathbb{E}\left[\lim_{n \rightarrow \infty} X_n Y^+ \mid \mathcal{G}\right] - \mathbb{E}\left[\lim_{n \rightarrow \infty} X_n Y^- \mid \mathcal{G}\right] \\ &\stackrel{\text{TCM}}{=} \lim_{n \rightarrow \infty} \mathbb{E}[X_n Y^+ \mid \mathcal{G}] - \lim_{n \rightarrow \infty} \mathbb{E}[X_n Y^- \mid \mathcal{G}] \\ &= \lim_{n \rightarrow \infty} X_n \mathbb{E}[Y^+ \mid \mathcal{G}] - \lim_{n \rightarrow \infty} X_n \mathbb{E}[Y^- \mid \mathcal{G}] \\ &= X \mathbb{E}[Y^+ \mid \mathcal{G}] - X \mathbb{E}[Y^- \mid \mathcal{G}] = X \mathbb{E}[Y \mid \mathcal{G}].\end{aligned}$$

IV. Sea $X \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$. Entonces, podemos separar X en su parte positiva y negativa, es decir, $X = X^+ - X^-$. Por el caso anterior, tenemos que

$$\begin{aligned}\mathbb{E}[XY \mid \mathcal{G}] &= \mathbb{E}[X^+ Y \mid \mathcal{G}] - \mathbb{E}[X^- Y \mid \mathcal{G}] \\ &= X^+ \mathbb{E}[Y \mid \mathcal{G}] - X^- \mathbb{E}[Y \mid \mathcal{G}] = X \mathbb{E}[Y \mid \mathcal{G}].\end{aligned}$$

■

Lema 0.2.19. Sean X, Y variables aleatorias tales que $XY \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ y X es $\sigma(Y, \mathcal{G})$ -independiente. Entonces,

$$\mathbb{E}[XY \mid \mathcal{G}] = \mathbb{E}[X] \mathbb{E}[Y \mid \mathcal{G}].$$

Demostración: Sea $A \in \mathcal{G}$. Entonces, tenemos que

$$\begin{aligned}\int_A \mathbb{E}[XY \mid \mathcal{G}] d\mathbb{P} &= \int_A XY d\mathbb{P} = \int_{\Omega} \mathbb{1}_A XY d\mathbb{P} \stackrel{\text{indep}}{=} \mathbb{E}[X] \int_{\Omega} \mathbb{1}_A Y d\mathbb{P} \\ &= \mathbb{E}[X] \int_A Y d\mathbb{P} = \mathbb{E}[X] \int_A \mathbb{E}[Y \mid \mathcal{G}] d\mathbb{P} = \int_A \mathbb{E}[X] \mathbb{E}[Y \mid \mathcal{G}] d\mathbb{P}.\end{aligned}$$

■

Ejemplo 0.2.20 (de que no basta con pedir X independiente de $\mathcal{G}$ y de Y). Con-

sideremos el experimento de lanzar dos monedas al aire. Entonces,

$$\Omega = \{HH, HT, TH, TT\}, \quad \mathcal{F} = \mathcal{P}(\Omega), \quad \forall \omega \in \Omega : \mathbb{P}(\{\omega\}) = 1/4.$$

Sea $X = \mathbb{1}_{\{HH, TT\}}$ e $Y = \mathbb{1}_{\{HH, TH\}}$. Consideramos además la sub- σ -álgebra $\mathcal{G} = \{\emptyset, \{HH, HT\}, \{TH, TT\}, \Omega\}$.

Entonces, X es independiente de $\mathcal{G}$ y de Y , pero no se cumple que $\mathbb{E}[XY | \mathcal{G}] = \mathbb{E}[X] \mathbb{E}[Y | \mathcal{G}]$.

Lema 0.2.21 (Proyección en $\mathcal{L}^2$). Sea $X \in \mathcal{L}^2(\Omega, \mathcal{F}, \mathbb{P})$. Entonces, $\mathbb{E}[X | \mathcal{G}]$ es la variable aleatoria $\mathcal{G}$ -medible que minimiza la distancia cuadrática a X , es decir,

$$\mathbb{E}[(X - \mathbb{E}[X | \mathcal{G}])^2] = \min_{Z \in \mathcal{G}} \mathbb{E}[(X - Z)^2].$$

Demostración: Sea $Z \in \mathcal{L}^2(\Omega, \mathcal{G}, \mathbb{P})$. Entonces, tenemos que

$$\mathbb{E}[ZX | \mathcal{G}] - \mathbb{E}[Z \mathbb{E}[X | \mathcal{G}] | \mathcal{G}] = 0.$$

■

Lema 0.2.22 (de Fatou para la esperanza condicional). Sea $(X_n)_{n \in \mathbb{N}} \subset \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ una sucesión de variables aleatorias no negativas. Entonces,

$$\mathbb{E}\left[\liminf_{n \rightarrow \infty} X_n \mid \mathcal{G}\right] \leq \liminf_{n \rightarrow \infty} \mathbb{E}[X_n | \mathcal{G}].$$

Teorema 0.2.23 (de convergencia dominada para la esperanza condicionada). Sea $(X_n)_{n \in \mathbb{N}} \subset \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ una sucesión de variables aleatorias tales que $X_n \rightarrow X$ c.s. y existe $Y \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ tal que $|X_n| \leq Y$ c.s. para todo $n \in \mathbb{N}$. Entonces,

$$\lim_{n \rightarrow \infty} \mathbb{E}[X_n | \mathcal{G}] = \mathbb{E}[X | \mathcal{G}] \text{ c.s.}$$

1. Martingalas a tiempo discreto

1.1. Filtraciones y martingalas

Definición 1.1.1 (Filtración). Sea $(\Omega, \Sigma, \mathbb{P})$ un espacio de probabilidad, F es una filtración

$$\iff F = (\mathcal{F}_n)_{n \in \mathbb{N}} : \forall n \in \mathbb{N} : \mathcal{F}_n \text{ es una } \sigma\text{-álgebra } \wedge \mathcal{F}_n \subset \mathcal{F}_{n+1} \subset \Sigma.$$

Observación 1.1.2. Dado que cada σ -álgebra $\mathcal{F}_n$ representa una cantidad de información parcial acerca del espacio de probabilidad y que $\mathcal{F}_n \subset \mathcal{F}_{n+1}$, podemos interpretar $\mathcal{F}_n$ como *toda* la información disponible hasta el instante n .

Es decir, hay un refinamiento progresivo de la información a medida que n aumenta, por eso se dice que F es una *filtración*, porque filtra la información disponible para el observador.

Definición 1.1.3 (Proceso adaptado). Sea $(X_n)_{n \in \mathbb{N}}$ un proceso estocástico y F una filtración en $(\Omega, \Sigma, \mathbb{P})$, $(X_n)_{n \in \mathbb{N}}$ es un proceso adaptado a $F \iff \forall n \in \mathbb{N} : X_n$ es $\mathcal{F}_n$ -medible.

Definición 1.1.4 (Submartingala). Sea $(X_n)_{n \in \mathbb{N}}$ un proceso estocástico adaptado a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$, $(X_n)_{n \in \mathbb{N}}$ es una submartingala

$$\iff \forall n \in \mathbb{N} : \mathbb{E}[X_{n+1} \mid \mathcal{F}_n] \geq X_n.$$

Definición 1.1.5 (Supermartingala). Sea $(X_n)_{n \in \mathbb{N}}$ un proceso estocástico adaptado a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$, $(X_n)_{n \in \mathbb{N}}$ es una supermartingala

$$\iff (-X_n)_{n \in \mathbb{N}} \text{ es una submartingala } \iff \forall n \in \mathbb{N} : \mathbb{E}[X_{n+1} \mid \mathcal{F}_n] \leq X_n.$$

Definición 1.1.6 (Martingala). Sea $(X_n)_{n \in \mathbb{N}}$ un proceso estocástico adaptado a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$, $(X_n)_{n \in \mathbb{N}}$ es una martingala

$$\iff (X_n)_{n \in \mathbb{N}} \text{ es una submartingala } \wedge (X_n)_{n \in \mathbb{N}} \text{ es una supermartingala}$$

$$\iff \forall n \in \mathbb{N} : \mathbb{E}[X_{n+1} \mid \mathcal{F}_n] = X_n.$$

Observación 1.1.7. En vista de las observaciones proceso-estocastico/2 y 1.1.2, podemos interpretar una martingala como un fenómeno aleatorio que evoluciona en el tiempo de manera tal que la mejor predicción del valor futuro, dado todo lo que se conoce hasta el momento, es igual al valor actual del fenómeno.

En otras palabras, no hay tendencia al alza ni a la baja en el valor esperado del fenómeno

a lo largo del tiempo, lo que implica que el proceso es “justo”, “neutral” o “imparcial”.

Ejemplo 1.1.8 (La Martingala de Doob). Sea $X \in \mathcal{L}^1(\mathbb{P})$, $(\mathcal{F}_n)_n$ una filtración y $X_n = \mathbb{E}[X | \mathcal{F}_n]$ para todo $n \in \mathbb{N}$. Entonces, $(X_n)_{n \in \mathbb{N}}$ es una martingala respecto a $(\mathcal{F}_n)_n$, ya que:

1. $\mathbb{E}[|X|] = \mathbb{E}[\mathbb{E}[|X| | \mathcal{F}_n]] \leq \mathbb{E}[\mathbb{E}[|X| | \mathcal{F}_n]] = \mathbb{E}[|X|] < \infty$.
2. $\forall n \in \mathbb{N} : X_n = \mathbb{E}[X | \mathcal{F}_n]$ es $\mathcal{F}_n$ -medible.
3. $\mathbb{E}[X_{n+1} | \mathcal{F}_n] = \mathbb{E}[\mathbb{E}[X | \mathcal{F}_{n+1}] | \mathcal{F}_n] \stackrel{\mathcal{F}_n \subset \mathcal{F}_{n+1}}{\downarrow} \mathbb{E}[X | \mathcal{F}_n] = X_n$.

Ejemplo 1.1.9. Sean $(X_j)_{j \in \mathbb{N}}$ variables aleatorias independientes y centradas. Entonces, si definimos

$$\forall C_0 \in \mathbb{R} : S_n^{C_0} := C_0 + \sum_{j=1}^n X_j,$$

$(S_n^{C_0})_{n \in \mathbb{N}}$ es una martingala respecto a la filtración dada por $\mathcal{F}_n = \sigma(X_1, \dots, X_n)$, ya que:

1. $\forall n \in \mathbb{N} : S_n^{C_0} = C_0 + \sum_{j=1}^n X_j$ es $\mathcal{F}_n$ -medible.
2. $\forall n \in \mathbb{N} : \mathbb{E}[|S_n^{C_0}|] \leq |C_0| + \sum_{j=1}^n \mathbb{E}[|X_j|] < \infty$.
3. Comprobamos la última condición fundamental de la definición de martingala:

$$\mathbb{E}[S_{n+1}^{C_0} | \mathcal{F}_n] = \mathbb{E}\left[X_{n+1} + C_0 + \sum_{j=1}^n X_j \mid \mathcal{F}_n\right] \stackrel{\text{lineal}}{=} \mathbb{E}[X_{n+1} | \mathcal{F}_n] + C_0 + \sum_{j=1}^n \mathbb{E}[X_j | \mathcal{F}_n].$$

Como las X_j son independientes, $\sigma(X_{n+1})$ es independiente de $\mathcal{F}_n = \sigma(X_1, \dots, X_n)$, por tanto, por la proposición 0.2.8, $\mathbb{E}[X_{n+1} | \mathcal{F}_n] = \mathbb{E}[X_{n+1}] = 0$. Además, como las $\{X_j\}_{j=1}^n$ son $\mathcal{F}_n$ -medibles, por la propiedad **lem-esperanza-condicionada/(3)** del **lem-esperanza-condicionada/lema 1** $\mathbb{E}[X_j | \mathcal{F}_n] = X_j$ para todo $j \leq n$.

$$\therefore \mathbb{E}[S_{n+1}^{C_0} | \mathcal{F}_n] = 0 + C_0 + \sum_{j=1}^n X_j = S_n^{C_0}.$$

Ejemplo 1.1.10 (Paseo aleatorio). Sean $(\xi_j)_{j \in \mathbb{N}}$ variables aleatorias independientes idénticamente distribuidas con $\mathbb{P}(\xi_j = 1) = p$ y $\mathbb{P}(\xi_j = -1) = 1 - p$. Definimos

$$\forall n \in \mathbb{N} : X_n = \sum_{j=1}^n \xi_j.$$

Entonces, como $\mathbb{E}[\xi_j] = 1 \cdot p + (-1) \cdot (1 - p) = 2p - 1$, tenemos que

$$\mathbb{E}[X_{n+1} | \mathcal{F}_n] = \mathbb{E}[X_n + \xi_{n+1} | \mathcal{F}_n] = X_n + \mathbb{E}[\xi_{n+1}] = X_n + (2p - 1).$$

Por lo tanto, tenemos tres casos distintos:

- I. Si $p \in [0, 1/2)$, $(X_n)_{n \in \mathbb{N}}$ es una supermartingala.
- II. Si $p = \frac{1}{2}$, $(X_n)_{n \in \mathbb{N}}$ es una martingala.
- III. Si $p \in (1/2, 1]$, $(X_n)_{n \in \mathbb{N}}$ es una submartingala.

Proposición 1.1.11. Sea $(X_n)_{n \in \mathbb{N}}$ una submartingala respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$. Entonces,

$$\forall m < n : X_m \leq \mathbb{E}[X_n \mid \mathcal{F}_m].$$

Demostración: Como $m < n$, existe $k \in \mathbb{N}$ tal que $m + k = n$. Veámoslo por inducción sobre k :

- Para $k = 1$, por la definición de submartingala, $\mathbb{E}[X_{m+1} \mid \mathcal{F}_m] \geq X_m$.
- Supongamos que la afirmación es cierta para k . Entonces, para $k + 1$, tenemos que

$$\mathbb{E}[X_{m+k+1} \mid \mathcal{F}_m] = \mathbb{E}[\mathbb{E}[X_{m+k+1} \mid \mathcal{F}_{m+k}] \mid \mathcal{F}_m] \geq \mathbb{E}[X_{m+k} \mid \mathcal{F}_m] \geq X_m,$$

donde la primera desigualdad se debe a que $(X_n)_{n \in \mathbb{N}}$ es una submartingala y la segunda desigualdad se debe a la hipótesis de inducción. ■

Proposición 1.1.12. Sea $(X_n)_{n \in \mathbb{N}}$ una martingala respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$ y sea $\varphi: \mathbb{R} \rightarrow \mathbb{R}$ una función convexa tal que $\forall n \in \mathbb{N} : \varphi(X_n) \in \mathcal{L}^1(\mathbb{P})$. Entonces, $(\varphi(X_n))_{n \in \mathbb{N}}$ es una submartingala respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$.

Demostración: Se sigue directamente de la desigualdad de Jensen para la esperanza condicional:

$$\varphi(X_n) = \varphi(\mathbb{E}[X_{n+1} \mid \mathcal{F}_n]) \leq \mathbb{E}[\varphi(X_{n+1}) \mid \mathcal{F}_n].$$

■

Corolario 1.1.13. Sea $p \geq 1$ y $(X_n)_{n \in \mathbb{N}}$ una martingala respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$ tal que $\forall n \in \mathbb{N} : X_n \in \mathcal{L}^p(\mathbb{P})$. Entonces, $(|X_n|^p)_{n \in \mathbb{N}}$ es una submartingala respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$.

1.2. Procesos predecibles. La transformada de martingala

Definición 1.2.1 (Proceso predecible). Sea $(X_n)_{n \in \mathbb{N}}$ un proceso estocástico adaptado a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$, $(X_n)_{n \in \mathbb{N}}$ es predecible $\iff \forall n \in \mathbb{N} : X_n$ es $\mathcal{F}_{n-1}$ -medible.

Teorema 1.2.2. Sea $X = (X_n)_{n \in \mathbb{N}}$ una submartingala y $H = (H_n)_{n \in \mathbb{N}}$ un proceso predecible tal que $\forall n \in \mathbb{N} : H_n \in \mathcal{L}^\infty \wedge H_n \geq 0$ casi seguramente. Entonces, $H \cdot X$ dada por

$$\forall n \in \mathbb{N} : (H \cdot X)_n = \sum_{j=1}^n H_j (X_j - X_{j-1})$$

es una submartingala respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$.

Demostración: Veamos que se satisfacen las condiciones de la definición de submartingala:

$$\begin{aligned} 1. \quad \mathbb{E} [| (H \cdot X)_n |] &\leq \sum_{j=1}^n \mathbb{E} [| H_j (X_j - X_{j-1}) |] \\ &\leq \sum_{j=1}^n \|H_j\|_\infty \mathbb{E} [| X_j - X_{j-1} |] \leq \sum_{j=1}^n \|H_j\|_\infty (\mathbb{E} [| X_j |] + \mathbb{E} [| X_{j-1} |]) < \infty. \end{aligned}$$

2. Comprobamos la última condición fundamental de la definición de submartingala:

$$\begin{aligned} \mathbb{E} [(H \cdot X)_{n+1} | \mathcal{F}_n] &= \sum_{j=1}^n \mathbb{E} [H_j (X_j - X_{j-1}) | \mathcal{F}_n] + \mathbb{E} [H_{n+1} (X_{n+1} - X_n) | \mathcal{F}_n] \\ &\stackrel{\text{medible}}{=} \sum_{j=1}^n H_j (X_j - X_{j-1}) + \mathbb{E} [H_{n+1} (X_{n+1} - X_n) | \mathcal{F}_n] \\ &\stackrel{H \text{ predecible}}{=} (H \cdot X)_n + H_n \mathbb{E} [X_{n+1} - X_n | \mathcal{F}_n]. \end{aligned}$$

Ahora bien, como X es una submartingala,

$$\mathbb{E} [X_{n+1} - X_n | \mathcal{F}_n] = \mathbb{E} [X_{n+1} | \mathcal{F}_n] - \mathbb{E} [X_n | \mathcal{F}_n] = \mathbb{E} [X_{n+1} | \mathcal{F}_n] - X_n \geq 0$$

casi seguramente, y como $H_n \geq 0$ casi seguramente, finalmente tenemos que

$$\mathbb{E} [(H \cdot X)_{n+1} | \mathcal{F}_n] \geq (H \cdot X)_n.$$

Así, $(H \cdot X)_n$ es una submartingala respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$. ■

Observación 1.2.3. $\forall n \in \mathbb{N} : (H \cdot X)_n$ es una suma de Riemann y también una integral estocástica discreta.

Observación 1.2.4. Si $(X_n)_{n \in \mathbb{N}}$ es una martingala, entonces la condición de $H_n \geq 0$ es innecesaria. En tal caso, se dice que $H \cdot X$ es la **transformada de martingala** de X por H .

Observación 1.2.5. Sean $(\xi_i)_{i \in \mathbb{N}}$ variables aleatorias independientes idénticamente distribuidas con $\mathbb{P}(\xi_i = 1) = 1/2$ y $\mathbb{P}(\xi_i = -1) = 1/2$. Definimos

$$\forall n \in \mathbb{N} : X_n = \sum_{j=1}^n \xi_j.$$

Entonces, $(X_n)_{n \in \mathbb{N}}$ es una martingala respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$ dada por $\mathcal{F}_n = \sigma(\xi_1, \dots, \xi_n)$.

Elaboramos la estrategia de apuesta $(Y_n)_{n \in \mathbb{N}}$, dada recursivamente por

$$\forall n \in \mathbb{N} : Y_{n+1} = Y_n + H_{n+1}\xi_{n+1}, \quad Y_0 = 0,$$

donde H_{n+1} es predecible respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$ y representa la cantidad de dinero apostada en el $(n+1)$ -ésimo paso. Entonces, tenemos que

$$\forall n \in \mathbb{N} : Y_n = Y_0 + \sum_{j=1}^n H_j (X_j - X_{j-1}).$$

Con esta interpretación, el teorema anterior nos dice que si $(X_n)_{n \in \mathbb{N}}$ es una martingala y H es un proceso predecible acotado, entonces la estrategia de apuesta Y es una martingala. En otras palabras, no hay manera de ganar dinero apostando en un juego justo.

Tomamos $\forall n \in \mathbb{N} :$

$$H_n = \begin{cases} 2H_{n-1} & \text{si } \xi_{n-1} = -1, \\ 1 & \text{si } \xi_{n-1} = 1 \end{cases}$$

Entonces, por el resultado anterior, $\mathbb{E}[(H \cdot X)_n] = 0$ para todo $n \in \mathbb{N}$. Esta estrategia es aparentemente ganadora porque, si $\xi_{n-1} = -1$, doblamos la apuesta y, si $\xi_{n-1} = 1$, apostamos 1. Por lo tanto, si en algún momento obtenemos un 1, ganamos 1 y, si obtenemos una racha de -1 's, doblamos la apuesta hasta que salga un 1. Sin embargo, el teorema nos dice que no hay manera de ganar dinero apostando en un juego justo.

En la práctica, el problema fundamental de esta estrategia es que debes tener un capital infinito para poder doblar la apuesta indefinidamente.

1.3. Tiempos de parada

Definición 1.3.1 (Tiempo de parada). Sea $T: \Omega \rightarrow \mathbb{N} \cup \{\infty\}$ una variable aleatoria en $(\Omega, \Sigma, \mathbb{P})$, T es un tiempo de parada respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$

$$\iff \forall n \in \mathbb{N} : T^{-1}(\{n\}) = \{\omega \in \Omega : T(\omega) = n\} \in \mathcal{F}_n.$$

Lema 1.3.2. Sea $T: \Omega \rightarrow \mathbb{N} \cup \{\infty\}$ una variable aleatoria, T es un tiempo de parada respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$

$$\iff \forall k \in \mathbb{N} : \{\omega \in \Omega : T(\omega) \leq k\} \in \mathcal{F}_k.$$

Demostración: Veamos ambas implicaciones:

$\Rightarrow$ Por definición, tenemos que $\forall n \in \mathbb{N} : T^{-1}(\{n\}) \in \mathcal{F}_n$. Por tanto,

$$\forall k \in \mathbb{N} : T^{-1}(\{n \in \mathbb{N} : n \leq k\}) = \bigcup_{n=1}^k T^{-1}(\{n\}) \in \mathcal{F}_k,$$

ya que las $\mathcal{F}_n$ están anidadas y son cerradas bajo uniones numerables.

$\Leftarrow$ Sea T una variable aleatoria tal que $\forall k \in \mathbb{N} : T^{-1}(\{n \in \mathbb{N} : n \leq k\}) \in \mathcal{F}_k$. Entonces, como las $\mathcal{F}_n$ son σ -álgebras anidadas, tenemos que

$$\begin{aligned} \forall n \in \mathbb{N} : T^{-1}(\{n\}) &= T^{-1}(\{k \leq n\}) \setminus T^{-1}(\{k \leq n-1\}) \\ &= T^{-1}(\{k \leq n\}) \cap (T^{-1}(\{k \leq n-1\}))^c \in \mathcal{F}_n. \end{aligned} \quad \blacksquare$$

Teorema 1.3.3. Sean $(X_n)_{n \in \mathbb{N}}$ una submartingala y T un tiempo de parada respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$. Entonces, $(X_{T \wedge n})_{n \in \mathbb{N}}$ es una submartingala respecto a $(\mathcal{F}_n)_{n \in \mathbb{N}}$, donde

$$\forall n \in \mathbb{N} : \forall \omega \in \Omega : (X_{T \wedge n})(\omega) := \begin{cases} X_n(\omega) & \text{si } T(\omega) \geq n, \\ X_{T(\omega)}(\omega) & \text{si } T(\omega) < n. \end{cases}$$

Demostración: Definimos $\forall n \in \mathbb{N} : H_n := \mathbb{1}_{\{T \geq n\}}$. Entonces, $H = (H_n)_{n \in \mathbb{N}}$ es un proceso predecible porque $\forall n \in \mathbb{N} : \{T \geq n\} = \{T \leq n-1\}^c \in \mathcal{F}_{n-1}$, y además, $H_n \geq 0$. Por tanto, $(H \cdot X)_n$ es una submartingala respecto a $(\mathcal{F}_n)_{n \in \mathbb{N}}$.

Recordemos que $\forall n \in \mathbb{N} :$

$$(H \cdot X)_n = \sum_{j=1}^n H_j (X_j - X_{j-1}) = \sum_{j=1}^n \mathbb{1}_{\{T \geq j\}} (X_j - X_{j-1}).$$

Sea $\omega \in \Omega$. Veamos dos posibilidades mutuamente excluyentes:

- I. Si $T(\omega) \geq n$, entonces $(H \cdot X)_n(\omega) = \sum_{j=1}^n (X_j - X_{j-1})(\omega) = X_n(\omega) - X_0(\omega)$.
- II. Si $T(\omega) < n$, entonces $(H \cdot X)_n(\omega) = \sum_{j=1}^{T(\omega)} (X_j - X_{j-1})(\omega) = X_{T(\omega)}(\omega) - X_0(\omega)$.

Por lo tanto, $\forall n \in \mathbb{N} : (H \cdot X)_n = X_{T \wedge n} - X_0$. Como $(H \cdot X)_n$ es una submartingala, $(X_{T \wedge n})_{n \in \mathbb{N}}$ también lo es. ■

Observación 1.3.4. Sea $(X_n)_{n \in \mathbb{N}}$ una submartingala, entonces

$$\mathbb{E}[X_0] \leq \mathbb{E}[\mathbb{E}[X_1 | \mathcal{F}_0]] = \mathbb{E}[X_1] \leq \mathbb{E}[X_2] \leq \dots$$

Por lo tanto, $(\mathbb{E}[X_n])_{n \in \mathbb{N}}$ es una sucesión creciente y acotada inferiormente por $\mathbb{E}[X_0]$. En particular, si $(X_n)_{n \in \mathbb{N}}$ es una martingala, entonces $\forall n \in \mathbb{N} : \mathbb{E}[X_n] = \mathbb{E}[X_0]$.

Ahora bien, para un tiempo de parada T , ¿es cierto que $\mathbb{E}[X_0] \leq \mathbb{E}[X_T]$? La respuesta es no, como muestra el siguiente ejemplo:

Ejemplo 1.3.5. Retomamos el ejemplo de la estrategia de martingala. Sea $(\xi_i)_{i \in \mathbb{N}}$ variables aleatorias independientes idénticamente distribuidas con $\mathbb{P}(\xi_i = 1) = 1/2$ y $\mathbb{P}(\xi_i = -1) = 1/2$. Definimos

$$\forall n \in \mathbb{N} : X_n = \sum_{j=1}^n \xi_j.$$

Entonces, $(X_n)_{n \in \mathbb{N}}$ es una martingala respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$ dada por $\mathcal{F}_n = \sigma(\xi_1, \dots, \xi_n)$.

Consideramos $\forall n \in \mathbb{N} : H_n = 2^{n-1} \mathbb{1}_{\{\xi_{n-1} = -1\}} + \mathbb{1}_{\{\xi_{n-1} = 1\}}$ y

$$\forall n \in \mathbb{N} : (H \cdot X)_n = \sum_{j=1}^n H_j (X_j - X_{j-1}).$$

Además, definimos el tiempo de parada $T = \inf \{n \in \mathbb{N} : X_n - X_{n-1} = 1\}$, entonces

$$(H \cdot X)_{T \wedge n} = \begin{cases} 1 & \text{si } T \leq n, \\ 1 - 2^n & \text{si } T > n. \end{cases}$$

Por tanto, $\mathbb{E}[(H \cdot X)_T] = \sum_{n=1}^{\infty} 1 \cdot \mathbb{P}(T = n) = \sum_{n=1}^{\infty} 2^{-n} = 1$, mientras que $\mathbb{E}[(H \cdot X)_0] = 0$.

Teorema 1.3.6. Sea $(X_n)_{n \in \mathbb{N}}$ una submartingala y sea T un tiempo de parada respecto a la

filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$ tal que $\exists N \in \mathbb{N} : \mathbb{P}(T \leq N) = 1$. Entonces,

$$\mathbb{E}[X_0] \leq \mathbb{E}[X_T] \leq \mathbb{E}[X_N].$$

Demostración: Fijamos $n \in \mathbb{N}$. Entonces, por la ley de la esperanza total, tenemos que

$$\mathbb{E}[X_{T \wedge (n+1)}] \geq \mathbb{E}[X_{T \wedge n}] \geq \cdots \geq \mathbb{E}[X_0].$$

Además, $\mathbb{E}[X_{T \wedge n}] \leq \mathbb{E}[X_{T \wedge (n+1)}] \leq \cdots \leq \mathbb{E}[X_T]$ luego $\mathbb{E}[X_0] \leq \mathbb{E}[X_T]$.

Por otro lado, para ver que $\mathbb{E}[X_T] \leq \mathbb{E}[X_N]$, tomamos $H_n := \mathbb{1}_{\{T \leq n-1\}}$. Entonces, $((H \cdot X)_n)_{n \in \mathbb{N}}$ es una submartingala y

$$(H \cdot X)_n = \sum_{j=1}^n \mathbb{1}_{\{T \leq j-1\}} (X_j - X_{j-1}) = X_n - X_{T \wedge n}.$$

Luego para $n = N$, $\mathbb{E}[X_N] - \mathbb{E}[X_T] = \mathbb{E}[(H \cdot X)_N] \geq 0$, por lo que $\mathbb{E}[X_T] \leq \mathbb{E}[X_N]$. ■

1.4. Teorema de descomposición de Doob

Definición 1.4.1 (Proceso creciente). Un proceso estocástico $(X_n)_{n \in \mathbb{N}}$ es creciente $\iff \forall n \in \mathbb{N} : X_n \leq X_{n+1}$ casi seguramente.

Teorema 1.4.2 (de descomposición de Doob). Sea $(X_n)_{n \in \mathbb{N}}$ una submartingala respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$. Entonces, existe una única descomposición de la forma $X_n = M_n + A_n$, donde

- (1) $(M_n)_{n \in \mathbb{N}}$ es una martingala respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$.
- (2) $(A_n)_{n \in \mathbb{N}}$ es un proceso estocástico creciente y predecible respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$ tal que $A_0 = 0$.

Demostración: Queremos ver que $\mathbb{E}[X_n | \mathcal{F}_{n-1}] = \mathbb{E}[M_n | \mathcal{F}_{n-1}] + \mathbb{E}[A_n | \mathcal{F}_{n-1}] = M_{n-1} + A_n = X_{n-1} + (A_n - A_{n-1})$. Por tanto, definimos

$$\begin{cases} A_n = A_{n-1} + (\mathbb{E}[X_n | \mathcal{F}_{n-1}] - X_{n-1}), \\ M_n = X_n - A_n. \end{cases}$$

Si fijamos $A_0 = 0$, la construcción es única. ■

1.5. Teorema de convergencia de martingalas de Doob

En esta sección, nos interesa estudiar el comportamiento asintótico de las martingalas. En particular, queremos encontrar las condiciones necesarias para garantizar que una martingala no escape a ∞ o evitar que oscile (*upcrossings inequality*).

Fijamos $[a, b] \subset \mathbb{R}$ queremos contar el número de veces que X_n cruza desde debajo de a hasta arriba de b . Para ello, definimos

$$\begin{aligned} N_0 &= -1 \\ N_1 &= \inf \{m > N_0 : X_m \leq a\}, \\ N_2 &= \inf \{m > N_1 : X_m \geq b\}, \\ &\vdots \\ N_{2k-1} &= \inf \{m > N_{2k-2} : X_m \leq a\}, \\ N_{2k} &= \inf \{m > N_{2k-1} : X_m \geq b\}. \end{aligned}$$

Así, tenemos que N_{2k-1} es el momento en que el X_n cruza por debajo de a (por primera vez desde que cruzó por encima de b) y N_{2k} es el momento en que X_n cruza por encima de b (por primera vez desde que cruzó por debajo de a). Por tanto, satisfacen que $\forall k \in \mathbb{N} : X_{N_{2k-1}} \leq a < b \leq X_{N_{2k}}$. Para contar el número de veces que X_n cruza desde debajo de a hasta arriba de b , definimos

$$\mathcal{U}_{n;[a,b]} := \sup \{k \in \mathbb{N} : N_{2k} \leq n\}.$$

Teorema 1.5.1 (Desigualdad de los cruces). *Sea $(X_n)_{n \in \mathbb{N}}$ una submartingala respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$. Entonces, para todo $a < b \in \mathbb{R}$ y $n \in \mathbb{N}$, se tiene que*

$$(b - a) \mathbb{E} [\mathcal{U}_{n;[a,b]}] \leq \mathbb{E} [(X_n - a)^+] - \mathbb{E} [(X_0 - a)^+].$$

Demostración: Definimos $\forall m \in \mathbb{N} : Y_m := a + (X_m - a)^+$. Entonces, $(Y_m)_{m \in \mathbb{N}}$ es una submartingala y sus cruces son los mismos que los de $(X_m)_{m \in \mathbb{N}}$.

Observamos que cada N_j es un tiempo de parada respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$, ya que

$$\forall k \in \mathbb{N} : \forall m \in \mathbb{N} : \{N_{2k-1} < m \leq N_{2k}\} = \{N_{2k-1} \leq m-1\} \cap \{N_{2k} \leq m-1\}^c \in \mathcal{F}_{m-1}.$$

Tomamos $\forall m \in \mathbb{N} : A_m := \bigcup_{k \in \mathbb{N}} \{N_{2k-1} < m \leq N_{2k}\}$ y definimos $H_m := \mathbb{1}_{A_m}$. Entonces, $\forall m \in \mathbb{N} : A_m \in \mathcal{F}_{m-1}$ y $H = (H_m)_{m \in \mathbb{N}}$ es un proceso predecible. Tomamos la transformada

de martingala $H \cdot Y$ y observamos que

$$(H \cdot Y)_n = \sum_{j=1}^n H_j (Y_j - Y_{j-1}) \geq (b-a) \mathcal{U}_{n,[a,b]} + \dots \geq (b-a) \mathcal{U}_{n,[a,b]}.$$

Tomamos ahora $\forall m \in \mathbb{N} : K_m = 1 - H_m$ y observamos que $K = (K_m)_{m \in \mathbb{N}}$ es un proceso predecible. Tomamos la transformada de martingala $K \cdot Y$ y observamos que

$$\mathbb{E}[(K \cdot Y)_n] \geq \mathbb{E}[(K \cdot Y)_0] = 0.$$

Entonces, $\mathbb{E}[Y_n] - \mathbb{E}[Y_0] = \mathbb{E}[(H \cdot Y)_n] + \mathbb{E}[(K \cdot Y)_n] \geq (b-a) \mathbb{E}[\mathcal{U}_{n,[a,b]}]$, de donde se obtiene la desigualdad deseada:

$$\mathbb{E}[(Y_n - Y_0)] = \mathbb{E}[(X_n - a)^+] - \mathbb{E}[(X_0 - a)^+] \geq (b-a) \mathbb{E}[\mathcal{U}_{n,[a,b]}].$$

■

Teorema 1.5.2 (de convergencia de Martingalas). *Sea $(X_n)_{n \in \mathbb{N}}$ una submartingala respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$ tal que $\sup_{n \in \mathbb{N}} \mathbb{E}[X_n^+] < \infty$. Entonces, existe una variable aleatoria $X_\infty \in \mathcal{L}^1(\mathbb{P})$ tal que $(X_n)_{n \in \mathbb{N}}$ converge casi seguramente a X_∞ .*

Demostración: Por la desigualdad de los cruces, $\forall a < b \in \mathbb{R} : \forall n \in \mathbb{N} :$

$$\mathbb{E}[\mathcal{U}_{n,[a,b]}] \leq \frac{1}{b-a} \mathbb{E}[(X_n - a)^+] \leq \frac{1}{b-a} (\mathbb{E}[X_n^+] + |a|)$$

luego $\sup_{n \in \mathbb{N}} \mathbb{E}[\mathcal{U}_{n,[a,b]}] < \infty$. Como la sucesión $(\mathcal{U}_{n,[a,b]})_{n \in \mathbb{N}}$ es no decreciente, por el teorema de la convergencia monótona, $\mathbb{E}[\mathcal{U}_{n,[a,b]}] < \infty \implies \mathcal{U}_{n,[a,b]} < \infty$ casi seguramente. Consideramos $A := \{\liminf_{n \rightarrow \infty} X_n < \limsup_{n \rightarrow \infty} X_n\}$ y para cualesquiera $a < b$, $A_{[a,b]} := \{\liminf_{n \rightarrow \infty} X_n < a < b < \limsup_{n \rightarrow \infty} X_n\}$.

Si $\liminf_{n \rightarrow \infty} X_n < a$, necesariamente $X_n < a$ infinitas veces y si $b < \limsup_{n \rightarrow \infty} X_n$, necesariamente $X_n > b$ infinitas veces. Por tanto, $\forall a < b \in \mathbb{R} : \mathbb{P}(A_{[a,b]}) = 0$ por la desigualdad de los cruces.

Tomamos $A = \bigcup_{a < b, a, b \in \mathbb{Q}} A_{[a,b]}$, entonces $\mathbb{P}(A) = 0$ y $\forall \omega \in A^c : \lim_{n \rightarrow \infty} X_n(\omega)$ existe y es finito. Definimos $X_\infty(\omega) := \lim_{n \rightarrow \infty} X_n(\omega)$ para $\omega \in A^c$ y $X_\infty(\omega) := 0$ para $\omega \in A$. Entonces, $(X_n)_{n \in \mathbb{N}}$ converge casi seguramente a X_∞ .

Veamos ahora que $X_\infty \in \mathcal{L}^1(\mathbb{P})$. Por la desigualdad de Fatou,

$$\mathbb{E}[X_\infty^+] \leq \liminf_{n \rightarrow \infty} \mathbb{E}[X_n^+] < \infty.$$

y $\mathbb{E}[X_n^-] = -\mathbb{E}[X_n] + \mathbb{E}[X_n^+] \leq \mathbb{E}[X_n^+] - \mathbb{E}[X_0]$. De nuevo por el lema de Fatou,

$$\mathbb{E}[X_\infty^-] \leq \liminf_{n \rightarrow \infty} \mathbb{E}[X_n^+] - \mathbb{E}[X_0] < \infty.$$

Así, $\mathbb{E}[|X_\infty|] = \mathbb{E}[X_\infty^+] + \mathbb{E}[X_\infty^-] < \infty$, por lo que $X_\infty \in \mathcal{L}^1(\mathbb{P})$. ■

1.6. Desigualdad de Doob y convergencia en $\mathcal{L}^p$

Teorema 1.6.1 (Desigualdad de Doob). *Sea $(X_n)_{n \in \mathbb{N}}$ una submartingala. Entonces,*

$$\forall C > 0 : \mathbb{P}\left(\max_{1 \leq m \leq n} X_m \geq C\right) \leq \frac{\mathbb{E}[X_n^+]}{C}.$$

Demostración: Fijamos $n \in \mathbb{N}$ y $C > 0$. Definimos

$$T = \inf\{m \in \mathbb{N}_n : X_m \geq C\} \wedge n.$$

Como T está acotado por n , $\mathbb{E}[X_T] \leq \mathbb{E}[X_n]$.

Por otro lado,

$$\mathbb{P}\left(\max_{1 \leq m \leq n} X_m \geq C\right) = \mathbb{E}\left[\mathbb{1}_{\{\max_{1 \leq m \leq n} X_m \geq C\}}\right] \leq \mathbb{E}\left[\frac{X_T}{C} \mathbb{1}_{\{\max_{1 \leq m \leq n} X_m \geq C\}}\right].$$

Por último, en $\{\max_{m \in \mathbb{N}_n} X_m \geq C\}^c$ tenemos que $X_T = X_n$, luego

$$\begin{aligned} \mathbb{E}[X_T \mathbb{1}_{\{\max_{m \in \mathbb{N}_n} X_m \geq C\}}] &= \mathbb{E}[X_T] - \mathbb{E}[X_T \mathbb{1}_{\{\max_{m \in \mathbb{N}_n} X_m \geq C\}^c}] \\ &\leq \mathbb{E}[X_n] - \mathbb{E}[X_n \mathbb{1}_{\{\max_{m \in \mathbb{N}_n} X_m \geq C\}^c}] = \mathbb{E}[X_n \mathbb{1}_{\{\max_{m \in \mathbb{N}_n} X_m \geq C\}}]. \end{aligned}$$

Así, $\mathbb{P}(\max_{m \in \mathbb{N}_n} X_m \geq C) \leq \frac{1}{C} \mathbb{E}[X_n \mathbb{1}_{\{\max_{m \in \mathbb{N}_n} X_m \geq C\}}] \leq \frac{1}{C} \mathbb{E}[X_n^+]$. ■

Lema 1.6.2. *Sea (X, Σ, μ) un espacio de medida σ -finito, $\phi: [0, \infty) \rightarrow [0, \infty)$ una función C^1 no decreciente con $\phi(0) = 0$ y $f: X \rightarrow \mathbb{R}$ medible. Entonces,*

$$\int_X \phi(|f|) d\mu = \int_0^\infty \phi'(\lambda) d_f(\lambda) d\lambda.$$

En particular, para $p \geq 1$, $\|f\|_{\mathcal{L}^p}^p = p \int_0^\infty \lambda^{p-1} d_f(\lambda) d\lambda$.

Demostración: Por el teorema fundamental del cálculo, $\phi(t) = \int_0^t \phi'(\lambda) d\lambda$. Por tanto,

$$\int_X \phi(|f|) d\mu = \int_X \int_0^{|f(x)|} \phi'(\lambda) d\lambda d\mu(x) = \int_X \int_0^\infty \phi'(\lambda) \mathbb{1}_{\{|f(x)| > \lambda\}} d\lambda d\mu(x).$$

La función $(x, \lambda) \mapsto \phi'(\lambda) \mathbb{1}_{\{|f(x)| > \lambda\}}$ es medible y no negativa en $X \times [0, \infty)$. Por el teorema de Tonelli, podemos cambiar el orden de integración y obtener

$$\int_X \phi(|f|) d\mu = \int_0^\infty \phi'(\lambda) \int_X \mathbb{1}_{\{|f(x)| > \lambda\}} d\mu(x) d\lambda = \int_0^\infty \phi'(\lambda) d_f(\lambda) d\lambda.$$

En particular, si $\phi(t) = t^p$, entonces $\phi'(t) = pt^{p-1}$ y obtenemos que

$$\|f\|_{\mathcal{L}^p}^p = \int_X |f|^p d\mu = \int_0^\infty p\lambda^{p-1} d_f(\lambda) d\lambda = p \int_0^\infty \lambda^{p-1} d_f(\lambda) d\lambda. \quad \blacksquare$$

Teorema 1.6.3 (Desigualdad maximal de Doob). *Sea $(X_n)_{n \in \mathbb{N}}$ una submartingala y sea $p > 1$. Entonces,*

$$\mathbb{E} \left[\left| \max_{m \in \mathbb{N}_n} X_m \right|^p \right] \leq \left(\frac{p}{p-1} \right)^p \mathbb{E} [|X_n^+|^p].$$

Demostración: Fijamos $M > 0$ y denotamos $X_n^M := \max_{m \in \mathbb{N}_n} X_m \wedge M$. Entonces,

$$\begin{aligned} \mathbb{E} [|X_n^M|^p] &\stackrel{1.6.2}{=} \int_0^\infty pt^{p-1} \mathbb{P}(|X_n^M| > t) dt \\ &= \int_0^M pt^{p-1} \mathbb{P} \left(\left| \max_{m \in \mathbb{N}_n} X_m \right| > t \right) dt \\ &\stackrel{1.6.1}{\leq} \int_0^M pt^{p-2} \mathbb{E} [X_n^+ \mathbb{1}_{\{\max_{m \in \mathbb{N}_n} X_m > t\}}] dt \\ &= \int_0^M pt^{p-2} \int_\Omega X_n^+ \mathbb{1}_{\{\max_{m \in \mathbb{N}_n} X_m > t\}} d\mathbb{P} dt \\ &\stackrel{\text{Fubini}}{=} \int_\Omega X_n^+ \int_0^{X_n^M} pt^{p-2} dt d\mathbb{P} \\ &= \int_\Omega X_n^+ \left[\frac{t^{p-1}}{p-1} \right]_0^{X_n^M} d\mathbb{P} = \frac{p}{p-1} \int_\Omega X_n^+ (X_n^M)^{p-1} d\mathbb{P} \\ &\stackrel{\text{Hölder}}{\leq} \frac{p}{p-1} (\mathbb{E} [|X_n^+|^p])^{1/p} (\mathbb{E} [|X_n^M|^p])^{(p-1)/p}. \end{aligned}$$

Por tanto, $(\mathbb{E} [|X_n^M|^p])^{1/p} \leq \frac{p}{p-1} (\mathbb{E} [|X_n^+|^p])^{1/p}$ y, al elevar ambos lados a la potencia p , obtenemos

$$\mathbb{E} [|X_n^M|^p] \leq \left(\frac{p}{p-1} \right)^p \mathbb{E} [|X_n^+|^p].$$

Al tomar el límite cuando $M \rightarrow \infty$, por convergencia monótona, obtenemos

$$\mathbb{E} \left[\left| \max_{m \in \mathbb{N}_n} X_m \right|^p \right] \leq \left(\frac{p}{p-1} \right)^p \mathbb{E} [|X_n^+|^p].$$

■

Teorema 1.6.4 (de convergencia de martingalas en $\mathcal{L}^p$). Sea $p > 1$. Sea $(X_n)_{n \in \mathbb{N}}$ una martingala tal que $\sup_{n \in \mathbb{N}} \mathbb{E}[|X_n|^p] < \infty$. Entonces, existe una variable aleatoria $X_\infty \in \mathcal{L}^p(\mathbb{P})$ tal que $(X_n)_{n \in \mathbb{N}}$ converge a X_∞ en $\mathcal{L}^p$ y casi seguramente.

Demostración: Por la desigualdad de Jensen, tenemos que

$$(\mathbb{E}[X_n^+])^p \leq \mathbb{E}[|X_n^+|^p] \leq \mathbb{E}[|X_n|^p].$$

Por tanto, $\sup_{n \in \mathbb{N}} \mathbb{E}[X_n^+] < \infty$ y por el teorema de convergencia de martingalas, existe una variable aleatoria X_∞ tal que $(X_n)_{n \in \mathbb{N}}$ converge a X_∞ casi seguramente.

Ahora bien, por la desigualdad maximal de Doob, tenemos que

$$\mathbb{E}\left[\left|\max_{m \in \mathbb{N}_n} X_m\right|^p\right] \leq \left(\frac{p}{p-1}\right)^p \mathbb{E}[|X_n^+|^p] \leq \left(\frac{p}{p-1}\right)^p \sup_{n \in \mathbb{N}} \mathbb{E}[|X_n|^p] < \infty$$

de manera uniforme en n (es decir, $\exists C > 0 : \forall n \in \mathbb{N} : \mathbb{E}[|\max_{m \in \mathbb{N}_n} X_m|^p] < C$).

Entonces, por el teorema de convergencia monótona, $\mathbb{E}[\sup_{n \in \mathbb{N}} |X_n|^p] < \infty$ y por el teorema de convergencia dominada, como $|X_n - X_\infty|^p \leq 2^p \sup_{n \in \mathbb{N}} |X_n|^p$, obtenemos que

$$\lim_{n \rightarrow \infty} \mathbb{E}[|X_n - X_\infty|^p] = 0,$$

es decir, $(X_n)_{n \in \mathbb{N}}$ converge a X_∞ en $\mathcal{L}^p$. ■

Observación 1.6.5. Para $p = 1$, tanto la desigualdad maximal de Doob como el teorema de convergencia de martingalas en $\mathcal{L}^p$ no se cumplen, como muestran los siguientes ejemplos:

Ejemplo 1.6.6 (de que no se cumple la convergencia en $\mathcal{L}^1$).

Sea $S_0 = 1, \forall n \in \mathbb{N} : S_{n+1} = S_n + \xi_{n+1}$ donde $(\xi_n)_{n \in \mathbb{N}}$ son variables aleatorias independientes con distribución de Bernoulli con parámetro $1/2$. Definimos $T = \inf\{n \in \mathbb{N} : S_n = 0\}$. Entonces, $X_{T \wedge n}$ es una martingala no negativa. Entonces, por el teorema de convergencia de martingalas, $X_{T \wedge n}$ converge casi seguramente a 0. Sin embargo, $\mathbb{E}[X_{T \wedge n}] = 1$ para todo $n \in \mathbb{N}$, luego $X_{T \wedge n}$ no converge a 0 en $\mathcal{L}^1$.

Ejercicio 1.6.7. Demuestra que la desigualdad maximal de Doob no se cumple para $p = 1$.

Sugerencia: El ejemplo anterior sirve para demostrarlo.

Solución: De momento todavía nos faltan herramientas para demostrarlo, pero se puede

hacer si asumimos que

$$\mathbb{P} \left(\max_{m \in \mathbb{N}} X_m \geq M \right) = \frac{1}{M}.$$

$$\mathbb{E} \left[\max_{m \in \mathbb{N}} X_m \right] = \sum_{M=1}^{\infty} \mathbb{P} \left(\max_{m \in \mathbb{N}} X_m \geq M \right) = \sum_{M=1}^{\infty} \frac{1}{M} = \infty.$$

Sin embargo, $\mathbb{E}[X_n] = 1$ para todo $n \in \mathbb{N}$, luego la desigualdad maximal de Doob no se puede cumplir para $p = 1$ porque $\mathbb{E}[\max_{m \in \mathbb{N}_n} X_m] \xrightarrow{n \rightarrow \infty} \infty$.

En la siguiente sección, vamos a ver bajo qué condiciones se puede garantizar la convergencia en $\mathcal{L}^1$ y la desigualdad maximal de Doob para $p = 1$.

1.7. Integrabilidad uniforme. Convergencia en $\mathcal{L}^1$

Definición 1.7.1 (Proceso uniformemente integrable). Un proceso estocástico $(X_t)_{t \in T}$ es uniformemente integrable

$$\iff \lim_{M \rightarrow \infty} \sup_{t \in T} \int_{\{|X_t| \geq M\}} |X_t| d\mathbb{P} = 0.$$

Teorema 1.7.2. Sea $(X_n)_{n \in \mathbb{N}}$ un proceso estocástico tal que $X_n \xrightarrow[n \rightarrow \infty]{c.s.} X$. Entonces, las siguientes condiciones son equivalentes:

- (1) $(X_n)_{n \in \mathbb{N}}$ es uniformemente integrable.
- (2) $X_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}^1} X$.
- (3) $\mathbb{E}[|X_n|] \xrightarrow{n \rightarrow \infty} \mathbb{E}[|X|] < \infty$.

2. Cadenas de Markov

2.1. Primeros ejemplos

2.1.1. Paseos aleatorios

Sean $\{\xi_k\}_{k \in \mathbb{N}}$ variables aleatorias independientes, dado $x_0 \in \mathbb{R}^d$, definimos

$$\forall n \in \mathbb{N} : X_n = x_0 + \sum_{k=1}^n \xi_k.$$

Según los valores que tomen las variables ξ_k y la distribución con la que se eligen, obtenemos distintos tipos de paseos aleatorios.

- **Simple:** ξ_k toman valores en $\{\pm e_j\}_{j=1}^d$. Si $\forall j \in \mathbb{N}_d : \mathbb{P}(\xi_k = e_j) = 1/(2d)$, entonces el paseo aleatorio es *simple* y *simétrico*. En caso contrario, decimos que es *simple* y *asimétrico*.
- **En grafos:** Si $G = (V, E)$ es un grafo, podemos definir un paseo aleatorio en G como una sucesión de vértices $\{X_n\}_{n \in \mathbb{N}}$ tales que $\forall n \in \mathbb{N} : X_{n+1} \in N(X_n)$, donde $N(v)$ es el conjunto de vecinos del vértice v .
- **Caminos gaussianos:** Suponemos que todas las ξ_k tienen una distribución normal $\mathcal{N}(0, 1)$ y definimos

$$\forall n \in \mathbb{N} : X_{n+1} = \alpha + \beta X_n + \gamma \xi_{n+1},$$

donde $\alpha, \beta, \gamma \in \mathbb{R}$ son constantes. Entonces, $(X_n)_{n \in \mathbb{N}}$ es un paseo aleatorio gaussiano.

2.1.2. Modelos de difusión discretos

En estos modelos de difusión, por ejemplo, el **modelo de Ehrenfest**, se considera un sistema de partículas que se mueven entre dos compartimentos. En cada paso de tiempo, una partícula es seleccionada al azar y se mueve de un compartimento al otro. Denotando N_A y N_B como el número de partículas en los compartimentos A y B respectivamente, tenemos que

$$\mathbb{P}(N_A(t+1) = i \mid N_A(t) = j) = \begin{cases} \frac{j}{N} & \text{si } i = j - 1, \\ 1 - \frac{j}{N} & \text{si } i = j + 1, \\ 0 & \text{en otro caso.} \end{cases}$$

En el **modelo de Bernoulli-Laplace**, se consideran dos tipos de partículas y, en cada paso

de tiempo, se selecciona una partícula de cada urna al azar y se intercambian.

En el **modelo de Polya**, se tiene una urna con bolas de diferentes colores. En cada paso de tiempo, se selecciona una bola al azar, se observa su color y luego se devuelve a la urna junto con un número adicional de bolas del mismo color. Esto genera un proceso de refuerzo positivo, donde los colores más frecuentes tienden a volverse aún más comunes con el tiempo.

Modelos de colas: En este modelo, se estudia el comportamiento de un sistema de colas, como una línea de espera en un supermercado.

- **Modelo M/G/1:** Denotamos al número de clientes en la cola en el n -ésimo servicio como X_n y a_k como la probabilidad de que k clientes lleguen durante el tiempo de servicio. Los a_k siguen una distribución de Poisson con parámetro λ .

Procesos de ramificación: En estos procesos, cada individuo puede dar lugar a varios descendientes en la siguiente generación. Un ejemplo clásico es el **proceso de Galton-Watson**, donde cada individuo tiene un número aleatorio de descendientes según una distribución de probabilidad fija.

La propiedad clave que todos estos modelos comparten es que el estado futuro del sistema depende únicamente del estado actual y no de cómo se llegó a ese estado, lo que caracteriza a los procesos de Markov.

2.2. Núcleos de transición y cadenas de Markov

Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad y $(M, \mathcal{S})$ un espacio medible.

Definición 2.2.1 (Núcleo de transición). Sea $(M, \mathcal{S})$ un espacio medible, una función $P: M \times \mathcal{S} \rightarrow [0, 1]$ es un núcleo de transición $\iff$

- (I) $\forall x \in M : P(x, \cdot): \mathcal{S} \rightarrow [0, 1]$ es una medida de probabilidad en $(M, \mathcal{S})$.
- (II) $\forall G \in \mathcal{S} : P(\cdot, G): M \rightarrow [0, 1]$ es medible.

Observación 2.2.2. Dado un núcleo de transición P en el espacio medible $(M, \mathcal{S})$, P actúa sobre funciones medibles $f: M \rightarrow \mathbb{R}$ mediante la fórmula

$$\forall x \in M : Pf(x) := \int_M f(y) P(x, dy).$$

Además, si f está acotada, entonces Pf también lo está.

Si μ es una medida de probabilidad en $(M, \mathcal{S})$, entonces P actúa sobre μ mediante la

fórmula

$$\forall G \in \mathcal{S} : \mu P(G) = \int_M P(y, G) \mu(dy).$$

Ejemplo 2.2.3 (de núcleo de transición). Sea $(M, \mathcal{S})$ un espacio medible con M numerable y $\mathcal{S} = \mathcal{P}(M)$. Consideramos $p: M \times M \rightarrow [0, 1]$ tal que $\forall x \in M : \sum_{y \in M} p(x, y) = 1$. Definimos $P: M \times \mathcal{S} \rightarrow [0, 1]$ mediante

$$\forall x \in M, A \in \mathcal{S} : P(x, A) = \sum_{y \in A} p(x, y).$$

Entonces, para una función medible $f: M \rightarrow \mathbb{R}$, tenemos que

$$\forall x \in M : Pf(x) = \sum_{y \in M} f(y) p(x, y).$$

Para una medida μ en $(M, \mathcal{S})$, tenemos que

$$\forall y \in M : \mu P(\{y\}) = \sum_{x \in M} p(x, y) \mu(\{x\}).$$

Si M es finito, entonces p puede representarse mediante una matriz estocástica, f mediante un vector columna, μ mediante un vector fila, Pf mediante el producto de la matriz p por el vector f y μP mediante el producto del vector μ por la matriz p .

Definición 2.2.4. Sea $\{P_n\}_{n \in \mathbb{N}}$ una familia de núcleos de transición en $(M, \mathcal{S})$ y $(X_n)_{n \in \mathbb{N}}$ un proceso estocástico adaptado a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$. Decimos que $(X_n)_{n \in \mathbb{N}}$ es una *cadena de Markov* con núcleos de transición $\{P_n\}_{n \in \mathbb{N}}$

$$\iff \forall n \in \mathbb{N}, G \in \mathcal{S} : \mathbb{P}(X_{n+1} \in G \mid \mathcal{F}_n) = P_{n+1}(X_n, G).$$

Lema 2.2.5. Sea $(X_n)_{n \in \mathbb{N}}$ un proceso estocástico adaptado a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$ y $\{P_n\}_{n \in \mathbb{N}}$ una familia de núcleos de transición en $(M, \mathcal{S})$. Entonces, $(X_n)_{n \in \mathbb{N}}$ es una cadena de Markov con núcleos de transición $\{P_n\}_{n \in \mathbb{N}}$ $\iff$

$$\forall f: M \rightarrow \mathbb{R} \text{ medible y acotada} : \mathbb{E}[f(X_{n+1}) \mid \mathcal{F}_n] = Pf(X_n).$$

Observación 2.2.6. Sea μ_n la medida de probabilidad en $(M, \mathcal{S})$ definida por $\mu_n(G) = \mathbb{P}(X_n \in G)$.

Entonces, para $G \in \mathcal{S}$, tenemos que

$$\begin{aligned} \mu_{n+1}(G) &= \mathbb{P}(X_{n+1} \in G) = \mathbb{E}[\mathbb{E}[\mathbb{1}_{X_{n+1} \in G} \mid \mathcal{F}_n]] \\ &= \mathbb{E}[P_{n+1} \mathbb{1}_G(X_n)] = \int_M P_{n+1}(x, G) \mu_n(dx) = \mu_n P_{n+1}(G). \end{aligned}$$

Por tanto, $\mu_{n+1} = \mu_n P_{n+1}$.

Lema 2.2.7. Sea $(X_n)_{n \in \mathbb{N}}$ una cadena de Markov con núcleos de transición $\{P_n\}_{n \in \mathbb{N}}$. Entonces,

$$(1) \quad \forall f: M \rightarrow \mathbb{R} \text{ medible y acotada: } \forall n \in \mathbb{N} : \mathbb{E}[f(X_{n+1}) \mid \mathcal{F}_n] = \mathbb{E}[f(X_{n+1}) \mid X_n].$$

$$(2) \quad \forall G \in \mathcal{S} : \forall n \in \mathbb{N} : \mathbb{P}(X_{n+1} \in G \mid \mathcal{F}_n) = \mathbb{P}(X_{n+1} \in G \mid X_n).$$

$$(3) \quad \text{Sean } \{A_i\}_{i=0}^{n+1} \subset \mathcal{S} \text{ tales que } \mathbb{P}(X_0 \in A_0 \wedge \dots \wedge X_n \in A_n) > 0. \text{ Entonces,}$$

$$\mathbb{P}(X_{n+1} \in A_{n+1} \mid X_0 \in A_0 \wedge \dots \wedge X_n \in A_n) = \mathbb{P}(X_{n+1} \in A_{n+1} \mid X_n \in A_n).$$

Demostración:

(1) Sea $f: M \rightarrow \mathbb{R}$ medible y acotada. Fijamos $n \in \mathbb{N}$. Entonces, $P_{n+1}f$ es $\mathcal{S}$ -medible y X_n es $\sigma(X_n)$ -medible, por lo que $P_{n+1}f(X_n)$ es $\sigma(X_n)$ -medible. Por lo tanto,

$$\begin{aligned} \mathbb{E}[f(X_{n+1}) \mid \mathcal{F}_n] &= P_{n+1}f(X_n) = \mathbb{E}[P_{n+1}f(X_n) \mid X_n] \\ &= \mathbb{E}[\mathbb{E}[f(X_{n+1}) \mid \mathcal{F}_n] \mid X_n] = \mathbb{E}[f(X_{n+1}) \mid X_n]. \end{aligned}$$

■

Definición 2.2.8. Sea $(X_n)_{n \in \mathbb{N}}$ una cadena de Markov con núcleos de transición $\{P_n\}_{n \in \mathbb{N}}$. Decimos que $(X_n)_{n \in \mathbb{N}}$ es temporalmente homogénea con núcleo $P \iff \forall n \in \mathbb{N} : P_n = P$.

Teorema 2.2.9 (Ecuación de Chapman-Kolmogorov). Sea $(X_n)_{n \in \mathbb{N}}$ una cadena de Markov temporalmente homogénea con núcleo P y sea X_0 una variable aleatoria con medida inducida μ_0 . Entonces,

$$\forall n \in \mathbb{N}, f: M \rightarrow \mathbb{R} \text{ medible y acotada: } \mathbb{E}[f(X_n) \mid X_0] = P^n f(X_0) \wedge \mu_n = \mu_0 P^n,$$

donde $P^1 = P$ y $P^n(x, A) = P^{n-1}P(x, A) = \int_M P(y, A) P^{n-1}(x, dy)$ para $n \geq 2$.

Demostración: Veámoslo por inducción sobre n . Para $n = 1$, la afirmación es trivial.

$$\begin{aligned} \mathbb{E}[\mathbb{1}_A(X_{n+1}) \mid X_0] &= \mathbb{E}[\mathbb{E}[\mathbb{1}_A(X_{n+1}) \mid \mathcal{F}_k] \mid X_0] = \mathbb{E}[\mathbb{E}[\mathbb{1}_A(X_{n+1}) \mid X_k] \mid X_0] \\ &= \mathbb{E}[P(X_k, A) \mid X_0] = P^k P(X_0, A) = P^{k+1}(X_0, A). \end{aligned}$$

■

Definición 2.2.10. μ es invariante para $P \iff \mu P = \mu$.

Observación 2.2.11. Si $X_0 \sim \mu$ y μ es invariante para P , entonces $\forall n \in \mathbb{N} : X_n \sim \mu$.

Lema 2.2.12. Sea $(M, \mathcal{S})$ un espacio medible con M finito y P un núcleo de transición en $(M, \mathcal{S})$. Entonces, existe una medida de probabilidad μ en $(M, \mathcal{S})$ invariante para P .

Demostración: Consideramos el conjunto

$$\mathcal{M} = \left\{ \mu \in \mathbb{R}^M : \forall x \in M : \mu(\{x\}) \geq 0 \wedge \sum_{x \in M} \mu(\{x\}) = 1 \right\},$$

que es un simplex. Definimos $T: \mathcal{M} \rightarrow \mathcal{M}$ mediante $T(\mu) = \mu P$. Entonces, T es continua y $\mathcal{M}$ es compacta y convexa, por lo que, por el teorema de Brouwer, existe $\mu \in \mathcal{M}$ tal que $T(\mu) = \mu$, es decir, $\mu P = \mu$. ■

Ejercicio 2.2.13. Demuestra que si M es infinito, puede no existir una medida de probabilidad invariante para P .

H. Hojas de ejercicios

H.1. Martingalas en tiempo discreto

- [1] Demuestra la desigualdad de Chebyshev condicional: para $a > 0$,

$$P(|X| \geq a \mid \mathcal{F}) \leq \frac{\mathbb{E}[X^2 \mid \mathcal{F}]}{a^2}.$$

- [2] Demuestra la desigualdad de Cauchy–Schwarz condicional:

$$(\mathbb{E}[XY \mid \mathcal{F}])^2 \leq \mathbb{E}[X^2 \mid \mathcal{F}]\mathbb{E}[Y^2 \mid \mathcal{F}].$$

(Indicación: $\mathbb{E}[(X + \theta Y)^2 \mid \mathcal{F}] \geq 0$ y, si $a\theta^2 + b\theta + c \geq 0$ para todo θ , entonces $b^2 - 4ac \leq 0$.)

- [3] Define la varianza condicional

$$\text{var}(X \mid \mathcal{F}) := \mathbb{E}[(X - \mathbb{E}[X \mid \mathcal{F}])^2 \mid \mathcal{F}].$$

Demuestra que

$$\text{var}(X) = \mathbb{E}(\text{var}(X \mid \mathcal{F})) + \text{var}(\mathbb{E}[X \mid \mathcal{F}]).$$

- [4] Sea X_n una submartingala. Demuestra que $X_n^+ := \max\{0, X_n\}$ es una submartingala.

- [5] Sean X_n y Y_n submartingalas con respecto a una filtración común $\mathcal{F}_n$. Demuestra que $Z_n := \max\{X_n, Y_n\}$ y $W_n := X_n + Y_n$ son submartingalas.

- [6] Sea X_n una submartingala. Sea $Y_n := X_n \log^+ X_n$. Suponiendo que $Y_n \in L^1$, demuestra que Y_n es una submartingala.

- [7] Sea $X_n \geq 0$ una supermartingala. Demuestra que existe $X \in L^1$ tal que $X_n \rightarrow X$ c.s. cuando $n \rightarrow \infty$ y $\mathbb{E}X \leq \mathbb{E}X_0$.

- [8] Sean $\{Y_k\}_{k \geq 1}$ variables aleatorias no negativas, i.i.d., con $\mathbb{E}Y_k = 1$. Sea

$$X_n := \prod_{k=1}^n Y_k.$$

Demuestra que X_n es una martingala. Demuestra que, si $P(Y_k = 1) < 1$, entonces $X_n \rightarrow 0$ c.s.

- [9] Sea X_n una martingala con $X_0 = 0$ y $\mathbb{E}X_n^2 < \infty$. Demuestra que

$$P\left(\max_{m \leq n} X_m \geq \lambda\right) \leq \frac{\mathbb{E}X_n^2}{\mathbb{E}X_n^2 + \lambda^2}.$$

(Indicación: Utiliza que $(X_n + c)^2$ es una submartingala y optimiza respecto de c .)

[10] Sea $X_n \geq 0$ una supermartingala y sea T un tiempo de parada (posiblemente no acotado). Demuestra que $\mathbb{E}X_0 \geq \mathbb{E}X_T$. (Advertencia: No se supone integrabilidad uniforme.)

[11] Sea $X_n \geq 0$ una supermartingala. Demuestra que, para todo $C > 0$,

$$P\left(\sup_n X_n > C\right) \leq \frac{\mathbb{E}X_0}{C}.$$

(Indicación: Recuerda la demostración de la desigualdad de Doob para martingalas y utiliza el ejercicio anterior.)

[12] (Identidad de Wald) Sean $\{\xi_k\}_{k \in \mathbb{N}}$ variables aleatorias reales, i.i.d., tales que $\mathbb{E}|\xi_k| < \infty$, y sea $S_n := \sum_{k=1}^n \xi_k$. Sea T un tiempo de parada (con respecto a la filtración natural) tal que $\mathbb{E}T < \infty$. Demuestra que

$$\mathbb{E}S_T = \mathbb{E}T \cdot \mathbb{E}\xi_1.$$

(Indicación: Considera primero el caso de ξ_k no negativas.)

[13] Sea X_n una sucesión de variables aleatorias, y sea Y una variable aleatoria no negativa con $\mathbb{E}Y < \infty$. Si $|X_n| \leq Y$, demuestra que X_n es uniformemente integrable.

[14] Sea X_n una sucesión de variables aleatorias y sea T un tiempo de parada. Supón que $\mathbb{E}X_T < \infty$ y que $X_n \mathbb{1}_{\{T > n\}}$ es uniformemente integrable. Demuestra que $X_{T \wedge n}$ es uniformemente integrable.

[15] (Parada opcional para incrementos condicionales acotados) Sea X_n una submartingala, y supón que existe una constante $K > 0$ tal que, para todo $n \in \mathbb{N}$,

$$\mathbb{E}(|X_{n+1} - X_n| \mid \mathcal{F}_n) \leq K \text{ c.s.}$$

Sea T un tiempo de parada tal que $\mathbb{E}T < \infty$. Demuestra que $\mathbb{E}X_0 \leq \mathbb{E}X_T$.

[16] Sean $\{\xi_k\}$ variables aleatorias i.i.d. que toman valores en $\{\pm 1\}$, con

$$P(\xi = 1) = p, \quad P(\xi = -1) = 1 - p, \quad p > \frac{1}{2},$$

y sea $X_n := \sum_{k=1}^n \xi_k$. Llamamos a X_n paseo aleatorio simple asimétrico.

a) Halla $c \in \mathbb{R}$ tal que el proceso $Y_n = X_n - cn$ sea una martingala.

b) Halla $r \in (0, 1)$ tal que el proceso $Z_n = r^{X_n}$ sea una martingala.

c) Para todo $a \in \mathbb{Z}$, sea

$$T_a = \inf\{n \in \mathbb{N} : X_n = a\}.$$

Demuestra que, para todo $a > 0$, $P(T_a < \infty) = 1$. (Indicación: Calcula la probabilidad de que $\lim_{n \rightarrow \infty} X_n = +\infty$.)

d) Demuestra que, para todo $a < 0 < b$,

$$P(T_a < T_b) = \frac{1 - r^b}{r^a - r^b}.$$

(Indicación: Utiliza el ejercicio 14.)

e) Demuestra que, para todo $a < 0$,

$$P(T_a < \infty) = \left(\frac{p}{1-p} \right)^{-a}.$$

f) Demuestra que, para todo $a > 0$,

$$\mathbb{E}T_a = \frac{a}{2p-1}.$$

(Indicación: Utiliza Y_n .)

E. Entregas

E.1. Martingalas y funciones armónicas

Ejercicio E.1.1. Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad. Sea $\mathcal{G} \subset \mathcal{F}$ una σ -álgebra. Sea $X: \Omega \rightarrow \mathbb{R}^d$ una variable aleatoria $\mathcal{G}$ -medible y sea $Y: \Omega \rightarrow \mathbb{R}^d$ una variable aleatoria $\mathcal{G}$ -independiente. Sea $\varphi: \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$ una función medible Borel, tal que $\mathbb{E}[|\varphi(X, Y)|] < \infty$. Demuestra que

$$\mathbb{E}[\varphi(X, Y) \mid \mathcal{G}] = g(X),$$

donde $g(x) := \mathbb{E}[\varphi(x, Y)]$.

(Pista: recuerda que, si dos variables aleatorias independientes A y B tienen distribuciones μ y ν , respectivamente, entonces la distribución conjunta de (A, B) es la medida producto $\mu \times \nu$.)

Solución: Por unicidad de la esperanza condicional, basta con comprobar dos condiciones:

(1) Veamos que $g(X)$ es $\mathcal{G}$ -medible y $g(X) \in \mathcal{L}^1(\mathbb{P})$.

Por hipótesis, tenemos que $\mathbb{E}[|\varphi(X, Y)|] < \infty$, es decir,

$$\mathbb{E}[|\varphi(X, Y)|] = \int_{\Omega} |\varphi(X(\omega), Y(\omega))| d\mathbb{P}(\omega) < \infty.$$

Como $(x, y) \mapsto |\varphi(x, y)|$ es una función medible Borel (por ser la composición de funciones medibles Borel), por el **teo-medida-inducida-integral-fn-medible/teorema 1**, tenemos que

$$\int_{\mathbb{R}^d \times \mathbb{R}^d} |\varphi(x, y)| d\mathbb{P}_{(X, Y)}(x, y) = \int_{\Omega} |\varphi(X(\omega), Y(\omega))| d\mathbb{P}(\omega) < \infty.$$

Es decir, $\varphi \in \mathcal{L}^1(\mathbb{P}_{(X, Y)})$.

Como X es $\mathcal{G}$ -medible e Y es $\mathcal{G}$ -independiente, X e Y son independientes. Entonces, por el **teo-carac-independencia-var-aleatorias-medida-inducida/teorema 1**, $\mathbb{P}_{(X, Y)} = \mathbb{P}_X \otimes \mathbb{P}_Y$. Así, $\varphi \in \mathcal{L}^1(\mathbb{P}_X \otimes \mathbb{P}_Y)$.

Entonces, $\exists A \in \mathcal{B}(\mathbb{R}^d)$ tal que $\mathbb{P}_X(A^c) = 0$ y $\forall x \in A: \int_{\mathbb{R}^d} |\varphi(x, y)| d\mathbb{P}_Y(y) < \infty$. Por tanto, $y \mapsto \varphi(x, y)$ está en $\mathcal{L}^1(\mathbb{P}_Y)$ para $\mathbb{P}_X$ -c.t.p. $x \in \mathbb{R}^d$. Entonces, por el **teo-medida-inducida-integral-fn-medible/teorema 1**, tenemos que

$$\forall x \in A: g(x) = \mathbb{E}[\varphi(x, Y)] = \int_{\Omega} \varphi(x, Y(\omega)) d\mathbb{P}(\omega) = \int_{\mathbb{R}^d} \varphi(x, y) d\mathbb{P}_Y(y).$$

Ahora bien, como $\mathbb{P}_X$ y $\mathbb{P}_Y$ son medidas de probabilidad en $\mathbb{R}^d$, en particular son σ -finitas. Como además $\varphi \in \mathcal{L}^1(\mathbb{P}_X \otimes \mathbb{P}_Y)$, por el teorema de Fubini-Tonelli, g es $\mathcal{B}(\mathbb{R}^d)$ -medible y además, $g \in \mathcal{L}^1(\mathbb{P}_X)$.

Como X es $\mathcal{G}$ -medible, concluimos que $g(X)$ es $\mathcal{G}$ -medible. Además, por el ~~teo-medida-inducida-integral-fn-medible~~ teorema 1 $g \in \mathcal{L}^1(\mathbb{P}_X)$ implica que $g(X) \in \mathcal{L}^1(\mathbb{P})$.

(2) Veamos que para todo $E \in \mathcal{G}$ se cumple $\int_E \varphi(X, Y) d\mathbb{P} = \int_E g(X) d\mathbb{P}$.

Sea $E \in \mathcal{G}$. Entonces, $\mathbb{1}_E$ es una función $\mathcal{G}$ -medible y, como X también es $\mathcal{G}$ -medible, el par $(X, \mathbb{1}_E) : \Omega \rightarrow \mathbb{R}^d \times \{0, 1\}$ es $\mathcal{G}$ -medible. En consecuencia, $(X, \mathbb{1}_E)$ e Y son variables aleatorias independientes, luego por el ~~teo-carac-independencia-var-aleatorias-medida-inducida~~ teorema 1 $\mathbb{P}_{(X, \mathbb{1}_E, Y)} = \mathbb{P}_{(X, \mathbb{1}_E)} \otimes \mathbb{P}_Y$.

Ahorrándonos algunos detalles técnicos que resultan fáciles pero tediosos de comprobar, podemos escribir la siguiente cadena de igualdades:

$$\begin{aligned}
\int_E \varphi(X, Y) d\mathbb{P} &= \int_{\Omega} \mathbb{1}_E(\omega) \cdot \varphi(X(\omega), Y(\omega)) d\mathbb{P}(\omega) \\
&\stackrel{\text{teo-medida-inducida-integral-fn-medible/teorema 1}}{=} \int_{\mathbb{R}^d \times \{0, 1\} \times \mathbb{R}^d} b \cdot \varphi(x, y) d\mathbb{P}_{(X, \mathbb{1}_E, Y)}(x, b, y) \\
&\stackrel{\text{independencia}}{=} \int_{\mathbb{R}^d \times \{0, 1\} \times \mathbb{R}^d} b \cdot \varphi(x, y) d(\mathbb{P}_{(X, \mathbb{1}_E)} \otimes \mathbb{P}_Y)(x, b, y) \\
&\stackrel{\text{Fubini}}{=} \int_{\mathbb{R}^d \times \{0, 1\}} b \left(\int_{\mathbb{R}^d} \varphi(x, y) d\mathbb{P}_Y(y) \right) d\mathbb{P}_{(X, \mathbb{1}_E)}(x, b) \\
&= \int_{\mathbb{R}^d \times \{0, 1\}} b \cdot g(x) d\mathbb{P}_{(X, \mathbb{1}_E)}(x, b) \\
&\stackrel{\text{teo-medida-inducida-integral-fn-medible/teorema 1}}{=} \int_{\Omega} \mathbb{1}_E(\omega) g(X(\omega)) d\mathbb{P}(\omega) = \int_E g(X) d\mathbb{P}.
\end{aligned}$$

Por unicidad de la esperanza condicional, como $g(X) \in \mathcal{L}^1(\mathbb{P})$ es una variable $\mathcal{G}$ -medible y $\forall E \in \mathcal{G} : \int_E \varphi(X, Y) d\mathbb{P} = \int_E g(X) d\mathbb{P}$, concluimos que $g(X) = \mathbb{E}[\varphi(X, Y) \mid \mathcal{G}]$ c.s. ■

Ejercicio E.1.2. Sea f una función armónica en $\mathbb{R}^d$. Sea $x \in \mathbb{R}^d$ y sean $\{\xi_k\}_{k \in \mathbb{N}}$ i.i.d. y uniformemente distribuidas en $\partial B_0(1)$ (la esfera de radio 1 y centro 0). Se define $\{S_n\}_{n \geq 0}$ por la recurrencia

$$S_0 = x, \quad S_n = \xi_n + S_{n-1}.$$

Demuestra que el proceso dado por $X_n := f(S_n)$ es una martingala.

Solución: Tomando $\forall n \in \mathbb{N} : \mathcal{F}_n := \sigma(\xi_1, \dots, \xi_n)$ y $\mathcal{F}_0 = \{\emptyset, \Omega\}$, tenemos que

$$\forall n \in \mathbb{N} \cup \{0\} : S_n = \xi_n + S_{n-1} = x + \sum_{k=1}^n \xi_k \text{ es una variable aleatoria } \mathcal{F}_n\text{-medible.}$$

Veamos que $(X_n)_{n \in \mathbb{N}}$ es una martingala respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$:

[1] Como f es armónica, en particular es continua, luego es medible Borel. Entonces, como $X_n = f(S_n)$ y S_n es $\mathcal{F}_n$ -medible, X_n también es $\mathcal{F}_n$ -medible.

[2] Como $S_n = x + \sum_{k=1}^n \xi_k$, dado $\omega \in \Omega$, tenemos que

$$\|S_n(\omega)\| = \left\| x + \sum_{k=1}^n \xi_k(\omega) \right\| \leq \|x\| + \sum_{k=1}^n \|\xi_k(\omega)\| = \|x\| + n.$$

Por tanto, $\forall n \in \mathbb{N}, \omega \in \Omega : S_n(\omega) \in \overline{B_0}(\|x\| + n)$. Entonces, como f es continua en $\mathbb{R}^d$, es acotada en $\overline{B_0}(\|x\| + n)$, luego

$$\forall n \in \mathbb{N} : \exists M_n > 0 : \forall \omega \in \Omega : |X_n(\omega)| = |f(S_n(\omega))| \leq M_n.$$

En consecuencia, $\mathbb{E}[|X_n|] = \int_{\Omega} |X_n(\omega)| d\mathbb{P}(\omega) \leq M_n < \infty$, es decir, $X_n \in \mathcal{L}^1(\mathbb{P})$.

[3] Por último, veamos que $\forall n \in \mathbb{N} : \mathbb{E}[X_{n+1} | \mathcal{F}_n] = X_n$. Para ello, tras fijar $n \in \mathbb{N}$, vamos a aplicar el ejercicio anterior con $\mathcal{G} = \mathcal{F}_n$, $X = S_n$, $Y = \xi_{n+1}$ y $\varphi(x, y) = f(x + y)$. Comprobemos que se cumplen las hipótesis del ejercicio anterior:

- a) S_n es $\mathcal{F}_n$ -medible por definición de S_n y $\mathcal{F}_n$.
- b) Como las ξ_n son independientes, ξ_{n+1} es independiente de $\mathcal{F}_n = \sigma(\xi_1, \dots, \xi_n)$.
- c) Como f es medible Borel, φ también lo es, por ser la composición de funciones medibles Borel.
- d) $\mathbb{E}[|f(S_n + \xi_{n+1})|] = \mathbb{E}[|f(S_{n+1})|] = \mathbb{E}[|X_{n+1}|] < \infty$ por el punto (2) anterior.

Por tanto, por el ejercicio anterior, tenemos que

$$\mathbb{E}[X_{n+1} | \mathcal{F}_n] = \mathbb{E}[f(S_n + \xi_{n+1}) | \mathcal{F}_n] = \mathbb{E}[\varphi(X, Y) | \mathcal{G}] = g(X) = g(S_n),$$

donde $g(x) = \mathbb{E}[\varphi(x, Y)] = \mathbb{E}[f(x + \xi_{n+1})]$.

Por último, como f es armónica, aplicando la propiedad de la media con $r = 1$, como ξ_{n+1} está uniformemente distribuida en $\partial B_0(1)$, tenemos que $\forall x \in \mathbb{R}^d$:

$$\begin{aligned} g(x) &= \mathbb{E}[f(x + \xi_{n+1})] = \int_{\Omega} f(x + \xi_{n+1}(\omega)) \, d\mathbb{P}(\omega) \stackrel{\text{teo-medida-inducida-integral-fn-medible/teorema 1}}{=} \int_{\partial B_0(1)} f(x + y) \, d\mathbb{P}_{\xi_{n+1}}(y) \\ &= \frac{1}{\omega_d} \int_{\partial B_0(1)} f(x + y) \, d\sigma(y) = \frac{1}{\omega_d 1^{d-1}} \int_{\partial B(x,1)} f(y) \, d\sigma(y) \stackrel{\text{teo-propiedad-media-fn-armonica/teorema 1}}{=} f(x). \end{aligned}$$

Por tanto, $g = f$ y, en particular, $\forall n \in \mathbb{N} : \mathbb{E}[X_{n+1} \mid \mathcal{F}_n] = g(S_n) = f(S_n) = X_n$.

Como se cumplen las tres condiciones, concluimos que $(X_n)_{n \in \mathbb{N}}$ es una martingala respecto a la filtración $(\mathcal{F}_n)_{n \in \mathbb{N}}$. ■