PROCESOS ESTOCÁSTICOS

Máster en Matemáticas y Aplicaciones

Hugo Marquerie

Profesor: Pablo Linares Ballesteros
Facultad de Ciencias - Universidad Autónoma de Madrid
Primer cuatrimestre

15 de octubre de 2026

Puedes encontrar mi colección completa de apuntes en https://hmarquer.github.io.

Índice general

0. Esperanza condicional **1**
0.1. Introducción e intuición 1
0.2. Definición y propiedades principales 1

1. Martingalas a tiempo discreto **11**
1.1. Filtraciones y martingalas 11
1.2. Procesos predecibles. La transformada de martingala 13
1.3. Tiempos de parada 15
1.4. Teorema de descomposición de Doob 18
1.5. Teorema de convergencia de martingalas de Doob 18
1.6. Desigualdad de Doob y convergencia en $\mathcal{L}^p$ 20
1.7. Integrabilidad uniforme. Convergencia en $\mathcal{L}^1$ 24

2. Cadenas de Markov **25**
2.1. Primeros ejemplos 25
2.1.1. Paseos aleatorios 25
2.1.2. Modelos de difusión discretos 25
2.2. Núcleos de transción y cadenas de Markov 26
2.3. La cadena canónica 29

H. Hojas de ejercicios **41**
H.1. Martingalas en tiempo discreto 41

E. Entregas **45**
E.1. Martingalas y funciones armónicas 45
E.2. Procesos de ramificación 49

0. Esperanza condicional

0.1. Introducción e intuición

La idea clave de la esperanza condicional es calcular probabilidades en función de la información que tenemos disponible. Por ejemplo, si sabemos que un evento A ha ocurrido, podemos calcular la probabilidad de otro evento B condicionado a que A ha ocurrido. La esperanza condicional nos permite hacer esto de manera más general, considerando variables aleatorias y sigma-álgebras.

¿Por qué la medibilidad equivale a la información? En el espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$, sea $A \in \mathcal{F}$ un evento. La información de que A ha ocurrido se puede representar mediante la variable aleatoria indicadora $\mathbb{1}_A$, que toma el valor 1 si A ocurre y 0 en caso contrario. Esta variable aleatoria es medible con respecto a la sigma-álgebra generada por A (que es $\{\varnothing, A, A^c, \Omega\}$).

Para saber qué valor toma $\mathbb{1}_A$ en un punto $\omega \in \Omega$, basta con saber si $\omega \in A$ o no, dicho de otra manera, si sabemos que $\mathbb{1}_A(\omega) = 1$, esto solo nos dice que $\omega \in A$, pero no sabemos qué ω es exactamente.

Ejemplo 0.1.1. Veámoslo con un caso concreto: el del juego del tute. Consideramos

$$\Omega = \{\text{Todos los posibles repartos de cartas}\},$$
$$\mathcal{F} = \sigma\text{-álgebra generada por las cartas de mi mano.}$$

Entonces, dado un suceso $A \in \mathcal{F}$, cualquier reparto de cartas ω que respete mi mano A es posible. Sin embargo, no sabemos qué reparto de cartas es exactamente, solo que es uno de los posibles repartos que respetan mi mano.

El objetivo es ir actualizando la distribución de probabilidad a medida que vamos obteniendo información nueva.

0.2. Definición y propiedades principales

Teorema 0.2.1 (de Radon-Nikodym). *Sea (X, Σ) un espacio medible, μ una medida σ-finita y ν una medida con signo finita, entonces $\exists! \lambda, s$ medidas con signo tales que*

$$\nu = \lambda + s \quad \wedge \quad \lambda \ll \mu \quad \wedge \quad s \perp \mu \quad \wedge \quad \exists! f \in L^1(\mu) : \forall E \in \Sigma : \lambda(E) = \int_E f \, \mathrm{d}\mu.$$

Esta f es la ***derivada de Radon-Nikodym*** *de ν con respecto a μ y se denota por $\mathrm{d}\nu/\mathrm{d}\mu$.*

***Demostración*:** Supongamos primero que ν es una medida positiva y μ es finita. Sea

$$\mathcal{F} := \left\{ f\colon X \to [0,1] : \forall E \in \Sigma : \int_E f \,\mathrm{d}\mu \leqslant \nu(E) \right\}.$$

Observamos entonces que para $f, g \in \mathcal{F}$, $\max\{f,g\} \in \mathcal{F}$, porque si $D = \{x : f(x) > g(x)\}$,

$$\forall A \in \Sigma : \int_A \max(f,g)\,\mathrm{d}\mu = \int_{A\cap D} f\,\mathrm{d}\mu + \int_{A\cap D^{\mathsf{c}}} g\,\mathrm{d}\mu \leqslant \nu(A\cap D) + \nu(A\cap D^{\mathsf{c}}) = \nu(A).$$

Sea ahora $a := \sup_{f\in\mathcal{F}} \int_X f\,\mathrm{d}\mu$. Tenemos que $a \leqslant \nu(X) < \infty$. Por definición de supremo, $\exists\, (f_n)_{n\in\mathbb{N}} \subset \mathcal{F}$ tal que $\int_X f_n\,\mathrm{d}\mu \xrightarrow[n\to\infty]{} a$. Entonces, tomando $g_n := \max\{f_1,\ldots,f_n\}$ para cada $n \in \mathbb{N}$, tenemos que $(g_n)_{n\in\mathbb{N}} \subset \mathcal{F}$ es creciente y $\lim_{n\to\infty} \int_X g_n\,\mathrm{d}\mu = a$. Definiendo

$$\forall x \in X : f_0(x) := \lim_{n\to\infty} g_n(x),$$

el teorema de la convergencia monótona nos asegura que

$$\int_X f_0\,\mathrm{d}\mu = \lim_{n\to\infty} \int_X g_n\,\mathrm{d}\mu = a \leqslant \nu(X) < \infty.$$

Es decir, $f_0 \in \mathcal{F}$ y $f_0 \in \mathcal{L}^1(\mu)$.

Tomamos $s\colon \Sigma \to \mathbb{R}$ definida por

$$\forall E \in \Sigma : s(E) := \nu(E) - \int_E f_0\,\mathrm{d}\mu.$$

Como $f_0 \in \mathcal{F}$, s es una medida positiva. Sólo hace falta ver que $s \perp \mu$.

Por el `teo-descomposicion-hahn-jordan/`teorema 1, podemos descomponer ν en dos medidas positivas ν^+, ν^- tales que $\nu = \nu^+ - \nu^-$. ■

Podemos suponer que ν es medida positiva (o, si no, considerar ν^+, ν^- por separado, también supondremos μ finita o nos restringimos a $X = \bigcup X_n$, $\mu(X_n) < \infty$).

Sea $\mathcal{F} = \{f : X \longrightarrow [0,1] : \int_E f d\mu \leqslant \nu(E), \forall E \in \mathcal{M}\}$. Es decir, $f \in \mathcal{F} \iff d\nu - f d\mu$ es una medida positiva en $\mathcal{M}$.

Observamos que si $f, g \in \mathcal{F}$, entonces $h = \max(f,g) \in \mathcal{F}$, porque si $D = \{x : f(x) > g(x)\}$,

$$\int_A h d\mu = \int_{A\cap D} f d\mu + \int_{A\cap D^c} g d\mu \leqslant \nu(A\cap D) + \nu(A\cap D^c) = \nu(A).$$

Sea $a = \sup\{\int_X f d\mu : f \in \mathcal{F}\}$. Se tiene $a \leqslant \nu(X) < \infty$. Afirmamos que $\exists f_0 \in \mathcal{F}$ extremal, es decir, tal que $a = \int_X f_0 d\mu$ (en particular $f_0 \geqslant 0$ y $f_0 \in L^1(d\mu)$). Esto es porque $\exists f_n \in \mathcal{F}$ tal que $\int_X f_n d\mu \longrightarrow a$, por definición de supremo.

Si $g_n = \max(f_1, ..., f_n)$, g_n es creciente, $g_n \in \mathcal{F}$ y $\int_X g_n d\mu \longrightarrow a$. Definiendo $f_0(x) = \lim_{n\to\infty} g_n$, el T.C.M. prueba la afirmación.

Sea $d\lambda = d\nu - f_0 d\mu$. λ es una medida positiva, porque $f_0 \in \mathcal{F}$. Sólo hace falta ver que $d\lambda \perp d\mu$. Pero si no lo fuera, por el lema anterior, $\exists \epsilon > 0$, $E \in \mathcal{M}$ con $\mu(E) > 0$ tal que E es positivo para $d\lambda - \epsilon d\mu$. En particular, $d\lambda - \epsilon\chi_E d\mu = d\nu - (f_0 + \epsilon\chi_E)d\mu$ es una medida positiva. Pero entonces $f_0 + \epsilon\chi_E \in \mathcal{F}$, lo cual es absurdo porque

$$\int_X (f_0 + \epsilon\chi_E)d\mu = a + \epsilon\mu(E) > a.$$

Teorema 0.2.2 (Radon-Nikodym). *Sea (X, Σ) un espacio medible y μ, ν dos medidas σ-finitas en X tales que $\nu \ll \mu$. Entonces,*

$$\exists! g \geqslant 0 : \forall E \in \Sigma : \nu(E) = \int_E g \, \mathrm{d}\mu.$$

Proposición 0.2.3 (Esperanza condicionada). *Sea $(\Omega, \Sigma, \mathbb{P})$ un espacio de probabilidad, $X \in \mathcal{L}^1(\Omega, \Sigma, \mathbb{P})$ y $\mathcal{F} \subset \Sigma$ una σ-álgebra. Entonces,*

$$\exists! Y \in L^1(\Omega, \mathcal{F}, \mathbb{P}) : \forall Z \in \mathcal{L}^\infty(\Omega, \mathcal{F}, \mathbb{P}) : \mathbb{E}[YZ] = \mathbb{E}[XZ].$$

En particular, $\forall A \in \mathcal{F} : \int_A Y \, \mathrm{d}\mathbb{P} = \int_A X \, \mathrm{d}\mathbb{P}$.
*Esta Y se denomina **esperanza condicionada** de X dada $\mathcal{F}$ y se denota por $\mathbb{E}[X \mid \mathcal{F}]$.*

***Demostración*:** Definimos $\nu \colon \mathcal{F} \longrightarrow \mathbb{R}$ dada por $\nu(A) := \int_A X(\omega) \, \mathrm{d}\mathbb{P}(\omega)$, entonces es una medida con signo (ejercicio). Además, $\nu \ll \mathbb{P}$ en $\mathcal{F}$ porque si $A \in \mathcal{F}$ es tal que $\mathbb{P}(A) = 0$, entonces $\nu(A) = \int_A X \, \mathrm{d}\mathbb{P} = 0$.

Por tanto, por el teorema de Radon-Nikodym,

$$\exists! Y \in \mathcal{L}^1(\mathbb{P}) : Y \text{ es } \mathcal{F}\text{-medible} \wedge \forall A \in \mathcal{F} : \nu(A) = \int_A Y \, \mathrm{d}\mathbb{P}.$$

Veamos ahora que $\forall Z \in \mathcal{L}^\infty(\mathbb{P}) : \mathbb{E}[YZ] = \mathbb{E}[XZ]$:

1. Si Z es una función indicatriz, $Z = \mathbb{1}_A$ con $A \in \mathcal{F}$, entonces
$$\mathbb{E}[Y\mathbb{1}_A] = \int_A Y \, \mathrm{d}\mathbb{P} = \nu(A) = \int_A X \, \mathrm{d}\mathbb{P} = \mathbb{E}[X\mathbb{1}_A].$$
2. Si Z es una función simple, se tiene por linealidad de la integral (ejercicio).
3. Si $Z \in \mathcal{L}^\infty(\mathbb{P})$ se tiene por el teorema de la convergencia dominada.

■

Ejemplo 0.2.4 (de esperanza condicional). En el espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$, sea $X \in \mathcal{L}^1$ una variable aleatoria y $A \in \mathcal{F}$ un evento y sea $\mathcal{G} = \sigma(A) = \{\varnothing, A, A^{\mathsf{c}}, \Omega\}$. Entonces, si definimos

$$X_A := \frac{1}{\mathbb{P}(A)} \int_A X \, \mathrm{d}\mathbb{P}, \qquad X_{A^{\mathsf{c}}} := \frac{1}{\mathbb{P}(A^{\mathsf{c}})} \int_{A^{\mathsf{c}}} X \, \mathrm{d}\mathbb{P},$$

tenemos que $\widetilde{X} := X_A \mathbb{1}_A + X_{A^{\mathsf{c}}} \mathbb{1}_{A^{\mathsf{c}}}$ es la esperanza condicional de X con respecto a $\mathcal{G}$ ya que, para todo $B \in \mathcal{G}$, se cumple que

$$\begin{aligned} \int_B \widetilde{X} \, \mathrm{d}\mathbb{P} &= \int_B X_A \mathbb{1}_A \, \mathrm{d}\mathbb{P} + \int_B X_{A^{\mathsf{c}}} \mathbb{1}_{A^{\mathsf{c}}} \, \mathrm{d}\mathbb{P} = \int_B X \, \mathrm{d}\mathbb{P} \\ &= \int_{A \cap B} X \, \mathrm{d}\mathbb{P} + \int_{A^{\mathsf{c}} \cap B} X \, \mathrm{d}\mathbb{P} = \int_B X \, \mathrm{d}\mathbb{P}. \end{aligned}$$

Proposición 0.2.5. *Sea $X \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ y $\mathcal{G} \subset \mathcal{F}$. Entonces, la esperanza condicional de X con respecto a $\mathcal{G}$ existe y es única (salvo cambios en un conjunto de medida cero).*

***Demostración*:** Definimos $\forall A \in \mathcal{F} : \nu(A) := \int_A X \, \mathrm{d}\mathbb{P}$ y consideramos las restricciones $\nu|_{\mathcal{G}}$ y $\mathbb{P}|_{\mathcal{G}}$. Entonces, $\nu|_{\mathcal{G}} \ll \mathbb{P}|_{\mathcal{G}}$ y, por el teorema de Radon-Nikodym, existe $Y \in \mathcal{L}^1(\Omega, \mathcal{G}, \mathbb{P})$ tal que $\forall B \in \mathcal{G}$:

$$\int_B Y \, \mathrm{d}\mathbb{P} = \nu|_{\mathcal{G}}(B) = \int_B X \, \mathrm{d}\mathbb{P}$$

y esta Y es única salvo cambios en un conjunto de medida cero. ■

Lema 0.2.6 (Ley de la esperanza total). *Sea $X \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ y $\mathcal{G} \subset \mathcal{F}$. Entonces,*

$$\mathbb{E}\left[\mathbb{E}\left[X \mid \mathcal{G}\right]\right] = \mathbb{E}[X].$$

***Demostración*:** Tomando $B = \Omega$ en la definición de esperanza condicional, tenemos que

$$\int_\Omega X \, \mathrm{d}\mathbb{P} = \int_\Omega \mathbb{E}\left[X \mid \mathcal{G}\right] \mathrm{d}\mathbb{P}.$$

■

Lema 0.2.7. *Sea $X \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$, entonces $\mathbb{E}\left[X \mid \mathcal{F}\right] = X$.*

***Demostración*:** Sea $B \in \mathcal{F}$, entonces

$$\int_B X \, \mathrm{d}\mathbb{P} = \int_B X \, \mathrm{d}\mathbb{P}.$$

Por lo tanto, X cumple la definición de esperanza condicional con respecto a $\mathcal{F}$. ■

Proposición 0.2.8. *Sea $X \in \mathcal{L}^1(\mathbb{P})$ y $\mathcal{F}$ una σ-álgebra independiente de $\sigma(X)$*

$$\implies \mathbb{E}\left[X \mid \mathcal{F}\right] \equiv \mathbb{E}\left[X\right] \ \textit{c.s.}$$

***Demostración*:** Sea $Z \in \mathcal{L}^\infty(\mathbb{P})$ $\mathcal{F}$-medible, entonces $\mathbb{E}[Z \cdot \mathbb{E}[X \mid \mathcal{F}]] = \mathbb{E}[X \cdot Z]$. Como $\sigma(X)$ es independiente de $\mathcal{F}$, Z y X son independientes, por lo que

$$\mathbb{E}[Z \cdot \mathbb{E}[X \mid \mathcal{F}]] = \mathbb{E}[Z \cdot X] \overset{\text{prop-esperanza-prod-var-aleatorias-indep/1}}{\overset{\downarrow}{=}} \mathbb{E}[Z] \cdot \mathbb{E}[X] \underset{\text{lineal}}{\underset{\uparrow}{=}} \mathbb{E}[\mathbb{E}[X] \cdot Z]$$

Entonces, la función $Y := \mathbb{E}[X]\,\mathbb{1}_\Omega$ es $\mathcal{F}$-medible y cumple $\mathbb{E}[Z \cdot Y] = \mathbb{E}[X \cdot Z]$ para todo Z $\mathcal{F}$-medible. Por la unicidad de la esperanza condicionada, $Y = \mathbb{E}[X \mid \mathcal{F}]$ c.s. ■

Lema 0.2.9 (Linealidad de la esperanza condicional). *Sean $X, Y \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ y $a, b \in \mathbb{R}$. Entonces, $\mathbb{E}[aX + bY \mid \mathcal{G}] = a\mathbb{E}[X \mid \mathcal{G}] + b\mathbb{E}[Y \mid \mathcal{G}]$.*

***Demostración*:** Se deja como ejercicio: se trata de usar la linealidad de la integral y la unicidad del teorema de Radon-Nikodym. ■

Lema 0.2.10 (Monotonía). *Sean $X, Y \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ tales que $X \leqslant Y$ casi seguramente. Entonces, $\mathbb{E}[X \mid \mathcal{G}] \leqslant \mathbb{E}[Y \mid \mathcal{G}]$ casi seguramente.*

***Demostración*:** Basta probar que $\mathbb{P}(\mathbb{E}[X \mid \mathcal{G}] - \mathbb{E}[Y \mid \mathcal{G}] > 0) = 0$. Sea $\varepsilon > 0$, tomamos

$$A_\varepsilon := \{\omega \in \Omega : \mathbb{E}[X \mid \mathcal{G}](\omega) - \mathbb{E}[Y \mid \mathcal{G}](\omega) > \varepsilon\}.$$

Entonces, $A_\varepsilon \in \mathcal{G}$. Por un lado, por definición de A_ε,

$$\int_{A_\varepsilon} (\mathbb{E}[X \mid \mathcal{G}] - \mathbb{E}[Y \mid \mathcal{G}])\,\mathrm{d}\mathbb{P} > \varepsilon\mathbb{P}(A_\varepsilon).$$

Por otro lado, por la definición de esperanza condicional, tenemos que

$$\int_{A_\varepsilon} (\mathbb{E}[X \mid \mathcal{G}] - \mathbb{E}[Y \mid \mathcal{G}])\,\mathrm{d}\mathbb{P} = \int_{A_\varepsilon} (X - Y)\,\mathrm{d}\mathbb{P}.$$

Como $X - Y \leqslant 0$ casi seguramente, tenemos que $\int_{A_\varepsilon}(X - Y)\,\mathrm{d}\mathbb{P} \leqslant 0$. Por lo tanto, $\varepsilon\mathbb{P}(A_\varepsilon) < 0$, lo que implica que $\mathbb{P}(A_\varepsilon) = 0$.

Si tomamos $A_0 := \bigcup_{n\in\mathbb{N}} A_{2^{-n}}$, tenemos que $\mathbb{P}(A_0) = \lim_{n\to\infty} \mathbb{P}(A_{2^{-n}}) = 0$. ■

Lema 0.2.11 (Convergencia monótona). *Sean $(X_n)_{n\in\mathbb{N}} \subset \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ tales que $X_n \nearrow X \in \mathcal{L}^1$ c.s.. Entonces, $\mathbb{E}[X_n \mid \mathcal{G}] \nearrow \mathbb{E}[X \mid \mathcal{G}]$ c.s..*

***Demostración*:** Por monotonía de la esperanza condicional, tenemos que $\mathbb{E}[X_n \mid \mathcal{G}] \leqslant \mathbb{E}[X_{n+1} \mid \mathcal{G}]$ c.s., por lo que $(\mathbb{E}[X_n \mid \mathcal{G}])_{n\in\mathbb{N}}$ es una sucesión creciente de variables aleatorias. Entonces, por el teorema de convergencia monótona, tenemos que

$$\forall A \in \mathcal{G} : \lim_{n\to\infty} \int_A \mathbb{E}[X_n \mid \mathcal{G}]\,\mathrm{d}\mathbb{P} = \int_A \lim_{n\to\infty} \mathbb{E}[X_n \mid \mathcal{G}]\,\mathrm{d}\mathbb{P}.$$

Por otro lado, por definición de esperanza condicional, tenemos que

$$\forall A \in \mathcal{G} : \lim_{n\to\infty} \int_A \mathbb{E}\left[X_n \mid \mathcal{G}\right] \mathrm{d}\mathbb{P} = \lim_{n\to\infty} \int_A X_n \,\mathrm{d}\mathbb{P} = \int_A X \,\mathrm{d}\mathbb{P} = \int_A \mathbb{E}\left[X \mid \mathcal{G}\right] \mathrm{d}\mathbb{P}.$$

■

Lema 0.2.12 (Desigualdad de Jensen condicional).
Sea $X \in \mathcal{L}^1(\mathbb{P})$ en $(\Omega, \Sigma, \mathbb{P})$, $\mathcal{F} \subset \Sigma$ una σ-álgebra y $\varphi\colon \mathbb{R} \longrightarrow \mathbb{R}$ una función convexa

$$\implies \varphi\left(\mathbb{E}\left[X \mid \mathcal{F}\right]\right) \leqslant \mathbb{E}\left[\varphi\left(X\right) \mid \mathcal{F}\right] \ \ c.s.$$

***Demostración*:** La veremos el próximo día. Requiere una caracterización de la convexidad de una función en términos de aproximación puntual inferior por rectas que no intersecan a la función. ■

Lema 0.2.13. $\forall p \geqslant 1 : \left\|\mathbb{E}\left[X \mid \mathcal{G}\right]\right\|_p \leqslant \left\|X\right\|_p$.

***Demostración*:** Por la desigualdad de Jensen condicional con la función convexa $f(x) = |x|^p$, tenemos que

$$\mathbb{E}\Big[\, |\mathbb{E}\left[X \mid \mathcal{G}\right]|^p \mid \mathcal{G}\Big] \leqslant \mathbb{E}\Big[\, |X|^p \mid \mathcal{G}\Big].$$

Por la ley de la esperanza total, concluimos que

$$\mathbb{E}\left[|\mathbb{E}\left[X \mid \mathcal{G}\right]|^p\right] \leqslant \mathbb{E}\left[|X|^p\right].$$

■

Lema 0.2.14 (Estabilidad). *Sean $\mathcal{G}_1 \subset \mathcal{G}_2 \subset \mathcal{F}$ dos sub-σ-álgebras y $X \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$. Entonces, $\mathbb{E}\left[\mathbb{E}\left[X \mid \mathcal{G}_2\right] \mid \mathcal{G}_1\right] = \mathbb{E}\left[X \mid \mathcal{G}_1\right]$.*

***Demostración*:** Se sigue de que $\mathbb{E}\left[X \mid \mathcal{G}_2\right]$ es $\mathcal{G}_2$-medible. ■

Lema 0.2.15 (Propiedad de la torre). *Sean $\mathcal{G}_1 \subset \mathcal{G}_2 \subset \mathcal{F}$ dos sub-σ-álgebras y $X \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$. Entonces, $\mathbb{E}\left[\mathbb{E}\left[X \mid \mathcal{G}_1\right] \mid \mathcal{G}_2\right] = \mathbb{E}\left[X \mid \mathcal{G}_1\right]$.*

***Demostración*:** Sea $A \in \mathcal{G}_1$, entonces

$$\int_A \mathbb{E}\left[X \mid \mathcal{G}_1\right] \mathrm{d}\mathbb{P} = \int_A X \,\mathrm{d}\mathbb{P} = \int_A \mathbb{E}\left[X \mid \mathcal{G}_2\right] \mathrm{d}\mathbb{P} = \int_A \mathbb{E}\left[\mathbb{E}\left[X \mid \mathcal{G}_2\right] \mid \mathcal{G}_1\right] \mathrm{d}\mathbb{P}.$$

Ahora bien, como $\mathbb{E}\left[X \mid \mathcal{G}_1\right]$ es $\mathcal{G}_1$-medible, tenemos que $\mathbb{E}\left[\mathbb{E}\left[X \mid \mathcal{G}_2\right] \mid \mathcal{G}_1\right] = \mathbb{E}\left[X \mid \mathcal{G}_1\right]$. ■

Observación 0.2.16. Sean $\mathcal{G}_1 \subset \mathcal{G}_2 \subset \mathcal{F}$ dos sub-σ-álgebras y $X \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$. Entonces, por la propiedad de la torre, tenemos que

$$\mathbb{E}\left[\mathbb{E}\left[X \mid \mathcal{G}_1\right] \mid \mathcal{G}_2\right] = \mathbb{E}\left[X \mid \mathcal{G}_1\right] = \mathbb{E}\left[\mathbb{E}\left[X \mid \mathcal{G}_2\right] \mid \mathcal{G}_1\right].$$

Pero cuidado, esto solo lo podemos afirmar si $\mathcal{G}_1, \mathcal{G}_2$ son comparables, es decir, si una de ellas está contenida en la otra.

Ejemplo 0.2.17. Sea $\Omega = \{a, b, c\}$, $\mathcal{F} = \mathcal{P}(\Omega)$ y $\mathbb{P}$ la medida de probabilidad uniforme. Consideramos las siguientes sub-σ-álgebras:

$$\mathcal{G}_1 = \{\varnothing, \{a\}, \{b, c\}, \Omega\}, \qquad \mathcal{G}_2 = \{\varnothing, \{b\}, \{a, c\}, \Omega\}.$$

Sea $X \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ dada por

$$\forall \omega \in \Omega : X(\omega) = \mathbb{1}_{\{a\}}(\omega) - \mathbb{1}_{\{c\}}(\omega) = \begin{cases} 1, & \text{si } \omega = a, \\ 0, & \text{si } \omega = b, \\ 1, & \text{si } \omega = c. \end{cases}$$

Para calcular la esperanza condicional de X con respecto a $\mathcal{G}_1$, primero nos fijamos en que, como $\mathcal{G}_1$ es tan sencilla, se trata de una combinación lineal de las variables aleatorias indicatrices de los conjuntos $\{a\}$ y $\{b, c\}$. Es decir,

$$\exists \alpha, \beta \in \mathbb{R} : \mathbb{E}[X \mid \mathcal{G}_1] = \alpha \mathbb{1}_{\{a\}} + \beta \mathbb{1}_{\{b,c\}}.$$

Para calcular α y β, usamos la propiedad de la esperanza condicional:

$$\int_{\{a\}} \left(\alpha \mathbb{1}_{\{a\}} + \beta \mathbb{1}_{\{b,c\}}\right) \mathrm{d}\mathbb{P} = \int_{\{a\}} X \, \mathrm{d}\mathbb{P} \implies \alpha \, \mathbb{P}(\{a\}) = \int_{\{a\}} X \, \mathrm{d}\mathbb{P} = 1 \cdot \mathbb{P}(\{a\}),$$

$$\int_{\{b,c\}} \left(\alpha \mathbb{1}_{\{a\}} + \beta \mathbb{1}_{\{b,c\}}\right) \mathrm{d}\mathbb{P} = \int_{\{b,c\}} X \, \mathrm{d}\mathbb{P} \implies \beta \, \mathbb{P}(\{b, c\}) = \int_{\{b,c\}} X \, \mathrm{d}\mathbb{P} = -\frac{1}{2} \cdot \mathbb{P}(\{b, c\}).$$

Por tanto, nos queda que $\alpha = 1$ y $\beta = -1/2$, luego $\mathbb{E}[X \mid \mathcal{G}_1] = \mathbb{1}_{\{a\}} - \frac{1}{2} \cdot \mathbb{1}_{\{b,c\}}$.
De manera similar, podemos volver a condicionar con respecto a $\mathcal{G}_2$. Esta vez la variable aleatoria resultante será una combinación lineal de las variables aleatorias indicatrices de los conjuntos $\{b\}$ y $\{a, c\}$. Es decir,

$$\exists \gamma, \delta \in \mathbb{R} : \mathbb{E}[\mathbb{E}[X \mid \mathcal{G}_1] \mid \mathcal{G}_2] = \gamma \mathbb{1}_{\{b\}} + \delta \mathbb{1}_{\{a,c\}}.$$

Para calcular γ y δ, usamos la propiedad de la esperanza condicional:

$$\int_{\{b\}} \left(\gamma \mathbb{1}_{\{b\}} + \delta \mathbb{1}_{\{a,c\}}\right) \mathrm{d}\mathbb{P} = \int_{\{b\}} \left(\mathbb{1}_{\{a\}} - \frac{1}{2} \cdot \mathbb{1}_{\{b,c\}}\right) \mathrm{d}\mathbb{P} \implies \gamma \, \mathbb{P}(\{b\}) = -\frac{1}{2} \cdot \mathbb{P}(\{b\}),$$

$$\int_{\{a,c\}} \left(\gamma \mathbb{1}_{\{b\}} + \delta \mathbb{1}_{\{a,c\}}\right) \mathrm{d}\mathbb{P} = \int_{\{a,c\}} \left(\mathbb{1}_{\{a\}} - \frac{1}{2} \cdot \mathbb{1}_{\{b,c\}}\right) \mathrm{d}\mathbb{P} \implies \delta \, \mathbb{P}(\{a, c\}) = \mathbb{P}(\{a\}) - \frac{1}{2} \cdot \mathbb{P}(\{c\}) = \frac{1}{2} \cdot \mathbb{P}(\{$$

Por tanto, nos queda que $\gamma = -1/2$ y $\delta = 1/4$,
Si calculamos $\mathbb{E}[\mathbb{E}[X \mid \mathcal{G}_2] \mid \mathcal{G}_1]$, veremos que no coincide con $\mathbb{E}[\mathbb{E}[X \mid \mathcal{G}_1] \mid \mathcal{G}_2]$.

Lema 0.2.18 (Factores medibles). *Sea $\mathcal{G} \subset \mathcal{F}$ una sub-σ-álgebra, X una variable aleato-*

ria $\mathcal{G}$-medible y $Y \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ tales que $XY \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$. Entonces,

$$\mathbb{E}\left[XY \mid \mathcal{G}\right] = X\,\mathbb{E}\left[Y \mid \mathcal{G}\right].$$

***Demostración*:** Veámoslo por casos de complejidad creciente:

I. Si $X = \mathbb{1}_B$ para algún $B \in \mathcal{G}$, entonces

$$\begin{aligned}\int_A \mathbb{E}\left[\mathbb{1}_B Y \mid \mathcal{G}\right] \mathrm{d}\mathbb{P} &= \int_A \mathbb{1}_B Y \,\mathrm{d}\mathbb{P} = \int_{A\cap B} Y \,\mathrm{d}\mathbb{P} \\ &= \int_{A\cap B} \mathbb{E}\left[Y \mid \mathcal{G}\right] \mathrm{d}\mathbb{P} = \int_A \mathbb{1}_B \mathbb{E}\left[Y \mid \mathcal{G}\right] \mathrm{d}\mathbb{P}.\end{aligned}$$

II. Sea $X = \sum_{i=1}^n \alpha_i \mathbb{1}_{B_i}$ una función simple $\mathcal{G}$-medible (es decir, $\forall i \in \mathbb{N}_n : B_i \in \mathcal{G} \ \wedge\ \alpha_i \in \mathbb{R}$). Entonces, por linealidad de la esperanza condicional y el caso anterior, tenemos que

$$\begin{aligned}\mathbb{E}\left[XY \mid \mathcal{G}\right] &= \mathbb{E}\left[\sum_{i=1}^n \alpha_i \mathbb{1}_{B_i} Y \mid \mathcal{G}\right] = \sum_{i=1}^n \alpha_i \mathbb{E}\left[\mathbb{1}_{B_i} Y \mid \mathcal{G}\right] \\ &= \sum_{i=1}^n \alpha_i \mathbb{1}_{B_i} \mathbb{E}\left[Y \mid \mathcal{G}\right] = X\,\mathbb{E}\left[Y \mid \mathcal{G}\right].\end{aligned}$$

III. Sea X una variable aleatoria $\mathcal{G}$-medible no negativa. Entonces, existe una sucesión creciente de funciones simples $\mathcal{G}$-medibles $(X_n)_{n\in\mathbb{N}}$ tal que $X_n \nearrow X$ c.s.. Por la linealidad de la esperanza condicional y el caso anterior, tenemos que

$$\begin{aligned}\mathbb{E}\left[X_n Y \mid \mathcal{G}\right] &= \mathbb{E}\left[\lim_{n\to\infty} X_n Y \mid \mathcal{G}\right] = \mathbb{E}\left[\lim_{n\to\infty} X_n Y^+ \mid \mathcal{G}\right] - \mathbb{E}\left[\lim_{n\to\infty} X_n Y^- \mid \mathcal{G}\right] \\ &\overset{\text{TCM}}{=} \lim_{n\to\infty} \mathbb{E}\left[X_n Y^+ \mid \mathcal{G}\right] - \lim_{n\to\infty} \mathbb{E}\left[X_n Y^- \mid \mathcal{G}\right] \\ &= \lim_{n\to\infty} X_n\,\mathbb{E}\left[Y^+ \mid \mathcal{G}\right] - \lim_{n\to\infty} X_n\,\mathbb{E}\left[Y^- \mid \mathcal{G}\right] \\ &= X\,\mathbb{E}\left[Y^+ \mid \mathcal{G}\right] - X\,\mathbb{E}\left[Y^- \mid \mathcal{G}\right] = X\,\mathbb{E}\left[Y \mid \mathcal{G}\right].\end{aligned}$$

IV. Sea $X \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$. Entonces, podemos separar X en su parte positiva y negativa, es decir, $X = X^+ - X^-$. Por el caso anterior, tenemos que

$$\begin{aligned}\mathbb{E}\left[XY \mid \mathcal{G}\right] &= \mathbb{E}\left[X^+ Y \mid \mathcal{G}\right] - \mathbb{E}\left[X^- Y \mid \mathcal{G}\right] \\ &= X^+\,\mathbb{E}\left[Y \mid \mathcal{G}\right] - X^-\,\mathbb{E}\left[Y \mid \mathcal{G}\right] = X\,\mathbb{E}\left[Y \mid \mathcal{G}\right].\end{aligned}$$

■

Lema 0.2.19. *Sean X, Y variables aleatorias tales que $XY \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ y X es $\sigma(Y, \mathcal{G})$-*

independiente. Entonces,

$$\mathbb{E}\left[XY \mid \mathcal{G}\right] = \mathbb{E}\left[X\right] \mathbb{E}\left[Y \mid \mathcal{G}\right].$$

***Demostración*:** Sea $A \in \mathcal{G}$. Entonces, tenemos que

$$\begin{aligned}\int_A \mathbb{E}\left[XY \mid \mathcal{G}\right] \mathrm{d}\mathbb{P} &= \int_A XY \,\mathrm{d}\mathbb{P} = \int_\Omega \mathbb{1}_A XY \,\mathrm{d}\mathbb{P} \overset{\text{indep}}{=\!=} \mathbb{E}\left[X\right] \int_\Omega \mathbb{1}_A Y \,\mathrm{d}\mathbb{P} \\ &= \mathbb{E}\left[X\right] \int_A Y \,\mathrm{d}\mathbb{P} = \mathbb{E}\left[X\right] \int_A \mathbb{E}\left[Y \mid \mathcal{G}\right] \mathrm{d}\mathbb{P} = \int_A \mathbb{E}\left[X\right] \mathbb{E}\left[Y \mid \mathcal{G}\right] \mathrm{d}\mathbb{P}.\end{aligned}$$

■

Ejemplo 0.2.20 (de que no basta con pedir X independiente de $\mathcal{G}$ y de Y). Consideremos el experimento de lanzar dos monedas al aire. Entonces,

$$\Omega = \{HH, HT, TH, TT\}, \qquad \mathcal{F} = \mathcal{P}(\Omega), \qquad \forall \omega \in \Omega : \mathbb{P}(\{\omega\}) = 1/4.$$

Sea $X = \mathbb{1}_{\{HH,TT\}}$ e $Y = \mathbb{1}_{\{HH,TH\}}$. Consideramos además la sub-σ-álgebra $\mathcal{G} = \{\varnothing, \{HH, HT\}, \{TH, TT$ Entonces, X es independiente de $\mathcal{G}$ y de Y, pero no se cumple que $\mathbb{E}\left[XY \mid \mathcal{G}\right] = \mathbb{E}\left[X\right] \mathbb{E}\left[Y \mid \mathcal{G}\right]$.

Lema 0.2.21 (Proyección en $\mathcal{L}^2$). *Sea $X \in \mathcal{L}^2(\Omega, \mathcal{F}, \mathbb{P})$. Entonces, $\mathbb{E}\left[X \mid \mathcal{G}\right]$ es la variable aleatoria $\mathcal{G}$-medible que minimiza la distancia cuadrática a X, es decir,*

$$\mathbb{E}\left[\left(X - \mathbb{E}\left[X \mid \mathcal{G}\right]\right)^2\right] = \min_{Z \in \mathcal{G}} \mathbb{E}\left[\left(X - Z\right)^2\right].$$

***Demostración*:** Sea $Z \in \mathcal{L}^2(\Omega, \mathcal{G}, \mathbb{P})$. Entonces, tenemos que

$$\mathbb{E}\left[ZX \mid \mathcal{G}\right] - \mathbb{E}\left[Z\,\mathbb{E}\left[X \mid \mathcal{G}\right] \mid \mathcal{G}\right] = 0.$$

■

Lema 0.2.22 (de Fatou para la esperanza condicional). *Sea $\left(X_n\right)_{n\in\mathbb{N}} \subset \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ una sucesión de variables aleatorias no negativas. Entonces,*

$$\mathbb{E}\left[\liminf_{n\to\infty} X_n \,\middle|\, \mathcal{G}\right] \leqslant \liminf_{n\to\infty} \mathbb{E}\left[X_n \mid \mathcal{G}\right].$$

Teorema 0.2.23 (de convergencia dominada para la esperanza condicionada). *Sea $\left(X_n\right)_{n\in\mathbb{N}} \subset \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ una sucesión de variables aleatorias tales que $X_n \to X$ c.s. y existe $Y \in \mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ tal que $|X_n| \leqslant Y$ c.s. para todo $n \in \mathbb{N}$. Entonces,*

$$\lim_{n\to\infty} \mathbb{E}\left[X_n \mid \mathcal{G}\right] = \mathbb{E}\left[X \mid \mathcal{G}\right] \ \text{ c.s.}$$

1. Martingalas a tiempo discreto

1.1. Filtraciones y martingalas

Definición 1.1.1 (Filtración). Sea $(\Omega, \Sigma, \mathbb{P})$ un espacio de probabilidad, F es una filtración

$$\iff F = (\mathcal{F}_n)_{n\in\mathbb{N}} : \forall n \in \mathbb{N} : \mathcal{F}_n \text{ es una } \sigma\text{-álgebra} \wedge \mathcal{F}_n \subset \mathcal{F}_{n+1} \subset \Sigma.$$

Observación 1.1.2. Dado que cada σ-álgebra $\mathcal{F}_n$ representa una cantidad de información parcial acerca del espacio de probabilidad y que $\mathcal{F}_n \subset \mathcal{F}_{n+1}$, podemos interpretar $\mathcal{F}_n$ como *toda* la información disponible hasta el instante n.

Es decir, hay un refinamiento progresivo de la información a medida que n aumenta, por eso se dice que F es una *filtración*, porque filtra la información disponible para el observador.

Definición 1.1.3 (Proceso adaptado). Sea $(X_n)_{n\in\mathbb{N}}$ un proceso estocástico y F una filtración en $(\Omega, \Sigma, \mathbb{P})$, $(X_n)_{n\in\mathbb{N}}$ es un proceso adaptado a $F \iff \forall n \in \mathbb{N} : X_n$ es $\mathcal{F}_n$-medible.

Definición 1.1.4 (Submartingala). Sea $(X_n)_{n\in\mathbb{N}}$ un proceso estocástico adaptado a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$, $(X_n)_{n\in\mathbb{N}}$ es una submartingala

$$\iff \forall n \in \mathbb{N} : \mathbb{E}\left[X_{n+1} \mid \mathcal{F}_n\right] \geqslant X_n.$$

Definición 1.1.5 (Supermartingala). Sea $(X_n)_{n\in\mathbb{N}}$ un proceso estocástico adaptado a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$, $(X_n)_{n\in\mathbb{N}}$ es una supermartingala

$$\iff (-X_n)_{n\in\mathbb{N}} \text{ es una submartingala} \iff \forall n \in \mathbb{N} : \mathbb{E}\left[X_{n+1} \mid \mathcal{F}_n\right] \leqslant X_n.$$

Definición 1.1.6 (Martingala). Sea $(X_n)_{n\in\mathbb{N}}$ un proceso estocástico adaptado a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$, $(X_n)_{n\in\mathbb{N}}$ es una martingala

$$\begin{aligned} &\iff (X_n)_{n\in\mathbb{N}} \text{ es una submartingala} \wedge (X_n)_{n\in\mathbb{N}} \text{ es una supermartingala} \\ &\iff \forall n \in \mathbb{N} : \mathbb{E}\left[X_{n+1} \mid \mathcal{F}_n\right] = X_n. \end{aligned}$$

Observación 1.1.7. En vista de las observaciones `proceso-estocastico/2` y 1.1.2, podemos interpretar una martingala como un fenómeno aleatorio que evoluciona en el tiempo de manera tal que la mejor predicción del valor futuro, dado todo lo que se conoce hasta el momento, es igual al valor actual del fenómeno.

En otras palabras, no hay tendencia al alza ni a la baja en el valor esperado del fenómeno a lo largo del tiempo, lo que implica que el proceso es "justo", "neutral" o "imparcial".

Ejemplo 1.1.8 (La Martingala de Doob). Sea $X \in \mathcal{L}^1(\mathbb{P})$, $(\mathcal{F}_n)_n$ una filtración y $X_n = \mathbb{E}[X \mid \mathcal{F}_n]$ para todo $n \in \mathbb{N}$. Entonces, $(X_n)_{n\in\mathbb{N}}$ es una martingala respecto a $(\mathcal{F}_n)_n$, ya que:

1. $\mathbb{E}[|X|] = \mathbb{E}[|\mathbb{E}[X \mid \mathcal{F}_n]|] \leqslant \mathbb{E}[\mathbb{E}[|X| \mid \mathcal{F}_n]] = \mathbb{E}[|X|] < \infty$.
2. $\forall n \in \mathbb{N} : X_n = \mathbb{E}[X \mid \mathcal{F}_n]$ es $\mathcal{F}_n$-medible.
3. $\mathbb{E}[X_{n+1} \mid \mathcal{F}_n] = \mathbb{E}[\mathbb{E}[X \mid \mathcal{F}_{n+1}] \mid \mathcal{F}_n] \overset{\mathcal{F}_n \subset \mathcal{F}_{n+1}}{\overset{\downarrow}{=}} \mathbb{E}[X \mid \mathcal{F}_n] = X_n$.

Ejemplo 1.1.9. Sean $(X_j)_{j\in\mathbb{N}}$ variables aleatorias independientes y centradas. Entonces, si definimos

$$\forall C_0 \in \mathbb{R} : S_n^{C_0} := C_0 + \sum_{j=1}^{n} X_j,$$

$\left(S_n^{C_0}\right)_{n\in\mathbb{N}}$ es una martingala respecto a la filtración dada por $\mathcal{F}_n = \sigma(X_1, \ldots, X_n)$, ya que:

1. $\forall n \in \mathbb{N} : S_n^{C_0} = C_0 + \sum_{j=1}^{n} X_j$ es $\mathcal{F}_n$-medible.
2. $\forall n \in \mathbb{N} : \mathbb{E}\left[\left|S_n^{C_0}\right|\right] \leqslant |C_0| + \sum_{j=1}^{n} \mathbb{E}[|X_j|] < \infty$.
3. Comprobamos la última condición fundamental de la definición de martingala:

   $$\mathbb{E}\left[S_{n+1}^{C_0} \mid \mathcal{F}_n\right] = \mathbb{E}\left[X_{n+1} + C_0 + \sum_{j=1}^{n} X_j \;\middle|\; \mathcal{F}_n\right] \overset{\text{lineal}}{\overset{\downarrow}{=}} \mathbb{E}[X_{n+1} \mid \mathcal{F}_n] + C_0 + \sum_{j=1}^{n} \mathbb{E}[X_j \mid \mathcal{F}_n].$$

   Como las X_j son independientes, $\sigma(X_{n+1})$ es independiente de $\mathcal{F}_n = \sigma(A_1, \ldots, X_n)$, por tanto, por la proposición 0.2.8, $\mathbb{E}[X_{n+1} \mid \mathcal{F}_n] = \mathbb{E}[X_{n+1}] = 0$. Además, como las $\{X_j\}_{j=1}^n$ son $\mathcal{F}_n$-medibles, por la propiedad `lem-esperanza-condicionada/`(3) del `lem-esperanza-condicionada/`lema 1 $\mathbb{E}[X_j \mid \mathcal{F}_n] = X_j$ para todo $j \leqslant n$.

$$\therefore \quad \mathbb{E}\left[S_{n+1}^{C_0} \mid \mathcal{F}_n\right] = 0 + C_0 + \sum_{j=1}^{n} X_j = S_n^{C_0}.$$

Ejemplo 1.1.10 (Paseo aleatorio). Sean $(\xi_j)_{j\in\mathbb{N}}$ variables aleatorias independientes idénticamente distribuidas con $\mathbb{P}(\xi_j = 1) = p$ y $\mathbb{P}(\xi_j = -1) = 1 - p$. Definimos

$$\forall n \in \mathbb{N} : X_n = \sum_{j=1}^{n} \xi_j.$$

Entonces, como $\mathbb{E}[\xi_j] = 1 \cdot p + (-1) \cdot (1 - p) = 2p - 1$, tenemos que

$$\mathbb{E}[X_{n+1} \mid \mathcal{F}_n] = \mathbb{E}[X_n + \xi_{n+1} \mid \mathcal{F}_n] = X_n + \mathbb{E}[\xi_{n+1}] = X_n + (2p - 1).$$

Por lo tanto, tenemos tres casos distintos:

I. Si $p \in \left[0, 1/2\right)$, $(X_n)_{n\in\mathbb{N}}$ es una supermartingala.
II. Si $p = \frac{1}{2}$, $(X_n)_{n\in\mathbb{N}}$ es una martingala.
III. Si $p \in \left(1/2, 1\right]$, $(X_n)_{n\in\mathbb{N}}$ es una submartingala.

Proposición 1.1.11. *Sea $(X_n)_{n\in\mathbb{N}}$ una submartingala respecto a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$. Entonces,*

$$\forall m < n : X_m \leqslant \mathbb{E}\left[X_n \mid \mathcal{F}_m\right].$$

***Demostración*:** Como $m < n$, existe $k \in \mathbb{N}$ tal que $m + k = n$. Veámoslo por inducción sobre k:

- Para $k = 1$, por la definición de submartingala, $\mathbb{E}\left[X_{m+1} \mid \mathcal{F}_m\right] \geqslant X_m$.
- Supongamos que la afirmación es cierta para k. Entonces, para $k+1$, tenemos que

  $$\mathbb{E}\left[X_{m+k+1} \mid \mathcal{F}_m\right] = \mathbb{E}\left[\mathbb{E}\left[X_{m+k+1} \mid \mathcal{F}_{m+k}\right] \mid \mathcal{F}_m\right] \geqslant \mathbb{E}\left[X_{m+k} \mid \mathcal{F}_m\right] \geqslant X_m,$$

  donde la primera desigualdad se debe a que $(X_n)_{n\in\mathbb{N}}$ es una submartingala y la segunda desigualdad se debe a la hipótesis de inducción.

■

Proposición 1.1.12. *Sea $(X_n)_{n\in\mathbb{N}}$ una martingala respecto a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$ y sea $\varphi\colon \mathbb{R} \to \mathbb{R}$ una función convexa tal que $\forall n \in \mathbb{N} : \varphi(X_n) \in \mathcal{L}^1(\mathbb{P})$. Entonces, $(\varphi(X_n))_{n\in\mathbb{N}}$ es una submartingala respecto a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$.*

***Demostración*:** Se sigue directamente de la desigualdad de Jensen para la esperanza condicional:

$$\varphi\left(X_n\right) = \varphi\left(\mathbb{E}\left[X_{n+1} \mid \mathcal{F}_n\right]\right) \leqslant \mathbb{E}\left[\varphi\left(X_{n+1}\right) \mid \mathcal{F}_n\right].$$

■

Corolario 1.1.13. *Sea $p \geqslant 1$ y $(X_n)_{n\in\mathbb{N}}$ una martingala respecto a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$ tal que $\forall n \in \mathbb{N} : X_n \in \mathcal{L}^p(\mathbb{P})$. Entonces, $(|X_n|^p)_{n\in\mathbb{N}}$ es una submartingala respecto a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$.*

1.2. Procesos predecibles. La transformada de martingala

Definición 1.2.1 (Proceso predecible). Sea $(X_n)_{n\in\mathbb{N}}$ un proceso estocástico adaptado a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$, $(X_n)_{n\in\mathbb{N}}$ es predecible $\iff \forall n \in \mathbb{N} : X_n$ es $\mathcal{F}_{n-1}$-medible.

Teorema 1.2.2. *Sea $X = (X_n)_{n\in\mathbb{N}}$ una submartingala y $H = (H_n)_{n\in\mathbb{N}}$ un proceso predecible tal que $\forall n \in \mathbb{N} : H_n \in \mathcal{L}^\infty \wedge H_n \geqslant 0$ casi seguramente. Entonces, $H \cdot X$ dada por*

$$\forall n \in \mathbb{N} : (H \cdot X)_n = \sum_{j=1}^{n} H_j \left(X_j - X_{j-1}\right)$$

es una submartingala respecto a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$.

***Demostración*:** Veamos que se satisfacen las condiciones de la definición de submartingala:

1. $$\begin{aligned}\mathbb{E}\left[|(H\cdot X)_n|\right] &\leqslant \sum_{j=1}^{n}\mathbb{E}\left[|H_j\left(X_j - X_{j-1}\right)|\right]\\ &\leqslant \sum_{j=1}^{n}\|H_j\|_\infty\,\mathbb{E}\left[|X_j - X_{j-1}|\right] \leqslant \sum_{j=1}^{n}\|H_j\|_\infty\left(\mathbb{E}\left[|X_j|\right] + \mathbb{E}\left[|X_{j-1}|\right]\right) < \infty.\end{aligned}$$

2. Comprobamos la última condición fundamental de la definición de submartingala:

$$\begin{aligned}\mathbb{E}\left[(H\cdot X)_{n+1} \mid \mathcal{F}_n\right] &= \sum_{j=1}^{n}\mathbb{E}\left[H_j\left(X_j - X_{j-1}\right) \mid \mathcal{F}_n\right] + \mathbb{E}\left[H_{n+1}\left(X_{n+1} - X_n\right) \mid \mathcal{F}_n\right]\\ &\overset{\text{medible}}{\overset{\downarrow}{=}} \sum_{j=1}^{n} H_j\left(X_j - X_{j-1}\right) + \mathbb{E}\left[H_{n+1}\left(X_{n+1} - X_n\right) \mid \mathcal{F}_n\right]\\ &\overset{H\text{ predecible}}{\overset{\downarrow}{=}} (H\cdot X)_n + H_n\mathbb{E}\left[X_{n+1} - X_n \mid \mathcal{F}_n\right].\end{aligned}$$

   Ahora bien, como X es una submartingala,

$$\mathbb{E}\left[X_{n+1} - X_n \mid \mathcal{F}_n\right] = \mathbb{E}\left[X_{n+1} \mid \mathcal{F}_n\right] - \mathbb{E}\left[X_n \mid \mathcal{F}_n\right] = \mathbb{E}\left[X_{n+1} \mid \mathcal{F}_n\right] - X_n \geqslant 0$$

   casi seguramente, y como $H_n \geqslant 0$ casi seguramente, finalmente tenemos que

$$\mathbb{E}\left[(H\cdot X)_{n+1} \mid \mathcal{F}_n\right] \geqslant (H\cdot X)_n.$$

Así, $(H\cdot X)_n$ es una submartingala respecto a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$. ■

Observación 1.2.3. $\forall n \in \mathbb{N} : (H\cdot X)_n$ es una suma de Riemann y también una integral estocástica discreta.

Observación 1.2.4. Si $(X_n)_{n\in\mathbb{N}}$ es una martingala, entonces la condición de $H_n \geqslant 0$ es innecesaria. En tal caso, se dice que $H\cdot X$ es la **transformada de martingala** de X por H.

Observación 1.2.5. Sean $(\xi_i)_{i\in\mathbb{N}}$ variables aleatorias independientes idénticamente distribuidas con $\mathbb{P}(\xi_i = 1) = 1/2$ y $\mathbb{P}(\xi_i = -1) = 1/2$. Definimos

$$\forall n \in \mathbb{N} : X_n = \sum_{j=1}^{n}\xi_j.$$

Entonces, $(X_n)_{n\in\mathbb{N}}$ es una martingala respecto a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$ dada por $\mathcal{F}_n =$

$\sigma(\xi_1, \ldots, \xi_n)$.

Elaboramos la estrategia de apuesta $(Y_n)_{n\in\mathbb{N}}$, dada recusivamente por

$$\forall n \in \mathbb{N} : Y_{n+1} = Y_n + H_{n+1}\xi_{n+1}, \quad Y_0 = 0,$$

donde H_{n+1} es predecible respecto a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$ y representa la cantidad de dinero apostada en el $(n+1)$-ésimo paso. Entonces, tenemos que

$$\forall n \in \mathbb{N} : Y_n = Y_0 + \sum_{j=1}^{n} H_j \left(X_j - X_{j-1}\right).$$

Con esta interpretación, el teorema anterior nos dice que si $(X_n)_{n\in\mathbb{N}}$ es una martingala y H es un proceso predecible acotado, entonces la estrategia de apuesta Y es una martingala. En otras palabras, no hay manera de ganar dinero apostando en un juego justo.

Tomamos $\forall n \in \mathbb{N}$:

$$H_n = \begin{cases} 2H_{n-1} & \text{si } \xi_{n-1} = -1, \\ 1 & \text{si } \xi_{n-1} = 1 \end{cases}$$

Entonces, por el resultado anterior, $\mathbb{E}\left[(H \cdot X)_n\right] = 0$ para todo $n \in \mathbb{N}$. Esta estrategia es aparentemente ganadora porque, si $\xi_{n-1} = -1$, doblamos la apuesta y, si $\xi_{n-1} = 1$, apostamos 1. Por lo tanto, si en algún momento obtenemos un 1, ganamos 1 y, si obtenemos una racha de -1's, doblamos la apuesta hasta que salga un 1. Sin embargo, el teorema nos dice que no hay manera de ganar dinero apostando en un juego justo.

En la práctica, el problema fundamental de esta estrategia es que debes tener un capital infinito para poder doblar la apuesta indefinidamente.

1.3. Tiempos de parada

Definición 1.3.1 (Tiempo de parada). Sea $T\colon \Omega \to \mathbb{N} \cup \{\infty\}$ una variable aleatoria en $(\Omega, \Sigma, \mathbb{P})$, T es un tiempo de parada respecto a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$

$$\iff \forall n \in \mathbb{N} : T^{-1}(\{n\}) = \{\omega \in \Omega : T(\omega) = n\} \in \mathcal{F}_n.$$

Lema 1.3.2. *Sea $T\colon \Omega \to \mathbb{N}\cup\{\infty\}$ una variable aleatoria, T es un tiempo de parada respecto a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$*

$$\iff \forall k \in \mathbb{N} : \{\omega \in \Omega : T(\omega) \leqslant k\} \in \mathcal{F}_k.$$

***Demostración*:** Veamos ambas implicaciones:

$\boxed{\Rightarrow}$ Por definición, tenemos que $\forall n \in \mathbb{N} : T^{-1}(\{n\}) \in \mathcal{F}_n$. Por tanto,

$$\forall k \in \mathbb{N} : T^{-1}(\{n \in \mathbb{N} : n \leqslant k\}) = \bigcup_{n=1}^{k} T^{-1}(\{n\}) \in \mathcal{F}_k,$$

ya que las $\mathcal{F}_n$ están anidadas y son cerradas bajo uniones numerables.

$\boxed{\Leftarrow}$ Sea T una variable aleatoria tal que $\forall k \in \mathbb{N} : T^{-1}(\{n \in \mathbb{N} : n \leqslant k\}) \in \mathcal{F}_k$. Entonces, como las $\mathcal{F}_n$ son σ-álgebras anidadas, tenemos que

$$\begin{aligned}\forall n \in \mathbb{N} : T^{-1}(\{n\}) &= T^{-1}(\{k \leqslant n\}) \setminus T^{-1}(\{k \leqslant n-1\}) \\ &= T^{-1}(\{k \leqslant n\}) \cap \left(T^{-1}(\{k \leqslant n-1\})\right)^{\mathsf{c}} \in \mathcal{F}_n.\end{aligned}$$

■

Teorema 1.3.3. *Sean $(X_n)_{n\in\mathbb{N}}$ una submartingala y T un tiempo de parada respecto a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$. Entonces, $(X_{T\wedge n})_{n\in\mathbb{N}}$ es una submartingala respecto a $(\mathcal{F}_n)_{n\in\mathbb{N}}$, donde*

$$\forall n \in \mathbb{N} : \forall \omega \in \Omega : (X_{T\wedge n})(\omega) := \begin{cases} X_n(\omega) & \text{si } T(\omega) \geqslant n, \\ X_{T(\omega)}(\omega) & \text{si } T(\omega) < n. \end{cases}$$

***Demostración*:** Definimos $\forall n \in \mathbb{N} : H_n := \mathbb{1}_{\{T \geqslant n\}}$. Entonces, $H = (H_n)_{n\in\mathbb{N}}$ es un proceso predecible porque $\forall n \in \mathbb{N} : \{T \geqslant n\} = \{T \leqslant n-1\}^{\mathsf{c}} \in \mathcal{F}_{n-1}$, y además, $H_n \geqslant 0$. Por tanto, $(H \cdot X)_n$ es una submartingala respecto a $(\mathcal{F}_n)_{n\in\mathbb{N}}$.

Recordemos que $\forall n \in \mathbb{N}$:

$$(H \cdot X)_n = \sum_{j=1}^{n} H_j (X_j - X_{j-1}) = \sum_{j=1}^{n} \mathbb{1}_{\{T \geqslant j\}} (X_j - X_{j-1}).$$

Sea $\omega \in \Omega$. Veamos dos posibilidades mutuamente excluyentes:

I. Si $T(\omega) \geqslant n$, entonces $(H \cdot X)_n(\omega) = \sum_{j=1}^{n} (X_j - X_{j-1})(\omega) = X_n(\omega) - X_0(\omega)$.

II. Si $T(\omega) < n$, entonces $(H \cdot X)_n(\omega) = \sum_{j=1}^{T(\omega)} (X_j - X_{j-1})(\omega) = X_{T(\omega)}(\omega) - X_0(\omega)$.

Por lo tanto, $\forall n \in \mathbb{N} : (H \cdot X)_n = X_{T\wedge n} - X_0$. Como $(H \cdot X)_n$ es una submartingala, $(X_{T\wedge n})_{n\in\mathbb{N}}$ también lo es. ■

Observación 1.3.4. Sea $(X_n)_{n\in\mathbb{N}}$ una submartingala, entonces

$$\mathbb{E}[X_0] \leqslant \mathbb{E}[\mathbb{E}[X_1 \mid \mathcal{F}_0]] = \mathbb{E}[X_1] \leqslant \mathbb{E}[X_2] \leqslant \dots.$$

Por lo tanto, $(\mathbb{E}[X_n])_{n\in\mathbb{N}}$ es una sucesión creciente y acotada inferiormente por $\mathbb{E}[X_0]$. En particular, si $(X_n)_{n\in\mathbb{N}}$ es una martingala, entonces $\forall n \in \mathbb{N} : \mathbb{E}[X_n] = \mathbb{E}[X_0]$.
Ahora bien, para un tiempo de parada T, ¿es cierto que $\mathbb{E}[X_0] \leqslant \mathbb{E}[X_T]$? La respuesta es no, como muestra el siguiente ejemplo:

Ejemplo 1.3.5. Retomamos el ejemplo de la estrategia de martingala. Sea $(\xi_i)_{i\in\mathbb{N}}$ variables aleatorias independientes idénticamente distribuidas con $\mathbb{P}(\xi_i = 1) = 1/2$ y $\mathbb{P}(\xi_i = -1) = 1/2$. Definimos

$$\forall n \in \mathbb{N} : X_n = \sum_{j=1}^{n} \xi_j.$$

Entonces, $(X_n)_{n\in\mathbb{N}}$ es una martingala respecto a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$ dada por $\mathcal{F}_n = \sigma(\xi_1, \ldots, \xi_n)$.

Consideramos $\forall n \in \mathbb{N} : H_n = 2^{n-1}\mathbb{1}_{\{\xi_{n-1}=-1\}} + \mathbb{1}_{\{\xi_{n-1}=1\}}$ y

$$\forall n \in \mathbb{N} : (H \cdot X)_n = \sum_{j=1}^{n} H_j (X_j - X_{j-1}).$$

Además, definimos el tiempo de parada $T = \text{ínf}\{n \in \mathbb{N} : X_n - X_{n-1} = 1\}$, entonces

$$(H \cdot X)_{T\wedge n} = \begin{cases} 1 & \text{si } T \leqslant n, \\ 1 - 2^n & \text{si } T > n. \end{cases}$$

Por tanto, $\mathbb{E}[(H \cdot X)_T] = \sum_{n=1}^{\infty} 1 \cdot \mathbb{P}(T = n) = \sum_{n=1}^{\infty} 2^{-n} = 1$, mientras que $\mathbb{E}[(H \cdot X)_0] = 0$.

Teorema 1.3.6. *Sea $(X_n)_{n\in\mathbb{N}}$ una submartingala y sea T un tiempo de parada respecto a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$ tal que $\exists N \in \mathbb{N} : \mathbb{P}(T \leqslant N) = 1$. Entonces,*

$$\mathbb{E}[X_0] \leqslant \mathbb{E}[X_T] \leqslant \mathbb{E}[X_N].$$

***Demostración*:** Fijamos $n \in \mathbb{N}$. Entonces, por la ley de la esperanza total, tenemos que

$$\mathbb{E}\left[X_{T\wedge(n+1)}\right] \geqslant \mathbb{E}[X_{T\wedge n}] \geqslant \cdots \geqslant \mathbb{E}[X_0].$$

Además, $\mathbb{E}[X_{T\wedge n}] \leqslant \mathbb{E}\left[X_{T\wedge(n+1)}\right] \leqslant \cdots \leqslant \mathbb{E}[X_T]$ luego $\mathbb{E}[X_0] \leqslant \mathbb{E}[X_T]$.

Por otro lado, para ver que $\mathbb{E}[X_T] \leqslant \mathbb{E}[X_N]$, tomamos $H_n := \mathbb{1}_{\{T\leqslant n-1\}}$. Entonces, $((H \cdot X)_n)_{n\in\mathbb{N}}$ es una submartingala y

$$(H \cdot X)_n = \sum_{j=1}^{n} \mathbb{1}_{\{T\leqslant j-1\}} (X_j - X_{j-1}) = X_n - X_{T\wedge n}.$$

Luego para $n = N$, $\mathbb{E}[X_N] - \mathbb{E}[X_T] = \mathbb{E}[(H \cdot X)_N] \geqslant 0$, por lo que $\mathbb{E}[X_T] \leqslant \mathbb{E}[X_N]$. ■

1.4. Teorema de descomposición de Doob

Definición 1.4.1 (Proceso creciente). Un proceso estocástico $(X_n)_{n\in\mathbb{N}}$ es creciente $\iff$ $\forall n \in \mathbb{N} : X_n \leqslant X_{n+1}$ casi seguramente.

Teorema 1.4.2 (de descomposición de Doob). *Sea $(X_n)_{n\in\mathbb{N}}$ una submartingala respecto a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$. Entonces, existe una única descomposición de la forma $X_n = M_n + A_n$, donde*

(1) *$(M_n)_{n\in\mathbb{N}}$ es una martingala respecto a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$.*
(2) *$(A_n)_{n\in\mathbb{N}}$ es un proceso estocástico creciente y predecible respecto a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$ tal que $A_0 = 0$.*

***Demostración*:** Queremos ver que $\mathbb{E}[X_n \mid \mathcal{F}_{n-1}] = \mathbb{E}[M_n \mid \mathcal{F}_{n-1}] + \mathbb{E}[A_n \mid \mathcal{F}_{n-1}] = M_{n-1} + A_n = X_{n-1} + (A_n - A_{n-1})$. Por tanto, definimos

$$\begin{cases} A_n = A_{n-1} + (\mathbb{E}[X_n \mid \mathcal{F}_{n-1}] - X_{n-1}), \\ M_n = X_n - A_n. \end{cases}$$

Si fijamos $A_0 = 0$, la construcción es única. ■

1.5. Teorema de convergencia de martingalas de Doob

En está sección, nos interesa estudiar el comportamiento asintótico de las martingalas. En particular, queremos encontrar las condiciones necesarias para garantizar que una martingala no escapa a ∞ o evitar que oscile (*upcrossings innequality*).

Fijamos $[a, b] \subset \mathbb{R}$ queremos contar el número de veces que X_n cruza desde debajo de a hasta arriba de b. Para ello, definimos

$$\begin{aligned} N_0 &= -1 \\ N_1 &= \text{ínf}\{m > N_0 : X_m \leqslant a\}, \\ N_2 &= \text{ínf}\{m > N_1 : X_m \geqslant b\}, \\ &\vdots \\ N_{2k-1} &= \text{ínf}\{m > N_{2k-2} : X_m \leqslant a\}, \\ N_{2k} &= \text{ínf}\{m > N_{2k-1} : X_m \geqslant b\}. \end{aligned}$$

Así, tenemos que N_{2k-1} es el momento en que el X_n cruza por debajo de a (por primera vez desde que cruzó por encima de b) y N_{2k} es el momento en que X_n cruza por encima de b (por primera vez desde que cruzó por debajo de a). Por tanto, satisfacen que $\forall k \in \mathbb{N} : X_{N_{2k-1}} \leqslant$

$a < b \leqslant X_{N_{2k}}$. Para contar el número de veces que X_n cruza desde debajo de a hasta arriba de b, definimos

$$\mathcal{U}_{n;[a,b]} := \sup\{k \in \mathbb{N} : N_{2k} \leqslant n\}.$$

Teorema 1.5.1 (Desigualdad de los cruces). *Sea $(X_n)_{n\in\mathbb{N}}$ una submartingala respecto a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$. Entonces, para todo $a < b \in \mathbb{R}$ y $n \in \mathbb{N}$, se tiene que*

$$(b-a)\,\mathbb{E}\left[\mathcal{U}_{n;[a,b]}\right] \leqslant \mathbb{E}\left[(X_n - a)^+\right] - \mathbb{E}\left[(X_0 - a)^+\right].$$

***Demostración*:** Definimos $\forall m \in \mathbb{N} : Y_m := a + (X_m - a)^+$. Entonces, $(Y_m)_{m\in\mathbb{N}}$ es una submartingala y sus cruces son los mismos que los de $(X_m)_{m\in\mathbb{N}}$.

Observamos que cada N_j es un tiempo de parada respecto a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$, ya que

$$\forall k \in \mathbb{N} : \forall m \in \mathbb{N} : \{N_{2k-1} < m \leqslant N_{2k}\} = \{N_{2k-1} \leqslant m-1\} \cap \{N_{2k} \leqslant m-1\}^{\mathsf{c}} \in \mathcal{F}_{m-1}.$$

Tomamos $\forall m \in \mathbb{N} : A_m := \bigcup_{k\in\mathbb{N}}\{N_{2k-1} < m \leqslant N_{2k}\}$ y definimos $H_m := \mathbb{1}_{A_m}$. Entonces, $\forall m \in \mathbb{N} : A_m \in \mathcal{F}_{m-1}$ y $H = (H_m)_{m\in\mathbb{N}}$ es un proceso predecible. Tomamos la transformada de martingala $H \cdot Y$ y observamos que

$$(H \cdot Y)_n = \sum_{j=1}^{n} H_j\,(Y_j - Y_{j-1}) \geqslant (b-a)\,\mathcal{U}_{n;[a,b]} + \cdots \geqslant (b-a)\,\mathcal{U}_{n;[a,b]}.$$

Tomamos ahora $\forall m \in \mathbb{N} : K_m = 1 - H_m$ y observamos que $K = (K_m)_{m\in\mathbb{N}}$ es un proceso predecible. Tomamos la transformada de martingala $K \cdot Y$ y observamos que

$$\mathbb{E}\left[(K \cdot Y)_n\right] \geqslant \mathbb{E}\left[(K \cdot Y)_0\right] = 0.$$

Entonces, $\mathbb{E}\left[Y_n\right] - \mathbb{E}\left[Y_0\right] = \mathbb{E}\left[(H \cdot Y)_n\right] + \mathbb{E}\left[(K \cdot Y)_n\right] \geqslant (b-a)\,\mathbb{E}\left[\mathcal{U}_{n;[a,b]}\right]$, de donde se obtiene la desigualdad deseada:

$$\mathbb{E}\left[(Y_n - Y_0)\right] = \mathbb{E}\left[(X_n - a)^+\right] - \mathbb{E}\left[(X_0 - a)^+\right] \geqslant (b-a)\,\mathbb{E}\left[\mathcal{U}_{n;[a,b]}\right].$$

■

Teorema 1.5.2 (de convergencia de Martingalas). *Sea $(X_n)_{n\in\mathbb{N}}$ una submartingala respecto a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$ tal que $\sup_{n\in\mathbb{N}}\mathbb{E}\left[X_n^+\right] < \infty$. Entonces, existe una variable aleatoria $X_\infty \in \mathcal{L}^1(\mathbb{P})$ tal que $(X_n)_{n\in\mathbb{N}}$ converge casi seguramente a X_∞.*

***Demostración*:** Por la desigualdad de los cruces, $\forall a < b \in \mathbb{R} : \forall n \in \mathbb{N}$:

$$\mathbb{E}\left[\mathcal{U}_{n;[a,b]}\right] \leqslant \frac{1}{b-a}\mathbb{E}\left[(X_n - a)^+\right] \leqslant \frac{1}{b-a}\left(\mathbb{E}\left[X_n^+\right] + |a|\right)$$

luego $\sup_{n\in\mathbb{N}} \mathbb{E}\left[\mathcal{U}_{n;[a,b]}\right] < \infty$. Como la sucesión $\left(\mathcal{U}_{n;[a,b]}\right)_{n\in\mathbb{N}}$ es no decreciente, por el teorema de la convergencia monótona, $\mathbb{E}\left[\mathcal{U}_{n;[a,b]}\right] < \infty \implies \mathcal{U}_{n;[a,b]} < \infty$ casi seguramente. Consideramos $A := \{\liminf_{n\to\infty} X_n < \limsup_{n\to\infty} X_n\}$ y para cualesquiera $a < b$, $A_{[a,b]} := \{\liminf_{n\to\infty} X_n < a < b < \limsup_{n\to\infty} X_n\}$.

Si $\liminf_{n\to\infty} X_n < a$, necesariamente $X_n < a$ infinitas veces y si $b < \limsup_{n\to\infty} X_n$, necesariamente $X_n > b$ infinitas veces. Por tanto, $\forall a < b \in \mathbb{R} : \mathbb{P}\left(A_{[a,b]}\right) = 0$ por la desigualdad de los cruces.

Tomamos $A = \bigcup_{\substack{a<b\\ a,b\in\mathbb{Q}}} A_{[a,b]}$, entonces $\mathbb{P}(A) = 0$ y $\forall \omega \in A^{\mathsf{c}} : \lim_{n\to\infty} X_n(\omega)$ existe y es finito. Definimos $X_\infty(\omega) := \lim_{n\to\infty} X_n(\omega)$ para $\omega \in A^{\mathsf{c}}$ y $X_\infty(\omega) := 0$ para $\omega \in A$. Entonces, $(X_n)_{n\in\mathbb{N}}$ converge casi seguramente a X_∞.

Veamos ahora que $X_\infty \in \mathcal{L}^1(\mathbb{P})$. Por la desigualdad de Fatou,

$$\mathbb{E}\left[X_\infty^+\right] \leqslant \liminf_{n\to\infty} \mathbb{E}\left[X_n^+\right] < \infty.$$

y $\mathbb{E}[X_n^-] = -\mathbb{E}[X_n] + \mathbb{E}[X_n^+] \leqslant \mathbb{E}[X_n^+] - \mathbb{E}[X_0]$. De nuevo por el lema de Fatou,

$$\mathbb{E}\left[X_\infty^-\right] \leqslant \liminf_{n\to\infty} \mathbb{E}\left[X_n^+\right] - \mathbb{E}[X_0] < \infty.$$

Así, $\mathbb{E}[|X_\infty|] = \mathbb{E}[X_\infty^+] + \mathbb{E}[X_\infty^-] < \infty$, por lo que $X_\infty \in \mathcal{L}^1(\mathbb{P})$. ■

1.6. Desigualdad de Doob y convergencia en $\mathcal{L}^p$

Teorema 1.6.1 (Desigualdad de Doob). *Sea $(X_n)_{n\in\mathbb{N}}$ una submartingala. Entonces,*

$$\forall C > 0 : \mathbb{P}\left(\max_{1\leqslant m\leqslant n} X_m \geqslant C\right) \leqslant \frac{\mathbb{E}[X_n^+]}{C}.$$

***Demostración*:** Fijamos $n \in \mathbb{N}$ y $C > 0$. Definimos

$$T = \text{ínf}\{m \in \mathbb{N}_n : X_m \geqslant C\} \wedge n.$$

Como T está acotado por n, $\mathbb{E}[X_T] \leqslant \mathbb{E}[X_n]$.

Por otro lado,

$$\mathbb{P}\left(\max_{1\leqslant m\leqslant n} X_m \geqslant C\right) = \mathbb{E}\left[\mathbb{1}_{\{\text{máx}_{1\leqslant m\leqslant n} X_m \geqslant C\}}\right] \leqslant \mathbb{E}\left[\frac{X_T}{C}\mathbb{1}_{\{\text{máx}_{1\leqslant m\leqslant n} X_m \geqslant C\}}\right].$$

Por último, en $\{\text{máx}_{m\in\mathbb{N}_n} X_m \geqslant C\}^{\mathsf{c}}$ tenemos que $X_T = X_n$, luego

$$\begin{aligned}\mathbb{E}\left[X_T\mathbb{1}_{\{\text{máx}_{m\in\mathbb{N}_n} X_m \geqslant C\}}\right] &= \mathbb{E}[X_T] - \mathbb{E}\left[X_T\mathbb{1}_{\{\text{máx}_{m\in\mathbb{N}_n} X_m \geqslant C\}^{\mathsf{c}}}\right]\\ &\leqslant \mathbb{E}[X_n] - \mathbb{E}\left[X_n\mathbb{1}_{\{\text{máx}_{m\in\mathbb{N}_n} X_m \geqslant C\}^{\mathsf{c}}}\right] = \mathbb{E}\left[X_n\mathbb{1}_{\{\text{máx}_{m\in\mathbb{N}_n} X_m \geqslant C\}}\right].\end{aligned}$$

Así, $\mathbb{P}\left(\text{máx}_{m\in\mathbb{N}_n} X_m \geqslant C\right) \leqslant \frac{1}{C}\mathbb{E}\left[X_n \mathbb{1}_{\{\text{máx}_{m\in\mathbb{N}_n} X_m \geqslant C\}}\right] \leqslant \frac{1}{C}\mathbb{E}\left[X_n^+\right]$. ■

Lema 1.6.2. *Sea (X, Σ, μ) un espacio de medida σ-finito, $\phi\colon [0,\infty) \to [0,\infty)$ una función $\mathcal{C}^1$ no decreciente con $\phi(0) = 0$ y $f\colon X \to \mathbb{R}$ medible. Entonces,*

$$\int_X \phi\left(|f|\right) \mathrm{d}\mu = \int_0^\infty \phi'(\lambda)\, d_f(\lambda)\, \mathrm{d}\lambda.$$

En particular, para $p \geqslant 1$, $\|f\|_{\mathcal{L}^p}{}^p = p\displaystyle\int_0^\infty \lambda^{p-1}\, d_f(\lambda)\, \mathrm{d}\lambda$.

***Demostración*:** Por el teorema fundamental del cálculo, $\phi(t) = \int_0^t \phi'(\lambda)\, \mathrm{d}\lambda$. Por tanto,

$$\int_X \phi\left(|f|\right) \mathrm{d}\mu = \int_X \int_0^{|f(x)|} \phi'(\lambda)\, \mathrm{d}\lambda\, \mathrm{d}\mu(x) = \int_X \int_0^\infty \phi'(\lambda)\, \mathbb{1}_{\{|f(x)|>\lambda\}}\, \mathrm{d}\lambda\, \mathrm{d}\mu(x).$$

La función $(x,\lambda) \mapsto \phi'(\lambda)\, \mathbb{1}_{\{|f(x)|>\lambda\}}$ es medible y no negativa en $X \times [0,\infty)$. Por el teorema de Tonelli, podemos cambiar el orden de integración y obtener

$$\int_X \phi\left(|f|\right) \mathrm{d}\mu = \int_0^\infty \phi'(\lambda) \int_X \mathbb{1}_{\{|f(x)|>\lambda\}}\, \mathrm{d}\mu(x)\, \mathrm{d}\lambda = \int_0^\infty \phi'(\lambda)\, d_f(\lambda)\, \mathrm{d}\lambda.$$

En particular, si $\phi(t) = t^p$, entonces $\phi'(t) = pt^{p-1}$ y obtenemos que

$$\|f\|_{\mathcal{L}^p}^p = \int_X |f|^p \, \mathrm{d}\mu = \int_0^\infty p\lambda^{p-1}\, d_f(\lambda)\, \mathrm{d}\lambda = p\int_0^\infty \lambda^{p-1}\, d_f(\lambda)\, \mathrm{d}\lambda.$$

■

Teorema 1.6.3 (Desigualdad maximal de Doob). *Sea $(X_n)_{n\in\mathbb{N}}$ una submartingala y sea $p > 1$. Entonces,*

$$\mathbb{E}\left[\left|\max_{m\in\mathbb{N}_n} X_m\right|^p\right] \leqslant \left(\frac{p}{p-1}\right)^p \mathbb{E}\left[\left|X_n^+\right|^p\right].$$

***Demostración*:** Fijamos $M > 0$ y denotamos $X_n^M := \max_{m\in\mathbb{N}_n} X_m \wedge M$. Entonces,

$$\begin{aligned}
\mathbb{E}\left[\left|X_n^M\right|^p\right] &\overset{1.6.2}{=} \int_0^\infty pt^{p-1}\mathbb{P}\left(\left|X_n^M\right| > t\right)\mathrm{d}t \\
&= \int_0^M pt^{p-1}\mathbb{P}\left(\left|\max_{m\in\mathbb{N}_n} X_m\right| > t\right)\mathrm{d}t \\
&\overset{1.6.1}{\leqslant} \int_0^M pt^{p-2}\mathbb{E}\left[X_n^+ \mathbb{1}_{\{\max_{m\in\mathbb{N}_n} X_m > t\}}\right]\mathrm{d}t \\
&= \int_0^M pt^{p-2}\int_\Omega X_n^+ \mathbb{1}_{\{\max_{m\in\mathbb{N}_n} X_m > t\}}\,\mathrm{d}\mathbb{P}\,\mathrm{d}t \\
&\overset{\text{Fubini}}{=} \int_\Omega X_n^+ \int_0^{X_n^M} pt^{p-2}\,\mathrm{d}t\,\mathrm{d}\mathbb{P} \\
&= \int_\Omega X_n^+ \left[\frac{t^{p-1}}{p-1}\right]_0^{X_n^M}\mathrm{d}\mathbb{P} = \frac{p}{p-1}\int_\Omega X_n^+\left(X_n^M\right)^{p-1}\mathrm{d}\mathbb{P} \\
&\overset{\text{Hölder}}{\leqslant} \frac{p}{p-1}\left(\mathbb{E}\left[\left|X_n^+\right|^p\right]\right)^{1/p}\left(\mathbb{E}\left[\left|X_n^M\right|^p\right]\right)^{(p-1)/p}.
\end{aligned}$$

Por tanto, $\left(\mathbb{E}\left[\left|X_n^M\right|^p\right]\right)^{1/p} \leqslant \frac{p}{p-1}\left(\mathbb{E}\left[|X_n^+|^p\right]\right)^{1/p}$ y, al elevar ambos lados a la potencia p, obtenemos

$$\mathbb{E}\left[\left|X_n^M\right|^p\right] \leqslant \left(\frac{p}{p-1}\right)^p \mathbb{E}\left[\left|X_n^+\right|^p\right].$$

Al tomar el límite cuando $M \to \infty$, por convergencia monótona, obtenemos

$$\mathbb{E}\left[\left|\max_{m\in\mathbb{N}_n} X_m\right|^p\right] \leqslant \left(\frac{p}{p-1}\right)^p \mathbb{E}\left[\left|X_n^+\right|^p\right].$$

■

Teorema 1.6.4 (de convergencia de martingalas en $\mathcal{L}^p$). *Sea $p > 1$. Sea $(X_n)_{n\in\mathbb{N}}$ una martingala tal que $\sup_{n\in\mathbb{N}}\mathbb{E}\left[|X_n|^p\right] < \infty$. Entonces, existe una variable aleatoria $X_\infty \in \mathcal{L}^p(\mathbb{P})$ tal que $(X_n)_{n\in\mathbb{N}}$ converge a X_∞ en $\mathcal{L}^p$ y casi seguramente.*

***Demostración*:** Por la desigualdad de Jensen, tenemos que

$$\left(\mathbb{E}\left[X_n^+\right]\right)^p \leqslant \mathbb{E}\left[\left|X_n^+\right|^p\right] \leqslant \mathbb{E}\left[|X_n|^p\right].$$

Por tanto, $\sup_{n\in\mathbb{N}}\mathbb{E}\left[X_n^+\right] < \infty$ y por el teorema de convergencia de martingalas, existe una variable aleatoria X_∞ tal que $(X_n)_{n\in\mathbb{N}}$ converge a X_∞ casi seguramente.

Ahora bien, por la desigualdad maximal de Doob, tenemos que

$$\mathbb{E}\left[\left|\max_{m\in\mathbb{N}_n} X_m\right|^p\right] \leqslant \left(\frac{p}{p-1}\right)^p \mathbb{E}\left[\left|X_n^+\right|^p\right] \leqslant \left(\frac{p}{p-1}\right)^p \sup_{n\in\mathbb{N}}\mathbb{E}\left[|X_n|^p\right] < \infty$$

de manera uniforme en n (es decir, $\exists C > 0 : \forall n \in \mathbb{N} : \mathbb{E}\left[|\text{máx}_{m\in\mathbb{N}_n} X_m|^p\right] < C$).

Entonces, por el teorema de convergencia monótona, $\mathbb{E}\left[\sup_{n\in\mathbb{N}} |X_n|^p\right] < \infty$ y por el teorema de convergencia dominada, como $|X_n - X_\infty|^p \leqslant 2^p \sup_{n\in\mathbb{N}} |X_n|^p$, obtenemos que

$$\lim_{n\to\infty} \mathbb{E}\left[|X_n - X_\infty|^p\right] = 0,$$

es decir, $(X_n)_{n\in\mathbb{N}}$ converge a X_∞ en $\mathcal{L}^p$.Ñ ■

Observación 1.6.5. Para $p = 1$, tanto la desigualdad maximal de Doob como el teorema de convergencia de martingalas en $\mathcal{L}^p$ no se cumplen, como muestran los siguientes ejemplos:

Ejemplo 1.6.6 (de que no se cumple la convergencia en $\mathcal{L}^1$).
Sea $S_0 = 1, \forall n \in \mathbb{N} : S_{n+1} = S_n + \xi_{n+1}$ donde $(\xi_n)_{n\in\mathbb{N}}$ son variables aleatorias independientes con distribución de Bernoulli con parámetro $1/2$. Definimos $T = \text{ínf}\{n \in \mathbb{N} : S_n = 0\}$. Entonces, $X_{T\wedge n}$ es una martingala no negativa. Entonces, por el teorema de convergencia de martingalas, $X_{T\wedge n}$ converge casi seguramente a 0. Sin embargo, $\mathbb{E}\left[X_{T\wedge n}\right] = 1$ para todo $n \in \mathbb{N}$, luego $X_{T\wedge n}$ no converge a 0 en $\mathcal{L}^1$.

Ejercicio 1.6.7. Demuestra que la desigualdad maximal de Doob no se cumple para $p = 1$.
Sugerencia: El ejemplo anterior sirve para demostrarlo.

***Solución*:** De momento todavía nos faltan herramientas para demostrarlo, pero se puede hacer si asumimos que

$$\mathbb{P}\left(\max_{m\in\mathbb{N}} X_m \geqslant M\right) = \frac{1}{M}.$$

$$\mathbb{E}\left[\max_{m\in\mathbb{N}} X_m\right] = \sum_{M=1}^{\infty} \mathbb{P}\left(\max_{m\in\mathbb{N}} X_m \geqslant M\right) = \sum_{M=1}^{\infty} \frac{1}{M} = \infty.$$

Sin embargo, $\mathbb{E}\left[X_n\right] = 1$ para todo $n \in \mathbb{N}$, luego la desigualdad maximal de Doob no se puede cumplir para $p = 1$ porque $\mathbb{E}\left[\text{máx}_{m\in\mathbb{N}_n} X_m\right] \xrightarrow[n\to\infty]{} \infty$.

En la siguiente sección, vamos a ver bajo qué condiciones se puede garantizar la convergencia en $\mathcal{L}^1$ y la desigualdad maximal de Doob para $p = 1$.

1.7. Integrabilidad uniforme. Convergencia en $\mathcal{L}^1$

Definición 1.7.1 (Proceso uniformemente integrable). Un proceso estocástico $(X_t)_{t\in T}$ es uniformemente integrable

$$\iff \lim_{M\to\infty} \sup_{t\in T} \int_{\{|X_t|\geqslant M\}} |X_t| \, \mathrm{d}\mathbb{P} = 0.$$

Teorema 1.7.2. *Sea $(X_n)_{n\in\mathbb{N}}$ un proceso estocástico tal que $X_n \xrightarrow[n\to\infty]{c.s.} X$. Entonces, las siguientes condiciones son equivalentes:*

(1) $(X_n)_{n\in\mathbb{N}}$ *es uniformemente integrable.*
(2) $X_n \xrightarrow[n\to\infty]{\mathcal{L}^1} X$.
(3) $\mathbb{E}\left[|X_n|\right] \xrightarrow[n\to\infty]{} \mathbb{E}\left[|X|\right] < \infty$.

2. Cadenas de Markov

2.1. Primeros ejemplos

2.1.1. Paseos aleatorios

Sean $\{\xi_k\}_{k\in\mathbb{N}}$ variables aleatorias independientes, dado $x_0 \in \mathbb{R}^d$, definimos

$$\forall n \in \mathbb{N} : X_n = x_0 + \sum_{k=1}^{n} \xi_k.$$

Según los valores que tomen las variables ξ_k y la distribución con la que se eligen, obtenemos distintos tipos de paseos aleatorios.

- **Simple:** ξ_k toman valores en $\{\pm e_j\}_{j=1}^d$. Si $\forall j \in \mathbb{N}_d : \mathbb{P}(\xi_k = e_j) = 1/(2d)$, entonces el paseo aleatorio es *simple* y *simétrico*. En caso contrario, decimos que es *simple* y *asimétrico*.
- **En grafos:** Si $G = (V, E)$ es un grafo, podemos definir un paseo aleatorio en G como una sucesión de vértices $\{X_n\}_{n\in\mathbb{N}}$ tales que $\forall n \in \mathbb{N} : X_{n+1} \in N(X_n)$, donde $N(v)$ es el conjunto de vecinos del vértice v.
- **Caminos gaussianos:** Suponemos que todas las ξ_k tienen una distribución normal $\mathcal{N}(0, 1)$ y definimos

  $$\forall n \in \mathbb{N} : X_{n+1} = \alpha + \beta X_n + \gamma \xi_{n+1},$$

  donde $\alpha, \beta, \gamma \in \mathbb{R}$ son constantes. Entonces, $(X_n)_{n\in\mathbb{N}}$ es un paseo aleatorio gaussiano.

2.1.2. Modelos de difusión discretos

En estos modelos de difusión, por ejemplo, el **modelo de Ehrenfest**, se considera un sistema de partículas que se mueven entre dos compartimentos. En cada paso de tiempo, una partícula es seleccionada al azar y se mueve de un compartimento al otro. Denotando N_A y N_B como el número de partículas en los compartimentos A y B respectivamente, tenemos que

$$\mathbb{P}(N_A(t+1) = i \mid N_A(t) = j) = \begin{cases} \frac{j}{N} & \text{si } i = j - 1, \\ 1 - \frac{j}{N} & \text{si } i = j + 1, \\ 0 & \text{en otro caso.} \end{cases}$$

En el **modelo de Bernoulli-Laplace**, se consideran dos tipos de partículas y, en cada paso

de tiempo, se selecciona una partícula de cada urna al azar y se intercambian.

En el **modelo de Polya**, se tiene una urna con bolas de diferentes colores. En cada paso de tiempo, se selecciona una bola al azar, se observa su color y luego se devuelve a la urna junto con un número adicional de bolas del mismo color. Esto genera un proceso de refuerzo positivo, donde los colores más frecuentes tienden a volverse aún más comunes con el tiempo.

Modelos de colas: En este modelo, se estudia el comportamiento de un sistema de colas, como una línea de espera en un supermercado.

- **Modelo M/G/1:** Denotamos al número de clientes en la cola en el n-ésimo servicio como X_n y a_k como la probalidad de que k clientes lleguen durante el tiempo de servicio. Los a_k siguen una distribución de Poisson con parámetro λ.

Procesos de ramificación: En estos procesos, cada individuo puede dar lugar a varios descendientes en la siguiente generación. Un ejemplo clásico es el **proceso de Galton-Watson**, donde cada individuo tiene un número aleatorio de descendientes según una distribución de probabilidad fija.

La propiedad clave que todos estos modelos comparten es que el estado futuro del sistema depende únicamente del estado actual y no de cómo se llegó a ese estado, lo que caracteriza a los procesos de Markov.

2.2. Núcleos de transción y cadenas de Markov

Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad y $(M, \mathcal{S})$ un espacio medible.

Definición 2.2.1 (Núcleo de transición). Sea $(M, \mathcal{S})$ un espacio medible, una función $P\colon M \times \mathcal{S} \to [0,1]$ es un núcleo de transición $\iff$

(I) $\forall x \in M : P(x, \cdot)\colon \mathcal{S} \to [0,1]$ es una medida de probabilidad en $(M, \mathcal{S})$.

(II) $\forall G \in \mathcal{S} : P(\cdot, G)\colon M \to [0,1]$ es medible.

Observación 2.2.2. Dado un núcleo de transición P en el espacio medible $(M, \mathcal{S})$, P actúa sobre funciones medibles $f\colon M \to \mathbb{R}$ mediante la fórmula

$$\forall x \in M : Pf(x) := \int_M f(y)\, P(x, \mathrm{d}y).$$

Además, si f está acotada, entonces Pf también lo está.

Si μ es una medida de probabilidad en $(M, \mathcal{S})$, entonces P actúa sobre μ mediante la fórmula

$$\forall G \in \mathcal{S} : \mu P(G) = \int_M P(y, G)\, \mu(\mathrm{d}y).$$

Ejemplo 2.2.3 (de núcleo de transición). Sea $(M, \mathcal{S})$ un espacio medible con M numerable y $\mathcal{S} = \mathcal{P}(M)$. Consideramos $p\colon M \times M \to [0,1]$ tal que $\forall x \in M : \sum_{y\in M} p(x,y) = 1$. Definimos $P\colon M \times \mathcal{S} \to [0,1]$ mediante

$$\forall x \in M, A \in \mathcal{S} : P(x,A) = \sum_{y\in A} p(x,y).$$

Entonces, para una función medible $f\colon M \to \mathbb{R}$, tenemos que

$$\forall x \in M : Pf(x) = \sum_{y\in M} f(y)\, p(x,y).$$

Para una medida μ en $(M, \mathcal{S})$, tenemos que

$$\forall y \in M : \mu P(\{y\}) = \sum_{x\in M} p(x,y)\, \mu(\{x\}).$$

Si M es finito, entonces p puede representarse mediante una matriz estocástica, f mediante un vector columna, μ mediante un vector fila, Pf mediante el producto de la matriz p por el vector f y μP mediante el producto del vector μ por la matriz p.

Definición 2.2.4. Sea $\{P_n\}_{n\in\mathbb{N}}$ una familia de núcleos de transición en $(M, \mathcal{S})$ y $(X_n)_{n\in\mathbb{N}}$ un proceso estocástico adaptado a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$. Decimos que $(X_n)_{n\in\mathbb{N}}$ es una *cadena de Markov* con núcleos de transición $\{P_n\}_{n\in\mathbb{N}}$

$$\iff \forall n \in \mathbb{N}, G \in \mathcal{S} : \mathbb{P}\left(X_{n+1} \in G \mid \mathcal{F}_n\right) = P_{n+1}(X_n, G).$$

Lema 2.2.5. *Sea $(X_n)_{n\in\mathbb{N}}$ un proceso estocástico adaptado a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$ y $\{P_n\}_{n\in\mathbb{N}}$ una familia de núcleos de transición en $(M, \mathcal{S})$. Entonces, $(X_n)_{n\in\mathbb{N}}$ es una cadena de Markov con núcleos de transición $\{P_n\}_{n\in\mathbb{N}}$ $\iff$*

$$\forall f\colon M \to \mathbb{R} \text{ medible y acotada} : \mathbb{E}\left[f(X_{n+1}) \mid \mathcal{F}_n\right] = Pf(X_n).$$

Observación 2.2.6. Sea μ_n la medida de probabilidad en $(M, \mathcal{S})$ definida por $\mu_n(G) = \mathbb{P}\left(X_n \in G\right)$. Entonces, para $G \in \mathcal{S}$, tenemos que

$$\begin{aligned}\mu_{n+1}(G) &= \mathbb{P}\left(X_{n+1} \in G\right) = \mathbb{E}\left[\mathbb{E}\left[\mathbb{1}_{X_{n+1}\in G} \mid \mathcal{F}_n\right]\right] \\ &= \mathbb{E}\left[P_{n+1}\mathbb{1}_G(X_n)\right] = \int_M P_{n+1}(x,G)\, \mu_n(\mathrm{d}x) = \mu_n P_{n+1}(G).\end{aligned}$$

Por tanto, $\mu_{n+1} = \mu_n P_{n+1}$.

Lema 2.2.7. *Sea $(X_n)_{n\in\mathbb{N}}$ una cadena de Markov con núcleos de transición $\{P_n\}_{n\in\mathbb{N}}$. Entonces,*

(1) $\forall f\colon M \to \mathbb{R}$ *medible y acotada*: $\forall n \in \mathbb{N} : \mathbb{E}\left[f(X_{n+1}) \mid \mathcal{F}_n\right] = \mathbb{E}\left[f(X_{n+1}) \mid X_n\right]$.

(2) $\forall G \in \mathcal{S} : \forall n \in \mathbb{N} : \mathbb{P}(X_{n+1} \in G \mid \mathcal{F}_n) = \mathbb{P}(X_{n+1} \in G \mid X_n)$.

(3) *Sean* $\{A_i\}_{i=0}^{n+1} \subset \mathcal{S}$ *tales que* $\mathbb{P}(X_0 \in A_0 \wedge \ldots \wedge X_n \in A_n) > 0$. *Entonces,*

$$\mathbb{P}(X_{n+1} \in A_{n+1} \mid X_0 \in A_0 \wedge \ldots \wedge X_n \in A_n) = \mathbb{P}(X_{n+1} \in A_{n+1} \mid X_n \in A_n).$$

***Demostración*:**

(1) Sea $f\colon M \to \mathbb{R}$ medible y acotada. Fijamos $n \in \mathbb{N}$. Entonces, $P_{n+1}f$ es $\mathcal{S}$-medible y X_n es $\sigma(X_n)$-medible, por lo que $P_{n+1}f(X_n)$ es $\sigma(X_n)$-medible. Por lo tanto,

$$\begin{aligned}\mathbb{E}[f(X_{n+1}) \mid \mathcal{F}_n] &= P_{n+1}f(X_n) = \mathbb{E}[P_{n+1}f(X_n) \mid X_n] \\ &= \mathbb{E}[\mathbb{E}[f(X_{n+1}) \mid \mathcal{F}_n] \mid X_n] = \mathbb{E}[f(X_{n+1}) \mid X_n].\end{aligned}$$

■

Definición 2.2.8. Sea $(X_n)_{n\in\mathbb{N}}$ una cadena de Markov con núcleos de transición $\{P_n\}_{n\in\mathbb{N}}$. Decimos que $(X_n)_{n\in\mathbb{N}}$ es temporalmente homogénea con núcleo $P \iff \forall n \in \mathbb{N} : P_n = P$.

Teorema 2.2.9 (Ecuación de Chapman-Kolmogorov). *Sea* $(X_n)_{n\in\mathbb{N}}$ *una cadena de Markov temporalmente homogénea con núcleo* P *y sea* X_0 *una variable aleatoria con medida inducida* μ_0. *Entonces,*

$$\forall n \in \mathbb{N}, f\colon M \to \mathbb{R} \text{ medible y acotada} : \mathbb{E}[f(X_n) \mid X_0] = P^n f(X_0) \wedge \mu_n = \mu_0 P^n,$$

donde $P^1 = P$ *y* $P^n(x, A) = P^{n-1}P(x, A) = \int_M P(y, A)\, P^{n-1}(x, \mathrm{d}y)$ *para* $n \geqslant 2$.

***Demostración*:** Veámoslo por inducción sobre n. Para $n = 1$, la afirmación es trivial.

$$\begin{aligned}\mathbb{E}[\mathbb{1}_A(X_{n+1}) \mid X_0] &= \mathbb{E}[\mathbb{E}[\mathbb{1}_A(X_{n+1}) \mid \mathcal{F}_k] \mid X_0] = \mathbb{E}[\mathbb{E}[\mathbb{1}_A(X_{n+1}) \mid X_k] \mid X_0] \\ &= \mathbb{E}[P(X_k, A) \mid X_0] = P^k P(X_0, A) = P^{k+1}(X_0, A).\end{aligned}$$

■

Definición 2.2.10. μ es invariante para $P \iff \mu P = \mu$.

Observación 2.2.11. Si $X_0 \sim \mu$ y μ es invariante para P, entonces $\forall n \in \mathbb{N} : X_n \sim \mu$.

Lema 2.2.12. *Sea* $(M, \mathcal{S})$ *un espacio medible con* M *finito y* P *un núcleo de transición en* $(M, \mathcal{S})$. *Entonces, existe una medida de probabilidad* μ *en* $(M, \mathcal{S})$ *invariante para* P.

***Demostración*:** Consideramos el conjunto

$$\mathcal{M} = \left\{ \mu \in \mathbb{R}^M : \forall x \in M : \mu(\{x\}) \geqslant 0 \wedge \sum_{x\in M} \mu(\{x\}) = 1 \right\},$$

que es un simplex. Definimos $T\colon \mathcal{M} \to \mathcal{M}$ mediante $T(\mu) = \mu P$. Entonces, T es continua y $\mathcal{M}$ es compacta y convexa, por lo que, por el teorema de Brouwer, existe $\mu \in \mathcal{M}$ tal que $T(\mu) = \mu$, es decir, $\mu P = \mu$. ■

Ejercicio 2.2.13. Demuestra que si M es infinito, puede no existir una medida de probabilidad invariante para P.

2.3. La cadena canónica

Proposición 2.3.1. *Sea $(X_n)_{n\in\mathbb{N}}$ una cadena de Markov con núcleos de transición $\{P_n\}_{n\in\mathbb{N}}$ y dsitribución inicial ν. Entonces, $\forall \{A_i\}_{i=0}^k \subset \mathcal{S} : \mathbb{P}\left(X_0 \in A_0 \wedge \ldots \wedge X_k \in A_k\right) =$*

$$= \int_{A_0} P_1(x_0, A_1) \int_{A_1} P_2(x_1, A_2) \ldots \int_{A_{k-1}} P_k(x_{k-1}, A_k)\, \nu(\mathrm{d}x_0) \ldots (\mathrm{d}x_{k-1}).$$

***Demostración*:** Sean $\{h_i\}_{i=0}^k$ funciones medibles y acotadas de M a $\mathbb{R}$. Entonces, por la ley de la esperanza total, tenemos que

$$\mathbb{E}\left[h_0(X_0) \ldots h_k(X_k)\right] = \mathbb{E}\left[\mathbb{E}\left[h_0(X_0) \ldots h_{k-1}(X_{k-1}) h_k(X_k) \mid \mathcal{F}_{k-1}\right]\right].$$

Como $h_0(X_0) \ldots h_{k-1}(X_{k-1})$ es $\mathcal{F}_{k-1}$-medible, tenemos que

$$\begin{aligned}\mathbb{E}\Big[h_0(X_0) \ldots h_k(X_k)\Big] &= \mathbb{E}\Big[h_0(X_0) \ldots h_{k-1}(X_{k-1})\, \mathbb{E}\Big[h_k(X_k) \mid \mathcal{F}_{k-1}\Big]\Big] \\ &= \mathbb{E}\Big[h_0(X_0) \ldots \left(h_{k-1}(X_{k-1}) P_k h_k(X_{k-1})\right)(X_{k-1})\Big].\end{aligned}$$

Reiterando este argumento y usando que ν es la distribución de X_0, obtenemos que

$$\mathbb{E}\left[h_0(X_0) \ldots h_k(X_k)\right] = \nu\left[h_0 P_1\left[h_1 P_2\left[h_2 \ldots P_k h_k\right]\right]\right].$$

Tomando $h_i = \mathbb{1}_{A_i}$, obtenemos la afirmación. ■

Definición 2.3.2. Sea $(\Omega, \mathcal{F})$ un espacio medible equipado con una topología $\mathcal{T}$ tal que $\forall K \Subset \Omega : K \in \mathcal{F}$. Una medida de probabilidad $\mathbb{P}$ en $(\Omega, \mathcal{F})$ es internamente regular

$$\forall A \in \mathcal{F} : \mathbb{P}(A) = \sup\{\mathbb{P}(K) : K \Subset A\},$$

o, equivalentemente, $\forall A \in \mathcal{F}, \varepsilon > 0 : \exists K \Subset A : \mathbb{P}(A \setminus K) < \varepsilon$.

Teorema 2.3.3 (Teorema de extensión de Kolmogorov). *Sea $\{(\Omega_t, \mathcal{F}_t)\}_{t\in T}$ una familia de espacios medibles donde $\forall t \in T : \Omega_t$ es un espacio topológico de Hausdorff y primero*

numerable. Para todo $J \subset T$ subconjunto finito de índices, consideramos

$$Q^J := \prod_{t\in J} \Omega_t \quad \wedge \quad \mathcal{F}^J := \bigotimes_{t\in J} \mathcal{F}_t.$$

Para $I \subset J \subset T$ subconjuntos finitos de índices, definimos la proyección

$$\begin{aligned} \pi_{J\to I} \colon Q^J &\longrightarrow Q^I \\ (\omega(t))_{t\in J} &\longmapsto (\omega(t))_{t\in I}\,. \end{aligned}$$

Supongamos que $\forall J \subset T$ subconjunto finito de índices : $\exists \mathbb{P}^J$ una medida de probabilidad internamente regular en $(Q^J, \mathcal{F}^J)$ con respecto a la topología producto $\mathcal{T}^J$ y que $\forall I \subset J$: $\mathbb{P}^I = (\pi_{J\to I})_* \mathbb{P}^J$. Entonces, existe una única medida de probabilidad en $(Q^T, \mathcal{F}^T)$ tal que $\forall J \subset T$ subconjunto finito de índices : $\mathbb{P}^J = (\pi_{T\to J})_* \mathbb{P}^T$.

***Demostración*:** Para aligerar la notación, denotaremos por $\pi_J := \pi_{T\to J} \colon Q^T \to Q^J$ la proyección canónica sobre el bloque de coordenadas $J \subset T$. Definimos la familia de cilindros medibles J-dimensionales como:

$$\mathcal{A} := \left\{ \pi_J^{-1}(X_J) : J \subset T \text{ finito } \wedge\, X_J \in \mathcal{F}^J \right\},$$

y definimos la función de conjunto $\mathbb{P} \colon \mathcal{A} \to [0,1]$ mediante la asignación:

$$\mathbb{P}\left(\pi_J^{-1}(X_J)\right) := \mathbb{P}^J(X_J).$$

El objetivo es demostrar que $\mathcal{A}$ es un álgebra de conjuntos, que $\mathbb{P}$ es una premedida (σ-aditiva) sobre $\mathcal{A}$, y finalmente aplicar el Teorema de Extensión de Carathéodory. Dividimos la demostración en varios pasos detallados.

Paso 1: Veamos que $\mathcal{A}$ es un álgebra de conjuntos sobre Q^T y que $\sigma(\mathcal{A}) = \mathcal{F}^T$.

Recordemos que para que $\mathcal{A} \subset \mathcal{P}(Q^T)$ sea un álgebra de conjuntos debe cumplir tres condiciones:

- $Q^T \in \mathcal{A}$.
- Si $A \in \mathcal{A}$, entonces $A^c = Q^T \setminus A \in \mathcal{A}$.
- Si $A, B \in \mathcal{A}$, entonces $A \cup B \in \mathcal{A}$.

Antes de comprobarlas, notemos una propiedad fundamental de la composición de proyecciones: si $I \subset J \subset T$ son finitos, por la definición de las proyecciones se verifica trivialmente la conmutatividad $\pi_I = \pi_{J\to I} \circ \pi_J$. Por lo tanto, para cualquier $X_I \in \mathcal{F}^I$, tomando la imagen inversa se cumple:

$$\pi_I^{-1}(X_I) = (\pi_{J\to I} \circ \pi_J)^{-1}(X_I) = \pi_J^{-1}\left(\pi_{J\to I}^{-1}(X_I)\right).$$

Puesto que $\pi_{J\to I}$ es continua y por tanto medible, la imagen inversa $\pi_{J\to I}^{-1}(X_I)$ pertenece a $\mathcal{F}^J$. Esto significa que cualquier cilindro con base en un subconjunto de índices I puede reescribirse equivalentemente como un cilindro con base en un subconjunto finito más grande $J \supset I$.

Comprobemos ahora las propiedades de álgebra:

(I) **Totalidad:** Tomando cualquier índice $t_0 \in T$ y el conjunto finito $J = \{t_0\}$, como $Q^{\{t_0\}} \in \mathcal{F}^{\{t_0\}}$, tenemos que $Q^T = \pi_{\{t_0\}}^{-1}(Q^{\{t_0\}}) \in \mathcal{A}$.

(II) **Complementario:** Sea $A \in \mathcal{A}$. Por definición, existen $J \subset T$ finito y $X_J \in \mathcal{F}^J$ tales que $A = \pi_J^{-1}(X_J)$. Utilizando las propiedades fundamentales de la imagen inversa respecto a la complementación de conjuntos:

$$A^c = Q^T \setminus \pi_J^{-1}(X_J) = \pi_J^{-1}(Q^J \setminus X_J).$$

Como $\mathcal{F}^J$ es una σ-álgebra en Q^J y $X_J \in \mathcal{F}^J$, el complementario $Q^J \setminus X_J$ también pertenece a $\mathcal{F}^J$. Así pues, $A^c = \pi_J^{-1}(Q^J \setminus X_J) \in \mathcal{A}$.

(III) **Unión finita:** Sean $A, B \in \mathcal{A}$. Existen subconjuntos finitos de índices $J, I \subset T$ y conjuntos medibles $X_J \in \mathcal{F}^J, Y_I \in \mathcal{F}^I$ tales que $A = \pi_J^{-1}(X_J)$ y $B = \pi_I^{-1}(Y_I)$.

Definimos el subconjunto finito común $K := J \cup I \subset T$. Aplicando la propiedad de conmutatividad antes explicada, expresamos A y B sobre la misma base de coordenadas K:

$$A = \pi_K^{-1}\left(\pi_{K\to J}^{-1}(X_J)\right) \quad \text{y} \quad B = \pi_K^{-1}\left(\pi_{K\to I}^{-1}(Y_I)\right).$$

Denotemos $\widetilde{X}_K := \pi_{K\to J}^{-1}(X_J) \in \mathcal{F}^K$ y $\widetilde{Y}_K := \pi_{K\to I}^{-1}(Y_I) \in \mathcal{F}^K$. Utilizando que la imagen inversa conmuta con la unión de conjuntos:

$$A \cup B = \pi_K^{-1}\left(\widetilde{X}_K\right) \cup \pi_K^{-1}\left(\widetilde{Y}_K\right) = \pi_K^{-1}\left(\widetilde{X}_K \cup \widetilde{Y}_K\right).$$

Como $\mathcal{F}^K$ es una σ-álgebra, la unión $\widetilde{X}_K \cup \widetilde{Y}_K$ pertenece a $\mathcal{F}^K$. Por lo tanto, $A \cup B \in \mathcal{A}$.

Concluimos que $\mathcal{A}$ es un álgebra de conjuntos sobre Q^T.

Demostremos ahora que $\sigma(\mathcal{A}) = \mathcal{F}^T$. Por definición, la σ-álgebra producto $\mathcal{F}^T = \bigotimes_{t\in T} \mathcal{F}_t$ es la menor σ-álgebra sobre Q^T que hace medibles a todas las proyecciones individuales $\pi_t \colon Q^T \to \Omega_t$. Esto equivale a decir que $\mathcal{F}^T = \sigma(\mathcal{C})$, donde $\mathcal{C}$ es la familia de cilindros elementales:

$$\mathcal{C} = \left\{ \pi_{j_1,\dots,j_n}^{-1}\left(\prod_{i=1}^{n} X_{j_i}\right) : n \in \mathbb{N},\, j_i \in T \wedge X_{j_i} \in \mathcal{F}_{j_i} \right\}.$$

Para cualquier elemento de $\mathcal{C}$, el producto $X_J = \prod_{i=1}^n X_{j_i}$ pertenece a la σ-álgebra producto

finita $\mathcal{F}^{\{j_1,\dots,j_n\}}$. Por consiguiente, todo cilindro elemental es un elemento de $\mathcal{A}$, es decir, $\mathcal{C} \subset \mathcal{A}$. Tomando la σ-álgebra generada en la inclusión $\mathcal{C} \subset \mathcal{A} \subset \mathcal{F}^T$, obtenemos:

$$\mathcal{F}^T = \sigma(\mathcal{C}) \subset \sigma(\mathcal{A}) \subset \sigma(\mathcal{F}^T) = \mathcal{F}^T,$$

lo que demuestra rigurosamente la igualdad $\sigma(\mathcal{A}) = \mathcal{F}^T$.

Paso 2: Veamos que $\mathbb{P}$ está bien definida en $\mathcal{A}$.

Un mismo conjunto $A \in \mathcal{A}$ puede admitir múltiples representaciones como cilindro (por ejemplo, añadiendo coordenadas superfluas que no restringen el conjunto). Necesitamos demostrar que el valor $\mathbb{P}(A)$ no depende de la representación elegida.

Supongamos que un conjunto $A \in \mathcal{A}$ tiene dos representaciones:

$$A = \pi_J^{-1}(X_J) = \pi_I^{-1}(Y_I),$$

para subconjuntos finitos de índices $J, I \subset T$ y conjuntos medibles $X_J \in \mathcal{F}^J$, $Y_I \in \mathcal{F}^I$.

Consideramos el subconjunto finito $K = J \cup I \subset T$. Expresando ambas representaciones sobre K:

$$A = \pi_K^{-1}\left(\pi_{K\to J}^{-1}(X_J)\right) = \pi_K^{-1}\left(\pi_{K\to I}^{-1}(Y_I)\right).$$

Puesto que la aplicación proyección $\pi_K \colon Q^T \to Q^K$ es sobreyectiva (ya que cada $\Omega_t \neq \varnothing$), la imagen inversa es inyectiva sobre los subconjuntos del codominio. Es decir, si $\pi_K^{-1}(U) = \pi_K^{-1}(V)$, entonces aplicando la imagen directa por π_K:

$$U = \pi_K(\pi_K^{-1}(U)) = \pi_K(\pi_K^{-1}(V)) = V.$$

Por lo tanto, deducimos la igualdad exacta de conjuntos en Q^K:

$$\pi_{K\to J}^{-1}(X_J) = \pi_{K\to I}^{-1}(Y_I).$$

Ahora aplicamos la medida $\mathbb{P}^K$ a ambos lados de esta igualdad. Por la hipótesis de consistencia del teorema, sabemos que para cualesquiera índices finitos $I \subset K$ se cumple $\mathbb{P}^I = (\pi_{K\to I})_* \mathbb{P}^K$, lo que significa por definición de medida push-forward que para todo $Y_I \in \mathcal{F}^I$:

$$\mathbb{P}^I(Y_I) = \mathbb{P}^K\left(\pi_{K\to I}^{-1}(Y_I)\right).$$

Usando esta hipótesis para $J \subset K$ y $I \subset K$, obtenemos:

$$\mathbb{P}^J(X_J) = \mathbb{P}^K\left(\pi_{K\to J}^{-1}(X_J)\right) = \mathbb{P}^K\left(\pi_{K\to I}^{-1}(Y_I)\right) = \mathbb{P}^I(Y_I).$$

Esto demuestra que el valor asignado por $\mathbb{P}(A)$ es único e independiente de la representación de A.

Paso 3: Veamos que $\mathbb{P}$ es finitamente aditiva en $\mathcal{A}$.

Sean $A, B \in \mathcal{A}$ dos conjuntos disjuntos ($A \cap B = \varnothing$). Por la construcción expuesta en el Paso 1, podemos encontrar un conjunto finito de índices común $K = J \cup I \subset T$ tal que $A = \pi_K^{-1}(\widetilde{X}_K)$ y $B = \pi_K^{-1}(\widetilde{Y}_K)$ con $\widetilde{X}_K, \widetilde{Y}_K \in \mathcal{F}^K$.

La condición de disyunción $A \cap B = \varnothing$ se traduce en:

$$\varnothing = A \cap B = \pi_K^{-1}(\widetilde{X}_K) \cap \pi_K^{-1}(\widetilde{Y}_K) = \pi_K^{-1}\left(\widetilde{X}_K \cap \widetilde{Y}_K\right).$$

Nuevamente, dada la sobreyectividad de π_K, la única forma de que la imagen inversa de un conjunto sea vacía es que el propio conjunto sea vacío. Por lo tanto, se verifica que $\widetilde{X}_K \cap \widetilde{Y}_K = \varnothing$ en Q^K.

Utilizando que $\mathbb{P}^K$ es una medida de probabilidad en $(Q^K, \mathcal{F}^K)$ y, por tanto, finitamente aditiva:

$$\begin{aligned}
\mathbb{P}(A \cup B) &= \mathbb{P}\left(\pi_K^{-1}\left(\widetilde{X}_K \cup \widetilde{Y}_K\right)\right) \\
&= \mathbb{P}^K\left(\widetilde{X}_K \cup \widetilde{Y}_K\right) \\
&= \mathbb{P}^K\left(\widetilde{X}_K\right) + \mathbb{P}^K\left(\widetilde{Y}_K\right) \quad \text{(por aditividad finita de } \mathbb{P}^K\text{)} \\
&= \mathbb{P}(A) + \mathbb{P}(B).
\end{aligned}$$

Por el principio de inducción, si $\{A_1, \ldots, A_m\} \subset \mathcal{A}$ es una colección finita de conjuntos disjuntos dos a dos, entonces $\mathbb{P}\left(\bigsqcup_{i=1}^m A_i\right) = \sum_{i=1}^m \mathbb{P}(A_i)$.

Paso 4: Veamos que $\mathbb{P}$ es σ-aditiva en $\mathcal{A}$ (es decir, una premedida).

- **Reducción a la continuidad en el vacío:** Queremos probar que para cualquier familia disjunta numerable $\{A^{(k)}\}_{k=1}^{\infty} \subset \mathcal{A}$ tal que su unión disjunta $A := \bigsqcup_{k=1}^{\infty} A^{(k)}$ pertenezca a $\mathcal{A}$, se cumple que $\mathbb{P}(A) = \sum_{k=1}^{\infty} \mathbb{P}(A^{(k)})$.

  Dado que el álgebra $\mathcal{A}$ es cerrada bajo uniones finitas, para cada $N \in \mathbb{N}$ la suma finita $\bigsqcup_{k=1}^{N} A^{(k)}$ pertenece a $\mathcal{A}$. Definimos el resto N-ésimo:

  $$B^{(N)} := A \setminus \left(\bigsqcup_{k=1}^{N} A^{(k)}\right) = \bigsqcup_{k=N+1}^{\infty} A^{(k)}.$$

  Puesto que $A \in \mathcal{A}$ y $\bigsqcup_{k=1}^{N} A^{(k)} \in \mathcal{A}$, por la propiedad de álgebra sabemos que el resto $B^{(N)} \in \mathcal{A}$ para todo $N \in \mathbb{N}$.

  Además, la sucesión $\{B^{(N)}\}_{N=1}^{\infty}$ cumple las siguientes dos propiedades:

  - Es decreciente: $B^{(N+1)} \subset B^{(N)}$ para todo $N \in \mathbb{N}$.

- Su intersección es vacía: $\bigcap_{N=1}^{\infty} B^{(N)} = \bigcap_{N=1}^{\infty} \left(\bigsqcup_{k=N+1}^{\infty} A^{(k)} \right) = \varnothing$. Decimos entonces que $B^{(N)} \downarrow \varnothing$.

Por la aditividad finita de $\mathbb{P}$ demostrada en el Paso 3, podemos escribir:

$$\mathbb{P}(A) = \mathbb{P}\left(\left(\bigsqcup_{k=1}^{N} A^{(k)} \right) \sqcup B^{(N)} \right) = \sum_{k=1}^{N} \mathbb{P}(A^{(k)}) + \mathbb{P}(B^{(N)}).$$

Tomando el límite cuando $N \to \infty$ en ambos lados:

$$\mathbb{P}(A) = \sum_{k=1}^{\infty} \mathbb{P}(A^{(k)}) + \lim_{N \to \infty} \mathbb{P}(B^{(N)}).$$

Por lo tanto, para demostrar que $\mathbb{P}(A) = \sum_{k=1}^{\infty} \mathbb{P}(A^{(k)})$, basta con demostrar que para toda sucesión decreciente $\{B^{(N)}\}_{N=1}^{\infty} \subset \mathcal{A}$ tal que $B^{(N)} \downarrow \varnothing$, se cumple $\lim_{N\to\infty} \mathbb{P}(B^{(N)}) = 0$ (propiedad conocida como *continuidad en el vacío*).

- **Demostración de la continuidad en el vacío por contradicción:** Supongamos que $\mathbb{P}$ no es continua en el vacío. Entonces existe una sucesión $\{B^{(n)}\}_{n=1}^{\infty} \subset \mathcal{A}$ tal que:
  - $B^{(n+1)} \subset B^{(n)}$ para todo $n \in \mathbb{N}$.
  - $\bigcap_{n=1}^{\infty} B^{(n)} = \varnothing$.
  - $\exists \varepsilon > 0$ tal que $\forall n \in \mathbb{N} : \mathbb{P}(B^{(n)}) \geq \varepsilon$.

  Por definición de $\mathcal{A}$, cada conjunto $B^{(n)}$ es un cilindro apoyado en un subconjunto finito de índices que denotaremos por $J'_n \subset T$.

  Para trabajar con una secuencia de índices coordinada y creciente, definimos $J_n := \bigcup_{i=1}^{n} J'_i$. De este modo obtenemos una cadena estrictamente creciente de subconjuntos finitos de índices:

  $$J_1 \subset J_2 \subset J_3 \subset \cdots \subset T.$$

  Dado que $J'_n \subset J_n$, reexpresamos cada $B^{(n)}$ sobre la base de índices J_n:

  $$B^{(n)} = \pi_{J_n}^{-1}(X_n), \quad \text{donde } X_n \in \mathcal{F}^{J_n}.$$

  Notemos que $\mathbb{P}^{J_n}(X_n) = \mathbb{P}(B^{(n)}) \geq \varepsilon > 0$ para todo $n \in \mathbb{N}$.

- **Uso de la regularidad interna de las medidas $\mathbb{P}^{J_n}$:** Por hipótesis del teorema, la medida de probabilidad $\mathbb{P}^{J_n}$ definida en el espacio medible $(Q^{J_n}, \mathcal{F}^{J_n})$ es internamente regular con respecto a la topología producto $\mathcal{T}^{J_n}$. Esto significa que para cualquier conjunto medible $X_n \in \mathcal{F}^{J_n}$ y cualquier $\delta > 0$, existe un conjunto compacto $K_n \subset X_n$ (en la topología producto de Q^{J_n}) tal que $\mathbb{P}^{J_n}(X_n \setminus K_n) < \delta$.

Elegimos para cada $n \in \mathbb{N}$ un número $\delta_n = \frac{\varepsilon}{2^{n+1}}$. Por regularidad interna, existe un compacto $K_n \subset X_n$ en Q^{J_n} tal que:

$$\mathbb{P}^{J_n}(X_n \setminus K_n) \leq \frac{\varepsilon}{2^{n+1}}.$$

Consideremos el cilindro asociado al compacto K_n:

$$C^{(n)} := \pi_{J_n}^{-1}(K_n) \in \mathcal{A}.$$

Como $K_n \subset X_n$, es evidente que $C^{(n)} \subset B^{(n)}$. Además, calculamos la medida de la diferencia:

$$\mathbb{P}(B^{(n)} \setminus C^{(n)}) = \mathbb{P}\left(\pi_{J_n}^{-1}(X_n \setminus K_n)\right) = \mathbb{P}^{J_n}(X_n \setminus K_n) \leq \frac{\varepsilon}{2^{n+1}}.$$

- **Construcción de una sucesión decreciente de cilindros compactos:** Los conjuntos $C^{(n)}$ no son necesariamente decrecientes por sí solos. Para solventar esto, definimos la intersección acumulada de los primeros n cilindros compactos:

$$D^{(n)} := \bigcap_{i=1}^{n} C^{(i)} \in \mathcal{A}.$$

Por construcción, $\{D^{(n)}\}_{n=1}^{\infty}$ es una sucesión decreciente por inclusión: $D^{(1)} \supset D^{(2)} \supset \dots$.

Además, como $C^{(i)} \subset B^{(i)}$ y los $B^{(i)}$ son decrecientes ($B^{(n)} \subset B^{(i)}$ para $i \leq n$), tenemos que:

$$D^{(n)} \subset \bigcap_{i=1}^{n} B^{(i)} = B^{(n)}.$$

Estimemos la medida de la diferencia $B^{(n)} \setminus D^{(n)}$ usando las leyes de De Morgan y la subaditividad finita de $\mathbb{P}$:

$$B^{(n)} \setminus D^{(n)} = B^{(n)} \setminus \left(\bigcap_{i=1}^{n} C^{(i)}\right) = \bigcup_{i=1}^{n} \left(B^{(n)} \setminus C^{(i)}\right) \subset \bigcup_{i=1}^{n} \left(B^{(i)} \setminus C^{(i)}\right).$$

Por tanto:

$$\mathbb{P}(B^{(n)} \setminus D^{(n)}) \leq \sum_{i=1}^{n} \mathbb{P}(B^{(i)} \setminus C^{(i)}) \leq \sum_{i=1}^{n} \frac{\varepsilon}{2^{i+1}} = \frac{\varepsilon}{2} \sum_{i=1}^{n} \frac{1}{2^i} < \frac{\varepsilon}{2}.$$

Así pues, obtenemos una cota inferior estricta para la medida de $D^{(n)}$:

$$\mathbb{P}(D^{(n)}) = \mathbb{P}(B^{(n)}) - \mathbb{P}(B^{(n)} \setminus D^{(n)}) > \varepsilon - \frac{\varepsilon}{2} = \frac{\varepsilon}{2} > 0.$$

En particular, como $\mathbb{P}(D^{(n)}) > 0$, cada conjunto $D^{(n)}$ es no vacío ($D^{(n)} \neq \varnothing$).

- **Análisis topológico en las bases compactas Q^{J_n}:** Para cada $n \in \mathbb{N}$, el conjunto

$D^{(n)}$ se puede escribir en la base J_n como $D^{(n)} = \pi_{J_n}^{-1}(F_n)$, donde:

$$F_n = \bigcap_{i=1}^{n} \pi_{J_n \to J_i}^{-1}(K_i) \subset Q^{J_n}.$$

Analicemos la naturaleza topológica del conjunto $F_n \subset Q^{J_n}$:

- Para cada $i \leq n$, la proyección $\pi_{J_n \to J_i}$ es una función continua entre espacios topológicos. Dado que K_i es compacto en un espacio de Hausdorff Q^{J_i}, K_i es cerrado. La preimagen de un cerrado por una función continua es cerrada, por lo que $\pi_{J_n \to J_i}^{-1}(K_i)$ es un cerrado en Q^{J_n}.
- F_n es la intersección finita de cerrados contenidos en $\pi_{J_n \to J_n}^{-1}(K_n) = K_n$. Como K_n es compacto y $F_n \subset K_n$ es cerrado, F_n es un subconjunto compacto no vacío de Q^{J_n}.

- **Construcción del elemento límite:** Puesto que $D^{(n)} \neq \varnothing$ para todo $n \in \mathbb{N}$, para cada $n \in \mathbb{N}$ podemos elegir un elemento $\omega_n \in D^{(n)} \subset Q^T$.

  Fijemos un índice $m \in \mathbb{N}$. Para todo $n \geq m$, como $D^{(n)} \subset D^{(m)} = \pi_{J_m}^{-1}(F_m)$, la proyección de ω_n sobre las coordenadas de J_m verifica:

  $$\pi_{J_m}(\omega_n) \in F_m \subset K_m, \quad \forall n \geq m.$$

  Recordemos que $K_1 \subset Q^{J_1}$ es compacto. Como $Q^{J_1} = \prod_{t \in J_1} \Omega_t$ es un producto finito de espacios topológicos de Hausdorff y primero numerables, K_1 es metrizable (o secuencialmente compacto).

  Por lo tanto, de la secuencia $\{\pi_{J_1}(\omega_n)\}_{n=1}^{\infty} \subset K_1$ podemos extraer una subsucesión convergente en K_1. Denotemos los índices de esta subsucesión por $N_1 \subset \mathbb{N}$. Existe un límite $z_1 \in F_1 \subset K_1$ tal que:

  $$\lim_{n \in N_1, n \to \infty} \pi_{J_1}(\omega_n) = z_1.$$

  Consideremos ahora las proyecciones en J_2 para la subsucesión N_1: $\{\pi_{J_2}(\omega_n)\}_{n \in N_1}$. A partir del índice $n \geq 2$, estos elementos pertenecen al compacto $F_2 \subset K_2$. Extraemos una nueva subsucesión $N_2 \subset N_1$ tal que:

  $$\lim_{n \in N_2, n \to \infty} \pi_{J_2}(\omega_n) = z_2 \in F_2.$$

  Debido a la continuidad de las proyecciones entre bloques de índices ($\pi_{J_2 \to J_1}$), se cumple automáticamente la compatibilidad $\pi_{J_2 \to J_1}(z_2) = z_1$.

  Reiterando inductivamente este procedimiento, obtenemos una secuencia de subsuce-

siones anidadas $\mathbb{N} \supset N_1 \supset N_2 \supset N_3 \supset \dots$ tales que para cada $m \in \mathbb{N}$:

$$\lim_{n \in N_m, n \to \infty} \pi_{J_m}(\omega_n) = z_m \in F_m \subset Q^{J_m},$$

cumpliendo que si $m < k$, entonces $\pi_{J_k \to J_m}(z_k) = z_m$.

Tomamos la subsucesión diagonal $d_k \in N_k$ (el k-ésimo término de la k-ésima subsucesión). Por construcción de la diagonal, para todo bloque J_m fijo, la sucesión $\{\pi_{J_m}(\omega_{d_k})\}_{k=m}^{\infty}$ es una subsucesión de N_m y por tanto converge:

$$\lim_{k \to \infty} \pi_{J_m}(\omega_{d_k}) = z_m \in F_m.$$

Definimos ahora un elemento candidato $\omega^* \in Q^T$ mediante sus coordenadas puntualizadas:

- Para $t \in \bigcup_{m=1}^{\infty} J_m$: si $t \in J_m$, definimos $\omega^*(t) := z_m(t) \in \Omega_t$. (Esta definición está bien formulada y no depende de m por la compatibilidad $\pi_{J_k \to J_m}(z_k) = z_m$).
- Para $t \notin \bigcup_{m=1}^{\infty} J_m$: elegimos un elemento fijo arbitrario $x_t \in \Omega_t$ y definimos $\omega^*(t) := x_t$.

- **Obtención de la contradicción:** Para cualquier $m \in \mathbb{N}$ fijo, la proyección de ω^* sobre el bloque J_m es, por construcción, $\pi_{J_m}(\omega^*) = z_m$.

  Como demostramos anteriormente, $z_m \in F_m$. Por lo tanto:

  $$\omega^* \in \pi_{J_m}^{-1}(F_m) = D^{(m)} \subset B^{(m)}.$$

  Como esta inclusión es válida para todo $m \in \mathbb{N}$, concluimos que:

  $$\omega^* \in \bigcap_{m=1}^{\infty} B^{(m)}.$$

  ¡Pero esto implica que $\bigcap_{m=1}^{\infty} B^{(m)} \neq \varnothing$, lo cual es una contradicción directa con la hipótesis de partida $B^{(m)} \downarrow \varnothing$!

  Esta contradicción demuestra que nuestra suposición inicial era falsa. Por consiguiente, debe cumplirse $\lim_{n \to \infty} \mathbb{P}(B^{(n)}) = 0$, lo que prueba que $\mathbb{P}$ es continua en el vacío y, por ende, $\mathbb{P}$ es una premedida (σ-aditiva) sobre el álgebra $\mathcal{A}$.

Paso 5: Aplicación del Teorema de Extensión de Carathéodory y conclusión.

Resumamos las propiedades obtenidas hasta el momento:

1. $\mathcal{A}$ es un álgebra de subconjuntos de Q^T.

2. $\sigma(\mathcal{A}) = \mathcal{F}^T$ es la σ-álgebra producto total sobre Q^T.

3. $\mathbb{P}\colon \mathcal{A} \to [0,1]$ es una premedida con $\mathbb{P}(Q^T) = \mathbb{P}^J(Q^J) = 1$.

Por el Teorema de Extensión de Carathéodory, toda premedida sobre un álgebra de conjuntos admite una extensión a una medida definida sobre la σ-álgebra generada $\sigma(\mathcal{A}) = \mathcal{F}^T$. Puesto que la medida total es finita ($\mathbb{P}(Q^T) = 1 < \infty$), dicho teorema garantiza que la extensión es única.

Denotemos por $\mathbb{P}^T$ a esta única medida de probabilidad sobre $(Q^T, \mathcal{F}^T)$.

Finalmente, verifiquemos que $\mathbb{P}^T$ satisface la condición del enunciado. Para cualquier subconjunto finito $J \subset T$ y cualquier conjunto medible $X_J \in \mathcal{F}^J$, la definición del push-forward $(\pi_J)_*\mathbb{P}^T$ nos da:

$$\left((\pi_J)_*\mathbb{P}^T\right)(X_J) = \mathbb{P}^T\left(\pi_J^{-1}(X_J)\right).$$

Puesto que $\pi_J^{-1}(X_J) \in \mathcal{A}$ y $\mathbb{P}^T$ extiende a $\mathbb{P}$ sobre $\mathcal{A}$:

$$\mathbb{P}^T\left(\pi_J^{-1}(X_J)\right) = \mathbb{P}\left(\pi_J^{-1}(X_J)\right) = \mathbb{P}^J(X_J).$$

Por lo tanto, $(\pi_{T\to J})_*\mathbb{P}^T = \mathbb{P}^J$ para todo subconjunto finito $J \subset T$. ■

Definición 2.3.4 (Espacio polaco). Sea $(X, \mathcal{T})$ un espacio topológico, es polaco

$$\iff X \text{ es separable y completamente metrizable.}$$

Teorema 2.3.5. *Sea M un espacio polaco equipado con su σ-álgebra de Borel $\mathcal{B}(M)$. Sea $\Omega = M^{\mathbb{N}_0}$ y $\mathcal{F} = \mathcal{B}(M)^{\otimes\mathbb{N}_0}$ la σ-álgebra producto sobre Ω. Sea ν una medida de probabilidad sobre $(M, \mathcal{B}(M))$. Sea $(P_n)_{n\in\mathbb{N}_0}$ una familia de núcleos de Markov sobre $(M, \mathcal{B}(M))$. Entonces,*

$$\exists!\, \mathbb{P}_\nu \text{ medida de probabilidad sobre } (\Omega, \mathcal{F}) : \forall n \in \mathbb{N}_0,\ \forall A_0, \ldots, A_n \in \mathcal{B}(M) :$$

$$\mathbb{P}_\nu\left(\bigcap_{i=0}^{n}\{X_i \in A_i\}\right) = \int_{A_0}\nu(dx_0)\int_{A_1}P_1(x_0, dx_1)\cdots\int_{A_n}P_n(x_{n-1}, dx_n).$$

***Demostración*:** Se sigue del Teorema de extensión de Kolmogorov. ■

Definición 2.3.6 (π-sistema). Sea $P \subset \mathcal{P}(\Omega)$, es un π-sistema de $X \neq \varnothing \iff$

(I) $P \neq \varnothing$.

(II) Cerrado bajo intersección: $\forall A, B \in P : A \cap B \in P$.

Definición 2.3.7 (λ-sistema). Sea $L \subset \mathcal{P}(\Omega)$, es un λ-sistema $\iff$

(I) $\Omega \in L$.

(II) Cerrado bajo diferencia de conjuntos anidados: $A, B \in L \wedge A \subset B \implies B \setminus A \in L$.

(III) $\forall \{A_j\}_{j=1}^{\infty} \subset L$ creciente : $\bigcup_{j=1}^{\infty} A_j \in L$.

Lema 2.3.8. *Sea L un λ-sistema de Ω cerrado por intersecciones finitas, entonces L es una σ-álgebra.*

***Demostración*:** Veamos que se satisfacen las condiciones de la definición de σ-álgebra:

(I) $\Omega \in L$ por definición de λ-sistema.

(II) Si $A \in L$, entonces

(III)

■

Teorema 2.3.9 (π-λ). *Sean P π-sistema y L λ-sistema de Ω con $P \subset L \implies \sigma(P) \subset L$.*

***Demostración*:** Veamos que el λ-sistema más pequeño que contiene a P es una σ-álgebra. Lo denotaremos por $\lambda(P)$. Por el lema 2.3.8, basta con ver que $\lambda(P)$ es cerrado por intersecciones finitas. Sea $A \in P$, definimos

$$\mathcal{G} = \{B \in L : A \cap B \in \lambda(P)\}.$$

Entonces, $\mathcal{G}$ es un λ-sistema:

(I) $\Omega \in \mathcal{G}$ ya que $A \cap \Omega = A \in P \subset \lambda(P)$.

(II) Sean $B, C \in \mathcal{G}$ con $B \subset C$, entonces $A \cap B, A \cap C \in \lambda(P)$ por definición de $\mathcal{G}$. Por tanto, $A \cap (C \setminus B) = (A \cap C) \setminus (A \cap B) \in \lambda(P)$, ya que $\lambda(P)$ es un λ-sistema. Por lo tanto, $C \setminus B \in \mathcal{G}$.

(III) Sea $\{B_j\}_{j=1}^{\infty} \subset \mathcal{G}$ creciente, entonces $\forall j \in \mathbb{N} : A \cap B_j \in \lambda(P)$. Por tanto, tenemos que $A \cap \bigcup_{j=1}^{\infty} B_j = \bigcup_{j=1}^{\infty}(A \cap B_j) \in \lambda(P)$, ya que $\lambda(P)$ es un λ-sistema. Por lo tanto, $\bigcup_{j=1}^{\infty} B_j \in \mathcal{G}$.

Entonces $\mathcal{G}$ es un λ-sistema que contiene a P, por lo que $\lambda(P) \subset \mathcal{G}$. Por tanto, $\forall B \in \lambda(P) : A \cap B \in \lambda(P)$, es decir, $\lambda(P)$ es cerrado por intersecciones finitas. Por el lema 2.3.8, $\lambda(P)$ es una σ-álgebra. Entonces, por definición de $\sigma(P)$, tenemos que $\sigma(P) \subset \lambda(P) \subset L$. ■

Teorema 2.3.10. *Sea M un espacio polaco equipado con su σ-álgebra de Borel $\mathcal{B}(M)$. Sea $\Omega = M^{\mathbb{N}_0}$ y $\mathcal{F} = \mathcal{B}(M)^{\otimes \mathbb{N}_0}$ la σ-álgebra producto sobre Ω. Sea ν una medida de probabilidad sobre $(M, \mathcal{B}(M))$. Entonces, el proceso $(X_n)_{n \in \mathbb{N}_0}$ definido por $X_n(\omega) = \omega_n$ es un proceso*

estocástico de Markov con distribución inicial ν y núcleos de transición $(P_n)_{n\in\mathbb{N}_0}$ con respeto a la filtración natural $(\mathcal{F}_n)_{n\in\mathbb{N}_0}$, donde $\mathcal{F}_n = \sigma(X_0, \ldots, X_n)$.
A esta cadena de Markov $(X_n)_{n\in\mathbb{N}_0}$ se le llama la ***cadena canónica****.*

***Demostración*:** Definimos los sucesos $A := \bigcap_{i=0}^{n} \{X_i \in A_i\}$ y $B = \{X_{n+1} \in A_{n+1}\}$, donde $A_0, \ldots, A_n, A_{n+1} \in \mathcal{B}(M)$ son fijos. Entonces, $A \in \mathcal{F}_n$ y $B \in \sigma(X_{n+1})$.

Entonces,

$$\int_A \mathbb{1}_{X_{n+1}\in B}\, \mathrm{d}\mathbb{P} = \int_A P_{n+1}(X_n, B)\, \mathrm{d}\mathbb{P}.$$

Vamos a probar que:

- La colección de conjuntos de la forma de A es un π-sistema.
- La colección de conjuntos que satisfacen la ecuación anterior es un λ-sistema.

Entonces, por el Teorema π-λ, la ecuación se cumple para todo A en la σ-álgebra generada por el π-sistema, que es $\mathcal{F}_n$. ■

H. Hojas de ejercicios

H.1. Martingalas en tiempo discreto

1 Demuestra la desigualdad de Chebyshev condicional: para $a > 0$,

$$P(|X| \geqslant a \mid \mathcal{F}) \leqslant \frac{\mathbb{E}[X^2 \mid \mathcal{F}]}{a^2}.$$

2 Demuestra la desigualdad de Cauchy–Schwarz condicional:

$$(\mathbb{E}[XY \mid \mathcal{F}])^2 \leqslant \mathbb{E}[X^2 \mid \mathcal{F}]\mathbb{E}[Y^2 \mid \mathcal{F}].$$

(Indicación: $\mathbb{E}[(X + \theta Y)^2 \mid \mathcal{F}] \geqslant 0$ y, si $a\theta^2 + b\theta + c \geqslant 0$ para todo θ, entonces $b^2 - 4ac \leqslant 0$.)

3 Define la varianza condicional

$$\operatorname{var}(X \mid \mathcal{F}) := \mathbb{E}\left((X - \mathbb{E}[X \mid \mathcal{F}])^2 \mid \mathcal{F}\right).$$

Demuestra que

$$\operatorname{var}(X) = \mathbb{E}\left(\operatorname{var}(X \mid \mathcal{F})\right) + \operatorname{var}\left(\mathbb{E}[X \mid \mathcal{F}]\right).$$

4 Sea X_n una submartingala. Demuestra que $X_n^+ := \max\{0, X_n\}$ es una submartingala.

5 Sean X_n y Y_n submartingalas con respecto a una filtración común $\mathcal{F}_n$. Demuestra que $Z_n := \max\{X_n, Y_n\}$ y $W_n := X_n + Y_n$ son submartingalas.

6 Sea X_n una submartingala. Sea $Y_n := X_n \log^+ X_n$. Suponiendo que $Y_n \in L^1$, demuestra que Y_n es una submartingala.

7 Sea $X_n \geqslant 0$ una supermartingala. Demuestra que existe $X \in L^1$ tal que $X_n \to X$ c.s. cuando $n \to \infty$ y $\mathbb{E}X \leqslant \mathbb{E}X_0$.

8 Sean $\{Y_k\}_{k \geqslant 1}$ variables aleatorias no negativas, i.i.d., con $\mathbb{E}Y_k = 1$. Sea

$$X_n := \prod_{k=1}^{n} Y_k.$$

Demuestra que X_n es una martingala. Demuestra que, si $P(Y_k = 1) < 1$, entonces $X_n \to 0$ c.s.

9 Sea X_n una martingala con $X_0 = 0$ y $\mathbb{E}X_n^2 < \infty$. Demuestra que

$$P\left(\max_{m \leqslant n} X_m \geqslant \lambda\right) \leqslant \frac{\mathbb{E}X_n^2}{\mathbb{E}X_n^2 + \lambda^2}.$$

(Indicación: Utiliza que $(X_n + c)^2$ es una submartingala y optimiza respecto de c.)

10 Sea $X_n \geqslant 0$ una supermartingala y sea T un tiempo de parada (posiblemente no acotado). Demuestra que $\mathbb{E}X_0 \geqslant \mathbb{E}X_T$. (Advertencia: No se supone integrabilidad uniforme.)

11 Sea $X_n \geqslant 0$ una supermartingala. Demuestra que, para todo $C > 0$,

$$P\left(\sup_n X_n > C\right) \leqslant \frac{\mathbb{E}X_0}{C}.$$

(Indicación: Recuerda la demostración de la desigualdad de Doob para martingalas y utiliza el ejercicio anterior.)

12 (Identidad de Wald) Sean $\{\xi_k\}_{k\in\mathbb{N}}$ variables aleatorias reales, i.i.d., tales que $\mathbb{E}\,|\xi_k| < \infty$, y sea $S_n := \sum_{k=1}^n \xi_k$. Sea T un tiempo de parada (con respecto a la filtración natural) tal que $\mathbb{E}T < \infty$. Demuestra que

$$\mathbb{E}S_T = \mathbb{E}T \cdot \mathbb{E}\xi_1.$$

(Indicación: Considera primero el caso de ξ_k no negativas.)

13 Sea X_n una sucesión de variables aleatorias, y sea Y una variable aleatoria no negativa con $\mathbb{E}Y < \infty$. Si $|X_n| \leqslant Y$, demuestra que X_n es uniformemente integrable.

14 Sea $(X_n)_{n\in\mathbb{N}}$ una sucesión de variables aleatorias y sea T un tiempo de parada. Supón que $\mathbb{E}\,[|X_T|] < \infty$ y que $X_n \mathbb{1}_{\{T>n\}}$ es uniformemente integrable. Demuestra que $X_{T\wedge n}$ es uniformemente integrable.

***Solución*:** Sea $\varepsilon > 0$. Como $X_n \mathbb{1}_{\{T>n\}}$ es uniformemente integrable, existe $K_1 > 0$ tal que

$$\sup_{n\in\mathbb{N}} \left\{ \mathbb{E}\left[\left| X_n \mathbb{1}_{\{T>n\}} \right| \mathbb{1}_{\left\{ \left| X_n \mathbb{1}_{\{T>n\}} \right| > K_1 \right\}} \right] \right\} < \frac{\varepsilon}{2}.$$

Sea $n \in \mathbb{N}$. Tenemos que para todo $\omega \in \Omega$,

$$\left| X_n(\omega)\, \mathbb{1}_{\{T(\omega)>n\}} \right| > K_1 \iff |X_n(\omega)| > K_1 \wedge T(\omega) > n$$

Por tanto, tenemos que

$$\mathbb{E}\left[\left| X_n \mathbb{1}_{\{T>n\}} \right| \mathbb{1}_{\left\{ \left| X_n \mathbb{1}_{\{T>n\}} \right| > K_1 \right\}} \right] = \mathbb{E}\left[|X_n|\, \mathbb{1}_{\{T>n\}} \mathbb{1}_{\{|X_n|>K_1\}} \right] < \frac{\varepsilon}{2}.$$

Por otro lado, como $\mathbb{E}\,[|X_T|] < \infty$, existe $K_2 > 0$ tal que $\mathbb{E}\left[|X_T|\, \mathbb{1}_{\{|X_T|>K_2\}} \right] < \frac{\varepsilon}{2}$.

Por último, por definición de $X_{T\wedge n}$, sabemos que

$$\begin{aligned} \forall K > 0 : |X_{T\wedge n}|\, \mathbb{1}_{\{|X_{T\wedge n}|>K\}} &= |X_n|\, \mathbb{1}_{\{|X_n|>K\}} \mathbb{1}_{\{T>n\}} + |X_T|\, \mathbb{1}_{\{|X_T|>K\}} \mathbb{1}_{\{T\leqslant n\}} \\ &\leqslant |X_n|\, \mathbb{1}_{\{|X_n|>K\}} \mathbb{1}_{\{T>n\}} + |X_T|\, \mathbb{1}_{\{|X_T|>K\}}. \end{aligned}$$

Ahora, al tomar $K := \max\{K_1, K_2\}$ y aplicar esperanzas, como $n \in \mathbb{N}$ era arbitrario, obtenemos que

$$\sup_{n\in\mathbb{N}} \left\{ \mathbb{E}\left[|X_{T\wedge n}| \, \mathbb{1}_{\{|X_{T\wedge n}|>K\}} \right] \right\} = \sup_{n\in\mathbb{N}} \left\{ \mathbb{E}\left[|X_n| \, \mathbb{1}_{\{|X_n|>K\}} \mathbb{1}_{\{T>n\}} \right] \right\} + \mathbb{E}\left[|X_T| \, \mathbb{1}_{\{|X_T|>K\}} \right]$$
$$< \frac{\varepsilon}{2} + \frac{\varepsilon}{2} = \varepsilon.$$

■

15 (Parada opcional para incrementos condicionales acotados) Sea X_n una submartingala, y supón que existe una constante $K > 0$ tal que, para todo $n \in \mathbb{N}$,

$$\mathbb{E}\left(|X_{n+1} - X_n| \mid \mathcal{F}_n \right) \leqslant K \text{ c.s.}$$

Sea T un tiempo de parada tal que $\mathbb{E}T < \infty$. Demuestra que $\mathbb{E}X_0 \leqslant \mathbb{E}X_T$.

16 Sean $\{\xi_k\}$ variables aleatorias i.i.d. que toman valores en $\{\pm 1\}$, con

$$P(\xi = 1) = p, \quad P(\xi = -1) = 1 - p, \quad p > \frac{1}{2},$$

y sea $X_n := \sum_{k=1}^{n} \xi_k$. Llamamos a X_n paseo aleatorio simple asimétrico.

a) Halla $c \in \mathbb{R}$ tal que el proceso $Y_n = X_n - cn$ sea una martingala.

b) Halla $r \in (0, 1)$ tal que el proceso $Z_n = r^{X_n}$ sea una martingala.

c) Para todo $a \in \mathbb{Z}$, sea

$$T_a = \inf\{n \in \mathbb{N} : X_n = a\}.$$

Demuestra que, para todo $a > 0$, $P(T_a < \infty) = 1$. (Indicación: Calcula la probabilidad de que $\lim_{n\to\infty} X_n = +\infty$.)

d) Demuestra que, para todo $a < 0 < b$,

$$P(T_a < T_b) = \frac{1 - r^b}{r^a - r^b}.$$

(Indicación: Utiliza el ejercicio 14.)

e) Demuestra que, para todo $a < 0$,

$$P(T_a < \infty) = \left(\frac{p}{1-p} \right)^{-a}.$$

f) Demuestra que, para todo $a > 0$,

$$\mathbb{E}T_a = \frac{a}{2p - 1}.$$

(Indicación: Utiliza Y_n.)

E. Entregas

E.1. Martingalas y funciones armónicas

Ejercicio E.1.1. Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad. Sea $\mathcal{G} \subset \mathcal{F}$ una σ-álgebra. Sea $X\colon \Omega \to \mathbb{R}^d$ una variable aleatoria $\mathcal{G}$-medible y sea $Y\colon \Omega \to \mathbb{R}^d$ una variable aleatoria $\mathcal{G}$-independiente. Sea $\varphi : \mathbb{R}^d \times \mathbb{R}^d \to \mathbb{R}$ una función medible Borel, tal que $\mathbb{E}\left[|\varphi(X,Y)|\right] < \infty$. Demuestra que

$$\mathbb{E}\left[\varphi(X,Y) \mid \mathcal{G}\right] = g(X),$$

donde $g(x) := \mathbb{E}\left[\varphi(x,Y)\right]$.
(Pista: recuerda que, si dos variables aleatorias independientes A y B tienen distribuciones μ y ν, respectivamente, entonces la distribución conjunta de (A,B) es la medida producto $\mu \times \nu$.)

***Solución*:** Por unicidad de la esperanza condicional, basta con comprobar dos condiciones:

(1) Veamos que $g(X)$ es $\mathcal{G}$-medible y $g(X) \in \mathcal{L}^1(\mathbb{P})$.

Por hipótesis, tenemos que $\mathbb{E}\left[|\varphi(X,Y)|\right] < \infty$, es decir,

$$\mathbb{E}\left[|\varphi(X,Y)|\right] = \int_\Omega |\varphi(X(\omega), Y(\omega))| \, \mathrm{d}\mathbb{P}(\omega) < \infty.$$

Como $(x,y) \mapsto |\varphi(x,y)|$ es una función medible Borel (por ser la composición de funciones medibles Borel), por el `teo-medida-inducida-integral-fn-medible/`teorema 1, tenemos que

$$\int_{\mathbb{R}^d \times \mathbb{R}^d} |\varphi(x,y)| \, \mathrm{d}\mathbb{P}_{(X,Y)}(x,y) = \int_\Omega |\varphi(X(\omega), Y(\omega))| \, \mathrm{d}\mathbb{P}(\omega) < \infty.$$

Es decir, $\varphi \in \mathcal{L}^1\left(\mathbb{P}_{(X,Y)}\right)$.

Como X es $\mathcal{G}$-medible e Y es $\mathcal{G}$-independiente, X e Y son independientes. Entonces, por el `teo-carac-independencia-var-aleatorias-medida-inducida/`teorema 1, $\mathbb{P}_{(X,Y)} = \mathbb{P}_X \otimes \mathbb{P}_Y$. Así, $\varphi \in \mathcal{L}^1\left(\mathbb{P}_X \otimes \mathbb{P}_Y\right)$.

Entonces, $\exists A \in \mathcal{B}\left(\mathbb{R}^d\right)$ tal que $\mathbb{P}_X\left(A^\mathsf{c}\right) = 0$ y $\forall x \in A : \int_{\mathbb{R}^d} |\varphi(x,y)| \, \mathrm{d}\mathbb{P}_Y(y) < \infty$. Por tanto, $y \mapsto \varphi(x,y)$ está en $\mathcal{L}^1\left(\mathbb{P}_Y\right)$ para $\mathbb{P}_X$-c.t.p. $x \in \mathbb{R}^d$. Entonces, por el `teo-medida-inducida-integral-fn-` tenemos que

$$\forall x \in A : g(x) = \mathbb{E}\left[\varphi(x,Y)\right] = \int_\Omega \varphi(x, Y(\omega)) \, \mathrm{d}\mathbb{P}(\omega) = \int_{\mathbb{R}^d} \varphi(x,y) \, \mathrm{d}\mathbb{P}_Y(y).$$

Ahora bien, como $\mathbb{P}_X$ y $\mathbb{P}_Y$ son medidas de probabilidad en $\mathbb{R}^d$, en particular son σ-finitas. Como además $\varphi \in \mathcal{L}^1(\mathbb{P}_X \otimes \mathbb{P}_Y)$, por el teorema de Fubini-Tonelli, g es $\mathcal{B}(\mathbb{R}^d)$-medible y además, $g \in \mathcal{L}^1(\mathbb{P}_X)$.

Como X es $\mathcal{G}$-medible, concluimos que $g(X)$ es $\mathcal{G}$-medible. Además, por el `teo-medida-inducida-integra` $g \in \mathcal{L}^1(\mathbb{P}_X)$ implica que $g(X) \in \mathcal{L}^1(\mathbb{P})$.

(2) Veamos que para todo $E \in \mathcal{G}$ se cumple $\int_E \varphi(X,Y)\,\mathrm{d}\mathbb{P} = \int_E g(X)\,\mathrm{d}\mathbb{P}$.

Sea $E \in \mathcal{G}$. Entonces, $\mathbb{1}_E$ es una función $\mathcal{G}$-medible y, como X también es $\mathcal{G}$-medible, el par $(X, \mathbb{1}_E) : \Omega \to \mathbb{R}^d \times \{0,1\}$ es $\mathcal{G}$-medible. En consecuencia, $(X, \mathbb{1}_E)$ e Y son variables aleatorias independientes, luego por el `teo-carac-independencia-var-aleatorias-medida-inducida/`teoren $\mathbb{P}_{(X,\mathbb{1}_E,Y)} = \mathbb{P}_{(X,\mathbb{1}_E)} \otimes \mathbb{P}_Y$.

Ahorrándonos algunos detalles técnicos que resultan fáciles pero tediosos de comprobar, podemos escribir la siguiente cadena de igualdades:

$$\begin{aligned}
\int_E \varphi(X,Y)\,\mathrm{d}\mathbb{P} &= \int_\Omega \mathbb{1}_E(\omega)\cdot\varphi(X(\omega),Y(\omega))\ \mathrm{d}\mathbb{P}(\omega) \\
&\overset{\text{teo-medida-inducida-integral-fn-medible/teorema 1}}{=} \int_{\mathbb{R}^d\times\{0,1\}\times\mathbb{R}^d} b\cdot\varphi(x,y)\ \mathrm{d}\mathbb{P}_{(X,\mathbb{1}_E,Y)}(x,b,y) \\
&\overset{\text{independencia}}{=} \int_{\mathbb{R}^d\times\{0,1\}\times\mathbb{R}^d} b\cdot\varphi(x,y)\ \mathrm{d}\left(\mathbb{P}_{(X,\mathbb{1}_E)}\otimes\mathbb{P}_Y\right)(x,b,y) \\
&\overset{\text{Fubini}}{=} \int_{\mathbb{R}^d\times\{0,1\}} b\left(\int_{\mathbb{R}^d}\varphi(x,y)\ \mathrm{d}\mathbb{P}_Y(y)\right)\mathrm{d}\mathbb{P}_{(X,\mathbb{1}_E)}(x,b) \\
&= \int_{\mathbb{R}^d\times\{0,1\}} b\cdot g(x)\ \mathrm{d}\mathbb{P}_{(X,\mathbb{1}_E)}(x,b) \\
&\overset{\text{teo-medida-inducida-integral-fn-medible/teorema 1}}{=} \int_\Omega \mathbb{1}_E(\omega)\,g(X(\omega))\ \mathrm{d}\mathbb{P}(\omega) = \int_E g(X)\,\mathrm{d}\mathbb{P}.
\end{aligned}$$

Por unicidad de la esperanza condicional, como $g(X) \in \mathcal{L}^1(\mathbb{P})$ es una variable $\mathcal{G}$-medible y $\forall E \in \mathcal{G} : \int_E \varphi(X,Y)\,\mathrm{d}\mathbb{P} = \int_E g(X)\,\mathrm{d}\mathbb{P}$, concluimos que $g(X) = \mathbb{E}[\varphi(X,Y) \mid \mathcal{G}]$ c.s. ■

Ejercicio E.1.2. Sea f una función armónica en $\mathbb{R}^d$. Sea $x \in \mathbb{R}^d$ y sean $\{\xi_k\}_{k\in\mathbb{N}}$ i.i.d. y uniformemente distribuidas en $\partial B_0(1)$ (la esfera de radio 1 y centro 0). Se define $\{S_n\}_{n\geqslant 0}$ por la recurrencia

$$S_0 = x, \qquad S_n = \xi_n + S_{n-1}.$$

Demuestra que el proceso dado por $X_n := f(S_n)$ es una martingala.

***Solución*:** Tomando $\forall n \in \mathbb{N} : \mathcal{F}_n := \sigma(\xi_1, \ldots, \xi_n)$ y $\mathcal{F}_0 = \{\varnothing, \Omega\}$, tenemos que

$$\forall n \in \mathbb{N} \cup \{0\} : S_n = \xi_n + S_{n-1} = x + \sum_{k=1}^{n} \xi_k \text{ es una variable aleatoria } \mathcal{F}_n\text{-medible.}$$

Veamos que $(X_n)_{n\in\mathbb{N}}$ es una martingala respecto a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$:

1 Como f es armónica, en particular es continua, luego es medible Borel. Entonces, como $X_n = f(S_n)$ y S_n es $\mathcal{F}_n$-medible, X_n también es $\mathcal{F}_n$-medible.

2 Como $S_n = x + \sum_{k=1}^{n} \xi_k$, dado $\omega \in \Omega$, tenemos que

$$\|S_n(\omega)\| = \left\| x + \sum_{k=1}^{n} \xi_k(\omega) \right\| \leqslant \|x\| + \sum_{k=1}^{n} \|\xi_k(\omega)\| = \|x\| + n.$$

Por tanto, $\forall n \in \mathbb{N}, \omega \in \Omega : S_n(\omega) \in \overline{B_0}(\|x\| + n)$. Entonces, como f es continua en $\mathbb{R}^d$, es acotada en $\overline{B_0}(\|x\| + n)$, luego

$$\forall n \in \mathbb{N} : \exists M_n > 0 : \forall \omega \in \Omega : |X_n(\omega)| = |f(S_n(\omega))| \leqslant M_n.$$

En consecuencia, $\mathbb{E}[|X_n|] = \int_\Omega |X_n(\omega)| \, \mathrm{d}\mathbb{P}(\omega) \leqslant M_n < \infty$, es decir, $X_n \in \mathcal{L}^1(\mathbb{P})$.

3 Por último, veamos que $\forall n \in \mathbb{N} : \mathbb{E}[X_{n+1} \mid \mathcal{F}_n] = X_n$. Para ello, tras fijar $n \in \mathbb{N}$, vamos a aplicar el ejercicio anterior con $\mathcal{G} = \mathcal{F}_n$, $X = S_n$, $Y = \xi_{n+1}$ y $\varphi(x, y) = f(x + y)$. Comprobemos que se cumplen las hipótesis del ejercicio anterior:

a) S_n es $\mathcal{F}_n$-medible por definición de S_n y $\mathcal{F}_n$.

b) Como las ξ_n son independientes, ξ_{n+1} es independiente de $\mathcal{F}_n = \sigma(\xi_1, \ldots, \xi_n)$.

c) Como f es medible Borel, φ también lo es, por ser la composición de funciones medibles Borel.

d) $\mathbb{E}[|f(S_n + \xi_{n+1})|] = \mathbb{E}[|f(S_{n+1})|] = \mathbb{E}[|X_{n+1}|] < \infty$ por el punto (2) anterior.

Por tanto, por el ejercicio anterior, tenemos que

$$\mathbb{E}[X_{n+1} \mid \mathcal{F}_n] = \mathbb{E}[f(S_n + \xi_{n+1}) \mid \mathcal{F}_n] = \mathbb{E}[\varphi(X, Y) \mid \mathcal{G}] = g(X) = g(S_n),$$

donde $g(x) = \mathbb{E}[\varphi(x, Y)] = \mathbb{E}[f(x + \xi_{n+1})]$.

Por último, como f es armónica, aplicando la propiedad de la media con $r = 1$, como ξ_{n+1} está uniformemente distribuida en $\partial B_0(1)$, tenemos que $\forall x \in \mathbb{R}^d$:

$$g(x) = \mathbb{E}\left[f(x + \xi_{n+1})\right] = \int_\Omega f(x + \xi_{n+1}(\omega))\,\mathrm{d}\mathbb{P}(\omega) \overset{\text{teo-medida-inducida-integral-fn-medible/teorema 1}}{\downarrow} \int_{\partial B_0(1)} f(x+y)\,\mathrm{d}\mathbb{P}_{\xi_{n+1}}(y)$$

$$= \frac{1}{\omega_d}\int_{\partial B_0(1)} f(x+y)\,\mathrm{d}\sigma(y) = \frac{1}{\omega_d\, 1^{d-1}}\int_{\partial B(x,1)} f(y)\,\mathrm{d}\sigma(y) \overset{\text{teo-propiedad-media-fn-armonica/teorema 1}}{\downarrow} f(x).$$

Por tanto, $g = f$ y, en particular, $\forall n \in \mathbb{N} : \mathbb{E}\left[X_{n+1} \mid \mathcal{F}_n\right] = g(S_n) = f(S_n) = X_n$.

Como se cumplen las tres condiciones, concluimos que $(X_n)_{n\in\mathbb{N}}$ es una martingala respecto a la filtración $(\mathcal{F}_n)_{n\in\mathbb{N}}$. ■

E.2. Procesos de ramificación

Sea $\left\{\xi_k^{(n)}\right\}_{k,n\geqslant 1}$ una familia de variables aleatorias i.i.d. que toman valores enteros no negativos, con media $\mu \geqslant 0$. Se define recursivamente el proceso

$$X_0 = x, \quad X_{n+1} = \begin{cases} \sum_{k=1}^{X_n} \xi_k^{(n+1)} & \text{si } X_n > 0, \\ 0 & \text{si } X_n = 0. \end{cases}$$

Estos procesos se denominan *procesos de ramificación*. Modelizan dinámicas de reproducción, como por ejemplo la propagación de apellidos en genealogía. X_n representa el número de miembros de una población en la generación n. La población comienza con x miembros y, en cada generación n, los miembros tienen, de forma independiente, un número de descendientes con la misma distribución (la distribución de $\xi_k^{(n)}$ suele denominarse *distribución de descendencia*).

En este enlace puede verse una simulación de un proceso de ramificación realizada por el Prof. Nils Berglund (Université d'Orléans).

Una pregunta natural en estos modelos es si la población sobrevivirá o se extinguirá. El objetivo de este ejercicio es demostrar que:

- Si $\mu < 1$ (es decir, el número esperado de descendientes de cada individuo es menor que 1), entonces la población se extinguirá casi seguramente.
- Si $\mu = 1$ pero $\mathbb{P}(\xi_k^{(n)} = 1) < 1$ (es decir, el número esperado de descendientes de cada individuo es 1, pero hay una probabilidad positiva de que no tengan descendencia), entonces la población se extinguirá casi seguramente.
- Si $\mu > 1$ (es decir, el número esperado de descendientes de cada individuo es mayor que 1), entonces la probabilidad de supervivencia es estrictamente positiva.

Ejercicio E.2.1. Sea $\mathcal{F}_n = \sigma\left(\xi_k^{(m)} : k \in \mathbb{N}, 1 \leqslant m \leqslant n\right)$. Demuestra que, para $\mu > 0$, $\mu^{-n} X_n$ es una $\mathcal{F}_n$-martingala y que converge c.s.

***Solución*:** Veamos que se cumplen las condiciones de la definición de martingala para $(M_n)_{n\in\mathbb{N}}$ dada por $\forall n \in \mathbb{N} : M_n := \mu^{-n} X_n$.

(I) Para n fijo, $\forall k \in \mathbb{N}, m \in \mathbb{N}_n : \xi_k^{(m)}$ es $\mathcal{F}_n$-medible por construcción, y por lo tanto $X_n = \sum_{k=1}^{X_{n-1}} \xi_k^{(n)}$ es $\mathcal{F}_n$-medible. Así, $M_n = \mu^{-n} X_n$ es $\mathcal{F}_n$-medible.

(II) Por la ley de la esperanza total (para variables no negativas), sabemos que

$$\mathbb{E}[X_n] = \mathbb{E}\left[\mathbb{E}\left[X_n \mid \mathcal{F}_{n-1}\right]\right].$$

Ahora, para calcular $\mathbb{E}\left[X_n \mid \mathcal{F}_{n-1}\right]$, observamos que

$$\mathbb{E}\left[X_n \mid \mathcal{F}_{n-1}\right] = \mathbb{E}\left[\sum_{k=1}^{\infty} \xi_k^{(n)} \mathbb{1}_{\{k \leqslant X_{n-1}\}} \,\middle|\, \mathcal{F}_{n-1}\right] \overset{\text{TCM}}{=} \sum_{k=1}^{\infty} \mathbb{E}\left[\xi_k^{(n)} \mathbb{1}_{\{k \leqslant X_{n-1}\}} \,\middle|\, \mathcal{F}_{n-1}\right].$$

Como $\mathbb{1}_{\{k \leqslant X_{n-1}\}}$ es $\mathcal{F}_{n-1}$-medible y $\xi_k^{(n)}$ es independiente de $\mathcal{F}_{n-1}$, obtenemos que

$$\mathbb{E}\left[X_n \mid \mathcal{F}_{n-1}\right] = \sum_{k=1}^{\infty} \mathbb{1}_{\{k \leqslant X_{n-1}\}} \mathbb{E}\left[\xi_k^{(n)}\right] = \sum_{k=1}^{X_{n-1}} \mu = \mu\, X_{n-1}. \tag{E.1}$$

Así, llegamos a que $\mathbb{E}[X_n] = \mathbb{E}\left[\mu\, X_{n-1}\right] = \mu\, \mathbb{E}[X_{n-1}]$. Por inducción, obtenemos que

$$\mathbb{E}[X_n] = \mu^n x. \tag{E.2}$$

Por tanto, $M_n = \mu^{-n} X_n$ es integrable con esperanza $\mathbb{E}[M_n] = x$.

(III) De la ecuación (E.1), obtenemos que

$$\begin{aligned}\mathbb{E}\left[M_n \mid \mathcal{F}_{n-1}\right] &= \mathbb{E}\left[\mu^{-n} X_n \mid \mathcal{F}_{n-1}\right] \\ &= \mu^{-n}\, \mathbb{E}\left[X_n \mid \mathcal{F}_{n-1}\right] = \mu^{-n}\, \mu\, X_{n-1} = \mu^{-(n-1)} X_{n-1} = M_{n-1}.\end{aligned}$$

Como cumple todas las condiciones, $(M_n)_{n\in\mathbb{N}}$ es una martingala.

Como $(M_n)_{n\in\mathbb{N}}$ es una martingala no negativa y $\sup_{n\in\mathbb{N}} \mathbb{E}[M_n] = x < \infty$, por el teorema de convergencia de martingalas, obtenemos que M_n converge c.s. a una variable aleatoria M_∞ integrable. ■

Ejercicio E.2.2. Supongamos que $\mu < 1$. Demuestra que $\mathbb{P}(X_n > 0 \text{ para todo } n) = 0$.
Pista: Demuestra que $\mathbb{P}(X_n > 0) \leqslant \mu^n x$.

***Solución*:** Por un lado, de (E.2), por la desigualdad de Markov, deducimos que

$$\forall n \in \mathbb{N} : \mathbb{P}\left(X_n > 0\right) = \mathbb{P}\left(X_n \geqslant 1\right) \leqslant \mathbb{E}[X_n] \overset{\text{(E.2)}}{\downarrow} \mu^n x. \tag{E.3}$$

Por otro lado, como $\{\forall n \in \mathbb{N} : X_n > 0\} = \bigcap_{n\in\mathbb{N}}\{X_n > 0\}$ y la sucesión de eventos $(\{X_n > 0\})_{n\in\mathbb{N}}$ es decreciente (pues si $X_n = 0$, entonces $X_{n+1} = 0$), por el teorema de convergencia monótona para sucesiones decrecientes de conjuntos, obtenemos que

$$\mathbb{P}\left(\forall n \in \mathbb{N} : X_n > 0\right) = \mathbb{P}\left(\bigcap_{n\in\mathbb{N}}\{X_n > 0\}\right) = \lim_{m\to\infty} \mathbb{P}\left(X_m > 0\right).$$

Juntando todo, obtenemos que

$$\mathbb{P}\left(\forall n \in \mathbb{N} : X_n > 0\right) = \lim_{m\to\infty} \mathbb{P}\left(X_m > 0\right) \overset{\text{(E.3)}}{\downarrow} \leqslant \lim_{m\to\infty} \mu^m x = 0.$$

Por lo tanto, concluimos que $\mathbb{P}\left(\forall n \in \mathbb{N} : X_n > 0\right) = 0$. ■

Ejercicio E.2.3. Supongamos que $\mu = 1$ y $\mathbb{P}\left(\xi_k^{(n)} = 1\right) < 1$. Demuestra que

$$\mathbb{P}\left(\forall n \in \mathbb{N} : X_n > 0\right) = 0.$$

Pista: Observa que, como las X_n toman valores enteros y convergen a cierta X_∞, debe cumplirse que $X_n = X_\infty$ para todo n suficientemente grande, c.s.

***Solución*:** Dividimos la demostración en varios pasos para mayor claridad.

Paso 1: Por el ejercicio E.2.1, sabemos que $M_n = \mu^{-n} X_n = X_n$ converge c.s. a una variable aleatoria $M_\infty =: X_\infty$, es decir, $\exists A \in \mathcal{F} : \mathbb{P}(A) = 0 \wedge \forall \omega \in A^{\mathsf{c}} : \lim_{n\to\infty} X_n(\omega) = X_\infty(\omega)$.

Tomando dicho $A \in \mathcal{F}$, se cumple que

$$\forall \varepsilon > 0 : \forall \omega \in A^{\mathsf{c}} : \exists N \in \mathbb{N} : \forall n \geqslant N : |X_n(\omega) - X_\infty(\omega)| < \varepsilon.$$

En particular, para $\varepsilon = 1/2$, como las X_n toman valores enteros, obtenemos que

$$\forall \omega \in A^{\mathsf{c}} : \exists N(\omega) \in \mathbb{N} : \forall n \geqslant N(\omega) : X_n(\omega) = X_\infty(\omega). \tag{E.4}$$

Por tanto, utilizando de nuevo que $X_n = 0 \implies X_{n+1} = 0$, obtenemos que

$$\begin{aligned}\mathbb{P}\left(\forall n \in \mathbb{N} : X_n > 0\right) &= \mathbb{P}\left(\{\omega \in \Omega : \forall n \in \mathbb{N} : X_n(\omega) > 0\} \cap A^{\mathsf{c}}\right) \\ &= \mathbb{P}\left(\{\omega \in \Omega : X_\infty(\omega) > 0\} \cap A^{\mathsf{c}}\right) = \mathbb{P}\left(X_\infty > 0\right).\end{aligned}$$

Observamos además que $\{X_\infty > 0\} = \bigcup_{k=1}^{\infty} \{X_\infty = k\}$, luego por subaditividad de la medida de probabilidad, llegamos a que

$$\mathbb{P}\left(\forall n \in \mathbb{N} : X_n > 0\right) = \mathbb{P}\left(X_\infty > 0\right) \leqslant \sum_{k\in\mathbb{N}} \mathbb{P}\left(X_\infty = k\right).$$

Paso 2: Sea $k \in \mathbb{N}$. Entonces, tenemos que

$$\begin{aligned}\mathbb{P}\left(X_\infty = k\right) &= \mathbb{P}\left(\{\omega \in \Omega : X_\infty(\omega) = k\} \cap A^{\mathsf{c}}\right) \\ &\overset{\text{(E.4)}}{=} \mathbb{P}\left(\{\omega \in \Omega : \exists N(\omega) \in \mathbb{N} : \forall n \geqslant N(\omega) : X_n(\omega) = k\} \cap A^{\mathsf{c}}\right) \\ &\leqslant \mathbb{P}\left(\bigcup_{N\in\mathbb{N}} \{\omega \in \Omega : \forall n \geqslant N : X_n(\omega) = k\}\right) \\ &\leqslant \sum_{N\in\mathbb{N}} \mathbb{P}\left(\forall n \geqslant N : X_n = k\right) = \sum_{N\in\mathbb{N}} \mathbb{P}\left(\bigcap_{n\geqslant N} \{X_n = k\}\right).\end{aligned}$$

Paso 3: Sean $k, N \in \mathbb{N}$. Para todo $m \in \mathbb{N}$, definimos el suceso

$$B_{N,m}^{(k)} := \bigcap_{n=N}^{N+m} \{X_n = k\}.$$

Entonces, $\bigcap_{n\geqslant N}\{X_n = k\} = \bigcap_{m\in\mathbb{N}} B_{N,m}^{(k)}$ donde $\left(B_{N,m}^{(k)}\right)_{m\in\mathbb{N}}$ es una sucesión decreciente de eventos. Por tanto, por el teorema de convergencia monótona para sucesiones decrecientes de conjuntos, obtenemos que

$$\mathbb{P}\left(\bigcap_{m\in\mathbb{N}} B_{N,m}^{(k)}\right) = \lim_{m\to\infty} \mathbb{P}\left(B_{N,m}^{(k)}\right).$$

Paso 4: Sean $k, N, m \in \mathbb{N}$ fijos, calculemos $\mathbb{P}\left(B_{N,m}^{(k)}\right)$. Como X_N es $\mathcal{F}_N$-medible, entonces $\{X_N = k\} \in \mathcal{F}_N$. Además, como para todo $r \in \mathbb{N}_m$ la variable aleatoria $\sum_{j=1}^k \xi_j^{(N+r)}$ es independiente de $\mathcal{F}_{N+r-1} \supset \mathcal{F}_N$, obtenemos que

$$\begin{aligned}
\mathbb{P}\left(B_{N,m}^{(k)}\right) &= \mathbb{P}\left(\forall n \in \{N, \dots, N+m\} : X_n = k\right) \\
&= \mathbb{P}\left(X_N = k \wedge \sum_{j=1}^k \xi_j^{(N+1)} = k \wedge \dots \wedge \sum_{j=1}^k \xi_j^{(N+m)} = k\right) \\
&\overset{\text{independencia}}{\downarrow} \mathbb{P}\left(X_N = k\right) \prod_{r=1}^m \mathbb{P}\left(\sum_{j=1}^k \xi_j^{(N+r)} = k\right) \overset{\text{i.d.}}{\downarrow} \mathbb{P}\left(X_N = k\right) \left(\mathbb{P}\left(\sum_{j=1}^k \xi_j^{(1)} = k\right)\right)^m.
\end{aligned}$$

Sea ξ una variable aleatoria con la misma distribución que las $\xi_j^{(n)}$. Entonces, como $\xi \geqslant 0$, $\mathbb{E}[\xi] = 1$ y $\mathbb{P}(\xi = 1) < 1$ por hipótesis, se sigue que $\mathbb{P}(\xi = 0) > 0$. De lo contrario, si $\mathbb{P}(\xi = 0) = 0$, entonces $\mathbb{E}[\xi] = 1$ implicaría que $\mathbb{P}(\xi = 1) = 1$, contradiciendo la hipótesis. Por lo tanto, tenemos que $\forall j \in \mathbb{N} : \mathbb{P}(\xi_j^{(1)} = 0) = \mathbb{P}(\xi = 0) > 0$.

Observamos además que $\{\sum_{j=1}^k \xi_j^{(1)} = k\}$ tiene intersección vacía con $\{\sum_{j=1}^k \xi_j^{(1)} = 0\}$ (ya que $k \geqslant 1$). Por lo tanto,

$$\mathbb{P}\left(\sum_{j=1}^k \xi_j^{(1)} = k\right) \leqslant 1 - \mathbb{P}\left(\sum_{j=1}^k \xi_j^{(1)} = 0\right) \overset{\text{indep.}}{\downarrow} 1 - \prod_{j=1}^k \mathbb{P}\left(\xi_j^{(1)} = 0\right) = 1 - \mathbb{P}(\xi = 0)^k < 1.$$

Así, obtenemos que $\mathbb{P}\left(B_{N,m}^{(k)}\right) \leqslant \mathbb{P}\left(X_N = k\right)\left(1 - \mathbb{P}(\xi = 0)^k\right)^m$ con $1 - \mathbb{P}(\xi = 0)^k < 1$.

Conclusión: Juntándolo todo, obtenemos que

$$\begin{aligned}
\mathbb{P}\left(\forall n \in \mathbb{N} : X_n > 0\right) &\overset{\text{paso 1}}{\downarrow\leqslant} \sum_{k\in\mathbb{N}} \mathbb{P}\left(X_\infty = k\right) \overset{\text{paso 2}}{\downarrow\leqslant} \sum_{k\in\mathbb{N}} \sum_{N\in\mathbb{N}} \mathbb{P}\left(\bigcap_{n\geqslant N} \{X_n = k\}\right) \\
&\overset{\text{paso 3}}{\downarrow=} \sum_{k,N\in\mathbb{N}} \lim_{m\to\infty} \mathbb{P}\left(B_{N,m}^{(k)}\right) \overset{\text{paso 4}}{\downarrow\leqslant} \sum_{k,N\in\mathbb{N}} \mathbb{P}\left(X_N = k\right) \underbrace{\lim_{m\to\infty} \left(1 - \mathbb{P}(\xi = 0)^k\right)^m}_{=0} \\
&= \sum_{k,N\in\mathbb{N}} \mathbb{P}\left(X_N = k\right) \cdot 0 = 0.
\end{aligned}$$

■

Ejercicio E.2.4. Supongamos que $\mu > 1$ y $x \geqslant 1$. Demuestra que $\mathbb{P}(X_n > 0 \text{ para todo } n) > 0$. Puedes seguir estos pasos:

(a) Sea $\varphi : [0,1) \to \mathbb{R}$ la función generatriz de probabilidad de la distribución de descendencia, es decir,

$$\varphi(s) = \sum_{j \geqslant 0} s^j \, \mathbb{P}\left(\xi_k^{(n)} = j\right).$$

Demuestra que φ tiene un único punto fijo $\rho \in [0,1)$. (Puedes usar, sin demostrarlo, que φ es creciente, convexa, $\lim_{s\uparrow 1} \varphi(s) = 1$ y $\lim_{s\uparrow 1} \varphi'(s) = \mu$.)

(b) Demuestra que $Z_n := \rho^{X_n}$ converge c.s. a una variable aleatoria Z_∞ tal que $\mathbb{E}[Z_\infty] = \rho^x$ y $Z_\infty \in \{0,1\}$ c.s.

(c) Concluye que $\mathbb{P}(X_n = 0 \text{ para algún } n \geqslant 1) = \rho^x < 1$.

***Solución*:**

(a) Como $\sum_{j\geqslant 0} \mathbb{P}\left(\xi_k^{(n)} = j\right) = 1$, la función generatriz de probabilidad φ está bien definida en $[0,1)$ y es de clase $\mathcal{C}^\infty$. Además, se puede extender por continuidad a $[0,1]$ definiendo $\varphi(1) = 1$. Observamos también que $\varphi(s) = \mathbb{E}[s^\xi]$.

Definimos $g\colon [0,1] \to \mathbb{R}$ mediante $g(s) := \varphi(s) - s$. Entonces, basta ver que g tiene una única raíz en $[0,1)$. Para la existencia de una raíz $\rho \in [0,1)$, consideremos dos casos mutuamente excluyentes:

I. $\mathbb{P}(\xi = 0) = 0$. Entonces $g(0) = \varphi(0) - 0 = \mathbb{P}(\xi = 0) - 0 = 0$, luego $\rho = 0$ es un punto fijo de φ.

II. $\mathbb{P}(\xi = 0) > 0$. Entonces $g(0) = \varphi(0) - 0 = \mathbb{P}(\xi = 0) - 0 > 0$.

Como el enunciado indica que $\lim_{s\uparrow 1} \varphi'(s) = \mu > 1$, se sigue que

$$\lim_{s\uparrow 1} g'(s) = \lim_{s\uparrow 1} \varphi'(s) - 1 = \mu - 1 > 0.$$

Esto implica que existe un $\delta > 0$ tal que $\forall s \in (1-\delta, 1) : g'(s) > 0$, es decir, g es estrictamente creciente en $(1-\delta, 1)$. Como $g(1) = \varphi(1) - 1 = 0$, se sigue que $g(s) < 0$ para todo $s \in (1-\delta, 1)$. Así, podemos tomar $s_1 \in (1-\delta, 1) \subset (0,1)$ tal que $g(s_1) < 0$.

Como $g(0) > 0$, $g(s_1) < 0$ y g es continua en $[0,1]$, por el teorema de Bolzano, existe $\rho \in (0, s_1) \subset (0,1)$ tal que $g(\rho) = 0$.

Solo falta ver que ρ es único. Como $\mu := \mathbb{E}[\xi] = \sum_{j\geqslant 0} j \, \mathbb{P}(\xi = j) > 1$, existe $k \geqslant 2$ tal que $\mathbb{P}(\xi = k) > 0$ ya que, de lo contrario, tendríamos que

$$\mathbb{E}[\xi] = 0 \cdot \mathbb{P}(\xi = 0) + 1 \cdot \mathbb{P}(\xi = 1) = \mathbb{P}(\xi = 1) \leqslant 1.$$

Por lo tanto, al calcular la segunda derivada de φ, obtenemos que

$$\forall s \in (0,1) : \varphi''(s) = \sum_{j \geqslant 2} j(j-1)s^{j-2}\,\mathbb{P}(\xi = j) \geqslant k(k-1)s^{k-2}\,\mathbb{P}(\xi = k) > 0,$$

es decir, φ es estrictamente convexa en $[0,1]$. En consecuencia, g es estrictamente convexa en $[0,1]$. Por lo tanto, g puede tener como máximo dos raíces en $[0,1]$. Como $g(\rho) = 0$ con $\rho < 1$ y $g(1) = \varphi(1) - 1 = 0$, ρ es la única raíz de g en $[0,1)$.

(b) Veamos que $(Z_n)_{n\in\mathbb{N}}$ es una martingala respecto a $(\mathcal{F}_n)_{n\in\mathbb{N}}$.

(I) Para n fijo, $Z_n = \rho^{X_n}$ es $\mathcal{F}_n$-medible ya que X_n es $\mathcal{F}_n$-medible y $\rho^{(\cdot)}$ es continua.

(II) Como $\rho \in [0,1)$ y $X_n \geqslant 0$, se cumple que $\forall \omega \in \Omega : |Z_n(\omega)| = \rho^{X_n(\omega)} \leqslant 1$, luego Z_n es integrable.

(III) Fijamos $n \in \mathbb{N}$. Como X_n toma valores en $\mathbb{N} \cup \{0\}$, podemos escribir

$$Z_{n+1} = \sum_{k=0}^{\infty} \mathbb{1}_{\{X_n = k\}} Z_{n+1} = \sum_{k=0}^{\infty} \mathbb{1}_{\{X_n = k\}} \cdot \rho^{\sum_{j=1}^{k} \xi_j^{(n+1)}} = \sum_{k=0}^{\infty} \mathbb{1}_{\{X_n = k\}} \prod_{j=1}^{k} \rho^{\xi_j^{(n+1)}}.$$

Entonces, por la linealidad de la esperanza condicional y la medibilidad de $\mathbb{1}_{\{X_n=k\}}$ respecto a $\mathcal{F}_n$, obtenemos que

$$\mathbb{E}\left[Z_{n+1} \mid \mathcal{F}_n\right] = \sum_{k=0}^{\infty} \mathbb{E}\left[\mathbb{1}_{\{X_n=k\}} \prod_{j=1}^{k} \rho^{\xi_j^{(n+1)}} \,\middle|\, \mathcal{F}_n\right] = \sum_{k=0}^{\infty} \mathbb{1}_{\{X_n=k\}} \mathbb{E}\left[\prod_{j=1}^{k} \rho^{\xi_j^{(n+1)}} \,\middle|\, \mathcal{F}_n\right].$$

Como las $\{\xi_j^{(n+1)}\}_{j\in\mathbb{N}}$ son independientes de $\mathcal{F}_n$, las $\{\rho^{\xi_j^{(n+1)}}\}_{j\in\mathbb{N}}$ también lo son, luego su producto también lo es. Por lo tanto,

$$\mathbb{E}\left[Z_{n+1} \mid \mathcal{F}_n\right] = \sum_{k=0}^{\infty} \mathbb{1}_{\{X_n=k\}} \mathbb{E}\left[\prod_{j=1}^{k} \rho^{\xi_j^{(n+1)}}\right].$$

Como las $\xi_j^{(n+1)}$ son i.i.d. y ρ es un punto fijo de φ, obtenemos que

$$\mathbb{E}\left[\prod_{j=1}^{k} \rho^{\xi_j^{(n+1)}}\right] = \prod_{j=1}^{k} \mathbb{E}\left[\rho^{\xi_j^{(n+1)}}\right] = \prod_{j=1}^{k} \mathbb{E}\left[\rho^{\xi}\right] = (\varphi(\rho))^k = \rho^k.$$

Así, llegamos finalmente a que

$$\mathbb{E}\left[Z_{n+1} \mid \mathcal{F}_n\right] = \sum_{k=0}^{\infty} \mathbb{1}_{\{X_n=k\}}\, \rho^k = \rho^{X_n} = Z_n.$$

Por tanto, $(Z_n)_{n\in\mathbb{N}}$ es una martingala respecto a $(\mathcal{F}_n)_{n\in\mathbb{N}}$. Como para cada $n \in \mathbb{N}$, $\mathbb{E}\left[Z_n\right] \leqslant 1$, por el teorema de convergencia de martingalas, obtenemos que Z_n converge c.s. a una variable aleatoria Z_∞ integrable. Además, como $\forall n \in \mathbb{N} : Z_n \in [0,1]$, se sigue que $Z_\infty \in$

$[0,1]$ c.s.

Es decir, $\exists A \in \mathcal{F} : \mathbb{P}(A) = 0 \ \wedge \ \forall \omega \in A^{\mathsf{c}} : Z_n(\omega) \xrightarrow[n\to\infty]{} Z_\infty(\omega)$. Por tanto,

$$\mathbb{E}\left[Z_\infty\right] = \int_\Omega Z_\infty \, \mathrm{d}\mathbb{P} = \int_{A^{\mathsf{c}}} Z_\infty \, \mathrm{d}\mathbb{P} = \int_{A^{\mathsf{c}}} \lim_{n\to\infty} Z_n \, \mathrm{d}\mathbb{P}.$$

Como $\forall n \in \mathbb{N} : Z_n \in [0,1]$, por el teorema de convergencia dominada, obtenemos que

$$\mathbb{E}\left[Z_\infty\right] = \int_{A^{\mathsf{c}}} \lim_{n\to\infty} Z_n \, \mathrm{d}\mathbb{P} = \lim_{n\to\infty} \int_{A^{\mathsf{c}}} Z_n \, \mathrm{d}\mathbb{P} = \lim_{n\to\infty} \int_\Omega Z_n \, \mathrm{d}\mathbb{P} = \lim_{n\to\infty} \mathbb{E}\left[Z_n\right].$$

Ahora bien, como $(Z_n)_{n\in\mathbb{N}}$ es una martingala, la esperanza se mantiene constante:

$$\forall n \in \mathbb{N} : \mathbb{E}\left[Z_n\right] = \mathbb{E}\left[Z_0\right] = \mathbb{E}\left[\rho^{X_0}\right] = \mathbb{E}\left[\rho^x\right] = \rho^x.$$

Así que $\mathbb{E}\left[Z_\infty\right] = \lim_{n\to\infty} \mathbb{E}\left[Z_n\right] = \rho^x$.

Para ver que $Z_\infty \in \{0,1\}$ c.s., definimos $E = \bigcup_{n=0}^{\infty} \{\omega \in A^{\mathsf{c}} : X_n(\omega) = 0\}$ y consideramos dos casos mutuamente excluyentes para $\omega \in A^{\mathsf{c}}$:

I. Si $\omega \in E$, entonces existe $n_0 \in \mathbb{N}$ tal que $X_{n_0}(\omega) = 0$. Como $X_n = 0 \implies X_{n+1} = 0$, se sigue que $\forall n \geqslant n_0 : X_n(\omega) = 0$. Por lo tanto,

$$Z_\infty(\omega) = \lim_{n\to\infty} Z_n(\omega) = \lim_{n\to\infty} \rho^{X_n(\omega)} = \lim_{n\to\infty} \rho^0 = 1.$$

II. Si $\omega \in E^{\mathsf{c}}$, entonces $X_n(\omega) > 0$ para todo $n \in \mathbb{N}_0$. Dado que $Z_n(\omega) = \rho^{X_n(\omega)} \in \{\rho^k : k \in \mathbb{N}\}$, los únicos posibles puntos de acumulación de $(Z_n(\omega))_{n\in\mathbb{N}_0}$ en $[0,1]$ son $\{0\} \cup \{\rho^k : k \in \mathbb{N}\}$. Por consiguiente, $Z_\infty(\omega) \in \{0\} \cup \{\rho^k : k \in \mathbb{N}\}$.

Fijemos $k \in \mathbb{N}$. Como ρ^k es un punto aislado de $\{\rho^k : k \in \mathbb{N}\}$, la convergencia $Z_n(\omega) \xrightarrow{n\to\infty} \rho^k$ exige que $X_n(\omega) = k$ para todo n suficientemente grande. Así,

$$\left\{\omega \in A^{\mathsf{c}} : Z_\infty(\omega) = \rho^k\right\} \subset \bigcup_{N=1}^{\infty} \bigcap_{n=N}^{\infty} \{X_n = k\}.$$

Como ya vimos en el paso 4 de la solución del ejercicio E.2.3, por la independencia de las familias de descendencia entre distintas generaciones, para todo $N, m \in \mathbb{N}$:

$$\mathbb{P}\left(\bigcap_{n=N}^{N+m} \{X_n = k\}\right) = \mathbb{P}(X_N = k) \prod_{r=1}^{m} \mathbb{P}\left(\sum_{j=1}^{k} \xi_j^{(N+r)} = k\right) = \mathbb{P}(X_N = k) \cdot (p_k)^m,$$

donde $p_k := \mathbb{P}\left(\sum_{j=1}^{k} \xi_j = k\right)$. Si fuera $p_k = 1$, la variable aleatoria $S_k = \sum_{j=1}^{k} \xi_j$ sería constantemente k c.s., por lo que su función generatriz verificaría $\mathbb{E}[s^{S_k}] = s^k$ para todo $s \in [0,1]$. Por otra parte, por la independencia de las variables ξ_j, se tiene que $\mathbb{E}[s^{S_k}] = (\varphi(s))^k$. Igualando ambas expresiones, tendríamos que $\varphi(s) = s$ para todo

$s \in [0,1]$, lo que contradice el apartado (a) ya que φ tiene un único punto fijo en $[0,1)$. Por tanto, $p_k < 1$.

Haciendo $m \to \infty$, obtenemos que $\mathbb{P}\left(\bigcap_{n=N}^{\infty}\{X_n = k\}\right) = 0$ para todo $N \in \mathbb{N}$, de donde $\mathbb{P}(Z_\infty = \rho^k) = 0$ para todo $k \geq 1$.

Concluimos que $\mathbb{P}(Z_\infty \notin \{0,1\}) = \sum_{k=1}^{\infty} \mathbb{P}(Z_\infty = \rho^k) = 0$, por lo que $Z_\infty = 0$ en E^{c} c.s.

Por tanto, $\forall \omega \in A^{\mathsf{c}} : Z_\infty(\omega) \in \{0,1\}$, es decir, $Z_\infty \in \{0,1\}$ c.s.

(c) Consideremos el evento de extinción de la población $E = \bigcup_{n=1}^{\infty}\{X_n = 0\}$.

Por lo demostrado en el apartado (b), la variable aleatoria límite Z_∞ sólo toma valores en $\{0,1\}$ c.s. En particular, $Z_\infty(\omega) = 1$ para todo $\omega \in E$ c.s., y $Z_\infty(\omega) = 0$ para todo $\omega \in E^{\mathsf{c}}$ c.s. Por consiguiente, $Z_\infty = \mathbb{1}_E$ c.s.

Tomando esperanzas a ambos lados de la igualdad y utilizando que, por el apartado (b), $\mathbb{E}[Z_\infty] = \rho^x$, llegamos a que

$$\mathbb{P}(\exists n \in \mathbb{N} : X_n = 0) = \mathbb{P}(E) = \mathbb{E}[\mathbb{1}_E] = \mathbb{E}[Z_\infty] = \rho^x.$$

Como $\rho < 1$ y $x \geqslant 1$, tenemos que $\rho^x < 1$. Por lo tanto, $\mathbb{P}(\exists n \in \mathbb{N} : X_n = 0) = \rho^x < 1$.

Así, por el apartado (c), obtenemos que

$$\mathbb{P}(\forall n \in \mathbb{N} : X_n > 0) = 1 - \mathbb{P}(\exists n \in \mathbb{N} : X_n = 0) = 1 - \rho^x > 0.$$

■